


Идентификация людей в реальном времени — на ноутбуке, без интернета, с 2023 года.

Narrow AI — модель решает одну задачу (обнаружение людей в кадре) и больше ничего.

На экране — **YOLOv8** на CPU ноутбука: **~30 fps**.
Без интернета · обучена в 2023.



Кадр модели в момент демо: 2 человека в боксах. YOLOv8 (Ultralytics, 2023).

Добро пожаловать на курс
«Отраслевое применение систем
искусственного интеллекта»

17 лекций о том, где AI работает в индустриях — и где нет.

Главный вопрос курса — не «можно ли AI?», а «нужно ли и где?».

100% AI-пилотов запускаются

–90% откатываются

**10% доходят
до прода**

Иллюстрация принципа (Gartner, McKinsey подтверждают похожие цифры).

Главная мысль курса

**Завтра — почти везде.
Сегодня — почти никто.
Курс — про этот разрыв.**


Центральный вопрос курса

**Где AI работает,
где — нет,
и как это понять?**

ЛЕКЦИЯ

Что такое AI? История, классификация, общие понятия

Карта применений AI: где работает, где — нет.



План лекции

0

Введение

*Демо · инструктор ·
центральный
вопрос*

1

Что такое AI

*Определения,
история, перелом*

2

Где мы сейчас

*Цифры рынка
2022-2026*

3

4 способа реализации

*Модель · чат ·
агент · приложение*

4

Границы и безопасность

*Что AI ломает
и где не работает*

5

Заключение

*Резюме · карта
семестра*



**Левко Максим
Николаевич**



Telegram

@Maxim_Levko



Email

Levko.maxim@gmail.com

Кто я и почему мне это важно.

**Архитектор, технический и продуктовый лидер создания
и внедрения информационных систем**



20+ лет опыта в ИТ

*10+ завершённых проектов
под руководством*



Экспертиза

*Системный анализ · Проектирование систем ·
Управление данными · Автоматизация бизнеса ·
Управление продуктами*

Консалтинг и inhouse



Yandex



МТС



Магнит



Сибур

Раздел 1 · Что такое AI

Определения, история, классификация.

0

Введение

*Демо · инструктор ·
центральный вопрос*

1

Что такое AI

*Определения,
история, перелом*

2

**Где мы
сейчас**

*Цифры рынка
2022-2026*

3

**Четыре
способа
реализации**

*Модель · чат ·
агент · приложение*

4

**Границы
и безопасность**

*Что AI ломает
и где не работает*

5

Заключение

*Резюме ·
карта семестра*

Определений AI много — потому что AI это движущаяся цель.

Russell & Norvig (AIMA, 2021)

«AI = система, мыслящая как человек, мыслящая рационально, действующая как человек или действующая рационально (4 квадранта по 2 осям).»

Russell & Norvig, AIMA, 4-е изд., 2021

ISO/IEC 22989:2022

«AI-система — это engineered system, которая генерирует выходы (рекомендации, прогнозы, решения) для целей, заданных человеком.»

Международный стандарт ISO/IEC 22989:2022 — опора EU AI Act

Через обучение (Mitchell, 1997)

«Программа улучшается с опытом E на задаче T по метрике P. Если поведение возникает из обученной модели — это AI.»

Mitchell, Machine Learning, 1997

Через бенчмарки и AGI

«AI = то, что проходит тест Тьюринга или решает бенчмарк на уровне человека.» Возражение Сёрла: поведение ≠ понимание.

Тьюринг 1950 / Searle 1980 — Chinese Room

AI Effect (Tesler): «AI is whatever hasn't been done yet». Как только техника начинает работать, её перестают называть AI.

Идея нейросети старше самого термина «искусственный интеллект» на 13 лет.

1943

*Мак-Каллок и Питтс:
формальный нейрон
как логический элемент*

13 лет

1956

*Дартмутская конференция:
термин «artificial intelligence»*

Формальный нейрон не решал прикладных задач, но предвосхитил коннекционистскую традицию — линию мысли, из которой десятилетия спустя вырастут нейросети и Трансформер.

Идея «нейросети» на теоретическом уровне старше самого термина «искусственный интеллект».

70 лет AI: открытия, зимы, точка перелома 2017.



★ 2017 — Vaswani и 7 соавторов (Shazeer, Parmar, Uszkoreit, Jones, Gomez, Kaiser, Polosukhin) вводят механизм self-attention — основу всех современных LLM. На май 2026 у статьи свыше 160 000 цитирований.

Раздел 2 · Где мы сейчас

AI как инфраструктура, прорывы 2023-2026.

0

Введение

*Демо · инструктор ·
центральный вопрос*

1

Что такое AI

*Определения,
история, перелом*

2

**Где мы
сейчас**

*Цифры рынка
2022-2026*

3

**Четыре
способа
реализации**

*Модель · чат ·
агент · приложение*

4

**Границы
и безопасность**

*Что AI ломает
и где не работает*

5

Заключение

*Резюме ·
карта семестра*

AI стал инфраструктурой за 3 года: 900М пользователей, 51% разработчиков ежедневно, 46% Copilot-кода.

900M



WAU

ChatGPT, февраль 2026

OpenAI

51%



ежедневно

Stack Overflow Dev Survey 2025

n=49k+, 177 стран

46%

кода у Copilot

GitHub Octoverse 2025

Java — 61%

\$390.9B→\$539.5B



AI-рынок 2025→2026

Grand View Research, 2026

Statista (software-only): ~\$244-260B

Контр-факт: ~90% AI-пилотов в РФ не доходят до прода. CNews / Vedomosti / Intellectual Analytics, март 2026.

Пространство открыто: 4 прорыва 2023–2026 от первых игроков.

сентябрь 2023	январь 2025	ноябрь 2025	февраль 2026
Mistral 7B	DeepSeek R1	OpenClaw	Llama.cpp
Apache 2.0 обходит Llama-2 13B	\$589B Nvidia drop за день	100K★ stars за квартал	100K+★ на GitHub быстрее PyTorch
<i>Mistral AI (FR)</i>	<i>DeepSeek (CN)</i>	<i>P. Steinberger</i>	<i>G. Gerganov / ggml.ai</i>

Не отчаивайтесь: серьёзные прорывы делают разные команды. Курс — про устойчивые концепты, переживающие смену поколений моделей.

Раздел 3 · Четыре способа реализации систем с AI

Не альтернативы, а слои.

0

Введение

*Демо · инструктор ·
центральный вопрос*

1

Что такое AI

*Определения,
история, перелом*

2

**Где мы
сейчас**

*Цифры рынка
2022-2026*

3

**Четыре
способа
реализации**

*Модель · чат ·
агент · приложение*

4

**Границы
и безопасность**

*Что AI ломает
и где не работает*

5

Заключение

*Резюме ·
карта семестра*

Способы реализации систем с AI: не альтернативы, а слои.

Каждый следующий слой
включает предыдущий

Не четыре альтернативные технологии, а четыре способа реализации одной задачи. Каждое следующее обёртывание добавляет способности — и сложность, стоимость, потенциал ошибок.

Выбор слоя — инженерное решение, не альтернатива.

Приложение

+ AI внутри продукта · формы, кнопки, интеграции

Агент

+ инструменты (API, поиск, код) · планирование · vector DB

Чат

+ UI диалога · память истории сообщений

Модель

stateless: вход → модель → выход

Классификация AI-систем — две оси: тип задачи × модальность.

	 Классиф.	 Распозн.	 Поиск	 Генерац.	 Прогноз
Текст	BERT, спам	spaCy NER	BM25	GPT-4o, Claude	GPT-4o, Claude
Изображ.	ResNet	YOLO	CLIP	DALL-E, MJ	frame predict
Звук / видео	PANNs	Whisper	Shazam	ElevenLabs, Sora	video forecast
Структ. данные	XGBoost	OCR таблиц	vector DB	Codex tab.	Prophet, ARIMA

YOLO — детекция объектов из демо в начале лекции. Подход к обучению и архитектура — позже в курсе.

Одна задача, три способа: контроль распределяется между разработчиком и пользователем.



Одна и та же задача

Извлечь поля из входящего PDF-договора:

- дата подписания
- контрагент
- сумма
- срок действия

и положить в таблицу.

Распределение контроля — инженерное решение, а не достоинство одного способа над другим.

МОДЕЛЬ

Модель — компонент, не система. Inference: вход → препроцессинг → модель → постпроцессинг → выход.

Это уже приложение



YOLOv8

детекция на изображениях

Whisper

распознавание речи

Stable Diffusion

генерация изображений

AlphaFold

прогноз структур белков

Препроцессинг и постпроцессинг — ответственность разработчика. YOLO = 50 строк; рабочая система с YOLO = сотни строк.

Как работает чат: цикл диалога.



Контроль через системный промпт. Промпт задаёт роль, ограничения, формат. Один и тот же чат настраивается под разные сценарии — это инженерный рычаг разработчика.

Ограничение — контекстное окно. 128k-1M токенов; когда история перестаёт помещаться, старые сообщения выпадают и чат «забывает» начало длинного разговора. Это ограничение модели, не баг.

Чат — это конвейер «собрать → подать → дописать → показать».

Чат = модель + интерфейс + память диалога.

Кейс — типовой для чата

Инженер получил непонятное ТЗ от смежного отдела, нужно составить чек-лист своей работы.

Вы: Объясни пункт 4.2 ТЗ простыми словами.

Чат: Это требование к...

Вы: Составь чек-лист на 5 пунктов.

Чат: 1. Проверить... 2. Согласовать... 3. ...

Разовая задача с уточнениями — оптимально для чата. Не модель, не агент, не приложение.

Оговорка для промышленных систем

Чистые чаты почти не используются в промышленной эксплуатации.

Почти везде они расширены до агентов — хотя бы для долгосрочной памяти и поиска по корпоративной базе (RAG).

Архитектуру агента разберём на следующем слайде.

Выбор чата — точка на шкале взаимодействия, не единственно верный вариант.

Агент = чат + оркестратор + внешняя память + инструменты.



Агент за работой: 200 PDF — последовательность шагов.

Кейс — типовой для агента

200 PDF-отчётов.
Извлечь дату, контрагента,
сумму.
Собрать сводную таблицу.

Не модель — нет специализированной модели «возьми 200 произвольных PDF».

Не чат — некомфортно копировать 200 файлов в окно.

Агент — естественный выбор.

Что делает агент — пошагово, с указанием инструмента

- | | | |
|---|----------------------------|-------------------------------------|
| 1 | Получить список файлов | файловая система |
| 2 | Открыть PDF #1 | чтение PDF |
| 3 | Извлечь текст | извлечение текста (OCR / парсер) |
| 4 | Сделать сводку → vector DB | эмбединги + векторная БД |
| 5 | Найти ключевые поля | поиск + извлечение LLM |
| 6 | Записать строку в таблицу | запись в таблицу (Sheets API / CSV) |
| 7 | Цикл по всем 200 файлам | цикл оркестратора |

Агент = последовательность вызовов инструментов, оркестрируемая LLM.

Уровни автономии AI-агентов: дизайн-решение, не свойство модели.

5 уровней автономии (Feng / McDonald / Zhang, 2025)

5. Наблюдатель (Observer)

Пользователь: только получает результат

AutoGPT на ночь

4. Утверждающий (Approver)

Пользователь: утверждает на контрольных точках

агент собирает PR, ждёт review

3. Консультант (Consultant)

Пользователь: ставит цель, правит план

Devin фиксирует баг по тикету

2. Соавтор (Collaborator)

Пользователь: работает наравне с агентом

Cursor парное программирование

1. Оператор (Operator)

Пользователь: одобряет каждое действие

Claude Code «approve each»

Где находится человек по отношению к циклу

Человек вне цикла (Human-out-of-the-loop)

Человек только смотрит итог ($\approx$ ур. 5).

Человек над циклом (Human-on-the-loop)

Человек наблюдает, прерывает при отклонениях ($\approx$ ур. 3-4).

Человек в цикле (Human-in-the-loop)

Человек одобряет каждый шаг ($\approx$ ур. 1-2).

Режимы ручного перехвата (Override)

Любой уровень — с ручным перехватом по тревоге.

Уровень автономии — выбор продукта, не свойство модели. На семинарах будем выбирать осознанно.

Приложение = AI, упакованный в продуктовый интерфейс.

Google Translate — масштаб 2026

1+ миллиард пользователей в месяц · **1 триллион** слов переведено / месяц

в Google Translate, Search, Lens и Circle to Search (Google Blog, апрель 2026)



Google Translate

нейронная трансляция



Notion AI

GPT-4/Claude в кнопках



ЯндексGPT в Поиске

AI-краткий ответ



Grammarly

NLP + LLM подсказки



Яндекс.Карты

ML маршрутизация



Adobe Firefly

диффузия в Photoshop

AI как функция, а не продукт. Большинство студентов уже ежедневно пользуются всеми шестью.

Чек-лист «Какой тип AI выбрать»: 2 вопроса + квадрант 2×2.



Раздел 4 · Границы AI — ваша зона

ОТВЕТСТВЕННОСТИ

Куда уходят данные · ошибки AI · «не умеет» — тоже ваше.

0

Введение

*Демо · инструктор ·
центральный вопрос*

1

Что такое AI

*Определения,
история, перелом*

2

**Где мы
сейчас**

*Цифры рынка
2022-2026*

3

**Четыре
способа
реализации**

*Модель · чат ·
агент · приложение*

4

**Границы
и безопасность**

*Что AI ломает
и где не работает*

5

Заключение

*Резюме ·
карта семестра*

Потребительские vs корпоративные тарифы — куда уходят ваши данные.

От общей зоны ответственности — к первому конкретному риску: данные.

ПОТРЕБИТЕЛЬСКИЕ ТАРИФЫ

данные → обучение по умолчанию

- ChatGPT Free / Plus — обучение по умолчанию
- Anthropic Claude (с сент. 2025) — по согласию, 5 лет хранение
- Gemini Free — обучение + проверка людьми, 3 года
- YandexGPT Free — стандартная политика

КОРПОРАТИВНЫЕ ТАРИФЫ / API

данные ≠ обучение

- ChatGPT Enterprise / Business — без обучения на данных
- OpenAI API (с марта 2023) — без обучения на данных
- Anthropic for Business — нулевое хранение данных доступно
- Google Workspace / Vertex AI — без обучения на данных

Samsung 2023 — канонический инцидент

3 эпизода за месяц (март-апрель): код, транскрипт совещания, тестовые последовательности → попали в датасет OpenAI. Самсунг ввёл запрет внешнего GenAI.

EU AI Act — штрафы

до 15M € / 3% оборота

до 35M € / 7% — за запрещённые практики

Галлюцинации — неотъемлемое свойство AI.

Промпт

«Назови три статьи 2023-2024 по теме "сейсмостойкость подземных трубопроводов" с авторами, журналом и DOI».

Ответ AI (3 фейк-ссылки):

Petrov A., Smith J. (2023).

Seismic Resilience of Small-Diameter Pipelines.

DOI: 10.1016/j.engfailanal.2023.107214 ✗

Ivanov K. et al. (2024).

Underground Infrastructure Earthquake Response.

DOI: 10.1080/15732479.2024.2218450 ✗

Chen L., Brown R. (2023).

Microscale Pipe Vibration Analysis.

DOI: 10.1007/s11069-023-06122-1 ✗

Vectara ННЕМ (2025-26)

процент галлюцинаций

< 1%

суммаризация (Gemini 2.0 Flash)

10-15%

reasoning (многошаговое)

Анти-паттерн: «AI знает всё». Любой ответ AI по фактическому вопросу — гипотеза для проверки.

Смещение, лесть, дрейф распределения — три проявления одной природы.



Смещение (bias)

Модель повторяет перекосы датасета.

Скрининг резюме обучен на исторических данных — дискриминирует, не «решая», а статистически.



Лесть (sycophancy)

Модель учится у разметки обратной связи поддакивать.

Соглашается с явно неверным, чрезмерно хвалит — пользователь не замечает потери критики.



Дрейф распределения (distribution shift)

Данные периода — устаревают.

Модель на коде 2023 в 2026 предложит устаревшую библиотеку без явного сбоя.

GPT-4o: лесть (sycophancy) — апрель 2025

25 апр — релиз обновления → **28 апр** — начало отката (Альтман в соцсети тем же вечером) → **29 апр** — разбор причин

Общая причина: модель отражает данные, на которых обучена.

Прогнозы AGI — 4 спикера, 4 разных стимула.

Спикер	Аффилиация	Прогноз AGI	Материальный интерес
Sam Altman	OpenAI	«Знаем как построить AGI; начало superintelligence» (январь 2026)	\$100B+ раунды; контекст IPO
Dario Amodei	Anthropic	«AGI через 2–3 года; нобелевский уровень за 2 года» (Давос 2026)	Конкуренция с OpenAI; раунд 2026
Demis Hassabis	Google DeepMind	«AGI к 2029–2030 (3–4 года); окно сузилось за 2026 год» (Axios/Google I/O, май 2026)	Лидер community; больше доверия при осторожной позиции
Yann LeCun	AMI Labs (экс-Meta)	«LLM не приведут к AGI; нужны world models, JEPA»	Раунд \$1B (март 2026) на альтернативный путь

Раздел 5 · Что забрать домой

Резюме · карта семестра · тизер лекции 2.

0

Введение

*Демо · инструктор ·
центральный вопрос*

1

Что такое AI

*Определения,
история, перелом*

2

**Где мы
сейчас**

*Цифры рынка
2022-2026*

3

**Четыре
способа
реализации**

*Модель · чат ·
агент · приложение*

4

**Границы
и безопасность**

*Что AI ломает
и где не работает*

5

Заключение

*Резюме ·
карта семестра*

Что мы прошли: три главных вывода.

1 AI — спектр, не монолит

Тип задачи x модальность x тип реализации.

Грамотное обсуждение начинается с явной классификации.

2 Выбор типа AI — навык

2 диагностических вопроса + квадрант 2x2.

Инструмент, который вы применяете на семинарах.

3 Целеполагание у человека

Все классы ошибок требуют человеческого контура.

Граница «AI / не-AI» — ваша инженерная зона.

Главный вопрос лекции: где AI работает, где — нет, и как это понять?

Карта семестра: 17 лекций, 3 модуля + экзамен.

Модуль 1	Модуль 2	Модуль 3	Экзамен
<i>Теор.-метод. основы + знакомые индустрии</i>	<i>Инж. проектирование, тяж. промышленность, АПК</i>	<i>Инфраструктура, наука, добыча, синтез</i>	<i>Итоговая аттестация</i>
1.1 Введение	2.1 CAD/CAM	3.1 Логистика	Экзамен
1.2 Архитектура AI	2.2 Авиакосмос / ОПК	3.2 Телеком / cybersec	
1.3 Агенты, RAG, API	2.3 Производство	3.3 Наука	
1.4 Разработка ПО	2.4 Цифровые двойники	3.4 Нефтегаз	
1.5 Финансы / ритейл	2.5 Сельское хоз-во ♦PK2	3.5 Медицина	
1.6 Креативные ♦PK1		3.6 Синтез ♦PK3	

♦ — рубежные контроли PK1/PK2/PK3, по завершении каждого из первых трёх модулей.

Оценка за семестр

$$100 = 10_{\text{(посещаемость)}} + 30_{\text{(экзамен)}} + 3 \times 20_{\text{(PK1/PK2/PK3)}}$$


Рубежные контроли — по завершении каждого из первых трёх модулей.

Лекция 2: «Как работают современные большие модели».



Токены

единицы, на которые модель режет текст



Эмбединги

(векторные представления) — адреса в смысловом пространстве



Внимание

(attention) — на какие части входа смотреть



Температура

случайность выбора следующего токена

Эти 4 концепта объясняют поведение всех современных LLM — от ChatGPT до DeepSeek.

Вопросы?

Спасибо