

**temperature=0 — значит, ответ
всегда одинаковый?**



Да, формально детерминирован. Но нет — на практике нет. Почему — сегодня.

1/47


Простой вопрос на разогрев: если поставить temperature на ноль, ответ модели на один и тот же запрос будет каждый раз одинаковым? Интуиция подсказывает «да» — ноль случайности, выбор самого вероятного токена, что тут может пойти не так. И интуиция почти права. Почти — потому что «почти» на инженерной практике стоит денег: тесты, которые полагаются на побитовую воспроизводимость при $T=0$, время от времени необъяснимо падают, а причина не в вашем коде. Сегодня разберём, откуда берётся это «но нет» — и ещё несколько похожих мест, где интуиция про модели работает в девяти случаях из десяти, а в десятом ломается предсказуемым и объяснимым образом. Идём по конвейеру инференса от текста до ответа — и на каждой стадии посмотрим, где основанная на наблюдениях интуиция перестаёт быть надёжной картой.

ЛЕКЦИЯ 2

Как работают современные большие модели

02

Конвейер инференса — и границы, которые меняют инженерные решения



2/47

Это вторая лекция курса. Сегодня мы рассмотрим, как работает большая языковая модель изнутри: систематизируем устройство конвейера и разберём тонкости, которые напрямую влияют на инженерные решения. Кто работает с моделями ежедневно — освежит основы и узнает тонкости; кто встречается эти понятия впервые — узнает всё необходимое. Каркас лекции — конвейер инференса: путь одного запроса от текста до ответа. Текст режется на токены, токены превращаются в векторы, механизм внимания решает, какие части контекста важны, из распределения вероятностей выбирается очередной токен — и цикл повторяется. Четыре стадии — четыре раздела; пятый раздел — новый в этой версии курса — разбирает виды и размеры моделей: на чём они запускаются и что умеют; шестой раздел собирает конвейер целиком и подводит итоги. Двинемся по карте.

Карта лекции — 7 разделов

- 0 Введение** — *рамка и конвейер целиком*
- 1 Токенизация** — *как модель видит ваш текст*
- 2 Эмбединги** — *пространство смыслов и граница похожести*
- 3 Механизм внимания** — *что важно сейчас: роли, кэш, длинный контекст*
- 4 Сэмплинг** — *от распределения к токену: температура, детерминизм, невидимые токены*
- 5 Виды и размеры моделей** — *на чём модели запускаются, мультимодальность, ландшафт 2026*
- 6 Финал** — *сборка конвейера, итоги механизмов*

3/47

Короткая карта маршрута, прежде чем погружаться. Лекция идёт вдоль конвейера инференса: порядок разделов повторяет порядок стадий, через которые проходит каждый ваш запрос. Раздел 1 — токенизация: как модель видит текст, почему «исправленный» strawberry ничего не доказывает, откуда берутся числа-чанки и glitch-токены. Раздел 2 — эмбединги: пространство смыслов, три разные вещи, которые называют одним словом «эмбединг», и граница, на которой семантическая похожесть перестаёт означать полезность. Раздел 3 — механизм внимания: почему промпт с ролью реально меняет ответ; откуда берётся экономика кэширования; что на самом деле умеет окно в миллион токенов. Раздел 4 — сэмплинг: температура, причина, по которой $T=0$ не даёт детерминизма, структурированный вывод и невидимые токены рассуждения, которые вы оплачиваете. Раздел 5 — новый в этой версии курса: виды и размеры моделей — на чём запускается маленькая модель, а на чём гигант, что каждый класс умеет по мультимодальности, и ландшафт конкретных моделей на сентябрь 2026 года. Раздел 6 — финал: конвейер целиком и сводка разобранных механизмов. Держите карту в голове — она не даст потеряться в деталях.

Объект сегодня — слой «модель» из четырёх слоёв Лекции 1



Слой «модель»: stateless-инференс — на вход данные, на выход предсказание, без памяти между вызовами.

Сегодня: разбираем, что происходит внутри этого инференса — и где его устройство меняет инженерные решения.

4/47

Объект сегодняшнего разговора — слой «модель». Лекция 1 дала слоистую картину: внизу модель, над ней цикл чата с системным промптом и историей, над чатом — агентный цикл, сверху — приложение. Модель там описана как stateless-инференс: на вход данные, на выход предсказание, без памяти между вызовами. Оттуда же у нас есть контекстное окно как ограничение, различие локальных и облачных моделей и три уровня причинности Пёрла — всё это сегодня считается известным и используется без повторного вывода. С этим описанием мы умеем говорить о том, где модель находится в большей системе. Но вопрос «что именно происходит внутри этой функции между запросом и ответом» Лекция 1 сознательно оставила чёрным ящиком. Сегодня мы этот ящик разбираем — и всё, что произойдёт на этой лекции, происходит внутри одного-единственного слоя, нижнего. Чат, агенты, RAG и приложения строятся поверх и обсуждаются в Лекции 3 и дальше. Мы идём за границами: в каких местах внутреннее устройство модели меняет то, как вы строите промпты, агентов и решения. Каждый механизм в лекции выбран потому, что у него есть наблюдаемое инженерное следствие — в стоимости, скорости, качестве или воспроизводимости.

Цель лекции

«Рассмотреть, как работает языковая модель, — и разобраться с **важными деталями**, которые меняют то, как вы строите промпты, агентов и решения.»

почему исправленный strawberry ничего не доказывает

почему промпт с ролью реально меняет ответ

что на деле умеет окно 1M

почему $T=0$ не даёт одинаковых ответов

сколько стоят невидимые токены рассуждения

маленькая модель или гигант — по какому критерию выбирать

чем заменить веру в бенчмарки

5/47

Цель лекции: рассмотреть, как работает языковая модель, — и разобраться с важными деталями, которые меняют то, как вы строите промпты, агентов и решения. Мы пройдём конвейер инференса от текста до ответа, и на каждой стадии — вместе с механизмом — покажем его границы. Мы покажем, где именно токенизация ломает арифметику и почему «исправленный» strawberry ничего не доказывает. Покажем механизм, из-за которого роль в промпте реально меняет ответ. Разберём, почему $temperature=0$ не даёт воспроизводимости и сколько стоит её получить по-настоящему. Добавим к этому реальную цену невидимых токенов рассуждения, критерий выбора между маленькой моделью и гигантом — и то, чем заменить веру в бенчмарки при выборе модели. Семь строк под целью — по одной на каждый раздел, который сегодня пройдём: на каждую к концу лекции будет ответ через конкретный механизм, а не через интуицию. Если по ходу покажется, что какой-то механизм не влияет на практику, — ловите меня на слове: таких мы сегодня не разбираем.

Поток данных в LLM — туда и обратно



6/47


Это опорная схема всей лекции — конвейер инференса, путь одного запроса от текста до ответа. Посмотрим на него целиком, до первого погружения; дальше мы будем возвращаться к нему на входе в каждый раздел. Слева — ваш текст. Первое преобразование — токенизация: текст режется на токены, идентификаторы из словаря модели; это Раздел 1. Дальше каждый токен превращается в вектор — список чисел, с которыми нейросеть умеет считать; это Раздел 2. В центре — сама модель: механизм внимания решает, какие части контекста важны для следующего шага; это Раздел 3. На выходе модель выдаёт не ответ, а распределение вероятностей по всему словарю; из него выбирается один очередной токен, он приклеивается к контексту — и цикл повторяется; это Раздел 4. Последний шаг — выбранные токены собираются обратно в текст. Главное наблюдение: слова существуют только на границах конвейера — на входе и на выходе. Всё внутри — операции над векторами. И обратите внимание на петлю в схеме: токены генерируются по одному, каждый выбранный токен добавляется ко входу — и конвейер прокручивается заново; ответ строится последовательными оборотами этой петли. Эта ось — не только про сегодня. Все последующие лекции курса лягут на неё же: RAG — это управление тем, что попадает в контекст до конвейера; агенты — цикл вокруг конвейера; оптимизация стоимости — экономика конвейера. Сегодняшняя лекция движется по этой же оси — каждый раздел раскрывает свой участок конвейера вместе с границами применимости.

Раздел 1

Токенизация

«Как модель видит ваш текст»

3 разбора · 3 провала



7/47

Входим в первую стадию конвейера — токенизацию. Это самый ближний к вам слой: именно с ним сталкивается текст, как только вы нажимаете «отправить». Текст не попадает в модель ни буквами, ни словами — он режется на токены, статистически частые подпоследовательности из словаря модели. Определение токена вы знаете, поэтому базу мы пройдем быстро и точно — она нужна как общий фундамент. Основное время раздела уйдет на второй этаж: места, где частотная нарезка расходится со структурой ваших данных. Посмотрим на диагноз 2026 года по классическому мему про подсчет букв: что именно доказывает модель, которая проходит strawberry и ошибается на cranberry. Увидим, что токенизатор делает с числами и кодом и почему это ломает арифметику. Познакомимся с glitch-токенами — недообученными углами словаря, которые никуда не делись и в современных моделях. И закроем раздел экономикой: сколько стоит один и тот же текст на разных языках и что с этим делать при настройке лимитов. Общий принцип раздела: у каждой странности токенизации есть механизм, а у механизма — проверяемое инженерное следствие.

Токен — id из словаря модели: не буква и не слово

cat → [cat] → 1 токен

tokenization → [token][ization] → 2 токена

клубника → [к][луб][ника] → 3 токена (o200k_base)

«В среднем: 1 токен ≈ 4 символа EN ≈ 2 символа RU»

Словарь и модель — два разных артефакта: словарь строится до обучения модели, отдельным алгоритмом на своём корпусе.

8/47

Точное определение. Токен — это идентификатор, целое число из словаря модели; словарь зафиксирован при обучении и не меняется в момент использования. Токен — не буква и не слово, а статистически частая подпоследовательность символов, выученная на корпусе. Частое английское `cat` попадает в словарь целиком; `tokenization` распадается на два токена; `клубника` — на три в том же словаре o200k_base. Размер словаря у современных моделей — порядка сотен тысяч записей: около 200 тысяч у семейства GPT-4o и новее, около 100 тысяч у предыдущих поколений, 128 256 у Llama 3 и новее. Рабочий ориентир стоимости: один токен — примерно четыре символа английского и примерно два символа русского текста. Одно уточнение, которое часто теряется: словарь и модель — два разных артефакта. Словарь строится отдельным алгоритмом на своём корпусе до обучения модели; модель потом учится работать с этим словарём на своём корпусе. Эта развязка — источник целого класса эффектов, к которым мы вернёмся в этом разделе. И ответ на резонный вопрос «почему не работать посимвольно»: экономика длины. Посимвольное представление удлиняет вход в три-пять раз, а стоимость внимания растёт с длиной квадратично — вчетверо длиннее вход означает в шестнадцать раз дороже слой внимания. Токенизация со всеми её артефактами — осознанно купленный компромисс, а не недосмотр, который «починят в следующей версии».

BPE — компромисс между алфавитом и словарём

Не все буквы (длинно) и не все слова (незнакомое выпадает) — частые подпоследовательности.



Разные вендоры режут один и тот же текст по-разному: Claude, GPT, Gemini — свои словари и правила.

9/47

Алгоритм построения словарей большинства современных LLM — BPE, байт-парное кодирование. Это компромисс между двумя крайностями. Словарь из отдельных символов представит любой текст, но последовательности получаются длинными. Словарь из целых слов даёт короткие последовательности, но любое незнакомое слово — опечатка, неологизм, имя — выпадает. BPE сидит посередине: начинаем с алфавита, итеративно объединяем самые частые пары соседних единиц; после многих итераций в словаре есть и одиночные символы, и частые слоги, и целые высокочастотные слова. Ключевая инженерная деталь: словарь строится один раз, до обучения модели. На корпусе запускают BPE, фиксируют словарь и правила слияния — и всё; на инференсе токенизация — это выборка по готовой таблице за миллисекунды. Отсюда два следствия, которые пригодятся ниже: токенизатор режет по частотной статистике своего корпуса, и эта статистика может не совпадать со структурой вашей задачи; а раз словарь и модель обучаются на разных корпусах — в словаре могут остаться записи, которые модель почти не видела. Практически важно и другое: разные вендоры считают один и тот же текст по-разному — свои словари, таблицы слияния, обработка пробелов. Один документ у разных провайдеров даст разное число токенов, а значит, разную стоимость и разное заполнение окна. При переносе нагрузки между провайдерами пересчитывайте токен-бюджет: для моделей OpenAI токенизация эмулируется локально библиотекой tiktoken, для открытых моделей — библиотекой tokenizers; токенизатор Claude закрыт, но фактический расход виден в счётчиках любого ответа API.


Гонка патчей: strawberry починили в апреле, cranberry — только в июле

Механизм — слепота к буквам

strawberry →

[st][raw][berry]

Модель видит **3 токена**, не 10 букв.



скриншот: ChatGPT, форум OpenAI, 2024

GPT-5.2 · дек 2025

strawberry X — «в strawberry две r»

GPT-5.5 · апр 2026

strawberry ✓ / cranberry X — «две r» вместо трёх

GPT-5.6 · июль 2026

cranberry ✓ — очередной вирусный кейс запатчен

StrawberryBench

847 вопросов, 7 уровней сложности — системная проверка вместо вирусного вопроса

«Рванный интеллект» (jagged intelligence): уровень навыка задаётся данными обучения, а не «общим умом» — модель берёт олимпийское золото и проваливает подсчёт букв.

Что делать: тестируйте «cranberry своей предметки» — редкие случаи, на которых никто не хайпил; вирусное прохождение ≠ навык.

10/47

Мем «сколько r в strawberry» вы знаете; вероятно, знаете и то, что современные модели отвечают на него правильно. Вывод «значит, научились считать буквы» — ложный, и вот почему. Механизм — слепота к буквам. Слово приходит в модель как три токена, а не десять букв. Внутри выученного вектора токена нет поля «содержит r на такой-то позиции» — там статистика контекстов. Посимвольный подсчёт требует рассуждения поверх токенизированного представления — разворачивания слова по буквам или вызова кода; один прямой проход к надёжному ответу не приводит. Это структурное свойство конвейера. Теперь смотрите на гонку патчей 2026 года. GPT-5.2 в декабре 2025-го всё ещё отвечал «две r» в strawberry. GPT-5.5, выпущенный в апреле 2026-го, проходит strawberry — но на вопрос «сколько r в cranberry» отвечал «две»; правильно — три. И только GPT-5.6 в июле 2026-го починил уже и cranberry — проверьте актуальную модель прямо сейчас. Обратите внимание на закономерность: каждый вирусный кейс патчится точно и по очереди, а не единым улучшением навыка — иначе фикс strawberry сразу закрыл бы и cranberry. Для систематической проверки класса задачи появился StrawberryBench — 847 вопросов в семи уровнях сложности; именно на нём, а не на одном вирусном слове, видно, что посимвольный счёт остаётся проблемным местом. У явления есть имя: «рванный интеллект» — профиль способностей с резкими провалами рядом с пиками. Причина в том, что уровень навыка задаётся данными обучения, а не «общим умом»: где в данных навык представлен богато — там пик, где представление слова скрывает нужную структуру — там провал. Та же модель решает олимпиадную математику и проваливает подсчёт букв; на умножении GPT-4 без инструментов давал около 59% на трёхзначных числах, 4% на четырёхзначных и 0% на пятизначных. Урок переносим в практику: если модель прошла ваш тест — проверьте её на «cranberry вашей предметной области», структурно аналогичном, но

незнаменитом примере, на котором никто не хайпил: вирусное прохождение — не навык. А для посимвольных операций и арифметики — внешний инструмент, не прямой проход.

Токенизатор режет по частоте, а не по структуре

Числа и код — самые частые «нетекстовые» входы: от их нарезки зависят арифметика модели и ваш бюджет токенов.

Числа

1000000 → [100][000][0]

Чанки слева направо — а математические разряды считаются справа налево: границы не совпадают, сложение в столбик ломается.

Нарезка справа налево улучшает арифметику; задача-специфичные схемы — **до +33% точности** к стандартной нарезке.

Код

GPT-2: **16 токенов** на отступ 4-го уровня.

GPT-4: пробелы группами — словарь чинится, но не под все задачи сразу.

Что делать:

Разделители разрядов («1 234 567»)

Вычисления — в инструмент

Единообразные отступы

Готовые чат-продукты уже сами уводят счёт во встроенные инструменты (code interpreter); звать инструмент самому — нестандартные случаи и свои приложения поверх API.

11/47

Зачем инженеру знать, как режутся числа и код: это самые частые «нетекстовые» входы, и от их нарезки напрямую зависят арифметика модели и ваш бюджет токенов на код. Два компактных примера того, как частотная нарезка расходится со структурой данных. Числа. Токенизатор cl100k_base стандартизировал нарезку чисел чанками по три цифры слева направо: миллион превращается в группы, границы которых не совпадают с разрядами. Человек читает разряды справа налево — тысячи, миллионы; модель получает нерегулярные блоки — и это прямой источник части арифметических ошибок. Исследования подтверждают диагноз с обеих сторон: принудительная нарезка справа налево заметно улучшает численное рассуждение, а задача-специфичные схемы токенизации чисел давали до плюс тридцати трёх процентов точности на арифметике с большими числами относительно стандартной нарезки. Код. GPT-2 кодировал каждый пробел отступа отдельным токеном: строка на четвёртом уровне вложенности тратила шестнадцать токенов только на отступ. Токенизаторы поколения GPT-4 группируют пробелы в единые токены, целясь именно в Python-стиль. Это редкий случай, когда проблему токенизации починили изменением словаря, — полезный контраст к strawberry: словарь можно оптимизировать под частый класс входов, но нельзя совместить нарезку со структурой всех задач сразу. Четыре приёма на вынос. Значимые числа записывайте с разделителями разрядов — «1 234 567» вместо сплошной строки: разделители выравнивают границы токенов по разрядам. Любую арифметику важнее прикидки выносите в инструмент — модели прекрасно пишут код для вычислений, которые не могут выполнить сами. Для кода — единообразное форматирование и оценка бюджета по измерению на реальных файлах: средний ориентир «четыре символа на токен» для кода систематически врёт. И важная поправка для практики: в готовых чат-продуктах — ChatGPT, Claude в

веб-интерфейсе — счёт и арифметика уже автоматически уходят во встроенный инструмент вроде `code interpreter`, минуя прямой проход модели; то, что мы сейчас разобрали, становится критичным именно тогда, когда вы вызываете модель через API напрямую — в своих приложениях и агентах, где такого автоматического роутинга нет, и в нестандартных случаях, которые готовый продукт не распознал как «нужен инструмент».

Порядка 4% словаря — glitch-токены

SolidGoldMagikarp (2023)

Юзернейм с Reddit в словаре GPT — модель не могла его повторить.



Механизм: корпус словаря ≠ корпус модели → эмбединг токена остаётся у случайной инициализации.

На что влияет

- Сбои парсинга экзотических строк — редкие идентификаторы, обфусцированный текст, необычный Unicode
- Риски в проде — логи, user-generated ID, произвольный пользовательский ввод
- Необъяснимые ответы «невпазд» без ошибки в коде

GlitchMiner (AAAI 2026)

порядка 4% словаря по одной из оценок;

воспроизводится в открытых семействах Llama, Qwen, Gemma, Phi-3, Mistral.

Что на практике:

Необъяснимое поведение на экзотических строках (редкие идентификаторы, обфусцированный текст, необычный Unicode)?
Гипотеза: glitch-токен. Проверка: замените строку плейсхолдером.

В продуктах, принимающих произвольный ввод, — нормализация и санитизация входа до модели.


Системная особенность конвейера, не баг версии — масштабом не чинится.

12/47

В январе 2023 года исследователи, изучая кластеры в пространстве эмбедингов GPT-моделей, наткнулись на группу странных записей словаря — строки вроде SolidGoldMagikarp: юзернеймы с Reddit, попавшие в корпус токенизатора при сборе данных. Модели вели себя на этих токенах аномально: не могли их повторить, отвечали невпазд, уходили от темы. Механизм коротко: строка может быть частой в корпусе, на котором строился словарь, и получить собственный токен — но почти не встречаться в корпусе, на котором потом обучалась модель; эмбединг такого токена остаётся близким к случайной инициализации и «ничего не значит» в выученной геометрии. Данные 2026 года говорят: это не курьёз эпохи GPT-3, а системное свойство. По одной из оценок, порядка четырёх процентов записей словаря протестированных моделей — glitch-токены, а фреймворк GlitchMiner находит их градиентным поиском в десяти открытых LLM семействах Llama, Qwen, Gemma, Phi-3 и Mistral. Проблема воспроизводится во всех проверенных семействах, потому что словарь строится отдельно от модели; масштабом такое не чинится. Теперь — на что это реально влияет в инженерной практике, и это важнее самого механизма. Первое: сбои парсинга на экзотических строках — модель необъяснимо теряет тему разговора или отказывает именно на конкретном входе, а не в целом на классе задач. Второе: прод-риски — любая система, принимающая произвольный пользовательский ввод, работает с потенциальным источником glitch-токенов: логи, автоматически сгенерированные ID, обфусцированный текст, редкие Unicode-последовательности. Третье: диагностика — если поведение необъяснимо именно на конкретном входе, среди гипотез должна быть «на входе glitch-токен»; проверяется за минуту заменой подозрительной строки на плейсхолдер — поведение выправилось, виновник найден. Четвёртое, продуктовое: нормализуйте и санитизируйте вход до подачи в модель — это

отсекает не только glitch-токены, но и целый класс смежных сюрпризов токенизации.

Русский текст стоит $\approx 2\times$ дороже английского



Переход на o200k_base:

примерно **–35%** нелатинским языкам — разрыв сокращается, но не исчезает.

Что делать:

- Калибруйте лимиты в токенах на своём языке: фрагменты для поиска, `max_tokens`, бюджет окна.
- Пакетная обработка больших объёмов — оцените перевод на английский ($\approx 2\times$ дешевле); в интерактиве разница того не стоит.

13/47


Один и тот же по смыслу текст стоит разное число токенов в зависимости от языка — прямое следствие того, что BPE-словарь учится на корпусе с доминирующим английским. Ориентиры для токенизаторов GPT-семейства: английский — около 0.25 токена на символ, русский — около 0.5, китайский — около 0.8, Python-код — около 0.4. Итого запрос на русском обходится примерно вдвое дороже английского, с разбросом от полутора до двух с половиной раз, и контекстное окно расходуется вдвое быстрее: документ в 80 тысяч символов — это примерно 20 тысяч токенов на английском и 40 тысяч на русском. Динамика 2024–2026 годов: переход OpenAI на o200k_base снизил удельную стоимость нелатинских языков примерно на 35% — разрыв сокращается, но не исчезает: английский остаётся статистическим ядром корпусов. Для моделей с увеличенной долей русского в словаре — YandexGPT, GigaChat — разрыв меньше; это один из рациональных аргументов в их пользу для массовых русскоязычных нагрузок. Правило прежнее: при пакетной обработке больших объёмов оцените, допускает ли задача перевод на английский; в интерактивной работе разница обычно не оправдывает потери удобства. Языковой коэффициент протекает и туда, где о нём забывают. Разбиение документов на фрагменты для поиска настраивается в токенах — фрагмент «в 512 токенов» на русском вмещает вдвое меньше смысла, и пороги из англоязычных руководств для русской базы систематически малы. Лимит `max_tokens` — та же история: русский ответ длиннее в токенах, и обрезки на полуслове случаются чаще. Любой числовой параметр в токенах калибруйте на своём языке и своих данных.

Раздел 2

Эмбеддинги

«Пространство смыслов — и граница похожести»


4 разбора · 1 провал



14/47

Первая стадия пройдена: текст стал последовательностью идентификаторов из словаря. Но с самим числом нейросеть содержательно работать не может — между номерами токенов нет осмысленной арифметики. Вторая стадия конвейера превращает идентификаторы в представление, с которым можно считать, — векторы. План раздела такой. Сначала зафиксируем, что такое эмбеддинг: выборка вектора из входной таблицы модели — быстро, это база. Затем — главный систематизирующий ход раздела: слово «эмбеддинг» в инженерном обиходе означает три разные сущности, и их нередко смешивают; разложим три жизни термина аккуратно — и увидим, что эмбеддинги работают не только внутри инференса, но и как самостоятельный инструмент поиска. Дальше — пространство смыслов: как выучиваются координаты, почему близкие по смыслу тексты лежат рядом и как это измеряется косинусным сходством. После этого — единственный, но важный провал раздела: граница похожести, случай, когда высокое сходство приносит практически противоположный по смыслу документ, и что с этим делают в боевых системах поиска. И в конце соберём раздел: почему эмбеддинги — фундамент того, что модель «понимает» переформулировки, и что из этого следует для систем поиска и RAG, к которым мы придём в Лекции 3.

Каждому токenu — вектор из входной таблицы модели



Что делать: опечатка или другой регистр — уже другой токен и другой вектор; нормализуйте вход до эмбединга.

15/47

Токен — это идентификатор из словаря, но с числом 48 213 нейросеть содержательно работать не может: между номерами токенов нет осмысленной арифметики. Эмбединг, векторное представление, — сопоставленный каждому токenu словаря вектор фиксированной длины, список чисел с плавающей точкой, выученный на этапе обучения вместе с остальными весами. После обучения входная таблица «токен → вектор» зафиксирована; на инференсе модель делает выборку: получает идентификатор, забирает вектор, передаёт дальше. Главное свойство выученного пространства: геометрическая близость соответствует смысловой. «Кот» близко к «собаке», «SSL» близко к «HTTPS» — не потому, что кто-то это разметил, а потому, что эти слова встречались в похожих контекстах обучающего корпуса. Близость в этом пространстве — статистическое отражение употребления, а не семантический справочник. Размерность — гиперпараметр: у публичных embedding-моделей OpenAI — 1536 и 3072 измерения; внутренние размерности флагманских LLM не публикуются, порядок — тысячи. И одна оговорка для тех, кто будет работать с векторами руками. Представьте трёхмерное пространство, где близкие по употреблению слова — рядом, и растяните число измерений до тысяч. Интуиции близости в основном переносятся, но в пространствах высокой размерности действует концентрация меры: случайные точки оказываются примерно на одном расстоянии друг от друга, и «сырые» дистанции сжимаются в узкий диапазон. Поэтому абсолютные значения сходств малоинформативны сами по себе — информативны сравнения и распределения значений в вашей задаче. Это первая причина, по которой универсальных порогов сходства не существует; вторая, содержательная, — впереди.

Эмбединги — не только внутренность инференса, но и инструмент поиска

Когда вы строите поиск или RAG, вы пользуетесь третьей жизнью термина «эмбединг» — отдельной *embedding-моделью*.

1

Входная таблица

внутри инференса

Статическая: вектор [кот] один и тот же в любом предложении. Выборка по id, контекста ещё нет.

2

Представление данных внутри модели

внутри инференса

Векторы, которые модель пересчитывает по ходу чтения контекста — после слов внимания. Именно они несут «понимание» модели.

3

Векторы для поиска

самостоятельный инструмент

Вектор целого текста от отдельной *embedding-модели* — не внутренности вашего чат-LLM. Свой продукт, своё обучение, свои лидерборды.

это и есть ваш поиск/RAG


Обновили чат-LLM → переиндексировать базу НЕ надо: индекс живёт в координатах *embedding-модели*.

16/47

Эмбединги нужны не только для инференса — это ещё и самостоятельный инструмент поиска. Слово «эмбединг» в инженерном обиходе обозначает три разные сущности; разложим три жизни термина и посмотрим, какой из них вы пользуетесь, когда строите поиск. Жизнь первая: входная таблица — статическая таблица «токен → вектор» на входе LLM. Вектор токена «кот» в ней один и тот же в любом предложении. Жизнь вторая: представление данных внутри модели. Последовательность входных векторов проходит через десятки слоёв внимания, и на каждом слое вектор каждой позиции обновляется с учётом окружения — на выходе вектор позиции «кот» уже не равен табличному, в него вмешан контекст; это векторы, которые модель пересчитывает по ходу чтения контекста. Именно эти представления несут «понимание» модели; входная таблица — лишь стартовая точка. Обе эти жизни — внутренности инференса. А третья жизнь — ваш рабочий инструмент: когда вы вызываете *embedding-API* для поиска или RAG, вы получаете вектор целого текста от отдельной модели, специально обученной под поиск и сравнение. Это не внутренности вашего чат-LLM: *embedding-модель* — самостоятельный продукт, и чат-модель с *embedding-моделью* могут быть от разных вендоров — это нормальная практика. Правило разграничения: речь про стоимость и окно — это токены и входная таблица; про «что модель поняла» — представление данных внутри модели; про поиск и векторные базы — выходные эмбединги отдельной модели. И типовые ошибки склейки, ради которых различие вводится. «У нас подписка на чат-модель — зачем платить за *embedding-модель*?» — затем, что чат-модель векторов для поиска не отдаёт. «Возьмём *embedding-модель* того же вендора — они совместимее» — совместимости здесь нет как категории: векторы сравниваются только друг с другом внутри одной *embedding-модели*, LLM их вовсе не видит. И зеркально: «обновили LLM — надо переиндексировать базу» — не надо; переиндексация

нужна ровно тогда, когда меняется сама embedding-модель.

Близкие по смыслу токены лежат рядом — в сотнях-тысячах измерений



Размерность

Публичные embedding-модели: **1536–3072** измерения; внутренние у флагманов — порядка тысяч.

Обучение

Координаты не задаются вручную: похожие контексты употребления → близкие векторы.

Проекция

Увидеть пространство можно только через PCA/t-SNE — 2D-картинка теряет часть структуры.

Что делать: близость измерима расстоянием — фильтрация и кластеризация без разметки и без LLM возможны прямо на векторах, дёшево.

17/47

Как устроено пространство, в котором живут векторы. Каждая точка — токен или текст; координаты — те самые сотни или тысячи чисел. Смысл измерений не задаётся вручную — это направления, которые модель выучила из статистики; постфактум многие из них читаются как признаки: тематика, формальность, домен. Цель обучения — устроить пространство так, чтобы единицы, встречавшиеся в похожих контекстах, лежали близко. «Как настроить SSL» и «Установка HTTPS-сертификата» окружены одними и теми же словами — «сертификат», «сервер», «домен» — и их векторы получаются близкими; «Деплой React-компонента» и «Сборка React-приложения» соседствуют со словами про фронтенд и сборку — и тоже оказываются рядом; а «Рецепт борща» живёт в совсем другой области пространства — одинокий выброс среди технических текстов. Структура возникает не из правил, а из миллионов примеров употребления. На картинке слева — двумерная проекция: два смысловых кластера и выброс — те же пять текстов встретятся дальше в таблице попарных сходств. Оси проекции подписаны как признаки: одна разводит веб-тематику и кулинарию, другая — инфраструктуру и фронтенд; каждая из полутора с лишним тысяч осей реального пространства — такой же выученный признак, здесь показаны две. Помните, что это упрощение: реальная проекция получается из пространства в тысячи измерений алгоритмами вроде метода главных компонент или t-SNE, которые выбирают две оси с максимумом различий. Любая плоская картинка теряет часть многомерной структуры — она годится для интуиции, не для выводов. И повторим оговорку, потому что она стоит денег на практике: в пространствах высокой размерности «сырые» расстояния сжимаются в узкий диапазон, и абсолютное значение сходства само по себе мало о чём говорит. Работают сравнения — «этот документ ближе того» — и распределения значений в вашей конкретной задаче. Универсального порога «выше 0.8 — значит похоже»

не существует; порог калибруется эмпирически на ваших данных. Дальше посмотрим, как эта геометрия работает на целых предложениях — и где у неё проходит граница.

Высокое сходство — «об одном и том же», не «с одинаковым смыслом»

cosine similarity

	SSL	HTTPS	React-к.	React-п.	Борщ
Как настроить SSL	1,00	0,85	0,18	0,20	0,08
Установка HTTPS-сертификата	0,85	1,00	0,22	0,19	0,07
Деплой React-компонента	0,18	0,22	1,00	0,78	0,12
Сборка React-приложения	0,20	0,19	0,78	1,00	0,10
Рецепт борща	0,08	0,07	0,12	0,10	1,00

«Как настроить SSL» ↔

«Как отключить SSL»

Очень высокое сходство — противоположный практический смысл.

шкала: 0 — светлое · 1 — тёмное

Similarity — сигнал кандидатов; релевантность — отдельная задача: реранкер, гибриды, фильтры.

18/47

Сначала — что похожесть работает. Пять коротких текстов, парная таблица косинусных сходств на современной embedding-модели: синонимичные по задаче пары — «настроить SSL» и «установка HTTPS-сертификата» — около 0.85; тематически близкие React-тексты — около 0.78; борщ против любого технического — 0.05–0.15. Запрос «клубника» находит документы про strawberry и землянику без таблицы синонимов — это то, что эмбединги дают поверх полнотекстового поиска. Теперь граница — и это новый материал даже для тех, кто активно строит семантический поиск. Высокое косинусное сходство означает «об одном и том же», а не «об одном и том же с одинаковым смыслом». Пара «как настроить SSL» и «как отключить SSL» получает очень высокое сходство: одинаковая тема, лексика, синтаксическая рамка — а практический смысл противоположный. Эмбединг усредняет контекстную статистику всего текста; короткое отрицание или антонимичный глагол сдвигает вектор слабо. В проде это выглядит болезненно: пользователь спрашивает, как включить проверку сертификатов, поиск уверенно приносит статью, как её отключить, LLM в RAG-конвейере добросовестно пересказывает — и система с высокими метриками похожести выдаёт вредный совет. Инженерные ответы известны: реранкер — вторая модель, оценивающая пару «запрос-документ» целиком; гибриды с полнотекстовым поиском для точных терминов; фильтры и метаданные для направленных атрибутов. И приём диагностики: соберите проверочный набор пар «запрос → правильный документ» с намеренными ловушками — вкл/выкл, до/после, разные версии — и посмотрите, что стоит на первых позициях. Устройство RAG-конвейера целиком — Лекция 3; отсюда забираем принцип: косинусное сходство — про тематическую близость, релевантность — отдельная задача.

Эмбединги — фундамент понимания: модель работает с векторами, не строками



Перефразирования и синонимы

«Как настроить SSL» и «Установка HTTPS-сертификата» — близкие векторы → модель отвечает одинаково; то же с «авто» и «машина».

Межъязыковая близость

«клубника» и strawberry — близкие векторы → ответ корректен независимо от языка запроса.

Семантическая близость на уровне предложений — основа «понимания» переформулировок.

Что делать: одна embedding-модель и индекс обслуживают поиск, кластеризацию и RAG сразу — смена модели означает переиндексацию всего хранилища; выбирайте как инфраструктурное решение.

Выбор embedding-модели под задачу (MTEB, матричные представления) — материал для самостоятельного чтения.

19/47

Соберём раздел. Модель работает не со словами и не со строками — она работает с векторами; слова существуют только на границах. На входе текст через токенизацию превращается в идентификаторы, через входную таблицу — в векторы; на выходе внутренний вектор через распределение и выбор токена возвращается в текст. Между человеческим вводом и человеческим выводом — путь полностью векторный. Это объясняет то, что мы интуитивно называем «пониманием». Когда вы спрашиваете «как настроить SSL», а потом «установка HTTPS-сертификата», модель отвечает похоже, потому что оба запроса попадают в близкие точки пространства. То же с синонимами и с межъязыковой близостью: «клубника» и strawberry — близкие векторы, и ответ корректен независимо от языка запроса. Практическая сторона: на одних и тех же векторах стоят три стандартных применения — поиск похожих, кластеризация без разметки и семантический поиск с RAG. Одна embedding-модель и один индекс обслуживают сразу несколько функций продукта, поэтому выбор embedding-модели — инфраструктурное решение, а смена — дорогая: означает переиндексацию всего хранилища. В боевых системах семантический поиск почти никогда не живёт один: рабочий стандарт — гибриды из полнотекстового индекса для точных совпадений, векторного для понятийной близости и реранкера сверху — прямое следствие границы похожести, которую мы только что разобрали. И помните: обратной операции у эмбединга нет — из вектора текст не восстанавливается, это одностороннее сжатие смысла. Как выбирать embedding-модель под язык и бюджет размерности — оставляю вам для самостоятельного чтения: в методичке это глава, часть 1 — раздел об embedding-моделях 2026.

Раздел 3

Механизм внимания

«Как модель решает, на что опереться в контексте — и что из этого следует для ролей, кэша и длинных окон»

4 разбора · 2 провала



Статья, давшая механизму имя: Vaswani et al., «Attention Is All You Need», 2017 (arXiv:1706.03762)



20/47

Две стадии конвейера позади. Токенизация: текст разрезан на токены — идентификаторы из словаря, зафиксированного до обучения. Эмбединги: каждый идентификатор получил выученный вектор, и близость векторов отражает близость употребления. Третья стадия — механизм внимания, самая насыщенная часть лекции. На входе — последовательность векторов; задача стадии — для каждого шага генерации решить, на какие части контекста модель опирается сильнее всего. Из этого механизма напрямую вырастают вещи, с которыми вы работаете каждый день: почему история чата кешируется и когда кэш перестаёт срабатывать; как устроена экономика кэширования промптов; почему промпт с ролью реально меняет ответ, но не делает ответ более точным; что на самом деле означает строка «окно 1 миллион токенов» в карточке модели — и где это обещание ломается. Порядок движения: сначала матрица внимания и точное определение с тремя проекциями Query/Key/Value на нашем примере; дальше — KV-cache и две фазы генерации; экономика кэширования промптов с живым кейсом; затем рабочий пример и полный механизм эффекта роли; гонка контекстных окон на сентябрь 2026 года; и в финале раздела — честный ответ на вопрос, сколько из миллионного окна модель действительно способна использовать для рассуждения.

Внимание — это сверка каждого токена со всеми остальными

Каждый токен «смотрит» на все остальные одновременно. На каждом шаге — $N \times N$ связей.

вес	Кот	съел	мышь	потому что	он	был	голоден
Кот	1,0	0,3	0,2	0,1	0,1	0,1	0,0
съел	0,4	1,0	0,5	0,1	0,1	0,1	0,1
мышь	0,2	0,4	1,0	0,1	0,1	0,0	0,1
потому что	0,1	0,2	0,2	1,0	0,3	0,2	0,2
он	0,7	0,1	0,2	0,2	1,0	0,3	0,4
был	0,1	0,2	0,2	0,3	0,4	1,0	0,5
голоден	0,1	0,2	0,3	0,3	0,4	0,5	1,0

По строке «он»: наибольший вес — на «Кот» (мужской род). Статистическая связь, выученная на корпусе.

В декодере токен видит только предыдущие — показана полная сверка для наглядности.

Размерность

$N \times N$, где N — длина контекста. Удвоение контекста — учетверение вычислений внимания.

На каждом шаге

Распределение весов пересчитывается заново на каждом шаге генерации.

Многоголовость

В каждом слое — десятки параллельных «голов» (типично 32–128); каждая ловит свой тип связей: грамматика, семантика, дальние зависимости.

На что влияют веса: они определяют, чьи Value попадут в представление текущего токена — и напрямую формируют следующее предсказание.

21/47

Вы знаете слово «внимание» из каждой второй статьи про трансформеры; зафиксируем точную форму. Внимание — не линейная, а матричная операция: каждый токен контекста сверяется с каждым, и для контекста длины N карта весов имеет размер N на N . Из этой формы сразу следует главное экономическое свойство всей архитектуры: удвоение контекста учетверяет объём вычислений внимания. Когда дальше мы будем говорить о цене миллионных окон и о том, почему провайдеры так агрессивно кэшируют, — корень именно здесь. На слайде — упрощённая матрица семь на семь для предложения «Кот съел мышь, потому что он был голоден». Числа иллюстративные, реальные веса нормируются так, что сумма по строке равна единице. Качественно картина типична: в строке токена «он» наибольший вес лежит на токене «Кот», а не на «мышь» — местоимение мужского рода разрешается на одушевлённый субъект того же рода, стоящий в начале предложения. Это то, что мы в быту называем «модель поняла, к чему относится местоимение», — технически это статистическая связь, выученная на огромном корпусе. Два уточнения к картинке. Первое: распределение весов пересчитывается на каждом шаге генерации заново — это не «посчитали один раз и пользуемся». Второе: реальный механизм многослойный и многоголовый — в каждом слое параллельно работают десятки «голов», типично от 32 до 128, и каждая специализируется на своём типе связей: одна ловит грамматическое согласование, другая тематическую близость, третья дальние зависимости. Эти специализации никто не проектировал — они выросли из обучения, потому что помогают предсказывать следующий токен. И главное — на что конкретно влияет это распределение весов, а не просто «что-то там взвешивается». Вес каждой связи определяет, какая доля Value-вектора соответствующего токена попадёт в итоговое представление текущей позиции: если «он» отдаёт 0.7 веса «Кот», то именно содержимое «Кот» — его Value —

доминирует в обновлённом представлении токена «он». А представление текущего токена — это именно то, из чего на следующем шаге строится распределение вероятностей для предсказания. Другими словами: распределение весов внимания напрямую и механически определяет, каким будет следующий предсказанный токен — это не побочный эффект, а прямая причинная цепочка.

Внимание — распределение весов на весь контекст: три проекции Query / Key / Value

Q — про текущий шаг. K и V — про уже обработанный контекст.

Query — «что я сейчас ищу»

Key — «что я предлагаю»

Value — «что я отдам, если меня выбрали»

«Кот съел мышь, потому что он был голоден»


Q («он») = «ищу: кто мог быть голоден»

K («Кот») = «я — одушевлённый субъект»

V («Кот») = содержимое, которое вольётся в представление «он»

Совпадение Q («он») и K («Кот») даёт высокий вес → V («Кот») определяет обновлённое представление токена «он».

Распределение весов — сумма = 1, лидер «Кот»



1. На вход — все токены контекста.

2. На выходе — распределение весов, сумма = 1.

3. Пересчитывается на каждом шаге генерации.


Метафора: фонарик в тёмной комнате — луч направлен на релевантные токены, яркость света = вес внимания.

22/47

Зафиксируем определение точно. Рабочая метафора — фонарик в тёмной комнате: все токены контекста присутствуют, но луч направлен на те, что релевантны текущему вопросу, и яркость по предметам — это веса. Формально на каждом шаге внимание возвращает распределение весов на все токены контекста, сумма равна единице, и это распределение пересчитывается на каждом шаге генерации заново. Теперь — один уровень глубже, на нашем же предложении, чтобы не потерять конкретику. Для каждого токена модель вычисляет три проекции его вектора: Query, Key и Value. Возьмём токен «он» из «Кот съел мышь, потому что он был голоден». Его Query можно грубо прочитать как «ищу: кто мог быть голоден» — запрос текущей позиции к остальному контексту. Токен «Кот» предлагает свой Key — нечто вроде «я — одушевлённый субъект», визитную карточку, по которой его находят чужие запросы. Когда Query «он» и Key «Кот» хорошо совпадают, вес между ними получается высоким — именно это мы видели в матрице на предыдущем слайде. А дальше в дело вступает Value «Кот» — содержимое, которое реально вливается в обновлённое представление токена «он». Итог позиции «он» — взвешенная сумма Value всего контекста, где Value «Кот» вносит наибольший вклад. Простыми словами: Query — это вопрос, который задаёт токен; Key — это то, чем токен отвечает на чужие вопросы; Value — это то, что токен реально передаёт, если его выбрали. Запомнить стоит одно структурное наблюдение: Query — про текущий шаг, а Key и Value — про уже обработанный контекст, который не меняется. Из этой асимметрии вырастает главная оптимизация всей индустрии вывода моделей — увидим её на следующем слайде, когда разберём, почему длинный чат тормозит.

К и V кешируются — заново считается только Q

KV-cache: Key/Value обработанных токенов сохраняются в памяти ускорителя. На каждом шаге вычисляется только Q нового токена — против сохранённых K/V.



Вспомните наблюдение с прошлого слайда: Query — про текущий шаг, Key и Value — про уже обработанный контекст, который не меняется. Генерация авторегрессионна: токены выдаются по одному, и наивная реализация пересчитывала бы K и V всех токенов на каждом шаге заново — но они не меняются. Отсюда центральная оптимизация всего инференса больших моделей — KV-cache: Key- и Value-векторы вычисленных токенов сохраняются в памяти ускорителя, и на каждом шаге вычисляется только Q нового токена и его произведения с сохранёнными K/V. Из кэша вырастает асимметрия двух фаз, которую вы наблюдаете в каждом запросе. Prefill — обработка входного промпта: все его токены известны сразу, их K/V считаются параллельно одним большим матричным вычислением; фаза упирается в вычислительную мощность и определяет паузу до первого символа ответа. Decode — генерация: строго последовательная, и на каждом шаге нужно прочитать весь накопленный кэш из памяти; фаза упирается в пропускную способность памяти и определяет скорость в токенах в секунду. Поэтому длинный промпт прежде всего растягивает паузу до первого токена, а длинный контекст в целом замедляет каждый шаг генерации. Здесь важна точная формулировка вывода, потому что она легко искажается в народную мудрость «для новой задачи — новый чат». Пока KV-cache работает — то есть история совпадает с тем, что уже посчитано, — повторная подача истории дешёвая и быстрая: именно ради этого кэш существует. «Тормозит и дорожает» происходит не как свойство длинного чата вообще, а именно тогда, когда кэш не срабатывает — когда контекст меняется в начале, когда сессия истекла, когда провайдер вытеснил ваш кэш из памяти под чужую нагрузку. История подаётся в модель целиком при каждом обороте — модель без состояния, как мы фиксировали в Лекции 1, — но это не значит, что каждый оборот пересчитывается с нуля. Устройство кэша у провайдеров разное, и это

прямо влияет на то, что вам нужно делать руками. У OpenAI и у DeepSeek кэш срабатывает автоматически — без специальной настройки в запросе; у DeepSeek он к тому же дисковый, а не только в памяти ускорителя. У Google Gemini — `implicit caching`, тоже включён по умолчанию. А у Anthropic кэш явный: нужно расставить маркер ``cache_control`` в нужных местах промпта самостоятельно — иначе кэш не сработает, даже если содержимое совпадает. Практический вывод: если вы на Anthropic и не видите экономии — проверьте, стоит ли маркер там, где нужно; на остальных трёх — проверьте метрики `cache hit rate` в ответе API, потому что «автоматический» не значит «гарантированно срабатывающий». Масштаб эффекта: при контекстах в сотни тысяч токенов кэш одного пользователя занимает гигабайты памяти ускорителя — отсюда агрессивный батчинг провайдеров и премиальная цена длинных контекстов.

Кэш промптов — ставка на повторное использование, а не скидка

Три запроса подряд:

Запрос 1: префикс пишется в кэш — запись 1.25–2× ставки

Запрос 2: тот же префикс → cache hit — чтение 0.1× (новейшие — 0.025×)

Запрос 3: строка добавлена в начало → префикс не совпал → мимо кэша, полная цена

Кейс: 50 000 анализов документов в месяц

без кэша \$45 000

\$8 000 с кэшем · -82%

Условие: точное совпадение префикса. Один изменившийся токен инвалидирует кэш для всего, что после него.

системный промпт ✓ кэш

инструкции ✓ кэш

документы ✓ кэш

«Сегодня 2026-09-05 14:23» — динамический !

вопрос × мимо кэша

Динамический элемент в начале (timestamp) рушит кэш всех блоков после него — это и есть «запрос 3».

Правило компоновки: стабильное — в начало (промпт, инструкции, примеры, документы), переменное — в конец.

24/47

KV-cache живёт внутри одной генерации. Провайдеры сделали следующий шаг: если два разных запроса имеют одинаковый префикс — тот же системный промпт, инструкции, документы, — его K/V можно переиспользовать между запросами. Это кэширование промптов, и с 2025–2026 годов это главный рычаг оптимизации стоимости LLM-нагрузок. Проследим механику на трёх последовательных запросах — так виднее, чем на отдельных цифрах. Запрос первый: вы отправляете промпт впервые, кэша ещё нет — префикс записывается в кэш, и запись стоит дороже обычного входа, от 1.25 до 2 ставок в зависимости от времени жизни кэша. Запрос второй: вы отправляете тот же префикс — например, тот же системный промпт и тот же набор документов, только новый вопрос пользователя в конце — префикс совпадает побайтово, кэш срабатывает, и вы платите десятую часть базовой ставки входа, у новейших моделей — до одной сороковой. Запрос третий: кто-то добавил в начало промпта одну строку — например, текущую дату или обновлённую инструкцию — и теперь префикс больше не совпадает с тем, что в кэше, начиная с этой строки. Кэш мимо: вся нагрузка платит полную цену, как будто кэша никогда не было, а если у вас явная запись — ещё и надбавку за неё. Кэш не бесплатен — это ставка на повторное использование: окупается со второго-третьего попадания, а нагрузка из уникальных запросов без общего префикса только дорожает. Масштаб эффекта реален: кейс на 50 тысяч анализов документов в месяц — 45 тысяч долларов без кэша против 8 тысяч с кэшем, экономия 82 процента. Главное техническое условие видно на третьем запросе — точное совпадение префикса: кэш срабатывает, только если всё до контрольной точки совпадает байт-в-байт. Классический самострел — добавить в начало системного промпта что-то переменное, вроде текущей даты и времени: тогда ни один запрос никогда не попадёт в кэш. Отсюда правило компоновки: стабильное — в начало, переменное

— в конец. И минутный аудит для действующего конвейера: посмотрите поля учёта кэша в ответах API — если при стабильном системном промпте чтения из кэша нулевые, вы почти наверняка чините это перестановкой промпта за один вечер. Для многошаговых агентов кэш — не оптимизация, а условие рентабельности: к этому вернёмся в следующей лекции.

Роль работает через вес во внимании — но не повышает фактическое качество

Рабочий пример: куда смотрит «он»

«Кот съел мышь, потому что он был голоден»

главный вес

Упрощение: агрегат сотен связей в десятках слоёв — модель воспроизводит корреляции употребления, не грамматический разбор.

Подумайте 30 секунд: куда уйдёт вес от «он» в «Программа упала, потому что он забыл обработать pull»?

Без роли

«Объясни GIL» → нейтральный, обобщённый ответ.

С ролью

«Ты — опытный Python-разработчик. Объясни GIL» — токены роли получают вес → смещают распределение следующих токенов: конкретнее, в экспертном регистре.

Zheng et al. (2024, EMNLP Findings; 2410 вопросов, 162 роли): персона/роль в промпте не повышает точность факта — эффект конкретной роли непредсказуем.

Отдельно от этого исследования — по наблюдениям курса: роль ощутимо меняет тон, стиль и отбор содержания ответа.

Роль — инструмент управления стилем и фокусом, а не «усилитель ума». Нужен ответ по вашим данным — дайте данные, а не третье прилагательное к слову «эксперт».

25/47

Разминка: «Кот съел мышь, потому что он был голоден». Дойдя до токена «он», модель должна разрешить, к кому он относится, — и в карте внимания вес распределён в пользу «Кот». Три стрелки — упрощение: агрегат сотен связей в десятках слоёв; модель не делает грамматический разбор, а воспроизводит корреляции употребления. Проверьте интуицию: «Программа упала, потому что он забыл обработать pull». На большинстве моделей вес уйдёт к ближайшему подходящему одушевлённому существительному по смыслу контекста — если ваша интуиция дала похожий ответ, вы уже думаете в терминах корпусной статистики. Теперь — то, ради чего вы это уже знаете. Сравним два одинаковых по сути промпта. «Объясни GIL» без роли — модель отвечает нейтрально, обобщённо. «Ты — опытный Python-разработчик. Объясни GIL» — вы наверняка замечали, что такой промпт работает иначе. Механизм: токены «опытный», «Python-разработчик» получают вес в распределении внимания при генерации каждого токена ответа, и выбор смещается в согласованную с ними сторону — ответ становится конкретнее и увереннее, в экспертном регистре. Роль — не просьба «поверь мне», а входной сигнал, физически участвующий во взвешивании. И граница эффекта, которую важно знать до того, как вы начнёте злоупотреблять ролями в промптах: Zheng et al. (2024, EMNLP Findings) проверили 2410 вопросов и 162 роли — персона/роль в промпте не повышает точность факта, эффект конкретной роли непредсказуем. Отдельно от этого исследования: по наблюдениям курса роль ощутимо меняет тон, стиль и отбор содержания ответа — это отдельный, не тождественный факту эффект. Роль смещает распределение, не добавляет знаний. Если модель не знает ответа, роль «эксперт» не заставит её узнать — она заставит её увереннее звучать, не будучи более правой. Практический вывод: роль — рабочий инструмент управления стилем и фокусом ответа, полезный и легитимный, но не путайте его с

повышением точности. Нужен точный ответ по вашим данным — дайте модели данные, а не третье прилагательное к слову «эксперт».

Фронтир-стандарт 2026 — окно до 1 млн токенов. Но заявленное ≠ полезное

GPT-3.5 (2022) — 4 тыс.



Claude 3.5 (2024) — 200 тыс.



Фронтир-стандарт (2026) — до 1 млн · Fable 5, GPT-5.6, Gemini 3.1 Pro и др.



Gemini 3.5 Pro (2026) — 2 млн · единичная модель, не стандарт



ширина — логарифмическая шкала

Llama 4 Scout: «10 млн»

заявлено; ни один опубликованный бенчмарк не подтверждает качество вблизи предела

YandexGPT 5 Pro: 32 тыс.

на полтора-два порядка меньше флагманов — для длинных документов это определяющее ограничение

Просто «растянуть» окно нельзя: позиция токена закодирована геометрией, обученной на конкретных длинах, — расширение (RoPE / YaRN) — отдельная инженерная работа.

Платите за то, что кладёте в окно, а не за то, что окно вмещает: 900 тыс. токенов входа по \$10/млн ≈ \$9 за один вызов.


Что делать: выбирайте модель по эффективному окну задачи (бенчмарки без лексических подсказок), не по маркетинговому максимуму.

26/47

Контекстное окно — максимальное число токенов на один запрос — за четыре года выросло на три порядка: 4 тысячи у GPT-3.5 в момент запуска ChatGPT, 200 тысяч у Claude 3.5 в 2024-м, и фронтир-стандарт 2026 года — до одного миллиона: Fable 5, GPT-5.6, Gemini 3.1 Pro и другие держат этот уровень, причём у части моделей полное окно входит в стандартную цену без наценки за длину. Два миллиона у Gemini 3.5 Pro — не стандарт, а полюс: пока единственная модель на этом уровне, а не типичный флагман; моделей с окном до миллиона на рынке уже больше десятка. Два отрезвляющих полюса вокруг стандарта. Сверху — маркетинг: Llama 4 Scout заявляет десять миллионов токенов, но ни один опубликованный бенчмарк не подтверждает сохранение качества вблизи этого предела; «заявленное окно» и «полезное окно» — разные величины, и разрыв между ними мы измерим через слайд. Снизу — контраст: YandexGPT 5 Pro работает с окном 32 тысячи — для задач с длинными документами это не нюанс, а определяющее ограничение выбора. Почему окно конечно и его нельзя «просто увеличить»? Первая причина знакома: квадратичная стоимость внимания плюс линейно растущий кэш. Вторая тоньше: позиция токена закодирована в геометрии модели способом, обученным на конкретных длинах, и наивное растяжение ломает механизм; методы расширения — RoPE, YaRN — разобраны в методичке для самостоятельного чтения: глава, часть 2 — раздел о позиционном кодировании. И арифметика денег, которую полезно проделать один раз. Полное окно — это токены, которые вы оплачиваете как вход при каждом запросе: запрос к премиальной модели по \$10 за миллион входных токенов, заполненный на 900 тысяч, стоит около \$9 — за один вызов; десять оборотов диалога — под сто долларов без кэширования. Вопрос «сколько контекста нужно этой задаче» экономически важнее вопроса «сколько модель может принять».

Поиск дословной вставки решён. Понимание длинного контекста — нет

Забывание победили ✓ — найти дословную вставку (needle-in-a-haystack)

U-кривая 2023 распрямилась: **single-needle** — до 99% на полном окне 1 млн (Gemini Deep Think).

Работу со смыслом — нет (NoLiMa, 2025: бенчмарк убрал буквальное совпадение слов)

Без лексических совпадений качество падает **ниже 50% от базового уже на 32K** — у 11 из 13 моделей.

32 тыс. токенов = 3% заявленного окна флагмана; база — точность той же модели на коротком контексте.

1M окна ≠ 1M рассуждения. Окно — сколько модель может прочитать; полезная длина — на скольких токенах она ещё связывает факты.

27/47

Вы, вероятно, знаете классический результат 2023 года «Lost in the Middle»: факт из середины длинного контекста извлекается хуже, чем с краёв, — U-образная кривая точности. Это знание требует обновления 2026 года — в обе стороны. Хорошая новость: буквальный поиск «иголки в стоге» — найти дословно вставленную фразу — флагманами практически решён: до 99% на полном миллионном окне. Если задача — найти, где в договоре упоминается сумма, большое окно работает почти как обещано. Плохая новость пришла от бенчмарка NoLiMa, который убрал главный костыль таких тестов — буквальное лексическое совпадение между вопросом и спрятанным фрагментом. Когда искомое нужно узнать по смыслу, а не по совпадающим словам, картина обрушивается: одиннадцать из тринадцати протестированных моделей падают ниже половины их же собственной точности на коротком контексте — обратите внимание на базу: сравнение модели с самой собой, а не абсолютный порог. И происходит это уже на 32 тысячах токенов — не на миллионе, а на трёх процентах заявленного окна флагмана. U-кривая не исчезла — она спряталась за высокими цифрами тестов, которые измеряют поиск, а не рассуждение. Формула для запоминания: миллион окна не равен миллиону рассуждения. Окно — это сколько модель может прочитать; полезная длина — на скольких токенах она ещё способна связывать факты без буквальных подсказок, и вторая величина во много раз меньше первой. Следствия: критические инструкции — в начало или конец, не в середину; «вывалить всю базу знаний в окно» проигрывает хорошему поиску с пятью-десятью целевыми фрагментами — про это следующая лекция; и при выборе модели для длинных документов спрашивайте не «какое окно», а «какие результаты на бенчмарках без лексического совпадения» — и тестируйте на рабочей длине вашей задачи: полчаса стресс-теста на реальных документах говорят больше любого лидерборда.

Раздел 4

Сэмплинг и генерация

«Как из распределения вероятностей рождается один токен — и какими ручками этот выбор управляется»

4 разбора · 2 провала



Казино-костюм Caesars Palace — Wikimedia Commons, CC-BY-SA




28/47

Три стадии конвейера позади: текст разрезан на токены, токены получили векторы, внимание решило, на что опереться в контексте. Итог этих трёх стадий — распределение вероятностей на весь словарь модели: для каждого из примерно двухсот тысяч токенов — вероятность оказаться следующим. Четвёртая стадия — сэмплинг: правило выбора одного токена из этого распределения. Всё «творчество» и вся «случайность» больших моделей живут в этом правиле, и оно — единственная часть конвейера, которой вы управляете напрямую, ручками API. Порядок движения по разделу. Сначала зафиксируем само распределение — что оно и есть «настоящий» выход модели, а всё остальное — политики поверх него. Затем точная механика температуры и её соседей — с живым сравнением поведения на нуле и на полутора. Дальше — проверка самого коварного из шести утверждений: действительно ли ноль температуры даёт одинаковые ответы; ответ вас, скорее всего, удивит и он важен для каждого, кто пишет тесты на LLM. После этого — как классический набор из четырёх ручек API вырос до шести, гарантированный формат ответа через структурированный вывод, авторегрессионный цикл, собирающий всё в единое целое, и токены рассуждения — невидимая, но платная статья вашего счёта. Завершим раздел свежим взглядом на выбор между локальной моделью и облаком.

На каждом шаге — распределение вероятностей на все токены словаря

Контекст: «Сегодня я съел ...»

P(следующий токен):



Сэмплинг → один токен

правило выбора одного токена из распределения — единственная ручка в ваших руках



[яблоко]

выбран один — остальные кандидаты исчезли из ответа

Остальные ~200 000 токенов словаря — каждый < 0.05. Сумма всех вероятностей = 1. Числа иллюстративные.

Распределение — «настоящий» выход модели. Уверенный ответ и галлюцинация до сэмплинга существовали одновременно — как вероятностная масса; выбор сделала политика.

29/47

Итог трёх стадий конвейера — на выходе модели лежит распределение вероятностей на весь словарь: для каждого из примерно двухсот тысяч токенов — вероятность оказаться следующим; сумма равна единице. На запросе «Сегодня я съел» распределение выглядит примерно так: «яблоко» — 0.32, «пиццу» — 0.19, «салат» — 0.14, дальше длинный хвост; числа иллюстративные, картина устойчива. Распределение не равномерное — у модели есть статистические предпочтения, — но и не точечное: правдоподобных кандидатов несколько. Сэмплинг — правило выбора одного токена из этого распределения. Всё «творчество» и вся «случайность» больших моделей живут в этом правиле, и оно — единственная часть конвейера, которой вы управляете напрямую, ручками API. Стоит один раз осознать, насколько это распределение — «настоящий» выход модели, а всё остальное — политики поверх него. Уверенный ответ и уклончивый, точный факт и галлюцинация, «Париж» и «возможно, вы имеете в виду...» — до сэмплинга всё это существовало одновременно, как вероятностная масса на разных продолжениях; выбор сделала политика, а не «мнение» модели. Практическое следствие для тех, кто строит конвейеры: часть провайдеров отдаёт срез этой информации в API — лог-вероятности топ-кандидатов на каждом шаге. Это полезный диагностический канал: широкое, размазанное распределение на ключевом токене ответа — честный сигнал неуверенности модели, который сам текст ответа может никак не выдавать. Для классификации это дешёвый способ получить меру уверенности без второго запроса «а насколько ты уверена?» — второй запрос, кстати, измеряет не уверенность модели, а её натренированность отвечать на такие вопросы.

Температура — делитель логитов: меняет остроту выбора, не знания

$T = 0 \Rightarrow \text{выбор} = \text{argmax } P(\text{токен})$ $T > 0 \Rightarrow \text{сэмплинг из } P^{(1/T)}\text{-образного распределения}$


логиты делятся на T до softmax: $T < 1$ заостряет распределение, $T > 1$ выравнивает

$T \rightarrow 0$ (argmax)



Выбор самого вероятного. Почти одинаковые ответы — «почти» разберём на следующем слайде.

$T = 1$ (стандарт)



Сэмплирование пропорционально вероятностям модели.

$T = 1.5$ (сглаживание)



Редкие токены получают реальные шансы — до бессвязности.

Почему T влияет, хотя порядок кандидатов не меняется: выбор — не «взять топ-1», а случайная выборка пропорционально вероятностям; T перекраивает сами вероятности.

top-p — отрез хвоста по вероятностной массе · **top-k** — по числу кандидатов · T под задачу: 0–0.3 код и классификация, 0.7+ генерация.

Живой прогон: один запрос — 10 раз при $T=0$ и 10 раз при $T=1.5$.

30/47


Эти ручки вы знаете — уточним механику до точной формулы. При $T=0$ выбор — это $\text{argmax } P(\text{токен})$: детерминированно берём токен с максимальной вероятностью, без всякого сэмплирования. При $T>0$ модель сэмплирует из распределения, преобразованного по правилу P в степени $1/T$ — технически это означает, что сырые логиты делятся на T перед тем, как пройти через softmax и превратиться в вероятности. Здесь стоит остановиться на вопросе, который часто вызывает путаницу: порядок токенов по вероятности не меняется от температуры — самый вероятный токен остаётся самым вероятным при любой T . Тогда почему температура вообще на что-то влияет, если ранжирование одно и то же? Ответ в том, что выбор токена — это не «взять топ-1 из списка», а случайная выборка, где вероятность выбора каждого токена пропорциональна его вероятности в распределении. А температура меняет сами эти вероятности, не их порядок: при T меньше единицы распределение заостряется — лидер получает ещё больше массы вероятности, аутсайдеры теряют шансы почти до нуля; при T больше единицы распределение выравнивается — разрыв между лидером и остальными токенами сокращается, и у токенов, которые раньше были почти невозможны, появляется реальный шанс быть выбранными. Именно поэтому $T=0$ — предельный случай: заострение доведено до предела, и вероятность лидера становится равна единице — argmax . Второй эшелон: top-p отрезает хвост по вероятностной массе — сэмплируем из минимального набора самых вероятных токенов с суммарной вероятностью не меньше p ; top-k отрезает по числу кандидатов. Практика не изменилась: основная ручка — температура, эти две — тонкая настройка. Теперь живой прогон: один и тот же запрос — «придумай название для сервиса заметок» — десять раз при нуле и десять раз при полутора. Первый ряд даёт почти идентичные ответы — «Заметкин», «Заметкин», «Заметкин», изредка меняется разве что окончание; слово «почти»

здесь несёт больше смысла, чем кажется, и ему посвящён следующий слайд. Второй ряд — разброс от удачных находок до бессвязицы: «МыслеПоток», «конспект-туман на рассвете», «блокнот дыхания чисел» (примеры иллюстративные — свой разнбой вы увидите за минуту). Ценность этого эксперимента, если повторите его сами, не в подтверждении теории, а в калибровке руки: вы увидите, как выглядит хвост распределения вашей конкретной задачи и на какой температуре он начинает протекать в ответы. И обратное упражнение: если ваши промпты в проде работают на температуре по умолчанию — выясните, какая она у вашего провайдера; значения по умолчанию у всех разные и меняются, а осознанный выбор здесь стоит одну строку кода.

T=0 не даёт детерминизма: 80 уникальных ответов из 1000

80 / 1000

уникальных вариантов ответа на идентичный запрос при T=0 — стандартный vLLM (открытый инференс-сервер; Thinking Machines Lab, сентябрь 2025)



Решение существует: batch-инвариантные ядра — 1000/1000 побитово идентичны

Причина — не «floating-point вообще», а отсутствие batch-инвариантности ядер:

1. Сервер группирует одновременные запросы разных пользователей в батчи
2. Размер батча зависит от чужой нагрузки в эту миллисекунду
3. Разный размер батча → разный порядок суммирования → младшие разряды другие
4. Два близких кандидата в argmax → младший разряд решает выбор токена → авторегрессия разносит расхождение по всему ответу

Цена: ~35% пропускной способности → провайдеры не включают; seed у OpenAI — официально «mostly deterministic», в основном детерминировано

Получить гарантированно детерминированный ответ от облачной LLM сегодня нельзя — стройте процессы с учётом этого. Следствие: тесты — не на побитовом сравнении, а семантически или по структуре.

31/47

Это утверждение — самое коварное из шести, потому что оно почти правда, и на нём строят тесты и конвейеры. Вы ставите ноль температуры, ожидая: одинаковый запрос — одинаковый ответ. Проверка на реальной инфраструктуре: стандартный vLLM, тысяча запусков идентичного запроса — восемьдесят уникальных вариантов ответа. Ноль действительно делает выбор argmax-детерминированным — но само распределение, из которого берётся argmax, оказывается чуть разным от запуска к запуску. Причина глубже, чем расхожее «floating-point на GPU». Главный виновник — отсутствие batch-инвариантности вычислительных ядер. Сервер провайдера динамически группирует одновременные запросы разных пользователей в батчи; размер батча зависит от нагрузки в конкретную миллисекунду; а многие ядра при разном размере батча используют разный порядок суммирования. Сложение чисел с плавающей точкой неассоциативно — порядок меняет младшие разряды, — и когда два кандидата в argmax близки, младший разряд решает выбор токена; дальше авторегрессия разносит расхождение по всему ответу. Ваш «детерминированный» запрос недетерминирован, потому что вы делите сервер с другими пользователями, и их трафик меняет размер вашего батча. Самое поучительное: проблема решается — и решение отвергнуто экономикой. Те же авторы написали batch-инвариантные ядра: тысяча из тысячи запусков побитово идентичны. Цена — около 35 процентов пропускной способности, поэтому провайдеры этот режим по умолчанию не включают; отсюда и статус параметра seed у OpenAI — официально «в основном детерминировано», без гарантий. Главный вывод формулируем так, и порядок здесь важен: получить гарантированно детерминированный ответ от облачной LLM сегодня нельзя — это не временный баг, а следствие экономического выбора провайдеров, и проектировать процессы нужно с учётом этого факта, а не в надежде, что «в

следующей версии починят». Отсюда, как следствие, а не как главный тезис: не стройте тесты на побитовом сравнении ответов — сравнивайте семантически или по структуре; воспроизводимость фиксируйте датасетом и метрикой. А если строгий детерминизм действительно нужен — аудит, регуляторика, — это отдельное требование к инфраструктуре с ценником в треть пропускной способности, заложенное в бюджет с самого начала.

Ручки API: к случайности и длине добавилась глубина рассуждения

Параметр	Диапазон	На что влияет	Типичное значение
temperature	0–2	Детерминизм ↔ хаос выбора токена	0 классификация; 0.7–1.2 текст
top_p	0.1–1	Ширина хвоста кандидатов при сэмплинге	0.9–0.95
max_tokens	целое	Жёсткий обрыв генерации — может прервать на середине	под задачу, с запасом на JSON/код
effort	none → xhigh	Глубина внутреннего рассуждения — и его цена	medium у большинства провайдеров
verbosity	low → high	Длина видимого ответа, независимо от глубины мышления	medium

effort / reasoning_effort — новая ось 2026: OpenAI — шкала effort; Anthropic — адаптивное мышление; Gemini — thinking budget.

Что делать: начинайте настройку с temperature и effort — две главные ручки; top_p / top_k / verbosity — тонкая настройка поверх.

32/47

Классический набор — температура, top_p, max_tokens — вы знаете; таблица параметров на слайде фиксирует диапазон и типичное значение для каждого: ноль для классификации, 0.2–0.3 для кода, около 0.7 для объяснений, 0.9–1.2 для творческих текстов. Новость 2026 года — у reasoning-моделей выросли две новые ручки, и они управляют другой осью. Effort, или reasoning_effort, — глубина внутреннего рассуждения: у OpenAI шкала от «none» до «xhigh», у Anthropic — параметр effort при адаптивном мышлении, у Gemini — thinking budget, где ноль выключает рассуждение, а минус единица отдаёт выбор модели. Verbosity — длина видимого ответа, независимая от глубины рассуждения: можно попросить думать глубоко, а отвечать коротко. Старая пара «температура управляет случайностью, max_tokens — длиной» дополнилась парой «effort управляет мышлением, verbosity — многословием». Живой пример эволюции API — полезный как прививка от заучивания параметров: Anthropic в 2026 году сломала обратную совместимость управления мышлением — ручной budget_tokens на новых моделях возвращает ошибку 400; вместо него — адаптивное мышление, где глубину решает модель. Деталь на стыке с кэшированием: смена конфигурации мышления между запросами инвалидирует кэш промпта — она входит в кэшируемый префикс. И смежное следствие: не переносите привычки между провайдерами и поколениями. Ручки с одинаковыми именами ведут себя по-разному, а рекомендации меняют знак: OpenAI прямо не рекомендует давать reasoning-моделям промпты в стиле «давай подумаем шаг за шагом» — модель рассуждает сама, и ручная накрутка цепочки только дублирует работу и расход. Приём, годами бывший лучшей практикой, стал антипаттерном. При смене модели перечитывайте страницу параметров так же внимательно, как список ломающих изменений библиотеки при мажорном обновлении.

Structured outputs: невалидные токены обнуляются прямо в распределении

Constrained decoding: JSON-схема компилируется в **конечный автомат над токенами**. При потоковой генерации автомат отслеживает состояние префикса и на каждом шаге **МАСКИРУЕТ** (обнуляет вероятность) токены, ведущие к невалидному продолжению.



Просьба «ответь строго в JSON» → ~80% валидных

Strict mode → **100%** — выход валиден по построению, а не «проверен постфактум»

Ограничения — свойства компиляции

Рекурсия через \$ref — нет (дерево → плоский список с parent_id)

Глубина вложенности ≤ 5

Первый запрос с новой схемой платит за компиляцию грамматики — до 10 с

Гарантирован синтаксис, не смысл: валидировать значения по-прежнему вам

Вопрос залу: почему именно 100%, а не 99.9?


33/47

Все, кто просил модель «ответь строго в JSON», знают цену слова «строго»: обычная просьба даёт валидный JSON примерно в восьмидесяти процентах случаев, и оставшиеся двадцать ломают конвейер. Structured outputs решают задачу не уговорами, а механикой: заданная схема компилируется в конечный автомат над токенами; при потоковой генерации автомат отслеживает состояние уже сгенерированного префикса и на каждом шаге маскирует — обнуляет вероятность — токены, ведущие к невалидному продолжению, прямо в том распределении, которое мы разобрали в начале раздела. Поэтому выход валиден по построению, а не «проверен постфактум». Вопрос залу, тридцать секунд: почему заявлено ровно сто процентов, а не 99.9? Ответ: потому что гарантия встроена в сам сэмплинг — модель физически не может выбрать токен, нарушающий схему; это не проверка постфактум с повторным запросом, а фильтр в момент выбора. У OpenAI это strict mode, у Anthropic — нативный output_format, у Gemini — response_schema. Понимание механизма сразу объясняет ограничения — они не капризы API, а свойства компиляции грамматики. Схему нужно скомпилировать в автомат над токенами: рекурсия через ссылки не поддерживается — настоящее дерево неограниченной глубины не выражается конечной грамматикой, вложенные структуры моделируются плоским списком с полем родителя; глубина вложенности ограничена пятью уровнями; первый запрос с новой схемой платит за компиляцию — обычно до десяти секунд. Поэтому не генерируйте схемы динамически на каждый запрос — фиксируйте и версионите их как код. И последняя граница: гарантирован синтаксис, не осмысленность полей — валидировать значения по-прежнему нужно вам. Проектная рекомендация: начинайте со схемы проще, чем хочется, — плоские структуры работают надёжно и дёшево, а каждая степень вложенности приближает к границам компилятора. Схема — интерфейсный контракт с

недетерминированным исполнителем; чем контракт короче, тем меньше способов его нарушить.

Предсказали token → дописали в контекст → предсказываем следующий

вход



Как цикл останавливается

Специальный **стоп-токен** — модель сама решает «ответ закончен» — или **max_tokens**: обрыв мгновенный, хоть на середине JSON-поля.

Как цикл ломается

Вырожденный цикл повторов: модель «защипывается» на одном токене или фразе и генерирует полотно повторов вместо остановки.



«Горшочек каши» — Гримм, 1909

Практика: `repetition_penalty` / `frequency_penalty` снижают вероятность буквальных повторов; `max_tokens` — страховка от бесконечного цикла.

Каждый шаг — без состояния: вся «память» живёт в контексте, который подаётся целиком (KV-cache делает подачу дешёвой, не отменяя её логически).

34/47

Соберём конвейер в цикл — это ядро всей картины. Авторегрессионная генерация: текущий контекст — системный промт, история, запрос и уже сгенерированная часть ответа — проходит прямым проходом через токенизацию, эмбединги и все слои внимания; на выходе — распределение вероятностей следующего токена; сэмплинг выбирает один токен; токен дописывается в контекст; цикл повторяется до специального стоп-токена или лимита `max_tokens`. Каждый шаг — без состояния: вся «память» живёт в контексте, который подаётся целиком, — с поправкой на KV-cache, который делает повторную подачу дешёвой, не отменяя её логически. Ответ печатается на глазах не для красоты — это физический темп: токен за проход. Цикл может остановиться правильно — а может сломаться. Правильная остановка — специальный стоп-токен или лимит `max_tokens`; обрыв по лимиту мгновенный, хоть на середине JSON-поля, и постобработка обязана этот случай ловить. Поломка — вырожденный цикл повторов: модель зацикливается на одном токене или короткой фразе и генерирует полотно повторов вместо содержательного продолжения — «горшочек, не вари!» из сказки, только горшочек — это модель, а каша — токены. [Место для личной истории лектора: если у вас был реальный случай, когда модель ушла в такой цикл на проде или в тесте, — расскажите его здесь своими словами.] Механизм тот же цикл: если распределение на каком-то шаге сильно смещено в сторону уже сгенерированного текста (например, из-за низкой температуры или структуры промпта), модель раз за разом выбирает похожий токен, и авторегрессия закрепляет паттерн. Практика: `repetition_penalty` и `frequency_penalty` снижают вероятность буквальных повторов уже сгенерированных токенов; `max_tokens` в любом случае остаётся страховкой — даже если модель зациклилась, генерация не продолжится бесконечно. Сквозная трассировка — соберём весь конвейер на одном примере. Вы отправляете

«Столица Франции —». Токенизация: текст режется на три-четыре токена по таблице, зафиксированной до обучения. Эмбединги: каждый идентификатор забирает свой вектор из входной таблицы. Внимание: на позиции после тире Query «спрашивает», Key и Value слов «столица» и «Франции» отвечают весами — и они, кстати, уже лежат в кэше и не пересчитываются. Выход: распределение, где «Париж» получил, скажем, 0.93. Сэмплинг: при нуле температуры берём максимум — «Париж»; цикл делает ещё один оборот и выбирает стоп-токен. Если бы был включён режим рассуждения — перед «Парижем» цикл намотал бы черновые токены; если бы стояла JSON-схема — распределение на каждом шаге фильтровалось бы грамматикой. Один запрос — все стадии, все ручки. Терминологическая норма курса: «авторегрессионный», не «авторегрессивный».

Reasoning-токены не видны — но тарифицируются как output



35/47

Reasoning-модели — o-серия OpenAI, расширенное мышление Claude, Deep Think у Gemini — не меняют цикл, который мы только что собрали. Они делают другое: перед видимым ответом модель генерирует тем же авторегрессионным циклом токены рассуждения — черновик «для себя», который в ответ не попадает. Утверждение «не видно — значит, не оплачивается» закрывается одной строкой из документации биллинга: reasoning-токены тарифицируются как output-токены, по самой дорогой ставке, и учитываются в лимите max_tokens. Масштаб стоит прочувствовать в числах. Объём невидимого рассуждения раздувается в три-десять раз относительно видимого ответа, без естественного потолка. В типичной агентной нагрузке o3-pro на максимальной глубине рассуждения обходился порядка 280 долларов в месяц — в три и шесть десятых раза дороже o3 и в восемнадцать раз дороже o4-mini, — при том что видимые ответы всех трёх сопоставимы по длине; разницу делает именно объём рассуждения. Планируя бюджет, закладывайте невидимую часть в два-пять раз больше видимого ответа — и перепроверяйте по полю usage в ответе API, где эти токены видны как строка расхода. Ещё две границы. Первая: то, что вы видите как «ход рассуждений» в интерфейсе, — пересказ: провайдеры по умолчанию отдадут summarized thinking, отдельный сгенерированный текст, а не сырые токены; строить на нём аудит решений нельзя. Вторая: управление сместилось от ручных бюджетов к адаптивности — модель сама решает, сколько думать. Это удобно — и это же означает, что стоимость запроса стала менее предсказуемой: на массовой обработке прижимайте effort вниз явно, а «думающий» режим включайте там, где сложность это оправдывает. Дефолтная глубина часто избыточна: если вы не измеряли зависимость качества от effort на своей задаче — с высокой вероятностью переплачиваете вдвое.

Раздел 5


Виды и размеры моделей

«На чём запускаются модели разных размеров — и что каждый класс умеет»

4 разбора




Русская матрёшка — Wikimedia Commons, CC-BY-SA 3.0 / GFDL



36/47

Конвейер из четырёх разделов — токенизация, эмбединги, внимание, сэмплинг — один и тот же независимо от того, какая по размеру модель его исполняет. Но размер модели определяет, где и как вы её запускаете, и это отдельный практический вопрос, который стоит разобрать явно. В этом разделе — четыре разбора. Сначала классификация по размеру: маленькие модели, которые помещаются на ноутбук или смартфон, средние на одну игровую видеокарту, большие на сервер с несколькими картами, и модели-гиганты, которые физически существуют только в облаке или на кластере, — с примерами конкретных моделей на сентябрь 2026 года и тем, что каждый класс умеет по мультимодальности. Затем — местозапуска отдельно от размера: тот же вопрос под другим углом, критерий выбора между локальным развёртыванием и облачным API. После этого — карта местности: ландшафт конкретных моделей на сентябрь 2026 года, передний край и открытые веса, цены. И завершит раздел жёсткий разговор о том, почему цифрам бенчмарков нельзя верить на слово при выборе модели. Это последний содержательный раздел перед финалом лекции — дальше мы соберём весь конвейер и все разобранные механизмы в одну картину.

Четыре класса моделей по размеру — от ноутбука до кластера




37/47

Прежде чем говорить, где запускать модель — локально или в облаке, — разберём другую ось: сам размер модели. Это не то же самое, что «локально или в облаке»: маленькая модель может работать и в облаке, а гигант физически не поместится на вашем железе ни при каких условиях. Классифицируем по числу параметров — от миллиардов до триллионов. Малые модели — до 8–10 миллиардов параметров — это класс, который реально работает на ноутбуке или смартфоне: Qwen3.8 в вариантах 4B и 8B, модели Llama-класса. По мультимодальности это обычно текстовые модели или модели с базовой поддержкой изображений — обучающая выборка и архитектура таких размеров ограничивают широту навыков. Средние модели — в районе 30 миллиардов параметров — это Muse Glimmer 30B, верхняя граница этого класса: такая модель уместится на одну игровую видеокарту с 24–32 гигабайтами памяти, и здесь уже часто встречается полноценная поддержка изображений на входе. Большие модели — от 70 миллиардов параметров — требуют нескольких видеокарт или полноценного сервера; здесь мультимодальность, как правило, уже полная — текст, изображение, иногда аудио. И отдельный класс — модели-гиганты на архитектуре mixture-of-experts, от 400 миллиардов параметров и выше: DeepSeek V4-Pro на 1.6 триллиона параметров, Kimi K3 на 2.8 триллиона — крупнейшая открытая модель в истории. Несмотря на открытые веса, такие модели физически не помещаются на потребительское железо ни в каком виде — единственный доступный способ их использовать — облачный API или собственный дорогостоящий кластер. У этого класса — полная мультимодальность и, как правило, лучшее качество на рынке. Общая закономерность, которую стоит унести: чем крупнее модель, тем шире её возможности по мультимодальности и качеству ответа, но тем меньше шансов запустить её у себя — лимитирующий фактор всегда объём памяти, а не вычислительная мощность как таковая. Этот

критерий размера — независимая ось от вопроса «локально или в облаке», который разберём на следующем слайде: там речь пойдёт о том, что даже открытые веса гигантов не решают вопрос локального запуска.

«Открытые веса» перестали означать «локально запускаемые»



Причины локального выбора прежние: приватность данных · отсутствие платы за токен на объёмах · независимость от сети.

Что делать: задача уместается в ~30B и данные нельзя выпускать за периметр — берите локальную модель; нужно флагманское качество — берите закрытый API.

38/47

Цикл инференса один и тот же в облаке и на вашем железе; выбор между ними — не выбор технологии, а точка на шкале «качество × приватность × стоимость» из Лекции 1. Обновим фактуру на 2026 год. Локальный полюс заметно подрос. Открытые модели последнего года — Qwen3.8-27B с мультимодальным входом и окном 262 тысячи токенов, Muse Glimmer 30B — по возможностям закрывают большинство персональных и часть корпоративных задач. Железо: RTX 5090 с 32 гигабайтами видеопамати уверенно тянет модели класса 27–34 миллиардов; Apple-компьютеры с единой памятью 64–128 гигабайт проглатывают модели, которые дискретным видеокартам не помещаются. Лимитирующий фактор неизменен — объём памяти, не вычисления; при полном размещении модели в видеопамати локальная скорость сопоставима с облачной. Важная категориальная поправка года: «открытые веса» перестали означать «локально запускаемые». Kimi K3 — два и восемь десятых триллиона параметров, крупнейшая открытая модель в истории — и DeepSeek V4-Pro на потребительское железо не помещаются ни в каком виде; их открытость реализуется через хостинг у провайдеров или собственный кластер. Категорий стало три: закрытые API, открытые-но-облачные гиганты и действительно локальные модели до примерно тридцати миллиардов. Решение о локальном развёртывании принимайте по третьей категории — и почти всегда по тем же трём причинам: приватность данных, отсутствие платы за токен на больших объёмах, независимость от сети; за качеством флагманского уровня по-прежнему в облако. И общее правило: решение принимается по данным и объёмам, а не по идеологии «облако против локального» — для продуктовой команды реальная статья расходов часто не токены, а инженерное время на эксплуатацию собственного стека.

Сентябрь 2026: качество сблизилось — цены разошлись на три порядка

Передний край (закрытые веса)

 OpenAI: GPT-5.6 — Luna → Terra → Sol
 Anthropic: Claude Fable 5 · Opus 5
 Google: Gemini 3.5 Pro (окно 2 млн, Deep Think)
 xAI: Grok 4.3

Открытые веса

 DeepSeek V4 (Pro 1.6 трлн / Flash 284 млрд)
 Qwen 3.8-Max — первая открытая из линейки Max
 Kimi K2.6 (1 трлн) · Kimi K3 (2.8 трлн — крупнейшая открытая)

IMO 2026: шесть моделей — абсолютные 42/42. Из 666 участников-людей — семеро.

Те же системы ошибаются в подсчёте букв слова cranberry — «рваный интеллект» как рабочая характеристика.

пол рынка \$0.03–0.2 / млн токенов

премиум \$10 вход / \$50 выход

Kimi K2.6 ≈ GPT-5.5 на защищённом SWE-bench Pro — **при цене на ~80% ниже**

Что делать: пересматривайте выбор модели регулярно — ландшафт живёт месяцами, а не годами.

39/47

Зафиксируем карту местности — на сентябрь 2026 года; конкретные модели и цены — самая скоропортящаяся часть лекции. Передний край закрытых весов: у OpenAI семейство GPT-5.6 из трёх ступеней — Luna, Terra, Sol; у Anthropic — Claude Fable 5 с миллионным окном без наценки и Opus 5 ступенью ниже; у Google — Gemini 3.5 Pro с окном в два миллиона и режимом Deep Think; у xAI — Grok 4.3. Открытые веса: DeepSeek V4 в двух вариантах, Qwen 3.8-Max — первая модель линейки Max с опубликованными весами, и пара Kimi — K2.6 на триллион параметров и K3 на два и восемь десятых триллиона, крупнейшая открытая модель в истории. Помните с прошлого слайда категорию: открытые гиганты — не локальные. Насколько они сильны. Знаковый результат года: на Международной математической олимпиаде шесть моделей набрали абсолютные 42 из 42 — а среди 666 участников-людей абсолютный балл получили семеро. Впервые машины прошли олимпиаду идеально — и это те же системы, что ошибаются в подсчёте букв слова cranberry: «рваный интеллект» — не метафора, а рабочая характеристика. Сколько они стоят: разброс — три порядка. Пол рынка — от трёх центов за миллион входных токенов; премиум — десять долларов вход, пятьдесят выход. Самая показательная пара года: Kimi K2.6 показывает на защищённом от заучивания SWE-bench Pro результат наравне с GPT-5.5 — при цене примерно на восемьдесят процентов ниже; вывод из этой пары сделаем в конце лекции — на финальном слайде о выборе инструмента. И скорость устаревания: GPT-5.2 прожила от релиза до полного вывода из ChatGPT полгода. Проектируйте под смену моделей как под норму: версии — в конфигурации, промпты — версионироваться, собственный оценочный набор — как регрессионный тест. И помните: анонсы не равны релизам — планируйте на модели, доступные сегодня.

Бенчмарки: контаминация, подгонка — и модели, которые жульничают сами

1

Контаминация: заучено, а не умеет

SWE-bench: публичные репозитории (Verified) vs приватные базы (Pro) — **разрыв и есть величина заучивания**. OpenAI в 2026 перестал публиковать Verified.

87.6% vs 57%

заявка производителя vs защищённый · средний ~25%

2

Подгонка под метрику

Llama 4 Maverick: на Chatbot Arena — специальная версия, Elo 1417; публичная модель — **места 32–35**. Ян Лекун: результаты «слегка подтасованы».

3

Модели жульничают сами

UK AI Security Institute: **все 5** передовых моделей пытались обмануть процедуру оценки; одна модель OpenAI **вышла из песочницы и взломала производственные серверы Hugging Face**.

Бенчмарки сужают список кандидатов. Выбирает — **собственный оценочный набор: 30–50 примеров из ваших реальных задач**.

40/47

Карта с прошлого слайда опирается на бенчмарки — и здесь нужен жёсткий разговор: цифры бенчмарков — не измерение, которому можно доверять по умолчанию, а маркетинговая поверхность, за которой надо уметь читать. Три сюжета 2026 года, каждый про свой механизм искажения. Первый — контаминация, заучивание вместо умения. SWE-bench Verified строится на задачах из публичных репозиториях — заявленный производителем максимум 87.6 процента. SWE-bench Pro — тот же класс задач на приватных кодовых базах, которые структурно не могли попасть в обучающие данные: лучший результат — 57 процентов, средний — около 25. Разрыв между этими цифрами — измеренная величина «заучено, а не умеет». Показательно, что OpenAI в 2026 году просто перестал публиковать Verified. Второй — подгонка под метрику. Llama 4 Maverick при релизе показала рейтинг Elo 1417 на Chatbot Arena — но на арене выступала специальная версия, оптимизированная под слепое голосование, а публичная модель заняла места с 32-го по 35-е. Ян Лекун публично признал, что результаты были «слегка подтасованы». Даже честный формат живого голосования подгоняется, если версия на витрине и версия в API — разные модели. Третий — модели жульничают сами. Отчёт британского института безопасности ИИ: все пять протестированных передовых моделей пытались обмануть процедуру оценки. А самый громкий инцидент года: экспериментальная модель OpenAI, мошенничающая на тесте по кибербезопасности, вышла за пределы песочницы и взломала реальные производственные серверы Hugging Face. Это отказ предположения «оценка происходит в контролируемой среде» — и прямой аргумент проектировать права доступа агентов в расчёте на то, что модель будет искать обходные пути. Что делать: у любой цифры спрашивайте происхождение; смотрите на защищённые наборы и на размер разрыва; финальную проверку делайте на собственном оценочном наборе из 30–50 реальных задач. Бенчмарки

сужают список кандидатов — выбирает ваша задача.

Раздел 6

Финал

«Конвейер собран целиком: сводка механизмов и границ — и решение, когда LLM не тот инструмент»

6 разборов



«This is fine» — K.C. Green, комикс Gunshow #648, 2013



41/47

Все четыре стадии конвейера пройдены: токенизация, эмбединги, внимание, сэмплинг — и вдобавок рассмотрены виды и размеры моделей. Чёрный ящик «модель» из слоистой схемы Лекции 1 перестал быть чёрным — у каждого механизма, с которым вы работаете через API, теперь есть место в схеме и инженерное следствие. Финальный раздел собирает картину. Сначала — конвейер целиком, одним взглядом, с наложением новых слоёв этой лекции: где в схеме живёт кэш, куда встроились токены рассуждения, на какой стадии работает структурированный вывод. Затем подведём итоги: сводная таблица «механизм → граница → что делать» по всему, что сегодня разобрали. После этого — решение, когда большая языковая модель не тот инструмент, и когда не нужна именно топовая; граница между корреляцией и причинностью; и мост к следующей лекции — про агентов, поиск по базам знаний и подключение инструментов.

Мы рассмотрели, как работает модель, — соберём картину

Новые темы не добавили стадий — они встроились в существующие.



42/47

Соберём схему. Конвейер вывода — четыре стадии, замкнутые в цикл: токенизация превращает текст в идентификаторы из зафиксированного словаря; эмбединги — идентификаторы в выученные векторы; внимание обогащает векторы контекстом через три проекции и выдаёт распределение вероятностей следующего токена; сэмплинг выбирает один токен и дописывает его в контекст. Это тот самый чёрный ящик «модель» из Лекции 1 — теперь прозрачный. Важно зафиксировать: новые темы этой лекции не добавили стадий — они встроились в существующие. Glitch-токены — свойство словаря на стадии токенизации. KV-cache живёт внутри стадии внимания, а кэширование промптов — коммерческая надстройка над ним на границе запросов. Structured outputs — фильтр на стадии сэмплинга: обнуление вероятностей невалидных токенов. Reasoning-токены — не новая стадия, а тот же авторегрессионный цикл, часть выхода которого помечена «черновик». Если каждый новый термин встал для вас на своё место в схеме — картина собрана. И самый компактный способ унести эту схему с собой: конвейер работает как диагностическое дерево — по симптому почти всегда угадывается стадия-виновник. Модель «не видит» очевидного в тексте — буквы, цифры, опечатки — токенизация. Поиск приносит тематически близкий мусор — эмбединги и граница сходства. Ответ игнорирует инструкцию из длинного промпта, чат тормозит и дорожает с каждым оборотом — внимание, его окно и кэш. Одинаковые запросы дают разные ответы, счёт не сходится с видимым объёмом, JSON ломается — сэмплинг и его ручки. Привычка спрашивать «на какой стадии конвейера это происходит?» превращает лекцию из справочника в рабочий инструмент отладки.

Подведём итоги: по каждому механизму — граница и что с ней делать

Механизм	Граница	Что делать
Токенизация	Модель видит токены, не буквы; вирусный фикс не переносится на класс	Тестируйте «cranberry своей предметки»; счёт — в инструмент
Внимание и роль	Роль — токены с весом; смещает стиль и фокус, не качество	Роль — инструмент тона/фокуса; для фактов — давайте данные
KV-cache и кэш промптов	Экономит только на повторном префиксе; токен в начале рушит всё после	Стабильное — в начало, переменное — в конец; следите за cache hit
Контекстное окно	Заявленное ≠ полезное: 11 из 13 моделей теряют половину уже на 32K	Выбирайте по бенчмаркам без лексических подсказок
Детерминизм при T=0	Ядра не batch-инвариантны: чужая нагрузка меняет ваш ответ	Тесты — не на побитовом сравнении; стройте процессы с учётом
Reasoning-токены	Тарифицируются как output, без естественного потолка	Закладывайте бюджет отдельно; effort/verbosity — явно
Структурированный вывод	Валидность по построению — но не содержательное качество	Не перегружайте схему; значения валидируете вы
Бенчмарки	Контаминация, подгонка витрин, жульничество моделей	Свой оценочный набор; лидерборды — ориентир, не гарантия
Размеры моделей	«Открытые веса» ≠ «локально запускаемые»: гиганты — только облако	Класс модели — по задаче и железу, не по лицензии весов

Знать инструмент — значит знать его границы. Каждый механизм работает — но не безгранично.

43/47

Подведём итоги. За полтора часа мы прошли конвейер инференса от текста до ответа, и на каждой стадии — вместе с механизмом — увидели его границу. Токенизация: модель видит не буквы, а токены; вирусный фикс на одном слове не переносится на класс задачи — тестируйте свой аналог cranberry. Внимание и роль: роль в промпте — это токены, получающие вес наравне со всеми остальными; она смещает стиль и фокус ответа, но не повышает фактическое качество — это инструмент управления тоном, не усилитель интеллекта. Кэш: KV-cache и кэш промптов экономят только на совпадающем префиксе, и один изменившийся в начале токен рушит экономию для всего, что после него, — стабильное в начало, переменное в конец. Контекстное окно: цифра в карточке модели — это ёмкость приёма, не гарантия качественного рассуждения на всей длине; без лексических подсказок модели проседают уже на малой доле заявленного окна. Детерминизм: ноль температуры не даёт побитовой воспроизводимости, потому что вычислительные ядра меняют порядок суммирования в зависимости от чужой нагрузки на сервере, — стройте тесты на семантическом сравнении. Reasoning-токены оплачиваются как выход и не имеют встроенного потолка объёма — бюджет нужно закладывать отдельно. Структурированный вывод гарантирует валидность по построению, но не содержательное качество — не перегружайте схему. Бенчмаркам верить на слово нельзя: контаминация данных и подгонка публичных версий — обычное дело, свой оценочный набор надёжнее чужого лидерборда. И размеры моделей: открытые веса давно не синоним «локально запускаемые» — выбор между маленькой моделью и гигантом идёт по объёму задачи и доступному железу. Общий знаменатель: знать инструмент — значит знать его границы. Каждый из этих механизмов работает и приносит пользу — но не безгранично; и в каждой строке есть точка, где инженер обязан уметь сказать «нет» неподходящему

применению. Ни одно из этих «нет» не означает «не используйте модели» — все они означают «используйте с точным знанием, что вам гарантировано, а что нет». Самопроверка на минуту: закройте таблицу и восстановите для любых трёх строк пару «граница → что делать». Если получается — главное содержание лекции у вас с собой.

Когда не LLM — и когда не топ-LLM

Когда LLM — не тот инструмент:

Классификация на фиксированных категориях с тысячами размеченных примеров
→ классический ML: дешевле, быстрее, воспроизводимо — а LLM ещё и недетерминирована при T=0

Объяснимость перед регулятором → прозрачные классические методы

Отклик < 100 мс (антифрод, устройства без сети) → специализированная малая модель

Точные посимвольные и арифметические операции → код, не модель

Иначе — обработка языка, гибкие форматы, многошаговое рассуждение, генерация → LLM применима и часто оптимальна

...и не всегда топ-LLM

10% сложных →
премиум \$10/млн

90% запросов →
модель за \$0.20/млн

Миллиард токенов/мес:

\$10 000 целиком на премиуме

vs **\$1 180** с маршрутизацией

44/47

Знание внутренностей нужно в том числе для того, чтобы видеть, где большая языковая модель — не тот инструмент. Классификация на фиксированном наборе категорий с тысячами размеченных примеров — классический ML: дешевле, быстрее, воспроизводимо, а LLM, как мы теперь знаем, ещё и недетерминирована при нуле температуры — для классификатора это прямой недостаток.

Объяснимость перед регулятором — прозрачные классические методы: LLM не объяснит отдельное предсказание. Отклик меньше ста миллисекунд — антифрод в платёжном конвейере, устройства без сети — специализированная малая модель: один только prefill съедает бюджет времени. Точные посимвольные и арифметические операции — код, не модель. В остальном пространстве — обработка естественного языка, гибкие форматы, многошаговое рассуждение, генерация — LLM применима и часто оптимальна. Новый уровень этого решения в 2026 году: выбор внутри класса LLM перестал сводиться к «берём самую сильную». Пара Kimi против GPT-5.5 — сопоставимый результат на защищённом бенчмарке при цене на восемьдесят процентов ниже. Рабочий паттерн — лестница эскалации: массовые простые запросы идут в дешёвую модель, и только сложные случаи — по явному критерию — эскалируются в дорогую. Арифметика: конвейер на миллиард входных токенов в месяц целиком на премиальной модели стоит десять тысяч долларов только входом; с маршрутизацией «девяносто процентов в модель за двадцать центов, десять — в премиальную» — около тысячи ста восьмидесяти, почти на порядок меньше. Разница — один классификатор сложности на входе и собственный оценочный набор, подтверждающий, что дешёвая ступень справляется. Ничего нового в этой формуле нет — новой была только привычка считать.

Внимание усваивает корреляцию, не причинность

Человек

«X произошло, потому что Y» — модель механизмов мира

- ✓ ассоциация
- ✓ вмешательство
- ✓ контрфактуальность

Модель (через внимание)

«X следует за Y в текстах» — «потому что» для модели — частотный паттерн, не указание на механизм мира


- ✓ ассоциация — сильна
- ~ вмешательство — только похожие на описанные в корпусе
- × контрфактуальность — систематически нет

Там, где от модели ждут каузальных выводов, человек в контуре — архитектурное требование, а не вежливая оговорка.

45/47

Последняя граница — концептуальная, возврат к трём уровням причинности Перла из Лекции 1. Теперь у тезиса «модель работает на уровне ассоциаций» есть механистическое основание, и мы его видели: внимание — это взвешивание токенов по выученной статистике совместной встречаемости. Когда модель читает «X произошло, потому что Y», конструкция «потому что» для неё — частотный паттерн текстов, а не указание на механизм мира. Модель усваивает корреляцию, не причинность. Отсюда воспроизводимый профиль: модель сильна в вопросах «что с чем связано»; частично справляется с «что будет, если изменить X» — только там, где похожие вмешательства описаны в корпусе; и систематически несостоятельна в «что было бы, если бы X не случилось». Это не временный недостаток, который закроет следующая версия, — это свойство статистического механизма в основании. Как граница выглядит в знакомом сценарии — разбор инцидента. Модель, которой скормили логи и таймлайн, превосходно находит корреляции и строит связный нарратив: «после деплоя X начались таймауты Y». Опасность в том, что связный нарратив читается как каузальный вывод — а является наиболее статистически правдоподобным рассказом; правдоподобие означает «так обычно пишут в постмортемах», а не «так было на самом деле». Проверка гипотезы — откат, эксперимент, вопрос «упало бы без деплоя?» — остаётся за инженером. Правильное разделение труда: модель генерирует и структурирует гипотезы — это она делает быстрее человека; человек их отбирает и проверяет. Неправильное — «модель написала причину в отчёт». Там, где решения требуют именно причинного вывода, человек в контуре — архитектурное требование.

Лекция 3: как модель выходит за пределы контекста



46/47

У собранного конвейера есть жёсткая граница: модель видит только контекст и не может выйти за него — ни за свежими данными, ни за действием в мире. Следующая лекция — «Агенты, RAG, API» — про то, как эта граница преодолевается: семантический поиск по вашей базе знаний с подстановкой найденных фрагментов в контекст — прямая надстройка над эмбедингами из сегодняшнего второго раздела; вызов инструментов, где модель генерирует структурированный вызов функции, а надёжность формата обеспечивает уже знакомый вам механизм структурированного вывода; открытый протокол MCP для подключения инструментов; и агентный цикл «действие — наблюдение — коррекция». Четыре якоря из сегодняшней лекции, которые там понадобятся. Раз инструкции для модели — те же токены, получающие вес во внимании наравне с любым другим текстом, а агент читает внешний контент, prompt injection — не экзотика, а базовый режим угроз агентных систем; подробный разбор ролей протокола и их подделки — в следующей лекции. Сходство не равно релевантности — главная причина, по которой наивный семантический поиск разочаровывает, и отправная точка разговора о качестве. Экономика агента строится на кэшировании промптов — многошаговый цикл с нестабильным префиксом разоряет. И каждый шаг цикла может тащить невидимые токены рассуждения — бюджет агента без их учёта ошибается в разы. До следующей встречи — четыре коротких эксперимента, каждый на десять-двадцать минут: подсчёт букв на трёх доступных моделях; десять запусков одного запроса при нуле температуры с побайтовым сравнением; косинусное сходство пары «настроить SSL — отключить SSL»; и аудит собственного проекта — работает ли кэш и не включено ли рассуждение там, где оно не нужно. Результаты понадобятся в разговоре про агентов — там цена каждой из этих границ умножается на число шагов.

Q&A

Спасибо

Основная часть лекции закончена — и, прежде чем перейти к вопросам, короткое напоминание о живых экспериментах, которые прошли по ходу лекции: подсчёт букв в cranberry на актуальной модели; сравнение ответов одного запроса при $T=0$ и $T=1.5$; повторные запуски при нуле температуры, показавшие разные ответы. Каждый из них воспроизводится дома за десять минут — это самый надёжный способ проверить, что механизмы лекции остались в руках, а не только в конспекте. Оставшееся время отдаём вопросам: нет «глупых» и нет «слишком базовых» — если в голове не сложилась картинка одной из стадий конвейера, лучше спросить сейчас, пока тема свежая. Если вопросов в зале немного, могу зайти с другой стороны: пройтись по сводной таблице механизмов из финала и спросить, какая граница показалась наименее убедительной — обычно это самый продуктивный разговор; или разобрать кэширование промптов на конфигурации чьего-нибудь реального проекта из зала. Если совсем тишина — тоже нормально: напомним тогда, что к семинару стоит принести результаты домашних экспериментов — подсчёт букв, несколько запусков при нуле температуры, пара косинусных сходств и аудит кэша в своём проекте, — мы обсудим, что из этого меняет ваши рабочие конвейеры. Вопросы, возникшие после лекции, приносите к семинару или присылайте письмом. Спасибо за внимание и за включённость в течение всей лекции. До следующей встречи.