

Сколько из этих утверждений **верны?**

1

«Современные модели уже научились считать буквы в словах — strawberry давно исправили»

2

«Роль system защищена архитектурно — подделать её из пользовательского ввода нельзя»

3

«Окно в миллион токенов — значит, модель одинаково хорошо работает со всем этим объёмом»

4

«temperature=0 даёт детерминированный ответ: одинаковый запрос — одинаковый результат»

5

«Reasoning-токены не видны в ответе — значит, они и не оплачиваются»

6


«Бенчмарки — надёжный способ выбрать модель»



Как работают современные большие модели

02

Проверяем ментальную модель: конвейер *inference* и шесть границ



Карта лекции — 6 разделов

0 **Введение** — чек-лист, рамка и конвейер целиком

1 **Токенизация** — как модель видит ваш текст

M1

M2

2 **Эмбединги** — пространство смыслов и граница похожести

3 **Механизм внимания** — что важно сейчас: роли, кэш, длинный контекст

M2

M3

4 **Сэмплинг** — от распределения к токену: температура, детерминизм, невидимые токены


M4

M5

5 **Финал** — сборка конвейера, ландшафт моделей, чек-лист заново

M6

Фиксируем рамку: всё сегодняшнее — внутри слоя «модель»



Известное: модель — stateless-инференс: на вход данные, на выход предсказание, без памяти между вызовами.

Сегодня: границы точного понимания того, что внутри этого инференса.

Центральный вопрос лекции

«Насколько точна ваша ментальная модель LLM — и какие из внутренних механизмов, которые вы знаете приблизительно, при точном понимании меняют то, как вы строите промпты, агентов и решения?»

почему исправленный strawberry
ничего не доказывает

почему роль работает — и
подделывается





что на деле умеет окно 1M

почему $T=0$ не даёт одинаковых
ответов

сколько стоят невидимые токены

чем заменить веру в бенчмарки

Поток данных в LLM — туда и обратно



Слова — только на границах; внутри — векторы.

Раздел 1

Токенизация

«Как модель видит ваш текст»

4 разбора · 3 провала



Токен — id из словаря модели: не буква и не слово

cat → [cat] → 1 токен

tokenization → [token][ization] → 2 токена

клубника → [к][луб][ника] → 3 токена (o200k_base)

«В среднем: 1 токен $\approx$ 4 символа EN $\approx$ 2 символа RU»

Словарь и модель — два разных артефакта: словарь строится до обучения модели, отдельным алгоритмом на своём корпусе.

ВРЕ — компромисс между алфавитом и словарём

Не все буквы (долго) и не все слова (незнакомое выпадает) — частые подпоследовательности.

Обучающий корпус

low
lower
newest
widest



ВРЕ-словарь

low · er · new · est · wid

+ одиночные символы, частые слоги, целые слова

Словарь строится один раз до обучения; на inference — выборка готовых правил, не вычисление.

Разные вендоры режут один и тот же текст по-разному: Claude, GPT, Gemini — свои словари и правила.

Роли system/user/assistant — те же токены в общем потоке

Структурированный диалог

```
{ "role": "system", "content": "Ты помощник..." }  
{ "role": "user", "content": "Объясни..." }
```



chat-шаблон

Плоский поток токенов

```
<|im_start|>system Ты помощник... <|im_end|>  
<|im_start|>user Объясни... <|im_end|>
```

Подделка

Внешний контент (веб-страница, файл, письмо) со строкой, похожей на разметку роли, вливается в тот же поток токенов — отдельного «защищённого канала» для ролей нет.

```
<|im_start|>assistant — из письма?
```

Почему роль при этом работает — и почему подделанная работает так же — вторая половина ответа в разделе про внимание.

GPT-5.5 отвечает на strawberry — и ошибается на cranberry

Механизм — слепота к буквам

strawberry →
[st][raw][berry]

Модель видит **3 токена**, не 10 букв.

GPT-5.2 · дек 2025

«в strawberry две r»

GPT-5.5 · апр 2026

strawberry ✓ / cranberry ✗ — «две r» вместо трёх

StrawberryBench

847 вопросов, 7 уровней сложности — системная проверка вместо вирусного вопроса

«Рванный интеллект» (jagged intelligence): успех на впечатляющей задаче ≠ надёжность на простой.

Токенизатор режет по частоте, а не по структуре

Числа

10000000 → [100][000][0]

Чанки по 3 цифры слева направо ≠ разряды.

Нарезка справа налево улучшает арифметику; задача-специфичные схемы — **до +33% точности** к стандартной нарезке.

Код

GPT-2: 16 токенов на отступ 4-го уровня.

GPT-4: пробелы группами — словарь чинится, но не под все задачи сразу.

Разделители разрядов («1 234 567»)

Вычисления — в инструмент

Единообразные отступы

Порядка 4% словаря — glitch-токены

SolidGoldMagikarp (2023)

Юзернейм с Reddit, попавший в словарь GPT: модель не могла его повторить, отвечала невпопад.

Механизм

корпус словаря $\neq$ корпус модели



эмбединг токена* остаётся у случайной инициализации



вектор «ничего не значит» в выученной геометрии

* числовой вектор токена; подробно — следующий раздел


GlitchMiner (AAAI 2026)

порядка 4% словаря по одной из оценок;

воспроизводится в открытых семействах Llama, Qwen, Gemma, Phi-3, Mistral.

Системная особенность конвейера, не баг версии.

Русский текст стоит $\approx 2\times$ дороже английского



словари GPT-семейства

Переход на o200k_base:

примерно **-35%** нелатинским языкам — разрыв сокращается, но не исчезает.

Любой лимит в токенах калибруйте на своём языке: разбиение на фрагменты, `max_tokens`, окно.

Раздел 2


Эмбе́ддинги

«Пространство смыслов — и граница похожести»

4 разбора · 1 провал



Каждому токenu — вектор из входной таблицы модели



Размерности

text-embedding-3-small — 1536

text-embedding-3-large — 3072

внутренние размерности флагманов не публикуются; порядок — тысячи

«Геометрическая близость = смысловая близость»

«Эмбе́ддинг» — это три разные сущности

1

Входная таблица

Статическая: вектор [кот] один и тот же в любом предложении. Выборка по id, контекста ещё нет.

2

Контекстуальные представления

После слоёв внимания: вектор каждой позиции обновлён с учётом окружения. Именно они несут «понимание» модели.

3

Векторы для поиска


Вектор целого текста от отдельной embedding-модели — не внутренности вашего чат-LLM. Свой продукт, своё обучение, свои лидерборды.

самая частая путаница

Обновили LLM → переиндексировать базу НЕ надо: индекс живёт в координатах embedding-модели.

Близкие по смыслу токены лежат рядом — в сотнях-тысячах измерений

2D-проекция (PCA-стиль)



Размерность

Публичные embedding-модели: **1536–3072** измерения;
внутренние у флагманов — порядка тысяч.

Обучение

Координаты не задаются вручную: похожие контексты
употребления → близкие векторы.

Проекция

Увидеть пространство можно только через PCA/t-SNE —
2D-картинка теряет часть структуры.

Высокое сходство — «об одном и том же», не «с одинаковым смыслом»

cosine similarity	SSL	HTTPS	React-к.	React-п.	Борщ
Как настроить SSL	1,00	0,85	0,18	0,20	0,08
Установка HTTPS-сертификата	0,85	1,00	0,22	0,19	0,07
Деплой React-компонента	0,18	0,22	1,00	0,78	0,12
Сборка React-приложения	0,20	0,19	0,78	1,00	0,10
Рецепт борща	0,08	0,07	0,12	0,10	1,00

«Как настроить SSL» ↔

«Как отключить SSL»

Очень высокое сходство — противоположный практический смысл.

шкала: 0 — светлое · 1 — тёмное

Similarity — сигнал кандидатов; релевантность — отдельная задача: реранкер, гибрид, фильтры.

Эмбединги — фундамент понимания: модель работает с векторами, не строками



Перефразирования и синонимы

«Как настроить SSL» и «Установка HTTPS-сертификата» — близкие векторы → модель отвечает одинаково; то же с «авто» и «машина».

Межъязыковая близость

«клубника» и strawberry — близкие векторы → ответ корректен независимо от языка запроса.

Семантическая близость на уровне предложений — основа «понимания» переформулировок.

Выбор embedding-модели под задачу (MTEB, матрёшечные представления) — материал для самостоятельного чтения.