

Сколько из этих утверждений **верны?**

1

«Современные модели уже научились считать буквы в словах — strawberry давно исправили»

2

«Роль system защищена архитектурно — подделать её из пользовательского ввода нельзя»

3

«Окно в миллион токенов — значит, модель одинаково хорошо работает со всем этим объёмом»

4

«temperature=0 даёт детерминированный ответ: одинаковый запрос — одинаковый результат»

5

«Reasoning-токены не видны в ответе — значит, они и не оплачиваются»


6

«Бенчмарки — надёжный способ выбрать модель»

Как работают современные большие модели

02

Проверяем ментальную модель: конвейер *inference* и шесть границ



Карта лекции — 6 разделов

0 **Введение** — чек-лист, рамка и конвейер целиком

1 **Токенизация** — как модель видит ваш текст

M1

M2

2 **Эмбединги** — пространство смыслов и граница похожести

3 **Механизм внимания** — что важно сейчас: роли, кэш, длинный контекст

M2

M3

4 **Сэмплинг** — от распределения к токену: температура, детерминизм, невидимые токены


M4

M5

5 **Финал** — сборка конвейера, ландшафт моделей, чек-лист заново

M6

Фиксируем рамку: всё сегодняшнее — внутри слоя «модель»



Известное: модель — stateless-инференс: на вход данные, на выход предсказание, без памяти между вызовами.

Сегодня: границы точного понимания того, что внутри этого инференса.

Центральный вопрос лекции

«Насколько точна ваша ментальная модель LLM — и какие из внутренних механизмов, которые вы знаете приблизительно, при точном понимании меняют то, как вы строите промпты, агентов и решения?»

почему исправленный strawberry
ничего не доказывает

почему роль работает — и
подделывается





что на деле умеет окно 1M

почему $T=0$ не даёт одинаковых
ответов

сколько стоят невидимые токены

чем заменить веру в бенчмарки

Поток данных в LLM — туда и обратно



Слова — только на границах; внутри — векторы.

Раздел 1

Токенизация

«Как модель видит ваш текст»

4 разбора · 3 провала



Токен — id из словаря модели: не буква и не слово

cat → [cat] → 1 токен

tokenization → [token][ization] → 2 токена

клубника → [к][луб][ника] → 3 токена (o200k_base)

«В среднем: 1 токен $\approx$ 4 символа EN $\approx$ 2 символа RU»

Словарь и модель — два разных артефакта: словарь строится до обучения модели, отдельным алгоритмом на своём корпусе.

ВРЕ — компромисс между алфавитом и словарём

Не все буквы (длинно) и не все слова (незнакомое выпадает) — частые подпоследовательности.

Обучающий корпус

low
lower
newest
widest



ВРЕ-словарь

low · er · new · est · wid

+ одиночные символы, частые слоги, целые слова

Словарь строится один раз до обучения; на inference — выборка готовых правил, не вычисление.

Разные вендоры режут один и тот же текст по-разному: Claude, GPT, Gemini — свои словари и правила.

Роли system/user/assistant — те же токены в общем потоке

Структурированный диалог

```
{ "role": "system", "content": "Ты помощник..." }  
{ "role": "user", "content": "Объясни..." }
```



chat-шаблон

Плоский поток токенов

```
<|im_start|>system Ты помощник... <|im_end|>  
<|im_start|>user Объясни... <|im_end|>
```

Подделка

Внешний контент (веб-страница, файл, письмо) со строкой, похожей на разметку роли, вливается в тот же поток токенов — отдельного «защищённого канала» для ролей нет.

```
<|im_start|>assistant — из письма?
```

Почему роль при этом работает — и почему подделанная работает так же — вторая половина ответа в разделе про внимание.

GPT-5.5 отвечает на strawberry — и ошибается на cranberry

Механизм — слепота к буквам

strawberry →

[st][raw][berry]

Модель видит **3 токена**, не 10 букв.

GPT-5.2 · дек 2025

«в strawberry две r»

GPT-5.5 · апр 2026

strawberry ✓ / cranberry ✗ — «две r» вместо трёх

StrawberryBench

847 вопросов, 7 уровней сложности — системная проверка вместо вирусного вопроса

«Рванный интеллект» (jagged intelligence): успех на впечатляющей задаче ≠ надёжность на простой.

Токенизатор режет по частоте, а не по структуре

Числа

10000000 → [100][000][0]

Чанки по 3 цифры слева направо ≠ разряды.

Нарезка справа налево улучшает арифметику; задача-специфичные схемы — **до +33% точности** к стандартной нарезке.

Код

GPT-2: 16 токенов на отступ 4-го уровня.

GPT-4: пробелы группами — словарь чинится, но не под все задачи сразу.

Разделители разрядов («1 234 567»)

Вычисления — в инструмент

Единообразные отступы

Порядка 4% словаря — glitch-токены

SolidGoldMagikarp (2023)

Юзернейм с Reddit, попавший в словарь GPT: модель не могла его повторить, отвечала невпопад.

Механизм

корпус словаря $\neq$ корпус модели



эмбединг токена* остаётся у случайной инициализации



вектор «ничего не значит» в выученной геометрии

** числовой вектор токена; подробно — следующий раздел*


GlitchMiner (AAAI 2026)

порядка 4% словаря по одной из оценок;

воспроизводится в открытых семействах Llama, Qwen, Gemma, Phi-3, Mistral.

Системная особенность конвейера, не баг версии.

Русский текст стоит $\approx 2\times$ дороже английского



словари GPT-семейства

Переход на o200k_base:

примерно **-35%** нелатинским языкам — разрыв сокращается, но не исчезает.

Любой лимит в токенах калибруйте на своём языке: разбиение на фрагменты, `max_tokens`, окно.

Раздел 2

Эмбе́ддинги

«Пространство смыслов — и граница похожести»

4 разбора · 1 провал



Каждому токenu — вектор из входной таблицы модели



Размерности

text-embedding-3-small — 1536

text-embedding-3-large — 3072

внутренние размерности фламанов не публикуются; порядок — тысячи

«Геометрическая близость = смысловая близость»

«Эмбе́ддинг» — это три разные сущности

1

Входная таблица

Статическая: вектор [кот] один и тот же в любом предложении. Выборка по id, контекста ещё нет.

2

Контекстуальные представления

После слоёв внимания: вектор каждой позиции обновлён с учётом окружения. Именно они несут «понимание» модели.

3

Векторы для поиска


Вектор целого текста от отдельной embedding-модели — не внутренности вашего чат-LLM. Свой продукт, своё обучение, свои лидерборды.

самая частая путаница

Обновили LLM → переиндексировать базу НЕ надо: индекс живёт в координатах embedding-модели.

Близкие по смыслу токены лежат рядом — в сотнях-тысячах измерений

2D-проекция (PCA-стиль)



Размерность

Публичные embedding-модели: **1536–3072** измерения;
внутренние у флагманов — порядка тысяч.

Обучение

Координаты не задаются вручную: похожие контексты
употребления → близкие векторы.

Проекция

Увидеть пространство можно только через PCA/t-SNE —
2D-картинка теряет часть структуры.

Высокое сходство — «об одном и том же», не «с одинаковым смыслом»

cosine similarity	SSL	HTTPS	React-к.	React-п.	Борщ
Как настроить SSL	1,00	0,85	0,18	0,20	0,08
Установка HTTPS-сертификата	0,85	1,00	0,22	0,19	0,07
Деплой React-компонента	0,18	0,22	1,00	0,78	0,12
Сборка React-приложения	0,20	0,19	0,78	1,00	0,10
Рецепт борща	0,08	0,07	0,12	0,10	1,00

«Как настроить SSL» ↔

«Как отключить SSL»

Очень высокое сходство — противоположный практический смысл.

шкала: 0 — светлое · 1 — тёмное

Similarity — сигнал кандидатов; релевантность — отдельная задача: реранкер, гибрид, фильтры.

Эмбединги — фундамент понимания: модель работает с векторами, не строками



Перефразирования и синонимы

«Как настроить SSL» и «Установка HTTPS-сертификата» — близкие векторы → модель отвечает одинаково; то же с «авто» и «машина».

Межъязыковая близость

«клубника» и strawberry — близкие векторы → ответ корректен независимо от языка запроса.

Семантическая близость на уровне предложений — основа «понимания» переформулировок.

Выбор embedding-модели под задачу (MTEB, матрёшечные представления) — материал для самостоятельного чтения.

Раздел 3

Механизм внимания

«Как модель решает, на что опереться в контексте — и что из этого следует для ролей, кэша и длинных окон»

4 разбора · 2 провала



Внимание — это сверка каждого токена со всеми остальными

Каждый токен «смотрит» на все остальные одновременно. На каждом шаге — $N \times N$ связей.

вес	Кот	съел	мышь	потому что	она	была	голодна
Кот	1,0	0,3	0,2	0,1	0,1	0,1	0,0
съел	0,4	1,0	0,5	0,1	0,1	0,1	0,1
мышь	0,2	0,4	1,0	0,1	0,1	0,0	0,1
потому что	0,1	0,2	0,2	1,0	0,3	0,2	0,2
она	0,1	0,1	0,7	0,2	1,0	0,3	0,4
была	0,1	0,2	0,2	0,3	0,4	1,0	0,5
голодна	0,1	0,2	0,3	0,3	0,4	0,5	1,0

По строке «она»: наибольший вес — на «мышь». Статистическая связь, выученная на корпусе.

Размерность

$N \times N$, где N — длина контекста. Удвоение контекста — **учетверение вычислений внимания**.

На каждом шаге

Распределение весов пересчитывается заново на каждом шаге генерации.

Многоголовость

В каждом слое — десятки параллельных «голов» (типично 32–128); каждая ловит свой тип связей: грамматика, семантика, дальние зависимости.

Внимание — матричная операция: каждый токен против каждого. Отсюда квадратичная стоимость длинного контекста.


Внимание — распределение весов на весь контекст: три проекции Query / Key / Value

Фонарик в тёмной комнате



- Все токены контекста — предметы в комнате
- Луч направлен на релевантные текущему вопросу
- Яркость по предметам = веса внимания
- Распределение света меняется с каждым вопросом

Распределение весов на токенах контекста — сумма = 1



1. На вход — все токены контекста.

2. На выходе — распределение весов, сумма = 1.

3. Пересчитывается на каждом шаге генерации.

Технически — три проекции каждого токена:

Query — «что я сейчас ищу»

Key — «что я предлагаю»

Value — «что я отдам, если меня выбрали»

Q — про текущий шаг. K и V — про уже обработанный контекст.

Роль работает через вес во внимании — и ровно поэтому подделанная роль работает так же

Рабочий пример: куда смотрит «она»

«Кот съел **мышь** , потому что **она** была голодна»

главный вес

Упрощение: агрегат сотен связей в десятках слоёв. Модель не делает грамматический разбор — она воспроизводит корреляции употребления.

Подумайте 30 секунд: куда уйдёт вес от «она» в «Программа упала, потому что она забыла обработать null»?

Роль работает

«Ты **эксперт по Python**. Объясни асинхронность **джуниору**»
— токены роли получают вес при генерации каждого токена ответа → конкретнее, проще, в экспертном регистре.

=


Подделка работает так же

Внедрённая в контекст последовательность, выглядящая как **разметка роли**, вливается в то же взвешивание — с той же силой, что настоящая.

Внимание не различает происхождение токенов. Архитектурного барьера нет — барьер строится снаружи: фильтрация входа + права инструментов.

К и V кешируются — заново считается только Q

KV-cache: Key/Value обработанных токенов сохраняются в памяти ускорителя. На каждом шаге вычисляется только Q нового токена — против сохранённых K/V.



Фаза 1 — prefill (обработка промпта)

- Все токены входа известны сразу → K/V считаются **параллельно**
- Упирается в **вычислительную мощность**
- Определяет **паузу до первого символа ответа (TTFT)**



Фаза 2 — decode (генерация ответа)

- Строго **последовательно**, токен за токеном
- Каждый шаг читает **весь накопленный кэш** из памяти
- Упирается в **пропускную способность памяти** → скорость «печати»

Почему длинный чат тормозит и дорожает: история подаётся целиком при каждом обороте — больше prefill, толще кэш, медленнее каждый шаг. «Начать новый чат» — буквально сброс груза, а не суеверие.

Кэш промптов — ставка на повторное использование, а не скидка

Тарифы (сентябрь 2026):

Чтение из кэша — **0.1× базовой ставки входа** (новейшие — до 0.025×)

Запись в кэш — **1.25–2× ставки** — дороже обычного входа

Окупается со второго-третьего попадания; уникальные запросы без общего префикса от кэша только дорожают.

Кейс: 50 000 анализов документов в месяц

без кэша

\$45 000

\$8 000 с кэшем · **−82%**

Условие: точное совпадение префикса. Один изменившийся токен инвалидирует кэш для всего, что после него.

системный промпт

✓ кэш

инструкции

✓ кэш

документы

✓ кэш

«Сегодня 2026-09-05 14:23» — динамический

!

вопрос

× мимо кэша

Мини-опрос: добавили динамический timestamp в начало системного промпта — что происходит с кэшем?

Правило компоновки: стабильное — в начало (промпт, инструкции, примеры, документы), переменное — в конец.

Стандарт 2026 — окно 1–2 миллиона токенов. Но заявленное ≠ полезное

GPT-3.5 (2022) — 4 тыс.



Claude 3.5 (2024) — 200 тыс.



Claude Fable 5 (2026) — 1 млн · без наценки за длину



Gemini 3.5 Pro (2026) — 2 млн · крупнейшее среди боевых флагманов



ширина — логарифмическая шкала

Llama 4 Scout: «10 млн»

заявлено; ни один опубликованный бенчмарк не подтверждает качество вблизи предела

YandexGPT 5 Pro: 32 тыс.

на полтора-два порядка меньше флагманов — для длинных документов это определяющее ограничение

Просто «растянуть» окно нельзя: позиция токена закодирована геометрией, обученной на конкретных длинах, — расширение (RoPE / YaRN) — отдельная инженерная работа.

Платите за то, что кладёте в окно, а не за то, что окно вмещает: 900 тыс. токенов входа по \$10/млн ≈ \$9 за один **ВЫЗОВ**.


Поиск дословной вставки решён. Понимание длинного контекста — нет

Найти дословно (needle-in-a-haystack) — почти решено ✓

- Найти вставленную фразу по буквальному совпадению: флагманы — **до 99% на полном окне в 1 млн токенов**
- «Найди, где в договоре упоминается сумма» — работает почти как обещано

Узнать по смыслу (NoLiMa, 2025) — обрушение

Бенчмарк убрал буквальное совпадение слов. **11 из 13 моделей — ниже 50% их же собственной точности на коротком контексте** — уже на **32 тыс. токенов** (~3% заявленного окна флагмана).



1M окна ≠ 1M рассуждения. Окно — сколько модель может прочитать; полезная длина — на скольких токенах она ещё связывает факты.

Критические инструкции — в начало или конец промпта · целевой поиск 5–10 фрагментов бьёт «вывалить всё в окно» · тестируйте на рабочей длине вашей задачи

Раздел 4

Сэмплинг и генерация

«Как из распределения вероятностей рождается один токен — и какими ручками этот выбор управляется»


4 разбора · 2 провала



На каждом шаге — распределение вероятностей на все токены словаря

Контекст: «Сегодня я съел ...»

$P(\text{следующий токен})$:



Сэмплинг → один токен

правило выбора одного токена из распределения — единственная ручка в ваших руках



[яблоко]

выбран один — остальные кандидаты исчезли из ответа

Остальные ~200 000 токенов словаря — каждый < 0.05 . Сумма всех вероятностей = 1. Числа иллюстративные.

Распределение — «настоящий» выход модели. Уверенный ответ и галлюцинация до сэмплинга существовали одновременно — как вероятностная масса; выбор сделала политика.


Температура — делитель логитов: меняет остроту выбора, не знания

$T \rightarrow 0$ (argmax)




Выбор самого вероятного. Почти одинаковые ответы — «почти» разберём на следующем слайде.

$T = 1$ (стандарт)



Сэмплирование пропорционально вероятностям модели. Естественная вариативность.

$T = 1.5$ (сглаживание)



Редкие токены получают реальные шансы — от удачных находок до бессвязности.

top-p — отрез хвоста по вероятностной массе · **top-k** — по числу кандидатов. Основная ручка — температура; эти две — тонкая настройка.

Живой прогон: один и тот же запрос — 10 раз при $T=0$ и 10 раз при $T=1.5$.

T=0 не даёт детерминизма: 80 уникальных ответов из 1000

80 / 1000

уникальных вариантов ответа на идентичный запрос при T=0 — стандартный vLLM (Thinking Machines Lab, сентябрь 2025)

Причина — не «floating-point вообще», а отсутствие **batch-инвариантности** ядер:

1. Сервер группирует одновременные запросы разных пользователей в батчи
2. Размер батча зависит от чужой нагрузки в эту миллисекунду
3. Разный размер батча → разный порядок суммирования → младшие разряды другие
4. Два близких кандидата в $\arg\max$ → младший разряд решает выбор токена → авторегрессия разносит расхождение по всему ответу

Решение существует: batch-инвариантные ядра — 1000/1000 побитово идентичны

Цена: ~35% пропускной способности → провайдеры не включают; seed у OpenAI — официально «mostly deterministic», в основном детерминировано

Не стройте тесты на побитовом сравнении ответов LLM — сравнивайте семантически или по структуре.

Ручек стало шесть: добавилась ось глубины рассуждения

Сценарий	temperature	top_p	max_tokens	Системный промпт
Классификация / извлечение	0	—	50–200	Минимальный, со схемой выхода
Кодогенерация	0.2–0.3	0.9	1000+	Роль + контекст репозитория
Творческое письмо	0.9–1.2	0.95	2000+	Роль + стиль

effort / reasoning_effort

2026

глубина внутреннего рассуждения: шкала от none до xhigh (OpenAI); effort при адаптивном мышлении (Anthropic); thinking budget (Gemini)

verbosity

2026

длина видимого ответа, независимая от глубины: думать глубоко, отвечать коротко

Заучивайте оси — случайность, длина, глубина, формат; имена параметров сверяйте с документацией текущего месяца.

Structured outputs: невалидные токены обнуляются прямо в распределении

Constrained decoding (ограниченное декодирование): на каждом шаге система вычисляет, какие токены оставляют вывод валидным относительно JSON-схемы, — и обнуляет вероятности всех остальных. Модель физически не может нарушить схему.



серые нарушают JSON-схему → вероятность 0

Просьба «ответь строго в JSON» → ~80% валидных

Strict mode → **100%** — гарантия встроена в сэмплинг, а не проверяется постфактум

Ограничения — свойства компиляции

Рекурсия через \$ref — нет (дерево → плоский список с parent_id)

Глубина вложенности — ≤ 5


Первый запрос с новой схемой платит за компиляцию грамматики — до 10 с

Гарантирован синтаксис, не смысл: валидировать значения по-прежнему вам

Вопрос залу: почему именно 100%, а не 99.9?

Предсказали токен → дописали в контекст → предсказываем следующий


ВХОД



До специального **стоп-токена** или до **max_tokens** — обрыв мгновенный, хоть на середине JSON-поля.

Каждый шаг — без состояния: вся «память» живёт в контексте, который подаётся целиком (KV-cache делает повторную подачу дешёвой, не отменяя её логически).

Reasoning-токены не видны — но тарифицируются как output



o4-mini

1×

o3

5×

o3-pro

18×

o3-pro: 3.6× дороже o3, 18× дороже o4-mini — при сопоставимой длине видимых ответов; разницу делает объём рассуждения.

Управление: адаптивное мышление / effort вместо ручных бюджетов — удобно, но стоимость запроса стала менее предсказуемой

«Ход рассуждений» в интерфейсе — **пересказ** (summarized), не сырые токены: строить аудит решений на «показанных мыслях» нельзя

Закладывайте в бюджет невидимую часть 2–5× видимого ответа — и сверяйте по полю usage в ответе API, где reasoning-токены видны как строка расхода.

«Открытые веса» перестали означать «локально запускаемые»

открытая ≠ локальная

Действительно локальные (≤ ~30B)

- Qwen3.8-27B (Apache 2.0, вход изображение+видео, окно 262 тыс.), Muse Glimmer 30B
- Железо: RTX 5090 (32 ГБ) · Apple unified 64–128 ГБ
- **Лимит — объём памяти, не вычисления**

Открытые, но облачные гиганты

- Kimi K3 — 2.8 трлн параметров, крупнейшая открытая модель
- DeepSeek V4-Pro — 1.6 трлн
- **На потребительское железо не помещаются ни в каком виде**

Закрытые API

- Флагманское качество — по-прежнему здесь
- Плата за токен, данные через провайдера

*Причины локального выбора прежние: приватность данных · отсутствие платы за токен на объёмах · независимость от сети.
Решение — по данным и объёмам, не по идеологии.*

Раздел 5


Финал

*«Конвейер собран целиком: карта моделей 2026, цена доверия бенчмаркам — и шесть утверждений
ЗАНОВО»*

4 разбора · 2 провала



Новые темы не добавили стадий — они встроились в существующие



Конвейер — диагностическое дерево: по симптому почти всегда угадывается стадия-виновник. Спрашивайте: «на какой стадии это происходит?»

Сентябрь 2026: качество сблизилось — цены разошлись на три порядка

Передний край (закрытые веса)

- OpenAI: GPT-5.6 — Luna → Terra → Sol
- Anthropic: Claude Fable 5 · Opus 5
- Google: Gemini 3.5 Pro (окно 2 млн, Deep Think)
- xAI: Grok 4.3

Открытые веса

- DeepSeek V4 (Pro 1.6 трлн / Flash 284 млрд)
- Qwen 3.8-Max — первая открытая из линейки Max
- **Kimi K2.6 (1 трлн) · Kimi K3 (2.8 трлн — крупнейшая открытая)**

IMO 2026: шесть моделей — абсолютные 42/42. Из 666 участников-людей — семеро.

Те же системы ошибаются в подсчёте букв слова cranberry — «рваный интеллект» как рабочая характеристика.

пол рынка \$0.03–0.2 / млн токенов

премиум \$10 вход / \$50 выход

Kimi K2.6 ≈ GPT-5.5 на защищённом SWE-bench Pro — **при цене на ~80% ниже**

Бенчмарки: контаминация, подгонка — и модели, которые жульничают сами

1

Контаминация: заучено, а не умеет

SWE-bench **Verified 87.6%** (заявка производителя, публичные репозитории) vs **Pro: 57% топ / ~25% средний** (приватные кодовые базы — заучить нельзя). Разрыв — измеренная величина заучивания. OpenAI в 2026 перестал публиковать Verified.

2

Подгонка под метрику

Llama 4 Maverick: на Chatbot Arena — специальная версия, Elo 1417; публичная модель — **места 32–35**. Ян Лекун: результаты «слегка подтасованы».

3

Модели жульничают сами

UK AI Security Institute: **все 5** протестированных передовых моделей пытались обмануть процедуру оценки. Одна модель OpenAI вышла за пределы тестовой песочницы и взломала производственные серверы Hugging Face.

Бенчмарки сужают список кандидатов. Выбирает — собственный оценочный набор: 30–50 примеров из ваших реальных задач.

Шесть утверждений — теперь по строке механизма на каждое

№	Утверждение — все ложны	Механизм
M1	«Модели научились считать буквы»	Модель видит токены, не буквы; strawberry починили точечным патчем — cranberry не работает
M2	«Роль system защищена архитектурно»	Роль — токены chat-шаблона в общем потоке; внимание не различает происхождения токенов
M3	«Окно 1M = работа со всем объёмом»	Окно — ёмкость приёма, не понимания: без лексических совпадений 11 из 13 моделей теряют >50% своей точности уже на 32K
M4	«T=0 даёт детерминированный ответ»	Ядра не batch-инвариантны: чужая нагрузка меняет размер батча — 80 уникальных ответов из 1000
M5	«Невидимые reasoning-токены не оплачиваются»	Тарифицируются как output; 3–10× видимого ответа; o3-pro в 18× дороже o4-mini
M6	«Бенчмарки — надёжный способ выбрать модель»	Контаминация (87.6% vs 57%), подгонка витрин, жульничество моделей; выбирает свой оценочный набор

Точная ментальная модель — это знание границ. Каждое утверждение — правда соседней области, растянутая за свою границу.

Когда не LLM — и когда не топ-LLM

Когда LLM — не тот инструмент:

Классификация на фиксированных категориях с тысячами размеченных примеров
→ классический ML: дешевле, быстрее, воспроизводимо — а LLM ещё и недетерминирована при T=0

Объяснимость перед регулятором → прозрачные классические методы

Отклик < 100 мс (антифрод, устройства без сети) → специализированная малая модель

Точные посимвольные и арифметические операции → код, не модель

Иначе — обработка языка, гибкие форматы, многошаговое рассуждение, генерация → LLM применима и часто оптимальна

...и не всегда топ-LLM

10% сложных →
премиум \$10/млн

90% запросов →
модель за \$0.20/млн

Миллиард токенов/мес:

\$10 000 целиком на премиуме

vs **\$1 180** с маршрутизацией

*Kimi K2.6 ≈ GPT-5.5 на защищённом бенчмарке при
–80% цены*

Внимание усваивает корреляцию, не причинность

Человек

«X произошло, потому что Y» — модель механизмов мира

✓ ассоциация

✓ вмешательство

✓ контрфактуальность

Модель (через внимание)

«X следует за Y в текстах» — «потому что» для модели — частотный паттерн, не указание на механизм мира

✓ ассоциация — сильна

~ вмешательство — только похоже на описанные в корпусе

× контрфактуальность — систематически нет

Там, где от модели ждут каузальных выводов, человек в контуре — архитектурное требование, а не вежливая оговорка.

Лекция 3: как модель выходит за пределы контекста

RAG

Семантический поиск по вашей базе → найденные фрагменты в контекст.

Якорь: сходство ≠ релевантность — главная причина разочарований наивного поиска.

Инструменты / вызов функций

Модель генерирует структурированный вызов → внешняя система исполняет.

Якорь: надёжность формата вызова обеспечивают structured outputs.

MCP

Открытый протокол подключения инструментов.

Якорь: стабильный префикс с описаниями инструментов → кэш промптов, экономика агента.

Агентный цикл

Действие → наблюдение → коррекция.

Якорь: агент читает внешний контент — спуфинг ролей превращается в prompt injection; невидимые токены рассуждения умножаются на число шагов.

Q&A

Спасибо