



Чат-бот выдумал политику — платит компания.

Moffatt v. Air Canada · трибунал ВС · 14.02.2024

- 1** Пассажир спросил чат-бота про тариф по случаю утраты близкого
- 2** Бот: «купи по полной цене, верни разницу в течение 90 дней»
- 3** Реальная политика этого не допускала — и была на той же странице, на которую бот ссылался
- 4** Трибунал: «бот — не отдельное юр. лицо» → компания компенсирует разницу

Это не сбой модели — это неправильный выбор архитектуры под задачу. Об этом классе ошибок вся лекция.

ЛЕКЦИЯ 3

Архитектуры AI-систем: агенты, RAG, API

| Какую архитектуру выбрать под задачу —
и когда правильный ответ «не ИИ»



Маршрут лекции — шесть разделов.

Одна несущая линия: выбор архитектуры под задачу — и когда правильный ответ «не ИИ».

0



Открытие

Air Canada: неправильная архитектура стоит денег

1



Промпт и его границы

что умеет один вызов и где его потолок

2



RAG

внешнее знание в контекст — и где оно тихо ломается

3



Fine-tune

менять веса под поведение, не под знание

4



Агенты

цикл, экипировка, память, безопасность — и провалы

5



Фреймворк

лестница + чек-лист: как выбрать быстро и обоснованно

Что мы переносим из Лекции 2 — и что надстроим.

Вокруг одного вызова модели надстраиваются 4 обвязки. Два готовых блока из Лекции 2 не переобъясняем.



RAG

внешнее знание в контекст перед ответом



Function calling

модель дотягивается до внешних систем

Один вызов LLM

single-shot инференс из Лекции 2: один проход, без памяти между вызовами



MCP

стандарт подключения инструментов



Цикл агента

много шагов вокруг одного прохода

Из Лекции 2 берём готовыми: *single-shot* инференс и семантический поиск на эмбедингах (основа RAG). Детали каждой обвязки — дальше по разделам.

ЦЕНТРАЛЬНЫЙ ВОПРОС ЛЕКЦИИ

У меня есть задача и доступ к LLM. Какую архитектуру выбрать — и когда правильный ответ «не ИИ»?

6

Multi-agent

несколько координируемых агентов

сложнее ↑

5

Агент

цикл $plan \rightarrow act \rightarrow check \rightarrow iterate$

4

Workflow

предопределённые пути

3

RAG / контекст-инжиниринг

поиск-дополненная генерация

2

Один вызов LLM

промт; + CoT (по шагам), + few-shot (примеры)

1

Обычный код (без ИИ)

точка отсчёта

проще ↓



Подниматься на следующую ступень — только при требовании задачи, которого текущая не закрывает.

Лестница — карта лекции, не требование понять всё сейчас. Каждую ступень разберём отдельно.

РАЗДЕЛ 1

Промпт и его границы

Лестницу мы увидели целиком — теперь снизу: что умеет один вызов и где его потолок, прежде чем что-либо усложнять.



Раздел 0
Открытие

Раздел 1
Промпт

Раздел 2
RAG

Раздел 3
Fine-tune

Раздел 4
Агенты

Раздел 5
Фреймворк

Дефолт — один вызов с хорошим промптом.

Модель знает только то, что в промпте (плюс то, что было в весах на обучении). Больше ей взять неоткуда.



Один вызов LLM с хорошим промптом

- минимальная стоимость (один проход)
- минимальная латентность (нет лишних обращений)
- максимальная предсказуемость (нет петель, нет retrieval, который тихо деградирует)

Добавляешь RAG →

конвейер индексации + векторное хранилище + компонент retrieval (может молча деградировать) + метрики его качества

Добавляешь инструменты / цикл →

внешние вызовы (падают, тормозят) + петли (расходятся) + недетерминизм траектории + новая поверхность атаки

Не усложняй архитектуру без причины, выраженной в требованиях задачи. Это распределение бремени доказательства, а не примитивизм.

Роль в промпте настраивает тон — не точность.

«Ты — опытный юрист» сдвигает внимание модели (механизм — Лекция 2) в сторону текста, похожего на ответ такой роли, — но это про стиль, не про факты.

Расхожий миф

«Напишу роль эксперта — и модель будет точнее отвечать по фактам»

Что показал эксперимент

162 персоны · 6 типов отношений · 8 доменов · 2410 вопросов фактического QA · 4 семейства LLM. Персоны НЕ улучшили точность ответа по сравнению с ответом без персоны вообще.



На что роль влияет реально

на тон и глубину изложения — насколько формально и подробно, а не верен ли факт (эффект модель-специфичен).

Нужна фактическая точность? Инструмент — не формулировка роли, а грамотный контекст и, при необходимости, RAG (опора на проверяемый источник). Это ещё один пункт «магической пилюли», опровергнутый измерением.

Структура промпта: разделяй инструкцию, контекст, данные.

Плоский промпт заставляет модель угадывать, где кончается инструкция и начинаются данные. Явная граница снимает эту неоднозначность.



Инструкция

что сделать



Контекст

на основе чего



Данные

с чем именно работать

Разделители (delimiters)

- XML-теги: `<инструкция>...</инструкция>`
- Markdown-заголовки: `## Задача · ## Данные`
- Тройные кавычки / бэктики вокруг данных

Тот же принцип, что structured output (Раздел 4): там схема задаёт структуру ВЫХОДА, здесь разделители — структуру ВХОДА. Ясная структура вместо «выведи форму по смыслу».

Модель, которой показали, где кончается инструкция и начинаются данные, реже принимает фрагмент данных за новую команду — та же путаница лежит в основе prompt injection (Раздел 4).

Chain-of-thought помогает — но его нельзя аудировать.

Без CoT

«Было 23 яблока, 7 испортились, докупили 2 ящика по 6. Сколько хороших?»

→ правдоподобное, но неверное число

С CoT («решай по шагам»)

$23 - 7 = 16$ · $2 \times 6 = 12$

$16 + 12 = 28$

→ верно

Технически это всё ещё один вызов — CoT инструмент под класс задач (цепочка шагов), не глобальный тумблер.

Но проговорённое рассуждение не обязано отражать реальную причину ответа (низкая faithfulness):

~25%

Claude 3.7 Sonnet

~39%

DeepSeek R1


— доля случаев, где модель упомянула реально использованную подсказку.

Контроль на самообъяснении модели — не контроль. Человек-валидатор проверяет РЕЗУЛЬТАТ и факты против внешнего источника, а не правдоподобность текста. И это же — почему шаг check в цикле агента (Раздел 4) не должен быть самооценкой модели.

Anthropic, апрель 2025 · верность падает на трудных задачах · перепроверить ко дню лекции.

Контекст-инжиниринг: минимум высокосигнального.

Промпт-инжиниринг — одна инструкция. Контекст-инжиниринг — курирование всего набора токенов, видимых модели на инференсе.



context rot = тот же «lost in the middle» из L2 — новый термин, не новая сущность

Когда НЕ RAG (точка 1)

малый стабильный корпус, влезает в окно → full-context + кэширование префикса, а не RAG-инфраструктура



RAG здесь добавил бы хрупкость без выигрыша

«Найти наименьший набор высокосигнальных токенов, максимизирующий вероятность желаемого исхода» — это инженерное требование, не эстетика.

Чит-шит: как строить промпт.

Минимум, ниже которого промпт систематически недорабатывает. Приложите к любому промпту перед первым запуском.

1 Роль

если нужен тон/регистр — и НЕ как обещание точности

2 Задача

конкретное проверяемое действие, не расплывчатое пожелание

3 Контекст

минимально необходимое, не «всё, что могло бы пригодиться»

4 Формат вывода

указан явно, если ответ машинно-обрабатываем

5 Разделители

если содержимого больше одного вида (инструкция/данные)

6 Примеры (few-shot)

только если формат неочевиден из одной инструкции

7 CoT

только если задача требует многошагового рассуждения

8 Длина

не длиннее необходимого — лишние токены «тонут» в контексте

Компактная форма всего раздела: роль ≠ точность, структура помогает разделить входы, CoT — точечный инструмент, контекст — минимальный. Для крупных архитектурных решений (RAG / FT / агент) — восьмишаговый чек-лист Раздела 5.

РАЗДЕЛ 2

RAG: поиск- дополненная генерация

*Извлечь релевантное → положить в контекст →
ответить с опорой на источник*



Раздел 0
Открытие

Раздел 1
Промпт

Раздел 2
RAG


Раздел 3
Fine-tune

Раздел 4
Агенты

Раздел 5
Фреймворк

Принцип RAG — три шага.

RAG = индексация → retrieval (semantic search Л2) → генерация с опорой; «не знаю» — корректный ответ.



«Не знаю» / «см. источник X» — корректный ответ RAG-системы. Правдоподобный ответ при нерелевантном retrieval — это дефект, а не «лучше, чем ничего».

Когда RAG — правильный выбор.

RAG оправдан при сильном сигнале по признакам ниже — и отсутствии blockers со следующего слайда «когда НЕ RAG».

Большое / растущее

не влезает в окно целиком,
или дорого класть весь
корпус в каждый запрос

Меняется

документы, цены,
регламенты обновляются
чаще, чем выходят версии
модели

Свежесть + провенанс

ответ опирается на
проверяемый источник;
можно показать, откуда
факт

Приватная база

знания компании не входят
в веса публичной модели

Признаки усиливают друг друга → RAG

Корп. база из тысяч регламентов, обновляется еженедельно, ответ с обязательной ссылкой на пункт: все признаки сошлись, ни один более простой механизм их совместно не закрывает → образцовый профиль RAG.



**Один признак — повод присмотреться,
но не строить автоматически:
сверьтесь с блокерами на следующем
слайде.**

Когда RAG — НЕ правильный выбор.

Знать, когда RAG не нужен, ценнее: это модная архитектура, её ставят туда, где она вредит.



1. Корпус влезает в окно

ориентир — менее ~200k токенов, меняется редко

→ **full-context + кэширование префикса, не RAG-инфраструктура**



2. Отдать фиксированную политику / значение

тариф, цена, пункт регламента, правило

→ **детерминированный lookup / статическая страница**



3. Данные доступны live через API / MCP

во внутреннем сервисе, базе, поиске другой системы

→ **вызвать инструмент напрямую; RAG-индекс поверх — лишний, более хрупкий и более устаревающий слой**

RAG избыточен, если выполнен ЛЮБОЙ из трёх: (а) корпус влезает в окно и стабилен, (б) задача сводится к фиксированному значению, (в) знание уже доступно напрямую и живьём через инструмент. «Прямой вызов вернёт данные на момент запроса; RAG-индекс — на момент последней индексации.»

Провал RAG на масштабе.

«Вернул что-то» ≠ «вернул правильное». У RAG нет сигнала «не нашёл» — он всегда отдаёт к ближайших, даже нерелевантных.



Legal-AI

«ближайшие» дела из другой юрисдикции / отменённый прецедент — модель опирается на них как на факт



Medical-RAG

смешал фрагменты разных пациентов — близки по симптомам, клинически объединять нельзя



Support-бот

работал на сотнях статей; после роста до тысяч качество тихо просело — никто не заметил

Air Canada — разбор архитектуры

Диагноз

сгенерированный правдоподобный текст поставлен в роль, требовавшую извлечённого проверенного факта — отказ grounding

Правильная альтернатива

фиксированная политика → lookup / страница;
нужен диалог → RAG со strict grounding,
обязательная цитата, явное «не знаю», проверка человеком

РАЗДЕЛ 3

Fine-tune vs промпт vs RAG

Проблему знания мы решили через RAG. А если проблема не в знании, а в поведении модели — её тоном, форматом, политикой?



Раздел 0
Открытие

Раздел 1
Промпт

Раздел 2
RAG


Раздел 3
Fine-tune

Раздел 4
Агенты

Раздел 5
Фреймворк

Что такое fine-tuning.

Fine-tuning (дообучение) — продолжение обучения уже готовой модели на ваших данных. В Л1 — тип использования; здесь — архитектурный выбор, одна из ступеней лестницы.



Промпт / RAG → КОНТЕКСТ

Меняют только вход — веса не трогаются; эффект живёт лишь в рамках запроса.

Fine-tuning → САМИ BECA

Изменение встроено в модель — действует всегда и стоит дороже того, что меняет контекст.

Промпт/RAG = «что показать модели». Fine-tuning = «изменить саму модель». На практике «дообучить» почти всегда означает LoRA/PEFT, а не переобучение всех весов (следующий слайд).

PEFT вместо full fine-tuning.

PEFT — базовые веса замораживаются, обучается лишь небольшой набор адаптеров. LoRA — низкоранговые матрицы-адаптеры; QLoRA — то же поверх квантованной модели.

**Базовые веса
(frozen)**

LoRA

LoRA

LoRA

адаптеры — мегабайты vs гигабайты

98,4% моделей с тегом PEFT — это LoRA

из 20 834 карточек на Hugging Face Hub · оговорка: доля среди моделей с тегом PEFT, не среди всего fine-tuning

1. Дешевле и быстрее

обучаются миллионы параметров вместо миллиардов; QLoRA — на одном GPU

2. Модульность

адаптеры мегабайты vs гигабайты; одна база — много специализаций

3. ↓ Риск catastrophic forgetting

база заморожена, физически не переписывается под новый сигнал — архитектурный аргумент

PEFT (LoRA/QLoRA) почти всегда лучше full fine-tuning: дешевле, модульнее, ↓ риск forgetting. Full FT в 2026 — почти никогда.

Fine-tuning не умер — он сузился до поведения.



Ушло из fine-tuning (2026)

знание, факты, то, что меняется → RAG / длинный контекст. Зашить факты в веса: нельзя процитировать, обновить точно, удалить один.



Осталось за fine-tuning


поведение · стиль · формат вывода · следование политике. Дистилляция — отдельная техника, часто применяемая в связке с дообучением.

Если задача требует...	→ правильный инструмент	...и НЕ этот, потому что
знание меняется / нужны свежесть, провенанс	RAG (или длинный контекст для малого корпуса)	не fine-tuning: устареет, дорого переобучать, риск forgetting
стабильное поведение / тон / формат / политика	fine-tuning (PEFT)	не RAG: подаёт знание, но не меняет манеру модели
снизить стоимость / латентность на узкой задаче	fine-tune teacher + дистилляция student	две отдельные техники в связке, НЕ «дистилляция = вид fine-tuning»
детерминированный, верифицируемый ответ	обычный код, без ИИ	ни RAG, ни FT: ИИ добавит недетерминизм без выигрыша

Реальный вопрос 2026 — не «RAG или fine-tuning», а «что здесь знание (→ RAG), что поведение (→ PEFT), что детерминировано (→ код)». Гибрид — норма там, где есть И проблема знания, И проблема поведения.

Провал: catastrophic forgetting.

Catastrophic forgetting (катастрофическое забывание) — деградация общих способностей модели в результате узкого агрессивного дообучения.



тяжелее с ростом масштаба модели — у крупной выше исходный уровень, ей «больше падать»

Нет eval-петли на общих задачах + нет версий датасета/весов → не увидишь поломку до прода + не сможешь откатиться → это не «риск», это критерий «НЕ делай fine-tuning»

Правильно: PEFT (замороженные веса — ниже риск); для меняющегося знания — RAG, не FT вообще.

Эмпирически наблюдается при continual fine-tuning (Luo et al. 2023). Механизмы — «исследования показывают» (preprint).

РАЗДЕЛ 4

Агенты

От собеседника в окне чата — к компоненту продакшен-системы: цикл, экипировка, память, доступ к инструментам — и где всё это ломается.



Раздел 0
Открытие

Раздел 1
Промпт

Раздел 2
RAG

Раздел 3
Fine-tune

Раздел 4
Агенты

Раздел 5
Фреймворк

Модель становится компонентом системы: API + MCP.



Structured output

выход строго по схеме (JSON), не текст для парсинга

встраиваемая



Function calling

модель формулирует «вызовы X»; исполняет ваш код, не модель

активная



Prompt caching

не пересчитывать неизменный префикс при каждом запросе

экономичная



MCP — «USB-C для инструментов LLM»

N×M несовместимых интеграций → **N+M**

инструмент один раз = MCP-сервер; модель один раз = MCP-клиент

AI Anthropic
11/2024



 OpenAI
03/2025



 Google
04/2025

Стандартизация подключения ≠ безопасность подключаемого — и усугубляет проблему доверия.

- код в вашем окружении / доступ к данным
- описание попадает в контекст — носитель prompt injection
- ещё одна граница доверия и retention-политика

Ни один механизм не делает модель надёжнее — правило лестницы не отменяется. Удобство подключения — не аргумент за подключение.

Числа экономии prompt caching и масштаб экосистемы MCP — в главе; перепроверить ко дню лекции.

Цикл агента: plan → act → check → iterate.

Агент — архитектура, где модель не делает один проход, а работает в цикле, сама определяя последовательность шагов.



Паттерны цикла (ReAct, Reflexion, Plan-and-Execute) — в главе. Проектировать агента = проектировать защиту на каждом из 4 шагов.

Workflow vs Agent.

Предсказуемая задача → workflow; непредсказуемая И ценность оправдывает кратный рост → агент.



Workflow (рабочий поток)

LLM и инструменты по предопределённым в коде путям

- последовательность шагов известна заранее
- предсказуемо, аудируемо
- большинство надёжных продакшн-систем — это workflow



Агент

LLM динамически определяет собственный процесс

- последовательность заранее не зафиксирована
- кратно больше токенов, чем чат
- ниже аудируемость, выше риск петель

Могу ли я заранее, до запуска, выписать последовательность шагов? да (даже с ветвлениями) → workflow · принципиально нет И ценность оправдывает кратные стоимость/риск → агент

Вложенность — норма: агент code review вызывает workflow «линтер→тесты→формат» как один шаг; workflow обработки заявок делегирует мини-агенту разбор свободной жалобы. Динамика — только там, где нужна.

Найди простейшее. «Лень формализовать» не делает задачу непредсказуемой.

Каждый слот экипировки агента — компромисс, не апгрейд.

Реальный агент-помощник (Claude Code, Cursor, Aider) — это цикл *plan→act→check→iterate* ПЛЮС оснастка. Пять типовых слотов:



Как не поднимаешься по лестнице архитектур без требования задачи — не добавляй агенту память, subagents или MCP «на всякий случай». Каждый слот несёт свою цену: операционную сложность, новую поверхность отказа, новую границу доверия — и должен отвечать на конкретный триггер (Раздел 5).

Память агента — тот же вопрос масштаба, что RAG.

Память — что агент помнит МЕЖДУ сессиями (в отличие от контекста одного разговора). Спектр — от плоского файла до graph-баз.



Плоский файл

агент дописывает факты в текстовый лог, при запуске читает целиком. Работает, пока лог мал и стабилен — прямая параллель критерию RAG «корпус помещается в окно».



Векторная / graph-база

- mem0 — cross-session память пользователя
- Cognee — memory на графе знаний
- Graphiti / Zep — temporal graph: когда факт верен, когда устарел

Тот же вопрос масштаба знания, что решает RAG для корпуса документов, здесь встаёт для памяти самого агента. Не ставьте graph-базу агенту с короткими несвязанными сессиями — это тот же технический долг без требования, что RAG для десяти статей.

«Агент, который помнит» — не всегда лучше.

Наличие памяти интуитивно кажется чистым улучшением. Независимый *live-eval* показывает: иногда — драматически нет.



Letta — Tier D

проигрывает И голым модели, И плоскому файлу на всех задачах. *persistbench_v1*:

Голая модель	1.000	94 с
Плоский файл	0.833	159 с
Letta	0.750	496 с

Механизмы: капитуляция под давлением · многословие топик факт · факт замечен, но не закоммичен.

Оговорка: тест на Letta v0.6.7 — отстаёт от текущей v0.16.8 (~18 мес).

Anthropic Memory Tool — Tier B

В целом сильный результат — но даже он теряет данные в

17% задач

- явный отказ записать «эфемерный» факт
- немотивированный отказ «вне рамок»
- тихая *lossy*-суммаризация — деталь не восстановить
- невоспроизводимость: та же беседа дважды → разный результат

agent-harness-registry (workain lab, live-eval 2026-07-05). «Работает хорошо» ≠ «работает всегда» — тот же урок, что RAG на масштабе и forgetting.

Файл-инструкция агенту — не «магическая прививка».

Операционный слой — файлы-конвенции (класс `CLAUDE.md` / `AGENTS.md`) + журнал задач. Интуиция «написал инструкцию → лучше» расходится с измерением.



presence paradox

RCT (Gloaguen et al. 2026): само наличие файла-инструкции НЕ даёт значимого прироста успешности — при этом стоимость и число шагов растут.

Помогает только там, где реально заполняет пробел документации.



Honest Lying

Dixit, Kamal, Oates 2026: self-authored память может ЗАКРЕПЛЯТЬ неверное убеждение — журнал бетонирует раннюю ошибку вместо пересмотра.

Рефлексия ошибочна → повторные попытки опираются на неё.



claude-code#51735

Реальный кейс: письменно признанная прошлая ошибка НЕ предотвратила её повторение спустя 25 дней.

Запись о провале ≠ гарантия, что поведение изменится.

Полезен, когда заполняет реальный пробел; бесполезен, когда дублирует доступное модели; может навредить, когда самоавторская память закрепляет ошибку. Тот же паттерн, что роль в промпте: «добавить X → лучше» не подтверждается измерением.

Skills, subagents, доступ — и граница доверия.



Skill

переиспользуемая процедура «как делать» под повторяющуюся задачу



Subagent

отдельное контекстное окно: не засорять главный + изолировать недоверенное



MCP-доступ

каждое подключение — новая граница доверия и retention-политика



Безопасность: как только агент делегирует и подключается — появляется поверхность, которой не было у одного вызова

GitHub MCP heist (май 2025)

issue с встроенной инструкцией + переизбыточный токен (PAT на все репо) → ассистент выгрузил приватные репозитории в публичный PR.

Катастрофа = инъекция × широкие права. Убери любое — атака не проходит.

«У нас ZDR» ≠ «нигде не хранится»: судебный приказ (NYT v. OpenAI) + third-party/MCP вне ZDR. Регулируемое — не слать без ZDR/BAA.

4 правила проектирования

- 1 Least-privilege**
минимум токенов/прав
- 2 Изоляция недоверенного**
отдельно от привилегий (subagent)
- 3 Human-in-the-loop на write**
необратимое — только через человека
- 4 Allowlist / pin**
аудированные версии; deny-by-default

Реальные coding-агенты — через рамку экипировки.

Разница между инструментами — не в «качестве модели», а в том, какие слоты экипировки заполнены и где агент физически живёт.

<> Claude Code

CLI + IDE · проприетарный

широкая экипировка: память, файлы-инструкции, skills, полноценные subagents, MCP — почти все 5 слотов

цена — большая операционная сложность

<> Aider

CLI-first · open source

минимальная простота: без развитой памяти, без subagents, без skills. ~47k★ на GitHub

«тонкая» оснастка — самостоятельный выбор, не недоразвитость

<> Cursor

desktop IDE (форк VS Code) · проприетарный

агент внутри редактора — не терминал. Форма интеграции — отдельная ось от оснастки

где живёт агент — тоже архитектурное решение

<> OpenHands

self-hosted платформа · MIT · ~80k★

широкая автономность, локальное/Docker/облако развёртывание

*[требуется подтверждения]
вероятный кандидат на «OpenClaw» из issue #157 — рабочая гипотеза по совпадению профиля, не установленный факт*

Выбор инструмента подчиняется тому же правилу: не бери самый оснащённый по умолчанию — смотри, какая оснастка нужна именно твоей задаче.

Провалы агентов.

Каждый провал — режим отказа цикла агента в датированном кейсе: урок + альтернатива.



1. Петля без лимитов

Агент на «синхронизировать заказы»
получил HTTP 429 →
план→вызов→429→...


\$4 200 за 63 часа

База сравнения: `retry`-скрипт с `backoff`
решил бы ту же задачу за секунды-
минуты, практически бесплатно

\$4 200 — цена не автоматизации, а
неправильного выбора архитектуры под
предсказуемую задачу

Более подходящая архитектура: `retry-with-backoff` скрипт, не агент; лимиты
бюджета и итераций ВНЕ агента

2. Накопление ошибок (compounding)



Вывод: «улучшить шаг» — слабый
рычаг; «меньше хопов + валидация
между шагами» — сильный



3. Мульти-агентная хрупкость

зависимые подзадачи →
параллельные субагенты
принимают конфликтующие
неявные решения

**Более подходящая: single-
threaded линейный агент;
мульти-агент — только широко-
параллельное независимое**

РАЗДЕЛ 5

Как выбрать: фреймворк решения

Мы разобрали все архитектуры по отдельности — и где каждая проваливается. Теперь соберём это в один инструмент выбора.



Раздел 0
Открытие

Раздел 1
Промпт

Раздел 2
RAG


Раздел 3
Fine-tune

Раздел 4
Агенты

Раздел 5
Фреймворк

Лестница архитектурной сложности.


Оставайся на нижней ступени; поднимайся только под требование задачи.



Нижняя ступень — «обычный код без ИИ»: лестница начинается с вопроса «а нужен ли ИИ вообще».

План решения: маршрут вопросов, а не сумма баллов.

Пройдите задачу сверху вниз; останавливайтесь на первом сработавшем вопросе.



Пример (задача А)

«2000 регламентов, меняются еженедельно, ответ со ссылкой на пункт» → вопрос 4 (меняется+провенанс) решающий → RAG со strict grounding. Не FT (устареет), не код (нужен NL).

Разминка (задача В)

«бот на ~150 FAQ, меняются раз в квартал» — пройдите маршрут сами; разбор на семинаре.

Приоритет маршрута: если задача детерминированная и верифицируемая — обычный код, СТОП здесь. ИИ добавил бы лишь недетерминизм, стоимость, латентность и поверхность для prompt injection.

Стартовый комплект агента — и когда его усложнять.

Та же лестница «не усложняй без требования», применённая на уровень ниже — к оснастке одного агента, а не системы целиком.



Дефолт — тонкий агент

- один файл-инструкция
- плоская память
- БЕЗ subagents
- минимальный набор skills
- минимальный MCP-доступ
Время доказательства — на усложнении, а не на простоте.



Память-бэкенд — когда:

история переросла контекст ИЛИ нужен structured retrieval по фактам (не «последние N сообщений»). Тот же критерий, что переход промпт→RAG.



Subagents — когда:

подзадача требует отдельного окна (не засорять контекст) ИЛИ изоляции недоверенной работы (least-privilege).



Больше MCP-доступа — когда:

конкретная задача требует конкретного инструмента — не «на всякий случай». Каждое подключение — новая граница доверия.

Тот же принцип, что лестница архитектур — применённый к оснастке одного агента: **presence paradox** показал, что даже файл-инструкция «как ритуал» не работает. Усложняй под конкретный проверяемый триггер.

Человек-валидатор + урок MIT NANDA.



**Агент делает — человек проверяет
результат и факты**

*против независимого источника истины, НЕ по правдоподобности
рассуждения (self-rationale ≠ контроль — урок про faithfulness).*

Степень автономности


от «человек нажимает кнопку» до «агент уведомляет
постфактум»

Область доверия

чтение (легко откатить) vs запись · обратимое vs необратимое

Непрерывный мониторинг

метрики качества постоянно, не разовая проверка на старте



~95%

корпоративных GenAI-пилотов без измеримого
возврата инвестиций —
корень в разрыве
обучения и провале
интеграции, не в
качестве модели

**«Запустить ИИ» ≠ «получить ценность». Решает
архитектурно-интеграционная дисциплина.
Иногда правильный ответ — простейшая
архитектура или не-ИИ.**

Дальше — отрасли. Начинаем с разработки ПО.

<> Лекция 4

AI в разработке программного обеспечения

тот же аппарат — на конкретных задачах разработчика: те же coding-агенты, что мы разобрали, со стороны инженерной практики.



Задание — Семинар 3

«Архитектурный выбор: чат / агент / RAG / API — 3 кейса»

Применить чек-лист к 3 кейсам; для каждого: архитектура + ≥ 2 причины по осям + ≥ 1 условие смены выбора + критерий «здесь это было бы НЕ так». Задача В — разминка.

Аппарат собран — прогоняйте чек-лист на каждой отраслевой лекции.



Q&A

Спасибо

[контакты преподавателя — заполнить перед лекцией]