



Чат-бот выдумал политику — платит компания.

Moffatt v. Air Canada · трибунал ВС · 14.02.2024

- 1 Пассажир спросил чат-бота про тариф по случаю утраты близкого
- 2 Бот: «купи по полной цене, верни разницу в течение 90 дней»
- 3 Реальная политика этого не допускала — и была на той же странице, на которую бот ссылался
- 4 Трибунал: «бот — не отдельное юр. лицо» → компания компенсирует разницу^[1,2]

Это не сбой модели — это неправильный выбор архитектуры под задачу. Об этом классе ошибок вся лекция.

^[1] McCarthy Tétrault — Moffatt v. Air Canada (BC CRT, 14.02.2024) · ^[2] ABA Business Law Today — компании отвечают за AI-чат-бота

Архитектуры AI-систем: агенты, RAG, API

03

Какую архитектуру выбрать под задачу —
и когда правильный ответ «не ИИ»

Маршрут лекции — шесть разделов.

Одна несущая линия: выбор архитектуры под задачу — и когда правильный ответ «не ИИ».

0



Открытие

Air Canada: неправильная архитектура
стоит денег

1



Промпт и его границы

что умеет один вызов и где его потолок

2



RAG

внешнее знание в контекст — и где оно
тихо ломается

3



Fine-tune

менять веса под поведение, не под знание

4



Агенты

цикл, экипировка, память, безопасность —
и провалы

5



Фреймворк

лестница + чек-лист: как выбрать быстро
и обоснованно

Что мы переносим из Лекции 2 — и что надстроим.

Вокруг одного вызова модели надстраиваются 4 обвязки. Два готовых блока из Лекции 2 не переобъясняем.



Из Лекции 2 берём готовыми: *single-shot инференс* и *семантический поиск на эмбедингах* (основа RAG). Детали каждой обвязки — дальше по разделам.

У меня есть задача и доступ к LLM. Какую архитектуру выбрать — и когда правильный ответ «не ИИ»?

6

Multi-agent

несколько координируемых агентов

сложнее ↑

5

Агент

цикл `plan` → `act` → `check` → `iterate`

4

Workflow

предопределённые пути

3

RAG / контекст-инжиниринг

поиск-дополненная генерация

2

Один вызов LLM

промт; + CoT (по шагам), + few-shot (примеры)

1

Обычный код (без ИИ)

точка отсчёта

проще ↓



Подниматься на следующую ступень — только при требовании задачи, которого текущая не закрывает.

РАЗДЕЛ 1

Промпт и его границы

Лестницу мы увидели целиком — теперь снизу: что умеет один вызов и где его потолок, прежде чем что-либо усложнять.



Раздел 0
Открытие

Раздел 1
Промпт

Раздел 2
RAG

Раздел 3
Fine-tune

Раздел 4
Агенты

Раздел 5
Фреймворк

Дефолт — один вызов с хорошим промптом.

Модель знает только то, что в промпте (плюс то, что было в весах на обучении). Больше ей взять неоткуда.



Один вызов LLM с хорошим промптом

- минимальная стоимость (один проход)
- минимальная латентность (нет лишних обращений)
- максимальная предсказуемость (нет петель, нет retrieval, который тихо деградирует)

Добавляешь RAG →

конвейер индексации + векторное хранилище + компонент retrieval (может молча деградировать) + метрики его качества

Добавляешь инструменты / цикл →

внешние вызовы (падают, тормозят) + петли (расходятся) + недетерминизм траектории + новая поверхность атаки

Не усложняй архитектуру без причины, выраженной в требованиях задачи^[1]. Это распределение бремени доказательства, а не примитивизм.

[1] Anthropic — Building Effective Agents («найди простейшее»)

Роль в промпте настраивает тон — не точность.

«Ты — опытный юрист» сдвигает внимание модели (механизм — Лекция 2) в сторону текста, похожего на ответ такой роли, — но это про стиль, не про факты.

Расхожий миф

«Напишу роль эксперта — и модель будет точнее отвечать по фактам»

Что показал эксперимент

162 персоны · 6 типов отношений · 8 доменов · 2410 вопросов фактического QA · 4 семейства LLM. Персоны НЕ улучшили точность ответа по сравнению с ответом без персоны вообще^[1].



На что роль влияет реально

на тон и глубину изложения — насколько формально и подробно, а не верен ли факт (эффект модель-специфичен).

Нужна фактическая точность? Инструмент — не формулировка роли, а грамотный контекст и, при необходимости, RAG (опора на проверяемый источник). Это ещё один пункт «магической пилюли», опровергнутый измерением.

Структура промпта: разделяй инструкцию, контекст, данные.

Плоский промпт заставляет модель угадывать, где кончается инструкция и начинаются данные. Явная граница снимает эту неоднозначность.



Инструкция

что сделать



Контекст

на основе чего



Данные

с чем именно работать

Разделители (delimiters)

- XML-теги: `<инструкция>...</инструкция>`
- Markdown-заголовки: `## Задача · ## Данные`
- Тройные кавычки / бэктики вокруг данных

Тот же принцип, что structured output (Раздел 4): там схема задаёт структуру ВЫХОДА, здесь разделители — структуру ВХОДА. Ясная структура вместо «выведи форму по смыслу».

Модель, которой показали, где кончается инструкция и начинаются данные, реже принимает фрагмент данных за новую команду — та же путаница лежит в основе prompt injection (Раздел 4).

Chain-of-thought помогает — но его нельзя аудировать.

Без CoT

«Было 23 яблока, 7 испортились, докупили 2 ящика по 6.
Сколько хороших?»

→ правдоподобное, но неверное число

С CoT («решай по шагам»)

$$23 - 7 = 16^{[1]} \quad \cdot \quad 2 \times 6 = 12$$

$$16 + 12 = 28$$

→ верно

Технически это всё ещё один вызов — CoT инструмент под класс задач (цепочка шагов), не глобальный тумблер.

Но проговорённое рассуждение не обязано отражать реальную причину ответа (низкая faithfulness):

~25%

Claude 3.7 Sonnet

~39%


DeepSeek R1

— доля случаев, где модель упомянула реально использованную подсказку^[2].

Контроль на самообъяснении модели — не контроль. Человек-валидатор проверяет РЕЗУЛЬТАТ и факты против внешнего источника, а не правдоподобность текста. И это же — почему шаг check в цикле агента (Раздел 4) не должен быть самооценкой модели.

Контекст-инжиниринг: минимум высокосигнального.

Промпт-инжиниринг — одна инструкция. Контекст-инжиниринг — курирование всего набора токенов, видимых модели на инференсе.



Когда НЕ RAG (точка 1)

малый стабильный корпус, влезает в окно → full-context + кэширование префикса, а не RAG-инфраструктура



RAG здесь добавил бы хрупкость без выигрыша

context rot = тот же «lost in the middle» из Л2 [1,2] — новый термин, не новая сущность

«Найти наименьший набор высокосигнальных токенов, максимизирующий вероятность желаемого исхода» — это инженерное требование, не эстетика [3].

Чит-шит: как строить промпт.

Минимум, ниже которого промпт систематически недорабатывает. Приложите к любому промпту перед первым запуском.

1 Роль

если нужен тон/регистр — и НЕ как обещание точности

2 Задача

конкретное проверяемое действие, не расплывчатое пожелание

3 Контекст

минимально необходимое, не «всё, что могло бы пригодиться»

4 Формат вывода

указан явно, если ответ машинно-обрабатываем

5 Разделители

если содержимого больше одного вида (инструкция/данные)

6 Примеры (few-shot)

только если формат неочевиден из одной инструкции

7 CoT

только если задача требует многошагового рассуждения

8 Длина

не длиннее необходимого — лишние токены «тонут» в контексте

Компактная форма всего раздела: роль ≠ точность, структура помогает разделить входы, CoT — точечный инструмент, контекст — минимальный. Для крупных архитектурных решений (RAG / FT / агент) — восьмишаговый чек-лист Раздела 5.

РАЗДЕЛ 2

RAG: поиск-дополненная генерация

Извлечь релевантное → положить в контекст → ответить с опорой на источник



Раздел 0
Открытие

Раздел 1
Промпт

Раздел 2
RAG


Раздел 3
Fine-tune

Раздел 4
Агенты

Раздел 5
Фреймворк

Принцип RAG — три шага.

RAG = индексация → retrieval (semantic search Л2) → генерация с опорой; «не знаю» — корректный ответ.



«Не знаю» / «см. источник X» — корректный ответ RAG-системы^[1]. Правдоподобный ответ при нерелевантном retrieval — это дефект, а не «лучше, чем ничего».

[1] [Lewis et al. 2020 — Retrieval-Augmented Generation \(NeurIPS\)](#)

Когда RAG — правильный выбор.

RAG оправдан при сильном сигнале по признакам ниже^[1] — и отсутствии blockers со следующего слайда «когда НЕ RAG».

Большое / растущее

не влезает в окно целиком, или дорого класть весь корпус в каждый запрос

Меняется

документы, цены, регламенты обновляются чаще, чем выходят версии модели

Свежесть + провенанс

ответ опирается на проверяемый источник; можно показать, откуда факт

Приватная база

знания компании не входят в веса публичной модели

Признаки усиливают друг друга → RAG

Корп. база из тысяч регламентов, обновляется еженедельно, ответ с обязательной ссылкой на пункт: все признаки сошлись, ни один более простой механизм их совместно не закрывает → образцовый профиль RAG.



Один признак — повод присмотреться^[2], но не строить автоматически: сверьтесь с блокерами на следующем слайде.

^[1] IBM — RAG vs Fine-Tuning (вендор-нейтрально) · ^[2] U-NIAH — RAG win-rate выше у меньших моделей

Когда RAG — НЕ правильный выбор.

Знать, когда RAG не нужен, ценнее: это модная архитектура, её ставят туда, где она вредит.

1 Корпус влезает в окно

*ориентир — менее ~200k токенов,
меняется редко*

→ **full-context + кэширование
префикса, не RAG-инфраструктура**

2 Фиксированная политика / значение^[2]

тариф, цена, пункт регламента, правило

→ **детерминированный lookup /
статическая страница**

3 Данные доступны live через API / MCP

*во внутреннем сервисе, базе, поиске другой
системы*

→ **вызвать инструмент напрямую;
RAG-индекс поверх — лишний, более
хрупкий и более устаревающий слой**

RAG избыточен, если выполнен ЛЮБОЙ из трёх^[1]: (а) корпус влезает в окно и стабилен, (б) задача сводится к фиксированному значению, (в) знание уже доступно напрямую и живьём через инструмент. «Прямой вызов вернёт данные на момент запроса; RAG-индекс — на момент последней индексации.»

Провал RAG на масштабе.

«Вернул что-то» ≠ «вернул правильное»^[1,2]. У RAG нет сигнала «не нашёл» — он всегда отдаёт к ближайших, даже нерелевантных.



Legal-AI

«ближайшие» дела из другой юрисдикции / отменённый прецедент — модель опирается на них как на факт



Medical-RAG

смешал фрагменты разных пациентов — близки по симптомам, клинически объединять нельзя



Support-бот

работал на сотнях статей; после роста до тысяч качество тихо просело — никто не заметил

Air Canada — разбор архитектуры^[3]

Диагноз

сгенерированный правдоподобный текст поставлен в роль, требовавшую извлечённого проверенного факта — отказ grounding

Правильная альтернатива

фиксированная политика → lookup / страница; нужен диалог → RAG со strict grounding, обязательная цитата, явное «не знаю», проверка человеком

РАЗДЕЛ 3

Fine-tune vs промпт vs RAG

Проблему знания мы решили через RAG. А если проблема не в знании, а в поведении модели — её тоном, форматом, политикой?



Раздел 0
Открытие

Раздел 1
Промпт

Раздел 2
RAG


Раздел 3
Fine-tune

Раздел 4
Агенты

Раздел 5
Фреймворк

Что такое fine-tuning.

Fine-tuning (дообучение) — продолжение обучения уже готовой модели на ваших данных. В Л1 — тип использования; здесь — архитектурный выбор, одна из ступеней лестницы.



Промпт / RAG → КОНТЕКСТ

Меняют только вход — веса не трогаются; эффект живёт лишь в рамках запроса.

Fine-tuning → САМИ BECA


Изменение встроено в модель — действует всегда и стоит дороже того, что меняет контекст.

Промпт/RAG = «что показать модели». Fine-tuning = «изменить саму модель»^[1]. На практике «дообучить» почти всегда означает LoRA/PEFT, а не переобучение всех весов (следующий слайд).

^[1] IBM — RAG vs Fine-Tuning (fine-tuning меняет веса)

PEFT вместо full fine-tuning.

PEFT — базовые веса замораживаются, обучается лишь небольшой набор адаптеров. LoRA — низкоранговые матрицы-адаптеры; QLoRA — то же поверх квантованной модели^[1,2].



адаптеры — мегабайты vs гигабайты

98,4% моделей с тегом PEFT — это LoRA^[3]

из 20 834 карточек на Hugging Face Hub · оговорка: доля среди моделей с тегом PEFT, не среди всего fine-tuning

1. Дешевле и быстрее

обучаются миллионы параметров вместо миллиардов; QLoRA — на одном GPU

2. Модульность

адаптеры мегабайты vs гигабайты; одна база — много специализаций

3. ↓ Риск catastrophic forgetting

база заморожена, физически не переписывается под новый сигнал — архитектурный аргумент

PEFT (LoRA/QLoRA) почти всегда лучше full fine-tuning: дешевле, модульнее, ↓ риск forgetting. Full FT в 2026 — почти никогда.

Fine-tuning не умер^[1] — он сузился до поведения.



Ушло из fine-tuning (2026)

знание, факты, то, что меняется → RAG / длинный контекст. Зашить факты в веса: нельзя процитировать, обновить точно, удалить один.



Осталось за fine-tuning

поведение · стиль · формат вывода · следование политике. Дистилляция — отдельная техника, часто применяемая в связке с дообучением^[2,3].


Если задача требует...	→ правильный инструмент	...и НЕ этот, потому что
знание меняется / нужны свежесть, провенанс	RAG (или длинный контекст для малого корпуса)	не fine-tuning: устареет, дорого переобучать, риск forgetting
стабильное поведение / тон / формат / политика	fine-tuning (PEFT)	не RAG: подаёт знание, но не меняет манеру модели
снизить стоимость / латентность на узкой задаче	fine-tune teacher + дистилляция student	две отдельные техники в связке, НЕ «дистилляция = вид fine-tuning»
детерминированный, верифицируемый ответ	обычный код, без ИИ	ни RAG, ни FT: ИИ добавит недетерминизм без выигрыша

Реальный вопрос 2026 — не «RAG или fine-tuning», а «что здесь знание (→ RAG), что поведение (→ PEFT), что детерминировано (→ код)». Гибрид — норма там, где есть И проблема знания, И проблема поведения.

[1] [BigData Boutique — Fine-Tuning When RAG Isn't Enough](#) · [2] [Hinton, Vinyals, Dean 2015 — Distilling the Knowledge](#) · [3] [PEFT survey — таксономия методов настройки](#)

Провал: catastrophic forgetting.

Catastrophic forgetting (катастрофическое забывание) — деградация общих способностей модели в результате узкого агрессивного дообучения^[1].



тяжелее с ростом масштаба модели — у крупной выше исходный уровень, ей «больше падать»

Нет eval-петли на общих задачах + нет версий датасета/весов → не увидишь поломку до прода + не сможешь откатиться → это не «риск», это критерий «НЕ делай fine-tuning»

Правильно: PEFT (замороженные веса — ниже риск); для меняющегося знания — RAG, не FT вовсе.

[1] Luo et al. 2023 — [Catastrophic Forgetting in LLM Continual FT](#) · Эмпирически наблюдается при continual fine-tuning (Luo et al. 2023). Механизмы — «исследования показывают» (preprint).

РАЗДЕЛ 4

Агенты

От собеседника в окне чата — к компоненту продакшен-системы: цикл, экипировка, память, доступ к инструментам — и где всё это ломается.



Раздел 0
Открытие

Раздел 1
Промпт

Раздел 2
RAG

Раздел 3
Fine-tune

Раздел 4
Агенты

Раздел 5
Фреймворк

Модель становится компонентом системы: API + MCP.



Structured output

выход строго по схеме (JSON), не текст для парсинга

встраиваемая



Function calling

модель формулирует «вызовы X»; исполняет ваш код, не модель

активная



Prompt caching

не пересчитывать неизменный префикс при каждом запросе

экономичная



MCP — «USB-C для инструментов LLM»

N×M несовместимых интеграций → **N+M**^[1]

инструмент один раз = MCP-сервер; модель один раз = MCP-клиент

AI Anthropic
11/2024



 OpenAI
03/2025



 Google
04/2025

Стандартизация подключения ≠ безопасность подключаемого — и усугубляет проблему доверия.

- код в вашем окружении / доступ к данным
- описание попадает в контекст — носитель prompt injection

Ни один механизм не делает модель надёжнее — правило лестницы не отменяется. Удобство подключения — не аргумент за подключение.

[1] [Anthropic — MCP donation / Agentic AI Foundation \(N×M → N+M\)](#) · Актуальные цифры экономии и масштаб экосистемы MCP — в главе методички.

Цикл агента: plan → act → check → iterate.

Агент — архитектура, где модель не делает один проход, а работает в цикле^[1], сама определяя последовательность шагов.



Workflow vs Agent.

Предсказуемая задача → workflow^[1]; непредсказуемая И ценность оправдывает кратный рост → агент.



Workflow (рабочий поток)

LLM и инструменты по предопределённым в коде путям

- последовательность шагов известна заранее
- предсказуемо, аудируемо
- большинство надёжных продакшн-систем — это workflow



Агент

LLM динамически определяет собственный процесс

- последовательность заранее не зафиксирована
- кратно больше токенов, чем чат
- ниже аудируемость, выше риск петель

Могу ли я заранее, до запуска, выписать последовательность шагов? **да (даже с ветвлениями) → workflow** ·
принципиально нет И ценность оправдывает кратные стоимость/риск → агент^[2]

Вложенность — норма: агент code review вызывает workflow «линтер → тесты → формат» как один шаг; workflow обработки заявок делегирует мини-агенту разбор свободной жалобы. Динамика — только там, где нужна.

Найди простейшее. «Лень формализовать» не делает задачу непредсказуемой.

Каждый слот экипировки агента — компромисс, не апгрейд.

Реальный агент-помощник (Claude Code, Cursor, Aider) — это цикл *plan* → *act* → *check* → *iterate* ПЛЮС оснастка. Пять типовых слотов^[1]:



Как не поднимаешься по лестнице архитектур без требования задачи — не добавляй агенту память, subagents или MCP «на всякий случай». Каждый слот несёт свою цену: операционную сложность, новую поверхность отказа, новую границу доверия — и должен отвечать на конкретный триггер (Раздел 5).

[1] *agent-harness-registry* — карта слотов экипировки агента

Память агента — тот же вопрос масштаба, что RAG.

Память — что агент помнит *МЕЖДУ* сессиями (в отличие от контекста одного разговора). Спектр — от плоского файла до graph-баз^[1].



Плоский файл

агент дописывает факты в текстовый лог, при запуске читает целиком. Работает, пока лог мал и стабилен — прямая параллель критерию RAG «корпус помещается в окно».



Векторная / graph-база

- mem0 — cross-session память пользователя
- Cognee — memory на графе знаний
- Graphiti / Zep — temporal graph: когда факт верен, когда устарел

Тот же вопрос масштаба знания, что решает RAG для корпуса документов, здесь встаёт для памяти самого агента. Не ставьте graph-базу агенту с короткими несвязанными сессиями — это тот же технический долг без требования, что RAG для десяти статей.

[1] [agent-harness-registry \(live-eval\)](#) — спектр памяти агента · Источник: публичный реестр [agent-harness-registry \(workain lab, live-eval\)](#).

«Агент, который помнит» — не всегда лучше.

Наличие памяти интуитивно кажется чистым улучшением. Независимый live-eval показывает: иногда — драматически нет^[1].



Letta — Tier D

проигрывает И голой модели, И плоскому файлу на всех задачах.
persistbench_v1:

 Голая модель	1.000	94 с
 Плоский файл	0.833	159 с
 Letta	0.750	496 с

Механизмы: капитуляция под давлением · многословие топик факт · факт замечен, но не закодирован.

Оговорка: тест на Letta v0.6.7 — отстаёт от текущей v0.16.8 (~18 мес).

Anthropic Memory Tool — Tier B

В целом сильный результат — но даже он теряет данные в

17% задач

- явный отказ записать «эфемерный» факт
- немотивированный отказ «вне рамок»
- тихая lossy-суммаризация — деталь не восстановить
- невоспроизводимость: та же беседа дважды → разный результат

Файл-инструкция агенту — не «магическая прививка».

Операционный слой — файлы-конвенции (класс *CLAUDE.md* / *AGENTS.md*) + журнал задач. Интуиция «написал инструкцию → лучше» расходится с измерением.



presence paradox

RCT (Gloaguen et al. 2026): само наличие файла-инструкции НЕ даёт значимого прироста^[1] успешности — при этом стоимость и число шагов растут.

Помогает только там, где реально заполняет пробел документации.



Honest Lying

Dixit, Kamal, Oates 2026: self-authored память может ЗАКРЕПЛЯТЬ неверное убеждение — журнал бетонирует раннюю ошибку вместо пересмотра.

Рефлексия ошибочна → повторные попытки опираются на неё.



claude-code#51735

Реальный кейс: письменно признанная прошлая ошибка НЕ предотвратила её повторение спустя 25 дней^[2].

Запись о провале ≠ гарантия, что поведение изменится.

Полезен, когда заполняет реальный пробел; бесполезен, когда дублирует доступное модели; может навредить, когда самоавторская память закрепляет ошибку. Тот же паттерн, что роль в промпте: «добавить X → лучше» не подтверждается измерением.

[1] [Gloaguen et al. 2026 — Evaluating AGENTS.md \(presence paradox\)](#) · [2] [GitHub anthropics/claude-code#51735 \(повтор ошибки через 25 дней\)](#)

Skills, subagents, доступ — и граница доверия.



Skill

переиспользуемая процедура «как делать»
под повторяющуюся задачу



Subagent

отдельное контекстное окно: не засорять
главный + изолировать недоверенное



MCP-доступ

каждое подключение — новая граница
доверия и retention-политика



Безопасность: как только агент делегирует и подключается — появляется поверхность ^[2,3], которой не было у одного вызова

GitHub MCP heist (май 2025)

issue с встроенной инструкцией + переизбыточный токен (PAT на все репо)
→ ассистент выгрузил приватные репозитории в публичный PR^[1].

Катастрофа = инъекция × широкие права. Убери любое — атака не проходит.

«У нас ZDR» ≠ «нигде не хранится»: судебный приказ (NYT v. OpenAI) + third-party/MCP вне ZDR^[4,5]. Регулируемое — не слать без ZDR/BAA.

4 правила проектирования

1

Least-privilege

минимум токенов/прав

2

Изоляция недоверенного

отдельно от привилегий (subagent)

3

Human-in-the-loop на write

необратимое — только через человека

4

Allowlist / pin

аудированные версии; deny-by-default

Реальные coding-агенты — через рамку экипировки.

Разница между инструментами — не в «качестве модели», а в том, какие слоты экипировки заполнены и где агент физически живёт^[1].

<> Claude Code

CLI + IDE · проприетарный

широкая экипировка: память, файлы-инструкции, skills, полноценные subagents, MCP — почти все 5 слотов

цена — большая операционная сложность

<> Aider

CLI-first · open source

минимальная простота: без развитой памяти, без subagents, без skills. ~47k★ на GitHub

«тонкая» оснастка — самостоятельный выбор, не недоразвитость

<> Cursor

desktop IDE (форк VS Code) · проприетарный

агент внутри редактора — не терминал. Форма интеграции — отдельная ось от оснастки

где живёт агент — тоже архитектурное решение

<> OpenHands

self-hosted платформа · MIT · ~80k★

широкая автономность, локальное/Docker/облако развёртывание

рабочая гипотеза по совпадению профиля — вероятный кандидат на «OpenClaw», не подтверждённый факт

Выбор инструмента подчиняется тому же правилу: не бери самый оснащённый по умолчанию — смотри, какая оснастка нужна именно твоей задаче.

[1] agent-harness-registry — обзор через рамку экипировки

Провалы агентов.

Каждый провал — режим отказа цикла агента в датированном кейсе: урок + альтернатива.



1. Петля без лимитов

Агент на «синхронизируй заказы» получил HTTP 429 → план → вызов → 429 → ...


\$4 200 за 63 часа^[1]

База сравнения: retry-скрипт с backoff решил бы ту же задачу за секунды-минуты, практически бесплатно

\$4 200 — цена не автоматизации, а неправильного выбора архитектуры под предсказуемую задачу

Более подходящая архитектура: retry-with-backoff скрипт, не агент; лимиты бюджета и итераций ВНЕ агента

2. Накопление ошибок (compounding)



Вывод: «улучшить шаг» — слабый рычаг; «меньше хопов + валидация между шагами» — сильный^[2]



3. Мульти-агентная хрупкость

зависимые подзадачи → параллельные субагенты принимают конфликтующие^[3] неявные решения

Более подходящая: single-threaded линейный агент; мульти-агент — только широко-параллельное независимое

РАЗДЕЛ 5

Как выбрать: фреймворк решения

Мы разобрали все архитектуры по отдельности — и где каждая проваливается. Теперь соберём это в один инструмент выбора.



Раздел 0
Открытие

Раздел 1
Промпт

Раздел 2
RAG

Раздел 3
Fine-tune

Раздел 4
Агенты

Раздел 5
Фреймворк

Лестница архитектурной сложности.

Оставайся на нижней ступени; поднимайся только под требование задачи.



[1] Anthropic — Building Effective Agents (правило лестницы) · Нижняя ступень — «обычный код без ИИ»: лестница начинается с вопроса «а нужен ли ИИ вообще».

План решения: маршрут вопросов, а не сумма баллов.

Пройдите задачу сверху вниз; останавливайтесь на первом сработавшем вопросе^[1].



Пример (задача А)

«2000 регламентов, меняются еженедельно, ответ со ссылкой на пункт» → вопрос 4 (меняется+провенанс) решающий → RAG со strict grounding. Не FT (устареет), не код (нужен NL).

Разминка (задача В)

«бот на ~150 FAQ, меняются раз в квартал» — пройдите маршрут сами; разбор на семинаре.

Приоритет маршрута: если задача детерминированная и верифицируемая — обычный код, СТОП здесь^[2]. ИИ добавил бы лишь недетерминизм, стоимость, латентность и поверхность для prompt injection.

[1] Anthropic — Building Effective Agents (маршрут выбора) · [2] McCarthy Tétrault — Air Canada (нижняя строка матрицы)

Стартовый комплект агента — и когда его усложнять.

Та же лестница «не усложняй без требования», применённая на уровень ниже — к оснастке одного агента, а не системы целиком.



Дефолт — тонкий агент

- один файл-инструкция
- плоская память
- БЕЗ subagents
- минимальный набор skills
- минимальный MCP-доступ
Бремя доказательства — на усложнении, а не на простоте.



Память-бэкенд — когда:

история переросла контекст ИЛИ нужен structured retrieval по фактам (не «последние N сообщений»). Тот же критерий, что переход промпт → RAG.



Subagents — когда:

подзадача требует отдельного окна (не засорять контекст) ИЛИ изоляции недоверенной работы (least-privilege).



Больше MCP-доступа — когда:

конкретная задача требует конкретного инструмента — не «на всякий случай». Каждое подключение — новая граница доверия.

Тот же принцип, что лестница архитектур — применённый к оснастке одного агента: presence paradox показал, что даже файл-инструкция «как ритуал» не работает. Усложняй под конкретный проверяемый триггер.

Человек-валидатор + урок MIT NANDA.



Агент делает — человек проверяет результат и факты

против независимого источника истины, НЕ по правдоподобности рассуждения^[1] (self-rationale ≠ контроль — урок про faithfulness).

Степень автономности


от «человек нажимает кнопку» до «агент уведомляет постфактум»

Область доверия

чтение (легко откатить) vs запись · обратимое vs необратимое

Непрерывный мониторинг

метрики качества постоянно, не разовая проверка на старте



~95%

корпоративных GenAI-пилотов без измеримого возврата инвестиций — корень в разрыве обучения и провале интеграции, не в качестве модели^[2]

«Запустить ИИ» ≠ «получить ценность». Решает архитектурно-интеграционная дисциплина. Иногда правильный ответ — простейшая архитектура или не-ИИ.

Дальше — отрасли. Начинаем с разработки ПО.

< > Лекция 4

AI в разработке программного обеспечения

тот же аппарат — на конкретных задачах разработчика: те же coding-агенты, что мы разобрали, со стороны инженерной практики.



Задание — Семинар 3

«Архитектурный выбор: чат / агент / RAG / API — 3 кейса»

Применить чек-лист к 3 кейсам; для каждого: архитектура + ≥ 2 причины по осям + ≥ 1 условие смены выбора + критерий «здесь это было бы НЕ так».
Задача В — разминка.

Аппарат собран — прогоняйте чек-лист на каждой отраслевой лекции.



Q&A

Спасибо

[контакты преподавателя — заполнить перед лекцией]