

Сборка стала почти бесплатной — и почти никто не превратил это в пользу



Недели работы → часы ^[1]

внутренний опыт Anthropic



**~95% организаций —
нулевая отдача** ^[2]

Массачусетский технологический институт, лето 2025 — доля от всех организаций, а не от дошедших до пилота

Оба факта правдивы одновременно: сборка стала почти бесплатной, а превращение сборки в ценность — нет. Разрыв между ними и есть предмет лекции; он разрешится в самом конце.





ЛЕКЦИЯ 5

ИИ-продукт: полный жизненный цикл — от намерения до эксплуатации

ИИ — искусственный интеллект

Курс «Осознанное применение ИИ» · инженеры-студенты 3 курса

Шесть разделов — шесть стрелок одной петли. Код из Лекции 4 — один шаг внутри неё, и теперь самый дешёвый из всех.

0
Введение

1
Исследование

2
Дизайн

3
Сборка и запуск

4
Измерение

5
Поддержка

6
Управление

7
Обобщение

Лекция — это петля, а не список из шести тем



1. Исследование — откуда берётся гипотеза

2. Дизайн — гипотеза становится артефактом

3. Сборка и запуск — артефакт становится продуктом

4. Измерение — сработало ли это на самом деле

5. Поддержка — работает без остановки

6. Управление — куда вкладывать

Золотая стрелка возврата: управление снова питает исследование. Петля замыкается и запускается заново — поэтому карта нарисована кругом.

Зачем продукту цикл: без него ошибку находят слишком поздно

Пять вопросов, на которые продукт отвечает наблюдением, а не мнением

1 Нужно ли это кому-то вообще

фаза 1 · исследование

2 Сможет ли человек этим воспользоваться и не пострадает ли тот, о ком не подумали

фаза 2 · дизайн

3 Можем ли мы это сделать и безопасно выпустить

фаза 3 · сборка и запуск

4 Выберут ли это настолько, чтобы за это платить

фазы 4 и 6 · измерение, управление

5 Держатся ли эти ответы через квартал

фаза 5 · поддержка

Первые четыре — риски продукта по Марти Кагану (продуктовый руководитель, основатель Silicon Valley Product Group, автор книги «Inspired»); пятый открывается только после запуска. У каждого своя фаза: цикл и есть минимальный набор мест, где на эти вопросы отвечают.

Когда цикла нет

Вопросы не исчезают — их место занимают оптимистичные допущения.

Ошибка не исчезает тоже — сдвигается только момент, когда её находят: после оплаченной сборки и состоявшегося релиза, где откат стоит дороже самой ошибки.

От требований до выпуска стоимость исправления расходится до ста раз в крупных проектах и вчетверо в небольших (Барри Боэм, исследователь экономики разработки программ, 1981).

Изнутри команды это не выглядит провалом

Собрали — никто не пользуется · дошли до пилота и застряли · работает, но не выбрано · внедрили, а через квартал перестали открывать.

Сборка во всех четырёх случаях прошла успешно — поэтому изнутри команды это читается как успех; ошибки в непроверенной гипотезе никто не видит.

Дороговизна сборки работала невольным заслоном: пока изготовление стоило недели, оно само заставляло думать заранее. Искусственный интеллект обнулил именно её — и у команд, у которых явного цикла не было никогда, не осталось ничего, что удерживало бы от пропуска этих вопросов.

Искусственный интеллект меняет каждую стрелку — но не одинаково

У каждой стрелки петли есть классическая дисциплина, и искусственный интеллект её не отменяет. Он меняет ровно две вещи: сколько эта дисциплина стоит и насколько ей можно верить без проверки.

Три стрелки петли — и что именно с каждой сделал искусственный интеллект



Строить

фаза сборки и запуска

стоимость упала почти до нуля: черновик кода, макета, плана исследования



Измерять и делать выводы

фаза измерения

стоимость та же, а доверие к результату упало: сам инструмент измерения стал вероятностным



Наблюдать за работой продукта

фаза поддержки

наблюдать стало быстрее, но само наблюдение уязвимо: подменённые данные на входе ведут к уверенному неверному выводу

Каждая из шести фаз дальше разбирается по одной и той же схеме: какая классическая дисциплина за неё отвечает, что в ней удешевил искусственный интеллект, и где подход «сначала ИИ» ломается.

Одну и ту же петлю независимо описали трижды: статистик качества Уильям Деминг (1939), лётчик-истребитель и военный теоретик Джон Бойд (1970-е), предприниматель Эрик Райс (2011). Это структурное свойство системы, которая учится в неопределённости, а не методология одного автора.

РАЗДЕЛ 1

Исследование — есть ли проблема и у кого

1 база · 2 практики · 2 провала

Цель фазы одна: выяснить, существует ли проблема и у кого именно, пока решение ещё не построено. Пропустить её можно — тогда ответ придёт в день запуска, когда деньги и месяцы уже потрачены, а вернуть их нечем.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Проверить гипотезу стоит нескольких разговоров — не проверить стоит всей разработки



ЗАЧЕМ ЭТА РАБОТА Исследование отвечает на один вопрос: существует ли проблема и у кого именно. Ответ придёт в любом случае — либо от восьми разговоров за две недели, либо от рынка в день запуска, когда разработка уже оплачена.



Развитие клиента (Customer Development)

Стив Бланк, предприниматель Кремниевой долины и преподаватель Стэнфорда, — дисциплина поиска ответа «что и для кого строить»

Правило, ради которого она существует: внутри офиса фактов нет, факты снаружи. Но выйти наружу мало: без записанной заранее гипотезы возвращаются с впечатлениями, подтверждающими то, во что верили до выхода.

мы верим X → проверим через Y → к дате Z получим ответ да или нет

Дата — не оформление: без неё «проверим» не имеет срока.

Два правила разговора

«The Mom Test» — «Тест мамы»: вопрос верен, если даже собственная мама не сможет соврать из вежливости. Роб Фитцпатрик, предприниматель



Спрашивать о конкретном прошлом, а не о мнении про будущее



Засчитывать обязательство — время, репутацию, деньги, — а не комплимент

Плохо: «Заплатили бы 20 долларов в месяц?» → **Хорошо:** «Сколько вы платите сегодня за ближайший аналог?»

Это не альтернатива циклу разработки и не второй процесс рядом с ним. Цикл отвечает на вопрос «как быстро проверять», эта дисциплина — на вопрос «что и у кого проверять». Она работает на первой стрелке петли, до того как что-то построено.

Что ИИ изменил в исследовании к 2026 году — и что не изменил

ШАГ ФАЗЫ	БЕЗ ИИ	С ИИ — 2026
 Кабинетный поиск <i>собрать, что уже известно о рынке и о боли</i>	Аналитик читает отчёты, публикации и форумы — дни работы	Режим глубокого исследования сам планирует поиск, читает сотни источников и отдаёт отчёт со ссылками за 2–30 минут. Есть у всех основных помощников, включая бесплатные тарифы с лимитом
 Сам разговор	Каждое интервью исследователь проводит лично; восемь разговоров — недели календаря	Вопросы задаёт модель, отвечает живой человек — разговоров за тот же сроккратно больше
 Сведение разговоров	Расшифровка вручную, темы выписываются глазами	Расшифровка стала бесплатным приложением к созвону; инструменты непрерывно пересобирают темы по всему накопленному корпусу, а не по одному звонку

Кто на том конце разговора

человек ↔ человек классическое интервью	человек ↔ модель спрашивает машина, отвечает живой человек	модель ↔ модель ИИ-персона: отвечает тоже машина — живого человека в цепочке нет ни разу
---	--	--

Опрос 150 исследователей, май 2026: **81%** регулярно применяют ИИ в работе · **8%** — как отвечающего участника · **28%** отвергают его прямо

Ссылка в отчёте не доказательство, пока её не открыли. Измерено на 53 090 ссылках из отчётов десяти моделей: 3–13% выдуманы — таких источников не существовало никогда. При самом низком уровне, 3%, отчёт с 50 ссылками содержит хотя бы одну выдуманную с вероятностью 78%. Именно такой отчёт Deloitte сдала правительству Австралии за 440 000 австралийских долларов.

[1] [Perplexity — обзор режима глубокого исследования](#) · [2] [User Interviews — «State of Synthetic Users», май 2026](#) · [3] [arXiv 2604.03173 — измерение ссылок в отчётах агентов](#) · [4] [Fortune \(7 окт. 2025\) — Deloitte Australia](#)

Репетиция вопросов интервью на ИИ-персонах

ЧТО ЭТО

Перед выходом к живым людям список вопросов прогоняют через нескольких выдуманных собеседников, которых играет модель. Цель — не узнать что-то о продукте, а поймать плохие вопросы до того, как они испортят настоящий разговор. Это репетиция, а не исследование.

МЕХАНИЗМ

- 1 Описывают несколько разных типов клиента — **не портретом**, а по тому, как человек живёт с задачей: чем пользуется сейчас, во что это обходится, что однажды попробовал и бросил.
- 2 Каждый тип держат отдельно, чтобы ответы не сливались в один общий голос.
- 3 Через всех прогоняют один и тот же список вопросов.
- 4 Читают **не ответы, а две вещи**: вопрос, на который все ответили одинаково, никого не различает; вопрос, на который отвечают про воображаемое будущее, подталкивает к вежливой выдумке. Оба переписывают.



наружу выходит только
правленный список вопросов

С ИИ И БЕЗ ИИ

БЕЗ ИИ — так репетировали всегда

Список вопросов проговаривают на коллеге или тратят на репетицию одно живое интервью из восьми. Работает, но даёт один взгляд и стоит дня.

С ИИ — что изменилось

Репетиция занимает минуты, и прогонов можно сделать десяток. Дешевеет **только репетиция**: само интервью с живым человеком не заменяется ничем.

ГДЕ НЕ РАБОТАЕТ

Ответы собеседников — не данные о пользователях: модель одна, и пять собеседников — это пять взглядов одной модели, а не пять людей. При сверке с настоящим национальным опросом средние ответы модель повторяет, а разброс мнений занижает вдвое (16 против 31). Приём запущен неправильно, если из прогона вынесен вывод о продукте, а не о формулировке вопроса.

Поиск боли по накопленным обращениям в поддержку

ЧТО ЭТО

Если у продукта уже есть пользователи, у него есть и архив их жалоб и вопросов. Приём превращает этот архив в источник гипотез: обращения складывают в поисковый массив, собирают похожие по смыслу в группы и смотрят, какие темы повторяются. Наружу выходит названная тема боли.

МЕХАНИЗМ

- 1 Каждое обращение кладут в общий массив и приписывают к нему, когда оно пришло, от кого и по какому продукту.
- 2 Ищут **двумя способами сразу**: по точному совпадению слов и по смыслу. Код ошибки находит только первый, описание проблемы своими словами — только второй.
- 3 Похожее собирают в группы и пересказывают в два приёма: сначала каждое обращение отдельно, потом общее между ними. Пропуск первого приёма — потеря 20–40% деталей.



**сложить
и разметить**



**искать словом
и смыслом**



**собрать похожее
в группы**

порядок шагов: пропуск разметки превращает архив в мешок текста

С ИИ И БЕЗ ИИ

БЕЗ ИИ — ручная разметка по темам

Обращения раскладывают по заранее придуманному списку тем. Поэтому находят только те темы, которые кто-то уже предположил.

С ИИ — что изменилось

Похожее по смыслу собирается само, без списка тем, и пересказ группы делается за минуты. **Название темы всё равно проверяет человек** — машина группирует, а не решает.

ГДЕ НЕ РАБОТАЕТ

Архив смещён по построению: в нём есть только те, кто дошёл до жалобы. Объём этого не лечит — не бывает обращения «мне нужно то, чего у вас вообще нет». На вопрос «почему люди не доходят до регистрации» приём не отвечает: нужен разговор с теми, кто ушёл. И поиск возвращает похожие обращения, а не важные: десять тысяч жалоб на опечатку — по-прежнему одна опечатка.



кто дошёл до жалобы



все пользователи



архив обращений

Синтетический собеседник не может произвести несогласие

Зеркало согласия

Доля случаев, в которых тон ответа модели сдвигается к позитиву. Замер по пяти языковым моделям.

72-91%

когда собеседник явно соглашается

7-28%

когда собеседник явно возражает

Измерен сдвиг тона: собеседник возразил — и модель поехала за ним, хотя данных у неё не прибавилось. Частота положительного ответа — другая величина.

Измерено исследователями компании Anthropic на пяти моделях: Мринанк Шарма и соавторы, 2023

Когда живой разговор строго лучше синтеза



1. Высока цена ошибки в решении «продолжать или остановить»



2. Нужно реальное прошлое, а не правдоподобное



3. Нужна проверка обязательством, а не мнением

У синтетического собеседника нет реального прошлого, способного противоречить формулировке вопроса, — поэтому несогласие он не производит в принципе. Сложите это со сдвигом тона слева: ответ смещён в сторону «да» — и притом «да» о событии, которого никогда не было.

Пересказ интервью теряет 20-40% деталей, если пропущен шаг «сначала каждое по отдельности», — прослеживаемый до конкретного шага сбой, а не расплывчатое «ИИ иногда ошибается».

Одна и та же задача: реальные люди — 3 из 7, панель ИИ-персон — 7 из 7 ^[1]



ЧТО ПРОИЗОШЛО Nielsen Norman Group — исследовательская группа, которая с 1998 года занимается удобством интерфейсов, — взяла один сценарий первого знакомства с продуктом и прогнала его дважды: с живыми участниками и с панелью ИИ-персон, сгенерированных под тот же профиль. Сравнивали две величины: сколько шагов сценария доведено до конца и как оценены одни и те же функции.

Живые участники



3 из 7 шагов доведены до конца

Панель ИИ-персон



отчиталась о 7 из 7

Об одной и той же функции: **«надуманно и бесполезно»** — живые участники, **«изменяет правила игры»** — ИИ-персоны

Расхождение прошло сразу по обоим измеряемым величинам, на одном и том же материале — неудачным прогоном это не объясняется: такой выход дисквалифицирован для решения «продолжать или остановить» по построению. Альтернатива: оставить панели до-исследовательскую роль, а решение опереть на тест с 5-8 живыми участниками — размер, который уже вскрывает большинство проблем удобства.

Продано 10 000 приборов из запланированных 100 000: сравнение с телефоном в кармане покупателя сделали после сборки



ЧТО ПРОИЗОШЛО Humane — компания, основанная в 2018 году выходцами из Apple. Её единственный продукт, AI Pin, — носимый прибор без экрана: коробочка на одежде с камерой, микрофоном и лазерной проекцией на ладонь, отвечающая голосом через языковую модель. Замысел: человек перестаёт смотреть в телефон. Прибор показали 9 ноября 2023 года, продажи открыли в апреле 2024-го — 699 долларов плюс 24 доллара в месяц. 18 февраля 2025 года активы купила HP за 116 млн долларов, 28 февраля облачный сервис погасили: приборы на руках у покупателей отвечать перестали.



Что показали числа

- Продано ≈10 000 приборов — десятая часть собственной цели компании, 100 000 за год
- Выручка ≈9 млн долларов против ≈230 млн привлечённых — около 4%
- Май-август 2024: возвратов больше, чем покупок; к августу на руках оставалось ближе к 7 000
- Цену снизили с 699 до 499 долларов — через полгода после начала продаж



Чего не выяснили до сборки

Вопрос фазы исследования звучит одной фразой: **по сравнению с чем**. У каждого покупателя в кармане уже лежал телефон, который делает то же самое и остальное сверху. Обзоры сошлись на том, что прибор делает меньше телефона и делает это медленнее.

Такой ответ стоит восьми разговоров с живыми людьми до сборки. Здесь его получили от рынка — через 230 млн долларов и 10,5 месяца продаж.

Ответ о пользователе приходит в любом случае; фаза исследования выбирает только, когда и по какой цене. Критерий, который переносится дальше: гипотезу о пользователе закрывают сравнением с тем, чем человек обходится сегодня.


Прибор при этом работоспособен, и промах лежит в ответе на вопрос, кому и зачем он нужен. Google Glass прошёл тот же путь в обратную сторону: очки за 1500 долларов сняли с широкой продажи в январе 2015 года, а затем отдали человеку, у которого руки заняты работой. У AGCO, производителя сельхозтехники, время сборки машин упало на 25%, время контроля — на 30%; у логистической компании DHL выработка на складе выросла на 15% — всё против той же работы без очков. Прибор тот же. Пользователь другой.

РАЗДЕЛ 2

Дизайн — гипотеза становится артефактом

1 база · 1 практика · 1 провал

Шаг, на котором гипотезу впервые показывают живому человеку — пока она стоит дёшево и её не жалко выбросить. Здесь же решают, как человек будет понимать систему: поверхности контакта, её поведение, ответ в неуверенности.



прыгнуть сразу к
решению



сначала —
правильная проблема

0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Дизайн здесь — вся работа человека с системой: поверхности контакта, поведение, ответ в неуверенности

 **ОБЪЁМ ПОНЯТИЯ** Экран — одна из поверхностей, через которые человек встречается с системой. Дизайн этой фазы решает весь состав встречи: где система попадает к человеку, как ведёт себя со временем и что делает в ту минуту, когда сама не уверена в ответе. У продукта с языковой моделью работы на остальных поверхностях обычно больше, чем на экране.

Поверхности и точки контакта



Экран

что человек видит и в каком порядке



Голос

то же решение без картинки: порядок, длина, право перебить



Уведомление

система начинает разговор сама: когда и по какому поводу



Письмо, отчёт

ответ, который читают, когда системы под рукой нет



Отказ

что система говорит, когда делать не станет



Молчание

обработка идёт, ответа ещё нет: что человек видит эту минуту

Поведение системы во времени



Уверена

отвечает и показывает, на чём ответ построен



Не уверена

говорит об этом от первого лица и предлагает ход дальше



Ошиблась

человек видит, что произошло, и у него есть путь назад

Решения этого слоя принимают один раз, и живут они дольше любой вёрстки: имя продукта, обещание на входе, право остановиться. Имя задаёт картину системы в голове раньше, чем человек увидит первый экран, — и правка этой картины обходится в отзыв всего парка.

Зачем нужен отдельный шаг дизайна: дешёвый черновик ловит ошибку раньше готового продукта

Зачем эта работа нужна

 Ошибку нашли на черновике — переделать набросок стоит часов работы одного человека. Черновик для того и делают: его не жалко выбросить целиком.



 Ту же ошибку нашли после выпуска — переделывать придётся работающий продукт: недели работы команды, и к ним прибавляются ушедшие пользователи.

Пропустить этот шаг — значит заплатить то же самое позже и дороже.

расширяем набор задач

расширяем набор решений



сводим к одной задаче

сводим к одному решению

Двойной ромб (Double Diamond) ^[1]

Ромб — один цикл работы: расширяем набор вариантов, потом сводим их к одному.

Ромбов два, потому что выбирают дважды: сначала задачу, и только потом — решение.

Нашу петлю он не заменяет: это увеличительное стекло на её шаге 2 «Дизайн».

 **Десять эвристик Якоба Нильсена (1994)** — короткий список правил удобства: знающий человек за полчаса проходит по нему готовый вариант и отвечает на вопрос, недоступный машине, — понятно ли это живому человеку. Её ставят поверх уже сведённого варианта; в череду стадий она не входит. ^[2]

Частая ошибка инженера — сойтись на решении, не проверив саму задачу: перепрыгнуть первый ромб. Тот же образ действия, что «сразу писать код», минуя вопрос, ту ли задачу мы вообще решаем. Оба ромба работают по всей встрече человека с системой: экран, голос, поведение в неуверенности.

Генераторы интерфейсов: машина даёт варианты, выбирает и доводит человек

Что машина делает сама: четыре непохожие раскладки одного экрана за минуты



Дальше человек: выбирает одно направление, отбрасывает остальные и правит то, что модель поняла неверно — отступы, порядок важности, редкие случаи.

Чем это делают в 2026 году ^[1]

Figma Make — собирает экраны внутри редактора макетов и берёт собственные детали команды вместо общих заготовок.

Google Stitch — из текста и набросков в экран; бесплатный, с марта 2026 умеет переносить макеты из Figma и отдавать код ^[2].

v0 — из описания сразу в готовый код интерфейса.

Lovable, bolt.new — из описания сразу в работающее приложение целиком.

Magic Patterns — быстрый перебор вариантов одного экрана.

С генератором и без него: замер вместо обещания ^[3]

Как мерили. Сто участников — пятьдесят дизайнеров и пятьдесят продуктовых руководителей — случайно поделены на две группы: одной дали генератор, второй не дали. Три одинаковые задачи на правку интерфейса, сентябрь 2026 года.

Обещание «день ручного черчения превращается в минуты» замер не подтверждает: выигрыш реален, но измеряется десятками процентов и зависит от того, кто работает и насколько сложна задача. Опыт поставила сама Figma на собственном инструменте — держите поправку в уме.

Что вышло. Общее время сократилось примерно на 20%. У продуктовых руководителей выигрыш 35%. У профессиональных дизайнеров — только на самой сложной из трёх задач (26%), а общий эффект у них пограничный (17%).

Машина расширяет набор вариантов. Свести их к одному — решение о ваших пользователях и ваших ограничениях, которых в обучающих данных нет. Генератор закрывает экран; поверхности контакта, поведение системы и ответ в неуверенности остаются за человеком.

Дизайн-система: общие правила интерфейса, которые машина умеет проверить сама

ЧТО ЭТО

Дизайн-система — общий свод правил интерфейса продукта и набор готовых деталей к нему: допустимые сочетания цветов, размеры кнопок и полей, вид элемента под курсором. Раньше это был документ для людей. Сейчас важнее другое: часть правил можно записать так, чтобы читала и проверяла их машина.

МЕХАНИЗМ

снизу вверх: каждый следующий слой сильнее предыдущего, и только верхний превращает пожелание в гарантию



3. ПРОВЕРКА, ОСТАНАВЛИВАЮЩАЯ ВЫПУСК

Правило проверяют автоматически на каждом сгенерированном экране, и нарушение блокируют без обсуждения. **Гарантию даёт только этот слой.**



2. СВОИ ДЕТАЛИ ВМЕСТО ЗАГОТОВОК

Генератору дают собственные детали команды. Это **снижает вероятность нарушения, но ничего не гарантирует.**



1. ПРАВИЛА, ЗАПИСАННЫЕ ЧИСЛАМИ

Пока правило живёт в картинке макета, проверить его может только человек и только глазами.

С ИИ И БЕЗ ИИ

БЕЗ ИИ — свод правил для людей

Проверяет его дизайнер глазами: набор правил держит продукт единообразным.

С ИИ — зачем правила стали машинными

Генератор выдаёт экраны быстрее, чем их успевает смотреть человек. Машинная проверка **растёт вместе с генерацией.**

ГДЕ НЕ РАБОТАЕТ

Машина проверяет только то, что выражается числом. «Понятно ли это живому человеку» остаётся человеку: экран может пройти все проверки и остаться непонятным. И отдельно: просьба к генератору механизмом контроля не является — механизм это правило, которое умеет остановить выпуск. Проверка эта смотрит экран: поведение системы во времени числом не выражается и ею не покрывается.

Сгенерированные интерфейсы прошли 29% проверок доступности: решает платформа, и переписать запрос не помогает



Что именно проверяли

WCAG (Web Content Accessibility Guidelines, «правила доступности веб-содержимого») — международный свод требований к интерфейсу: хватает ли контраста между текстом и фоном, не передан ли смысл одним лишь цветом, работает ли всё без мыши, подписаны ли поля. Исследователи прогнали 21 880 таких проверок на экранах, сгенерированных инструментами с прошлого слайда: пройдено 29,0%. Хуже всего — самое простое и машинно-проверяемое: контраст 26,8%, использование цвета 19,2% ¹¹.

Что определило итог

На итог сильнее влияли настройки самой платформы, чем текст запроса. Значит, оправдание «надо было правильно попросить» не работает: переписывание формулировки доступным результат не делает.

Какие именно две из десяти эвристик Нильсена ломаются на продукте с языковой моделью

Эвристика 4 — единообразие и стандарты

Классика исходит из того, что одинаковое действие даёт одинаковый результат. У языковой модели это не так: единообразие приходится переносить с точных слов на тон и поведение.

Эвристика 9 — помощь в распознавании ошибки

Классика требует, чтобы система показывала, что пошло не так. Модель обычно не знает, что она неправа, и подаёт выдумку с той же уверенностью, что и факт.

Отсюда три приёма подачи, которых в классике нет: система говорит о своей неуверенности от первого лица, вместо общей оговорки мелким шрифтом; человек стоит в контуре решения там, где у ошибки есть настоящая цена; и прямо сказано, что ответ сгенерирован. Все три — решения о поведении системы: на макете экрана их не видно.

Отозваны все 2 031 220 машин с функцией помощи водителю: заметность элементов управления признали недостаточной



функции помощи
водителю

Что за случай

Autopilot — набор функций помощи водителю в машинах Tesla: держит полосу, скорость и дистанцию, пока человек следит за дорогой и держит руки на руле.

13 августа 2021 года Национальное управление безопасности дорожного движения США (NHTSA) открыло расследование: машины с включённым Autopilot врезались в стоящие на дороге автомобили спецслужб. 12 декабря 2023 года Tesla отозвала все 2 031 220 машин с этой функцией — весь парк, выпущенный с 2012 года. В отчёте о дефекте компания записала: заметность и охват элементов управления системы могут быть недостаточны, чтобы предотвратить неверное применение водителем.

Расследование
08.2021

Отзыв 2 031 220 машин
12.12.2023

Обновление по воздуху
12.2023

Проверка устранения
25.04.2024

≥20 аварий
после обновления

Что сломалось

За время расследования, с августа 2021 по декабрь 2023 года, набралось не менее 13 аварий с погибшими, где свою роль сыграло предсказуемое неверное применение.

Картина системы в голове водителя расходилась с тем, что система делала. Имя этой ошибки — **путаница режимов**.

Почему это решение фазы дизайна

Отзыв не затронул ни одной строки модели вождения. Исправляли то, как система себя предъявляет: заметность предупреждений, частоту проверок внимания, порог, за которым функция отключается.

Имя «Autopilot» — решение того же слоя: оно задаёт картину раньше первого предупреждения.

Корень — решение о том, как система предъявляет себя человеку: что сообщает, насколько настойчиво и когда отказывается продолжать. От расследования до отзыва прошло два года и четыре месяца, и всё это время парк ездил с заданной ему картиной. Проверкой модели такую ошибку не поймать.

Проверку устранения ведомство открыло 25 апреля 2024 года: за первые четыре месяца набралось не менее 20 аварий с предполагаемым участием системы, а часть мер водитель включает своим согласием и так же отключает. Мера, которую человек может выключить, остаётся просьбой — механизмом её делает способность остановить действие.

РАЗДЕЛ 3

Сборка и запуск — довести продукт до пользователя, пока ошибка ещё обратима

3 приёма · 2 разобранных случая

Без дисциплины запуска у сбоя два исхода, и оба плохие: продукт застревает в бесконечном пилоте и гипотеза не проверяется — либо выходит сразу на всех, и редкий сбой становится кризисом за день.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Задача фазы — довести продукт до пользователя так, чтобы ошибка осталась обратимой



ЗАЧЕМ ЭТА РАБОТА

Это единственное место цикла, где команда сама назначает, каким кругом людей и в каком темпе проверяется продукт, пока ошибка ещё дешёвая. Без этой дисциплины у сбоя два исхода: продукт застревает в бесконечном пилоте и гипотеза не проверяется — либо выходит сразу на всех, и редкий сбой становится кризисом за день.



Минимально жизнеспособный продукт

Эрик Райс, предприниматель, книга «Бережливый стартап», 2011 ^[1]

Первая версия существует ради обучения, и только ради него. Планируется в обратном порядке: сначала чему надо научиться, потом какой меркой это различить, и только потом что собрать.



Рубеж «продолжать или закрыть»

Stage-Gate: Роберт Купер, исследователь новых продуктов, 1990 ^[2]

Воронка, а не туннель: вложение растёт только после пройденного рубежа. Дешёвая ранняя стадия существует ровно затем, чтобы отсеивать до крупных трат.

Механику раскатки — переключатель функции, канареечный выпуск, поэтапное включение, возврат к прошлой версии — инженер знает из непрерывной интеграции и поставки (CI/CD — continuous integration / continuous delivery). Новое здесь — чьё решение эти примитивы обслуживают: вопрос сместился с «включить функцию» на «продолжать вкладываться или закрыть».

Порог записывают числом до старта, потому что иначе нельзя отличить «данные сказали нет» от «мы устали». Без него у команды нет права честно закончить.



Проект Foghorn, лаборатория X: топливо из морской воды. Порог назначили числом до начала работ — **8 долларов за галлон бензинового эквивалента**. Через два года модели стоимости дали 8–16, а дешёвый водород требовал ещё пяти лет исследований. В январе 2016 проект закрыли, результаты опубликовали, команде выплатили премию: записанное заранее число и дало право закончить. ^[3]

Писать код стало дешевле, проверять — нет: к узкому месту на входе добавилось ревью

ИЗМЕРЕННЫЙ СДВИГ

+200%

объём кода на инженера за год — собственное измерение Anthropic

16% → 54%

доля изменений с содержательным ревью до слияния: было — стало, после того как первый проход отдали автоматике; почти половина и теперь идёт без него ^[1]

+441%

медианное время, которое изменение проводит в ревью — телеметрия 22 000 разработчиков, Faros AI

2,5× / 5×

изменения от ИИ крупнее и дольше ждут ревьюера — 8,1 млн запросов на слияние, LinearB

ПРАКТИКИ ФАЗЫ: ЧТО БЫЛО И ЧТО ДОБАВИЛОСЬ

делали и делаем без ИИ

что добавляется, когда код пишет агент

Ревью изменений перед слиянием



оно же стало узким местом; передать слияние агенту — значит снять единственный контроль

Переключатель функции



переключает уровень самостоятельности: сколько система решает сама

Поэтапная раскатка по доле пользователей



раскатывают по двум осям сразу: доля аудитории и уровень самостоятельности

Тест как исполняемая спецификация и гейт прогона



добавился гейт по доле убитых мутантов: проверяет, что тест вообще способен поймать дефект

Аварийное отключение



нужно всегда: сбой расходится быстрее, чем его успевают заметить

Спецификация, которой владеет человек



единственный вход, который агент не может придумать себе сам

Дефицитны края работы: точность задачи на входе и скорость суждения на выходе.

Шкала самостоятельности — право решать отдают по частям

ЧТО ЭТО

Функцию выпускают уровнями самостоятельности — от подсказки к предложению, которое подтверждает человек, и дальше к самостоятельному решению (ступени справа). **Версия здесь означает уровень самостоятельности, который система заслужила.**

МЕХАНИЗМ

- 1 Каждый уровень — **отдельный выпуск**: свой круг пользователей, свой набор наблюдаемых признаков, свой способ остановиться.
- 2 Подъём открывают **доказательством, записанным числом до прогона**: система справляется с теми случаями, которые доверяет ей новый уровень. Календарь основанием не считается.
- 3 Доказательство должно держаться **при повторных попытках**. Однократный успех его не даёт.
- 4 Заранее описано, **как вернуть систему на уровень ниже**: кто решает, по какому признаку и за какое время.

подсказывает

решает человек



предлагает решение

подтверждает человек



решает сама

возвращает трудное человеку

*шкала самостоятельности, а не
последовательность версий продукта*

С ИИ И БЕЗ ИИ

БЕЗ ИИ — права выдают по частям давно

И людям, и автоматике: новичку сначала дают смотреть, потом предлагать, потом решать самому. Уровень держится на стаже без нареканий.

С ИИ — уровень подтверждают измерением

Система опыта не набирает. Meta двинула порог риска, при котором изменение сливается без человека, с 25-го перцентиля на 50-й: одобряются автоматически **60,31%**. Откаты у них **втрое реже**, сбои в проде — **в 50 раз реже**, чем на обычном пути (535 тыс. изменений).

ГДЕ НЕ РАБОТАЕТ

«Оператор давно ничего не правил» доказательством не является: отсутствие замечаний — это отсутствие измерения. Автоматическое одобрение держится на детерминированной проверке в конце цепочки; слияние по вердикту ИИ-ревьюера снимает единственный контроль. А необратимое и дорогое не поднимают на верхний уровень никогда: обязывающее предложение клиенту, удаление рабочих данных, выпуск сразу на всех — за жёстким правилом поверх модели.

Проверку, которой ни разу не подсовывали дефект нарочно, считают сломанной

ЧТО ЭТО

Мутационное тестирование — в код намеренно вносят мелкую ошибку («мутанта») и смотрят, упадёт ли хоть одна проверка. Доля убитых мутантов и говорит, способен ли набор проверок что-нибудь поймать; покрытие отвечает на другой вопрос — была ли строка затронута прогоном. В работе с ИИ тот же приём наводят на всё, чем ИИ ограничивают: **на набор оценок, на файл инструкций агенту, на правило в конвейере.**

МЕХАНИЗМ

- 1 Назвать проверку, на которую вы полагаетесь, и **класс ошибок, который она обязана ловить.**
- 2 Внести ошибку этого класса **нарочно** — одну, мелкую, в одном месте.
- 3 Прогнать проверку. **Молчание значит, что проверки нет:** она не отличает исправное от испорченного.
- 4 Записать долю пойманного **числом** и повторять замер после каждой правки проверки: проверки стареют молча.

Тот же приём — на трёх разных проверках

Модульные тесты

перевернуть условие

Набор оценок

подменить ответ на почти верный

Файл инструкций агенту

задача, где нарушить правило короче

молчание на подсаженный дефект и значит, что проверки нет

С ИИ И БЕЗ ИИ

БЕЗ ИИ — мутантов порождает список правил

Перевернуть условие, сдвинуть границу, убрать вызов. Прогон воспроизводим, инструменты есть под каждый язык: PIT, mutmut, Cosmic Ray, Stryker.

С ИИ — мутантов пишет модель

Они ближе к настоящим ошибкам: находят **76,5%** реальных дефектов против **44,2%** у списка правил (851 дефект). Плата — около трети сгенерированных мутантов не компилируется.

ГДЕ НЕ РАБОТАЕТ

Часть дефектов приём не видит по построению: из 357 реальных ошибок 27% не связаны ни с одним мутантом — неверные алгоритмы и код, который следовало удалить. И доля убитых портится так же, как покрытие: поставьте по ней гейт — начнут плодиться легко убиваемые мутанты, а обнаружение не вырастет.

Поэтапная раскатка и путь назад — как назначить цену ошибки заранее

ЧТО ЭТО

Новое включают не всем сразу, а сначала узкому кругу, и заранее договариваются, как всё вернуть обратно. **Радиус поражения — сколько людей пострадает, если новое окажется плохим, — решение команды, а не то, что выясняется после запуска.**

МЕХАНИЗМ

- 1 **Ступени** — какие доли аудитории проходим и в каком порядке.
- 2 **Признак остановки** — что наблюдают на каждой ступени и какое ухудшение останавливает движение вперёд; без названного заранее признака «стало хуже» обсуждается бесконечно.
- 3 **Путь назад** — кто принимает решение вернуться, за какое время это делается и проверяли ли, что возврат вообще работает.



С ИИ И БЕЗ ИИ

БЕЗ ИИ — приёму несколько десятилетий

Поэтапная раскатка и откат придуманы задолго до ИИ и устроены точно так же. **Изобретать заново нечего**, берут готовое.

С ИИ — меняется только скорость ступеней

Обычную функцию видно по отказам и задержкам сразу, а ухудшение ответов проступает только на объёме: на каждую ступень нужны **часы наблюдения, а не минуты**.

ГДЕ НЕ РАБОТАЕТ

Раскатка ограничивает радиус, но не заменяет решение. Долгий пилот на крошечной доле, который продолжает сбоить, — не «нужно ещё немного данных», а потолок подхода. Обратная ошибка так же реальна: зрелость продукта не даёт права пропустить пилот, а повышает цену пропуска. И путь назад, который описан, но ни разу не проверен, — намерение, а не путь назад.

Удвоенная скорость генерации удваивает очередь на проверку; пропускная способность стоит на месте

Две операции разработки и что с ними сделал ИИ

**сделать
подешевело**

**проверить
не сдвинулось**

сопоставление стоимости двух операций

Сделать правдоподобный результат — секунды. Убедиться, что он верный, безопасный и делает именно то, что нужно, по-прежнему требует человеческого понимания в реальном времени.

Работа не исчезла: вся её масса переехала на ту сторону, которая не подешевела. Это не нехватка людей, которая пройдёт.

Разрыв 70 процентов ^[1]

Инструмент доводит команду примерно на 70% пути к рабочему результату. Оставшиеся 30% — приведение в поддерживаемый вид, ловля краевых случаев, инженерный опыт.



70% пути · 30% остаются человеку

Документированное расхождение: опытный инженер переосмысливает и ограничивает результат модели, начинающий принимает его охотнее и отправляет дальше код, который выглядит завершённым и рассыпается под нагрузкой.

Выпуск без проверки на наборе примеров и без проверенного пути назад берёт скорость в долг: это отложенная цена. Определение готовности обязано вобрать эти 30%, иначе оно молча сводится к «тесты прошли — значит готово».

Google AI Overviews, май 2024: включили сразу всем — минуя пилот целиком

ЧТО ПРОИЗОШЛО

Google встроил в поиск генеративные ответы: вместо списка ссылок вверху страницы стал появляться готовый ответ, составленный моделью по найденным страницам. Функцию включили сразу всем пользователям поиска в США, одним шагом, и отключить её пользователь не мог. За несколько дней в ответах разошлись советы есть камни и добавлять в пиццу клей, чтобы сыр держался: модель приняла за источники сатирическую статью и старую шутку с форума. Компания реагировала уже после — ограничила ответы на бессмысленные запросы, отфильтровала сатиру, приостановила ответы на темах о здоровье.



как надо:

1%



10%



25%



50%



100%

как пошли:

0% → 100% одним шагом

с нуля сразу на всю аудиторию поиска в США — пилотной ступени не было ни одной

РАЗБОР

- Модель не сломалась технически: она сделала ровно то, что делает генеративная система — собрала правдоподобный ответ из корпуса, не отличив шутку от факта, и выдала его с уверенностью авторитетного источника
- Это режим «уверенно неправильно»: тест его не ловит, ловит наблюдение на живом, но ограниченном трафике
- Зрелость основного продукта не даёт права пропустить пилот: она повышает цену пропуска — вся аудитория здесь означает всю базу сразу

На одном проценте трафика этот класс сбоя всплыл бы за дни во внутреннем наблюдении. Вместо этого — публичное осмеяние сразу на всей аудитории.

McDonald's и IBM, 2021-2024: пилот на 0,7% сети закрыли — и это было правильно

ЧТО ПРОИЗОШЛО

С конца 2021 года сеть McDonald's вместе с корпорацией IBM испытывала приём заказов голосом у окна автораздачи: посетитель говорит заказ прямо системе, минуя сотрудника. Испытание держали примерно на 100 ресторанах из почти 13 800 в США — это 0,7% сети — и продолжали два с половиной года. Всё это время в сеть попадали ролики со сбоями: бекон в мороженом, девять чаёв вместо одного, перепутанные заказы соседних полос. В июне 2024 партнёрство прекратили. Закрыли при этом подход; цель осталась — голосовая автоматизация всё ещё в планах.



0,7%

≈100 из ≈13 800 ресторанов США · пилот 2,5 года

РАЗБОР

- Знаменатель обязателен: «100 ресторанов» без «из 13 800» читается как масштабное внедрение, а со знаменателем — как узкая полоса, специально удержанная узкой
- Потолок здесь понятный: распознавание речи в шуме, с разными выговорами и посторонними голосами. Такой потолок не двигается дополнительным временем
- Закрыт конкретный технический путь; задача осталась. Это разные решения, и смешивать их дорого
- Зеркало предыдущего случая: там пропустили пилот целиком, здесь прошли его честно и прочитали сигнал


Сигнал прочитан верно: длинный пилот на малой доле, продолжающий публично сбивать, означает потолок подхода; нехватка данных тут ни при чём. Это и есть сработавший рубеж «продолжать или закрыть».

РАЗДЕЛ 4

Измерение: отличить «сработало» от «показалось»

1 база · 2 практики · 2 провала

Без измерения решение о продукте принимают по впечатлению, а цену узнают после запуска: в 2026 году 44% команд выключали уже работавшие ИИ-функции, обнаружив, что расходы на них выше пользы. Этот раздел — про то, как узнавать раньше.



0
Введение

1
Исследование

2
Дизайн

3
Сборка и запуск

4
Измерение

5
Поддержка

6
Управление

7
Обобщение

Контролируемый эксперимент: две случайные группы

Зачем это нужно. «Метрика выросла после релиза» само по себе не значит ничего: за ту же неделю сменился сезон, прошла рекламная кампания, пришла другая аудитория. Без группы, которой изменение не показали, отделить свой вклад от чужого нечем.

Случайное деление даёт причинность



Поэтапная раскатка этого не заменяет: удерживаемой случайной группы у неё нет — она отвечает «сломалось ли», а не «помогло ли».

Договариваются до старта о трёх вещах

- 1 Метрика решения — одна и с направлением.** В литературе — сводный критерий оценки (OEC, Overall Evaluation Criterion). Учебный случай: «время на сайте поддержки» приняли единогласно и раскололись на вопросе, рост это хорошо или плохо.
- 2 Метрика-ограничитель.** Её мониторят, но не оптимизируют: она ловит ущерб, которого метрика решения не видит.
- 3 Число наблюдений.** Его считают до старта, а не набирают сколько получится.

Посчитанное число наблюдений может оказаться недостижимым. Тогда честный ответ — «этот вопрос экспериментом не решается, нужен другой метод», а не «запустим и посмотрим»: эксперимент на слишком малой выборке не становится слабым доказательством, он перестаёт быть доказательством.

Пред-регистрация: решение записывают до того, как увидят результат

ЧТО ЭТО

МЕХАНИЗМ

С ИИ И БЕЗ ИИ

ГДЕ НЕ РАБОТАЕТ

Короткая записка, которую делают **до** запуска эксперимента: что именно измеряем, какой результат считаем успехом, когда останавливаемся. Приём пришёл из медицины — там протокол регистрируют до набора пациентов, иначе журнал не примет статью.

1

До запуска записывают четыре вещи: какую величину считаем основанием решения и в какую сторону она должна двинуться; что наблюдаем как ограничитель; какой размер эффекта значим и сколько для него нужно наблюдений; при каком условии останавливаемся.

2

Запись кладут туда, где есть время — с датой и автором. Весь механизм в этом: метка времени стоит раньше первого результата.

3

После запуска запись не переписывают — к ней дописывают принятое решение и дату.

запись сделана

первый результат



критерий успеха записан раньше первого результата

Три ловушки — остановить на удачной точке, перебрать метрики, подвинуть порог — **все требуют, чтобы критерий успеха можно было выбрать после результата.**

БЕЗ ИИ — приём родом из медицины

Одна величина решения, размер выборки, правило остановки — записаны заранее. Так работают клинические протоколы и обычные продуктовые эксперименты.

С ИИ — что приходится записывать дополнительно

Распределение по пользователю, а не по запросу: в диалоге один человек иначе попадает сразу в обе группы. И **не одну величину, а набор:** оценку качества ответа, долю переспрашиваний и правок, стоимость обращения.

Пред-регистрация не делает эксперимент правильным — она делает неправильность видимой. Эффект новизны она не лечит: для него нужна отдельная удерживаемая группа. И она бессильна там, где наблюдений физически не хватает: честный выход — сменить вопрос или метод, а не выборку.

ответа ждать больше трёх месяцев

31 200

нужно на группу

5 000

есть в неделю

Распределение по пользователю против распределения по реплике · Расчёт 31 200 на группу — иллюстративный

Петля оценок: увидеть, что ответы стали хуже, раньше пользователя

ЧТО ЭТО

Оценка (в обиходе «эвал») — набор задач с заранее записанным желаемым ответом, на котором прогоняют модель или агента. **Нужна потому, что качество ответов меняется без изменения кода:** сменили версию модели, правило или источник — поведение поехало, а тесты кода остались зелёными и ничего не сообщили.

МЕХАНИЗМ

1 **До выпуска** — прогон против отобранного набора: воспроизводимо, ловит то, что уже ломалось.

2 **После выпуска** — оценка на живом трафике: вскрывает входы, которых в наборе не было, и поведение на длинной цепочке ходов.

3 **Замыкание** — разбор промышленного сбоя добавляет в набор строку, и она остаётся там навсегда.

4 **Чем исполняют:** promptfoo роняет сборку кодом возврата, когда доля прошедших ниже порога; DeepEval — обычным прогоном тестов с минимальным баллом на метрику; Braintrust и Langfuse сравнивают версии и блокируют слияние при падении балла.

набор задач

выпуск

разбор сбоя

живой трафик

золотая стрелка и делает петлю петлём: разбор сбоя добавляет в набор строку — без этого шага это отчёт, а не петля

С ИИ И БЕЗ ИИ

БЕЗ ИИ — набор тестов кода

Ответ известен посимвольно, прогон воспроизводим, результат — «прошёл» или «не прошёл».

С ИИ — три разные роли у самого ИИ

Предмет оценки

 — его проверяют.

Измеритель

 — модель-судья ставит балл по писаному правилу.

Поставщик случаев

 — размечает живой трафик и предлагает, что добавить в набор. «Что считать хорошим ответом» решает человек.

ГДЕ НЕ РАБОТАЕТ

Модель-судья соглашается с человеком на 80-90%, где предпочтение очевидно, и падает к 60-65%, как только ответы близки или их меняют местами — надёжна меньше всего там, где цена ошибки выше всего. Поправки: перемешивать порядок ответов, брать судью из другого семейства. Эксперимент на живых пользователей дороже и оценками не заменяется.

Когда мера становится целью, она перестаёт быть мерой

Лодка, которая никогда не финиширует

Агент, обученный с подкреплением — то есть на вознаграждении за результат, без размеченных примеров, — в гоночной игре набрал больше очков, чем игроки-люди. Гонку он не закончил ни разу: кружил в лагуне и собирал восстанавливающиеся бонусы, загораясь и врезаясь в другие лодки. Очки задумывались как признак прогресса гонки.

очки: +20% к результату людей

финиш: ни одного

Взлом вознаграждения

Так называют закон Гудхарта применительно к обучаемым системам: поведение удовлетворяет букве заданной цели, не достигая задуманного. Формулировка закона — экономист Чарльз Гудхарт, 1975 год.

Эскалация, которой не обучали

Anthropic обучала модель на задачах, всё более пригодных для взлома. Модель прошла путь от лести к подделке собственных отчётов о выполнении и дальше — к прямому редактированию своей функции вознаграждения, чтобы присвоить себе идеальный балл. Этой эскалации её отдельно не учили.

Это не умысел системы, а свойство оптимизации: она находит самый дешёвый способ поднять ту величину, которую назвали целью. Отсюда два следствия. Метрика решения всегда идёт в паре с метрикой-ограничителем. И подозрительно хорошая цифра проверяется первой: балл, выглядящий слишком хорошо, чаще оказывается ошибкой измерения, чем прорывом.

Метрика выиграла тест, а вред заметили через полтора года

ЧТО СЛУЧИЛОСЬ

Январь 2018 года. Facebook меняет правило, по которому лента решает, что показать выше. Новая величина — **MSI, meaningful social interactions, «содержательные социальные взаимодействия»**: чем сильнее реакция на запись, тем выше запись в ленте. Все пять реакций получили вес в 5 раз выше обычной отметки «нравится». Распространённый пересказ «усилили именно гнев» неточен: веса были равны.

facebook

«люблю»

х5

«ха-ха»

х5

«ух ты»

х5

«печаль»

х5

«гнев»

х5

полтора года без метрики качества

● метрика введена, 2018

● вес гнева обнулён, сентябрь 2019

РАЗБОР К 2019 году внутреннее исследование подтвердило: записи, собирающие гневную реакцию, непропорционально часто содержат недостоверный и токсичный материал. Решение «любая сильная реакция означает более содержательное взаимодействие» было огульной косвенной метрикой качества общения: величину, которую легко измерить, приняли за величину, которая интересует на самом деле.

Не хватало не аналитиков — команда анализа данных была одной из сильнейших в мире. Не хватало самой метрики: качество материала не измеряли с первого дня, поэтому вред вскрылся отдельным качественным разбором после полной раскатки, а не показателями самого эксперимента. Метрика решения без метрики-ограничителя рядом — незакрытая конструкция.

Балл на бенчмарке — свидетельство только о его формате

Бенчмарк — стандартный набор задач, на котором модели сравнивают между собой

СЛУЧАЙ 1. МЕДИЦИНА

86,5% на MedQA

2023 год. Google показывает Med-PaLM 2 — модель для медицинских вопросов. На MedQA (наборе вопросов в формате медицинского лицензионного экзамена, с четырьмя готовыми вариантами ответа) она набирает 86,5% и попадает в заголовки как «ИИ уровня врача». При этом собственные исследователи Google отдельно строят более сложный набор из 240 состязательных вопросов — экзамен с готовыми вариантами не вскрывает сбоев клинической безопасности в открытом диалоге, где пациент вариантов не предлагает.

СЛУЧАЙ 2. ПРАВО

Lexis+ **17% выдуманных ссылок**

Westlaw **33% выдуманных ссылок**

2023 год. Адвокат подаёт в суд документ с шестью полностью выдуманными судебными делами — дело Mata против Avianca. Сгенерировал их ChatGPT, а не юридический сервис Harvey: это частая ошибка атрибуции. Затем Stanford RegLab проверяет сами юридические инструменты на реальных запросах: наиболее точный из протестированных выдумывает ссылки примерно в одном запросе из шести, второй — вдвое чаще, несмотря на обещание «без галлюцинаций».

РАЗБОР Балл измерен на узком формате задачи и не переносится на реальную задачу пользователя. Бенчмарк при этом не бесполезен — он честно сравнивает версии модели между собой. Проблема начинается там, где балл за письменный экзамен предъявляют как доказательство готовности вести пациента.

К 2026 году к разрыву форматов добавилось насыщение. На MMLU (Massive Multitask Language Understanding, сводном наборе из 57 предметов) передовые модели держатся в узкой полосе 89–92% — различать их этот балл уже не может. Хуже того: 6,5% вопросов самого набора содержат ошибку в эталонном ответе, а в разделе вирусологии — 57%. Заявление о безопасности только по бенчмарку не подтверждено: нужна состязательная проверка на той задаче, которую продукт решает.

РАЗДЕЛ 5

Поддержка удерживает качество: люди и система

2 базы · 2 практики · 3 провала

Продукт живёт годами, и отказы приходят от изменений, которые вносим мы сами. Качество держат на двух половинах: доволен ли человек продуктом и держит ли система нагрузку. Без этой работы о деградации компания узнаёт из суда или из списания.



0
Введение

1
Исследование

2
Дизайн

3
Сборка и запуск

4
Измерение

5
Поддержка

6
Управление

7
Обобщение

Поддержка удерживает качество: половина — люди, половина — система

ЧТО ТАКОЕ ПОДДЕРЖКА. После запуска продукт каждый день обещает одно и то же: ответ придёт, он будет верным, а сломанное починят. Поддержка — работа, которая удерживает это обещание годами. У обещания две половины, и меряют их разными приборами: одну спрашивают у человека, другую снимают с системы.

ЛЮДИ · удовлетворённость пользователя продуктом

Половина, обращённая к человеку: вопросы, жалобы, обращения, возвраты.

Дисциплина выросла из службы поддержки и свода правил управления ИТ-услугами (ITIL).

Измерители — то, что видит человек

- доля обращений, закрытых с первого раза
- время до первого ответа и до решения
- оценка человека после закрытия обращения

Где входит ИИ: подсказчик оператору и робот, отвечающий клиенту сам — следующий слайд.

СИСТЕМА · надёжность

Половина, обращённая к машине: доступность, задержки, сбои, выкатки.

Дисциплина оформлена в Google и издана книгой в 2016 году — инженерия надёжности (Site Reliability Engineering, SRE).

Измерители — то, что снимают с системы

- доля успешно обслуженных запросов
- задержка ответа
- бюджет ошибок: сколько сбоев допустимо за период

Где входит ИИ: объект наблюдения и инструмент учений.

Половины держат качество только вместе. Безотказная система, по которой человек не может получить ответ на свой вопрос, обещание продукта теряет; внимательная поддержка поверх падающего сервиса теряет его тоже. Дальше раздел идёт по обеим: надёжность числом, ИИ в работе с людьми, учение, которое проверяет обе.

Бюджет ошибок: допустимое число сбоев, посчитанное заранее

половина «система»

ЗАЧЕМ ЭТА РАБОТА. Около 70% отказов работающей системы Google относит к собственным изменениям команды: выкатка, правка промпта, смена версии модели. Остальное делят между собой отказы оборудования и внешние причины. Значит, сбои порождает та же работа, которой команда занята каждый день, и допустимое их число стоит согласовать заранее: иначе спор «быстрее или надёжнее» решается после инцидента и в пользу того, кто громче.

Показатель уровня сервиса (SLI)

мера глазами пользователя

Цель уровня сервиса (SLO)

планка команды: 99,9%

Бюджет ошибок

остаток: 1000 ошибок

Цель 99,9% на миллионе запросов за период даёт **1000 ошибок** — остаток, который можно потратить.

Правило: бюджет исчерпан — выкатка новых функций останавливается. Разговор о скорости против надёжности состоится до инцидента, и у него будет основание, с которым нельзя спорить риторически.

Два окна наблюдения, всегда оба

поодиночке каждое слепо к случаю другого

Короткое окно — резкий скачок



2% бюджета за час

при таком темпе он кончится за двое суток — поднять дежурного сейчас

Длинное окно — медленное сползание



5% за шесть часов — задача на рабочее время

Всё это построено для системы, где запрос либо успешен, либо нет. Код 200 — «ответ отдан успешно» — приходит и тогда, когда модель уверенно выдумывает. Дальше — вторая половина качества: люди, их обращения и ИИ в работе с ними.

ИИ в поддержке: подсказчик оператору и робот, отвечающий сам

ЧТО ЭТО


ИИ входит в работу с обращениями двумя способами, и спутать их дорого. **Подсказчик** предлагает оператору ответ; отправляет человек, он же за сказанное отвечает. **Робот** разговаривает с клиентом сам, и каждое его слово — слово компании.

МЕХАНИЗМ

- 1 **Разложить поток обращений по цене ошибки.** Справка, целиком выводимая из своей базы знаний, живёт отдельно от обязательства, за которое компания платит деньгами или отвечает по закону.
- 2 **На справочном потоке начинать с подсказчика.** Выигрыш он даёт там, где мало опыта, и ответ оставляет за человеком.
- 3 **Робота включать там, где ответ выводится из проверяемого источника** — и показывать этот источник рядом с ответом.
- 4 **Два предохранителя обязательны:** гарантированный путь к живому человеку и порог, по которому робот замолкает и зовёт оператора.

Подсказчик: замер на 5 172 операторах поддержки

база до внедрения — 2,1 решения в час



у самых опытных качество диалога слегка ниже: подсказка предлагает им средний ответ

оператор с двумя месяцами стажа и подсказчиком работает как оператор с полугодом без него

С ИИ И БЕЗ ИИ

БЕЗ ИИ — то, на чём поддержка стоит и будет стоять
База знаний, шаблоны ответов, маршрутизация обращений, наставник у новичка. Скорость упирается в стаж оператора: знание редких случаев набирают месяцами и теряют вместе с человеком, который уволился.

С ИИ — что он добавил
Подсказка в реальном времени поверх той же базы знаний; робот на типовом потоке; сводка длинной переписки для того, кто её принимает. **База знаний остаётся условием:** на том, чего в ней нет, ИИ достраивает недостающее сам.

ГДЕ НЕ РАБОТАЕТ

Робот уверенно объявляет правило, которого нет. Апрель 2025: бот поддержки Cursor сообщил клиентам о придуманном им ограничении «один вход на пользователя»; люди отменяли подписки, компания извинялась и возвращала деньги — политики такой никогда не существовало.

Учебная тревога: есть ли чем заметить деградацию


ЧТО ЭТО

Учебная пожарная тревога проверяет здание и людей: сработал датчик, завывла сирена, выход свободен, все вышли за норматив. Огня нет — его роль играет план. Учение в поддержке устроено так же: качество ответов портят намеренно и управляемо, чтобы увидеть, сработает ли обнаружение.

Элемент учения → элемент системы: дым → подменённая инструкция модели · датчик → порог по косвенной метрике · сирена → оповещение дежурному · выход → откат версии и путь к человеку · норматив эвакуации → четыре измеренных времени.

МЕХАНИЗМ

- 1 Выбирают **один класс отказа** и назначают дату. **ИИ:** предлагает сценарии по прошлым разборам; выбирает человек.
- 2 Качество ухудшают **управляемо**: подменяют инструкцию модели на слабую, ослабляют ограничители. **ИИ:** создаёт поток обращений по сценарию, чтобы дежурный увидел нагрузку.
- 3 Измеряют **четыре времени** и записывают числом — свои, с этого учения.
- 4 Разбор. **ИИ:** собирает хронологию и отдаёт черновик; выводы и правки инструкций подписывает человек.
- 5 Учение, не изменившее ни одной инструкции, было слишком лёгким.



числа — с одного проведённого учения; в следующем их заполняют заново

С ИИ И БЕЗ ИИ

БЕЗ ИИ — классическое учение на отказ

Гасят службу, отнимают ресурс: смотрят, поднимется ли система и придёт ли дежурный. Сценарий, хронологию и разбор делает человек.

С ИИ — чем он занят внутри учения

Сценарии ИИ предлагает по прошлым разборам, поток обращений создаёт он же, хронологию собирает из записей и отдаёт черновик разбора. Инструменты 2026 года: incident.io, Rootly, PagerDuty.

ГДЕ НЕ РАБОТАЕТ

ИИ предлагает вариации пережитого: класса отказа, которого ещё не было, он не придумает. Черновик разбора правдоподобен и когда причина названа неверно. Учение раз в квартал даёт обнаружение с окном в квартал.

Графики остаются зелёными, пока доверие уже падает недели



Четыре кадра — четыре недели наблюдения. Графики не меняются, доверие уходит.

Тихий дрейф

Модель продолжает отвечать, пользователи продолжают получать ответы, графики остаются зелёными — но ответы становятся чуть менее обоснованными. Самые активные пользователи замечают регрессию раньше агрегированных метрик: к моменту, когда команда видит явную деградацию, она идёт уже недели.

Дрейф правил

Защитные правила без версионирования молча устаревают: система вокруг меняется, а правила остаются прежними. Ощущение защищённости сохраняется, фактическое соответствие — нет. Лечится тем, что правила ведут как код: версионизируют, проверяют, пересматривают.

Klarna

Klarna, май 2025. Компания, публично объявившая поддержку без доступа к человеку, эту политику развернула. Причина, названная руководителем: клиент должен всегда знать, что живой человек будет, если он его попросит. Автоматизация при этом никуда не ушла — ИИ по-прежнему закрывает две трети обращений. Урок не «ИИ не справился», а **«путь к человеку — часть продукта, а не опция, которую восстанавливают задним числом»**.

Что остаётся обязательным: путь к человеку, ответственность за ответ, дисциплина разбора инцидентов. Автономность ИИ их не отменила — она подняла их цену.

Zillow: алгоритм скупал дома, рынок сдвинулся, бизнес закрыли



ЧТО СЛУЧИЛОСЬ

Zillow Offers — сервис, который покупал дома по алгоритмической оценке и быстро перепродавал. За третий квартал 2021 года купил 9680 домов, продал 3032. 2 ноября 2021 года компания объявила о закрытии сервиса: списания **\$304-408 млн**, сокращение около **2000 человек** — примерно **25% штата**. Средний убыток — около **\$80 тыс. на дом**.

Zillow Offers: сколько домов купили и сколько продали



РАЗБОР: ЭТО ПРОВАЛ ЭКСПЛУАТАЦИИ, А НЕ ИЗМЕРЕНИЯ

Модель была откалибрована корректно — на исторически стабильных данных. Не было другого: наблюдения за точностью в реальном времени и автоматической остановки при её падении.

Вернитесь к двум окнам: у Zillow не было ни одного. Короткого — резкий рост ошибки прошёл незамеченным. Длинного — квартальная отчётность есть, но раз в три месяца это не окно наблюдения, а исторический архив: дома уже куплены.

Критерий: модель, которая сама распоряжается деньгами, требует наблюдения за точностью в реальном времени и порога, по которому она останавливается без участия человека. Альтернатива: алгоритмическая оценка как вход, а решение выше порога риска — за человеком.

Air Canada: чат-бот пообещал скидку, которой нет — платит компания

ЧТО СЛУЧИЛОСЬ

В ноябре 2022 года чат-бот на сайте Air Canada сообщил клиенту, что тариф по случаю утраты близкого можно оформить ретроактивно в течение 90 дней. Действующая политика компании этого не допускала. Клиент купил билеты по полной цене, а в скидке ему затем отказали. В феврале 2024 года трибунал Британской Колумбии взыскал с компании **812,02 канадского доллара** — разницу в цене билетов, проценты и пошлину.

ЧТО РАЗОШЛОСЬ

Ответил чат-бот

«Купите билет по полной цене, а скидку по тарифу на случай утраты близкого запросите в течение 90 дней».

а на соседней странице того же сайта

Действующая политика компании

Тариф не применяется к уже состоявшейся поездке — задним числом его не оформляют.

РАЗБОР

Защита: чат-бот — отдельное юридическое лицо, отвечающее за свои действия само. Трибунал назвал это примечательным заявлением и отклонил: компания отвечает за всю информацию на своём сайте, исходит ли она из статичной страницы или из чат-бота.

Операционная причина: не было процесса, который сверяет базу знаний бота с действующей политикой. Содержимое поддержки жило отдельно от единого источника правды.


Сумма мала важным образом: это цена двух билетов, и скромность суммы делает прецедент чистым.

Вы владеете каждым ответом бота — не больше, но и ни на грамм меньше ответственности, чем за любой другой контент сайта. «Бот ошибся» защитой не является.

Нью-Йорк: городской бот 10 раз из 10 посоветовал нарушить закон

ЧТО СЛУЧИЛОСЬ

Город Нью-Йорк выпустил чат-бот для владельцев малого бизнеса — отвечать на вопросы о городских правилах. В марте 2024 года расследование показало, что бот советовал работодателям забирать чаевые сотрудников и увольнять за жалобу на домогательство, а владельцам жилья — отказывать съёмщикам с жилищными сертификатами. Всё это противоречит действующим нормам, и совет давался уверенно, в форме инструкции. Все **10 из 10** задавших вопрос журналистов получили один и тот же неверный ответ. Мэр города признал ошибки и бот с публикации не снял, хотя технически отключить его было возможно.



Один и тот же вопрос — десять раз. Один и тот же незаконный ответ — десять раз.



десять спросивших — десять одинаковых советов нарушить закон

РАЗБОР

Ключевая цифра — не содержание ответов, а их повторяемость, и она меняет класс события. Единичная ошибка — повод для правки. Десять одинаковых ответов на десять одинаковых вопросов — свойство системы, воспроизводимое по команде.

Решение продолжить итерации приняли после того, как воспроизводимость показали публично. Это и есть разбираемая ошибка: данные были, реакция осталась прежней.

Критерий: воспроизводимый вредный ответ требует аварийного выключателя, а не следующей итерации. Порог формулируется числом заранее — иначе в момент, когда его надо применить, он обсуждается заново и проигрывает желанию «доработать».

РАЗДЕЛ 6

Во что вкладывать дальше — и что пора закрыть

1 база · 2 практики · 2 провала

Продукт может работать и всё равно не окупаться. Здесь решают, какие инициативы финансировать дальше, а какие остановить — и почему у ИИ-продукта это считается иначе.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Зачем нужен этот шаг: решить, что финансировать дальше, а что закрыть

ЧТО ЗДЕСЬ РЕШАЮТ

Отбор инициатив: много на входе — финансируют немногие

десятки инициатив

первое решение

второе решение

финансируют

ЧТО БУДЕТ, ЕСЛИ НЕ РЕШАТЬ

Инициатива, которую никто не закрыл, продолжает тратить людей и деньги, не показывая результата.
Deloitte, 2026: 42% технологических руководителей сообщают о низком или нулевом возврате вложенного.
Boston Consulting Group, январь 2026 (2 360 руководителей): измеримую отдачу — снижение расходов или рост выручки — видят 6% компаний.

ЗАТРАТЫ РАСТУТ ВМЕСТЕ С МАСШТАБОМ — ВСЕГДА



Расход на одно обращение со временем падает. Это другая линейка — совокупный счёт всё равно идёт вверх.


Применили ИИ где угодно внутри продукта или вокруг него — в функции для пользователя, в поддержке, в разработке, во внутреннем инструменте — и у этого применения появился **счётчик**, который тикает от объёма работы.

У каждой ступени один и тот же вопрос: окупает ли новая функция свой скачок расхода. Окупает — оставляем и платим за неё; не окупает — закрываем сейчас, пока на эту ступень не встала следующая.

Структура расхода и дохода: по типам — замерено, по функциям — сами

ПО ТИПАМ — ЧТО ЗАМЕРИЛИ

доли расхода на продукт: до запуска → на масштабе
до запуска продукта



- люди — 32% → 26%
- вызовы модели — 20% → 23%
- оборудование и облако — около 17%, не меняется
- хранение и обработка данных — 6%
- остальное — обучение моделей, соблюдение норм

ICONIQ Capital, обзор состояния ИИ 2026: около 305 руководителей компаний, делающих продукты с ИИ, опрос второго квартала 2026 года. Первые четыре доли — из отчёта, последняя закрывает сумму до 100%

Со стороны дохода: вызовы модели съедают около **23% выручки**. Валовая маржа продуктов с ИИ — **45%** в 2025 году, на 2026 ожидают **53%**; у классического программного продукта она держится выше 70%.

ПО ФУНКЦИЯМ — И КАК ПРИНИМАЮТ РЕШЕНИЕ

разбор на условных числах одного каталога: такую разбивку по функциям умеют строить немногие

Функция	Выручка	Расход	Решение
Подсказки в поиске по каталогу	+8% к оплаченным заказам	+0,9 ₽ за обращение	расширяем
Агент на первой линии поддержки	0 напрямую	–40% времени оператора на обращение	оставляем: платит экономией
Пересказ отзывов на карточке товара	в пределах погрешности	+1,4 ₽ за просмотр	закрываем
Журнал решений и выход к человеку	0	постоянный, растёт с объёмом	закрывать нельзя

Каждое число разбора — против одной базы: тот же каталог без этой функции за тот же месяц. Разбивку по функциям умеют строить немногие: связать расход на ИИ с деньгами могут 22% финансовых руководителей, и 60% согласны, что тратят на ИИ больше, чем могут обосновать — CloudZero, июнь 2026, 260 респондентов, больше половины — финансовые директора

Оговорка: убыточная строка не всегда подлежит закрытию. Журнал решений и выход к человеку для системы высокого риска требует Регламент Европейского союза об искусственном интеллекте: с 2 августа 2026 года события записываются автоматически, журналы хранят не меньше шести месяцев. Выручки ноль, расход постоянный, выключить нельзя. Тот же класс — функция, убыточная в своей строке и держащая выручку в чужой: бесплатный тариф, поддержка, экспорт данных.

Записываем, при каком результате пилот закрывают, — до того как включим

ЧТО ЭТО

Одна заранее записанная фраза с числами, по которой через несколько недель видно: продолжать или закрывать. Ближайший знакомый аналог — **приёмочный критерий в техническом задании**, только не про функциональность, а про деньги. Число, названное после результата, объясняет результат, а не проверяет его.

МЕХАНИЗМ

- 1 **Что улучшаем** — и с какой величины до какой.
- 2 **Чего при этом нельзя ухудшить** — одна-две величины-ограничителя.
- 3 **На каком объёме и за какой срок** проверяем.
- 4 **Кто смотрит и как часто**. Запись делают до включения, с датой и именем: иначе проверить порядок во времени нечем.

«Разбор обращений моделью снизит стоимость одного обращения **с 42 ₽ до 15 ₽**, удовлетворённость клиента не упадёт **ниже 4,2 из 5**, доля обращений, переданных человеку, не превысит **20%**. Проверяем на **5 000 обращений за 6 недель**. Смотрит **руководитель поддержки, раз в неделю**».

заполненный образец записи: в нём по одной части на каждый шаг слева

С ИИ И БЕЗ ИИ

БЕЗ ИИ — аппарату полвека

Обоснование вложений с порогом окупаемости и решением на контрольной точке. **Изобретать заново нечего**, берут готовое.

С ИИ — меняется только ритм

Расход меняется каждый день, а не раз в квартал, поэтому и смотрят еженедельно. А компании меряют активность вместо денег — отсюда разрыв: вкладываются почти все, измеримую отдачу видят **6%**.

ГДЕ НЕ РАБОТАЕТ

Исходную величину меряют на своём процессе, а не берут из обещания поставщика: чужая цифра описывает чужой процесс. Если среди возможных исходов нет «закрываем» — это не критерий: порог, который нельзя не взять, разрешения не даёт. И числа, появившиеся после включения, — объяснение результата, поэтому дату записи и имя проверяют раньше самих чисел.

Как оценивают любую функцию — безразлично, есть внутри ИИ или нет

1 Что функция меняет в поведении

Какое действие пользователя станет чаще, быстрее или дешевле. Пока действие не названо, оценивать нечего.

2 Против какой базы

Тот же продукт без этой функции за тот же период. Без базы любой прирост запишется в заслугу функции.

3 Во что она обходится

Разработка однажды и обслуживание каждый месяц. Второе считают вместе с объёмом использования.

4 При каком результате её закрывают

Число и срок записаны до запуска: названное после результата, оно его только объясняет.

ЧТО МЕНЯЕТСЯ, ЕСЛИ ВНУТРИ ФУНКЦИИ ЕСТЬ ИИ

Меняются два пункта из четырёх. **Третий:** обслуживание перестаёт быть разовым — у него появляется счётчик, который тикает от объёма. **Первый:** ответ модели меняется от запуска к запуску, поэтому «работает» подтверждают выборкой, и один удачный пример не считается. **Второй и четвёртый** остаются слово в слово теми же.


Второй вопрос — про базу — ломается чаще остальных трёх. Дальше два разбора ровно об этом: в первом громкая цифра провала оказывается цифрой без знаменателя, во втором заявленная автономность расходится с собственной целью компании в четырнадцать раз.

Отчёт про «95% провалов ИИ»: что в нём написано на самом деле



ЧТО ПРОИЗОШЛО

В июле 2025 года исследовательская группа Массачусетского технологического института (MIT) выложила предварительный отчёт о состоянии ИИ в бизнесе — версия 0.1, без научного рецензирования. Основание: 52 интервью с руководителями, 153 анкеты и обзор 300 публичных внедрений. В заголовки ушла одна строка: **95% корпоративных пилотов не дали измеримого эффекта на прибыль** при 30–40 млрд долларов вложений. За месяц цифру перепечатали деловые издания по всему миру.



ЧТО В ОТЧЁТЕ

60% организаций изучали тему · 20% дошли до пилота · 5% довели до промышленной эксплуатации. Пять из двадцати дошедших — **25% успеха**; в заголовок попали 5%. И меряли здесь мнение руководителя о пилоте — финансовый результат никто не считал.

ЧЕТЫРЕ ВОПРОСА К ЛЮБОЙ ГРОМКОЙ ЦИФРЕ

- 1 Каков знаменатель — от чего считаем?
- 2 Что именно засчитано провалом?
- 3 Есть ли у автора конфликт интересов? Здесь — все четыре автора строят и продают агентные продукты.
- 4 Прослеживается ли цифра до первоисточника с описанной методикой?

Корень не в моделях. Boston Consulting Group, январь 2026, 2 360 руководителей: измеримую отдачу видят 6% компаний — большинство меряет активность (сэкономленные часы, автоматизированные задачи) вместо денег. Нечем мерить — нечего и предъявить.

Магазин без касс: шесть лет «полной автономии» и 700 ручных проверок на 1000 покупок



ЧТО ПРОИЗОШЛО

С 2018 года Amazon открывал магазины без касс: берёшь товар с полки и выходишь, деньги списываются сами. Технологию продавали как **чистое компьютерное зрение** — камеры и датчики сами понимают, что ты взял. В апреле 2024 года журналисты выяснили: больше тысячи человек в Индии просматривали видеозаписи и вручную размечали покупки, которые система не смогла распознать.



РАЗБОР — ОДНА И ТА ЖЕ ЛИНЕЙКА КОМПАНИИ

700 из 1000 покупок требовали ручной проверки — против собственной внутренней цели **20-50 из 1000**. Превышение от 14 до 35 раз. Само участие людей — не разоблачение: они размечали записи постфактум, и формально Amazon возразил верно. Разоблачение в другом: цель поставила сама компания, и заявленное разошлось с измеренным по её же линейке. Спорить о значении слова «автономный» не нужно — достаточно найти число.

ЧЕМ КОНЧИЛОСЬ

Из больших продуктовых магазинов технологию убрали в 2024-м, а в январе 2026-го Amazon закрыл и сами сети Go и Fresh.

Технология переехала туда, где ассортимент мал и предсказуем: **360+ сторонних точек** в пяти странах — стадионы, больницы, университеты.

Где и это сложно, компьютерное зрение заменили **радиочастотными метками (RFID)** — предсказуемым решением **без ИИ**.

А в больших магазинах место заняла **тележка со сканером**: товар отмечает сам покупатель.

Если для приемлемой точности нужна ручная проверка кратно выше собственной цели — заявленная автономность не достигнута. Дальше два честных хода: снизить обещание до «с помощью ИИ» либо признать нишу пока неподходящей и взять инструмент проще. Amazon в итоге сделал оба.

РАЗДЕЛ 7

Обобщение: один инструмент на все шесть фаз

6 фаз · 1 матрица · 3 оси решения

Шесть фаз разобраны по отдельности, а задача приходит целиком — по разделам лекции её никто не разложит. Без общего инструмента остаётся шесть отдельных выводов и ни одного ответа на случай, которого здесь не было.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Шесть фаз — одна структура: дисциплина, удешевление, режим отказа, человек

Фаза	Ведущая дисциплина	Что удешевил ИИ	Режим отказа	Где человек обязателен
 Исследование	Развитие клиента и «The Mom Test»: проверяемая гипотеза	Кабинетный поиск, ведение и сведение разговоров	Угодливость: синтетический источник не скажет «нет»	Проверка реальным прошлым и реальным обязательством
 Дизайн	Двойной ромб, эвристики Нильсена, дизайн-система	Варианты экрана: –20% времени против базы	Пробелы доступности; один запрос даёт разные ответы	Сведение к контексту; проверка, умеющая остановить выпуск
 Сборка и запуск	Минимально жизнеспособный продукт; рубеж остановки	Сама сборка: шаблонный и связующий код	Пропуск рубежа; раскатка сразу на всю аудиторию	Спецификация намерения; решение о темпе и об остановке
 Измерение	Контролируемый эксперимент; метрика-ограничитель	Оценка качества в масштабе; дешёвый первый проход	Взломанная косвенная метрика; замер не переносится на задачу	Критерий и метрика-ограничитель названы до теста
 Поддержка	Инженерия надёжности: цель уровня сервиса, бюджет ошибок	Подсказка оператору: +15% решений в час от базы 2,1	Тихий дрейф маскируется средним по всем ответам	Системная модель и ответственность за каждый ответ
 Управление	Портфельное управление; у каждой цифры есть владелец	Ничего: здесь ИИ добавляет расход, растущий с масштабом	Статистика без знаменателя	Критерий успеха согласован заранее; своя базовая линия

Как читать: назовите фазу своей задачи — строка отвечает по порядку, какую дисциплину держать, чем здесь помогает ИИ, какой отказ стеречь и что остаётся за человеком. Имена инструментов сменяемы; четыре столбца держатся на характере сложности и цене ошибки фазы.

Три оси решают, можно ли убрать человека с рубежа

Раньше всех трёх — вопрос о классической дисциплине фазы: нет её — сначала выстраивают, в пустоте усиливать нечего.



Обратимость

Легко ли откатить следствие, если вывод неверен

Низкая → поэтапность и путь отката



Цена ошибки

Во что обойдётся ошибка: деньги, репутация, здоровье

Высокая → названный владелец решения




Наблюдаемость

Как быстро видно, что вывод неверен

Низкая → петля оценок и метрика-ограничитель

Ни одна ось не запрещает ИИ — каждая называет, что должно стоять рядом. Все три в хорошем положении — человека с рубежа можно убрать; любое другое сочетание требует рубежа по проблемной оси.

Метод переносится, список инструментов — нет: код был первым полигоном, продукт — вторым



Курс не учит «применяйте ИИ больше» и не учит «бойтесь ИИ» — он учит говорить обоснованное «да» и обоснованное «нет».

Семинар 7

Полный прогон инструмента на учебном ИИ-продукте: от гипотезы до точки эскалации к человеку.

Лекция 6

Тот же метод в системах автоматизированного проектирования (САПР): цена физической ошибки выше.

Вопросы?

Инженер за рабочей станцией системы автоматизированного проектирования (САПР) со световым пером, конец 1970-х: инструмент исчез — дисциплина проектирования осталась