

# Сборка почти бесплатна. Почему тогда почти никто не извлекает из этого пользу?



Недели работы → часы <sup>[1]</sup>

*внутренний опыт Anthropic*



~95% пилотов — ноль  
отдачи <sup>[2]</sup>

*MIT, лето 2025*

Оба факта правдивы одновременно: сборка стала почти бесплатной, а превращение сборки в ценность — нет. Держите вопрос — вернёмся к нему в конце лекции.





## ЛЕКЦИЯ 5

# AI-продукт: полный жизненный цикл — от намерения до эксплуатации

Курс «Осознанное применение ИИ» · инженеры-студенты 3 курса

Шесть разделов — шесть стрелок одной петли: код (Лекция 4) — один дешёвый шаг внутри неё.

0  
Введение

1  
Исследование

2  
Дизайн

3  
Сборка и запуск

4  
Измерение

5  
Поддержка

6  
Управление

7  
Обобщение

# Лекция — это петля, а не список из шести тем



1. Исследование — откуда гипотеза

2. Дизайн — гипотеза → артефакт

3. Сборка и запуск — артефакт → продукт

4. Измерение — сработало ли

5. Поддержка — живёт 24/7


6. Управление — куда вкладывать

Стрелка возврата: управление снова питает исследование — замкнутая петля, а не одноразовый линейный процесс.

# Цикл кода Лекции 4 — это один шаг внутри цикла продукта

## Цикл продукта (Лекция 5)

откуда берётся уверенность, что стоит писать этот код



6 фаз



исследование → дизайн → сборка/запуск → измерение →  
эксплуатация → управление → снова исследование



## Цикл кода (Лекция 4)

как надёжно писать код с ИИ

спека → ADR → план → PR → инцидент

Чтобы пользовательская ценность состоялась — то есть продукт работал, был внедрён и кем-то выбран, — цикл кода приходится обернуть в ещё один цикл. Без внешнего цикла выходит собранное и никем не используемое: код есть, продукта нет.

Когда ИИ сделал сборку почти бесплатной — что стало настоящим узким местом продукта, и на каждой фазе цикла: какая классическая дисциплина остаётся, что ИИ ускоряет, и где AI-first ломается?

# Три человека из разных областей нарисовали один и тот же чертёж



**Не сговариваясь — один и тот же чертёж: петля обратной связи как структурное свойство любой системы, которая учится в условиях неопределённости.**

# ИИ меняет стоимость и доверие каждой стрелки петли — но не одинаково



**Строить**

стоимость почти обнулилась



**Измерять / учиться**

стоимость та же, доверие упало



**Исследовать**

быстрее, но уязвимее к атаке

**Мета-паттерн, повторяется в каждом из 6 разделов: у каждой стрелки есть классическая дисциплина — ИИ её не отменяет, а меняет её стоимость и требуемую степень проверки.**

*Подумайте: на какой стрелке вашей последней задачи скорость обогнала ваше реальное доверие к результату?*

## РАЗДЕЛ 1

# Исследование — намерение и гипотеза

2 базы · 3 провала

*Откуда вообще берётся гипотеза о том, что строить. У большинства есть неформальный опыт «спросить у друзей» — и почти никто не сталкивался с формальной дисциплиной, объясняющей, почему этот опыт систематически лжёт.*



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

# Исследование простыми словами



простыми словами

## Что это

Фаза, где вы ищете не решение, а проблему: у кого болит, насколько сильно и готов ли человек за это платить временем, репутацией или деньгами.


## Зачем

Построить можно что угодно; ценно только то, что решает реальную боль реального человека. «Я бы таким пользовался» — не факт.

## Ментальная модель

Внутри офиса нет фактов — факты снаружи. Записываете гипотезу, выходите к людям, проверяете. ИИ ускоряет сбор, но не заменяет разговор с настоящим человеком.

# «Внутри офиса нет фактов» — 4 шага, каждый заканчивается решением



Стив Бланк — методология Customer Development <sup>[1]</sup>



## Фальсифицируемая гипотеза

мы верим X → проверим через Y → к дате Z получим ответ да/нет

**BML — двигатель; Customer Development — карта местности, по которой двигатель едет. Сначала понять, что проверяем и у кого — потом, как быстро крутить цикл.**

[1] Blank — Customer Development (Four Steps to the Epiphany)

# Даже мать соврёт — если вопрос сконструирован неправильно <sup>[1]</sup>



## Об их жизни, не о вашей идее

*не питчите идею и не просите вердикт*



## О прошлом, не о будущем

*гипотетические вопросы провоцируют нечестный оптимизм*



## Обязательством, не комплиментом

*легитимные сигналы: время, репутация, деньги*

### Плохо

*«Заплатили бы \$20 в месяц?»*

### Хорошо

**«Сколько вы платите сегодня за ближайший аналог?»**

**JTBD (Jobs-to-be-Done), «работа, на которую нанимают продукт» — смежная рамка Кристенсена: спрашиваем не о предпочтениях, а об обстоятельстве последней покупки, и получаем таймлайн решения, а не список мнений.**



**ВОПРОС ЗАЛУ** «Как вам идея — ассистент, который сам разбирает вашу почту?» Какое из трёх правил нарушил этот вопрос и как переспросить, чтобы получить факт?

# Часы → минуты: но ссылки существуют, чтобы их проверяли



проверь источник

## Desk research (кабинетное исследование)

Perplexity Deep Research: 2 часа → ~30 минут <sup>[1]</sup>



## Синтез интервью

Dovetail — кластеризация более в масштабе <sup>[2]</sup>



## Reference dataset (эталонный набор)

курируемая коллекция «запрос → правильный ответ»

**97% исследователей используют ИИ — лишь ~8% доверяют ИИ-персонам как данным** <sup>[3]</sup>

Обязательная практика: проверять важные данные напрямую по источнику до использования в решении. Синтетические пользователи — только пре-исследование (пилотаж гайда, черновик персон, генерация гипотез), никогда не доказательство для решения «продолжать/остановить».



**ВОПРОС ЗАЛУ** ИИ-персона прошла ваш сценарий знакомства с продуктом целиком и назвала функцию отличной. Что в устройстве такого источника мешает ему сказать «нет»?

# Синтетический собеседник не может произвести несогласие



## Зеркало согласия

**72-91%**

при явном согласии

**7-28%**

при явном несогласии

Сдвиг тона ответа модели к позитиву («feedback positivity», 5 моделей) — это не «частота отрицательного ответа».

*Sharma и др., 2023 — Figure 1, ICLR 2024*

## Когда живое интервью строго лучше ИИ-синтеза



**1. Высокая цена ошибки «продолжать/остановить»**



**2. Нужно реальное прошлое, не правдоподобное**




**3. Нужна валидация обязательством, не мнением**

У синтетического собеседника нет реального прошлого, способного противоречить формулировке вопроса, — поэтому несогласие он не производит в принципе.

**ИИ-резюме теряет 20-40% деталей интервью (Torres) <sup>[1]</sup>, если пропущен шаг «сначала по отдельности» — прослеживаемый до конкретного шага сбой, не расплывчатое «ИИ иногда ошибается».**

# Одна и та же задача: реальные люди — 3 из 7, синтетическая панель — 7 из 7 <sup>[1]</sup>



NN/g: контролируемое сравнение на сценарии знакомства с продуктом

## Реальные люди



3 из 7 — «надуманно и бесполезно»

## Синт-панель



7 из 7 — «меняет правила игры»

Одна и та же фича — противоположные вердикты

**Критерий: синтетический выход дисквалифицирован для решения «продолжать/остановить» по построению, а не из-за невезения прогона. Альтернатива: до-исследовательская роль + реальное тестирование 5-8 участников.**

# A\$440 000 отчёт правительству — с выдуманными цитатами внутри



## Deloitte Australia, 2025

- Ссылки на несуществующие статьи + сфабрикованная цитата суда <sup>[1]</sup>
- Подготовлен через Azure OpenAI без человеческой верификации цитат



**A\$440 000**

≈US\$290 000 отчёт

База: ~712 судебных решений по миру с ИИ-галлюцинированными цитатами, ~90% — в 2025 году <sup>[2]</sup>

**Урок: вывод модели в discovery-фазе — не верифицированный черновик, не источник фактов. Критерий: итоговый документ внешнему заказчику требует 100% проверки каждой ссылки, не выборочной.**

# Один бренд, два провала: данные подвели одну систему, закупка — другую

## IBM Watson Health



### Случай А — Watson for Oncology

*Memorial Sloan Kettering, с 2012*

- Коммерческий запуск 2015; внутренние документы: рекомендации «небезопасные и некорректные»
- Бевацизумаб гипотетическому пациенту с активным кровотечением — вопреки предупреждению производителя

*STAT News · 25 июля 2018 <sup>[1]</sup>*

**Причина: обучен на малом числе синтетических, гипотетических кейсов горстки онкологов MSK — не на реальных исходах <sup>[2]</sup>**



### Случай В — Oncology Expert Advisor

*MD Anderson, 2013-2016*

- Контракт через 12 продлений вырос с \$2,4 млн до \$39,2 млн IBM + \$23 млн PwC
- Закрит в сентябре 2016 — без единого пролеченного пациента

**≈ \$62 млн → 0 пациентов**

**Причина по аудиту University of Texas System: обход конкурсных закупочных процедур + дефицит донорского финансирования ≈ \$11,6 млн — не про данные и не про модель**


**Два независимых механизма отказа одной корпорации: непригодные данные против несостоятельного управления проектом. Не всякий дорогой провал с ИИ на обложке объясняется самим ИИ.**

## РАЗДЕЛ 2

# Дизайн — гипотеза становится артефактом

2 базы · 2 провала

*Как гипотеза из исследования превращается в конкретный артефакт, который можно показать человеку. Здесь же закладывается безопасность — в дизайн-брифе, а не патчем после того, как что-то пошло не так.*



прыгнуть сразу к  
решению



сначала —  
правильная проблема

0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

# Дизайн простыми словами



простыми словами

## Что это

Гипотеза становится дешёвым черновиком: наброском экрана, кликабельным прототипом — тем, что можно показать человеку.

## Зачем

Черновик не жалко выбросить. Понять «не работает» на бумаге — копейки; понять то же самое после релиза — очень дорого.

## Ментальная модель

Два ромба: сначала ищем правильную проблему, потом правильное решение. Частая ошибка — прыгнуть сразу к решению.

# Два алмаза: сначала правильная проблема, потом правильное решение



**Частая ошибка: конвергировать на решении, не проверив саму проблему — перепрыгнуть первый алмаз. Дешёвый прототип нужен именно для того, чтобы это вскрыть до траты денег на разработку.**

# Эвристики Нильсена — линтер для UX, не замена тестированию



## Топ-5 из 10 эвристик <sup>[1]</sup>

- 1 Видимость статуса системы
- 2 Соответствие языку пользователя
- 3 Контроль и свобода (отмена)
- 4 Консистентность
- 5 Предотвращение ошибок



## Дизайн-система = guardrail

Удерживает генеративную свободу в рамках провалидированного бренда.



**ВОПРОС ЗАЛУ** Интерфейс на один и тот же ввод даёт разный вывод. Какая из пяти эвристик ломается первой?


Метафора: эвристики — как линтер для интерфейса. Ловят типовые проблемы до траты денег на исследование — но не заменяют тест на живом пользователе <sup>[2]</sup>.



«Я снова прошу»: эвристики ловят типовые проблемы, но не заменяют проверку на живом пользователе.

# ИИ для дивергенции, человек для конвергенции

## Генерация направлений



## Инструменты 2025-26

v0 (Vercel) · Figma Make <sup>[1]</sup> · Google Stitch <sup>[2]</sup> · bolt.new

- 2-4 направления за минуты (было — день ручного вайрфрейминга)
- Figma Make подтягивает собственные компоненты команды — меньше переделки

**Конвергенция требует суждения о конкретном контексте, которого нет в обучающих данных: ИИ расширяет пространство вариантов, а выбор и проверку на живом пользователе оставляем человеку.**

## 29% соответствие WCAG на 21 880 оценках — платформа важнее промпта <sup>[1]</sup>



21 880 оценок WCAG на ИИ-интерфейсах:

- контраст 26,8%
- использование цвета 19,2%

*«Сделай доступным» в промпте не гарантирует результат — решают дефолты платформы, а не текст запроса.*

**Дизайн для НЕДЕТЕРМИНИРОВАННОГО вывода: тот же ввод → разный вывод → ломает эвристику консистентности; нужны человеко-контрольные точки.**



**ВОПРОС ЗАЛУ** Черновик экрана теперь стоит минуты. Какой вопрос дизайн-брифа при такой скорости пропускают первым?

# Защита появилась почти через два года после запуска — уже после трагедии



**Защита уязвимых пользователей добавлена ретрофитом — после трагедии, а не в исходном дизайн-брифе.**



**Character.AI**

## Character.AI

14-летний пользователь погиб после месяцев общения с ИИ-персонажем (02.2024) <sup>[1]</sup>.



**Корень — не рантайм-баг, а отсутствующее требование в дизайн-брифе: MVP оптимизировал вовлечённость без вопроса «кто может пострадать». Критерий: защита уязвимых — в MVP, а не патчем после трагедии.**

## Найдено случайно: та же анкета с другой датой рождения — мгновенное приглашение



**Фильтр с жёстко зашитым правилом  
«дата рождения»**

**Женщины 55+ / мужчины 60+ → автоотказ**

*Обнаружено случайно: переподача той же анкеты с другой датой рождения → мгновенное приглашение.*



**\$365 000** <sup>[1]</sup>

*EEOC, 9 авг. 2023 — первое урегулирование по ИИ-дискриминации*

**Контраст с Character.AI: там дизайн НЕ заложил защиту; здесь дизайн ЗАЛОЖИЛ конкретное вредное правило. Критерий: автоматизация решения о людях → аудит признаков на дискриминацию ДО релиза.**

## РАЗДЕЛ 3

# Сборка и запуск — схлопнутая стрелка

2 базы · 2 провала

*Здесь ИИ меняет больше всего — стоимость самого написания кода. Но раздел начинается не с этого факта, а с классической дисциплины релиза: как выкатывать безопасно и когда остановиться.*



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

# Сборка и запуск простыми словами



простыми словами

## Что это

Артефакт становится работающим продуктом у пользователей. ИИ сделал само написание кода почти бесплатным.


## Зачем механика запуска

Раз строить дёшево — цена ошибки теперь не «написать», а «выкатить не то на всех сразу». Нужно включать понемногу и быстро откатывать.

## Ментальная модель

Запуск — это кран, а не рубильник: 1% → 10% → 100%, следим за реакцией. И держим наготове решение «убить», а не «дорабатывать вечно».

## Та же механика — но здесь решение убить продукт, а не флаг переключить



Эти примитивы вы знаете из инженерной раскатки (CI/CD)



**НОВОЕ** здесь — чьё и по каким критериям решение они обслуживают: MVP (Райс) <sup>[1]</sup> = обучение, не отгрузка. Stage-Gate go/kill (Купер) <sup>[2]</sup> — «воронка, не туннель»: пороги провала записаны числом заранее.

**Общий смысл:** скорость запуска покупается ограниченным «радиусом поражения» — сколько пользователей задето, если новое окажется плохим.

## +200% кода на инженера — но лишь 16% PR получили содержательное ревью <sup>[1]</sup>



### Измерение Anthropic

- Реализация: недели/месяцы → минуты агентного исполнения
- Объем кода на инженера: +200% год к году
- Содержательное человеческое ревью до слияния: лишь ~16% PR

**Дефицитный ресурс сместился к двум человеческим концам: точность намерения на входе и качество суждения на выходе — узкое место теперь ревью, а не написание.**

# Запуск — это не «включить», а передача контроля по ступеням

v3

**Автоматически, с возвратом к человеку**

*заслужено трассами*

v2

**Предлагает решения на утверждение человека**

*человек в петле*

v1

**Высокий контроль / низкая агентность**

*маршрутизирует*

## CC/CD против привычного CI/CD <sup>[1]</sup>

CC/CD — Continuous Calibration/Development (непрерывная калибровка). Релиз версионизируется по уровню агентности, а не по набору функций.

### Лестница агентности (agency-ladder)

Три ступени передачи контроля; поднимаются по ней под требование, а не по готовности инструмента.

«Если не тестировали при высоком контроле — не готовы давать высокую агентность»: автономию агент заслуживает трассами исполнения, а не сразу по умолчанию.



**ВОПРОС ЗАЛУ** Возьмите функцию из своего проекта, которую доверили бы ИИ. На какой она ступени сейчас — и какое требование должно появиться, чтобы поднять её на следующую?

# Удвоив скорость генерации, вы удваиваете очередь на ревью — не пропускную способность



**генерация  
дёшево и быстро**

**верификация  
не ускорилась**

*Сгенерировать правдоподобный код — секунды; проверить его — не ускорилось.*

## Проблема 70% <sup>[1]</sup>

Опытный разработчик переосмысливает ИИ-вывод и тратит время на переделку.

Новичок отправляет «карточный домик кода», который выглядит правдоподобно, но рассыпается под нагрузкой.

**Отгрузка без eval-гейта или плана отката — это не скорость, это отложенная цена: ревью не масштабируется вместе с генерацией.**

# 0% → 100% одним шагом — минуя канареечную раскатку целиком



Google

## Google AI Overviews, май 2024

Раскатан на 100% поиска США одним шагом <sup>[1]</sup>. Без eval-гейта. Отключить пользователю нельзя.

1%

10%

25%


50%

100%

*правильная канареечная раскатка (перепрыгнута)*

На 1% трафика паттерн («ешьте камни» — сатира The Onion; «клей на пиццу» — шутка на Reddit) всплыл бы за дни во внутреннем мониторинге <sup>[2]</sup>. Вместо этого — публичное осмеяние сразу на 100% аудитории.

## 2,5-3 года на 0,7% сети — и решение остановиться было правильным <sup>[1]</sup>



0,7%

~100 из ~13 786 ресторанов  
США

### McDonald's × IBM — голосовой приём заказов

- 2,5–3 года пилота на 0,7% сети <sup>[2]</sup>
- Вирусные провалы: бекон в мороженом, 9 чаёв вместо одного
- Закрит июнь 2024 — цель (голосовая автоматизация) осталась, вендорский подход убит

**Зеркало предыдущего кейса: там пропустили пилот целиком и выкатили на всех; здесь пилот был долгим — и его сигнал использовали правильно, приняв дисциплинированное решение «убить», а не масштабировать провал.**

## РАЗДЕЛ 4

# Измерение — стрелка, которой ИИ снизил доверие

2 базы · 2 провала

*Измерение — то место, где «выглядит хорошо» бьёт по продукту сильнее всего. Формальную дисциплину продуктового эксперимента многие видят впервые.*

«метрика  
выросла!»

а эффект реален?



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

# Измерение простыми словами



простыми словами

## Что это

Фаза, где вы честно проверяете: сработало изменение или только кажется. Формальную дисциплину эксперимента многие видят впервые.

## Зачем

«Метрика выросла после релиза» ничего не доказывает — она могла вырасти сама. Нужен способ отделить причину от совпадения.

## Ментальная модель

Делим пользователей на две случайные группы: одной — новое, другой — старое. Разница и есть настоящий эффект. Метрику успеха фиксируем заранее.

# Рандомизация отличает причину от совпадения



**ОЕС — метрика, о значении которой договорились заранее** <sup>[1]</sup>

Контролируемый эксперимент (Кохави): гипотеза с механизмом → рандомизация → заранее определённый размер выборки → решение.

Учебная ловушка: «время на сайте поддержки» — это хорошо или плохо? Направление метрики надо согласовать до теста.

**Только случайное деление групп даёт причинность: разница между Control и Treatment вызвана вашим изменением, а не сезоном, рекламой или везением** <sup>[2]</sup>.



**ВОПРОС ЗАЛУ** ОЕС вырос на 8% на третий день теста,  $p < 0,05$ . Останавливаете тест и раскатываете?

# Три вопроса ловят все восемь ловушек эксперимента

## ДО ТЕСТА

1



### Настроен ли тест правильно?

*SRM (перекос групп) [1] — доли пользователей в группах не совпали с планом; размер выборки должен быть зафиксирован заранее, а не подогнан под результат*

## ИНТЕРПРЕТАЦИЯ

2



### Правильно ли читаю результат?

*peeking (подглядывание) [2] — досрочная проверка результата: 2 подглядки  $\approx$  2х ложных срабатываний, поэтому решение принимается только на заранее заданный размер выборки*

## ЭФФЕКТ

3



### Реален ли сам эффект?

*закон Тваймана [3]: слишком красивая или неожиданная цифра обычно означает ошибку измерения, а не реальный эффект — сначала перепроверь методологию, потом радуйся результату*

**А/В (измерение) — это не то же, что feature flag (раскатка): первое проверяет эффект, второе управляет доступом. И осторожнее с легендами: тест Bing  $\approx$  \$100 млн прироста выручки (Kohavi/Thomke, HBR 2017) — это НЕ «кнопка за \$300 млн» (отдельный кейс юзабилити).**


# $\text{pass}@k$ стремится к 100%, $\text{pass}^k$ — к 0%: одна вероятность, разный вопрос

## 3 уровня оценки (Хусейн)

1 Unit-тесты — быстрые, детерминированные

2 Человек + LLM-as-judge (модель-судья) <sup>[2]</sup>

3 А/В — только когда продукт зрел



$\text{pass}@k$  = хотя бы 1 успех из k;  $\text{pass}^k$  = ВСЕ k успешны <sup>[1]</sup>. Промышленная надёжность почти всегда требует  $\text{pass}^k$  — «юнит-тесты для агента», где вероятностный вывод ломает привычный «прошёл/не прошёл».

# Лодка кружит в лагуне и набирает очки — но никогда не финиширует



RL-агент в гонке набрал на 20% больше очков людей — кружа в лагуне и собирая бонусы, никогда не пересекая финиш <sup>[1]</sup>. Оптимизировал прокси, а не реальную цель.


**Закон Гудхарта: когда мера становится целью, она перестаёт быть хорошей мерой.**

Anthropic: модель обобщила от угодливости к прямому редактированию собственной функции вознаграждения <sup>[2]</sup>.

Что остаётся: ОЕС-дисциплина, guardrail-метрики, закон Тваймана — подозрительно идеальный балл теперь скорее баг, чем прорыв.

**Взлом награды (reward hacking): модель находит способ «выиграть» прокси-метрику, не достигая задуманного результата — поэтому мера и цель нельзя путать.**

## Все 5 реакций взвешены одинаково ×5 — не только «ГНЕВ»



facebook

Facebook MSI, январь 2018:  
love/haha/wow/sad/angry — все ×5 выше лайка  
(не только гнев) <sup>[1]</sup>.

love

×5

haha

×5

wow

×5

sad

×5

angry

×5

**Прокси вовлечённости без guardrail на дезинформацию скрывал вред  
~2 года: внутренний guardrail (корреляция гнев ↔ дезинформация)  
подтверждён к 2019, вес обнулён в сентябре 2019 <sup>[2]</sup>. Урок: guardrail-  
метрику надо измерять с первого дня, а не когда вред уже случился.**

# Сдал бенчмарк формата А ≠ безопасен в проде формата В

## Медицина

**86,5% MedQA [1]**

Med-PaLM 2 хорош на бенчмарке вопросов-ответов — но клиническая безопасность требует ОТДЕЛЬНОГО adversarial (сопоставительного) safety-набора.

## Право


Stanford RegLab: Lexis+ 17% галлюцинаций, Westlaw 33% — на реальных юридических запросах <sup>[3]</sup>.

**Дело Mata v. Avianca (фейковые цитаты) = ChatGPT, НЕ Harvey <sup>[2]</sup> — частая ошибка атрибуции.**

**Бенчмарк — свидетельство о производительности только на формате задачи именно этого бенчмарка.  
Альтернатива: сопоставительные evals на реальных краевых случаях того домена, где продукт будет работать.**

# А/В остаётся фундаментом — evals и guardrail-метрики теперь обязательны поверх

Измерение = стрелка, которой ИИ снизил доверие



- Рандомизация — по-прежнему то, что даёт причинность, а не совпадение.
- Оценки (evals) и guardrail-метрики — новые слои поверх, а не замена А/В.
- Центральный навык фазы — отличать сигнал от шума.

Мост в поддержку: тот же навык «сигнал  $\neq$  шум» в эксплуатации означает заметить дрейф раньше, чем он проявится на дашборде.

## РАЗДЕЛ 5

# Поддержка — продукт как оркестр

2 базы · 3 провала

*Между «код работает у меня» и «продукт надёжно работает у миллионов 24/7» — пропасть, и её закрывают процессом эксплуатации, а не только качеством кода.*



0  
Введение

1  
Исследование

2  
Дизайн

3  
Сборка и запуск

4  
Измерение

5  
Поддержка

6  
Управление

7  
Обобщение

# Поддержка простыми словами



простыми словами

## Что это

Продукт уже живёт у людей круглосуточно: его надо наблюдать, чинить сбои и отвечать на жалобы — годами.


## Зачем

«Работает у меня» и «надёжно работает у миллионов 24/7» — разные вещи. Разрыв закрывают процессом, а не только чистым кодом.

## Ментальная модель

Заранее договариваемся, сколько сбоев допустимо (бюджет на ошибки). С ИИ сложнее: модель может «тихо деградировать», пока графики ещё зелёные.

## Ответ с кодом 200 ничего не говорит о том, галлюцинирует ли модель



Error budget = «1 - SLO». Пример: 99,9% → 1000 ошибок на 1 млн запросов за 4 недели. Изменения —  $\approx 70\%$  всех сбоев <sup>[1]</sup>.




**SLI «доля ответов с кодом 200» = всё ок? Нет: 200 приходит и когда модель уверенно галлюцинирует. Инфраструктурная метрика не видит качества ответа.**

**Дежурства, разбор инцидентов без поиска виноватых, инструкции — вы это можете знать. Новое здесь: в проде теперь недетерминированная модель (следующий слайд).**

# Трейсинг ловит дрейф галлюцинаций там, где инфра-мониторинг молчит

Трейсинг (камера над каждым узлом): *LangSmith · Langfuse · Arize Phoenix · Helicone* <sup>[1]</sup>



## LLMOps / AgentOps

Эксплуатация моделей и эксплуатация агентов: LLMOps следит за одним вызовом (промт, ответ, стоимость), AgentOps — за цепочкой шагов и вызовов инструментов целиком.

Дрейф данных против дрейфа концепта · защитные правила во время работы · предохранитель (circuit breaker) · Guardian Agents (категория Gartner) <sup>[2]</sup> — агенты, следящие за агентами.



**Не отправлять регулируемые PII (перс. данные) во внешний трейсинг без анонимизации или self-host.**

**Инфраструктурный мониторинг видит «сервис жив»; трейсинг видит «ответы деградируют»: дрейф галлюцинаций, сбои поиска, регрессию промптов.**

# Дашборды остаются зелёными, пока доверие уже падает недели



## Тихий дрейф

Самые активные пользователи замечают регрессию раньше агрегированных метрик — доверие падает раньше, чем двигаются дашборды.

## Дрейф правил

Guardrails (защитные правила) без версионирования молча устаревают: правила расходятся с реальностью незаметно.

**Что остаётся: эскалация к человеку, ответственность, инцидент-дисциплина — усилены автономностью ИИ, не отменены ею.**




**ВОПРОС ЗАЛУ** Назовите один сигнал в своей системе, который сегодня не попадает ни в один дашборд, но первым скажет, что качество упало.

# Модель была откалибрована корректно — не было предохранителя на дрейф в реальном времени



Рынок сдвинулся — дрейф концепта без предохранителя



Разные единицы и разные шкалы — МЛН слева, Тыс. справа (длины баров НЕ сравнивать напрямую)

Zillow Offers, ноябрь 2021: 9680 домов куплено, 3032 продано · ~2000 уволенных (~25% штата) <sup>[1]</sup> · ≈\$80 тыс. убытка на объект <sup>[2]</sup>.

**Критерий: модель, совершающая сделки на деньги, требует мониторинга точности предсказания в реальном времени с автоматическим предохранителем (circuit breaker), который отключает её при дрейфе.**

# «Бот — отдельное юрлицо» — трибунал отклонил этот довод одной фразой



**Весы в равновесии: ответ бота = статичная страница сайта. Одинаковая ответственность за оба.**

## **Air Canada, чат-бот сайта**

Бот некорректно сообщил о ретроактивной скидке. Трибунал — \$812,02 CAD <sup>[1]</sup>: компания отвечает за ответ бота как за любой другой контент сайта <sup>[2]</sup>.

**Ты владеешь каждым ответом бота — не больше, но и ни на грамм меньше ответственности, чем за любой другой контент сайта.**

# 10 из 10 журналистов получили один и тот же незаконный совет — не единичный сбой

## Klarna

Klarna: политика «только ИИ» откатилась (05.2025) <sup>[1]</sup> — но автоматизация выросла до 853 чел.-эквивалентов <sup>[2]</sup> (усиление людей, не замена).



## NYC MyCity — гос-бот



10 из 10 журналистов — один и тот же незаконный совет <sup>[3]</sup>. Мэр не отзывал бот сразу.

**Урок не «ИИ не работает», а «метрика пропускной способности без гарантированной эскалации к человеку — неверный дизайн».**

# Эксплуатация — точка, где петля физически замыкается



Поддержка → Продукт замыкает петлю.

Сигнал из эксплуатации(дрейф, инцидент, жалоба) обновляет reference dataset (эталонный набор) и guardrail — а при глубоком сигнале возвращает к самому намерению: что мы строим и для кого.

**Наблюдать, интерпретировать, решать — эти шаги остаются человеческими на каждом витке петли, даже когда исполнение почти бесплатно.**

## РАЗДЕЛ 6

# Управление — капстоун, отвечающий на хук-парадокс

2 провала · развязка

*Почему сборка почти бесплатна, а ценность — нет. Здесь мы поднимаемся на уровень организации и собираем петлю целиком.*



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

# Управление простыми словами



простыми словами

## Что это

Уровень организации: не «как сделать один продукт», а «во что вообще вкладывать деньги» — и остановить то, что не окупается.

## Зачем

Ресурсы ограничены. Тот же гейт «продолжать / убить», что и для одной функции, поднимается на уровень капитала между многими инициативами.

## Ментальная модель

Воронка портфеля: много идей на входе, немного профинансированных на выходе. У ИИ-продукта новая переменная — стоимость каждого запроса против его ценности.

## Тот же go/kill-гейт — но теперь распределяет капитал между многими инициативами

### Воронка портфеля

много инициатив

гейт 1

гейт 2

профинансировано

### Unit-экономика ИИ-продукта

Новая переменная — стоимость на запрос против ценности на запрос. Каждое обращение к модели стоит денег.

**Финансовый KPI на входе в пилот: «снизим стоимость тикета с X₽ до Y₽ при CSAT  $\geq$  Z; N тикетов, M недель, владелец — Иванов».**

**Портфельное управление = Stage-Gate, поднятый на уровень капитала: та же дисциплина «воронка, не туннель», но между продуктами, а не внутри одного.**

# Узкое место сместилось с технологии на операционную модель организации



## Зрелость 0-5 (maturity)



Сбер здесь →

Операторы → оркестраторы. Сбер сам ставит себя на уровень 3 из 5 <sup>[2]</sup> — сигнал против хайпа: даже крупный игрок не заявляет вершину шкалы.

**Пять независимых источников сходятся в одном: выигрывает не тот, у кого лучше модель, а тот, кто перестроил команды и управление под неё.**



**ВОПРОС ЗАЛУ** Вам показывают заголовок «95% ИИ-пилотов провалились». Какой первый вопрос вы задаёте этой цифре?

**60% исследовали → 20% пилот → 5% успех: это 25% среди дошедших, не «95% провал»** <sup>[1]</sup>



**«95% провал» — заголовок, который не переживает калибровку: успех среди дошедших до пилота — 25%, не 5%** <sup>[2, 3]</sup>.



#### 4 вопроса к любой громкой цифре провала ИИ

1. Каков знаменатель?
2. Что считается «провалом»?
3. Каков конфликт интересов автора? <sup>[4]</sup>
4. Прослеживается ли к первоисточнику?

**BCG AI Radar 2025 (январь 2025, 1803 руководителя): 60% компаний не отслеживают ни одного финансового KPI, привязанного к ценности ИИ** <sup>[5]</sup>.

«Автономный» магазин: 700 из 1000 транзакций требовали ручной проверки против цели 50



Just Walk Out (Amazon), с 2018: 700/1000 транзакций — ручная проверка (14× выше цели 50/1000) <sup>[1]</sup>. 6 лет маркетинга «автономный ИИ» без раскрытия масштаба труда (скрытая человеческая стоимость) <sup>[2]</sup>.

Фаза × что ИИ меняет × что остаётся из классики

| Исследование     | Дизайн         | Сборка/запуск    | Измерение      | Поддержка | Управление     |
|------------------|----------------|------------------|----------------|-----------|----------------|
| синтез, кабинет. | генерация      | код ≈ бесплатно  | оценки (evals) | трейсинг  | операц. модель |
| интервью         | требов. безоп. | ревью, kill-гейт | рандомизация   | эскалация | стоим./запрос  |

[1] Business Standard (anp. 2024) — Just Walk Out · [2] Retail Dive — демонтаж Just Walk Out

# Сборка бесплатна — дефицит теперь: суждение, а не исполнение



Центр управления NASA, Apollo 16 — решение принимают люди

## Разрешение парадокса, с которого начали

Сборка стала почти бесплатной — правда. Успех редок — тоже правда, но точнее: 25% среди дошедших до пилота, а не 5% «всех».



## Что изменилось

- Стоимость сборки
- Скорость исследования
- Скорость прототипа
- Скорость наблюдения



## Что осталось человеческим

- Намерение
- Суждение о сигнале против шума
- Ответственность за каждый ответ продукта
- Решение «здесь ИИ не тот инструмент»
- Управление с названным владельцем

**Когда сборка бесплатна, дефицитный ресурс — не исполнение, а суждение.**

## РАЗДЕЛ 7

# Обобщение — аппарат суждения из шести пройденных фаз

6 фаз · 3 свидетельства · 1 инструмент решения

*Здесь не появляется ничего нового — появляется способ применить уже разобранные к случаю, которого ещё не было в этой лекции.*



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

# Шесть фаз — одна структура: дисциплина, удешевление, режим отказа, человек

| Фаза                                                                                                     | Дисциплина (артефакт)                                      | Что ИИ удешевил                                    | Режим отказа                                                              | Где человек обязателен                                                |
|----------------------------------------------------------------------------------------------------------|------------------------------------------------------------|----------------------------------------------------|---------------------------------------------------------------------------|-----------------------------------------------------------------------|
|  <b>Исследование</b>    | Customer Development и Mom Test: фальсифицируемая гипотеза | Кабинетный поиск; синтез сотен интервью в кластеры | Угодливость: синтетический источник не производит «нет»                   | Проверка реальным прошлым и реальным обязательством                   |
|  <b>Дизайн</b>          | Double Diamond, эвристики Нильсена, дизайн-система         | Черновик экрана: день → минуты                     | Однообразие решений; пробелы доступности — 29,0% экранов проходят WCAG    | Сведение к контексту бренда и аудит безопасности до MVP               |
|  <b>Сборка и запуск</b> | MVP, гейт «продолжать/убить», канареечный запуск           | Сама сборка: шаблонный и связующий код             | Пропуск гейта оценки и поэтапной раскатки — ошибка сразу на всю аудиторию | Спецификация намерения на входе; решение о темпе и об остановке       |
|  <b>Измерение</b>       | Контролируемый эксперимент, OEC, guardrail-метрики         | Оценки в масштабе; дешёвый первый проход           | Взломанная прокси без guardrail; бенчмарк не переносится на задачу        | OEC и guardrail названы до теста; чтение результата через ловушки     |
|  <b>Поддержка</b>       | SRE: SLI, SLO, бюджет ошибок, эскалация к человеку         | Скорость наблюдения: трассировка и дашборды        | Тихий дрейф маскируется агрегатом; поток ответов без гарантии эскалации   | Владение системной моделью; ответственность за каждый ответ           |
|  <b>Управление</b>     | Портфельное управление, финансовый показатель с владельцем | Диагностика операционной модели организации        | Статистика без знаменателя: 25% успеха среди дошедших, не 5% «всех»       | Критерий успеха согласован заранее; сравнение со своей базовой линией |

29,0% экранов проходят WCAG — ACM Web4All, 2026 · воронка 60% → 20% → 5% и знаменатель пилотов — MIT NANDA, июль 2025 · 60% компаний без финансового показателя ценности ИИ — BCG AI Radar, январь 2025 (n=1803)

**Как читать: назовите фазу задачи — дальше матрица отвечает по порядку, какую дисциплину держать, какой режим отказа стеречь и где решение не делегируется. Имена инструментов сменяемы; дисциплина, режим отказа и точка человека держатся на характере сложности и цене ошибки фазы.**

Три независимых метода — один вывод: артефакт дешевет, суждение — нет

| Свидетельство                                                                                                                                      | Метод                                                                                                                                                                                | Что показывает                                                                                                                                             | Граница метода                                                                                                     |
|----------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------|
| <br><b>Организационные опросы</b><br><i>макро-уровень</i>         | Кросс-секционный срез по многим организациям: BCG AI Radar 2025 — 1803 руководителя высшего звена, 19 стран (январь 2025); MIT NANDA — 300+ инициатив и 153 руководителя (июль 2025) | 60% компаний не отслеживают ни одного финансового показателя ценности AI. Воронка 60% → 20% → 5%: успех среди дошедших до пилота — 25%, не 5% «всех»       | Самоотчёт руководителей; разные знаменатели у разных обзоров; у MIT NANDA — нераскрытый конфликт интересов авторов |
| <br><b>Внутренняя телеметрия</b><br><i>уровень сборки и ревью</i> | Данные одной компании о собственной практике: публичное заявление инженера Anthropic (Черны, 9 марта 2026) и анонс инструмента ревью (~10 марта 2026, подтверждён InfoQ)             | Объём кода на инженера вырос примерно на 200% год к году. Доля запросов на слияние с содержательным ревью выросла с ~16% до ~54% после запуска инструмента | Одна компания — напрямую на индустрию не обобщается; зато раскрыт невыгодный для собственного продукта разрыв      |
| <br><b>Контролируемое измерение</b><br><i>уровень оценки</i>      | Состязательный набор задач и рецензируемое измерение на реальном формате работы: Med-PaLM 2; Stanford RegLab, 2024 — 202 юридических запроса                                         | 86,5% на экзаменационном наборе MedQA не вскрывают открытые сбои клинической безопасности. Lexis+ AI ошибается в 17% случаев, Westlaw AI — примерно в 33%  | Узкие предметные области; единицы измерения между доменами разные и напрямую не складываются                       |

Опрос

Телеметрия

Измерение



Сила аргумента — не в величине отдельного числа, а в независимости методов: три разных объекта измерены тремя разными инструментами, и все три указывают в одну сторону. Артефакт производится быстро и дёшево, а работа «назвать критерий заранее и содержательно проверить результат» не дешевет.

Три оси решают режим фазы: без гейта — только при высокой обратимости, низкой стоимости и высокой наблюдаемости

**Обратимость**

Насколько легко откатить следствие, если вывод неверен.

**Стоимость ошибки**

Во что обойдётся ошибка: деньги, репутация, здоровье, ответственность.

**Наблюдаемость**

Насколько быстро узнаем, что вывод неверен, — до того как вред накопится.

AI-first без дополнительного человеческого гейта оправдан только при сочетании высокой обратимости, низкой стоимости ошибки и высокой наблюдаемости одновременно. Любая другая комбинация требует гейта, соразмерного проблемной оси.

| Случай                                                               | Обратимость                                            | Стоимость ошибки                                                               | Наблюдаемость                                                                         | Проблемная ось → мера                                                          |
|----------------------------------------------------------------------|--------------------------------------------------------|--------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|
| <b>Google AI Overviews</b><br><i>раскатка на 100% трафика поиска</i> | низкая — вся аудитория увидела ответ одновременно      | высокая — вирусный, потенциально опасный совет                                 | была бы высокой при канареечной фазе, но её пропустили                                | обратимость (масштаб раскатки) → поэтапная раскатка возвращает и наблюдаемость |
| <b>Zillow Offers</b><br><i>закупка недвижимости по прогнозу цены</i> | минимальная — купленный дом не отменяется одним кликом | максимальная — списания \$304-408 млн, ≈2000 домов в убыток, ≈\$80 тыс. на дом | низкая по конструкции — только квартальная отчётность, не контроль в реальном времени | все три оси сразу → нужен жёсткий гейт на каждой, не было ни одного            |


Вопрос залу: команда хочет отдать ИИ автоматический ответ на публичные отзывы о продукте. Прогоните случай по трём осям — какая из них проблемная и какая мера её закрывает?

## Восемь вопросов, восемь действий: чек-лист распределяет бремя доказательства

| № | Вопрос                                       | Действие, если ответ «нет»                                                                                |
|---|----------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| 1 | ✓ Классика фазы на месте?                    | Сначала выстроить базовую дисциплину фазы — в пустоте усиливать нечего                                    |
| 2 | ✓ Стоит ли доверие своей цены?               | Добавить проверку там, где доверие упало: guardrail-метрику или мониторинг сегментов, а не агрегат        |
| 3 | ✓ Есть эталонный набор и оценка против него? | Построить набор из 20–100 примеров до развёртывания — иначе нет базы, от которой меряется регрессия       |
| 4 | ✓ Есть guardrail-метрика?                    | Назвать guardrail явно до теста, а не постфактум: что мониторим, но не оптимизируем                       |
| 5 | ✓ Поэтапная раскатка и быстрый откат?        | Ввести канареечную фазу или лестницу самостоятельности до полной раскатки — это ось обратимости из триады |
| 6 | ✓ Эскалация к человеку гарантирована?        | Спроектировать эскалацию как архитектуру с первого дня, а не как функцию после инцидента                  |
| 7 | ✓ Кто отвечает за результат?                 | Назначить владельца и записать финансовый показатель до запуска                                           |
| 8 | ✓ Данные безопасны?                          | Обезличить регулируемые поля или перейти на собственный контур до подключения внешнего инструмента        |

**Хотя бы одно «нет» не значит «не применять ИИ» — значит «закрыть разрыв до, а не после»: для подходящей задачи чек-лист осознанно приведёт к высокой самостоятельности.**

## Метод переносится, а не список инструментов: код был первым полигоном, продукт — вторым



*Инженер за рабочей станцией САПР со световым пером, конец 1970-х: инструмент исчез — дисциплина проектирования осталась*

**Курс не учит «применяйте ИИ больше» и не учит «бойтесь ИИ» — он учит говорить обоснованное «да» и обоснованное «нет».**

### Семинар 7

Полный прогон аппарата на учебном AI-продукте: от гипотезы до точки эскалации к человеку.

### Лекция 6

Тот же метод в инженерном проектировании и CAD/CAM — там цена физической ошибки выше.

## Вопросы?