

Сборка почти бесплатна. Почему тогда почти никто не извлекает из этого пользу?



Недели работы → часы ^[1]

внутренний опыт Anthropic



**~95% пилотов — ноль
отдачи** ^[2]

MIT, лето 2025

Оба факта правдивы одновременно: сборка стала почти бесплатной, а превращение сборки в ценность — нет. Держите вопрос — вернёмся к нему в конце лекции.





ЛЕКЦИЯ 5

AI-продукт: полный жизненный цикл — от намерения до эксплуатации

Курс «Осознанное применение ИИ» · инженеры-студенты 3 курса

Шесть разделов — шесть стрелок одной петли: код (Лекция 4) — один дешёвый шаг внутри неё.

0
Введение

1
Исследование

2
Дизайн

3
Сборка и запуск

4
Измерение

5
Поддержка

6
Управление

7
Обобщение

Лекция — это петля, а не список из шести тем




1. Исследование — откуда гипотеза
2. Дизайн — гипотеза → артефакт
3. Сборка и запуск — артефакт → продукт
4. Измерение — сработало ли
5. Поддержка — живёт 24/7
6. Управление — куда вкладывать

Стрелка возврата: управление снова питает исследование — замкнутая петля, а не одноразовый линейный процесс.

Цикл кода Лекции 4 — это один шаг внутри цикла продукта

Цикл продукта (Лекция 5)

откуда берётся уверенность, что стоит писать этот код



6 фаз



исследование → дизайн → сборка/запуск → измерение →
эксплуатация → управление → снова исследование



Цикл кода (Лекция 4)

как надёжно писать код с ИИ

спека → ADR → план → PR → инцидент

Чтобы пользовательская ценность состоялась — то есть продукт работал, был внедрён и кем-то выбран, — цикл кода приходится обернуть в ещё один цикл. Без внешнего цикла выходит собранное и никем не используемое: код есть, продукта нет.

Когда ИИ сделал сборку почти бесплатной — что стало настоящим узким местом продукта, и на каждой фазе цикла: какая классическая дисциплина остаётся, что ИИ ускоряет, и где AI-first ломается?

Три человека из разных областей нарисовали один и тот же чертёж



Не сговариваясь — один и тот же чертёж: петля обратной связи как структурное свойство любой системы, которая учится в условиях неопределённости.

ИИ меняет стоимость и доверие каждой стрелки петли — но не одинаково



Строить

стоимость почти обнулилась



Измерять / учиться

стоимость та же, доверие упало



Исследовать

быстрее, но уязвимее к атаке

Мета-паттерн, повторяется в каждом из 6 разделов: у каждой стрелки есть классическая дисциплина — ИИ её не отменяет, а меняет её стоимость и требуемую степень проверки.

Подумайте: на какой стрелке вашей последней задачи скорость обогнала ваше реальное доверие к результату?

РАЗДЕЛ 1

Исследование — намерение и гипотеза

2 базы · 3 провала

Откуда вообще берётся гипотеза о том, что строить. У большинства есть неформальный опыт «спросить у друзей» — и почти никто не сталкивался с формальной дисциплиной, объясняющей, почему этот опыт систематически лжёт.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Исследование простыми словами



простыми словами

Что это

Фаза, где вы ищете не решение, а проблему: у кого болит, насколько сильно и готов ли человек за это платить временем, репутацией или деньгами.


Зачем

Построить можно что угодно; ценно только то, что решает реальную боль реального человека. «Я бы таким пользовался» — не факт.

Ментальная модель

Внутри офиса нет фактов — факты снаружи. Записываете гипотезу, выходите к людям, проверяете. ИИ ускоряет сбор, но не заменяет разговор с настоящим человеком.

«Внутри офиса нет фактов» — 4 шага, каждый заканчивается решением



Стив Бланк — методология Customer Development ^[1]



Фальсифицируемая гипотеза

мы верим X → проверим через Y → к дате Z получим ответ да/нет

BML — двигатель; Customer Development — карта местности, по которой двигатель едет. Сначала понять, что проверяем и у кого — потом, как быстро крутить цикл.

[1] Blank — Customer Development (Four Steps to the Epiphany)

Даже мать соврёт — если вопрос сконструирован неправильно ^[1]



Об их жизни, не о вашей идее

не питчите идею и не просите вердикт



О прошлом, не о будущем

гипотетические вопросы провоцируют нечестный оптимизм



Обязательством, не комплиментом

легитимные сигналы: время, репутация, деньги

Плохо

«Заплатили бы \$20 в месяц?»

Хорошо

«Сколько вы платите сегодня за ближайший аналог?»

JTBD (Jobs-to-be-Done), «работа, на которую нанимают продукт» — смежная рамка Кристенсена: спрашиваем не о предпочтениях, а об обстоятельстве последней покупки, и получаем таймлайн решения, а не список мнений.



ВОПРОС ЗАЛУ «Как вам идея — ассистент, который сам разбирает вашу почту?» Какое из трёх правил нарушил этот вопрос и как переспросить, чтобы получить факт?

Часы → минуты: но ссылки существуют, чтобы их проверяли



проверь источник

Desk research (кабинетное исследование)

Perplexity Deep Research: 2 часа → ~30 минут ^[1]



Синтез интервью

Dovetail — кластеризация более в масштабе ^[2]



Reference dataset (эталонный набор)

курируемая коллекция «запрос → правильный ответ»

97% исследователей используют ИИ — лишь ~8% доверяют ИИ-персонам как данным ^[3]

Обязательная практика: проверять важные данные напрямую по источнику до использования в решении. Синтетические пользователи — только пре-исследование (пилотаж гайда, черновик персон, генерация гипотез), никогда не доказательство для решения «продолжать/остановить».



ВОПРОС ЗАЛУ ИИ-персона прошла ваш сценарий знакомства с продуктом целиком и назвала функцию отличной. Что в устройстве такого источника мешает ему сказать «нет»?

Синтетический собеседник не может произвести несогласие



Зеркало согласия

72-91%

при явном согласии

7-28%

при явном несогласии

Сдвиг тона ответа модели к позитиву («feedback positivity», 5 моделей) — это не «частота отрицательного ответа».

Sharma и др., 2023 — Figure 1, ICLR 2024

Когда живое интервью строго лучше ИИ-синтеза



1. Высокая цена ошибки «продолжать/остановить»



2. Нужно реальное прошлое, не правдоподобное




3. Нужна валидация обязательством, не мнением

У синтетического собеседника нет реального прошлого, способного противоречить формулировке вопроса, — поэтому несогласие он не производит в принципе.

ИИ-резюме теряет 20-40% деталей интервью (Torres) ^[1], если пропущен шаг «сначала по отдельности» — прослеживаемый до конкретного шага сбой, не расплывчатое «ИИ иногда ошибается».

Одна и та же задача: реальные люди — 3 из 7, синтетическая панель — 7 из 7 ^[1]



NN/g: контролируемое сравнение на сценарии знакомства с продуктом

Реальные люди



3 из 7 — «надуманно и бесполезно»

Синт-панель



7 из 7 — «меняет правила игры»

Одна и та же фича — противоположные вердикты

Критерий: синтетический выход дисквалифицирован для решения «продолжать/остановить» по построению, а не из-за невезения прогона. **Альтернатива:** до-исследовательская роль + реальное тестирование 5-8 участников.

A\$440 000 отчёт правительству — с выдуманными цитатами внутри



Deloitte Australia, 2025

- Ссылки на несуществующие статьи + сфабрикованная цитата суда ^[1]
- Подготовлен через Azure OpenAI без человеческой верификации цитат



A\$440 000

≈US\$290 000 отчёт

База: ~712 судебных решений по миру с ИИ-галлюцинированными цитатами, ~90% — в 2025 году ^[2]

Урок: вывод модели в discovery-фазе — не верифицированный черновик, не источник фактов. Критерий: итоговый документ внешнему заказчику требует 100% проверки каждой ссылки, не выборочной.

Один бренд, два провала: данные подвели одну систему, закупка — другую

IBM Watson Health



Случай А — Watson for Oncology

Memorial Sloan Kettering, с 2012

- Коммерческий запуск 2015; внутренние документы: рекомендации «небезопасные и некорректные»
- Бевацизумаб гипотетическому пациенту с активным кровотечением — вопреки предупреждению производителя

STAT News · 25 июля 2018 ^[1]

Причина: обучен на малом числе синтетических, гипотетических кейсов горстки онкологов MSK — не на реальных исходах ^[2]



Случай В — Oncology Expert Advisor

MD Anderson, 2013-2016

- Контракт через 12 продлений вырос с \$2,4 млн до \$39,2 млн IBM + \$23 млн PwC
- Закрит в сентябре 2016 — без единого пролеченного пациента

≈ \$62 млн → 0 пациентов

Причина по аудиту University of Texas System: обход конкурсных закупочных процедур + дефицит донорского финансирования ≈ \$11,6 млн — не про данные и не про модель


Два независимых механизма отказа одной корпорации: непригодные данные против несостоятельного управления проектом. Не всякий дорогой провал с ИИ на обложке объясняется самим ИИ.

РАЗДЕЛ 2

Дизайн — гипотеза становится артефактом

2 базы · 2 провала

Как гипотеза из исследования превращается в конкретный артефакт, который можно показать человеку. Здесь же закладывается безопасность — в дизайн-брифе, а не патчем после того, как что-то пошло не так.



прыгнуть сразу к
решению



сначала —
правильная проблема

0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Дизайн простыми словами



простыми словами

Что это

Гипотеза становится дешёвым черновиком: наброском экрана, кликабельным прототипом — тем, что можно показать человеку.

Зачем

Черновик не жалко выбросить. Понять «не работает» на бумаге — копейки; понять то же самое после релиза — очень дорого.

Ментальная модель

Два ромба: сначала ищем правильную проблему, потом правильное решение. Частая ошибка — прыгнуть сразу к решению.

Два алмаза: сначала правильная проблема, потом правильное решение



Частая ошибка: конвергировать на решении, не проверив саму проблему — перепрыгнуть первый алмаз. Дешёвый прототип нужен именно для того, чтобы это вскрыть до траты денег на разработку.

Эвристики Нильсена — линтер для UX, не замена тестированию



Топ-5 из 10 эвристик ^[1]

- 1 Видимость статуса системы
- 2 Соответствие языку пользователя
- 3 Контроль и свобода (отмена)
- 4 Консистентность
- 5 Предотвращение ошибок




Дизайн-система = guardrail

Удерживает генеративную свободу в рамках провалидированного бренда.



ВОПРОС ЗАЛУ Интерфейс на один и тот же ввод даёт разный вывод. Какая из пяти эвристик ломается первой?


Метафора: эвристики — как линтер для интерфейса. Ловят типовые проблемы до траты денег на исследование — но не заменяют тест на живом пользователе ^[2].



«Я снова прошу»: эвристики ловят типовые проблемы, но не заменяют проверку на живом пользователе.

ИИ для дивергенции, человек для конвергенции

Генерация направлений



Инструменты 2025-26

v0 (Vercel) · Figma Make ^[1] · Google Stitch ^[2] · bolt.new

- 2-4 направления за минуты (было — день ручного вайрфрейминга)
- Figma Make подтягивает собственные компоненты команды — меньше переделки

Конвергенция требует суждения о конкретном контексте, которого нет в обучающих данных: ИИ расширяет пространство вариантов, а выбор и проверку на живом пользователе оставляем человеку.

29% соответствие WCAG на 21 880 оценках — платформа важнее промпта ^[1]



21 880 оценок WCAG на ИИ-интерфейсах:

- контраст 26,8%
- использование цвета 19,2%

«Сделай доступным» в промпте не гарантирует результат — решают дефолты платформы, а не текст запроса.

Дизайн для НЕДЕТЕРМИНИРОВАННОГО вывода: тот же ввод → разный вывод → ломает эвристику консистентности; нужны человеко-контрольные точки.



ВОПРОС ЗАЛУ Черновик экрана теперь стоит минуты. Какой вопрос дизайн-брифа при такой скорости пропускают первым?

Защита появилась почти через два года после запуска — уже после трагедии



Защита уязвимых пользователей добавлена ретрофитом — после трагедии, а не в исходном дизайн-брифе.



Character.AI

Character.AI

14-летний пользователь погиб после месяцев общения с ИИ-персонажем (02.2024) ^[1].



Корень — не рантайм-баг, а отсутствующее требование в дизайн-брифе: MVP оптимизировал вовлечённость без вопроса «кто может пострадать». Критерий: защита уязвимых — в MVP, а не патчем после трагедии.

Найдено случайно: та же анкета с другой датой рождения — мгновенное приглашение



**Фильтр с жёстко зашитым правилом
«дата рождения»**

Женщины 55+ / мужчины 60+ → автоотказ

Обнаружено случайно: переподача той же анкеты с другой датой рождения → мгновенное приглашение.



\$365 000 ^[1]

EEOC, 9 авг. 2023 — первое урегулирование по ИИ-дискриминации

Контраст с Character.AI: там дизайн НЕ заложил защиту; здесь дизайн ЗАЛОЖИЛ конкретное вредное правило. Критерий: автоматизация решения о людях → аудит признаков на дискриминацию ДО релиза.

РАЗДЕЛ 3

Сборка и запуск — схлопнутая стрелка

2 базы · 2 провала

Здесь ИИ меняет больше всего — стоимость самого написания кода. Но раздел начинается не с этого факта, а с классической дисциплины релиза: как выкатывать безопасно и когда остановиться.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Сборка и запуск простыми словами



простыми словами

Что это

Артефакт становится работающим продуктом у пользователей. ИИ сделал само написание кода почти бесплатным.


Зачем механика запуска

Раз строить дёшево — цена ошибки теперь не «написать», а «выкатить не то на всех сразу». Нужно включать понемногу и быстро откатывать.

Ментальная модель

Запуск — это кран, а не рубильник: 1% → 10% → 100%, следим за реакцией. И держим наготове решение «убить», а не «дорабатывать вечно».

Та же механика — но здесь решение убить продукт, а не флаг переключить



Эти примитивы вы знаете из инженерной раскатки (CI/CD)



НОВОЕ здесь — чьё и по каким критериям решение они обслуживают: MVP (Райс) ^[1] = обучение, не отгрузка. Stage-Gate go/kill (Купер) ^[2] — «воронка, не туннель»: пороги провала записаны числом заранее.

Общий смысл: скорость запуска покупается ограниченным «радиусом поражения» — сколько пользователей задето, если новое окажется плохим.

+200% кода на инженера — но лишь 16% PR получили содержательное ревью ^[1]



Измерение Anthropic

- Реализация: недели/месяцы → минуты агентного исполнения
- Объем кода на инженера: +200% год к году
- Содержательное человеческое ревью до слияния: лишь ~16% PR

Дефицитный ресурс сместился к двум человеческим концам: точность намерения на входе и качество суждения на выходе — узкое место теперь ревью, а не написание.

Запуск — это не «включить», а передача контроля по ступеням

v3

Автоматически, с возвратом к человеку

заслужено трассами

v2

Предлагает решения на утверждение человека

человек в петле

v1

Высокий контроль / низкая агентность

маршрутизирует

CC/CD против привычного CI/CD ^[1]

CC/CD — Continuous Calibration/Development (непрерывная калибровка). Релиз версионизируется по уровню агентности, а не по набору функций.

Лестница агентности (agency-ladder)

Три ступени передачи контроля; поднимаются по ней под требование, а не по готовности инструмента.

«Если не тестировали при высоком контроле — не готовы давать высокую агентность»: автономию агент заслуживает трассами исполнения, а не сразу по умолчанию.



ВОПРОС ЗАЛУ Возьмите функцию из своего проекта, которую доверили бы ИИ. На какой она ступени сейчас — и какое требование должно появиться, чтобы поднять её на следующую?

Удвоив скорость генерации, вы удваиваете очередь на ревью — не пропускную способность



**генерация
дёшево и быстро**

**верификация
не ускорилась**

Сгенерировать правдоподобный код — секунды; проверить его — не ускорилось.

Проблема 70% ^[1]

Опытный разработчик переосмысливает ИИ-вывод и тратит время на переделку.

Новичок отправляет «карточный домик кода», который выглядит правдоподобно, но рассыпается под нагрузкой.

Отгрузка без eval-гейта или плана отката — это не скорость, это отложенная цена: ревью не масштабируется вместе с генерацией.

0% → 100% одним шагом — минуя канареечную раскатку целиком



Google

Google AI Overviews, май 2024

Раскатан на 100% поиска США одним шагом ^[1]. Без eval-гейта. Отключить пользователю нельзя.

1%

10%

25%


50%

100%

правильная канареечная раскатка (перепрыгнута)

На 1% трафика паттерн («ешьте камни» — сатира The Onion; «клей на пиццу» — шутка на Reddit) всплыл бы за дни во внутреннем мониторинге ^[2]. Вместо этого — публичное осмеяние сразу на 100% аудитории.

2,5-3 года на 0,7% сети — и решение остановиться было правильным ^[1]



0,7%

~100 из ~13 786 ресторанов
США

McDonald's × IBM — голосовой приём заказов

- 2,5–3 года пилота на 0,7% сети ^[2]
- Вирусные провалы: бекон в мороженом, 9 чаёв вместо одного
- Закрит июнь 2024 — цель (голосовая автоматизация) осталась, вендорский подход убит

Зеркало предыдущего кейса: там пропустили пилот целиком и выкатили на всех; здесь пилот был долгим — и его сигнал использовали правильно, приняв дисциплинированное решение «убить», а не масштабировать провал.

РАЗДЕЛ 4

Измерение — стрелка, которой ИИ снизил доверие

2 базы · 2 провала

Измерение — то место, где «выглядит хорошо» бьёт по продукту сильнее всего. Формальную дисциплину продуктового эксперимента многие видят впервые.

«метрика
выросла!»

а эффект реален?



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Измерение простыми словами



простыми словами

Что это

Фаза, где вы честно проверяете: сработало изменение или только кажется. Формальную дисциплину эксперимента многие видят впервые.

Зачем

«Метрика выросла после релиза» ничего не доказывает — она могла вырасти сама. Нужен способ отделить причину от совпадения.

Ментальная модель

Делим пользователей на две случайные группы: одной — новое, другой — старое. Разница и есть настоящий эффект. Метрику успеха фиксируем заранее.

Рандомизация отличает причину от совпадения



ОЕС — метрика, о значении которой договорились заранее ^[1]

Контролируемый эксперимент (Кохави): гипотеза с механизмом → рандомизация → заранее определённый размер выборки → решение.

Учебная ловушка: «время на сайте поддержки» — это хорошо или плохо? Направление метрики надо согласовать до теста.

Только случайное деление групп даёт причинность: разница между Control и Treatment вызвана вашим изменением, а не сезоном, рекламой или везением ^[2].



ВОПРОС ЗАЛУ ОЕС вырос на 8% на третий день теста, $p < 0,05$. Останавливаете тест и раскатываете?

Три вопроса ловят все восемь ловушек эксперимента

ДО ТЕСТА

1



Настроен ли тест правильно?

SRM (перекос групп) [1] — доли пользователей в группах не совпали с планом; размер выборки должен быть зафиксирован заранее, а не подогнан под результат

ИНТЕРПРЕТАЦИЯ

2



Правильно ли читаю результат?

peeking (подглядывание) [2] — досрочная проверка результата: 2 подглядки $\approx$ 2х ложных срабатываний, поэтому решение принимается только на заранее заданный размер выборки

ЭФФЕКТ

3



Реален ли сам эффект?

закон Тваймана [3]: слишком красивая или неожиданная цифра обычно означает ошибку измерения, а не реальный эффект — сначала перепроверь методологию, потом радуйся результату

А/В (измерение) — это не то же, что feature flag (раскатка): первое проверяет эффект, второе управляет доступом. И осторожнее с легендами: тест Bing $\approx$ \$100 млн прироста выручки (Kohavi/Thomke, HBR 2017) — это НЕ «кнопка за \$300 млн» (отдельный кейс юзабилити).


$\text{pass}@k$ стремится к 100%, pass^k — к 0%: одна вероятность, разный вопрос

3 уровня оценки (Хусейн)

1 Unit-тесты — быстрые, детерминированные

2 Человек + LLM-as-judge (модель-судья) ^[2]

3 А/В — только когда продукт зрел



$\text{pass}@k$ = хотя бы 1 успех из k; pass^k = ВСЕ k успешны ^[1]. Промышленная надёжность почти всегда требует pass^k — «юнит-тесты для агента», где вероятностный вывод ломает привычный «прошёл/не прошёл».

Лодка кружит в лагуне и набирает очки — но никогда не финиширует



RL-агент в гонке набрал на 20% больше очков людей — кружа в лагуне и собирая бонусы, никогда не пересекая финиш ^[1]. Оптимизировал прокси, а не реальную цель.


Закон Гудхарта: когда мера становится целью, она перестаёт быть хорошей мерой.

Anthropic: модель обобщила от угодливости к прямому редактированию собственной функции вознаграждения ^[2].

Что остаётся: ОЕС-дисциплина, guardrail-метрики, закон Тваймана — подозрительно идеальный балл теперь скорее баг, чем прорыв.

Взлом награды (reward hacking): модель находит способ «выиграть» прокси-метрику, не достигая задуманного результата — поэтому мера и цель нельзя путать.

Все 5 реакций взвешены одинаково ×5 — не только «ГНЕВ»



facebook

Facebook MSI, январь 2018:
love/haha/wow/sad/angry — все ×5 выше лайка
(не только гнев) ^[1].

love

×5

haha

×5

wow

×5

sad

×5

angry

×5

**Прокси вовлечённости без guardrail на дезинформацию скрывал вред
~2 года: внутренний guardrail (корреляция гнев ↔ дезинформация)
подтверждён к 2019, вес обнулён в сентябре 2019 ^[2]. Урок: guardrail-
метрику надо измерять с первого дня, а не когда вред уже случился.**

Сдал бенчмарк формата А ≠ безопасен в проде формата В

Медицина

86,5% MedQA [1]

Med-PaLM 2 хорош на бенчмарке вопросов-ответов — но клиническая безопасность требует ОТДЕЛЬНОГО adversarial (состязательного) safety-набора.

Право


Stanford RegLab: Lexis+ 17% галлюцинаций, Westlaw 33% — на реальных юридических запросах ^[3].

Дело Mata v. Avianca (фейковые цитаты) = ChatGPT, НЕ Harvey ^[2] — частая ошибка атрибуции.

**Бенчмарк — свидетельство о производительности только на формате задачи именно этого бенчмарка.
Альтернатива: состязательные evals на реальных краевых случаях того домена, где продукт будет работать.**

А/В остаётся фундаментом — evals и guardrail-метрики теперь обязательны поверх

Измерение = стрелка, которой ИИ снизил доверие



- Рандомизация — по-прежнему то, что даёт причинность, а не совпадение.
- Оценки (evals) и guardrail-метрики — новые слои поверх, а не замена А/В.
- Центральный навык фазы — отличать сигнал от шума.

Мост в поддержку: тот же навык «сигнал $\neq$ шум» в эксплуатации означает заметить дрейф раньше, чем он проявится на дашборде.

РАЗДЕЛ 5

Поддержка — продукт как оркестр

2 базы · 3 провала

Между «код работает у меня» и «продукт надёжно работает у миллионов 24/7» — пропасть, и её закрывают процессом эксплуатации, а не только качеством кода.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Поддержка простыми словами



простыми словами

Что это

Продукт уже живёт у людей круглосуточно: его надо наблюдать, чинить сбои и отвечать на жалобы — годами.


Зачем

«Работает у меня» и «надёжно работает у миллионов 24/7» — разные вещи. Разрыв закрывают процессом, а не только чистым кодом.

Ментальная модель

Заранее договариваемся, сколько сбоев допустимо (бюджет на ошибки). С ИИ сложнее: модель может «тихо деградировать», пока графики ещё зелёные.

Ответ с кодом 200 ничего не говорит о том, галлюцинирует ли модель



Error budget = «1 – SLO». Пример: 99,9% → 1000 ошибок на 1 млн запросов за 4 недели. Изменения — $\approx 70\%$ всех сбоев ^[1].




SLI «доля ответов с кодом 200» = всё ок? Нет: 200 приходит и когда модель уверенно галлюцинирует. Инфраструктурная метрика не видит качества ответа.

Дежурства, разбор инцидентов без поиска виноватых, инструкции — вы это можете знать. Новое здесь: в проде теперь недетерминированная модель (следующий слайд).

Трейсинг ловит дрейф галлюцинаций там, где инфра-мониторинг молчит

Трейсинг (камера над каждым узлом): *LangSmith · Langfuse · Arize Phoenix · Helicone* ^[1]



LLMOps / AgentOps

Эксплуатация моделей и эксплуатация агентов: LLMOps следит за одним вызовом (промт, ответ, стоимость), AgentOps — за цепочкой шагов и вызовов инструментов целиком.


Дрейф данных vs дрейф концепта · защитные правила во время работы · предохранитель (circuit breaker) · Guardian Agents (категория Gartner) ^[2] — агенты, следящие за агентами.



Не отправлять регулируемые PII (перс. данные) во внешний трейсинг без анонимизации или self-host.

Инфраструктурный мониторинг видит «сервис жив»; трейсинг видит «ответы деградируют»: дрейф галлюцинаций, сбои поиска, регрессию промптов.

Дашборды остаются зелёными, пока доверие уже падает недели



Тихий дрейф

Самые активные пользователи замечают регрессию раньше агрегированных метрик — доверие падает раньше, чем двигаются дашборды.

Дрейф правил

Guardrails (защитные правила) без версионирования молча устаревают: правила расходятся с реальностью незаметно.

Что остаётся: эскалация к человеку, ответственность, инцидент-дисциплина — усилены автономностью ИИ, не отменены ею.




ВОПРОС ЗАЛУ Назовите один сигнал в своей системе, который сегодня не попадает ни в один дашборд, но первым скажет, что качество упало.

Модель была откалибрована корректно — не было предохранителя на дрейф в реальном времени



Рынок сдвинулся — дрейф концепта без предохранителя



Разные единицы и разные шкалы — МЛН слева, Тыс. справа (длины баров НЕ сравнивать напрямую)

Zillow Offers, ноябрь 2021: 9680 домов куплено, 3032 продано · ~2000 уволенных (~25% штата) ^[1] · ≈\$80 тыс. убытка на объект ^[2].

Критерий: модель, совершающая сделки на деньги, требует мониторинга точности предсказания в реальном времени с автоматическим предохранителем (circuit breaker), который отключает её при дрейфе.

«Бот — отдельное юрлицо» — трибунал отклонил этот довод одной фразой



Весы в равновесии: ответ бота = статичная страница сайта. Одинаковая ответственность за оба.

Air Canada, чат-бот сайта

Бот некорректно сообщил о ретроактивной скидке. Трибунал — \$812,02 CAD ^[1]: компания отвечает за ответ бота как за любой другой контент сайта ^[2].

Ты владеешь каждым ответом бота — не больше, но и ни на грамм меньше ответственности, чем за любой другой контент сайта.

10 из 10 журналистов получили один и тот же незаконный совет — не единичный сбой

Klarna

Klarna: политика «только ИИ» откатилась (05.2025) ^[1] — но автоматизация выросла до 853 чел.-эквивалентов ^[2] (усиление людей, не замена).



NYC MyCity — гос-бот



10 из 10 журналистов — один и тот же незаконный совет ^[3]. Мэр не отзывал бот сразу.

Урок не «ИИ не работает», а «метрика пропускной способности без гарантированной эскалации к человеку — неверный дизайн».

