

Сборка почти бесплатна. Почему тогда почти никто не извлекает из этого пользу?



Недели работы → часы ^[1]

внутренний опыт Anthropic




~95% пилотов — ноль
отдачи ^[2]

MIT, лето 2025

Оба факта правдивы одновременно: сборка стала почти бесплатной, а превращение сборки в ценность — нет. Держите вопрос — вернёмся к нему в конце лекции.





ЛЕКЦИЯ 5

AI-продукт: полный жизненный цикл — от намерения до эксплуатации

Курс «Осознанное применение ИИ» · инженеры-студенты 3 курса

Шесть разделов — шесть стрелок одной петли: код (Лекция 4) — один дешёвый шаг внутри неё.

0
Введение

1
Исследование

2
Дизайн

3
Сборка и запуск

4
Измерение

5
Поддержка

6
Управление

7
Обобщение

Лекция — это петля, а не список из шести тем




1. Исследование — откуда гипотеза
2. Дизайн — гипотеза → артефакт
3. Сборка и запуск — артефакт → продукт
4. Измерение — сработало ли
5. Поддержка — живёт 24/7
6. Управление — куда вкладывать

Стрелка возврата: управление снова питает исследование — замкнутая петля, а не одноразовый линейный процесс.

Цикл кода Лекции 4 — это один шаг внутри цикла продукта

Цикл продукта (Лекция 5)

откуда берётся уверенность, что стоит писать этот код



6 фаз



исследование → дизайн → сборка/запуск → измерение →
эксплуатация → управление → снова исследование



Цикл кода (Лекция 4)

как надёжно писать код с ИИ

спека → ADR → план → PR → инцидент

Чтобы пользовательская ценность состоялась — то есть продукт работал, был внедрён и кем-то выбран, — цикл кода приходится обернуть в ещё один цикл. Без внешнего цикла выходит собранное и никем не используемое: код есть, продукта нет.

Когда ИИ сделал сборку почти бесплатной — что стало настоящим узким местом продукта, и на каждой фазе цикла: какая классическая дисциплина остаётся, что ИИ ускоряет, и где AI-first ломается?

Три человека из разных областей нарисовали один и тот же чертёж



Не сговариваясь — один и тот же чертёж: петля обратной связи как структурное свойство любой системы, которая учится в условиях неопределённости.

ИИ меняет стоимость и доверие каждой стрелки петли — но не одинаково



Строить

стоимость почти обнулилась



Измерять / учиться

стоимость та же, доверие упало



Исследовать

быстрее, но уязвимее к атаке

Мета-паттерн, повторяется в каждом из 6 разделов: у каждой стрелки есть классическая дисциплина — ИИ её не отменяет, а меняет её стоимость и требуемую степень проверки.

Подумайте: на какой стрелке вашей последней задачи скорость обогнала ваше реальное доверие к результату?

РАЗДЕЛ 1

Исследование — намерение и гипотеза

1 база · 2 практики · 2 провала

Откуда вообще берётся гипотеза о том, что строить. У большинства есть неформальный опыт «спросить у друзей» — и почти никто не сталкивался с формальной дисциплиной, объясняющей, почему этот опыт систематически лжёт.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка


6

Управление

7

Обобщение

«Внутри офиса нет фактов» — 4 шага, каждый заканчивается решением



Стив Бланк — методология Customer Development ^[1]



Фальсифицируемая гипотеза

мы верим X → проверим через Y → к дате Z получим ответ да/нет

BML — двигатель; Customer Development — карта местности, по которой двигатель едет. Сначала понять, что проверяем и у кого — потом, как быстро крутить цикл.

[1] Blank — Customer Development (Four Steps to the Epiphany)

Часы → минуты: но ссылки существуют, чтобы их проверяли



проверь источник

Desk research (кабинетное исследование)

Perplexity Deep Research: 2 часа → ~30 минут ^[1]



Синтез интервью

Dovetail — кластеризация более в масштабе ^[2]



Reference dataset (эталонный набор)

курируемая коллекция «запрос → правильный ответ»

97% исследователей используют ИИ — лишь ~8% доверяют ИИ-персонам как данным ^[3]

Обязательная практика: проверять важные данные напрямую по источнику до использования в решении. Синтетические пользователи — только пре-исследование (пилотаж гайда, черновик персон, генерация гипотез), никогда не доказательство для решения «продолжать/остановить».



ВОПРОС ЗАЛУ ИИ-персона прошла ваш сценарий знакомства с продуктом целиком и назвала функцию отличной. Что в устройстве такого источника мешает ему сказать «нет»?

Панель субагентов правит гайд интервью — и ничего не говорит о продукте

МЕХАНИЗМ

- 1 Персона — **отдельный файл-агент со своим контекстным окном**, а не абзац внутри общего диалога: субагенты не видят ответов друг друга и не сходятся незаметно к одному голосу.
- 2 Профиль пишется в формате JTBD — работы, ради которой продукт нанимают: что делал перед тем, как начал искать решение; чем пользуется сейчас; во что обходится в часах и деньгах; что попробовал и бросил. Не «Анна, 34, любит удобные интерфейсы».
- 3 Один и тот же гайд прогоняется через всех персон.
- 4 Смотрят на **две производные**, а не на содержание ответов: вопрос с одинаковым ответом у всех ничего не различает — переписать; ответ гипотетическим будущим («я бы этим пользовался») нарушает правило спрашивать о конкретном прошлом — переписать.

АРТЕФАКТ

```
research/
  personas/
    b2b-ops-lead.md      # файл на персону,
    solo-founder.md      # версионирован
    guide.md             # v1 → v2; в диффе видно,
                        # какой вопрос и по какому сигналу
```



КРИТЕРИЙ

Доля переписанных вопросов видна диффом · доля вопросов «одинаковый ответ у всех» падает от версии к версии · пилотное живое интервью по правленому гайду даёт таймлайн «первая мысль — почти-решение — отказ — выбор», а не список предпочтений.

ГРАНИЦА

Ни один ответ персоны не идёт в решение и не цитируется как данные: наружу выходит только правленный гайд. Отдельное окно даёт изоляцию, но не независимость — веса и распределение те же, поэтому пять субагентов дают пять коррелированных выборок, а не пять человек. Сверка с реальным опросом: средние воспроизводятся, разброс схлопывается — отклонение 16 против 31 у живых. Неправильный запуск виден по выводу о продукте.

ОПОРА НА ПРОЙДЕННОЕ Лекция 3 — субагент как отдельный слот со своей ценой настройки: для короткого гайда эта цена не окупается.

ВОПРОС ЗАЛУ Вы прогнали гайд интервью через пять ИИ-персон. На один вопрос все пять ответили почти одинаково. Что это говорит — про продукт или про вопрос? И что вы меняете?

Три шага по корпусу обращений — и ни одной гипотезы без трёх дословных цитат

МЕХАНИЗМ



1. ИНДЕКСАЦИЯ

Один тикет — один фрагмент с обязательными метаданными: дата, продукт, сегмент, канал, признак повторного обращения. Без них корпус — мешок текста: не отфильтровать ни устаревшее, ни нерелевантное.



2. ИЗВЛЕЧЕНИЕ

Гибридный поиск — лексический BM25 плюс плотные векторные представления — с переранжированием. Чисто векторный поиск по тикетам плохо ловит коды ошибок и номера заказов.



3. КЛАСТЕРИЗАЦИЯ

Фрагменты группируются в темы боли, к каждому кластеру — двухшаговый синтез: сначала каждый тикет по отдельности, потом между тикетами. Пропуск первого шага — потеря 20–40% детали.

АРТЕФАКТ

Одна таблица — и в ней гипотеза не существует без прослеживаемости до тикета:

Кластер	Тикетов	Цитаты с номером	Гипотеза «вера — тест — дата»	К какому сегменту идти живьём
тема боли	N	#___ · #___ · #___	вера — тест — дата	сегмент

КРИТЕРИЙ

Каждая гипотеза прослеживается минимум до **трёх дословных цитат с номером тикета** · кластер без цитаты — артефакт модели, а не боль клиента, и вычёркивается · дальше уходит только гипотеза с записанным порогом.

ГРАНИЦА

Корпус смещён по построению, а не по недосмотру: в нём есть только те, кто дошёл до жалобы. Объём этого не лечит — сто тысяч тикетов смещены ровно так же, как тысяча, потому что не бывает тикета «мне нужно то, чего у вас вообще нет». Вопрос «чего у нас нет» закрывается другим инструментом — интервью с теми, кто отвалился. И второе: извлечение возвращает похожие обращения, а не важные. Десять тысяч жалоб на опечатку — это по-прежнему одна опечатка.



кто дошёл до жалобы



все пользователи



корпус обращений

ОПОРА НА ПРОЙДЕННОЕ Лекция 2 — векторные представления и кластеризация. Лекция 3 — поиск с дополнением генерации: метаданные, свежесть, гибридное извлечение, «вернул что-то не значит вернул правильное».

Синтетический собеседник не может произвести несогласие



Зеркало согласия

72-91%

при явном согласии

7-28%

при явном несогласии

Сдвиг тона ответа модели к позитиву («feedback positivity», 5 моделей) — это не «частота отрицательного ответа».

Sharma и др., 2023 — Figure 1, ICLR 2024

Когда живое интервью строго лучше ИИ-синтеза



1. Высокая цена ошибки «продолжать/остановить»



2. Нужно реальное прошлое, не правдоподобное




3. Нужна валидация обязательством, не мнением

У синтетического собеседника нет реального прошлого, способного противоречить формулировке вопроса, — поэтому несогласие он не производит в принципе.

ИИ-резюме теряет 20-40% деталей интервью (Torres) ^[1], если пропущен шаг «сначала по отдельности» — прослеживаемый до конкретного шага сбой, не расплывчатое «ИИ иногда ошибается».

Одна и та же задача: реальные люди — 3 из 7, синтетическая панель — 7 из 7 ^[1]



NN/g: контролируемое сравнение на сценарии знакомства с продуктом

Реальные люди

✓✓✓ X X X X 3 из 7 — «надуманно и бесполезно»

Синт-панель

✓✓✓✓✓✓✓ 7 из 7 — «меняет правила игры»

Одна и та же фиша — противоположные вердикты

Критерий: синтетический выход дисквалифицирован для решения «продолжать/остановить» по построению, а не из-за невезения прогона. Альтернатива: до-исследовательская роль + реальное тестирование 5-8 участников.

Один бренд, два провала: данные подвели одну систему, закупка — другую

IBM Watson Health



Случай А — Watson for Oncology

Memorial Sloan Kettering, с 2012

- Коммерческий запуск 2015; внутренние документы: рекомендации «небезопасные и некорректные»
- Бевацизумаб гипотетическому пациенту с активным кровотечением — вопреки предупреждению производителя

STAT News · 25 июля 2018 ^[1]

Причина: обучен на малом числе синтетических, гипотетических кейсов горстки онкологов MSK — не на реальных исходах ^[2]



Случай В — Oncology Expert Advisor

MD Anderson, 2013-2016

- Контракт через 12 продлений вырос с \$2,4 млн до \$39,2 млн IBM + \$23 млн PwC
- Закрит в сентябре 2016 — без единого пролеченного пациента

≈ \$62 млн → 0 пациентов

Причина по аудиту University of Texas System: обход конкурсных закупочных процедур + дефицит донорского финансирования ≈ \$11,6 млн — не про данные и не про модель


Два независимых механизма отказа одной корпорации: непригодные данные против несостоятельного управления проектом. Не всякий дорогой провал с ИИ на обложке объясняется самим ИИ.

РАЗДЕЛ 2

Дизайн — гипотеза становится артефактом

1 база · 1 практика · 1 провал

Как гипотеза из исследования превращается в конкретный артефакт, который можно показать человеку. Здесь же закладывается безопасность — в дизайн-брифе, а не патчем после того, как что-то пошло не так.



прыгнуть сразу к
решению



сначала —
правильная проблема

0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение


Два алмаза: сначала правильная проблема, потом правильное решение



Частая ошибка: конвергировать на решении, не проверив саму проблему — перепрыгнуть первый алмаз. Дешёвый прототип нужен именно для того, чтобы это вскрыть до траты денег на разработку.

ИИ для дивергенции, человек для конвергенции

Генерация направлений



Инструменты 2025-26

v0 (Vercel) · Figma Make ^[1] · Google Stitch ^[2] · bolt.new

- 2-4 направления за минуты (было — день ручного вайрфрейминга)
- Figma Make подтягивает собственные компоненты команды — меньше переделки

Конвергенция требует суждения о конкретном контексте, которого нет в обучающих данных: ИИ расширяет пространство вариантов, а выбор и проверку на живом пользователе оставляем человеку.

Три слоя дизайн-системы — контролем является только третий

МЕХАНИЗМ



3. ГЕЙТ В СБОРКЕ

Экран прогоняется движком проверки доступности (axe-core, pa11y, Lighthouse) с порогом, записанным числом заранее. Нарушение останавливает сборку. **Ни один из трёх движков не является ИИ-инструментом, и это часть урока.**



2. СВОИ КОМПОНЕНТЫ

Генератору подаются собственные компоненты команды, а не общие шаблоны: меньше переделки — но это **снижение вероятности, не гарантия**.




1. ТОКЕНЫ


Машиночитаемый файл, а не картинка в макете: пары «фон/текст» с посчитанным контрастом, размеры целей нажатия, состояния фокуса.

АРТЕФАКТ

```
design/tokens.json    # контрасты и размеры
                     # посчитаны, а не заявлены
tests/ally/          # прогон на каждый экран
# + строка в критерии готовности:
#   экран не готов без зелёного гейта
```

Доля экранов, проходящих два худших измеренных критерия доступности, — оба проверяются машиной:

контраст  26,8%

использование цвета  19,2%

КРИТЕРИЙ

Доля сгенерированных экранов, проходящих гейт **с первого прогона**, растёт от итерации к итерации · нарушения по контрасту и использованию цвета уходят к нулю: оба детерминированно проверяемы машиной и не зависят от формулировки запроса.

ГРАНИЦА



Гейт ловит только машинно-проверяемое: контраст, подписи, размер цели нажатия, порядок перехода фокуса. Он не ловит «понятно ли это»: экран может пройти гейт целиком и остаться непонятным, поэтому приём не заменяет ни обзор по эвристикам, ни тест с 5-8 живыми людьми — он снимает с обоих то, что дешевле поймать машиной. И «попросите генератор сделать доступно» механизмом контроля не является: механизм — число, останавливающее сборку.

ОПОРА НА ПРОЙДЕННОЕ Лекция 4 — тест-инвариант как автоматический надзор: та же конструкция, применённая не к модулям, а к интерфейсу.



ВОПРОС ЗАЛУ Вы трижды написали генератору «сделай экран доступным» — и трижды получили экран, не проходящий проверку контраста. Почему четвёртая формулировка не поможет, и что тогда является механизмом контроля?

29% соответствие WCAG на 21 880 оценках — платформа важнее промпта ^[1]



21 880 оценок WCAG на ИИ-интерфейсах:

- контраст 26,8%
- использование цвета 19,2%

«Сделай доступным» в промпте не гарантирует результат — решают дефолты платформы, а не текст запроса.

Дизайн для НЕДЕТЕРМИНИРОВАННОГО вывода: тот же ввод → разный вывод → ломает эвристику консистентности; нужны человеко-контрольные точки.



ВОПРОС ЗАЛУ Черновик экрана теперь стоит минуты. Какой вопрос дизайн-брифа при такой скорости пропускают первым?

Защита появилась почти через два года после запуска — уже после трагедии



Защита уязвимых пользователей добавлена ретрофитом — после трагедии, а не в исходном дизайн-брифе.



Character.AI

Character.AI

14-летний пользователь погиб после месяцев общения с ИИ-персонажем (02.2024) ^[1].



Корень — не рантайм-баг, а отсутствующее требование в дизайн-брифе: MVP оптимизировал вовлечённость без вопроса «кто может пострадать». Критерий: защита уязвимых — в MVP, а не патчем после трагедии.

РАЗДЕЛ 3

Сборка и запуск — схлопнутая стрелка

1 база · 3 практики · 2 провала

Здесь ИИ меняет больше всего — стоимость самого написания кода. Но раздел начинается не с этого факта, а с классической дисциплины релиза: как выкатывать безопасно и когда остановиться.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка


6

Управление

7

Обобщение

Та же механика — но здесь решение убить продукт, а не флаг переключить



Эти примитивы вы знаете из инженерной раскатки (CI/CD)



НОВОЕ здесь — чьё и по каким критериям решение они обслуживают: MVP (Райс) ^[1] = обучение, не отгрузка. Stage-Gate go/kill (Купер) ^[2] — «воронка, не туннель»: пороги провала записаны числом заранее.

Общий смысл: скорость запуска покупается ограниченным «радиусом поражения» — сколько пользователей задето, если новое окажется плохим.

+200% кода на инженера — но лишь 16% PR получили содержательное ревью ^[1]



Измерение Anthropic

- Реализация: недели/месяцы → минуты агентного исполнения
- Объем кода на инженера: +200% год к году
- Содержательное человеческое ревью до слияния: лишь ~16% PR

Дефицитный ресурс сместился к двум человеческим концам: точность намерения на входе и качество суждения на выходе — узкое место теперь ревью, а не написание.

Степень автономии открывается доказательством — четыре пункта, которые предъявляют до перехода

МЕХАНИЗМ	Релиз версионруется по уровню контроля, а не по набору функций: в3 решает сам, с возвратом к человеку при затруднении в2 предлагает решение на утверждение человеку в1 маршрутизирует обращения тот же регулятор доверия в инструментах для кода: подсказка-завершение → блок кода → целый запрос на слияние	 ЧЕМ ОТКРЫВАЕТСЯ СЛЕДУЮЩАЯ СТУПЕНЬ — четыре пункта 1 Эталонный набор с кейсами того самого класса риска, который открывает новая ступень, а не общего. 2 Порог для этого класса, записанный числом до прогона, и гейт на повторных прогонах — «успешен во всех попытках», а не «хотя бы в одной»: автоматический режим отвечает каждый раз. 3 Строки, добавленные в набор из реальных отказов предыдущей ступени, — и они зелёные. 4 Записанный путь назад: как функция возвращается на ступень ниже, за какое время и по чьему решению.
АРТЕФАКТ	releases/agency-level.md # ступень функции, дата подъёма, # кто решил, путь назад evals/thresholds.yaml # порог того класса риска, # который открывает ступень	 «Оператор давно ничего не правил» — в этот файл не записывается: правом на переход не является.
КРИТЕРИЙ	Все четыре пункта предъявлены до перехода, а не после · переход зафиксирован датой и именем решившего · путь назад проверен, а не описан.	
ГРАНИЦА	«Оператор давно ничего не правил» — не доказательство, а отсутствие измерения: если ступень не произвела ни одной записанной правки, на неё не смотрели, а не отработали безупречно. Всегда зелёный набор разрешения тоже не даёт — это насыщение, сломанный измеритель. Дословно: не тестировали поведение при высоком контроле — не готовы давать высокую автономию. Решение, необратимое по природе — юридически связывающее предложение, удаление промышленных данных, релиз на всю аудиторию без отката — моделью не принимается.	

ОПОРА НА ПРОЙДЕННОЕ Лекция 4 — контракт без версии не контракт: ступень, дата и путь назад лежат в версионизируемом файле.

Эталонный набор — спецификация, которую исполняет сборка, а не документ

МЕХАНИЗМ

Набор живёт в репозитории как версионируемый файл. Строка — четыре поля:

```
{ "вход": "...",  
  "ожидаемый_ответ_или_рубрика": "...",  
  "класс_риска": "отказ_по_политике",  
  "источник": "инцидент-2026-04-11" }
```

Источник обязателен и обязательно реальный: начинают с 5–10 настоящих промышленных примеров — то же «реальное прошлое, а не правдоподобное», что и в интервью.

ПОРОГИ — числом, заранее, по классам риска

Рутинный запрос	не ниже 90%
Отказ по политике безопасности	100%, без исключений
Ответ с юридическим последствием	не через модель

последняя строка — не порог, а отказ от инструмента: детерминированное правило поверх модели

АРТЕФАКТ

```
evals/reference.jsonl      # строки набора  
evals/thresholds.yaml     # пороги по классам риска  
# + строка в гейте «продолжаем / закрываем»  
# + строка в критерии готовности
```

-  **Гейт.** Прогон набора — команда в конвейере сборки, возвращающая ненулевой код при недоборе порога.
-  **Замыкание.** Каждый сбой возвращается строкой с источником «инцидент».

КРИТЕРИЙ

Набор растёт после каждого инцидента — измеримо, по числу строк с источником «инцидент» · однажды пойманная регрессия не повторяется молча на следующем релизе.

ГРАНИЦА: три режима отказа

Насыщение — всегда зелёный набор ничего не измеряет: это сломанный измеритель, а не гарантия. Переобучение под набор — как только прохождение становится целью команды, набор перестаёт быть мерой. Успех хотя бы раз против успеха всегда — гейт на среднем проходе не даёт постоянства при повторных запусках. И зелёный набор формата «вопрос — ответ» не переносится на открытую генерацию.

ОПОРА НА ПРОЙДЕННОЕ Лекция 4 — исполняемая спецификация и гейт прогона: тест, написанный до кода, переносится с кода на продукт без изменения конструкции.



ВОПРОС ЗАЛУ Ваш эталонный набор третий релиз подряд зелёный на 100%. Хорошая это новость или плохая — и какое действие отсюда следует?

Гейт выполняется тем же конвейером, что и тесты кода

МЕХАНИЗМ	>_ promptfoo promptfoo eval Код выхода 100 при падении балла ниже порога — сборка останавливается тем же механизмом, что и на проваленном тесте. ↻ claude plugin eval claude plugin eval --threshold Кейсы из каталога evals/ прогоняются трижды, а не один раз: разброс виден сразу, не только средний балл. 🧪 DeepEval pytest Запускается тем же прогоном тестов, которым команда уже пользуется: отдельный шаг заводить не нужно. Стоит знать заранее: единого термина для строки набора нет: goldens, examples, test cases, samples означают одно и то же.
АРТЕФАКТ	evals/reference.jsonl # наследуется у набора evals/thresholds.yaml # наследуются пороги Своего артефакта у приёма нет: добавляется шаг конвейера, который запускает уже существующие два файла.
КРИТЕРИЙ	Гейт краснеет на недоборе порога и останавливает слияние, а не пишет предупреждение в журнал.
ГРАНИЦА	Порог бессмыслен, если он выше надёжности того, чем измеряется. Модель-судья согласуется с людьми примерно на 85% — на уровне, на котором люди согласуются между собой. Значит, гейт на 95% с таким судьёй измеряет надёжность судьи, а не системы. И число на маленьком наборе без оценки разброса — шум, а не сигнал. надёжность судьи · 85% порог гейта · 95% порог выше измерителя — измеряется измеритель

ОПОРА НА ПРОЙДЕННОЕ Лекция 4 — гейт прогона в конвейере: красный шаг блокирует слияние. Меняется только объект проверки — не код, а ответ.

Удвоив скорость генерации, вы удваиваете очередь на ревью — не пропускную способность



**генерация
дёшево и быстро**

**верификация
не ускорилась**

Сгенерировать правдоподобный код — секунды; проверить его — не ускорилось.

Проблема 70% ^[1]

Опытный разработчик переосмысливает ИИ-вывод и тратит время на переделку.

Новичок отправляет «карточный домик кода», который выглядит правдоподобно, но рассыпается под нагрузкой.

Отгрузка без eval-гейта или плана отката — это не скорость, это отложенная цена: ревью не масштабируется вместе с генерацией.

0% → 100% одним шагом — минуя канареечную раскатку целиком



Google

Google AI Overviews, май 2024

Раскатан на 100% поиска США одним шагом ^[1]. Без eval-гейта. Отключить пользователю нельзя.

1%

10%

25%


50%

100%

правильная канареечная раскатка (перепрыгнута)

На 1% трафика паттерн («ешьте камни» — сатира The Onion; «клей на пиццу» — шутка на Reddit) всплыл бы за дни во внутреннем мониторинге ^[2]. Вместо этого — публичное осмеяние сразу на 100% аудитории.

2,5-3 года на 0,7% сети — и решение остановиться было правильным ^[1]



0,7%

~100 из ~13 786 ресторанов
США

McDonald's × IBM — голосовой приём заказов

- 2,5–3 года пилота на 0,7% сети ^[2]
- Вирусные провалы: бекон в мороженом, 9 чаёв вместо одного
- Закрит июнь 2024 — цель (голосовая автоматизация) осталась, вендорский подход убит

Зеркало предыдущего кейса: там пропустили пилот целиком и выкатили на всех; здесь пилот был долгим — и его сигнал использовали правильно, приняв дисциплинированное решение «убить», а не масштабировать провал.

РАЗДЕЛ 4

Измерение — стрелка, которой ИИ снизил доверие

1 база · 2 практики · 2 провала

Измерение — то место, где «выглядит хорошо» бьёт по продукту сильнее всего. Формальную дисциплину продуктового эксперимента многие видят впервые.

«метрика
выросла!»

а эффект реален?



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Рандомизация отличает причину от совпадения



ОЕС — метрика, о значении которой договорились заранее ^[1]

Контролируемый эксперимент (Кохави): гипотеза с механизмом → рандомизация → заранее определённый размер выборки → решение.

Учебная ловушка: «время на сайте поддержки» — это хорошо или плохо? Направление метрики надо согласовать до теста.

Только случайное деление групп даёт причинность: разница между Control и Treatment вызвана вашим изменением, а не сезоном, рекламой или везением ^[2].



ВОПРОС ЗАЛУ ОЕС вырос на 8% на третий день теста, $p < 0,05$. Останавливаете тест и раскатываете?

Файл коммитится до включения эксперимента — и дальше только дополняется


МЕХАНИЗМ

Подглядывание, подгонка и множественные сравнения держатся на одном: что считать успехом, решают **после** первых результатов.

🔑 **КОММИТ ДО ВКЛЮЧЕНИЯ**

```
оес: конверсия в оплату      # с направлением: растёт
guardrails: [время ответа, доля отписок]
mde: 10% относительных
sample_size: 31 200 на группу # посчитан, не назначен
unit: пользователь           # не запрос
stopping_rule: ...
decision_metric: оес          # ровно одна
```

ПОЧЕМУ ЭТО РАБОТАЕТ — порядок во времени коммит файла **первый результат**



После включения файл **не редактируется** — только дополняется секцией «решение» с датой.

АРТЕФАКТ

```
experiments/<имя>/preregistration.md
# статус, даты, владелец — в заголовке; каталог на работу
```

Тот же приём, что и у единицы работы в репозитории: файл с полями в заголовке, живущий в истории изменений, а не в переписке.

КРИТЕРИЙ

Решение принято по названной заранее метрике · если по другой — это зафиксировано как **отклонение с обоснованием**, а не тихо.

ГРАНИЦА

Пред-регистрация не делает эксперимент валидным — она делает невалидность видимой. Эффекта новизны она не лечит: для него нужна отдельная контрольная группа. И она не работает там, где выборки не хватает: честный вывод не «посмотрим на маленькой выборке», а пересмотр минимально значимого эффекта или качественный метод — недостижимая выборка перестаёт быть источником причинного вывода вообще.




ОПОРА НА ПРОЙДЕННОЕ Лекция 4 — один файл на единицу работы и тест, написанный до кода: порог существует раньше результата, который он оценивает.

ВОПРОС ЗАЛУ Вы хотите проверить, что ИИ-подсказки поднимают конверсию на 10% относительных. У продукта 5000 активных пользователей в неделю. Какое решение вы принимаете до того, как включить тест?

Расчёт мощности 31 200 на группу — иллюстративный

Петля замыкается не дашбордом, а строкой инцидента, вернувшейся в набор



ОПОРА НА ПРОЙДЕННОЕ Лекция 4 — гейт прогона до слияния и петля «сбой — правка — проверка»: здесь она замкнута на качество ответа.

Лодка кружит в лагуне и набирает очки — но никогда не финиширует



RL-агент в гонке набрал на 20% больше очков людей — кружа в лагуне и собирая бонусы, никогда не пересекая финиш ^[1]. Оптимизировал прокси, а не реальную цель.


Закон Гудхарта: когда мера становится целью, она перестаёт быть хорошей мерой.

Anthropic: модель обобщила от угодливости к прямому редактированию собственной функции вознаграждения ^[2].

Что остаётся: ОЕС-дисциплина, guardrail-метрики, закон Тваймана — подозрительно идеальный балл теперь скорее баг, чем прорыв.

Взлом награды (reward hacking): модель находит способ «выиграть» прокси-метрику, не достигая задуманного результата — поэтому мера и цель нельзя путать.

Все 5 реакций взвешены одинаково ×5 — не только «ГНЕВ»



facebook

Facebook MSI, январь 2018:
love/haha/wow/sad/angry — все ×5 выше лайка
(не только гнев) ^[1].

love

×5

haha

×5

wow

×5

sad

×5

angry

×5

**Прокси вовлечённости без guardrail на дезинформацию скрывал вред
~2 года: внутренний guardrail (корреляция гнев ↔ дезинформация)
подтверждён к 2019, вес обнулён в сентябре 2019 ^[2]. Урок: guardrail-
метрику надо измерять с первого дня, а не когда вред уже случился.**

Сдал бенчмарк формата А ≠ безопасен в проде формата В

Медицина

86,5% MedQA [1]

Med-PaLM 2 хорош на бенчмарке вопросов-ответов — но клиническая безопасность требует ОТДЕЛЬНОГО adversarial (сопоставительного) safety-набора.

Право

Stanford RegLab: Lexis+ 17% галлюцинаций, Westlaw 33% — на реальных юридических запросах ^[3].

Дело Mata v. Avianca (фейковые цитаты) = ChatGPT, НЕ Harvey ^[2] — частая ошибка атрибуции.

**Бенчмарк — свидетельство о производительности только на формате задачи именно этого бенчмарка.
Альтернатива: сопоставительные evals на реальных краевых случаях того домена, где продукт будет работать.**

РАЗДЕЛ 5

Поддержка — продукт как оркестр

1 база · 2 практики · 3 провала

Между «код работает у меня» и «продукт надёжно работает у миллионов 24/7» — пропасть, и её закрывают процессом эксплуатации, а не только качеством кода.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка


6

Управление

7

Обобщение

Ответ с кодом 200 ничего не говорит о том, галлюцинирует ли модель



Error budget = «1 - SLO». Пример: 99,9% → 1000 ошибок на 1 млн запросов за 4 недели. Изменения — $\approx 70\%$ всех сбоев ^[1].




SLI «доля ответов с кодом 200» = всё ок? Нет: 200 приходит и когда модель уверенно галлюцинирует. Инфраструктурная метрика не видит качества ответа.

Дежурства, разбор инцидентов без поиска виноватых, инструкции — вы это можете знать. Новое здесь: в проде теперь недетерминированная модель (следующий слайд).

Трасса без версии — не трасса: три части наблюдаемости ИИ-компонента

МЕХАНИЗМ

- 1 **Трасса на каждый ответ с идентификаторами версий.** Промпт → извлечение → вызовы инструментов → ответ. Обязательны версии промпта, модели и конфигурации ограничителей: без них на разборе инцидента нельзя сказать, что изменилось. **Контракт без версии — не контракт.**
- 2 **Бюджет ошибок считается на немедленно доступном прокси,** а не на отложенной истинной метке: правильность ответа часто известна не сразу. Прокси выбирается **один раз и записывается**, иначе на первом же инциденте начнётся спор, что считать ошибкой.
- 3 **Порог скорости сжигания калибруется на историческом разбросе этой же модели,** а не копируется из инфраструктурного норматива. Вариативность доходит до **15 процентных пунктов** между одинаковыми прогонами: абсолютный порог либо шумит, либо не срабатывает на реальном дрейфе вовсе.



АРТЕФАКТ

```
runbook-ai-quality.md
# «качество поехало» → откатить версию промпта →
# поднять порог эскалации → включить строгий
# ограничитель → кого будить
# + дашборд на выбранном прокси
# + запись «какой разброс нормален»: дата калибровки
```

Регламент — не описание намерения, а последовательность действий с именами: **что откатить, что поднять, кого будить.**

КРИТЕРИЙ

Проверяется не декларацией, а **плановым учением**: алерт срабатывает в заявленное окно · дежурный находит нужный раздел регламента · откат укладывается в заявленное время.

ГРАНИЦА: тройная

Трассы по построению уходят во внешний сервис — регулируемые данные туда нельзя без редактирования на входе или развёртывания у себя. Прокси коррелирует с качеством, но не равен ему: путать частоту эскалаций с точностью в отчёте — способ обмануть себя. Калибровка стареет вместе с моделью, и незаверсионированный порог даёт то же ложное чувство защищённости, что незаверсионированный ограничитель.

ОПОРА НА ПРОЙДЕННОЕ Лекция 4 — слой логирования: вопрос не «логировать ли», а какая гранулярность соразмерна цене ошибки.

Четыре времени, измеренные на учении, — а не заявленные в регламенте

МЕХАНИЗМ	Раз в несколько недель — запланированный прогон. Деградация вызывается искусственно, одним из трёх способов: подменить версию промпта на заведомо худшую на теневом трафике опустить порог ограничителя эмулировать всплеск отказов И замеряются четыре времени — поля пустые: число берётся с учения, а не из регламента до срабатывания алерта 1 до открытия регламента дежурным 2 до срабатывания размыкателя 3 до завершённого отката 4
АРТЕФАКТ	<pre>ops/drills/<дата>-<сценарий>.md # запись в формате разбора инцидента; дата в имени # несущая: по каталогу видно, когда учение было # + дифф самого runbook-ai-quality.md</pre> + Дифф регламента важнее записи: правка и есть доказательство, что учение чему-то научило.
КРИТЕРИЙ	Все четыре времени измерены, а не заявлены · учение, не давшее ни одной правки регламента, было слишком лёгким — тот же диагноз, что у сдувшегося набора оценок: измеритель, который всегда зелёный, ничего не измеряет.
ГРАНИЦА	Учение проверяет только известный класс отказа. Тихий дрейф по определению не воспроизводится по кнопке — его признак именно в том, что ничего явно не ломается, — поэтому учение дополняет, а не заменяет мониторинг по сегментам и канал качественных сигналов от пользователей. Если единственный механизм обнаружения — учение раз в квартал, это тот же дрейф с более длинным окном, только названный процессом.

ОПОРА НА ПРОЙДЕННОЕ Лекция 4 — гейт прогона: проверка существует, только если её кто-то запускает и она умеет краснеть. Здесь запускают руками.

Дашборды остаются зелёными, пока доверие уже падает недели



Тихий дрейф

Самые активные пользователи замечают регрессию раньше агрегированных метрик — доверие падает раньше, чем двигаются дашборды.

Дрейф правил

Guardrails (защитные правила) без версионирования молча устаревают: правила расходятся с реальностью незаметно.

Что остаётся: эскалация к человеку, ответственность, инцидент-дисциплина — усилены автономностью ИИ, не отменены ею.




ВОПРОС ЗАЛУ Назовите один сигнал в своей системе, который сегодня не попадает ни в один дашборд, но первым скажет, что качество упало.

Модель была откалибрована корректно — не было предохранителя на дрейф в реальном времени



Рынок сдвинулся — дрейф концепта без предохранителя



Разные единицы и разные шкалы — МЛН слева, Тыс. справа (длины баров НЕ сравнивать напрямую)

Zillow Offers, ноябрь 2021: 9680 домов куплено, 3032 продано · ~2000 уволенных (~25% штата) ^[1] · ≈\$80 тыс. убытка на объект ^[2].

Критерий: модель, совершающая сделки на деньги, требует мониторинга точности предсказания в реальном времени с автоматическим предохранителем (circuit breaker), который отключает её при дрейфе.

«Бот — отдельное юрлицо» — трибунал отклонил этот довод одной фразой



Весы в равновесии: ответ бота = статичная страница сайта. Одинаковая ответственность за оба.

Air Canada, чат-бот сайта

Бот некорректно сообщил о ретроактивной скидке. Трибунал — \$812,02 CAD ^[1]: компания отвечает за ответ бота как за любой другой контент сайта ^[2].

Ты владеешь каждым ответом бота — не больше, но и ни на грамм меньше ответственности, чем за любой другой контент сайта.


10 из 10 журналистов получили один и тот же незаконный совет — не единичный сбой

Klarna

Klarna: политика «только ИИ» откатилась (05.2025) ^[1] — но автоматизация выросла до 853 чел.-эквивалентов ^[2] (усиление людей, не замена).



NYC MyCity — гос-бот



10 из 10 журналистов — один и тот же незаконный совет ^[3]. Мэр не отзывал бот сразу.

Урок не «ИИ не работает», а «метрика пропускной способности без гарантированной эскалации к человеку — неверный дизайн».

РАЗДЕЛ 6

Управление — капстоун, отвечающий на хук-парадокс

1 база · 2 практики · 2 провала

Почему сборка почти бесплатна, а ценность — нет. Здесь мы поднимаемся на уровень организации и собираем петлю целиком.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Тот же go/kill-гейт — но теперь распределяет капитал между многими инициативами

Воронка портфеля

много инициатив

гейт 1

гейт 2

профинансировано


Unit-экономика ИИ-продукта

Новая переменная — стоимость на запрос против ценности на запрос. Каждое обращение к модели стоит денег.

Финансовый KPI на входе в пилот: «снизим стоимость тикета с X₽ до Y₽ при CSAT $\geq$ Z; N тикетов, M недель, владелец — Иванов».

Портфельное управление = Stage-Gate, поднятый на уровень капитала: та же дисциплина «воронка, не туннель», но между продуктами, а не внутри одного.

Четыре множителя — и ни один из них не новый

МЕХАНИЗМ	Стоимость одного взаимодействия: токены входа × цена входа + токены выхода × цена выхода × среднее число шагов агента × коэффициент повторных попыток  ЧТО СТОИТ ЗА КАЖДЫМ МНОЖИТЕЛЕМ Длина в токенах зависит от языка. Русскоязычный текст на ту же мысль даёт заметно больше токенов, чем англоязычный: продукт на русском платит за один и тот же смысл больше, и разница не исчезает от улучшения формулировки запроса.  Токены рассуждения невидимы в ответе, но оплачиваются как выход и в агентном сценарии часто составляют основную статью расхода. Дашборд, считающий только видимый ответ, занижает реальную стоимость. Кэширование входа меняет знаменатель: повторяющийся системный промпт читается из кэша дешевле, чем пишется заново, и порог окупаемости кэша считают явно, а не принимают на веру.
АРТЕФАКТ	<pre>pilots/<имя-пилота>/ unit-cost.md # расчёт на единицу взаимодействия; # допущения явно: число шагов агента, # доля повторных попыток, средняя длина # ответа; рядом — ценность на запрос go-kill.md # критерий остановки пилота</pre> Дашборд «стоимость на запрос по дням» — не файл в репозитории:  синим — стоимость на запрос, бирюзовым — ценность; золотая точка — день, когда они сошлись
КРИТЕРИЙ	Тренд считается по собственному паттерну использования, а не по чужому · рост средней длины ответа или числа шагов агента виден на дашборде до квартального счёта, а не после.
ГРАНИЦА: три пункта	Падение цены токена не гарантирует падения расхода — команды закономерно отвечают на удешевление увеличением числа шагов, и бремя доказательства лежит на утверждении «подешевеет само». Стоимость на запрос — метрика-ограничитель, а не цель оптимизации: оптимизировать её означает получить короткие и бесполезные ответы. И сравнивать нужно с базовой линией без ИИ: сколько стоил тот же результат человеком. Без этого знаменателя получается не юнит-экономика, а учёт расходов.

Критерий записан до пилота — иначе это объяснение результата, а не критерий

МЕХАНИЗМ

 **дата записи и имя записавшего — проверяются первыми**

«Мы верим, что ИИ-разбор обращений **снизит стоимость на обращение с ХР до YР** при не-ухудшении удовлетворённости клиента ниже порога **Z** и доле эскалаций не выше **W**; проверим на **N обращениях за M недель**; владелец — **конкретный человек, отслеживающий это еженедельно**».

одна фраза несёт сразу четыре аппарата: оптимизируемая величина · ограничители · объём и срок · владелец

 **ЧЕТЫРЕ ПРОВЕРКИ ГОДНОСТИ — все до старта**

- 1** **ХР** измерена на **собственном процессе**, а не взята из обещания поставщика: чужая цифра описывает чужой процесс.
- 2** **У** каждой величины есть **единица и направление** («снизить с ХР до YР»), а не одно намерение.
- 3** **Назван владелец** — человек с недельным ритмом: критерий без имени не проверяет никто.
- 4** **Существует исход «закрываем»**: гейт ставится ровно для того, чтобы отличать «данные сказали нет» от «мы устали».

АРТЕФАКТ

```
pilots/<имя-пилота>/go-kill.md
# дата записи и имя записавшего
# ХР — измерено на своём процессе
# YР, Z, W — единица и направление
# N обращений, M недель; владелец, ритм — еженедельно
```



Тот же каталог пилота, что и у расчёта стоимости: расчёт и критерий остановки — **два файла одного решения**, а не два разных хозяйства.

КРИТЕРИЙ

Решение на гейте принято **против записанного** — с датой и именем, проверяемыми первыми.

ГРАНИЦА

Если числа порога появились или изменились после включения пилота — это уже не критерий, а объяснение результата: решение принято, а формулировка подогнана под него. Критерий без названного владельца не проверяет никто, а сравнение с отраслевым обещанием вместо собственной базовой линии превращает юнит-экономику в учёт расходов. Отсутствие этой конкретики — не «забыли посчитать окупаемость», а отсутствие линейки, которой её измеряют: по замеру таких компаний 60%.

ОПОРА НА ПРОЙДЕННОЕ Лекция 4 — исполняемая спецификация: порог существует раньше результата. Тот же приём, применённый к решению финансировать.

Узкое место сместилось с технологии на операционную модель организации



Зрелость 0-5 (maturity)



Сбер здесь →

Операторы → оркестраторы. Сбер сам ставит себя на уровень 3 из 5 ^[2] — сигнал против хайпа: даже крупный игрок не заявляет вершину шкалы.

Пять независимых источников сходятся в одном: выигрывает не тот, у кого лучше модель, а тот, кто перестроил команды и управление под неё.



ВОПРОС ЗАЛУ Вам показывают заголовок «95% ИИ-пилотов провалились». Какой первый вопрос вы задаёте этой цифре?

60% исследовали → 20% пилот → 5% успех: это 25% среди дошедших, не «95% провал» ^[1]



«95% провал» — заголовок, который не переживает калибровку: успех среди дошедших до пилота — 25%, не 5% ^[2, 3].



4 вопроса к любой громкой цифре провала ИИ

1. Каков знаменатель?
2. Что считается «провалом»?
3. Каков конфликт интересов автора? ^[4]
4. Прослеживается ли к первоисточнику?

BCG AI Radar 2025 (январь 2025, 1803 руководителя): 60% компаний не отслеживают ни одного финансового KPI, привязанного к ценности ИИ ^[5].

«Автономный» магазин: 700 из 1000 транзакций требовали ручной проверки против цели 50



Just Walk Out (Amazon), с 2018: 700/1000 транзакций — ручная проверка (14× выше цели 50/1000) ^[1]. 6 лет маркетинга «автономный ИИ» без раскрытия масштаба труда (скрытая человеческая стоимость) ^[2].

Фаза × что ИИ меняет × что остаётся из классики

Исследование	Дизайн	Сборка/запуск	Измерение	Поддержка	Управление
синтез, кабинет.	генерация	код ≈ бесплатно	оценки (evals)	трейсинг	операц. модель
интервью	требов. безоп.	ревью, kill-гейт	рандомизация	эскалация	стоим./запрос

[1] Business Standard (anp. 2024) — Just Walk Out · [2] Retail Dive — демонтаж Just Walk Out

РАЗДЕЛ 7

Обобщение — аппарат суждения из шести пройденных фаз

6 фаз · 1 матрица · 3 оси · 8 пунктов

Здесь не появляется ничего нового — появляется способ применить уже разобранные к случаю, которого ещё не было в этой лекции.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Шесть фаз — одна структура: дисциплина, удешевление, режим отказа, человек

Фаза	Дисциплина (артефакт)	Что ИИ удешевил	Режим отказа	Где человек обязателен
 Исследование	Customer Development и Mom Test: фальсифицируемая гипотеза	Кабинетный поиск; синтез сотен интервью в кластеры	Угодливость: синтетический источник не производит «нет»	Проверка реальным прошлым и реальным обязательством
 Дизайн	Double Diamond, эвристики Нильсена, дизайн-система	Черновик экрана: день → минуты	Однообразие решений; пробелы доступности — 29,0% экранов проходят WCAG	Сведение к контексту бренда и аудит безопасности до MVP
 Сборка и запуск	MVP, гейт «продолжать/убить», канареечный запуск	Сама сборка: шаблонный и связующий код	Пропуск гейта оценки и поэтапной раскатки — ошибка сразу на всю аудиторию	Спецификация намерения на входе; решение о темпе и об остановке
 Измерение	Контролируемый эксперимент, OEC, guardrail-метрики	Оценки в масштабе; дешёвый первый проход	Взломанная прокси без guardrail; бенчмарк не переносится на задачу	OEC и guardrail названы до теста; чтение результата через ловушки
 Поддержка	SRE: SLI, SLO, бюджет ошибок, эскалация к человеку	Скорость наблюдения: трассировка и дашборды	Тихий дрейф маскируется агрегатом; поток ответов без гарантии эскалации	Владение системной моделью; ответственность за каждый ответ
 Управление	Портфельное управление, финансовый показатель с владельцем	Диагностика операционной модели организации	Статистика без знаменателя: 25% успеха среди дошедших, не 5% «всех»	Критерий успеха согласован заранее; сравнение со своей базовой линией

29,0% экранов проходят WCAG — ACM Web4All, 2026 · воронка 60% → 20% → 5% и знаменатель пилотов — MIT NANDA, июль 2025 · 60% компаний без финансового показателя ценности ИИ — BCG AI Radar, январь 2025 (n=1803)

Как читать: назовите фазу задачи — дальше матрица отвечает по порядку, какую дисциплину держать, какой режим отказа стеречь и где решение не делегируется. Имена инструментов сменяемы; дисциплина, режим отказа и точка человека держатся на характере сложности и цене ошибки фазы.

Три оси решают режим фазы: без гейта — только при высокой обратимости, низкой стоимости и высокой наблюдаемости

**Обратимость**

Насколько легко откатить следствие, если вывод неверен.

**Стоимость ошибки**

Во что обойдётся ошибка: деньги, репутация, здоровье, ответственность.

**Наблюдаемость**

Насколько быстро узнаем, что вывод неверен, — до того как вред накопится.

AI-first без дополнительного человеческого гейта оправдан только при сочетании высокой обратимости, низкой стоимости ошибки и высокой наблюдаемости одновременно. Любая другая комбинация требует гейта, соразмерного проблемной оси.

Случай	Обратимость	Стоимость ошибки	Наблюдаемость	Проблемная ось → мера
Google AI Overviews <i>раскатка на 100% трафика поиска</i>	низкая — вся аудитория увидела ответ одновременно	высокая — вирусный, потенциально опасный совет	была бы высокой при канареечной фазе, но её пропустили	обратимость (масштаб раскатки) → поэтапная раскатка возвращает и наблюдаемость
Zillow Offers <i>закупка недвижимости по прогнозу цены</i>	минимальная — купленный дом не отменяется одним кликом	максимальная — списания \$304-408 млн, ≈2000 домов в убыток, ≈\$80 тыс. на дом	низкая по конструкции — только квартальная отчётность, не контроль в реальном времени	все три оси сразу → нужен жёсткий гейт на каждой, не было ни одного


Вопрос залу: команда хочет отдать ИИ автоматический ответ на публичные отзывы о продукте. Прогоните случай по трём осям — какая из них проблемная и какая мера её закрывает?

Восемь вопросов, восемь действий: чек-лист распределяет бремя доказательства

№	Вопрос	Действие, если ответ «нет»
1	✓ Классика фазы на месте?	Сначала выстроить базовую дисциплину фазы — в пустоте усиливать нечего
2	✓ Стоит ли доверие своей цены?	Добавить проверку там, где доверие упало: guardrail-метрику или мониторинг сегментов, а не агрегат
3	✓ Есть эталонный набор и оценка против него?	Построить набор из 20–100 примеров до развёртывания — иначе нет базы, от которой меряется регрессия
4	✓ Есть guardrail-метрика?	Назвать guardrail явно до теста, а не постфактум: что мониторим, но не оптимизируем
5	✓ Поэтапная раскатка и быстрый откат?	Ввести канареечную фазу или лестницу самостоятельности до полной раскатки — это ось обратимости из триады
6	✓ Эскалация к человеку гарантирована?	Спроектировать эскалацию как архитектуру с первого дня, а не как функцию после инцидента
7	✓ Кто отвечает за результат?	Назначить владельца и записать финансовый показатель до запуска
8	✓ Данные безопасны?	Обезличить регулируемые поля или перейти на собственный контур до подключения внешнего инструмента

Хотя бы одно «нет» не значит «не применять ИИ» — значит «закрыть разрыв до, а не после»: для подходящей задачи чек-лист осознанно приведёт к высокой самостоятельности.

Метод переносится, а не список инструментов: код был первым полигоном, продукт — вторым



Инженер за рабочей станцией САПР со световым пером, конец 1970-х: инструмент исчез — дисциплина проектирования осталась

Курс не учит «применяйте ИИ больше» и не учит «бойтесь ИИ» — он учит говорить обоснованное «да» и обоснованное «нет».

Семинар 7

Полный прогон аппарата на учебном AI-продукте: от гипотезы до точки эскалации к человеку.

Лекция 6

Тот же метод в инженерном проектировании и CAD/CAM — там цена физической ошибки выше.

Вопросы?