

Одна прогнозная модель закрыла целое направление крупной компании.



Zillow Offers · iBuying · ноябрь 2021

\$500M+

совокупные потери — целое направление закрыто

\$300M+

списание за квартал

~2000

уволено (≈25%)

–25%

акция за дни

Модель прогнозировала цену дома · Zillow авто покупала, ремонтировала, перепродавала тысячи домов · систематически переоценивала



Это был не ChatGPT

Прогнозная модель оценивала число (цену) по табличным и геоданным. LLM здесь не применялась и не могла — задача не текстовая.

Какой тип ИИ это был — и почему обычная ошибка модели стала потерей бизнеса, а не мелкой неточностью?

Ошибка прогноза нормальна. Бизнес рухнул из-за того, КУДА она подключена: к авто-, необратимому действию в масштабе тысяч домов.

ЛЕКЦИЯ 5

AI в финансовом секторе и ритейле

05

Под какую задачу — какой тип ИИ,
почему именно он, и где он ломается

Раздел 0
Открытие

Раздел 1
Прогноз

Раздел 2
Аномалии

Раздел 3
Скоринг

Раздел 4
LLM

Раздел 5
Рекоменд.

Раздел 6
Фреймворк

Один тип ИИ вглубь (Л4) → палитра типов под палитру задач (Л5).

Л2: дерево «какой ИИ» — ML / глубокое / LLM

→ Л5: пять структурно разных типов под разные задачи

Л4: один тип (LLM-кодер) в глубину по автономности

→ Л5: палитра типов под палитру задач одной индустрии

Карта пяти типов ИИ под пять разных задач (+ сквозной CV-пласт):



Прогноз
рядов



Поиск
аномалий



ML-
скоринг



LLM-
ассистенты



Рекомендации
и цены


Большую часть ценности здесь даёт НЕ языковая модель. LLM — не универсальный молоток: разная задача требует разного типа ИИ. Это и есть «палитра типов под палитру задач».

Центральный вопрос лекции.



«Финансы и ритейл — отрасли максимального внедрения ИИ. Под какую задачу — какой тип ИИ, почему именно он (а не LLM везде), и где этот тип ломается?»

Каждый тип разбираем по одной схеме (5 шагов):



Карта — это структура лекции, не требование понять всё сейчас. Прогноз · аномалии · скоринг · LLM · рекомендации (+ сквозной CV).

Ответ — не «ИИ хорош» и не «ИИ плох», а аппарат: назвать уместный тип, обосновать выбор и заранее увидеть точку обязательного человека. К концу схема станет вашим инструментом выбора.

РАЗДЕЛ 1

Прогнозирование: спрос, продажи, отток

Начнём с самой массовой задачи ритейла — и сразу с типа ИИ, который НЕ LLM.



Раздел 0
Открытие

Раздел 1
Прогноз

Раздел 2
Аномалии

Раздел 3
Скоринг

Раздел 4
LLM

Раздел 5
Рекоменд.

Раздел 6
Фреймворк

Прогноз ряда и языковая модель решают структурно разные задачи.

Языковая модель (LLM)	Прогноз временного ряда
предсказывает следующий ТОКЕН текста	предсказывает следующее ЧИСЛО в ряду
оптимизирована на правдоподобие формулировки	нужна числовая точность + калиброванная неопределённость
нет внутреннего понятия «сезонность» / «тренд»	ряд = тренд + сезонность + шум
видела тексты О продажах	видит сам ряд продаж как ряд

Тип ИИ под прогноз: классическая статистика и табличный ML — ARIMA-семейство, градиентный бустинг. НЕ генеративная модель, НЕ LLM.

Поставить «спрогнозируй спрос» текстовой модели — она выдаст правдоподобное число без связи с сезонностью: галлюцинация в числовой обёртке. Тип ИИ определяется СТРУКТУРОЙ задачи, а не модностью инструмента.

Почему здесь табличная модель, а не LLM — три аргумента, а не оговорка.



1. Структура данных

табличные числовые ряды (дата, точка, товар, цена, признаки). Модели для рядов извлекают тренд и сезонность; перевод ряда в текст для LLM теряет именно эту структуру.



2. Измеримость и калибровка

решение о размере закупки строится на численной метрике ошибки + доверительном интервале. Классические модели дают это из коробки; от LLM такого нет.



3. Что сломается

LLM даст правдоподобное число без обоснованной неопределённости — а решение всё равно придётся принять, и цена систематической ошибки × объём (механизм Zillow).

Альтернатива и критерий: правильный инструмент — табличная прогнозная модель с измеримой ошибкой. Даже её недостаточно при нестационарной среде + необратимом капитальном действии без человеческого контроля.

Задача: прогноз спроса (полка / закупка), cash-flow (ликвидность), оттока клиентов (кого удержать).

Прогноз диктуется задачей: ни X5, ни Магнит не взяли LLM.

X5 Group · «Пятёрочка», «Перекрёсток»

Точность прогноза спроса **> 70%**

Доп. выручка от ML-инструментов **+5 млрд ₽**

Списания просрочки **–2%**

Магнит — импортозамещение прогнозных систем

До 2022: иностранные вендоры класса SAP / Blue Yonder

После ухода: собственная система прогноза + автозаказа (F&R)

Статус: пилот на распределительном центре (2024–2025)

Уход иностранных вендоров сделал импортозамещение прогнозных систем прямой инженерной задачей отрасли.

Ни X5, ни Магнит не решают задачу языковой моделью — они строят специализированные прогнозные системы, потому что ТИП ИИ ДИКТУЕТСЯ ЗАДАЧЕЙ.

Прогноз продлевает паттерны прошлого — здесь его сила и уязвимость.

История продаж



Тренд — продажи растут



Сезонность — недельный / годовой цикл



Шум — случайные колебания



Любой ряд продаж = тренд + сезонность + шум; модель продлевает регулярную часть.

Что делает модель — численно

- раскладывает историю на тренд + сезонность + шум
- обучается на регулярных паттернах, продлевает их
- добавляет поправки на промо / праздник

Прогноз → действие: «спрос $\approx N$ » → «заказать $N + \text{запас}$ »

Аналогия: модель прогноза — как опытный товаровед «к выходным возьми больше», но для миллионов пар магазин $\times$ товар сразу.

Встроенная уязвимость: прогноз силён ровно настолько, насколько ЗАВТРА ПОХОЖЕ НА ВЧЕРА. Меняется среда качественно — модель уверенно экстраполирует паттерны, которых больше нет. Ключ к следующему слайду.

Разорил Zillow не дрейф модели, а то, к чему был подключён её выход.

distribution shift (дрейф распределения)

данные в реальности перестали быть похожи на обучающие — рынок жилья 2020–2021 стал статистически другим

асимметрия цены ошибки

ошибка рекомендации ≈ 0 · та же ошибка, на которой куплен дом = десятки тыс. \$ × N, и НЕОБРАТИМА

Три вещи вместе = фатально

необратимое действие × авто по выходу модели × нестационарная среда без circuit-breaker (авто-стоп при аномалии)

Knight Capital, 2012: \$440M / ~45 мин на детерм. алгоритме — тот же класс ошибки

Zillow vs Opendoor

Тот же тип ИИ, тот же период. Opendoor выжил за счёт более консервативного спреда и риск-дизайна.

Опасно, когда одновременно: (а) выход запускает крупное необратимое действие авто, (б) среда нестационарна, (в) нет circuit-breaker.

Альтернатива: узкий сегмент + human-gate + live error-monitoring + circuit-breaker.

Модель делала ровно то, для чего предназначена. Ошибка — инженерное решение, КУДА подключить её выход. Тот же ИИ, другое суждение → банкротство vs выживание.

РАЗДЕЛ 2

Поиск аномалий: фрод и AML

Прогноз — про будущее; теперь про настоящее — поймать аномалию за миллисекунды, пока платёж ещё не прошёл.



Раздел 0
Открытие

Раздел 1
Прогноз

Раздел 2
Аномалии


Раздел 3
Скоринг

Раздел 4
LLM

Раздел 5
Рекоменд.

Раздел 6
Фреймворк

Учить «норму клиента» и ловить отклонение — а не учить «как выглядит фрод».



Задача: поймать мошенническую транзакцию в реальном времени, где почти всё легитимно, а доля фрода крайне мала.

Тип ИИ — поиск аномалий (anomaly detection): модель строит «норму» клиента и сигнализирует об отклонениях.

не классификация фрод редок и постоянно меняет форму (движущаяся цель)

не прогноз ряда вопрос — не «следующее значение», а «насколько не похоже на норму»

не LLM транзакция структурирована; задача геометрическая, не языковая

AML — подмножество той же задачи; жёсткие законодательные пороги = детерминированные правила, не модель.

Модель не «знает», что это фрод — она знает, что это НЕ ПОХОЖЕ НА НОРМУ, и поднимает флаг для проверки.

Антифрод — это «норма / отклонение» в реальном времени, не генерация.

Что даёт поиск аномалий в антифроде — каждая метрика в своих единицах:

Stripe Radar

–32% фрода

при одобрении легитимных > 99%

JPMorgan

–30% ложных

меньше ложных срабатываний

Visa · предотвращено

~\$40 млрд

мошеннических операций (FY2023)

Россия

Поиск аномалий — стандартная практика крупных банков (по материалам Банка России, 20.11.2025).

Заметьте: «снижение ЛОЖНЫХ срабатываний» — ключевая метрика антифрода НЕ «точность вообще», а соотношение двух типов ошибок. Разберём дальше.

Разные единицы — НЕ одна шкала: % снижения, % ложных, млрд \$. И всё равно главная метрика — не «ассигасу», а FP / FN отдельно.

«Точность 99,9%» при сильном дисбалансе обманчива.



Формальный аппарат (*sensitivity / specificity*) строится в Лекции 7 на медицинском примере; здесь — рабочая интуиция.

Первый вопрос к любой цифре антифрода — НЕ «какая точность», а «какие FP и FN отдельно и по какой цене».

«Снизили FP на 25%» усредняет копеечный FP и катастрофический FP.

Тот же класс ошибки — цена на порядки разная

FP №1 · \$5 за кофе

клиент повторил, забыл через час → цена ≈ 0, ОБРАТИМО

FP №2 · \$5000 за лечение за границей

дозвониться трудно, время критично → НЕОБРАТИМО по последствиям

precision ↔ recall — КОМПРОМИСС, а не задача «обе в ноль». Лучшая модель сдвигает кривую, точку выбирает инженер по цене ошибки.

Авто-блок необратимого без гейта — класс Zillow / Knight

Критерий:

- авто-жёсткий блок — только обратимое / мелкое
- крупное / необратимое → мягкий challenge (3DS, звонок, пуш) + быстрый человеческий канал разблокировки
- жёсткий AML-порог — rules-engine (закон, не «с вероятностью 0,97»)

Цена FP усредняет копеечный и катастрофический — измерять отдельно.

Масштаб не уменьшает вред: 0,5% ложных от миллиардов = десятки миллионов заблокированных легитимных операций. За каждой — конкретный человек.

РАЗДЕЛ 3

Кредитный скоринг: почему НЕ нейросеть

Аномалию нашли; теперь решение, которое меняет жизнь клиента, — и почему здесь нельзя чёрный ящик.



Раздел 0
Открытие

Раздел 1
Прогноз

Раздел 2
Аномалии

Раздел 3
Скоринг

Раздел 4
LLM

Раздел 5
Рекоменд.

Раздел 6
Фреймворк

Чёрный ящик в скоринге неприменим в принципе — не «менее удобен».



1. Объяснимость = закон

клиенту с отказом по закону положено объяснение (reason codes: «высокая долговая нагрузка»). «Алгоритм так решил» — недопустимо.



2. Данные табличные

глубокие сети сильны на тексте/звуке/изображении; на табличных бустинг конкурентен при несравнимо большей интерпретируемости.



3. Аудит > +1% точности

регулятор должен воспроизвести решение, проверить отсутствие дискриминации. Стабильная объяснимая важнее непрозрачной точнее.



4. Что сломается с чёрным ящиком

нельзя объяснить → нарушение · нельзя аудировать на bias → кризис (Apple Card) · нестабильно → не защитить перед регулятором.

Аналогия-якорь: кредитный инспектор



Интерпретируемая модель

инспектор показывает расчёт построчно

Высокая долговая нагрузка **-18**

Короткая кредитная история **-9**

Стабильная занятость **+6**

«Отказ: причина — долговая нагрузка» (reason codes)

Чёрный ящик

говорит «нет», объяснить отказывается

???

«Отказано». Почему — неизвестно

в регулируемой отрасли недопустимо по закону

Интерпретируемая модель показывает расчёт построчно (reason codes); чёрный ящик отказывается объяснять.

«Новое = нейросеть, значит лучше» в скоринге — структурная ошибка: объяснимость здесь не бонус, а УСЛОВИЕ ЗАКОННОСТИ.

«100% решений ИИ» в РФ ≠ нейросеть-чёрный-ящик бесконтрольно.

Сбербанк · с февраля–марта 2024

Решения по физлицам

~100% ИИ

Скоринговая модель

до 5000 параметров

Эффект ИИ по всем направлениям, 2023

+350 млрд ₽

«100% ИИ» означает на самом деле:

- высокая автоматизация конвейера на интерпретируемых моделях
- reason codes на каждое решение
- регуляторный надзор Банка России

● **сохранённое право клиента на сотрудника: > 80% финорганизаций дают opt-out на человека**

Тип ИИ — табличный ML, выбранный из-за объяснимости, а не вопреки. Тезис лекции на масштабе крупнейшего банка.

Даже формально-законная модель без объяснимости создаёт кризис.

Apple Card / Goldman Sachs · 2019–2021

- нояб. 2019: вирусный тред — лимит ×20 выше у мужа (рейтинг супруги выше)
- NYDFS открыл расследование (~400 000 заявителей)
- март 2021: NYDFS НЕ нашёл нарушения закона
- НО: клиенты не получали объяснений → регуляторно-репутационный кризис

Утверждать «доказана дискриминация» — фактологически неверно.

Прокси-предвзятость «на пальцах»

Инженер не подаёт пол/расу. Но остаются признаки, **КОРРЕЛИРУЮЩИЕ** с ними: почтовый индекс, история трат, занятость. Модель, оптимизируя точность, **КОСВЕННО** восстанавливает запрещённый признак через прокси — без всякого умысла.

Критерий: регулируемое решение требует одновременно reason codes + appeal path (человек на оспоренном) + bias-аудит исходов ДО прода.

Канонический разбор механизма (Obermeyer/Optum) — Лекция 7.

«Мы не используем защищённые признаки» — НЕОБХОДИМОЕ, но совершенно недостаточное условие. Единственное доказательство — прямой аудит исходов по группам.

Чем выше автономия, тем строже должен быть гейт вокруг неё.

Один класс ошибки — три разных типа ИИ:

Zillow

прогноз → авто необратимая скупка

fraud-автоблок

аномалия → авто необратимая блокировка

Knight Capital

детерм. алгоритм → авто необратимые заявки

Автоматика, исполняющая необратимые финансовые действия в открытом контуре без kill-switch (ручного «всё стоп»), без лимитов на объём/позицию, без circuit-breaker (авто-стоп при аномалии) и без верифицированного развёртывания, превращает обычную ошибку модели в СКОРОСТЬ РАЗОРЕНИЯ.

Скоринг в РФ ~100% автоматизирован → критерий применим остро. «100% ИИ» приемлемо ТОЛЬКО в обвязке: reason codes + человеческий канал + bias-аудит + мониторинг дрейфа + надзор. Уберите обвязку — это Apple Card на масштабе банка.

Высокая автономия — не цель и не зло сама по себе. Цель — автономия, вокруг которой стоят оплаченные гейты, пропорциональные цене ошибки и необратимости действия.

РАЗДЕЛ 4

LLM в финансах: ассистенты и fact-checking

До сих пор — намеренно НЕ LLM. Теперь LLM — и сразу про его границы в регулируемой отрасли.



Раздел 0
Открытие

Раздел 1
Прогноз

Раздел 2
Аномалии

Раздел 3
Скоринг

Раздел 4
LLM

Раздел 5
Рекоменд.

Раздел 6
Фреймворк

LLM хорош ровно там, где задача текстово-диалоговая — и плох там, где нет.

Где LLM — правильный тип в банке:

- клиентская поддержка — ответы на типовые вопросы
- голосовой ассистент — распознать запрос, провести по сценарию
- помощь сотруднику — суммаризировать обращение, подсказать регламент
- объяснение продукта простым языком

Это ровно то, подо что LLM спроектирована (в отличие от Разделов 1–3).

Масштаб (verified): чат-бот Т-Банка > 40% обращений; ~70% банков планировали голос к 2025.

Почему НЕ «> 90% обращений банков»

Цифра ~90% реальна — но это доля звонков голосового ассистента В КОЛЛ-ЦЕНТРЕ ОДНОГО БАНКА, не доля обращений банков в целом. Это ПОДМЕНА БАЗЫ (класс 5 fact-checking).

Лекция учим fact-checking — строить assertion на цифре с подменённой базой значило бы нарушить ровно тот принцип, которому она учит. Точная скромная цифра ценнее громкой.

Симметрия с Разделами 1–3: «разная задача — разный тип ИИ» означает не «LLM плох», а «LLM хорош ровно там, где задача текстово-диалоговая, и плох там, где нет».

LLM здесь не источник истины, а интерфейс к источнику истины.

Когда LLM НЕ источник истины — 3 аргумента

механизм	генерирует правдоподобное, не извлекает факт («правдоподобно» ≠ «верно»)
цена	неверная ставка/условие = нарушение, отвечает организация
что сломается	свободная генерация о фактах = генератор дезинформации с юр. ответственностью

Пять классов ошибок ИИ-утверждения

1. галлюцинация факта → сверить с первоисточником
2. устаревшие данные → проверить дату/актуальность
3. прокси-bias в выводе → аудит исходов, не входов
4. обман метрикой → FP/FN отдельно в деньгах
5. подмена базы → запросить «доля чего от чего»

Аналогия-якорь grounding: студент угадывает уверенным тоном vs сначала открывает справочник



Альтернатива: фиксированный факт → детерминированная выборка (grounded RAG), не генерация. На лекции — распознать класс (Understand); проверить 5 заявлений по первоисточникам — Семинар 5 (Apply).

Правильный тип ИИ без grounding и человеческого выхода = Air Canada / Klarna.

Кейс E — Air Canada (callback)

- чат-бот сообщил несуществующую политику возврата
- пассажир действовал на основании ответа
- фев. 2024: суд — компания ОТВЕЧАЕТ за инфо своего чат-бота, обязал выплатить компенсацию
- класс: галлюцинация финфакта = юр. ответственность

Кейс F — Klarna (дуга 2023 → 2025)

- LLM-ассистент: ~2/3 обращений, ~11 мин → < 2 мин
- заявленная экономия ~\$40 млн/год (Klarna, 2024)
- 2024: подавалось как «ИИ заменяет поддержку»
- сер. 2025: CSAT↓ → вернулись к найму людей

Критерий: фиксированная политика/тариф/право → детерминированная выборка/grounded, не свободная генерация; и при любом сценарии гарантирован путь к человеку.

Устойчива не замена, а AUGMENTATION: ИИ на массовой рутине + гарантированная человеческая эскалация на эмоциональном / спорном / нестандартном хвосте.

Чекпойнт: 4 типа из 5 пройдены — поворот к «человек + обязанка».

Прогресс по 5 типам — у 4 пройденных провал одной формы:

✓ Прогноз

Zillow

✓ Аномалии

fraud-FP

✓ Скоринг

Apple Card

✓ LLM

Air Canada

→ Recsys

следующий

Уровень 1 «какой тип ИИ» — решается структурой задачи, чаще однозначно. Уровень 2 «что вокруг ИИ на цене ошибки» — проектируется отдельно. Поворот лекции: дальше внимание уходит с типа на обязанку.



Последний тип — recsys / pricing — кажется самым БЕЗОБИДНЫМ: цена ошибки около нуля. Именно поэтому он опаснее остальных: провал ТИХИЙ — система рапортует успех по своей метрике.

Вопрос на оставшийся раздел — НЕ «какой тип», а «почему самый безобидный по цене ошибки тип может оказаться опаснее громких провалов?»

РАЗДЕЛ 5

Рекомендации и динамическое ценообразование

Последний тип — самый «безобидный» по цене ошибки, но с самыми тонкими патологиями.



Раздел 0
Открытие

Раздел 1
Прогноз

Раздел 2
Аномалии

Раздел 3
Скоринг

Раздел 4
LLM

Раздел 5
Рекоменд.

Раздел 6
Фреймворк

Два базовых подхода рекомендаций — и слабость у каждого по имени.

Collaborative — «спроси похожих на тебя»	Content-based — «ещё похожее по описанию»
матрица пользователь × товар	атрибуты товара (жанр, бренд)
⊕ ловит неожиданные связи	⊕ нет cold-start нового товара
⊖ cold-start + popularity bias	⊖ over-specialization (ниша)

Аналогия-якорь: три продавца (collaborative · content · hybrid)

 Collaborative	 Content-based	 Hybrid
«Брали то же, что вы — ещё взяли вот это»	«Похоже по описанию на вашу любимую вещь»	«И что брали похожие, и что похоже + контекст»
помнит ПАТТЕРН поведения, не знает товар	знает КАТАЛОГ наизусть, не знает толпу	совмещает оба + ситуацию (вечер пятницы, телефон)

Запомнить: ЧТО это за подходы и КАКАЯ слабость по названию у каждого — collaborative (паттерн поведения) vs content (суть товара).

Гибрид смягчает слабости — но без явного разнообразия пузырь не отменяет.

Hybrid recommender

collaborative + content-based + контекст. Контентная часть закрывает cold-start, коллаборативная ломает over-specialization. Большинство промышленных систем.

Amazon

~35%

выручки — от рекомендаций

Netflix

~75%

просмотров — от рекомендаций

Историческая оценка (восходит к McKinsey ~2013), НЕ свежий верифицированный показатель — поэтому числом, не графиком-«фактом».

Filter bubble (информационный пузырь)

показал похожее → пользователь взаимодействует с похожим → модель показывает ещё более похожее. Сужение разнообразия — НЕ злой умысел, а следствие оптимизации на краткосрочную релевантность.

Dynamic pricing

автоподстройка цены под спрос/время/контекст. Восприятие справедливости и закон — ОГРАНИЧЕНИЯ задачи, а НЕ оптимизируемые переменные.

Filter bubble возникает без всякого умысла — прямое следствие «угадать, что купишь сейчас». Гибрид это сужение автоматически НЕ отменяет.

Система рапортует успех по своей метрике — пока разрушает, что в метрику не попало.


Корень — прокси $\neq$ цель

система оптимизирует измеримое в моменте (ПРОКСИ: клики, время, маржа) $\neq$ настоящая цель (доверие, благополучие). Расхождение $\rightarrow$ filter bubble, dark patterns, гомогенизация.

Кейс G — Wendy's, февраль 2024

~\$20 млн в цифровые меню-борды с динамическим ценообразованием $\rightarrow$ СМИ прочитали как surge-pricing $\rightarrow$ #BoycottWendys, конкурент обыграл в рекламе $\rightarrow$ откат за дни. Деньги вложены, технология доступна — провалилось игнорирование того, что справедливость восприятия = ОГРАНИЧЕНИЕ, а не переменная.

Почему провал ТИХИЙ:



дашборд зелёный, доверие падает

Критерий:

- прокси $\neq$ цель $\rightarrow$ serendipity + объяснимость + аудит на дискриминацию
- цена — решение ЧЕЛОВЕКА В ПРАВОВОЙ РАМКЕ, не выход оптимизатора

Единый класс через всю лекцию: ассурасу-обман, прокси-bias скоринга, Klarna, filter bubble — ПРОКСИ $\neq$ ЦЕЛЬ. Чем мощнее оптимизатор, тем дороже расхождение. Провал тихий.

Назвать тип под структуру задачи — и иногда правильный тип это не ИИ.

Задача	Тип ИИ · почему именно он	Типичный провал
 Прогноз спроса / cash-flow / отток	Прогноз рядов (ARIMA/бустинг) — числа с трендом, не текст	distribution shift × необратимое авто (Zillow)
 Фрод real-time / AML	Поиск аномалий + rules-engine — норма/отклонение	FP на масштабе; accuracy лжёт при дисбалансе
 Кредитный скоринг	Табличный ML (логрег/GBM+SHAP) — объяснимость = закон	прокси-bias + непрозрачность (Apple Card)
 Поддержка / голос / объяснение	LLM (grounded) — текстово-диалоговая задача	галлюцинация финфакта = юр.ответственность (Air Canada)
 Рекомендации / ценообразование	Recsys; pricing — оптимизатор в рамке	прокси≠цель: filter bubble (Wendy's)
 Детерм. регуляторная задача (жёсткий AML-порог)	Обычный код / rules-engine — НЕ ИИ; закон ≠ вероятность	ИИ добавил бы недетерминизм + поверхность ошибки

Нижняя строка — намеренно. Жёсткое верифицируемое регуляторное правило → детерминированный код, НЕ ИИ: ИИ добавил бы недетерминизм там, где нужны точность и аудит.

Содержательный ответ на центральный вопрос лекции.

Ни в одном из пяти провалов исправление — это «лучшая модель». Во всех — лучшее **СУЖДЕНИЕ** о том, что стоит вокруг ИИ на цене ошибки.

Пять кейсов лекции — одно и то же лекарство (НЕ модель):



Это и есть ответ: не «ИИ хорош/плох», а «назвать тип, обосновать выбор и спроектировать обвязку под цену ошибки».

Финданные, PII (персональные данные) и биометрию нельзя в публичный LLM.



(А) Данные и закон: ФЗ-152 / PII

- финданные + PII + биометрия = чувствительные; ФЗ-152 — локализация ПДн граждан РФ, биометрия = строгий режим
- публичное облако: данные покидают контур · нет контроля retention · аудируемость падает
- критерий — по чувствительности данных и режиму, НЕ по силе модели



(Б) CV-пласт: KYC, биометрия, скрытый труд

- KYC = идентификация клиента; liveness — перед камерой живой человек, не фото/маска/дипфейк (строгий режим)
- Just Walk Out (Amazon) свёрнут 2024: «автономная» касса опиралась на > 1000 ревьюеров в Индии — скрытый труд
- Bias компьютерного зрения углубляется в Лекции 7.

Биометрия необратимо скомпрометирована при утечке — та же логика «необратимое → строгий гейт», что прошла через всю лекцию.

Пароль



Утёк → сменил. ОБРАТИМО

vs

Лицо / отпечаток



Утекло → новое не выдать. НЕОБРАТИМО

«Полностью автономно» в маркетинге — гипотеза для проверки, не факт (Amazon оспаривал масштаб).

Прежде чем применять ИИ к финансовой / ритейл-задаче:

1. Какой тип ИИ диктует структура задачи?
2. Почему НЕ LLM здесь? (≥ 1 структурная причина)
3. Можно ли решить вообще без ИИ? (правило $\rightarrow$ код)
4. Обратимо ли действие на выходе? (необратимое $\rightarrow$ gate)
5. Как проверить факт? (класс ошибки + принцип)
6. Регулируемо ли решение? (reason codes / appeal)
7. Кто отвечает и где человек обязателен?
8. Есть ли PII / финданные / биометрия? $\rightarrow$ не в LLM; ФЗ-152

Задание — Семинар 5 «Проверка фактов AI на финансовых данных»

Команды за ~30 мин сами проверяют 5 реальных заявлений по первоисточникам (Банк России / ВЦИОМ), маркируют верно/частично/ложь. Лекция учит распознавать класс (Understand); семинар — самостоятельно верифицировать (Apply).

Вопросы

Палитра типов — линза для всех отраслевых лекций дальше. Спасибо за внимание.