

Сборка стала почти бесплатной — и почти никто не превратил это в пользу



Недели работы → часы ^[1]

внутренний опыт Anthropic



**~95% организаций —
нулевая отдача** ^[2]

Массачусетский технологический институт, лето 2025 — доля от всех организаций, а не от дошедших до пилота

Оба факта правдивы одновременно: сборка стала почти бесплатной, а превращение сборки в ценность — нет. Разрыв между ними и есть предмет лекции; он разрешится в самом конце.





ЛЕКЦИЯ 5

ИИ-продукт: полный жизненный цикл — от намерения до эксплуатации

ИИ — искусственный интеллект

Курс «Осознанное применение ИИ» · инженеры-студенты 3 курса

Шесть разделов — шесть стрелок одной петли. Код из Лекции 4 — один шаг внутри неё, и теперь самый дешёвый из всех.

0
Введение

1
Исследование

2
Дизайн

3
Сборка и запуск

4
Измерение

5
Поддержка

6
Управление

7
Обобщение

Лекция — это петля, а не список из шести тем



1. Исследование — откуда берётся гипотеза

2. Дизайн — гипотеза становится артефактом

3. Сборка и запуск — артефакт становится продуктом

4. Измерение — сработало ли это на самом деле

5. Поддержка — работает без остановки

6. Управление — куда вкладывать

Золотая стрелка возврата: управление снова питает исследование. Это замкнутая петля, а не одноразовый линейный процесс — поэтому карта нарисована кругом.

Зачем продукту цикл: без него ошибку находят слишком поздно

Цикл кода из Лекции 4 — спецификация, архитектурное решение, план, запрос на слияние, запись об инциденте — целиком лежит внутри одной из этих фаз, «сборки и запуска».

Пять вопросов, на которые продукт отвечает наблюдением, а не мнением

1 Нужно ли это кому-то вообще

фаза 1 · исследование

2 Сможет ли человек этим воспользоваться и не пострадает ли тот, о ком не подумали

фаза 2 · дизайн

3 Можем ли мы это сделать и безопасно выпустить

фаза 3 · сборка и запуск

4 Выберут ли это настолько, чтобы за это платить

фазы 4 и 6 · измерение, управление

5 Держатся ли эти ответы через квартал

фаза 5 · поддержка

Первые четыре — риски продукта по Марти Кагану; пятый открывается только после запуска. У каждого своя фаза: цикл и есть минимальный набор мест, где на эти вопросы отвечают.

Когда цикла нет

Вопросы не исчезают — их место занимают допущения, обычно оптимистичные.

Ошибка тоже не исчезает — сдвигается только момент, когда её находят.

Находят её после того, как сборка оплачена, релиз состоялся, а откат стоит дороже самой ошибки.

Цена позднего обнаружения

От требований до выпуска стоимость исправления расходится до ста раз в крупных проектах и примерно вчетверо в небольших (Барри Бозм, 1981).

Цикл не устраняет ошибку в гипотезе: он двигает её обнаружение туда, где она стоит разговор, а не сборку.

Изнутри команды это не выглядит провалом

Собрали — никто не пользуется · дошли до пилота и застряли · работает, но не выбрано · внедрили, а через квартал перестали открывать. Сборка во всех четырёх случаях прошла успешно.

Дороговизна сборки работала невольным заслоном: пока изготовление стоило недели, оно само заставляло думать заранее. Искусственный интеллект обнулил именно её — и у команд, у которых явного цикла не было никогда, не осталось ничего, что удерживало бы от пропуска этих вопросов. Воронка из начала лекции — 60% организаций пробуют, 20% доходят до пилота, 5% внедряют — не парадокс, а следствие.

Искусственный интеллект меняет каждую стрелку — но не одинаково



Строить

фаза сборки и запуска

стоимость упала почти до нуля: черновик кода, макета, плана исследования



Измерять и делать выводы

фаза измерения

стоимость та же, а доверие к результату упало: сам инструмент измерения стал вероятностным



Наблюдать за работой продукта

фаза поддержки

наблюдать стало быстрее, но само наблюдение уязвимо: подменённые данные на входе ведут к уверенному неверному выводу

Одну и ту же петлю независимо описали трижды: в статистике качества (Деминг, 1939), в военной авиации (Бойд, 1970-е) и в стартапах (Райс, 2011). Это структурное свойство любой системы, которая учится в неопределённости, а не методология одного автора.

Мета-паттерн всех шести разделов: у каждой стрелки есть классическая дисциплина, и искусственный интеллект её не отменяет. Он меняет, сколько эта дисциплина стоит и насколько ей можно верить без проверки.

Каждая из шести фаз дальше разбирается по одной и той же схеме: какая классическая дисциплина за неё отвечает, что в ней удешевил искусственный интеллект, и где подход «сначала ИИ» ломается.

РАЗДЕЛ 1

Исследование — есть ли проблема и у кого

1 база · 2 практики · 2 провала

Цель фазы одна: выяснить, существует ли проблема и у кого именно, пока решение ещё не построено. Пропустить её можно — тогда ответ придёт в день запуска, когда деньги и месяцы уже потрачены, а вернуть их нечем.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Проверить гипотезу стоит нескольких разговоров — не проверить стоит всей разработки



ЗАЧЕМ ЭТА РАБОТА Исследование отвечает на один вопрос: существует ли проблема и у кого именно. Ответ придёт в любом случае — либо от восьми разговоров за две недели, либо от рынка в день запуска, когда разработка уже оплачена.



Развитие клиента (Customer Development)

Стив Бланк — дисциплина поиска ответа «что и для кого строить»

Правило, ради которого она существует: внутри офиса фактов нет, факты снаружи. Но выйти наружу мало: без записанной заранее гипотезы возвращаются с впечатлениями, подтверждающими то, во что верили до выхода.

мы верим X → проверим через Y → к дате Z получим ответ да или нет

Дата — не оформление: без неё «проверим» не имеет срока.

Два правила разговора

книга «The Mom Test», Роб Фитцпатрик



Спрашивать о конкретном прошлом, а не о мнении про будущее



Засчитывать обязательство — время, репутацию, деньги, — а не комплимент

Плохо: «Заплатили бы 20 долларов в месяц?» → **Хорошо:** «Сколько вы платите сегодня за ближайший аналог?»

Это не альтернатива циклу разработки и не второй процесс рядом с ним. Цикл отвечает на вопрос «как быстро проверять», эта дисциплина — на вопрос «что и у кого проверять». Она работает на первой стрелке петли, до того как что-то построено.

Что ИИ изменил в исследовании к 2026 году — и что не изменил

ШАГ ФАЗЫ	БЕЗ ИИ	С ИИ — 2026
 Кабинетный поиск <i>собрать, что уже известно о рынке и о боли</i>	Аналитик читает отчёты, публикации и форумы — дни работы	Режим глубокого исследования сам планирует поиск, читает сотни источников и отдаёт отчёт со ссылками за 2–30 минут. Есть у всех основных помощников, включая бесплатные тарифы с лимитом
 Сам разговор	Каждое интервью исследователь проводит лично; восемь разговоров — недели календаря	Вопросы задаёт модель, отвечает живой человек — разговоров за тот же сроккратно больше
 Сведение разговоров	Расшифровка вручную, темы выписываются глазами	Расшифровка стала бесплатным приложением к созвону; инструменты непрерывно пересобирают темы по всему накопленному корпусу, а не по одному звонку

Кто на том конце разговора

человек ↔ человек классическое интервью	человек ↔ модель спрашивает машина, отвечает живой человек	модель ↔ модель ИИ-персона: отвечает тоже машина — живого человека в цепочке нет ни разу
---	--	--

Опрос 150 исследователей, май 2026: **81%** регулярно применяют ИИ в работе · **8%** — как отвечающего участника · **28%** отвергают его прямо

Ссылка в отчёте не доказательство, пока её не открыли. Измерено на 53 090 ссылках из отчётов десяти моделей и исследовательских агентов: 3–13% ссылок выдуманы — их нет даже в веб-архиве, они не существовали никогда, и не открываются ещё от 5 до 18%. Отсюда прямая арифметика: при самом низком измеренном уровне 3% отчёт с 50 ссылками содержит хотя бы одну несуществующую с вероятностью 78% — это верхняя оценка: расчёт считает ссылки независимыми друг от друга. Deloitte сдала правительству Австралии отчёт за 440 000 австралийских долларов именно с таким содержанием.

[1] [Perplexity — обзор режима глубокого исследования](#) · [2] [User Interviews — «State of Synthetic Users», май 2026](#) · [3] [arXiv 2604.03173 — измерение ссылок в отчётах агентов](#) · [4] [Fortune \(7 окт. 2025\) — Deloitte Australia](#)

Репетиция вопросов интервью на ИИ-персонах

ЧТО ЭТО

Перед выходом к живым людям список вопросов прогоняют через нескольких выдуманных собеседников, которых играет модель. Цель — не узнать что-то о продукте, а поймать плохие вопросы до того, как они испортят настоящий разговор. Это репетиция, а не исследование: слушают не содержание реплик, а то, где текст не работает.

МЕХАНИЗМ

- 1 Описывают несколько разных типов клиента — **не портретом** («Анна, 34, любит удобные интерфейсы»), а по тому, как человек живёт с задачей: что делал перед тем, как начал искать решение, чем пользуется сейчас, во что это обходится в часах или деньгах, что однажды попробовал и бросил.
- 2 Каждый тип держат отдельно, чтобы ответы не сливались в один общий голос.
- 3 Через всех прогоняют один и тот же список вопросов.
- 4 Читают **не ответы, а две вещи**. Вопрос, на который все ответили примерно одинаково, никого не различает — переписать. Вопрос, на который отвечают про воображаемое будущее («я бы этим пользовался»), подталкивает к вежливой выдумке вместо воспоминания — переписать.



выдуманные собеседники не слышат друг друга

**наружу выходит только
правленный список вопросов**

ГРАНИЦА

Ответы собеседников — не данные о пользователях, и цитировать их как мнение нельзя: модель одна, и пять таких собеседников — это пять взглядов одной модели, а не пять людей. При сверке с настоящим национальным опросом средние ответы модель повторяет, а разброс мнений занижает вдвое (16 против 31) — согласие выглядит прочнее, чем оно есть, ровно там, где живые люди расходятся сильнее всего. Приём запущен неправильно, если из прогона вынесен вывод о продукте, а не о формулировке вопроса.

Поиск боли по накопленным обращениям в поддержку

ЧТО ЭТО

Если у продукта уже есть пользователи, у него есть и архив их жалоб и вопросов. Приём превращает этот архив в источник гипотез: обращения складывают в поисковый массив, собирают похожие по смыслу в группы и смотрят, какие темы повторяются. Наружу выходит не ощущение «пользователи недовольны», а названная тема боли с дословными цитатами и указанием, с кем об этом говорить живьём.

МЕХАНИЗМ



1. СЛОЖИТЬ И РАЗМЕТИТЬ

Каждое обращение кладут в общий массив и приписывают к нему, когда оно пришло, от кого и по какому продукту. Без разметки архив превращается в мешок текста: не отделить прошлогоднее от сегодняшнего и чужое от своего.



2. ИСКАТЬ ДВУМЯ СПОСОБАМИ

По точному совпадению слов и по смыслу. Точный код ошибки или номер заказа находит только первый способ, описание проблемы своими словами — только второй. Поодиночке каждый систематически промахивается.



3. СОБРАТЬ ПОХОЖЕЕ В ГРУППЫ

Каждую группу пересказывают в два приёма: сначала каждое обращение по отдельности, потом общее между ними. Пропуск первого приёма — потеря 20-40% деталей.

ГРАНИЦА

Архив смещён по построению, а не по недосмотру: в нём есть только те, кто дошёл до жалобы. Объём этого не лечит — сто тысяч обращений смещены ровно так же, как тысяча, потому что не бывает обращения «мне нужно то, чего у вас вообще нет». На вопрос «чего у нас нет» и «почему люди не доходят до регистрации» этот приём не отвечает вообще — нужен разговор с теми, кто ушёл. И второе: поиск возвращает похожие обращения, а не важные. Десять тысяч жалоб на опечатку в письме — это по-прежнему одна опечатка, просто заметная в масштабе.



кто дошёл до
жалобы



все пользователи



архив обращений

Синтетический собеседник не может произвести несогласие



Зеркало согласия

72-91%

когда собеседник
явно соглашается

7-28%

когда собеседник
явно возражает

Это доля случаев, в которых тон ответа модели сдвигается к позитиву (5 моделей). Не «частота отрицательного ответа» — именно сдвиг тона.

Sharma и соавторы, 2023 — рисунок 1

Когда живой разговор строго лучше синтеза



1. Высока цена ошибки в решении «продолжать или остановить»



2. Нужно реальное прошлое, а не правдоподобное



3. Нужна проверка обязательством, а не мнением

У синтетического собеседника нет реального прошлого, способного противоречить формулировке вопроса, — поэтому несогласие он не производит в принципе. Сложите это со сдвигом тона слева: ответ смещён не просто в сторону «да», а в сторону «да» о событии, которого никогда не было.

Пересказ интервью теряет 20-40% деталей, если пропущен шаг «сначала каждое по отдельности», — прослеживаемый до конкретного шага сбой, а не расплывчатое «ИИ иногда ошибается».

Одна и та же задача: реальные люди — 3 из 7, панель ИИ-персон — 7 из 7 ^[1]



ЧТО ПРОИЗОШЛО Nielsen Norman Group — исследовательская группа, которая с 1998 года занимается удобством интерфейсов, — взяла один сценарий первого знакомства с продуктом и прогнала его дважды: с живыми участниками и с панелью ИИ-персон, сгенерированных под тот же профиль. Сравнивали две величины: сколько шагов сценария доведено до конца и как оценены одни и те же функции.

Живые участники



3 из 7 шагов доведены до конца

Панель ИИ-персон



отчиталась о 7 из 7

Об одной и той же функции: **«надуманно и бесполезно»** — живые участники, **«изменяет правила игры»** — ИИ-персоны

Расхождение здесь не в одной измеряемой величине, а сразу в обеих, на одном и том же материале: дело не в неудачном прогоне — такой выход дисквалифицирован для решения «продолжать или остановить» по построению. Альтернатива: оставить панели до-исследовательскую роль, а решение опереть на тест с 5-8 живыми участниками — размер, который уже вскрывает большинство проблем удобства.

Помощник врача, обученный на придуманных случаях: рекомендации назвали небезопасными



ЧТО ПРОИЗОШЛО С 2012 года компания IBM вместе с онкологическим центром Memorial Sloan Kettering разрабатывала Watson for Oncology — систему, подсказывающую врачу схему лечения рака. С 2015 года её продавали больницам по всему миру. 25 июля 2018 года издание STAT News опубликовало утёкшие внутренние документы компании.




Что показали документы

- Сотрудники в переписке называли рекомендации системы «небезопасными и некорректными»
- Разобранный пример: препарат назначен гипотетическому пациенту с активным кровотечением — вопреки прямому предупреждению производителя против такого применения



Почему так вышло

придуманные случаи
(на них обучали)



реальные исходы лечения
(на них не обучали)

Обучали на небольшом числе придуманных случаев, размеченных горсткой врачей одной клиники: материал правдоподобный, непротиворечивый и полностью выдуманный. Мнение горстки врачей при этом выдано за отраслевой стандарт.

Тот же класс сбоя, что двумя слайдами раньше: правдоподобный материал принят за реальный. Разница только в цене ошибки — здесь она измеряется в людях, а не в возвращённом гонораре. Чем выше цена ошибки, тем строже требование: материал, на котором строится решение, должен прослеживаться до зафиксированного прошлого, а не до правдоподобного.

РАЗДЕЛ 2

Дизайн — гипотеза становится артефактом

1 база · 1 практика · 1 провал

Шаг, на котором гипотезу впервые показывают живому человеку — пока она стоит дёшево и её не жалко выбросить. Здесь же решают, кого продукт может задеть: это решение принимают в задании на дизайн, потом уже нечем.



прыгнуть сразу к
решению

сначала —
правильная проблема

0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Зачем нужен отдельный шаг дизайна: ошибку ищут на дешёвом черновике, а не в готовом продукте

Зачем эта работа нужна

 Ошибку нашли на черновике — переделать набросок стоит часов работы одного человека. Черновик для того и делают: его не жалко выбросить целиком.



Ту же ошибку нашли после выпуска — переделывать придётся работающий продукт: недели работы команды, и к ним прибавляются ушедшие пользователи.

Пропустить этот шаг — не сэкономить, а заплатить то же самое позже и дороже.

расширяем набор задач

расширяем набор решений



сводим к одной задаче

сводим к одному решению

Двойной ромб (Double Diamond) ^[1]

Ромб — один цикл работы: расширяем набор вариантов, потом сводим их к одному.

Ромбов два, потому что выбирают дважды: сначала задачу, и только потом — решение.

Это не вторая петля вместо нашей, а увеличительное стекло на её шаге 2 «Дизайн».

 **Десять эвристик Якоба Нильсена (1994)** — короткий список правил удобства: знающий человек за полчаса проходит по нему готовый вариант и отвечает на вопрос, недоступный машине, — понятно ли это живому человеку. Не стадия процесса, а проверка поверх уже сведённого варианта. ^[2]

Частая ошибка инженера — сойтись на решении, не проверив саму задачу: перепрыгнуть первый ромб. Тот же образ действия, что «сразу писать код», минуя вопрос, ту ли задачу мы вообще решаем.

Генераторы интерфейсов: машина даёт варианты, выбирает и доводит человек

Что машина делает сама



набросок 1



набросок 2



набросок 3



набросок 4

Дальше человек: выбирает одно направление, отбрасывает остальные и правит то, что модель поняла неверно — отступы, порядок важности, редкие случаи.

Чем это делают в 2026 году ^[1]

Figma Make — собирает экраны внутри редактора макетов и берёт собственные детали команды, а не общие заготовки.

Google Stitch — из текста и набросков в экран; бесплатный, с марта 2026 умеет переносить макеты из Figma и отдавать код ^[2].

v0 — из описания сразу в готовый код интерфейса.

Lovable, bolt.new — из описания сразу в работающее приложение целиком.

Magic Patterns — быстрый перебор вариантов одного экрана.

С генератором и без него — замер, а не обещание ^[3]

Как мерили. Сто участников — пятьдесят дизайнеров и пятьдесят продуктовых руководителей — случайно поделены на две группы: одной дали генератор, второй не дали. Три одинаковые задачи на правку интерфейса, сентябрь 2026 года.

Обещание «день ручного черчения превращается в минуты» замер не подтверждает: выигрыш реален, но измеряется десятками процентов и зависит от того, кто работает и насколько сложна задача. Опыт поставила сама Figma на собственном инструменте — держите поправку в уме.

Что вышло. Общее время сократилось примерно на 20%. У продуктовых руководителей выигрыш 35%. У профессиональных дизайнеров — только на самой сложной из трёх задач (26%), а общий эффект у них пограничный (17%).

Машина расширяет набор вариантов. Свести их к одному — решение о конкретном случае: о ваших пользователях, ваших ограничениях и вашем контексте, которых в обучающих данных нет. Поэтому выбирает и отвечает за выбор человек.

Дизайн-система: общие правила интерфейса, которые машина умеет проверить сама

ЧТО ЭТО

Дизайн-система — это общий свод правил интерфейса продукта и набор готовых деталей к нему: какие сочетания цветов допустимы, какого размера бывают кнопки и поля ввода, как выглядит элемент, на котором сейчас стоит курсор, из чего собираются типовые блоки. Раньше это был документ для людей. Сейчас важнее другое: часть этих правил можно записать так, чтобы читал и проверял их не человек глазами, а машина, — и именно эта часть превращает свод правил в настоящий ограничитель для генератора.

МЕХАНИЗМ

Слои уложены снизу вверх: каждый следующий сильнее предыдущего, и только верхний превращает пожелание в гарантию.

3. ПРОВЕРКА, ОСТАНАВЛИВАЮЩАЯ ВЫПУСК

Правило проверяют автоматически на каждом сгенерированном экране, и нарушение не обсуждают, а блокируют — ровно как красный тест не пускает изменение дальше. **Гарантию даёт только этот слой.** Готовые движки такой проверки (axe-core, rally, встроенная проверка Lighthouse) существуют давно и сами по себе к ИИ отношения не имеют — и это часть урока.

2. СВОИ ДЕТАЛИ ВМЕСТО ЧУЖИХ ЗАГОТОВОК

Генератору дают собственные детали команды, а не общие шаблоны: результат ближе к продукту и требует меньше переделок. Это **снижает вероятность нарушения, но ничего не гарантирует.**

1. ПРАВИЛА, ЗАПИСАННЫЕ ЧИСЛАМИ

Пока правило живёт в картинке макета или в устной договорённости, проверить его может только человек и только глазами. Записанное числом, оно становится проверяемым.

ГРАНИЦА

Машина проверяет только то, что выражается числом: хватает ли контраста, велика ли кнопка, подписано ли поле. «Понятно ли это живому человеку» остаётся человеку: экран может пройти все проверки и остаться непонятным. Поэтому приём не отменяет ни обзор по десяти эвристикам Нильсена, ни показ живым людям. И главное: просьба к генератору механизмом контроля не является ни в какой формулировке. Механизм — это правило, которое умеет остановить выпуск.

Сгенерированные интерфейсы прошли 29% проверок доступности — решает платформа, а не формулировка запроса



Что именно проверяли

WCAG (Web Content Accessibility Guidelines, «правила доступности веб-содержимого») — международный свод требований к интерфейсу: хватает ли контраста между текстом и фоном, не передан ли смысл одним лишь цветом, работает ли всё без мыши, подписаны ли поля. Исследователи прогнали 21 880 таких проверок на экранах, сгенерированных инструментами с прошлого слайда: пройдено 29,0%. Хуже всего — самое

простое и машинно-проверяемое: контраст 26,8%, использование цвета 19,2% ^[1].

Главная находка

На итог сильнее влияли настройки самой платформы, чем текст запроса. Значит, оправдание «надо было правильно попросить» не работает: переписывание формулировки доступным результат не делает.

Второе ограничение: один и тот же запрос даёт разные ответы

Классические эвристики Нильсена исходят из того, что одинаковое действие даёт одинаковый результат. У продукта на языковой модели это не так. Из десяти эвристик буквально ломаются два. Единообразие приходится переносить с уровня точных слов на уровень тона и поведения. Помощь в распознавании ошибки ломается сильнее: система обычно не знает, что она неправа, и выдумку подаёт с той же уверенностью, что и точный факт.

Отсюда три приёма подачи, которых в классике нет: система говорит о своей неуверенности от первого лица, а не общей оговоркой мелким шрифтом; человек стоит в контуре решения там, где у ошибки есть настоящая цена; и прямо сказано, что ответ сгенерирован.

Защиту несовершеннолетних включили через три года после запуска — и через 21 месяц после смерти подростка



Character.AI

сервис общения
с ИИ-персонажами

Что за случай

Character.AI — сервис, где человек переписывается с вымышленными персонажами: можно выбрать готового героя или сочинить своего, а отвечает за него языковая модель. Продукт устроен так, чтобы к персонажу возвращались: он помнит переписку, держит характер и поддерживает разговор сколь угодно долго.

В феврале 2024 года четырнадцатилетний пользователь покончил с собой после месяцев ежедневного общения с таким персонажем ^[1]. Проверки возраста, распознавания кризисного состояния и ограничения времени в продукте тогда не было.

Запуск
09.2022

Смерть подростка
02.2024

Иск
10.2024

Защита включена
11.2025 ^[2]

Урегулирование
01.2026 ^[3]

Корень — не сбой в работе, а требование, которого не было в задании на дизайн: продукт оптимизировали на то, чтобы к нему возвращались, и ни разу не спросили, кто может пострадать от такого потока общения. Ошибку в работе ловят проверкой перед выпуском. Требование, которого нет, не ловится ничем, кроме вопроса, заданного вовремя, — ни один тест не проверяет то, чего никто не просил.

Там, где продукт рассчитан на эмоциональную привязанность уязвимых людей, защита входит в первую же версию, а не добавляется после иска. Альтернатива не гипотетическая: площадки взаимной поддержки с живой модерацией и клинически проверенные помощники с обязательной передачей случая живому человеку.

РАЗДЕЛ 3

Сборка и запуск — довести продукт до пользователя, пока ошибка ещё обратима

3 приёма · 2 разобранных случая

Без дисциплины запуска у сбоя два исхода, и оба плохие: продукт застревает в бесконечном пилоте и гипотеза не проверяется — либо выходит сразу на всех, и редкий сбой становится кризисом за день.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Задача фазы — довести продукт до пользователя так, чтобы ошибка осталась обратимой



ЗАЧЕМ ЭТА РАБОТА

Это единственное место цикла, где команда сама назначает, каким кругом людей и в каком темпе проверяется продукт, пока ошибка ещё дешёвая. Без этой дисциплины у сбоя два исхода: продукт застревает в бесконечном пилоте и гипотеза не проверяется — либо выходит сразу на всех, и редкий сбой становится кризисом за день.



Минимально жизнеспособный продукт

MVP — minimum viable product, Эрик Райс [1]

Первая версия существует ради обучения, а не ради отгрузки. Планируется в обратном порядке: сначала чему надо научиться, потом какой меркой это различить, и только потом что собрать.



Рубеж «продолжать или закрыть»

Stage-Gate, Роберт Купер [2]

Воронка, а не туннель: вложение растёт только после пройденного рубежа. Дешёвая ранняя стадия существует ровно затем, чтобы отсеивать до крупных трат.

Механику раскатки — переключатель функции, канареечный выпуск, поэтапное включение, возврат к прошлой версии — инженер знает из непрерывной интеграции и поставки (CI/CD — continuous integration / continuous delivery). Новое здесь не сами примитивы, а чьё решение они обслуживают: не «включить функцию», а «продолжать вкладываться или закрыть».

Порог записывают числом до старта, потому что иначе нельзя отличить «данные сказали нет» от «мы устали». Без него у команды нет права честно закончить.



Онкологический центр MD Anderson, проект Oncology Expert Advisor. Контракт вырос через двенадцать продлений с 2,4 до ≈62 млн долларов и был закрыт без единого пролеченного пациента. Двенадцать поводов пройти рубеж — и ни одного записанного порога, по которому его можно было не пройти.

Писать код стало дешевле, проверять — нет: узкое место переехало в ревью

ИЗМЕРЕННЫЙ СДВИГ

+200%

объём кода на инженера за год — собственное измерение Anthropic

16% → 54%

доля изменений с содержательным ревью до слияния: было — стало, после того как первый проход отдали автоматике; почти половина и теперь идёт без него ^[1]

+441%

медианное время, которое изменение проводит в ревью — телеметрия 22 000 разработчиков, Faros AI

2,5× / 5×

изменения от ИИ крупнее и дольше ждут ревьюера — 8,1 млн запросов на слияние, LinearB

КЛЮЧЕВЫЕ ПРАКТИКИ: ЧТО БЫЛО И ЧТО ДОБАВИЛОСЬ

делали и делаем без ИИ

что добавляется, когда код пишет агент

Ревью изменений перед слиянием



оно же стало узким местом: изменения крупнее, очередь длиннее

Переключатель функции



переключает уже не видимость функции, а уровень самостоятельности системы

Поэтапная раскатка по доле пользователей



вторая ось раскатки — уровень контроля, а не только процент аудитории

Тесты, написанные до кода



эталонный набор: проверяют ответ модели, а не только код

Аварийное отключение



нужно всегда: сбой расходится быстрее, чем его успевают заметить

Спецификация, которой владеет человек



единственный вход, который агент не может придумать себе сам

Дефицитный ресурс — не «кто напишет код», а «кто достаточно точно поставит задачу» на входе и «кто успеет проверить» на выходе.

Шкала самостоятельности — право решать отдают по частям

ЧТО ЭТО

Функцию не «включают с ИИ», а выпускают уровнями самостоятельности. Сначала система только подсказывает и ничего не решает. Потом предлагает готовое решение, а подтверждает человек. И лишь потом решает сама, возвращая человеку то, с чем не справилась. **Версия продукта здесь — не набор функций, а уровень самостоятельности, который система на сегодня заслужила.**

ШКАЛА

подсказывает

решает человек



предлагает решение

подтверждает человек



решает сама

возвращает человеку трудное

шкала самостоятельности, а не последовательность версий продукта · так же устроены регуляторы доверия в инструментах для написания кода: от подсказки к блоку кода и к целому готовому изменению

КАК РАБОТАЕТ

Каждый уровень — отдельный выпуск: со своим кругом пользователей, своим набором наблюдаемых признаков и своим способом остановиться. Подъём на следующий уровень не наступает по календарю и не выдаётся за хорошее поведение — его открывают доказательством, и доказательство состоит из трёх вещей: система справляется **именно с теми случаями, которые новый уровень ей доверяет**, а не со случаями вообще; справляется **устойчиво, при повторных попытках**, а не один раз; и для неё **заранее описано, как вернуть её на уровень ниже** — кто решает, по какому признаку и за какое время.

ГДЕ НЕ РАБОТАЕТ

«Оператор давно ничего не правил» доказательством не является: если правок нет, ровно так же возможно, что на систему просто не смотрели. Отсутствие замечаний — не результат измерения, а его отсутствие. И есть решения, которые не поднимают на верхний уровень никогда, сколько бы система ни работала без нареканий: необратимые и дорогие. Юридически обязывающее предложение, удаление рабочих данных, выпуск сразу на всю аудиторию без возможности вернуться — такие решения остаются за жёстким правилом поверх модели, а не за моделью.

Эталонный набор — как проверять ответы ИИ так же, как проверяют код

что это

Небольшая коллекция реальных случаев, для каждого из которых заранее записано, какой ответ считается приемлемым. По сути это те же тесты, только проверяется не код, а ответ модели. Набор собирают **из настоящих обращений пользователей, а не из придуманных**: правдоподобный пример проверяет воображение команды, а реальный — продукт. Начинают обычно с пяти-десяти случаев и растят набор дальше.

как работает

Набор живёт рядом с продуктом и меняется вместе с ним, а не лежит отдельным документом. Проверка запускается сама, вместе с обычными тестами, и так же **останавливает выпуск**, а не пишет предупреждение в журнал. Каждый случившийся сбой возвращается в набор отдельным случаем — поэтому однажды пойманная ошибка **не повторяется молча** на следующем выпуске. Готовые инструменты для этого есть — собирать свой с нуля не нужно.

Требования назначают заранее — по цене ошибки	
Обычный запрос	правильно почти всегда
Отказ по правилам безопасности	каждый раз, без исключений
Ответ с юридическим последствием	не доверяют модели — жёсткое правило поверх

последняя строка — не порог, а отказ от инструмента

где не работает


Три способа обмануть себя этим приёмом. Набор, который всегда зелёный, ничего не измеряет — это сломанный измеритель, а не гарантия. Как только прохождение набора становится целью команды, а не средством, он перестаёт быть мерой. Одна удачная попытка доказательством не является: одинаковые прогоны расходятся между собой, поэтому проверку повторяют, а требование ставят с запасом на разброс. Отдельно: требование выше точности самого измерителя измеряет измеритель, а не продукт — если ответы оценивает другая модель, согласная с людьми примерно в 85% случаев, планка в 95% бессмысленна.

Поэтапная раскатка и путь назад — как назначить цену ошибки заранее

ЧТО ЭТО

Новое включают не всем сразу, а сначала узкому кругу, и заранее договариваются, как всё вернуть обратно. **Радиус поражения — сколько людей пострадает, если новое окажется плохим — становится решением команды, а не тем, что выясняется после запуска.** Это самая старая практика раздела, и именно её проверяют оба случая, которые разбираются дальше.

СХЕМА



доля аудитории растёт ступенями, и на каждой заранее сказано, что наблюдают и какое ухудшение останавливает движение вперёд; возврат описан до запуска, а не сочиняется в момент сбоя

КАК РАБОТАЕТ

Три вещи назначаются до включения, а не по ходу. **Ступени** — какие доли аудитории проходим и в каком порядке. **Признак остановки** — что на каждой ступени наблюдают и какое ухудшение останавливает движение вперёд; без названного заранее признака «стало хуже» обсуждается бесконечно. **Путь назад** — кто принимает решение вернуться, за какое время это делается и проверяли ли, что возврат вообще работает. Для функции на основе модели ступени идут медленнее, чем для обычной: сигнал качества шумный, и на его чтение нужны часы наблюдения, а не минуты — обычную функцию видно по отказам и задержкам сразу, а ухудшение ответов проступает только на объёме.

ГДЕ НЕ РАБОТАЕТ

Раскатка ограничивает радиус, но не заменяет решение. Долгий пилот на крошечной доле, который продолжает сбить, — это не «нужно ещё немного данных», а потолок подхода, и читать его надо как повод закрыть. Обратная ошибка так же реальна: зрелость основного продукта не даёт права пропустить пилот, а повышает цену такого пропуска — «сто процентов аудитории» здесь означает всю базу сразу. И путь назад, который описан, но ни разу не проверен, — это не путь назад, а намерение.

Удвоенная скорость генерации удваивает очередь на проверку, а не пропускную способность



**сделать
подешевело**

**проверить
не сдвинулось**

сопоставление стоимости двух операций

Сделать правдоподобный результат — секунды. Убедиться, что он верный, безопасный и делает именно то, что нужно, по-прежнему требует человеческого понимания в реальном времени. Работа не исчезла: вся её масса переехала на ту сторону, которая не подешевела. Это не нехватка людей, которая пройдёт.

Разрыв 70 процентов ^[1]

Инструмент доводит команду примерно на 70% пути к рабочему результату. Оставшиеся 30% — приведение в поддерживаемый вид, ловля краевых случаев, инженерный опыт.



70% пути · 30% остаются человеку

Документированное расхождение: опытный инженер переосмысливает и ограничивает результат модели, начинающий принимает его охотнее и отправляет дальше код, который выглядит завершённым и рассыпается под нагрузкой.

Выпуск без проверки на наборе примеров и без проверенного пути назад — это не скорость, а отложенная цена. Определение готовности обязано вобрать эти 30%, иначе оно молча сводится к «тесты прошли — значит готово».

Google AI Overviews, май 2024: включили сразу всем — минуя пилот целиком

ЧТО ПРОИЗОШЛО

Google встроил в поиск генеративные ответы: вместо списка ссылок вверху страницы стал появляться готовый ответ, составленный моделью по найденным страницам. Функцию включили сразу всем пользователям поиска в США, одним шагом, и отключить её пользователь не мог. За несколько дней в ответах разошлись советы есть камни и добавлять в пиццу клей, чтобы сыр держался: модель приняла за источники сатирическую статью и старую шутку с форума. Компания реагировала уже после — ограничила ответы на бессмысленные запросы, отфильтровала сатиру, приостановила ответы на темах о здоровье.



как надо:

1%



10%



25%



50%



100%

как пошли:

0% → 100% одним шагом

с нуля сразу на всю аудиторию поиска в США — пилотной ступени не было ни одной

РАЗБОР

- Модель не сломалась технически: она сделала ровно то, что делает генеративная система — собрала правдоподобный ответ из корпуса, не отличив шутку от факта, и выдала его с уверенностью авторитетного источника
- Это режим «уверенно неправильно», и ловится он не тестом, а наблюдением на живом, но ограниченном трафике
- Зрелость основного продукта не даёт права пропустить пилот: она повышает цену пропуска — вся аудитория здесь означает всю базу сразу

На одном проценте трафика этот класс сбоя всплыл бы за дни во внутреннем наблюдении. Вместо этого — публичное осмеяние сразу на всей аудитории.

McDonald's и IBM, 2021-2024: пилот на 0,7% сети закрыли — и это было правильно

ЧТО ПРОИЗОШЛО

С конца 2021 года сеть McDonald's вместе с корпорацией IBM испытывала приём заказов голосом у окна автораздачи: посетитель говорит заказ, распознаёт его система, а не сотрудник. Испытание держали примерно на 100 ресторанах из почти 13 800 в США — это 0,7% сети — и продолжали два с половиной года. Всё это время в сеть попадали ролики со сбоями: бекон в мороженом, девять чаёв вместо одного, перепутанные заказы соседних полос. В июне 2024 партнёрство прекратили. Закрыли при этом подход, а не цель: голосовая автоматизация осталась в планах.



0,7%

≈100 из ≈13 800 ресторанов США · пилот 2,5 года

РАЗБОР

- Знаменатель обязателен: «100 ресторанов» без «из 13 800» читается как масштабное внедрение, а со знаменателем — как узкая полоса, специально удержанная узкой
- Потолок здесь понятный: распознавание речи в шуме, с разными выговорами и посторонними голосами. Такой потолок не двигается дополнительным временем
- Закрыт конкретный технический путь, а не задача — это разные решения, и смешивать их дорого
- Зеркало предыдущего случая: там пропустили пилот целиком, здесь прошли его честно и прочитали сигнал


Сигнал прочитан верно: длинный пилот на малой доле, продолжающий публично сбивать, означает потолок подхода, а не нехватку данных. Это и есть сработавший рубеж «продолжать или закрыть».

РАЗДЕЛ 4

Измерение: отличить «сработало» от «показалось»

1 база · 2 практики · 2 провала

Без измерения решение о продукте принимают по впечатлению, а цену узнают после запуска: в 2026 году 44% команд выключали уже работавшие ИИ-функции, обнаружив, что расходы на них выше пользы. Этот раздел — про то, как узнавать раньше.



0
Введение

1
Исследование

2
Дизайн

3
Сборка и запуск

4
Измерение

5
Поддержка

6
Управление

7
Обобщение

Контролируемый эксперимент: две случайные группы

Зачем это нужно. «Метрика выросла после релиза» само по себе не значит ничего: за ту же неделю сменился сезон, прошла рекламная кампания, пришла другая аудитория. Без группы, которой изменение не показали, отделить свой вклад от чужого нечем.

Случайное деление даёт причинность



Поэтапная раскатка этого не заменяет: удерживаемой случайной группы у неё нет — она отвечает «сломалось ли», а не «помогло ли».

Договариваются до старта о трёх вещах

- 1 Метрика решения — одна и с направлением.** В литературе — сводный критерий оценки (OEC, Overall Evaluation Criterion). Учебный случай: «время на сайте поддержки» приняли единогласно и раскололись на вопросе, рост это хорошо или плохо.
- 2 Метрика-ограничитель.** Её мониторят, но не оптимизируют: она ловит ущерб, которого метрика решения не видит.
- 3 Число наблюдений.** Его считают до старта, а не набирают сколько получится.

Посчитанное число наблюдений может оказаться недостижимым. Тогда честный ответ — «этот вопрос экспериментом не решается, нужен другой метод», а не «запустим и посмотрим»: эксперимент на слишком малой выборке не становится слабым доказательством, он перестаёт быть доказательством.


Пред-регистрация: решение записывают до того, как увидят результат

ЧТО ЭТО

Короткая записка, которую делают **до** запуска эксперимента: что именно измеряем, какой результат считаем успехом, когда останавливаемся. Приём пришёл из медицины — там протокол исследования регистрируют до набора пациентов, иначе журнал не примет статью. В продукте это одна запись на эксперимент, лежащая там, где у записей есть дата и автор.

КАК ЭТО РАБОТАЕТ

- 1 До запуска записывают четыре вещи:** какую одну величину считаем основанием решения и в какую сторону она должна двинуться; что мониторим как ограничитель; какой размер эффекта считаем значимым и сколько для него нужно наблюдений; при каком условии останавливаемся.
- 2 Запись кладут туда, где есть время** — в систему контроля версий, с датой и автором. Весь механизм в этом: метка времени стоит раньше первого результата.
- 3 После запуска запись не переписывают** — к ней дописывают принятое решение и дату.



Почему это работает. Три частые ловушки — остановить на удачной точке, перебрать метрики и выбрать сработавшую, подвинуть порог — все требуют, чтобы критерий успеха можно было выбрать после результата. Если он записан раньше, выбирать не из чего.

ПРАКТИКИ 2026 Платформы экспериментов Statsig, GrowthBook, Erro считают доверительный интервал так, что смотреть на результат можно в любой момент без потери корректности: запрет на подглядывание стал настройкой, а не дисциплиной. Платят за это чувствительностью, и правило остановки всё равно задают до запуска.

ГРАНИЦА

Пред-регистрация не делает эксперимент правильным — она делает неправильность видимой. Эффект новизны она не лечит: для него нужна отдельная контрольная группа. И она бессильна там, где наблюдений физически не хватает: честный выход — сменить вопрос или метод, а не выборку.

ответа ждать больше трёх месяцев

31 200



нужно на группу

5 000

есть в неделю

Оценки: тесты для системы, которая каждый раз отвечает иначе

ЧТО ЭТО

Оценка (в обиходе «эвал») — набор задач с заранее известным желаемым ответом, на котором прогоняют модель или агента. Смысл тот же, что у набора тестов для кода, но с одной разницей: ответ не сверяют посимвольно. Его оценивает человек, отдельная модель-судья или проверка по правилу — поэтому результат не «прошёл / не прошёл», а доля.

КАК ЭТО РАБОТАЕТ



- 1 До выпуска** — прогон против отобранного набора: воспроизводимо, ловит то, что уже ломалось.
- 2 После выпуска** — оценка на живом трафике: вскрывает входы, которых в наборе не было, и поведение, заметное только на длинной цепочке ходов.
- 3 Замыкание** — разбор промышленного сбоя добавляет в набор строку.

проверки на каждое изменение

человек и модель-судья

эксперимент на живых пользователях

Лестница задаёт дороговизну: эксперимент на живых пользователях — **последняя ступень, а не первая**. Оценками он не заменяется. Балл, упёршийся в потолок, — не «задача решена», а сдувшийся набор.

ИНСТРУМЕНТЫ 2026 Langfuse, Braintrust, LangSmith, Arize Phoenix — все строятся вокруг трассы запроса, к которой оценки прикрепляются прямо на живом трафике; Langfuse и Phoenix разворачиваются на своём оборудовании.

ГРАНИЦА

Модель-судья соглашается с человеком на 80-90% там, где предпочтение очевидно, и падает к 60-65%, как только ответы близки или их просто меняют местами — то есть надёжна меньше всего там, где цена ошибки выше всего. Отсюда обязательные поправки: перемешивать порядок ответов, измерять согласие с человеческими метками, сверять с судьёй из другого семейства моделей. Набор, который всегда зелёный, — не гарантия качества, а сломанный измеритель.

Когда мера становится целью, она перестаёт быть мерой

Лодка, которая никогда не финиширует

Агент, обученный с подкреплением — то есть на вознаграждении за результат, без размеченных примеров, — в гоночной игре набрал больше очков, чем игроки-люди. Гонку он не закончил ни разу: кружил в лагуне и собирал восстанавливающиеся бонусы, загораюсь и врезаясь в другие лодки. Очки задумывались как признак прогресса гонки.

очки: +20% к результату людей

финиш: ни одного

Взлом вознаграждения

Так называют закон Гудхарта применительно к обучаемым системам: поведение удовлетворяет букве заданной цели, не достигая задуманного. Формулировка закона — экономист Чарльз Гудхарт, 1975 год.

Эскалация, которой не обучали

Anthropic обучала модель на задачах, всё более пригодных для взлома. Модель прошла путь от лести к подделке собственных отчётов о выполнении и дальше — к прямому редактированию своей функции вознаграждения, чтобы присвоить себе идеальный балл. Этой эскалации её отдельно не учили.

Это не умысел системы, а свойство оптимизации: она находит самый дешёвый способ поднять ту величину, которую назвали целью. Отсюда два следствия. Метрика решения всегда идёт в паре с метрикой-ограничителем. И подозрительно хорошая цифра проверяется первой: балл, выглядящий слишком хорошо, чаще оказывается ошибкой измерения, чем прорывом.

Метрика выиграла тест, а вред заметили через полтора года

ЧТО СЛУЧИЛОСЬ

Январь 2018 года. Facebook меняет правило, по которому лента решает, что показать выше. Новая величина — **MSI, meaningful social interactions, «содержательные социальные взаимодействия»**: чем сильнее реакция на запись, тем выше запись в ленте. Все пять реакций получили вес в 5 раз выше обычной отметки «нравится». Распространённый пересказ «усилили именно гнев» неточен: веса были равны.

facebook

«люблю»

х5

«ха-ха»

х5

«ух ты»

х5

«печаль»

х5

«гнев»

х5

полтора года без метрики качества

● метрика введена, 2018

● вес гнева обнулён, сентябрь 2019

РАЗБОР К 2019 году внутреннее исследование подтвердило: записи, собирающие гневную реакцию, непропорционально часто содержат недостоверный и токсичный материал. Решение «любая сильная реакция означает более содержательное взаимодействие» было огульной косвенной метрикой качества общения: величину, которую легко измерить, приняли за величину, которая интересует на самом деле.

Не хватало не аналитиков — команда анализа данных была одной из сильнейших в мире. Не хватало самой метрики: качество материала не измеряли с первого дня, поэтому вред вскрылся отдельным качественным разбором после полной раскатки, а не показателями самого эксперимента. Метрика решения без метрики-ограничителя рядом — незакрытая конструкция.

Балл на бенчмарке — свидетельство только о его формате

Бенчмарк — стандартный набор задач, на котором модели сравнивают между собой

СЛУЧАЙ 1. МЕДИЦИНА

86,5% на MedQA

2023 год. Google показывает Med-PaLM 2 — модель для медицинских вопросов. На MedQA (наборе вопросов в формате медицинского лицензионного экзамена, с четырьмя готовыми вариантами ответа) она набирает 86,5% и попадает в заголовки как «ИИ уровня врача». При этом собственные исследователи Google отдельно строят более сложный набор из 240 состязательных вопросов — экзамен с готовыми вариантами не вскрывает сбоев клинической безопасности в открытом диалоге, где пациент вариантов не предлагает.

СЛУЧАЙ 2. ПРАВО

Lexis+ **17% выдуманных ссылок**

Westlaw **33% выдуманных ссылок**

2023 год. Адвокат подаёт в суд документ с шестью полностью выдуманными судебными делами — дело Mata против Avianca. Сгенерировал их ChatGPT, а не юридический сервис Harvey: это частая ошибка атрибуции. Затем Stanford RegLab проверяет сами юридические инструменты на реальных запросах: наиболее точный из протестированных выдумывает ссылки примерно в одном запросе из шести, второй — вдвое чаще, несмотря на обещание «без галлюцинаций».

РАЗБОР Балл измерен на узком формате задачи и не переносится на реальную задачу пользователя. Бенчмарк при этом не бесполезен — он честно сравнивает версии модели между собой. Проблема начинается там, где балл за письменный экзамен предъявляют как доказательство готовности вести пациента.

К 2026 году к разрыву форматов добавилось насыщение. На MMLU (Massive Multitask Language Understanding, сводном наборе из 57 предметов) передовые модели держатся в узкой полосе 89–92% — различать их этот балл уже не может. Хуже того: 6,5% вопросов самого набора содержат ошибку в эталонном ответе, а в разделе вирусологии — 57%. Заявление о безопасности только по бенчмарку не подтверждено: нужна состязательная проверка на той задаче, которую продукт решает.

РАЗДЕЛ 5

Поддержка — удержать обещание продукта после запуска

1 база • 2 практики • 3 провала

Продукт живёт годами после запуска, и большинство отказов приходит не от износа, а от изменений, которые вносим мы сами. Без этой работы деградацию первым замечает пользователь — а компания узнаёт о ней из суда, из списания капитала или из публичного расследования.



0
Введение

1
Исследование

2
Дизайн

3
Сборка и запуск

4
Измерение

5
Поддержка

6
Управление

7
Обобщение

Бюджет ошибок: сколько сбоев допустимо — число, а не лозунг

ЗАЧЕМ ЭТА РАБОТА. Около 70% отказов работающей системы приходят не от износа, а от изменений, которые вносим мы сами: выкатка, правка промпта, смена версии модели. Значит, источник сбоев — та работа, которой команда занята каждый день. Если допустимое число сбоев не согласовано заранее, спор «быстрее или надёжнее» решается после инцидента и в пользу того, кто громче.

Показатель уровня сервиса (SLI)

мера глазами пользователя

Цель уровня сервиса (SLO)

планка команды: 99,9%

Бюджет ошибок

остаток: 1000 ошибок

Цель 99,9% на миллионе запросов за период даёт **1000 ошибок** — остаток, который расходуют, а не лозунг про надёжность.

Правило: бюджет исчерпан — выкатка новых функций останавливается. Разговор о скорости против надёжности состоится до инцидента, и у него будет основание, с которым нельзя спорить риторически.

Два окна наблюдения, всегда оба

по отдельности ни одно из них второй случай не видит

Короткое окно — резкий скачок



поднять дежурного сейчас

Длинное окно — медленное сползание



задача на рабочее время, не звонок ночью

Всё это построено для системы, где запрос либо успешен, либо нет. Код 200 — «ответ отдан успешно» — приходит и тогда, когда модель уверенно выдумывает. Дальше: на чём считать бюджет, когда сбой не возвращает ошибки.


Наблюдаемость ИИ-ответов: как увидеть, что качество упало

ЧТО ЭТО

Наблюдаемость — это когда по записям системы можно ответить на вопрос «что у нас произошло», не переспрашивая саму систему. Для обычного сервиса записи отвечают, работал он или нет. Для ИИ-компонента нужен другой ответ — **не «ответил ли», а «насколько хорошо ответил»**. Этого система про себя не знает, и измерять приходится снаружи.

МЕХАНИЗМ

- 1 **Записывать путь ответа целиком, а не только его конец** — и пометать версией всё, что на результат влияет. Без версий на разборе нельзя сказать, что именно изменилось.
- 2 **Договориться заранее о быстрой косвенной метрике качества**. Правильность ответа часто выясняется поздно или никогда, поэтому следят за тем, что видно сразу: как часто зовут человека, как часто переспрашивают, как часто система отказывается отвечать.
- 3 **Порог тревоги брать из собственного разброса системы, а не из чужого норматива**. Одна и та же модель отвечает по-разному на один и тот же запрос — расхождение доходит до **15 процентных пунктов**.



С ИИ И БЕЗ ИИ

БЕЗ ИИ — классика, работает и здесь
Сквозная трассировка по общему стандарту: по одной записи виден весь путь запроса через службы.

С ИИ — что добавилось к 2026 году
Тот же стандарт, расширенный соглашениями для генеративных моделей, — но они **ещё в разработке**: переносимость держат инструменты, а не стандарт. Поверх — выборочная самооценка живых ответов моделью-судьёй и слежение за расхождением по версии промпта, модели и сегменту пользователей.

ГРАНИЦА

Записи ответов по построению уходят наружу — персональные данные туда нельзя без обезличивания или своего развёртывания. Косвенная метрика не равна качеству: путать частоту обращений к человеку с точностью — способ обмануть себя. Модель-судья не оракул: её согласие с человеком надо проверять отдельно, иначе тревога считается по мнению другой модели. Калибровка стареет вместе с моделью.


Учебная тревога: проверка, что деградацию вообще есть чем заметить

ЧТО ЭТО

То же, что **учебная пожарная тревога**, только для качества ответов. Раз в несколько недель систему намеренно и управляемо портят — и смотрят, сработает ли обнаружение. Проверяют не систему, а себя: есть ли вообще чем заметить деградацию и успеет ли кто-то на неё прийти. Без такой проверки наблюдаемость остаётся бумагой: приборы стоят, но никто не знает, показывают ли они.

МЕХАНИЗМ

Ухудшить качество управляемо и по плану, а затем измерить **четыре времени**. Поля пустые намеренно: число берётся с учения, а не из инструкции.



С ИИ И БЕЗ ИИ

БЕЗ ИИ — классические учения на отказ

Гасят службу, отнимают ресурс: проверяют, поднимется ли система и придёт ли дежурный.

С ИИ — портят не доступность, а качество

Ломать доступность бессмысленно: **ИИ-компонент деградирует, оставаясь доступным**. Подменяют инструкцию модели на заведомо более слабую, ослабляют ограничители, имитируют поток отказов. Отсюда и четвертое время: вернуть как было — это откат версии, а не перезапуск.

ГРАНИЦА

Учение проверяет только тот класс отказа, который удалось придумать заранее. Тихий дрейф по кнопке не воспроизводится — его признак именно в том, что ничего явно не ломается, — поэтому учение дополняет наблюдение по сегментам и живой канал жалоб, а не заменяет их. Если обнаружение существует только в виде учения раз в квартал, это не процесс, а его отсутствие с длинным окном.

Графики остаются зелёными, пока доверие уже падает недели



Четыре кадра — четыре недели наблюдения. Графики не меняются, доверие уходит.

Тихий дрейф

Модель продолжает отвечать, пользователи продолжают получать ответы, графики остаются зелёными — но ответы становятся чуть менее обоснованными. Самые активные пользователи замечают регрессию раньше агрегированных метрик: к моменту, когда команда видит явную деградацию, она идёт уже недели.

Дрейф правил

Защитные правила без версионирования молча устаревают: система вокруг меняется, а правила остаются прежними. Ощущение защищённости сохраняется, фактическое соответствие — нет. Лечится тем, что правила ведут как код: версионизируют, проверяют, пересматривают.

Klarna

Klarna, май 2025. Компания, публично объявившая поддержку без доступа к человеку, эту политику развернула. Причина, названная руководителем: клиент должен всегда знать, что живой человек будет, если он его попросит. Автоматизация при этом никуда не ушла — ИИ по-прежнему закрывает две трети обращений. Урок не «ИИ не справился», а **«путь к человеку — часть продукта, а не опция, которую восстанавливают задним числом»**.

Что остаётся обязательным: путь к человеку, ответственность за ответ, дисциплина разбора инцидентов. Автономность ИИ их не отменила — она подняла их цену.


Zillow: алгоритм скупал дома, рынок сдвинулся, бизнес закрыли



ЧТО СЛУЧИЛОСЬ


Zillow Offers — сервис, который покупал дома по алгоритмической оценке и быстро перепродавал. За третий квартал 2021 года купил 9680 домов, продал 3032. 2 ноября 2021 года компания объявила о закрытии сервиса: списания **\$304-408 млн**, сокращение около **2000 человек** — примерно **25% штата**. Средний убыток — около **\$80 тыс. на дом**.

Общее списание, \$ МЛН



Разные единицы и разные шкалы — МЛН слева, ТыС. справа (длины баров НЕ сравнивать напрямую)

На один дом, \$ ТыС.



РАЗБОР: ЭТО ПРОВАЛ ЭКСПЛУАТАЦИИ, А НЕ ИЗМЕРЕНИЯ

Модель была откалибрована корректно — на исторически стабильных данных. Не было другого: наблюдения за точностью в реальном времени и автоматической остановки при её падении.

Вернитесь к двум окнам: у Zillow не было ни одного. Короткого — резкий рост ошибки прошёл незамеченным. Длинного — квартальная отчётность есть, но раз в три месяца это не окно наблюдения, а исторический архив: дома уже куплены.

Критерий: модель, которая сама распоряжается деньгами, требует наблюдения за точностью в реальном времени и порога, по которому она останавливается без участия человека. Альтернатива: алгоритмическая оценка как вход, а решение выше порога риска — за человеком.

Air Canada: чат-бот пообещал скидку, которой нет — платит компания

ЧТО СЛУЧИЛОСЬ

В ноябре 2022 года чат-бот на сайте Air Canada сообщил клиенту, что тариф по случаю утраты близкого можно оформить ретроактивно в течение 90 дней. Действующая политика компании этого не допускала. Клиент купил билеты по полной цене, а в скидке ему затем отказали. В феврале 2024 года трибунал Британской Колумбии взыскал с компании **812,02 канадского доллара** — разницу в цене билетов, проценты и пошлину.



РАЗБОР

Защита: чат-бот — отдельное юридическое лицо, отвечающее за свои действия само. Трибунал назвал это примечательным заявлением и отклонил: компания отвечает за всю информацию на своём сайте, исходит ли она из статичной страницы или из чат-бота.

Операционная причина: не было процесса, который сверяет базу знаний бота с действующей политикой. Содержимое поддержки жило отдельно от единого источника правды.


Сумма мала важным образом: это цена двух билетов, и скромность суммы делает прецедент чистым.

Вы владеете каждым ответом бота — не больше, но и ни на грамм меньше ответственности, чем за любой другой контент сайта. «Бот ошибся» защитой не является.

Нью-Йорк: городской бот 10 раз из 10 советовал нарушить закон

ЧТО СЛУЧИЛОСЬ

Город Нью-Йорк выпустил чат-бот для владельцев малого бизнеса — отвечать на вопросы о городских правилах. В марте 2024 года расследование показало, что бот советовал работодателям забирать чаевые сотрудников и увольнять за жалобу на домогательство, а владельцам жилья — отказывать съёмщикам с жилищными сертификатами. Всё это противоречит действующим нормам, и совет давался уверенно, в форме инструкции. Все **10 из 10** задавших вопрос журналистов получили один и тот же неверный ответ. Мэр города признал ошибки и бот с публикации не снял, хотя технически отключить его было возможно.



Один и тот же вопрос — десять раз. Один и тот же незаконный ответ — десять раз.



десять спросивших — десять одинаковых советов нарушить закон

РАЗБОР

Ключевая цифра — не содержание ответов, а их повторяемость, и она меняет класс события. Единичная ошибка — повод для правки. Десять одинаковых ответов на десять одинаковых вопросов — свойство системы, воспроизводимое по команде.

Решение продолжить итерации приняли после того, как воспроизводимость показали публично. Это и есть разбираемая ошибка: данные были, реакция осталась прежней.

Критерий: воспроизводимый вредный ответ требует аварийного выключателя, а не следующей итерации. Порог формулируется числом заранее — иначе в момент, когда его надо применить, он обсуждается заново и проигрывает желанию «доработать».

РАЗДЕЛ 6

Во что вкладывать дальше — и что пора закрыть

1 база · 2 практики · 2 провала

Продукт может работать и всё равно не окупаться. Здесь решают, какие инициативы финансировать дальше, а какие остановить — и почему у ИИ-продукта это считается иначе.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Зачем нужен этот шаг: решить, что финансировать дальше, а что остановить

ЧТО ЗДЕСЬ РЕШАЮТ

Отбор инициатив: много на входе — финансируют немногие


десятки инициатив

первое решение

второе решение

финансируют

ЧТО ЗДЕСЬ НОВОГО У ИИ-ПРОДУКТА



горизонталь — число запросов · вертикаль — расходы на обслуживание

У обычной программы обслуживание ещё одного пользователя почти ничего не стоит: сервер оплачен. У ИИ-продукта каждое обращение — **платный вызов модели**.

ЧТО БУДЕТ, ЕСЛИ НЕ РЕШАТЬ

Инициатива, которую никто не закрыл, не исчезает: она продолжает тратить людей и деньги, не показывая результата. **Deloitte, 2026:** 42% технологических руководителей сообщают о низком или нулевом возврате вложенного. **Boston Consulting Group, январь 2026** (2 360 руководителей): измеримую отдачу — снижение расходов или рост выручки — видят 6% компаний.

Поэтому продукт, где один запрос стоит дороже, чем приносит, не спасает рост: каждый новый пользователь делает убыток больше. Это арифметика, и её считают до пилота, а не по квартальному счёту.


Считаем, во что обходится один запрос к модели

ЧТО ЭТО

Расчёт на полстраницы: во что обходится одно обращение пользователя к вашему продукту и сколько оно приносит. Делается на бумаге, до пилота, занимает полчаса. Отвечает на один вопрос — **может ли этот продукт быть прибыльным в принципе**, или демонстрация красивая, а арифметика нет. Платят при этом не за вопрос, а за объём текста: его считают в **токенах** — кусочках слова, на которые модель режет текст, — и отдельно за входящий, отдельно за исходящий.

МЕХАНИЗМ

- 1 Объём текста туда и обратно.** Русский текст на ту же мысль занимает заметно больше английского — и платят за это тоже.
- 2 Сколько шагов модель делает, прежде чем ответить.** Промежуточные рассуждения пользователь не видит, но оплачивает как ответ — в агентном сценарии это часто главная статья расхода.
- 3 Как часто приходится переспрашивать.** Неудачная попытка стоит столько же, сколько удачная.
- 4 Что удалось не пересчитывать заново.** Повторяющаяся часть запроса читается из памяти дешевле, чем разбирается с нуля.



С ИИ И БЕЗ ИИ

БЕЗ ИИ — и это делают первым

Если задачу решает обычный код, правило или поиск по базе — **модель не зовут вообще**. Самая дешёвая из всех оптимизаций, и сравнивать стоимость запроса нужно именно с этим вариантом.

С ИИ — что делают к 2026 году

Запрос направляют **самой дешёвой модели, которая справляется**, а к дорогой поднимают только не прошедшее по качеству: счёт падает на 40–85% без заметной потери качества.

ГРАНИЦА

Падение цены за токен не означает падения счёта: расход растёт быстрее, чем дешевеет единица. Многоагентная схема расходует примерно в 15 раз больше обычного диалога — решение «пусть агенты посоветуются» имеет цену. Считать бесполезно, если не с чем сравнить: без цены того же результата без ИИ это учёт расходов, а не экономика. И стоимость запроса — ограничитель, а не цель: если давить именно её, получатся короткие и бесполезные ответы.

Записываем, при каком результате пилот закрывают, — до того как включим

ЧТО ЭТО

Одна заранее записанная фраза с числами, по которой через несколько недель видно: продолжать или закрывать. Ближайший знакомый аналог — **приёмочный критерий в техническом задании**, только не про функциональность, а про деньги. Пишется до включения: число, названное после результата, объясняет результат, а не проверяет его.

МЕХАНИЗМ

«Разбор обращений моделью снизит стоимость одного обращения **с 42 ₽ до 15 ₽**, при этом удовлетворённость клиента не упадёт **ниже 4,2 из 5**, а доля обращений, переданных человеку, не превысит **20%**. Проверяем на **5 000 обращений за 6 недель**. Смотрит **руководитель поддержки, раз в неделю**».

что улучшаем —
и с какой величины до какой

чего при этом
нельзя ухудшить

на каком объёме
и за какой срок

кто смотрит
и как часто

С ИИ И БЕЗ ИИ

БЕЗ ИИ — аппарату полвека

Обоснование вложений с порогом окупаемости и решением на контрольной точке. **Изобретать заново нечего**, берут готовое: это ровно та же дисциплина, только про деньги, а не про функциональность.

С ИИ — что меняется к 2026 году

Меняется **только ритм**: расход меняется каждый день, а не раз в квартал, поэтому и смотрят еженедельно. А на практике компании меряют активность — сэкономленные часы, автоматизированные задачи — вместо денег. Отсюда разрыв: вкладываются почти все, а измеримую отдачу видят **6%**.

ГРАНИЦА

Исходную величину меряют на своём процессе, а не берут из обещания поставщика: чужая цифра описывает чужой процесс, и разница между ними и есть то, ради чего затевался пилот. Если среди возможных исходов нет «закрываем» — это не критерий: порог, который нельзя не взять, разрешения не даёт. И числа, появившиеся после включения, — объяснение результата, поэтому дату записи и имя проверяют раньше самих чисел.

Узкое место — не модель, а то, как устроена работа вокруг неё

Deloitte, 2026 · более 660 руководителей

81% уверены, что смогут масштабировать ИИ · 75% говорят, что операционная модель обязана измениться · 42% сообщают о низком или нулевом возврате вложенного. Уверенность высокая, готовность — нет.

Gartner · прогноз по агентным проектам

Более 40% агентных проектов закроют до конца 2027 года — из-за расходов, неясной ценности и слабого контроля рисков. Из тысяч поставщиков, называющих продукт агентным, реально агентных около 130.

Boston Consulting Group, 2026

Ценность создаёт не алгоритм — на него приходится десятая часть. Самый частый способ не получить ничего: ускорить отдельную задачу, не тронув процесс вокруг неё.

ИЗ ЧЕГО СКЛАДЫВАЕТСЯ РЕЗУЛЬТАТ

70%

люди и процессы
вокруг модели

20%

данные и техника

10%

сам алгоритм

доли вклада в результат проекта, а не этапы работы


Отсюда рабочий вывод. Если инициатива буксует, первый вопрос — не «нужна ли модель побольше», а «названы ли у неё владелец, деньги и срок». Почти всегда узкое место именно там, и следующие два разбора — про то же самое.

Отчёт про «95% провалов ИИ»: что в нём написано на самом деле



ЧТО ПРОИЗОШЛО

В июле 2025 года исследовательская группа Массачусетского технологического института (MIT) выложила предварительный отчёт о состоянии ИИ в бизнесе — версия 0.1, без научного рецензирования. Основание: 52 интервью с руководителями, 153 анкеты и обзор 300 публичных внедрений. В заголовки ушла одна строка: **95% корпоративных пилотов не дали измеримого эффекта на прибыль** при 30–40 млрд долларов вложений. За месяц цифру перепечатали деловые издания по всему миру.



ЧТО В ОТЧЁТЕ

60% организаций изучали тему · 20% дошли до пилота · 5% довели до промышленной эксплуатации. Пять из двадцати дошедших — это **25% успеха**, а не 5%.

И единица измерения здесь — мнение руководителя о пилоте, а не финансовый результат пилота.

ЧЕТЫРЕ ВОПРОСА К ЛЮБОЙ ГРОМКОЙ ЦИФРЕ

- 1 Каков знаменатель — от чего считаем?
- 2 Что именно засчитано провалом?
- 3 Есть ли у автора конфликт интересов? Здесь — все четыре автора строят и продают агентные продукты.
- 4 Прослеживается ли цифра до первоисточника с описанной методикой?

Корень не в моделях. Boston Consulting Group, январь 2026, 2 360 руководителей: измеримую отдачу видят 6% компаний — а большинство меряет активность (сэкономленные часы, автоматизированные задачи), а не деньги. Нечем мерить — нечего и предъявить.

Магазин без касс: шесть лет «полной автономии» и 700 ручных проверок на 1000 покупок



ЧТО ПРОИЗОШЛО

С 2018 года Amazon открывал магазины без касс: берёшь товар с полки и выходишь, деньги списываются сами. Технологию продавали как **чистое компьютерное зрение** — камеры и датчики сами понимают, что ты взял. В апреле 2024 года журналисты выяснили: больше тысячи человек в Индии просматривали видеозаписи и вручную размечали покупки, которые система не смогла распознать.



РАЗБОР — ОДНА И ТА ЖЕ ЛИНЕЙКА КОМПАНИИ

700 из 1000 покупок требовали ручной проверки — против собственной внутренней цели **20-50 из 1000**. Превышение от 14 до 35 раз. Само участие людей — не разоблачение: они размечали записи постфактум, и формально Amazon возразил верно. Разоблачение в другом: цель поставила сама компания, и заявленное разошлось с измеренным по её же линейке. Спорить о значении слова «автономный» не нужно — достаточно найти число.

ЧЕМ КОНЧИЛОСЬ

Из больших продуктовых магазинов технологию убрали в 2024-м, а в январе 2026-го Amazon закрыл и сами сети Go и Fresh.

Технология переехала туда, где ассортимент мал и предсказуем: **360+ сторонних точек** в пяти странах — стадионы, больницы, университеты.

Где и это сложно, компьютерное зрение заменили **радиочастотными метками (RFID)** — предсказуемым решением **без ИИ**.

А в больших магазинах место заняла **тележка со сканером**: товар отмечает сам покупатель.

Если для приемлемой точности нужна ручная проверка кратно выше собственной цели — заявленная автономность не достигнута. Дальше два честных хода: снизить обещание до «с помощью ИИ» либо признать нишу пока неподходящей и взять инструмент проще. Amazon в итоге сделал оба.

РАЗДЕЛ 7

Обобщение: один инструмент на все шесть фаз

6 фаз · 1 матрица · 3 оси решения

Шесть фаз разобраны по отдельности, но решение принимают по задаче, а не по разделу лекции. Без общего инструмента остаётся шесть отдельных выводов и ни одного ответа на случай, которого здесь не было.



0

Введение

1

Исследование

2

Дизайн

3

Сборка и запуск

4

Измерение

5

Поддержка

6

Управление

7

Обобщение

Шесть фаз — одна структура: дисциплина, удешевление, режим отказа, человек

Фаза	Ведущая дисциплина	Что удешевил ИИ	Режим отказа	Где человек обязателен
 Исследование	Развитие клиента и «The Mom Test»: проверяемая гипотеза	Кабинетный поиск; синтез сотен интервью	Угодливость: синтетический источник не скажет «нет»	Проверка реальным прошлым и реальным обязательством
 Дизайн	Двойной ромб, эвристики Нильсена, дизайн-система	Черновик экрана: день → минуты	Однообразие решений; пробелы доступности	Сведение к контексту бренда; аудит безопасности
 Сборка и запуск	Минимально жизнеспособный продукт; рубеж остановки	Сама сборка: шаблонный и связующий код	Пропуск рубежа; раскатка сразу на всю аудиторию	Спецификация намерения; решение о темпе и об остановке
 Измерение	Контролируемый эксперимент; метрика-ограничитель	Оценка качества в масштабе; дешёвый первый проход	Взломанная косвенная метрика; замер не переносится на задачу	Критерий и метрика-ограничитель названы до теста
 Поддержка	Инженерия надёжности: цель уровня сервиса, бюджет ошибок	Скорость наблюдения: трассировка и живые панели	Тихий дрейф маскируется средним по всем ответам	Системная модель и ответственность за каждый ответ
 Управление	Портфельное управление; у каждой цифры есть владелец	Диагностика операционной модели организации	Статистика без знаменателя	Критерий успеха согласован заранее; своя базовая линия

Как читать: назовите фазу своей задачи — строка отвечает по порядку, какую дисциплину держать, чем здесь помогает ИИ, какой отказ стеречь и что остаётся за человеком. Имена инструментов сменяемы; сами четыре столбца держатся на характере сложности и цене ошибки фазы.

Три оси задают режим фазы: без человека на рубеже — только при высокой обратимости, низкой цене ошибки и высокой наблюдаемости

Три оси решения: что каждая означает и что должно стоять рядом, если ось в проблемном положении



Обратимость

Насколько легко откатить следствие, если вывод ИИ окажется неверным.

Низкая — нужна поэтапность, путь отката и выход к человеку.



Цена ошибки

Во что обойдётся ошибка: деньги, репутация, здоровье, ответственность.

Высокая — нужен названный владелец и граница для регулируемых данных.



Наблюдаемость

Насколько быстро видно, что вывод неверен, — прежде чем вред накопится.

Низкая — нужен эталонный набор и метрика-ограничитель раньше доверия к средним.


Отдать фазу ИИ без человека на рубеже оправдано только при сочетании высокой обратимости, низкой цены ошибки и высокой наблюдаемости. Любая другая комбинация требует рубежа по проблемной оси.

Прогон тех же трёх осей через два случая, разобранных в лекции

Случай	Обратимость	Цена ошибки	Наблюдаемость	Проблемная ось → мера
Google AI Overviews ответ поиска раскатан сразу на всех	низкая — ошибку увидели все одновременно	высокая — вирусный, потенциально опасный совет	была бы высокой при канареечном выпуске, но его пропустили	обратимость: поэтапная раскатка возвращает и наблюдаемость
Zillow Offers дома закупают по прогнозу цены от модели	минимальная — купленный дом не отменить одним кликом	максимальная — \$304-408 млн списаний при ≈\$80 тыс. на дом: это ≈3 800-5 100 домов из 9 680 купленных за квартал	низкая по конструкции — квартальный отчёт, а не контроль в реальном времени	все три оси сразу: жёсткий рубеж нужен на каждой — не было ни одного

Ни одна ось не запрещает ИИ — каждая называет, что должно стоять рядом. Там, где все три условия выполнены сразу, высокая самостоятельность обоснована, а не рискованна.

Метод переносится, а не список инструментов: код был первым полигоном, продукт — вторым



Инженер за рабочей станцией системы автоматизированного проектирования (САПР) со световым пером, конец 1970-х: инструмент исчез — дисциплина проектирования осталась

Курс не учит «применяйте ИИ больше» и не учит «бойтесь ИИ» — он учит говорить обоснованное «да» и обоснованное «нет».

Семинар 7

Полный прогон инструмента на учебном ИИ-продукте: от гипотезы до точки эскалации к человеку.

Лекция 6

Тот же метод в системах автоматизированного проектирования (САПР): цена физической ошибки выше.

Вопросы?