Три механизма искажений человек — модель: усиление, якорение, наследование

Три механизма, проверенных в медицине, менеджменте и образовании. Все три держатся после окончания работы с моделью.

механизм	было → стало	знаменатель и разряд
Усиление предубеждений	смещённых ответов из ста: с человеком **50,6** → **51,5**, с моделью **49,9** → **56,3**	1 401 участник; с человеком роста нет
Якорение	оценки стягиваются к подсказке	775 менеджеров; величины нет
Наследование	критическое мышление ниже при частом пользовании	666 участников, тест **без** доступа к модели
Якорение у врача	верных заключений при неверной подсказке **92,8** → **23,6** из ста	220 читателей снимков
Наследование у врача	предраковых находок **без** помощника **28,4** → **22,4** из ста	226 из 795, затем 145 из 648

Рычаг назван той же работой: предупредить не помогает, а потребовать рассмотреть противоположное — помогает. Те же 775 менеджеров.

Своего смещения человек не видит: смещающую модель участники назвали менее влиятельной, чем точную. Без модели они правили себя сами — **56,7** → **51,9** из ста; с моделью доля росла до **61,4**.

Полная запись источников · *медицинские замеры*

Рамка этого кадра — не наша. Три механизма предложены работой об искажениях при взаимодействии человек — модель, и медицинские замеры всей этой лекции ложатся на два из трёх как частный случай. Произносить это надо прямо: механизмы проверены в трёх областях на двух с лишним тысячах человек совокупно, значит медицина не особая. Возражение «у врачей так, потому что медицина» на одном медицинском замере не снимается, а на трёх областях снимается.

Первая строка — единственная с контрольной ветвью, и поэтому она головная. Люди классифицировали выражение лиц в наборах по двенадцать; их ответы отдали свёрточной сети, та усилила исходное смещение, и рядом с ней работала новая группа людей. Доля смещённых ответов у этой группы выросла с сорока девяти и девяти десятых до пятидесяти шести и трёх десятых из ста. Контрольная ветвь устроена так же, только вместо модели — другие люди: там доля не изменилась, пятьдесят и шесть десятых против пятидесяти одного с половиной, различия нет. Вот это и есть содержание механизма: усиливает не согласие с чужим мнением вообще, усиливает именно модель. И усиление растёт: в первом блоке взаимодействия смещённых ответов было пятьдесят и семь десятых из ста, в последнем — шестьдесят один и четыре. Снежный ком, и он измерен, а не назван.

Вторую строку надо произнести вместе с её рычагом, иначе кадр учит бессилию. Семьсот семьдесят пять менеджеров в двух опытах оценивали работу сотрудников после подсказки, и оценки стягивались к подсказке. Величину работа в реферате не печатает, и ставить сюда похожее число из другого опыта нельзя. Зато та же работа называет своим вторым вкладом приём, который якорение снимает: потребовать от человека рассмотреть противоположное. Это

не то же, что предупредить. Предупреждение — сообщение, которое человек принимает к сведению и продолжает делать как делал; рассмотрение противоположного — действие, которое он обязан выполнить. Разница между сообщением и действием и есть практический вывод. И тонкость: источник подсказки взаимодействовал с величиной якоря — при высоком якоре человек и модель давали разные оценки, при низком разницы не было. Значит «модель влияет сильнее человека» верно не всегда, и это говорит сама работа.

Третья строка — наследование, и у неё самый аккуратный замер из трёх: шестьсот шестьдесят шесть участников проходили тест критического мышления БЕЗ доступа к модели, и связь частоты пользования с результатом оказалась отрицательной и значимой. Коэффициента не называю: полный текст закрыт по всем маршрутам, включая ссылку, которую обещает указатель открытого доступа. Рядом там же две вещи, о которых спрашивают: чем моложе участник, тем сильнее опора на модель и ниже результат; а образование связано с результатом независимо от пользования. Два других замера этого же механизма: пятьдесят четыре человека писали эссе с моделью и без под замером токов мозга, и снижение сохранялось в сессиях без модели; шестьдесят семь человек оценивали правдивость новостей, и разговор с моделью веру в дезинформацию снижал, а устойчивого навыка различения не оставлял.

Четвёртая и пятая строки — те же второй и третий механизмы, снятые в медицине. Двести двадцать читателей снимков грудной клетки: при верной подсказке доля верных заключений девяносто два и восемь десятых, при заведомо неверной — двадцать три и шесть. Это якорение в чистом виде, и падение здесь больше, чем прибавка от верной подсказки. Доля процедур с найденным предраковым образованием: в процедурах БЕЗ помощника она упала с двадцати восьми и четырёх десятых до двадцати двух и четырёх — двести двадцать шесть находок из семисот девяноста пяти процедур до внедрения, сто сорок пять из шестисот сорока восьми после. Разряд у этой строки слабее остальных: ретроспективное наблюдательное, окна по три месяца, повторения нет, и причинности авторы не утверждают. Врачей было девятнадцать — шестнадцать гастроэнтерологов и три хирурга; числа этого нет в реферате самой работы, оно из разбора рецензируемого журнального клуба, то есть источник второго разряда. Оттуда же возражение, которое надо произнести вместе с падением: среднее число находок на процедуру изменилось незначимо — ноль пятьдесят четыре против ноль сорока трёх, — и по продвинутым находкам разницы нет вовсе. То есть упала доля процедур с находкой, а не количество найденного.

Последняя подпись отвечает на вопрос, который зал задаёт сам: почему этого не видно изнутри. В той же первой работе участников спросили, насколько на них повлиял каждый алгоритм, и они назвали смещающий менее влиятельным, чем точный, — то есть ровно наоборот. А без всякой модели человек своё смещение правит сам: доля падала с пятидесяти шести и семи десятых до пятидесяти одного и девяти по ходу опыта. Способность к самокоррекции у него есть; рядом с моделью она не работает. И честная половина того же замера: точный алгоритм

точность участников поднимал. Кадр не говорит, что модель вредна — он говорит, куда смотреть.

Источники. Полная запись — разбор работы владельца об искажениях (рамка трёх механизмов и все 18 источников) и свод медицинских замеров. Числа первой строки и последней подписи сняты из полного текста Glickman и Sharot, Nature Human Behaviour 2025, PMID 39695250; четвёртой — Prinster и соавт., Radiology 2024;313(2), опыт с имитированной подсказкой; пятой — Budzyń и соавт., PMID 40816301.

Влияние ИИ на пациента: доверие, раскрытие, перепроверка

Каждая строка — пара внутри одной выборки. Между собой строки в пару не складываются.

что измерено в пациенте	было → стало	знаменатель и разряд
Раскрытие роняет доверие	**0,63** → **0,50** → **0,34** → **0,30** из единицы	1 762 взрослых, четыре группы
Одним читателем не берут	единственным **23 из 518**, вторым **368**	скрининг молочной железы
Перепроверку просят вверх	после тревоги модели к врачу — **319 из 359**; обратно — **184**	оба вопроса каждой
Доплата двигает выбор	выбор модели **43** → **81** из ста	248 взрослых, 50 долларов снято
Без подписи выбирают машину	сочувствие: врач **2,01**, машина **4,11** из пяти	45 человек, текст ответа

Четыре группы первой строки: врач прямо отказался от ИИ · об ИИ не сказано · пользуется умеренно · пользуется широко.

Возраст и образование отказа не объясняют: падение одинаково по возрасту, полу и образованию у тех же 1 762 человек.

Затухания доверия к медицинской модели во времени не измерено нигде. Новизна измерена на чат-боте отказа от курения: удовлетворённость **3,69** → **2,97** из пяти за пять недель, 102 участника.

Полная запись источников

У врача мерили поведение на задаче. У пациента мерят согласие — чем он отвечает на сам факт, что в его случае участвовала модель. И первое для зала: согласие это не одно число. Пациент принимает модель помощником и отвергает исполнителем, причём обе величины сняты на одних и тех же людях.

Замер, который прямее остальных. Тысяча семьсот шестьдесят два взрослых, представительных для населения Соединённых Штатов, случайно разделены на четыре группы по признаку пользования ИИ. Профиль врача у всех один. Шкала пятиступенчатая, приведённая к отрезку от нуля до единицы; лестница вышла ровная: шестьдесят три сотых, пятьдесят, тридцать четыре, тридцать. Раскрытие стоит пациенту двадцати пунктов доверия от середины шкалы. И менее ожидаемое: прямой отказ от ИИ приносит врачу тринадцать пунктов сверх того, что он имеет, когда об ИИ не сказано вовсе. Молчание — не нейтральная позиция, а уже проигрышная относительно заявленного отказа.

Вторая и третья строки сняты на одной выборке и читаются вместе. Пятьсот восемнадцать женщин, пришедших на снимок молочной железы. Модель единственным читателем согласились принять двадцать три человека; вторым читателем — триста шестьдесят восемь из тех же пятисот восемнадцати. Разница в шестнадцать раз: пациент против не модели, а её одиночества. Третья строка показывает, что согласие несимметрично. Трёмстам пятидесяти девяти участницам задали оба вопроса: тревогу подняла модель — пусть посмотрит врач? триста девятнадцать да. Вызвал врач — пусть посмотрит модель? сто восемьдесят четыре. Перепроверка просится вверх и почти не просится вниз.

Четвёртая строка про то, чем согласие двигается на самом деле. Двести сорок восемь взрослых с диабетом первого типа: пора на ежегодный осмотр глаз,

доступна самостоятельная модель вместо направления к специалисту. Снятие доплаты в пятьдесят долларов подняло выбор модели с сорока трёх до восьмидесяти одного из ста, почти вдвое, а кто за неё платит — страховщик или разработчик, — на выбор не повлияло. Рядом то, что деньгами не сдвинулось: выбравшие модель хотели перепроверки у специалиста заметно сильнее обратного, и хотели её даже при нормальном результате. Произносить это надо парой: цена согласие покупает, доверия не покупает.

Пятая строка — противоположный знак, и его надо назвать честно. Сорок пять человек с онкологическим диагнозом оценивали ответы на вопросы о болезни: четыре ответа на вопрос, три машинных и один врачебный, перемешанные и без подписи. Сочувствие в машинном ответе они оценили в четыре целых одиннадцать сотых из пяти, во врачебном — в две целых одну сотую. Строка говорит не то, что машина сочувствует: человек, не знающий авторства, выбирает машинный текст, а знающий — снижает доверие к врачу за один факт пользования. В одну фразу эти две строки не складываются: выборки и вопросы разные, и у пятой сорок пять участников, почти все старше шестидесяти пяти.

Про новизну. Сто два взрослых курильщика пять недель разговаривали с чат-ботом поддержки отказа от курения, удовлетворённость замерялась каждую неделю. Кривая ровно та, которую новизна и даёт: три целых четыре десятых на входе, три целых семь на первой неделе — вершина, — и три целых ноль к пятой. Причину авторы называют предположительно, и на исход вмешательства падение не повлияло. И прямо скажу, чего нет: замера затухания доверия пациента к медицинской модели во времени не нашлось ни одного. Всё, что есть рядом, — срез по частоте собственного пользования ИИ в работе о раскрытии: у тех, кто пользуется часто, разрыв доверия меньше. Это срез, а не наблюдение во времени.

Про возраст и образование, потому что спрашивают именно об этом. В работе о раскрытии падение доверия оказалось одинаковым по возрасту, полу, образованию и политическим взглядам: отказ широкий, а не свойство группы, — и это снимает удобное «не привыкли старшие». Одобрение модели в принципе у образованных выше, отношение шансов около двух, но это другой вопрос и другие люди.

И последнее, прикладное. Три тысячи взрослых выбирали между описаниями приёма; цена двух признаков названа числом: присутствие врача поднимает вероятность выбора на восемнадцать пунктов, уровень модели выше специалиста — на тридцать два. Вот и ответ, чем лечить недоверие: качеством модели и человеком, оставленным в контуре. Объяснения и кампании в этом замере не участвовали.

Источники. Полная запись всех шести замеров с выборками, интервалами и разрядом — свод доверия пациента к модели. Там же §8 — две пары, которые намеренно не собраны, и §9 — чего не нашлось.