2. Анализ данных — и группа, на которой он посчитан

Здесь заключение по измеренному выносит сама система — без человека.

У каждой доли есть группа, на которой она посчитана: на других людях та же доля означает другое.

3 разбора · 1 классический режим отдельным кадром · 2 упоминания с числом

Разборы по порядку: **Пример 1: Таиланд — точность приехала, а снимки не прошли · Пример 2: кожа и состав набора · Пример 3: расходы вместо болезни**



Рабочее место, где снимают данные

Что делают участники на стадии анализа данных — до всякой обученной модели

ДОЛИ СЧИТАЛИ

все 62 отобранные работы

из 2 212 просмотренных публикаций

ГРУППУ, НА КОТОРОЙ ОНИ ПОСЧИТАНЫ

ПОЧТИ НИКТО

ни одна не пригодна для клинического применения

У прибора стоит человек — лаборант, техник, медсестра.

Порог, за которым говорят «болен», записан в протоколе кабинета до прибора.

Шесть действий стадии

- назначить рабочую точку
- снять измерение
- решить, годно ли оно
- прочесть и назвать две доли
- пересчитать их под свою распространённость
- сообщить результат тому, кто решает

Без обученной модели каждое из шести делает человек по записанному правилу.

С обученной моделью — два шага из шести: прочесть измерение, где вместо величины выдаётся один балл, и сообщить результат.

Рабочая точка, съёмка, годность и пересчёт остались людям. Новый шаг — повторный визит тем, чьё измерение не прошло.

Чувствительность и **специфичность** — полнота по больным и по здоровым; всегда парой и всегда для одной рабочей точки.

Доля верных тревог — третья, и считает её тот, кто применяет. Врач на приёме видит на столе именно её.

Вам называют «точность 94 процента». На какой группе она посчитана — и кто у вас задаёт этот вопрос вслух?

Систематический обзор работ машинного обучения на снимках при ковидной пневмонии: Roberts и соавторы, Nature Machine Intelligence, 2021;3:199–217

Одна система, две группы: 8 верных тревог из ста против 79

ЛОВИТ БОЛЬНЫХ

94 из ста больных

опубликованная рабочая точка, взятая иллюстрацией методики

НАПРАСНО ПУГАЕТ ЗДОРОВЫХ

11 из ста здоровых

та же точка; обе доли меняются только вместе

ВЕРНАЯ ТРЕВОГА — ПОГОЛОВНЫЙ ПОТОК

8 из ста тревог

на 10 000 подряд больных 100: 94 верные тревоги и 1 089 ложных — 1 183 поднятые

ВЕРНАЯ ТРЕВОГА — ПРОФИЛЬНОЕ ОТДЕЛЕНИЕ

79 из ста тревог

на тех же 10 000 больных 3 000: 2 820 верных и 770 ложных — 3 590 поднятых

Внутри системы не изменилась ни одна строка. Долю больных назначил тот, кто решил, кого звать.

Это счёт методики на опубликованной рабочей точке — не разбор изделия.

Три способа поднять долю верных тревог, и ни один не состоит в улучшении модели

• сдвинуть порог: ложных тревог меньше, пропущенных больных больше

• сменить группу: обследовать тех, у кого болезнь встречается чаще

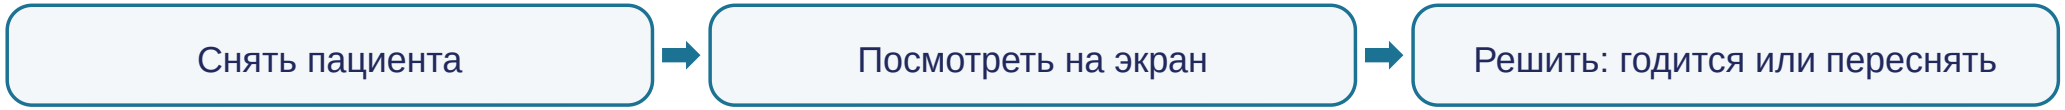
• поставить вторым подтверждающий тест и объявлять «болен» по двум

Заявленная точность без названной группы и распространённости болезни на слайд не идёт.

Рабочая точка 94 и 11 — опубликованный замер модели чтения снимков грудной клетки: Rajpurkar и соавторы, CheXNet, 2017, взята иллюстрацией методики; доля верных тревог посчитана при распространённости один из ста и тридцать из ста

Классический режим: годность снимка решает человек

Без модели



Решение техника о годности снимка

Из трёх классических режимов чтения раздел берёт один — **контроль годности измерения**.

Двойное чтение и арбитраж придут позже, вместе с человеком, который читает рядом с моделью.

Техник флюорографии районной поликлиники ставит пациента, снимает, смотрит на экран и решает — годится снимок или нужно переснять.

По какому правилу он решает. Инструкция кабинета и видимое качество кадра. В приборе этого правила нет.

Что бывает, если негодный снимок уйдёт на чтение. Диагноз ставят по тому, что видно, не по тому, что было на самом деле.

Кто это заметит, если не он. Чаще всего — никто, пока не понадобится пересмотр.

Пригодность измерения решает не прибор.

Пример 1: Таиланд — точность приехала, а снимки не прошли

СНИМОК ОТКЛОНЁН ПО КАЧЕСТВУ

21 из ста снимков

393 снимка из 1 838 в одиннадцати клиниках за первые полгода развёртывания; причины — освещение в кабинете и медленная связь

Цена обеих ошибок — в исходах и в визитах, не в деньгах

• пропуск: поражение глазного дна бессимптомно до поздних стадий, потеря зрения необратима

• ложная тревога: направление к офтальмологу, которого в районе может не быть вовсе

Классический режим — словами, без числа: раз в год человек с диабетом идёт к офтальмологу, тот сам снимает и сам читает.

Модель против него — автономное чтение двух снимков глазного дна на месте, без офтальмолога, результат меньше чем за минуту.

В поле по качеству отклонён **21 снимок из ста**: 393 из 1 838 за первые полгода в одиннадцати клиниках.

Причины названы, и обе они про место съёмки: освещение в кабинете и медленная связь.

Это доля негодных снимков. Явку мерил другой разбор и на другой выборке.

Полевая оценка развёртывания автономного чтения глазного дна в одиннадцати клиниках Таиланда: Beede и соавторы, CHI 2020

Пример 1, цена: тот же техник и новая работа — добиться годного снимка

ДАЛО

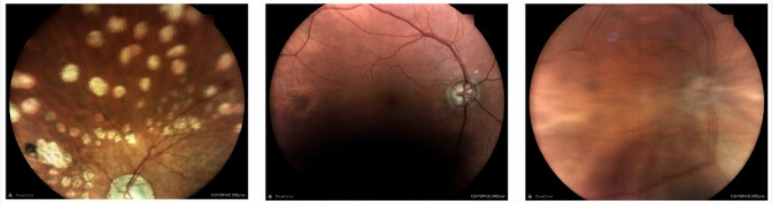
Результат в кабинете первичного звена

ПОТРЕБОВАЛО

Годный снимок в непроверенных условиях

В СУММЕ

На старте хуже лабораторного замера



Нагрузка выросла на том же месте: у техника появилась работа добиться годного снимка.

Появился шаг — повторный визит тем, чей снимок не прошёл: это 21 человек из каждых ста обследованных.

Причины отклонения обе про место съёмки: освещение в кабинете и медленная связь. Ни одна на лабораторном наборе не видна.

То же полевое наблюдение развёртывания, одиннадцать клиник, первые полгода: Beede и соавторы, CHI 2020 · *Иллюстрация: Skevas и соавт., BMC Ophthalmology 2024, рис. 3*

Пример 2: кожа и состав набора

ОСМОТР НЕВООРУЖЁННЫМ ГЛАЗОМ

86 из ста больных

специфичность 77; оба режима из одного метаанализа

ДЕРМОСКОПИЯ У СПЕЦИАЛИСТА

91 из ста больных

специфичность 74

РАЗРЫВ ПО ТОНУ КОЖИ У МОДЕЛИ

9–15 пунктов площади под кривой

тёмные тона против светлых, у трёх моделей

БАЗА ЗАМЕРА

656 изображений

207 самых тёмных тонов · 241 средних · 208 светлых; все с биопсией

Цена обеих ошибок. Пропуск — лечение на поздней стадии вместо ранней. Лишняя тревога — биопсия, рубец, месяцы ожидания.

Оба классических режима посчитаны одной методологией — одним метаанализом прямого сравнения.

Модель против них. На биопсийно подтверждённых изображениях три модели дают площадь под кривой на тёмных тонах ниже, чем на светлых.

Знаменатель назван: это не «несколько примеров».

Одну ходовую цифру разбор произносить отказывается: «на тёмной коже чувствительность падает на 20–30 процентов» в публикации не найдена.

Ближайшее измеренное, у одной из трёх моделей: 69 больных из ста на светлых тонах против 23 на тёмных.

Набор DDI, 656 биопсийно подтверждённых изображений — Daneshjou и соавторы, Science Advances, 2022;8(31):eabq6147 · осмотр и дермоскопия — Vestergaard и соавторы, British Journal of Dermatology, 2008;159(3):669–676

Пример 2, цена: разрыв лечит состав данных

ДООБУЧЕНИЕ НА ПРЕДСТАВИТЕЛЬНОМ НАБОРЕ

разрыв снимает и переворачивает

измеренное исправление; лечит его сбор и разметка — та работа, которая в руках инженера

ТРИ АЛГОРИТМИЧЕСКИХ МЕТОДА ПРОТИВ СМЕЩЕНИЯ

значимо не уменьшили разрыв

РАЗРЫВ ПО ТОНУ КОЖИ У КЛАССИЧЕСКИХ МЕТОДОВ

не измерен вовсе

по тону кожи точность не разбивает ни метаанализ, ни обзоры — сказать «модель хуже человека на этой подгруппе» не с чем

Что переехало. Сместилась цена ошибки: средняя точность по набору осталась приличной, а платит за разрыв подгруппа, которой в обучающем наборе было мало.

Исправление измерено, и лечит его не алгоритм.

дало постоянную оценку образования там, где дерматолога нет · **потребовало** набора, повторяющего состав тех, на ком система будет работать · **в сумме** средняя держится, а цена ошибки переехала на подгруппу

Строка, которая несёт разбор: разрыв **измерен у модели** и у классических методов **не измерен вовсе**. Отсутствие замера равенства не доказывает.

Та же работа — Daneshjou и соавторы, Science Advances, 2022;8(31):eabq6147

Пример 3: расходы вместо болезни

ОТБОР РЕШЕНИЕМ ВРАЧА

19,2 из ста отобранных

доля рассматриваемой группы среди отобранных

ОТБОР БАЛЛОМ ПО ПРОГНОЗУ РАСХОДОВ

17,2 из ста отобранных

числа различает только ярлык режима

ПРИ РАВНОМ БАЛЛЕ БОЛЕЗНЕЙ БОЛЬШЕ НА

26 процентов

целевой переменной взяты будущие расходы

БАЗА ЗАМЕРА

49 618 пациентов

одна академическая больница, 100 009 пациенто-лет, 2013–2015 годы

Цена обеих ошибок. Не попал тот, кому программа нужна: болезнь развивается без присмотра.

Попал тот, кому она не нужна: занято место и время координатора.

Оба классических режима посчитаны на одной выборке.

Модель против них. Один балл на каждого, отбор по порогу; целью взяты будущие расходы на лечение.

Ограничение второго режима: врач, отбиравший пациентов, уже видел балл. Отбора до модели в публикации нет.

Чем это делают сегодня — счёт риска на данных плательщика и на медицинской карте, *прогноз на структурированных данных*:

- покупает это администрация или плательщик, не врач
- «дорого лечится» от «болен» такой счёт не отличает

Разбор промышленного алгоритма отбора в программу повышенного внимания: Obermeyer и соавторы, Science, 2019;366(6464):447–453

Пример 3, цена: исправление посчитали и не применили

ДОЛЯ ГРУППЫ СРЕДИ ОТОБРАННЫХ: НАБЛЮДАЕМАЯ → ПРИ УБРАННОМ РАЗРЫВЕ

17,7 → 46,5 из ста

вторая половина — расчёт авторов на тех же данных, внедрения не было

ДАЛО

последовательный отбор там, где ручной непоследователен

ПОТРЕБОВАЛО

совпадения расходов с болезнью, которого нет

В СУММЕ

для одной группы хуже прежнего отбора, и исправление только посчитано

Исправление посчитано и не применено. Разрыв убран расчётом, не внедрением.

Что переехало. Сменился исполнитель — отбор делал врач, стал делать балл. Цена ошибки переехала на группу, где при равном балле болезней больше.

Масштаб и знаменатель — порознь. К моделям этого класса отнесены около **200 миллионов** человек в год.

Это оценка охвата; перекос измерен на 49 618 пациентах.

Внутренняя проверка этого не видит: провал лежит там, где его не проверяют.

Та же публикация: Obermeyer и соавторы, Science, 2019;366(6464):447–453

Анализ данных: ни в одном разборе не провалилось само чтение

Что получается

• Постоянство: десятитысячный снимок читается так же, как первый

• Поток: чтение нормы перестаёт занимать специалиста

• Воспроизводимость: один вход даёт один выход, и расхождение можно разобрать

Что не получается

• Назначить рабочую точку: за порогом стоит цена обеих ошибок

• Переснять: качество входа остаётся человеку без профильной подготовки

• Увидеть, чем измерен вход: смещение прибора модель наследует молча — **11,7 против 3,6 процента измерений** у пациентов с тёмной и светлой кожей

Что стало с работой

• Нагрузка выросла на том же месте: у техника появилась работа добиться годного снимка

• Появился шаг: повторный визит тем, чьё измерение не прошло

• Сменился исполнитель: отбор делал врач, стал делать один балл

• Сместилась цена ошибки на подгруппу, которой в обучающем наборе было мало

Что это держит

• Рабочая точка под цену обеих ошибок и пересчёт доли верных тревог под свою группу

• Контроль годности измерения: правило кабинета, и прибор его не заменяет

• Прочерк: процедуры, которая проверяла бы, что система считает своей целью, нет

Ни в одном из трёх разборов не провалилось само чтение: провалились развёртывание, состав набора и определение цели.

Карта стадии: какая задача и какие данные

	текст	изображение	структурированные данные
классификация	—	**Таиланд · кожа и состав набора · (отбор)**	—
распознавание	—	(отбор)	—
поиск с генерацией	(отбор)	—	—
прогноз	—	—	**расходы вместо болезни**

Полужирное — этот раздел, в скобках — кто занял клетку раньше, прочерк — пусто. Занято 4 клетки из 12, новая одна: прогноз.

Восемь прочерков за два раздела не двинулись, и читать надо их: инструмент такого класса здесь искать незачем.

Одна клетка занята дважды, и провалилось разное: в Таиланде — место развёртывания, в дерматологии — состав набора. Отчёт под именем клетки не сказал бы ни о том, ни о другом.

Вне окна — одно занятое место: *измерение · сигнал прибора*, где обученной модели нет вовсе.

- **автономное чтение без врача** — LumineticsCore · EyeArt · AEYE-DS
- **оценка кожного образования** — SkinVision · DermaSensor
- **счёт риска внутри карты** — покупает плательщик или администрация, не врач

Сетка «тип задачи × данные» — Лекция 1. Полужирным — разборы этого раздела со сверенными числами; в скобках — раздел, занявший клетку раньше