2. Инструментальная и лабораторная диагностика

В скрининге решали, кого посмотреть. Здесь человека измеряют прибором — снимком, анализом, пробой под нагрузкой — и превращают его состояние в величину, которую прочтут в другом месте и в другое время.

Диагноза эта стадия не ставит: она производит величины. И у каждой величины есть группа, на которой посчитаны её свойства, — **одна и та же система даёт 8 верных тревог из ста в поголовном потоке и 79 из ста в профильном отделении.**

Три разбора по порядку: Таиланд — чтение глазного дна в кабинете первичного звена · **кожа и состав набора** · **отбор в программу повышенного внимания**.



Исследование: шесть действий стадии и два, которые заняла модель

Человек — четыре

назначить порог → снять измерение → решить, годно ли → пересчитать под свою группу

Модель — два

прочесть измерение

сообщить результат

Шесть действий стадии; модель заняла два



Четыре способа снять величину, и заменять один другим нельзя:

- **Инструментальное исследование** — прибор работает по самому человеку
- **Лабораторный анализ** — человека рядом уже нет, переснять по месту невозможно
- **Функциональная проба** — протокол нагрузки входит в условия измерения
- **Удалённое исследование** — читающий пациента не видел

Модель заняла два действия из шести, и не самые трудные. Порог под цену ошибки не назначает, переснять не умеет, годность входа оставляет человеку.

Вам называют «точность 94 процента». На какой группе она посчитана?

Roberts и соавт., Nature Machine Intelligence 2021

Как считают точность: одну рабочую точку применили к двум группам по десять тысяч человек

РАБОЧАЯ ТОЧКА СИСТЕМЫ

94 из ста больных · 11 из ста здоровых напрасно

опубликованная точка чтения снимков грудной клетки

ВЕРНЫХ ТРЕВОГ: ПОТОК → ОТДЕЛЕНИЕ

8 → 79 из ста

94 на 1 183 поднятые против 2 820 на 3 590

Поголовный поток	больных 1 из ста	тревог 1 183	верных 8 из ста
Профильное отделение	больных 30 из ста	тревог 3 590	верных 79 из ста

Система одна, рабочая точка одна; различается доля больных в группе

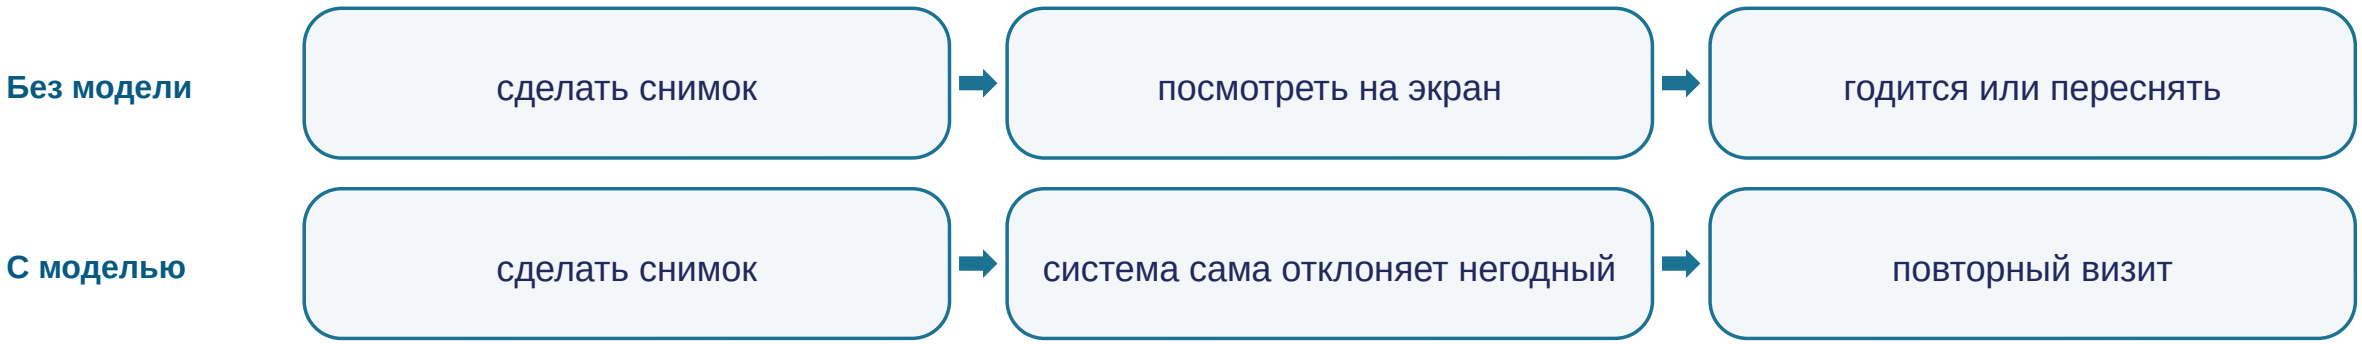
Стадия производит величины — а свойства величины считают на группе. Одну опубликованную рабочую точку применили к двум группам по десять тысяч человек, отличающимся только долей больных.

Разница почти десятикратная, и внутри системы не изменилась ни одна строка. У этой доли есть имя — **прогностическая ценность положительного результата**: какая часть поднятых тревог оказалась болезнью. Чувствительности врач на приёме не видит, он видит именно её.

Женщина с письмом стоит в поголовном потоке: у неё 8 из ста.

Rajpurkar и соавт., CheXNet 2017

Классический режим: годность снимка решает техник у аппарата



Решение о годности снимка: без модели и с моделью

Классический режим стадии — **контроль годности измерения.**

По какому правилу решает техник: инструкция кабинета и видимое качество кадра. В приборе этого правила нет.

Чем это кончается, если негодный снимок уйдёт на чтение: заключение поставят по тому, что видно, — и дальше по цепочке идут неверный диагноз, повторное исследование, потерянные недели и лечение, начатое не вовремя. **Заметит это никто,** пока не понадобится пересмотр.

С моделью развилка не исчезает, а раздваивается: негодный снимок она отклоняет сама — и тогда человеку достаётся повторный визит; не отклонит — читает то, что ей дали.

Что работает и что не работает, когда измерение читает модель

ПРИБОР НАСЫЩЕНИЯ КРОВИ ПРОТИВ АНАЛИЗА: РАСХОЖДЕНИЕ У ПАЦИЕНТОВ С ТЁМНОЙ КОЖЕЙ

11,7 против 3,6 из ста измерений

88 из 749 против 99 из 2 778, одна названная когорта

Работает

• постоянство: десятитысячный снимок читается как первый, усталости нет
• поток: чтение «нормы» перестаёт занимать специалиста
• воспроизводимость: один вход — один выход, и расхождение можно разобрать

Не работает

• качество входа: переснять система не умеет
• перенос: доли, посчитанные в одной больнице, не переезжают вместе с прибором
• чем измерен вход: смещение прибора модель наследует, не создавая его

Обученной модели в этом приборе нет вовсе — это оптическое измерение, смещённое до всякого обучения, и смещение одностороннее: показание выше, чем даёт анализ крови, то есть опасное снижение насыщения пропускается чаще. Регулятор выпустил предупреждение, затем проект требования испытывать приборы на разных тонах кожи.

Проверять надо не только модель, но и то, чем измерен её вход.

Sjoding и соавт., New England Journal of Medicine 2020 · предупреждение регулятора США 19.02.2021, проект руководства 06.01.2025

Инструментальная диагностика по странам: охват и участие ИИ



Масштаб потока похож, порядок внедрения разный. Россия строит городскую и федеральную платформу параллельно; Британия финансирует вендорский инструмент поверх уже существующей сети больниц; в США регулятор допускает изделия поштучно.

Доли охвата нет ни у одной страны: знаменателя «всего исследований в год» не публикует никто.

Botkin.AI, ноябрь 2023: надзор впервые в стране приостановил применение медизделия с обученной моделью — отчётов мониторинга не представили, результаты отклонились от заявленных при регистрации. Возобновили в мае 2024 с повышением класса риска.

Golshani и Joseph, Cureus 2026 · государственное сообщение gov.uk о развёртывании чтения рентгена грудной клетки в Национальной службе здравоохранения · «Независимая газета», 21.05.2026, по первичным данным Департамента здравоохранения Москвы

Пример 1: Таиланд — чтение глазного дна в кабинете первичного звена

ЦЕНА ОБЕИХ ОШИБОК

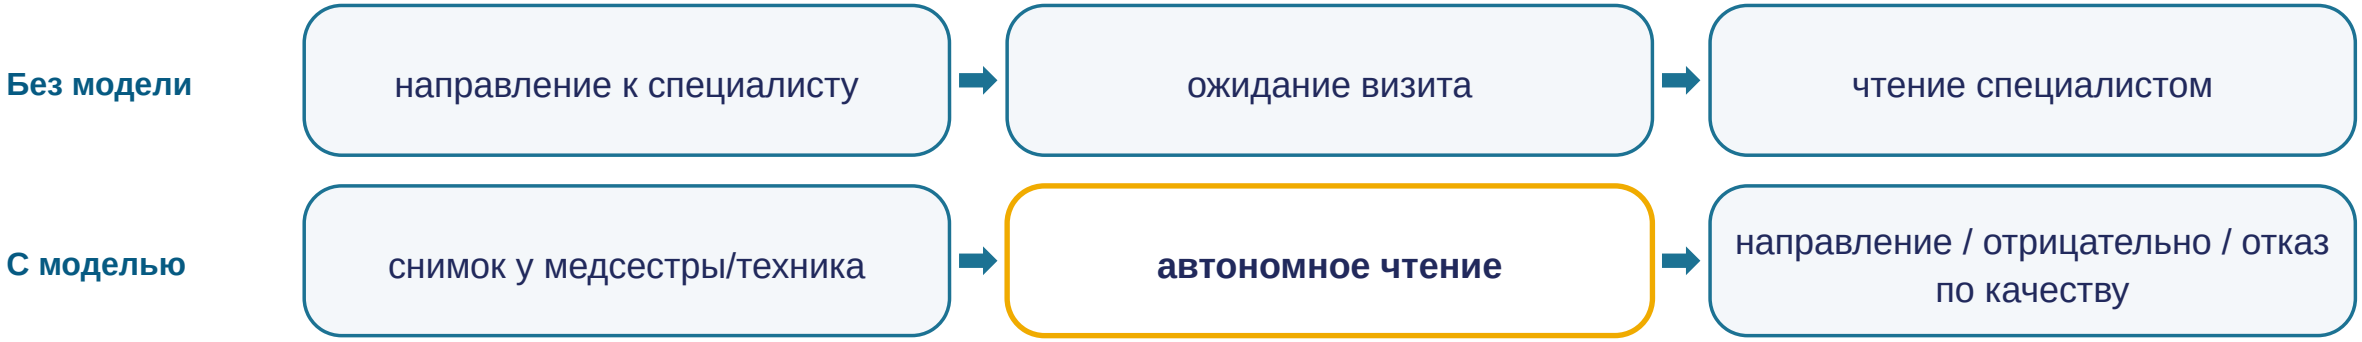
потеря зрения · визит к офтальмологу, которого нет

денежных оценок для этой страны нет

СНИМОК ОТКЛОНЁН ПО КАЧЕСТВУ → ПОВТОРНЫЙ ВИЗИТ

21 из ста

393 из 1 838 за первые полгода



Чтение глазного дна в кабинете первичного звена. Полгода, одиннадцать клиник Таиланда: медсёстры и техники снимали, система читала на месте меньше минуты и сама отклоняла негодное.

Устроено. Обучено на отобранных по качеству снимках; в поле отбор делает человек без правила. Имени системы не называют. **Причины отказов:** освещение, медленная связь.

Провалилось развёртывание, чтение сработало. *Полевое наблюдение, измерено однажды; сопоставляются порядки, не выборки.*

Beede и соавт., CHI 2020

Пример 2: кожа и состав набора

ЦЕНА ОБЕИХ ОШИБОК

лечение на поздней стадии · биопсия и рубец

ОСМОТР ГЛАЗОМ → ДЕРМОСКОПИЯ

86 → 91 из ста больных

специфичность 77 → 74, один метаанализ

РАЗРЫВ ПО ТОНУ КОЖИ

9–15 пунктов площади под кривой

площадь под кривой — различение больного и здорового: 0,5 монетка, 1,0 без промаха. 656 изображений с биопсией: 208 светлых · 241 средних · 207 тёмных

Без модели

осмотр глазом / дермоскопия → решение: к врачу или нет

С моделью

снимок телефоном/камерой → **модель** → показать врачу или нет

Что делали до модели. Человек находит на коже образование и хочет знать, идти ли к врачу. Смотрел врач глазом, обученный специалист — через дермоскоп.

Устроено. Три модели на одном проверочном наборе, светлые тона против тёмных. Наборы у трёх свои, тёмных тонов в них мало — в этом дело. *Классификация на изображении.*

Классические режимы — из одного метаанализа прямого сравнения.

Daneshjou и соавт., Science Advances 2022 · *Vestergaard и соавт., British Journal of Dermatology 2008*

Пример 2, цена: разрыв лечит состав данных

ДООБУЧЕНИЕ НА ПРЕДСТАВИТЕЛЬНОМ НАБОРЕ

разрыв снимает

лечит сбор и разметка, не алгоритм

ТРИ МЕТОДА ПРОТИВ СМЕЩЕНИЯ

разрыв не уменьшили

У КЛАССИЧЕСКИХ МЕТОДОВ РАЗРЫВ

не измерен вовсе

по тону кожи точность не разбивает ни метаанализ, ни обзоры

ДАЛО → ПОТРЕБОВАЛО

оценку там, где дерматолога нет → набор под состав тех, на ком работает

в сумме: средняя держится, цена — на подгруппе

Поправка метода	алгоритмическая поправка	➡ разрыв не уменьшился
Состав данных	дообучение на представительном наборе	➡ разрыв снят

Из двух путей против смещения сработал один, и это не выбор метода

Что переехало. Сместилась цена ошибки: средняя по набору осталась приличной, а платит подгруппа, которой в обучающем наборе было мало.

Отсутствие замера равенства не доказывает.

Исправление измерено в той же работе; в настоящем кабинете — ни одну из трёх.

Daneshjou и соавт., Science Advances 2022

Пример 3: отбор в программу повышенного внимания — балл вместо решения врача

ЦЕНА ОБЕИХ ОШИБОК

болезнь без присмотра · занятое место

время координатора — кто-то третий не попал

ОТБОР: ВРАЧ → БАЛЛ

19,2 → 17,2 из ста отобранных

одна выборка

ПРИ РАВНОМ БАЛЛЕ БОЛЕЗНЕЙ БОЛЬШЕ НА

26 процентов

49 618 пациентов, 100 009 пациенто-лет, 2013–2015

ДОЛЯ ЭТОЙ ГРУППЫ СРЕДИ ОТОБРАННЫХ

17,7 из ста

при полностью убранном разрыве в здоровье поднялась бы до 46,5 — расчёт авторов на тех же данных; внедрения за ним нет

Врач (видел балл)	карта пациента	подсказка: балл	решение врача
Один балл	карта + расходы	**прогноз расходов**	отбор по порогу

Отбор в программу повышенного внимания. Кого позвать на усиленное наблюдение, решал врач — стало решать одно число. **Обучено оно предсказывать будущие расходы на лечение** — а решение принималось о болезни; расходы отражают обращаемость, а она при одинаковом здоровье у групп разная.

Устроено. Имени промышленному алгоритму публикация не даёт. *Прогноз на структурированных данных.*

Переехала цена ошибки — на группу, где при равном балле болезней больше. **Эффекта на деньги и здоровье работа не измеряла:** посчитан состав отобранных, а не исходы людей.

Obermeyer и соавт., Science 2019

Вывод раздела: ни в одном из трёх разборов не провалилось само чтение

ПРОВАЛИЛИСЬ

развёртывание · состав набора · определение цели

Таиланд · кожа · отбор в программу — чтение не провалилось ни в одном

ИСПРАВЛЕНИЕ ИЗМЕРЕНО ОДИН РАЗ

дообучением на наборе

три алгоритмических метода разрыв не сняли

Что получается

- постоянство: десятитысячный снимок как первый
- поток: «норма» не занимает специалиста
- воспроизводимость: расхождение можно разобрать

Что не получается

- назначить рабочую точку: за порогом цена обеих ошибок
- переснять: годность измерения осталась человеку
- увидеть, что смещён сам вход — этого не умеет ни одна из процедур

Ошибиться можно в трёх местах, не ошибившись в модели — вход измеряет прибор, набор собирает человек, цель задаёт переменная.

Где модель на этой стадии стоит. *Классификация на изображении* — чтение глазного дна, оценка кожного образования. *Распознавание на изображении* — сортировка потока на рентгене и томографии. *Прогноз на структурированных данных* — счёт риска в карте. *Измерение · сигнал прибора* — **модели нет, а смещение есть.**

Четыре вопроса, которые задают до вопроса о точности

ВОПРОСОВ

четыре

задаются до вопроса о точности, а не после

СОРВАЛИ ВНЕДРЕНИЕ

три из четырёх

Таиланд · кожа · отбор в программу

ЧЕТВЁРТЫЙ СОРВАЛ ИЗМЕРЕНИЕ

до всякой модели

прибор насыщения крови: обученной модели в нём нет

«Какая у неё точность» — вопрос пятый. Четыре идут раньше.

• **На какой группе посчитаны доли?** Лабораторный набор собрали из снимков, прошедших отбор по качеству. В поле отбор делает человек без правила — *Таиланд*.

• **Чем измерен вход?** Прибор насыщения крови расходится с анализом **11,7 против 3,6 из ста измерений** — и обученной модели в нём нет вовсе.

• **Из чего собран обучающий набор?** Тёмных тонов кожи в наборах было мало: **разрыв 9–15 пунктов** площади под кривой между светлыми и тёмными тонами, 656 изображений с биопсией — *кожа*.

• **Что система считает своей целью?** Обучена на будущих расходах, решение принималось о болезни — *отбор в программу*.

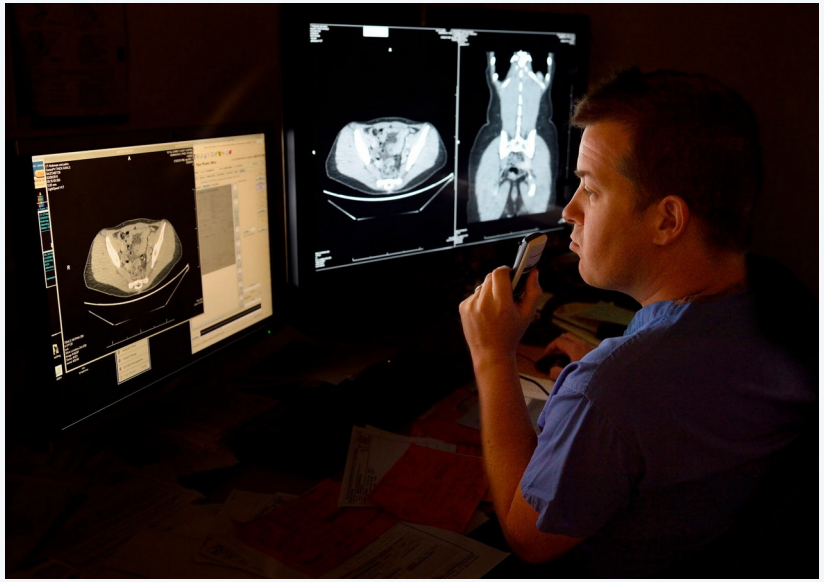
Три вопроса сорвали по внедрению. Четвёртый сорвал измерение, в котором модели нет.

3. Постановка диагноза

Там стадия производила величины — здесь по величинам выносят заключение, и подпись под ним ставит человек. Читает он теперь не только снимок, но и подсказку модели рядом; от того, в каком порядке они предъявлены, зависит результат.

Пять разборов по порядку. Замер взгляда · **патологи читают срезы** · **шведское испытание** · **хирурги оценивают риск** · и, уже из непрерывного наблюдения, **модель раннего предупреждения о сепсисе**.

Инструмент в двух из них один, а исходы противоположны — расходится не модель, а устройство процедуры.



Постановка диагноза: семь действий стадии и три, на которых стоит модель

ЧАСТОТА ДИАГНОСТИЧЕСКОЙ ОШИБКИ: АМБУЛАТОРНЫЙ ПРИЁМ ВЗРОСЛОГО

5,08 приёма из ста

выявляли триггером — необычный возврат пациента, ненормальный результат без дообследования; поэтому сосчитана часть ошибок; саму долю перенесли на взрослое население США; авторы называют это занижением: частота может быть заметно выше пяти процентов



Ход работы

собрать данные → выписать болезни → назначить проверку → вычеркнуть лишнее

Заняла модель

состав списка | второе чтение | подпись

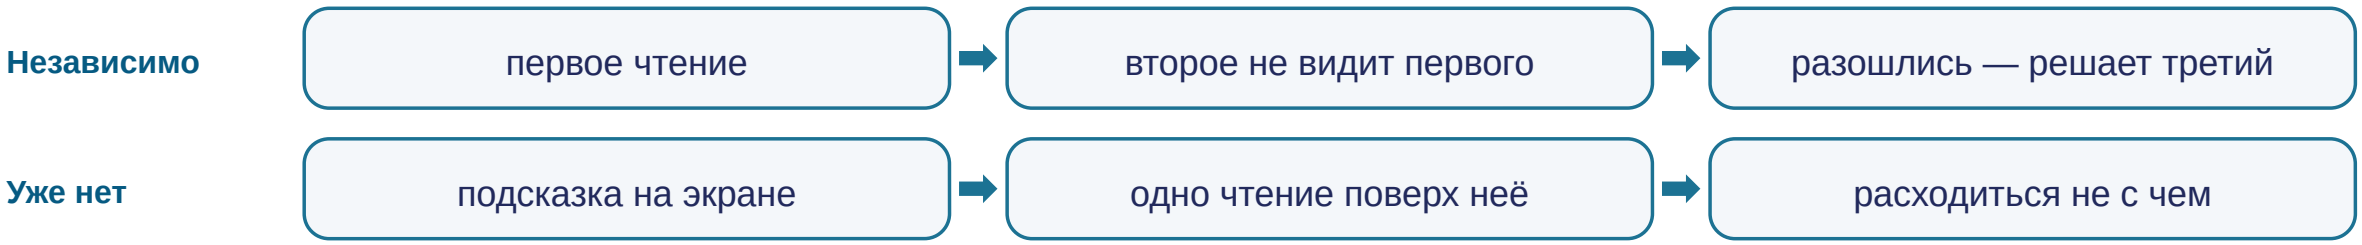
Как сужается список: стадия сразу за исследованием

Один приём: кашель три недели, вечерняя температура, минус четыре килограмма. Из четырёх болезней снимок и анализ крови вычеркнули две — остались две, неразличимые по снимку.

Модель стоит на трёх из семи действий: состав списка, второе чтение, подпись. **И добавила одно — решить, верить ли подсказке.**

Singh и соавт., BMJ Quality & Safety 2014

Второе мнение: чем оно держится и когда перестаёт быть вторым



Два мнения: когда они независимы и когда уже нет

Держится независимостью: второму читателю закрывают доступ к первому заключению, а расхождение разбирает третий.

Второе мнение от модели, подсказавшей первое, — уже не второе: ошибка общая и удваивается вместо усреднения.

Порядок предъявления измерен. Подсказка до того, как человек составил своё мнение, против подсказки после — **8,9 пункта** по решениям к действию. *70 врачей, 254 случая.*

Кто из вас просил у модели второе мнение по решению, которое принял сам? Что сделали, когда она не согласилась?

Goh и соавт., продолжение того же испытания

Четыре ступени участия

участие человека — вниз по ступеням

Смотрит первым
видит случай

Смотрит вторым
видит случай и готовый вывод

Смотрит только спорное
видит выборку, которую отобрала модель

Подписывает не глядя
видит только текст

На второй ступени стоят и выигрыш, и три провала. Шведское испытание — там же, где замер взгляда, патологи и хирурги: ступень одна, исходы противоположные. Расходится у них **устройство процедуры** — сохранена ли независимость двух мнений и кто разбирает расхождение.

Обучение на ступень выше не передвигает: 44 обученных врача читали по шесть клинических задач — точность рассуждения **84,9 → 73,3 из ста**, когда часть рекомендаций неверна.

Риск третьей ступени: человек не знает, что модель отсеяла. **Четвёртой** — формальное требование «человек проверил» выполняется за время, за которое подсказку прочесть нельзя.

Qazi I. A. и соавт., NEJM AI 2026 · *Mozannar и соавт., CHI 2024*

Пример 1: замер взгляда — при ложной и при верной подсказке

ПРОПУЩЕННЫХ РАКОВ ПРИ ЛОЖНОЙ ПОДСКАЗКЕ: БЕЗ → С

29 → 61 из ста имевшихся

14 случаев, где подсказка молчала; значимо. Цена — лечение позже и хуже

ПРОПУЩЕННЫХ РАКОВ, КОГДА РАЗМЕТКУ ЗАПРАШИВАЛИ САМИ: БЕЗ → С

165 → 115 из 900 прочтений

75 случаев с раком на режим; прибавка 5,6 пункта при интервале −0,3…+11,4 — значимости нет. Время чтения не изменилось

Отметка со снимком

снимок с отметкой → чтение → оценка

Разметка по запросу

снимок → чтение → запрос разметки → оценка

Разошлись опыты порядком предъявления подсказки

Два замера одной величины. 10 радиологов прочли 60 маммограмм дважды — сами и с подсказкой, нарочно ошибавшейся в обе стороны. 12 радиологов другой программы — 150 исследований тоже дважды, с допущенной системой.

Та же величина, другой порядок предъявления — обратный знак.

Устроено. Вход — маммограмма, выход — оценка подозрительности области. Изделие называет вторая работа: **Transpara 2.1.0, ScreenPoint Medical. Фокусировка:** осмотрено 11,1 → 9,5 из ста площади снимка, в нужном месте дольше — 4,4 → 5,4 секунды.

Нагрузка на том же месте упала, и при ложной подсказке это цена: пропуск модели стал пропуском читателя.

Taib и соавт., Radiology 2026 · *Gommers и соавт., Radiology 2025*

Пример 2: патологи читают срезы — с подсказкой и без

ДОЛЯ ВЕРНЫХ ЗАКЛЮЧЕНИЙ: МОДЕЛЬ ОДНА · ПАТОЛОГ САМ · ПАРА

0,842 · 0,898 · 0,914

интервалы 0,875–0,916 у патолога и 0,893–0,930 у пары; прибавка пары к патологу на группе НЕ устойчива — отношение шансов 1,281. Точность модели — на своём независимом наборе

ТА ЖЕ ПАРА В РАЗРЕЗЕ ПРАВОТЫ ПОДСКАЗКИ: ВЕРНАЯ → НЕВЕРНАЯ

≈0,94 → ≈0,50

пересчёт из отношений шансов 4,289 и 0,253, устойчивых в обе стороны, от базы восемь верных из десяти: работа печатает шансы, доли иллюстративны

В СУММЕ

средняя та же, разброс вырос

Без модели

срез на экране → патолог решает → подпись

С моделью

срез на экране → **подсказка модели** → патолог решает → подпись

Половина случаев с подсказкой, половина без; подпись в обоих случаях за патологом

11 патологов разного опыта различали два вида рака печени по 80 оцифрованным срезам. **Цена ошибки обоюдна:** спутать два вида опухоли — другое лечение; перепроверка — время специалиста.

Здесь патолог сильнее модели, и пара выше обеих сторон. Ошибка модели при этом становится ошибкой врача: подпись ставит он.

«Эффекта нет» в отчёте с одним числом: на группе прибавка незначима, хотя в обе стороны эффект вчетверо.

Kiani и соавт., npj Digital Medicine 2020

Пример 3: шведское испытание — одно человеческое чтение поверх модели вместо двух

ПРОПУЩЕННЫХ РАКОВ: ДВОЙНОЕ ЧТЕНИЕ → ЧЕЛОВЕК С МОДЕЛЬЮ И АРБИТРОМ

26 → 20 из ста имевшихся

рандомизированное испытание, 105 934 женщины; различие устойчиво

ИНТЕРВАЛЬНЫЕ РАКИ НА 1000 ОБСЛЕДОВАННЫХ: ДВОЙНОЕ ЧТЕНИЕ → С МОДЕЛЬЮ

1,76 → 1,55

93 из 52 872 против 82 из 53 043. Улучшение НЕ доказано: отношение 0,88 при интервале 0,65–1,18 — не-худшесть

ОБЪЁМ ЧЕЛОВЕЧЕСКОГО ЧТЕНИЯ

ниже на 44,3 процента

база — двойное чтение, два человеческих прочтения на снимок; промежуточный анализ, 80 033 обследованных

Двойное чтение

два радиолога порознь → расхождение сводят → решение

Модель и один человек

модель читает первой → один радиолог → расхождение — третий → решение

К арбитру уходит только расхождение, а не весь поток

105 934 женщины шведской программы распределены жребием между двумя порядками чтения. Человеческого чтения во втором меньше потому, что к арбитру уходит только расхождение.

Модель одну это испытание не измеряло, и одиночного чтения без арбитража в нём тоже нет: сравнивали против сильного режима.

Арбитраж стал новой работой; повторных вызовов не стало ни больше, ни меньше.

Итоговый анализ MASAI, The Lancet 2026 · *анализ безопасности, Lancet Oncology 2023* · *Dembrower и соавт., Radiology 2025*

Кардиограмма с неверной машинной расшифровкой: кто теряет больше

ПОТЕРЯ ТОЧНОСТИ НА НЕВЕРНОЙ РАСШИФРОВКЕ: КАРДИОЛОГИ → ДРУГИЕ СПЕЦИАЛЬНОСТИ

−43,20 → −58,95 пункта

различие устойчиво в обеих группах; менее экспертная теряет на 15,75 пункта больше — вывод авторов, высказанный дважды

СОГЛАШАЛИСЬ С НЕВЕРНОЙ РАСШИФРОВКОЙ

30,77 против 42,31 из ста

медианы по тем же двум группам, в том же порядке: менее экспертная соглашается чаще

Как читали

кардиограмма с расшифровкой ➡ стажёр читает ➡ заключение

Расшифровка приходит до собственного решения; чтения без неё работа не измеряла

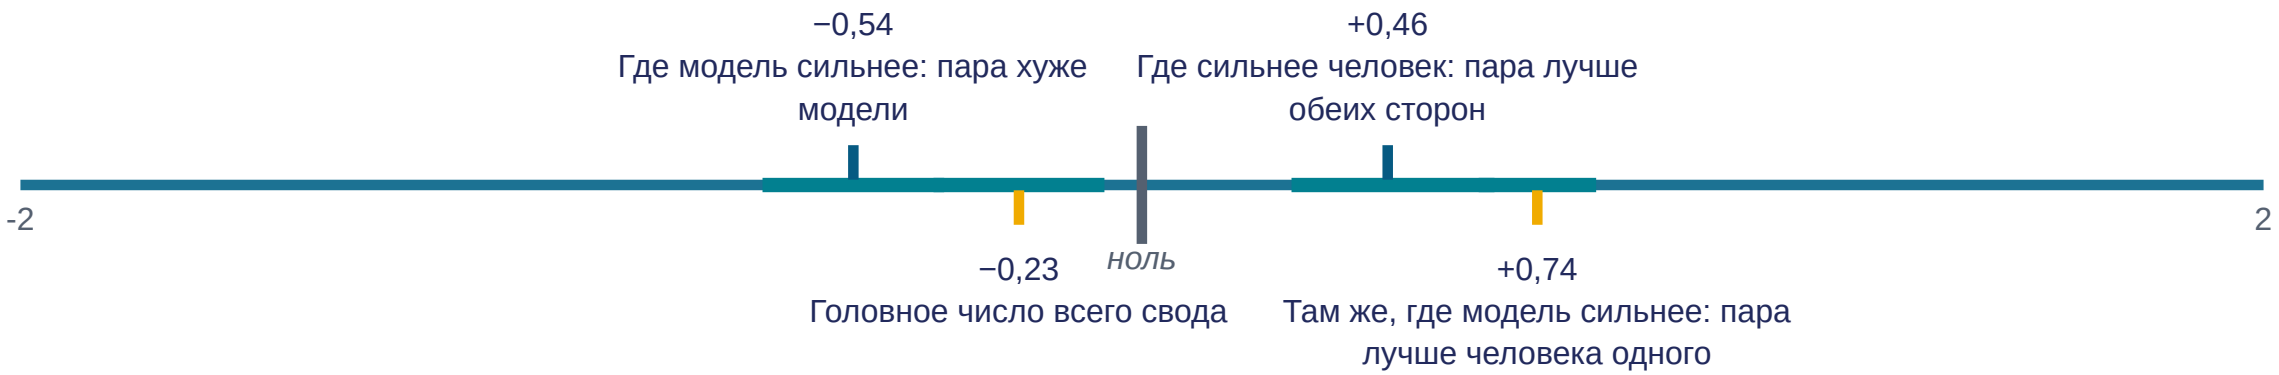
30 стажёров читали кардиограммы с машинной расшифровкой — верной и неверной. 15 из кардиологии, 15 из других специальностей.

точность заключения, из ста	верная расшифровка	неверная
стажёры кардиологии	84,86	**41,66**
другие специальности	86,38	**27,43**

Опыт защищает, но не спасает: падают обе группы, и вдвое.

Bond и соавт., Journal of Electrocardiology 2018 · Buçinca и соавт., CSCW 2021 · Yu и соавт., Nature Medicine 2024

Обзор 106 опытов: где пара сильнее человека и где слабее модели



размер эффекта в долях разброса · 74 работы · 106 опытов · 370 размеров эффекта из 5 126 просмотренных

ни один из четырёх интервалов нуля не накрывает

Предрегистрированный обзор с мета-анализом. Брали только тот опыт, где измерены все три величины: человек один, модель одна и пара.

Головное число свода — минус 0,23: в среднем пара хуже сильнейшей из сторон. От него обе половины свода читаются как части, а не как итог.

Там, где модель сильнее человека, обе величины считаны на одних и тех же опытах: пара хуже модели на 0,54 и при этом лучше человека одного на 0,74. Обе разом — и есть правило: пара обходит слабейшую сторону и не догоняет сильнейшую.

По всему своду пара обходит человека одного на 0,64 — но это другая база и другие опыты, рядом с минус 0,54 это число не ставится.

Vaccaro, Almaatouq, Malone, Nature Human Behaviour 2024

Пример 4: хирурги оценивают риск — сами и после знакомства с моделью

НЕДООЦЕНИТЬ РИСК

оперируют как рядовой случай

без реанимации и без разговора с семьёй

ПЕРЕОЦЕНИТЬ РИСК

операцию отложат или отменят

в тридцатидневном счёте её не видно: не оперировали — сравнивать не с чем

ПЛОЩАДЬ ПОД КРИВОЙ, ХИРУРГ САМ → С POTTER

смертность 0,841 → 0,870 · септический шок 0,820 → 0,712

пневмония 0,753 → 0,803: на трёх исходах из четырёх пара точнее хирурга одного. Шкала: 0,5 — монетка, 1,0 — без промаха

Хирург сам

письменное описание случая ➡ оценка риска ➡ пять исходов

Хирург после модели

описание случая ➡ **POTTER: 4–11 ответов** ➡ оценка риска ➡ пять исходов

Жребием на две группы по 15; больного не осматривал никто

30 хирургов оценивали риск по 150 письменным описаниям случаев; исходы прослежены вперёд 30 дней.

На септическом шоке пара ниже и хирурга, и модели: та одна дала 0,816. **Второй классический режим — шкалы риска,** другая выборка: 0,874–0,898 против модели 0,916.

Исполнитель тот же, но стал хуже. Ступень — смотрит вторым. Где перевес модели наибольший, пара не прибавила вовсе: **0,834 против 0,833.**

Больного не осматривал никто. Повторения замера нет.

Бертсимас и соавт., Annals of Surgery 2018 · *модель против чутья хирурга, Journal of Trauma 2023* · *Эверетт и соавт., npj Digital Medicine 2026*

Ответ собран: четыре случая, четыре эффекта, один вывод

случай	эффект	вывод
Хирурги и POTTER. 30 хирургов, 150 случаев, жребием	на трёх исходах из четырёх пара точнее хирурга; на септическом шоке **0,712** против 0,820 и 0,816	проиграла там, где человек был сильнее
Врачи с языковой моделью. 50 врачей, жребием	балл рассуждения **76 против 74**: разница 2 пункта, интервал −4…8	от справочника не отличима
Обзор с мета-анализом. 74 работы, 106 опытов	где модель сильнее — пара хуже модели на **0,54**, лучше человека на 0,74; по всему обзору −0,23	счёт идёт против сильнейшей стороны
Замер взгляда. 10 читателей, против себя	где подсказка молчала (14 случаев) — пропущенных раков **29** → **61** из ста	знак задаёт правота подсказки

Ни в одном из четырёх решение человека не дошло до больного. Исходы служат эталоном для счёта точности, а не последствием подсказки.

хирурги: Journal of Trauma 2023 · *врачи с языковой моделью: JAMA Network Open 2024* · *свод: Nature Human Behaviour 2024* · *взгляд: Radiology 2026*

Пример 5: модель раннего предупреждения о сепсисе

ЦЕНА ПРОПУСКА

часы до реанимации

не в деньгах

ЦЕНА ЛОЖНОЙ ТРЕВОГИ

через сотню — закрывать не читая

время, снятое с другого пациента

ПОДТВЕРЖДАЕТСЯ ИЗ ПОДНЯТЫХ ТРЕВОГ: ШКАЛА → МОДЕЛЬ

8 → 12 из ста

шкала: 45 776 пациентов, сепсис 3,3 из ста · модель: 38 455 госпитализаций, 6,6 из ста

ЗАЯВЛЕНО → ИЗМЕРЕНО НЕЗАВИСИМОЙ ПРОВЕРКОЙ

0,76–0,83 → 0,63

площадь под кривой: 0,5 монетка, 1,0 без промаха. Поймано 33 случая из ста — не выявлено 1 709 из 2 552

Шкала руками	баллы по таблице	➡	сумма	➡	порог	➡ назначенное действие
Модель в карте	показатели и записи непрерывно	➡	**балл риска**	➡	тревога с назначениями	➡ смена разбирает

Классический режим — не ноль, а шкала, которую считали руками

Модель сепсиса Epic в медицинской карте. *Прогноз на структурированных данных: штрафованная логистическая регрессия, глубокой сети нет.*

Сравнивать надо со шкалой, а не с нулём. *Ретроспективно, 27 697 пациентов.*

Wong, Otles и соавт., JAMA Internal Medicine 2021, с эрратой того же журнала · сравнение балльных шкал, JAMIA Open 2021 · Ostermayer и соавт., JAMIA Open 2024 · заявление по второй версии и проспективная проверка

Пример 5, цена: восемнадцать тревог на сто госпитализаций

ЧТОБЫ НАЙТИ ОДИН СЛУЧАЙ, РАЗОБРАТЬ

восемь тревог

прежние пятнадцать отозваны эрратой того же журнала

ВТОРАЯ ПРОВЕРКА, ДРУГИЕ АВТОРЫ И БОЛЬНИЦЫ

опережение — ноль минут

медианное; 145 885 обращений, 2023 год

ДОЛЯ ПАЦИЕНТОВ С ТРЕВОГОЙ ЗА ЭПИДЕМИЮ

9 → 21 из ста

другая база — 24 больницы: поток 953 → 1 363 при загрузке 10 159 → 6 634

До	обход по расписанию →	балл по таблице →	звать врача или нет
После	карта считает непрерывно →	**тревога модели** →	разбор и отклонение

Разбор тревоги — новый шаг той же смены

Тревога приходит на 18 госпитализаций из ста; подтверждается 12 из ста поднятых тревог — считано от разного, путать нельзя.

Шкала подтверждалась 8 из ста, модель — 12: из этой полосы она не вышла. Населения разные — сравнивается порядок величины, превосходства оно не устанавливает.

Вторая проверка дословно: «добавляет мало к тому, что врачи и так делают».

Что переехало: нагрузка выросла на том же месте, и **появился шаг** — у шкалы отклонять было нечего, порог она считала сама. **Распределение входов сдвинулось, порог остался.**

Wong, Otles и соавт., JAMA Internal Medicine 2021, с эрратой того же журнала · Ostermayer и соавт., JAMIA Open 2024 · объём тревог за эпидемию

Вывод раздела: инструмент один, исходы противоположные

Что получается

• второй взгляд на поток целиком
• напоминание о редком диагнозе
• пара сильнее обеих сторон — при одном устройстве процедуры
• арбитраж только на расхождениях: весь поток к нему не идёт

Что не получается

• сохранить независимость двух мнений
• удержать преимущество там, где человек сильнее
• заметить, что распределение входов сдвинулось
• назначить ступень участия: её не записывает никто

Пять разборов стадии дали противоположные исходы при одном и том же инструменте. Шведское испытание: одно человеческое чтение поверх модели сильнее двойного человеческого. Хирурги: та же пара ниже и человека, и модели. Расходится не модель — расходится устройство процедуры: сохранена ли независимость двух мнений и в каком порядке предъявлена подсказка.

Держат это порог, назначенный под цену обеих ошибок, арбитраж на расхождениях и порядок предъявления подсказки.

Ступень участия нигде не записана. Неназначенная сползает к подписи не глядя.