


Лекция 17

Систематизация знаний и навыков — инженерная карта AI

Где AI **работает**, где — **нет**,
и как это **понять**?



Карта 16 отраслей курса на одной плоскости

Карта применимости ИИ: горизонталь — нужен ли AI, вертикаль — сколько ему доверять.



Две оси

Горизонталь — нужен ли AI вообще (применимость).

Вертикаль — сколько автономии доверять (L0 → L5).

Высокое значение — не «лучше», а «AI подходит» / «AI делает больше».

Верхне-левый квадрант обязан оставаться пустым.

1

Раздел 1

Когда AI применять, когда нет

Семь критериев — горизонтальная ось карты как диагностический чек-лист.

7 критериев · последовательные ворота · полностью про границы

1. Критерии

2. Лестница

3. Карта 16

4. Провалы

5. Карточки

Семь критериев работают как последовательные ворота: один однозначный «нет» — и задача не для полной автономии AI.



1. Закрытая петля или открытая среда?

Есть ли быстрая измеримая обратная связь?



2. Достаточно ли обучающих данных

и совпадает ли распределение с эксплуатацией?



3. Повторяемость и объём

задача частая или штучная?



4. Цена ошибки и радиус разрушения

сколько стоит ошибка и как широко расходится?



5. Доступность эталона

есть ли быстрая проверка правильности?



6. Объяснимость и аудит

нужно ли объяснить каждое решение?



7. Экономика против базовой линии

окупается ли AI против классической альтернативы?

Правило применения

Один **X** → **СТОП**: полная автономия не подходит.

Несколько **⚠** → начинайте с advisory + человек в петле.

Все **✓** → пилот с явными точками GO / NO-GO.

Закрытая петля с быстрой обратной связью — AI работает; открытая среда с распределённым сдвигом — AI системно проваливается.

Закрытая петля — AI работает

See & Spray — агро (фото)

контролируемый ряд, −50% гербицидов: $\approx 1 \rightarrow 0,5$ фунт/акр на 5 млн акров (0,55% пашни США)

Aidoc — медицина (радиология)

стандартизованные снимки, человек в петле, FDA-режим L1

Складская робототехника — логистика

миллионы операций в контролируемой среде

Открытая среда — AI проваливается

Zillow — недвижимость

COVID-сдвиг, \$304 млн списания, 25% сокращений ($\approx 2\,000/8\,000$), ноя. 2021

Monarch — агро

открытое поле, погода; 38% сокращений ($\approx 53/140$), янв. 2025

Cruise — транспорт

протащил пешехода 20 футов 02.10.2023; GM закрыл подразделение 10.12.2024



John Deere · Wikimedia · CC BY 2.0


Критерий 2: даже закрытая среда не спасёт без данных, отражающих эксплуатацию. Epic Sepsis — вендор заявлял AUC 0,76, внешняя валидация на 38 000 пациентов дала 0,63.

AI окупается на повторяемых задачах с низкой ценой ошибки — и опасен там, где цена ошибки умножается на большой радиус разрушения.

Критерий 3 — повторяемость и объём

GitHub Copilot — разработка ПО: миллиарды дополнений/день; 20+ млн платных (из ≈28 млн разработчиков GitHub); 46% кода. Ошибка — нажать Esc. AI окупается с запасом.

Архитектура крупной системы: раз в год-полтора, огромная цена ошибки. AI не окупается — нужен сеньор.



BSOD на табло LaGuardia 19.07.2024 · Wikimedia · CC BY-SA 4.0

Критерий 4 — цена ошибки × радиус разрушения (по возрастанию радиуса)

Применение	Радиус	Обнаружение	Откат
Copilot — ошибка автодополнения	1 разработчик	секунды	секунды (Ctrl-Z)
Aidoc — пропуск (в L1)	1 пациент	минуты-дни	радиолог проверит
Waymo — инцидент	1-несколько	секунды	минуты
CrowdStrike Falcon (19.07.2024)	8,5 млн устройств	минуты	часы (ребут каждого)

CrowdStrike отличается на порядки. \$5+ млрд ущерба клиентам (оценка Parametrix по Fortune 500 — не убытки самой CrowdStrike). Широкий радиус не запрещает систему — требует строже дисциплины развёртывания.

Без быстрого эталона и без объяснимости AI остаётся на advisory — даже без злого умысла чёрная коробка разрушает доверие.

Критерий 5 — доступность эталона

Три уровня причинности Pearl:

Уровень 3 — контрфактуальность

«что было бы, если бы X не произошло» — для AI структурно недоступен (территория человека)

Уровень 2 — вмешательство

«что будет, если сделать X» — умеренно (нужен RCT / A/B-тест)

Уровень 1 — ассоциация

«что бывает вместе с X» — применимость высокая (ML учится на корреляциях)

Скорость эталона: компилятор (секунды) → дефолт по кредиту (месяцы) → исход лечения (годы)

Критерий 6 — объяснимость и аудит

EU AI Act (в силе с 01.08.2024): системы высокого риска обязаны давать объяснимые решения.

Apple Card 2019

Вирусная жалоба на 20× разницу лимита; расследование DFS Нью-Йорк закрыто в марте 2021 — Goldman Sachs оправдан в намеренной дискриминации (пол не был во входных признаках).

Урок — объяснимость, не предвзятость.

AI обязан бить лучшую классическую альтернативу на деньгах — иначе отказ от AI это инженерное решение, не поражение.

Критерий 7 — окупается ли AI против классической альтернативы

UPS ORION — логистика

операционные исследования, \$300-400 млн экономии/год, ни одной нейросети. ML давал «несколько %», но стоимость интеграции их съедала.

MPC против RL — нефтехимия

предиктивное управление работает десятилетиями; RL впервые показан промышленно (Yokogawa FKDP, 2022), но не вытеснил MPC.

Запасы — EOQ (Ford-Harris, 1913)

формула + страховой запас; ML добавляет ценность только на переменном спросе.



Грузовик UPS · USDA · Public domain (кейс ORION)

Q1 — AI работает + автономно

Copilot · Claude Code · Stripe Radar · Symbolic · AlphaFold

Q3 — «классика выигрывает»

UPS ORION (Gurobi/CPLEX) · MPC · EOQ — AI не нужен

Вендор обещает «–30% потерь воды за 18 месяцев» — семь критериев за 20 минут дают вердикт: не полная автоматизация, а L1 advisory + A/B против EPANET.

Сценарий

Вендор «AquaOptima»: deep learning прогноз расхода + автоматическое управление задвижками.

Обещание: –30% потерь, 25 млн ₽/год, окупаемость 18 месяцев.

Вердикт: не входить в 6-месячный пилот полной автоматизации. 2 мес. аудит данных + базовая линия EPANET → 4 мес. A/B (AI advisory + EPANET vs EPANET). Все управляющие действия — человек. Дельта <10% — остаться на EPANET.



1. Закрытая/открытая

⚠️ полуоткрытая (погода, события, утечки)



2. Данные

⚠️ нужен аудит (утечки не зафиксированы)



3. Повторяемость

✓ десятки тысяч точек, млн измерений



4. Цена ошибки / радиус

✗ задвижка → район без воды на часы



5. Эталон

⚠️ общий расход — да; локальные утечки — нет



6. Объяснимость

⚠️ публичные решения о ремонтах



7. Экономика vs базовая

⚠️ «–30%» против чего? A/B с EPANET

Критерий 4 (✗) — блокирующий: одна неправильная задвижка оставит район без воды. Эталон — EPANET (открытый гидравлический симулятор водопроводных сетей).

2

Раздел 2

Лестница автономии L0 → L5

Вертикальная ось карты — формальная шкала с маппингом локальных шкал курса в единую.

6 ступеней · кросс-отраслевой маппинг · антипаттерн на каждой

1. Критерии


2. Лестница

3. Карта 16

4. Провалы

5. Карточки

Шесть дискретных ступеней — от «человек делает всё» до недостижимой в 2026 полной автономии.



Все локальные шкалы курса сводятся в единую L0 → L5 — но не все они про автономию: ось среды и функции ортогональны.

Таблица А — прямой маппинг (это шкалы автономии)

Единая L0 → L5	Разработка ПО	Авиакосмос	Производство
L0 без автомат.	—	—	A0 наблюдать
L1 advisory	A автодополнение	L1 assistive	A1 советовать
L2 supervised	B внутри задачи	L2 supervised	A2 (часть)
L3 conditional	C код по спецификации	L3 conditional	A2 замыкать
L4 high	D инженер-агент	L4 high	A3 пилот
L5 full	(недоступен)	L5 двойн. назнач.	(редко)


Врезка В — ортогональные оси
(НЕ автономия)

Логистика — 5 уровней
структурированности среды
(контролируемая → город → последняя миля
→ чёрный лебедь): это ось среды. Чем
структурнее среда, тем легче L3-L4.

Кибербезопасность — «Видит →
Решает → Действует»
функциональная декомпозиция: каждая
функция может быть на разном уровне
автономии.

Маппинг не точный — это переводчик. Когда вендор говорит «наш AI на L3», спросите: в какой нотации? Источник: SAE J3016 (адаптация).

L1 advisory — самый частый уровень зрелой промышленной эксплуатации: AI советует, человек решает всегда.



Примеры из курса


Stripe Radar — платежи: скоринг + флаг «возможный фрод», аналитик решает

Aidoc, Chester AI — медицина: пометка «возможная патология», радиолог решает

GitHub Copilot — разработка ПО: предлагает строку, разработчик принимает

Crop Wizard — агро: отвечает фермеру со ссылками, фермер действует

Project Maven — авиакосмос/оборона: выделяет объекты на снимке, аналитик авторизует



КТ-снимок мозга · Wikimedia · CC BY 4.0 (кейс Aidoc)

Подъём на L2 требует:

базовая линия измерена + улучшение AI измерено ·
контроль изменений · готов откат · приемлемая частота
ложных срабатываний.

Человек решает — всегда. L1 не «недоразвитость», а намеренный режим в регулируемых отраслях.

L2 supervised и L3 conditional — AI действует, но человек подтверждает каждое (L2) или AI работает только в узком домене (L3).

L2 — Supervised (действует с подтверждением)

AI выполняет действие, человек подтверждает или отменяет каждое.

Примеры:


- Stripe Radar — авто-блок высоко-уверенного фрода (платежи)
- Microsoft Defender XDR — авто-карантин (кибербезопасность)
- Copilot Workspace — разработка ПО
- Yokogawa FKDP — RL для реактора, оператор вмешивается (процессное производство)

L3 — Conditional (узкий ODD)

Автономно в строго ограниченном домене (ODD); вне домена — отказ и передача человеку. ODD проверяемо в реальном времени.

Примеры:

- Waymo в геозон-районах (транспорт, фото)
- Mobileye Chauffeur на конкретных шоссе (транспорт)
- Copilot-агент / Claude Code на очерченном PR (разработка ПО)
- See & Spray в узком ODD (агро)



Waymo robotaxi, SF · Dllu · Wikimedia · CC BY-SA 3.0

ODD (Operational Design Domain) — формальное определение условий, где система работает. Подъём на L4: проверка sim-to-real · канареечный выпуск 5-10% на 2-4 недели · числовые ворота go/no-go.

L4 high достижим в широком домене с человеком на петле; L5 full в 2026 — теоретический горизонт, не цель.

L4 — High (широкий ODD, человек на петле)

Waymo — транспорт

сотни тысяч поездок/год без водителя безопасности

Symbotic, Amazon Sparrow — логистика (фото)

миллионы операций в сутки

See & Spray в коммерции — агро

5 млн акров за 3 года

AlphaFold (конвейер) — наука

200 млн структур без вмешательства человека



Amazon fulfilment robot · Wikimedia · CC BY-SA 4.0 (проксу Symbotic)

L5 — Full: почему недостижим в 2026

1. Страховые рынки отказываются страховать за пределами узких сценариев
2. Регуляторы требуют человеческого надзора для систем высокого риска
3. События вне распределения структурно не лечатся данными
4. Распределение ответственности при L5 юридически не определено
5. Экономика: L4 уже покрывает 99%+ реалистичных сценариев

L5 — теоретический горизонт, не цель. Tesla позиционируется как «full self-driving», но классификация NHTSA — L2.

У каждой ступени свой характерный провал — от превышения роли Klarna на L1 до блока по LAWS на L5.



L1 — Превышение роли

Klarna, поддержка клиентов

Заявлен советник, действует без подтверждения → обратный найм операторов.

Урок: Позиционирование ≠ режим.



L2 — Скучный человек в петле

Uber Tempe 2018, транспорт

Водитель на телефоне, погиб пешеход.

Урок: Скучный мониторинг → HOOL с алертом.



L3 — Расширение ODD без валидации

Cruise 02.10.2023, транспорт

Расширили домен без проверки, протащили пешехода 20 футов.

Урок: Расширение ODD требует валидации.



L4 — Действие без канарейки

CrowdStrike 19.07.2024, кибербез

Широкий домен = большой радиус, без канареечного выпуска.

Урок: Широкий ODD требует строже.



L5 — Этический / регуляторный блок

Дебаты о LAWS, авиакосмос/оборона

Технически возможно, этически и регуляторно — нет.

Урок: L5 для оружия — запрещён.



Сквозной — Пропуск ступени

Toyota Digit / Cassie, двойники

Нельзя с L1 на L3 без L2; двойник как мост.

Урок: Каждая ступень — другая дисциплина.



Стенд Klarna, Internet World Fair 2017 ·
Wikimedia · CC0 (кейс L1 превышение роли)

AI-помощник для приёма экзаменов — максимум L1 advisory: высокая цена ошибки + обязательная апелляция держат человека в решении.

Лестница — потолок = L1

L5 *недопустим*

L4 *недопустим*

L3 *недопустим*

L2 *недопустим*

L1 ← **потолок (максимум)**

L0

Анализ

Цена ошибки — высокая (несправедливая оценка, обвинение в плагиате, академический рекорд).

Объяснимость — критическая (студент имеет право апеллировать).

Регуляторное окно — академические правила требуют человека-оценщика.

Эталон — для тестов есть, для эссе частично (rubrics, субъективность остаётся).

Вердикт: L1 advisory — максимум. AI выставляет предварительную оценку + флаг плагиата + объяснение; преподаватель решает; студент может оспорить.

Подъём на L2:

измерить базовую линию (сколько ошибается преподаватель / AI на тест-сете); если AI систематически точнее — переход с контролем изменений.

L3-L4 недопустимы по регулятору и этике.

3

Раздел 3

16 отраслей на одной карте

Точечная диаграмма строится слой за слоем + кластерный анализ.

точечная карта · 1 плоскость · ~20 точек · 4 квадранта

1. Критерии

2. Лестница

3. Карта 16


4. Провалы

5. Карточки

Каждая из 16 отраслей курса поднимала свою локальную ось — и все они про одно: насколько AI берёт действие на себя.

Введение в AI Диагностический вопрос; эффект ИИ; 3 уровня Pearl	Большие модели Конвейер вывода; «слепота к буквам» как граница	Архитектуры AI prompt → RAG → агент → дообучение; накопление ненадёжности	Разработка ПО Лестница A/B/C/D (автодополнение → инженер-агент)
Финансы и ритейл Закрытый мир vs открытый мир прогноза	CAD/CAM 6 классов AI в проектировании; «оптимизация ≠ генерация»	Медицина Закрытая петля; человек в петле; RCT как эталон	Креатив «Добавил → изменил → сломал» × 4 области
Авиакосмос/оборона OODA; человек в/на/вне петли; автономия L1-L5	Агросектор Лестница АПК; закрытая петля vs открытая среда	Производство Дискретное vs процессное; болото пилотов	Цифровые двойники A0-A3 + цифровой двойник как мост
Логистика/транспорт Лестница среды (5 уровней); ODD; 7 критериев	Телеком/кибербез «Видит → Решает → Действует»; MITRE ATLAS	Наука Лестница научного цикла; AlphaFold vs Galactica	Нефтегаз Матрица 2×2 «данные × процесс»

Первые четыре точки уже показывают структуру: смежное с IT — вверху-справа, регулируемая медицина — внизу-справа.



Разработка ПО — верх-право
текст/код — модальность фундаментальных моделей; компилятор даёт эталон; объём гигантский.

Финансы и ритейл — верх-середина
фрод (закрытый мир) высоко; iBuying (открытый мир) низко — Zillow показал почему.

Медицина — низ-право
узкая визуализация высоко; автономия капнута FDA на L1.

Авиакосмос/оборона — потолок
восприятие высоко, действие ограничено этически (дебаты о LAWS).

Разработка ПО — чистая координата верх-право.

Средний набор добавляет двойственные (бимодальные) отрасли: агро раздваивается на узкую очерченную See & Spray и провальный Monarch.



CAD/CAM — середина
оптимизация высоко; LLM для CAD-скриптов низко (ORCA 45-63%).


Креатив — бимодально
массовые ассеты высоко; авторское производство низко (Getty vs Stability).

Агро — двойственное облако
See & Spray ↑ верх-право; Monarch ↖ верх-лево (зона предупреждения), провал.

Производство — середина-низ
CV на конвейере высоко; LLM на коде PLC низко.

Агро раздваивается — готовность локальна по задачам, не глобальна по отрасли.

Логистика — три точки одной отрасли: склад L4, робот-такси L3, чёрный лебедь фактически L0.



Логистика (3 точки!)

склад (Symbolic, L4) ↑; робот-такси (Waymo/Cruise) середина; чёрный лебедь (Суэц, COVID) — фактически L0.

Телеком/кибербез

восприятие высоко (L1-L3); действие ограничено радиусом (CrowdStrike).

Наука — двойственная

AlphaFold (закрытый мир) высоко vs Galactica (открытый мир) низко.

Нефтегаз

LLM без физики не заменит геолога — нужны PINN / гибриды физика+ML.

Логистика — самая бимодальная: внутри одной компании AI на L4 (склад) и на L0 (чёрный лебедь). Зрелость локальна, не глобальна.

Кластер закрытой петли (верхний правый) — пять общих признаков, профиль успешного применения AI.



Пять общих признаков — профиль успеха

1. Среда контролируемая или закрытая (критерий 1 ✓)
2. Эталон быстрый и однозначный (критерий 5 ✓): компилятор / чарджбэк / разметка
3. Объём задач большой (критерий 3 ✓)
4. Цена ошибки низкая или поглощаемая (критерий 4 ✓)
5. Распределение обучения совпадает с эксплуатацией (критерий 2 ✓)



AlphaFold · Wikimedia · CC BY-SA 4.0

Новая отрасль удовлетворяет всем пяти признакам — у проекта хорошие шансы.

Кластер открытой среды (верхний левый) — зона провалов; открытая среда это физика задачи, а не недостаток модели.



Состав и что общего (зона предупреждения)

Monarch (38% сокращений ≈53/140) · Plenty (\$940 млн+ → Chapter 11)

Cruise · чёрный лебедь (Suez, COVID) · Zillow (\$304 млн) · Galactica (отозвана за 48 ч)


1. Среда открытая, состязательная (критерий 1 ✗)
2. Данные не покрывают редкие события (критерий 2 ✗)
3. Цена ошибки высокая (критерий 4 ✗) · 4. Эталон медленный/нет (критерий 5 ✗)



Monarch MK-V ·
monarchtractor.com · fair use

Открытая среда — это физика задачи, а не недостаток модели. Сузьте домен; перейдите на advisory; откажитесь от AI.

Кластер высоких ставок (нижний правый) — применимость высокая, но автономия капнута регулятором; цель — усиление, не замена.



Состав (регуляторно-капнутая автономия)

Медицина (капнут FDA на L1) · Авиакосмос (капнут регуляцией LAWS)

Производство, критичное к безопасности (IEC 61508 SIL 2/3)

Кибербезопасность уровня действия (дисциплина радиуса)

Нефтегаз ATEX Zone 0 (сертификация оборудования)


Общее: применимость высокая, автономия ограничена; объяснимость обязательна.



Мониторинг ICU · US Navy · Public domain (кейс Epic Sepsis)

Усиление, а не замена. Радиолог с AI лучше радиолога без — но решение всегда за радиологом (IBM Watson Health показал, что полная замена проваливается).

Пустой верхне-левый квадрант — дидактический сигнал: низкая применимость × высокая автономия = катастрофа.



Верхний левый — пустой и опасный

Кто туда попадает:

- CrowdStrike Falcon BSOD — радиус 8,5 млн устройств
- F-35 ALIS — предиктивное обслуживание с высокой автономией
- Cruise — расширение домена в открытой среде

Два направления сдвига:

Вправо → повысить применимость (закрыть среду, набрать данные, улучшить эталон).

Вниз ↓ снизить автономию (на-петле → в-петле → советник).

Попадаю ли я в верхне-левый? Если да — что изменить, чтобы сдвинуться?

4

Раздел 4

Двенадцать провалов курса. Что выучили?

Каждый провал — повторяющийся паттерн, не ошибка одной компании.

кросс-отраслевые · уроки → альтернативы · полностью про границы

1. Критерии

2. Лестница

3. Карта 16

4. Провалы

5. Карточки

Провалы 1-4: открытый мир, накопление ненадёжности, демо ≠ промышленная эксплуатация, скучный человек в петле.



1. Прогноз в открытом мире без закрытой петли

Zillow · Monarch · Cruise

Урок: распределённый сдвиг убивает ML на исторических данных.

Альтернатива: сузить домен; советник; не-AI базовая линия.



2. Накопление ненадёжности в многошаговом агенте

\$4 200-петля у агента поддержки; агентная разработка ПО

Урок: $p^N \rightarrow 0$ при $N > 10$ ($p=0,95$, $N=10 \rightarrow 0,59$).

Альтернатива: лимит бюджета + макс. шагов + точки человека.



3. Демо вендора ≠ промышленная эксплуатация

Devin · IBM Watson · Epic Sepsis · Klarna

Урок: вендорский бенчмарк ≠ ваша среда.

Альтернатива: повторить измерение на ваших данных.



4. Скучный человек в петле не работает

Uber Tempe · F-35 ALIS

Урок: редкий скучный мониторинг проваливается.

Альтернатива: человек-на-петле с алертом.



Uber Volvo XC90 (модель из аварии Tempe 2018) · Dllu · Wikimedia · CC BY-SA 2.0

Провалы 5-8: переавтоматизация, действие без канарейки, научная галлюцинация, голос/видео-дипфейк мошенничество.



5. Переавтоматизация в зонах вариативности

Tesla 2018 · Boeing 737 MAX 9

Урок: парадокс автоматизации (Бейнбридж, 1983): автоматизация ломает пропускную способность.

Альтернатива: Jidoka — усиление; SPC остаётся.



7. Научная галлюцинация класса Galactica

Meta Galactica — галлюцинации цитат

Урок: в науке эталон — воспроизводимый эксперимент, а не текст.

Альтернатива: RAG-заземление + рецензирование по чек-листу.



6. Действие без канарейки и отката

CrowdStrike · Cloudflare

Урок: широкий домен = большой радиус разрушения.

Альтернатива: канарейка 1-5% + телеметрия + откат в один клик.



8. Голос/чат-мошенничество и дипфейк

Wendy's · Air Canada · Arup \$25 млн (видео-конф., февр. 2024)

Урок: шумная среда + сложность = AI ненадёжен; видео+голос = новый вектор.

Альтернатива: C2PA-подпись; проверка через независимый канал.



Видеоконференция (концепт; кейс Arup \$25 млн) · DoD · CC BY 2.0

Провалы 9-12: утечка обучающих данных, привязка к вендору, slopsquatting, болото пилотов.



9. Дословная утечка обучающих данных

Getty vs Stability · NYT vs OpenAI

Урок: у фундаментальных моделей есть хвост запоминания — часть данных хранится дословно.

Альтернатива: лицензированные датасеты; аудит провенанса; C2PA.



10. Привязка к вендору в регулируемых отраслях

Climate FieldView · F-35 ALIS · IBM Watson

Урок: привязка → стратегический риск; данные у вендора, выход стоит миллионы.

Альтернатива: гос-инфраструктура; экспорт данных в контракте.



11. Slopsquatting / галлюцинации цепочки поставок

Атаки на имена пакетов npm/pip — разработка ПО

Урок: AI выдумывает имена пакетов; атакующие их занимают → вредоносный код.

Альтернатива: проверка SBOM + список разрешённых импортов.



12. Болото пилотов / 90-95% не доходят

MIT NANDA 95% · McKinsey 5,5% · РФ 9 из 10 · двойники 75%*

Урок: пилот соскальзывает в бесконечность.

Альтернатива: явные ворота GO/NO-GO + базовая линия + лимит бюджета.



Stable Diffusion с искажённым Getty-watermark (кейс Getty v. Stability) · AI-gen · Public domain

Почти все провалы сводятся к трём мега-паттернам: AI за границей закрытой петли, плохой человек в петле, проигнорированная базовая линия.



Мега-паттерн 1

AI за границей закрытой петли

Провалы 1 (Zillow/Monarch/Cruise), 7 (Galactica), частично 5.

Диагностируйте среду до старта (критерий 1).



Мега-паттерн 2

Человек в петле спроектирован плохо

Провалы 4 (Uber Tempe/F-35 ALIS), частично 1 (Cruise), 6 (CrowdStrike).

Человек в петле — инженерная дисциплина, не формулировка.



Мега-паттерн 3

Экономическая базовая линия проигнорирована

Провалы 3 (демо ≠ эксплуатация), 12 (болото пилотов), частично 10.

Измерьте базовую линию + классическую альтернативу до коммита.

30-секундная процедура для любого AI-предложения:

1. Какая среда — закрытая или открытая со сдвигом?
2. Есть ли человек в петле, и не скучно ли ему?
3. Какая базовая линия, и окупит ли AI дельту?

Четыре опорные карточки — то, что вы заберёте с собой и будете применять в работе.



Карточка #1 (A4)

Матрица из 7 критериев

«применять ли AI» — чек-лист



Карточка #2 (A4)

**Лестница автономии
L0 → L5**

+ критерии подъёма



Карточка #3 (A4)

Реестр 12 провалов

+ противоядия

главная по ценности



Карточка #4 (A1)

Карта 16 отраслей

плакат на 2D-плоскости

Карточка #1 — матрица из 7 критериев: пройди 7 строк, один X — СТОП.

№	Вопрос	Индикатор	Пример из курса
1	Среда контролируемая/закрытая?	✓ закрытая / △ полу / X открытая	See & Spray ✓; Monarch X
2	Данных достаточно + совпадают?	✓ / △ / X	компилятор ✓; Epic Sepsis X
3	Повторяема + высокий объём?	✓ / X	Copilot ✓; штучная архитектура X
4	Цена ошибки приемлема?	✓ низкая / △ HITL / X катастрофа	Stripe Radar ✓; CrowdStrike X
5	Эталон быстрый?	✓ / X	компилятор ✓; скупка жилья X
6	Нужна объяснимость?	✓ SHAP/LIME / △ прозрачн. модель / X	Aidoc; Apple Card 2019
7	Окупается vs базовая линия?	✓ / X	LaserWeeder ✓; ML vs MPC X

Один X — СТОП, отказ от полного AI. ≥2 △ — СТОП, обоснуй человека в петле + канарейка + откат. Все 7 ✓ — пилот с явными GO/NO-GO.

QR
PDF

Карточка #2 — лестница автономии L0 → L5: определи текущий уровень и максимально допустимый.


Уровень	Название	Что AI делает	Кто решает	Критерий подъёма
L0	Без автоматизации	Нет AI	Человек	Базовая линия собрана
L1	Advisory	Классиф./предсказ./реком.	Человек всегда	База + контроль изменений + откат
L2	Supervised	Действует, человек подтв.	Человек каждое	Ложные срабат. + канарейка + откат
L3	Conditional	Действует в узком ODD	На петле (HOOL)	ODD + телеметрия + ворота go/no-go
L4	High	Действует в широком ODD	Вне петли (большинство)	99,9% + страховка + допуск регулятора
L5	Full	Решает везде	(недостижим 2026)	Для большинства отраслей недоступен

Антипаттерны: L1 превышение роли (Klarna) · L2 скучный HITL (Uber Tempe) · L3 расширение ODD (Cruise) · L4 без канарейки (CrowdStrike) · L5 этический блок (LAWS) · пропуск ступени (двойник как мост).

Карточка #3 — реестр 12 провалов: главная по ценности, прививка против реальных ошибок.

№	Провал	Источник	Урок → альтернатива
1	Открытый мир без петли	Zillow/Monarch/Cruise	сдвиг убивает ML → сузить домен
2	Накопление ненадёжности	\$4 200-петля / разработка ПО	$p^N \rightarrow 0$ при $N > 10$ → лимит + точки HITL
3	Демо ≠ эксплуатация	Devin/Watson/Epic/Klarna	бенчмарк ≠ ваша среда → повторить на своих
4	Скучный HITL	Uber Tempe / F-35 ALIS	мониторинг проваливается → HOOL с алертом
5	Переавтоматизация	Tesla 2018 / Boeing MAX 9	парадокс Bainbridge → Jidoka, усиление
6	Действие без канарейки	CrowdStrike / Cloudflare	широкий ODD = радиус → канарейка + откат
7	Научная галлюцинация	Galactica	текст ≠ эксперимент → RAG + рецензирование
8	Голос/видео-дипфейк	Wendy's / Air Canada / Arup \$25M	шум+сложность → C2PA + проверка
9	Утечка обуч. данных	Getty / NYT	хвост запоминания → лицензир. датасеты
10	Привязка к вендору	Climate FieldView/ALIS/Watson	стратегич. риск → экспорт данных
11	Slopsquatting	имена npm / pip	выдуманные имена = атака → SBOM + allow-list
12	Болото пилотов	MIT 95% / McKinsey 5,5% / РФ 9 из 10	слип в бесконечность → ворота GO/NO-GO

Карточка #4 — плакат A1: карта 16 отраслей на стену; для новой отрасли — аналогии по координатам.



Повесьте на стену. Для новой отрасли: «эта задача похожа на See & Spray по closed-loop структуре» или «похожа на робот-такси — домен недостаточен».

Знать ИИ — значит знать его **границы**.

Вопросы?

До новых встреч

Две оси карты: применимость × автономия · Семь критериев — один X → СТОП · Три мега-паттерна провалов