


Классифицируй и не ошибись

Тип AI, чек-лист и провалы

Модель отличает верную рамку от ошибочной по чёткому критерию — сегодня вы тренируетесь так же чётко отличать модель от чата, чата от агента, а правду AI от уверенно поданной неправды.

GROUND TRUTH ПРОТИВ ПРЕДСКАЗАНИЯ



Две оси и один чек-лист — язык, который вы уже знаете

Тип задачи × модальность

 **Распознавание** *изображение · YOLO-детектор (демо сегодня утром)*

 **Классификация** *текст / данные · спам-фильтр, скоринг*

 **Поиск** *текст · корпоративная база знаний*

 **Генерация** *текст / код · черновик письма, автодополнение*

Чек-лист «2 вопроса + квадрант»

Q1: нужно ли взаимодействие с пользователем?

Q2: нужна ли самостоятельная работа с инструментами?

Модель

Нет / Нет

Чат

Да / Нет

Приложение

Нет / Да

Агент

Да / Да

Шесть инструментов — один и тот же вопрос: модель, чат, агент или приложение?



4 раунда поднятия руки на инструмент — один вариант за раз

где голоса разойдутся — объясняем выбор вслух до официального ответа

1  YOLO-детектор — демо Лекции 1

детекция людей в кадре в реальном времени

2  AI-чат для разовой консультации

например, ChatGPT — уточняющий диалог по тексту

3  GitHub Copilot — inline Tab-completion

подсказка следующей строки кода

4  GitHub Copilot — Agent-режим

самостоятельно открывает файлы, правит код, коммитит

5  YandexGPT во врезке поиска

краткий ответ над обычными результатами

6  Агент для 200 PDF-отчётов

читает файлы, собирает сводную таблицу

Модель, чат, агент или приложение?



YOLO-детектор людей в кадре

Детекция людей в кадре в реальном времени — прямая перекличка с демо Лекции 1.



AI-чат для разовой консультации по тексту

Например, ChatGPT — уточняющий диалог по тексту.



4 раунда поднятия руки на инструмент — модель? чат? агент? приложение?

Один проход без диалога — модель. Диалог без инструментов — чат



YOLO-детектор людей в кадре

Модель

Q1 нет — нет диалога на каждый кадр. Q2 нет — один проход «изображение → детекция» без вызова инструментов.

Прямая переключка с сегодняшним утренним демо.



AI-чат для разовой консультации по тексту

Чат

Q1 да — диалог, уточнения. Q2 нет — модель работает с тем, что дал пользователь, не ходит сама в базы данных.

Разминочный пункт — ожидаемо низкая дискуссия.

Один и тот же продукт, два режима использования — что это?

 GitHub Copilot — один и тот же продукт, два режима использования



Inline-автодополнение (Tab-completion)

Нажал Tab — получил предложение по текущей строке. Нет диалога, нет многошагового планирования.



Agent-режим (Workspace)

Получает текстовую задачу, сам открывает несколько файлов проекта, правит код, коммитит.

4 раунда голосования на каждый режим — модель? чат? агент? приложение?

Один инструмент — два режима — два разных типа

`</>` GitHub Copilot — один и тот же продукт, два режима использования



Inline-автодополнение (Tab-completion)

Нажал Tab — получил предложение по текущей строке. Нет диалога, нет многошагового планирования.

Приложение

Q1 нет · Q2 нет



Agent-режим (Workspace)

Получает текстовую задачу, сам открывает несколько файлов проекта, правит код, коммитит.

Агент

Q1 да · Q2 да

Тип определяется режимом использования, а не брендом продукта

Модель, чат, агент или приложение?



YandexGPT во врезке Яндекс.Поиска

Сгенерированный краткий ответ над списком обычных результатов поиска.



Агент читает 200 PDF-отчётов

Собирает сводную таблицу — тот же разобранный пример, что на лекции.



4 раунда поднятия руки на инструмент — модель? чат? агент? приложение?

AI «под капотом» — приложение. Самостоятельная работа с файлами — агент



YandexGPT во врезке Яндекс.Поиска

Приложение

Q1 нет · Q2 да

Пользователь не пишет промпт и не ведёт диалог — это функция поиска, AI работает «под капотом».



Агент читает 200 PDF-отчётов → сводная таблица

Агент

Q1 да · Q2 да

Пользователь ставит задачу и утверждает результат; агент открывает файлы, парсит, дописывает в таблицу.

Четыре инженерных сценария — чек-лист под давлением времени

Интуитивный первый ответ здесь иногда неверен — это и есть смысл упражнения



После всех четырёх — общий вопрос: где обычный код справился бы не хуже AI?

Фоновый скрипт проверки орфографии — куда его отнести?



Раз в час фоновый скрипт автоматически проверяет орфографию во всех открытых файлах проекта и дописывает список ошибок в текстовый лог — без интерфейса, без диалога, без вашего участия в моменте проверки.

Q1: нужно ли взаимодействие с пользователем?

Q2: нужна ли самостоятельная работа с инструментами?

Модель

Чат

Приложение

Агент

30–60 сек размышления → голосуем по всем 4 углам

Фоновый скрипт проверки орфографии — разминка



Раз в час фоновый скрипт автоматически проверяет орфографию во всех открытых файлах проекта и дописывает список ошибок в текстовый лог — без интерфейса, без диалога, без вашего участия в моменте проверки.

Q1: нужно ли взаимодействие с пользователем?

Q2: нужна ли самостоятельная работа с инструментами?

Модель

Чат

Приложение

Агент

Q1 нет · Q2 нет — самый чистый случай раздела

Ночной скрипт: баг-репорты → критичность → очереди Jira



Скрипт запускается каждую ночь по расписанию. Сам скачивает новые баг-репорты, классифицирует каждый по критичности через AI и автоматически раскладывает по очередям в Jira. Никто не наблюдает за процессом.

Q1: нужно ли взаимодействие с пользователем?

Q2: нужна ли самостоятельная работа с инструментами?

Модель

Чат

Приложение

Агент



30–60 сек размышления → голосуем по всем
4 углам

Ночной скрипт: баг-репорты → критичность → очереди Jira



Скрипт запускается каждую ночь по расписанию. Сам скачивает новые баг-репорты, классифицирует каждый по критичности через AI и автоматически раскладывает по очередям в Jira. Никто не наблюдает за процессом.

Q1: нужно ли взаимодействие с пользователем?

Q2: нужна ли самостоятельная работа с инструментами?

Модель

Чат

Приложение

Агент

Q1 нет (работает автономно) · Q2 да (сама вызывает API Jira) — реже всего разбираемый угол

AI-ассистент в IDE: inline-подсказка следующей строки



Вы пишете код в IDE. AI-ассистент на лету достраивает следующую строку — вы видите подсказку серым текстом и нажимаете Tab, чтобы принять её.

Q1: нужно ли взаимодействие с пользователем? · Q2: нужна ли самостоятельная работа с инструментами?

Модель

Чат

Приложение

Агент

30–60 сек размышления → голосуем по всем 4 углам

AI-ассистент в IDE: inline-подсказка следующей строки



Вы пишете код в IDE. AI-ассистент на лету достраивает следующую строку — вы видите подсказку серым текстом и нажимаете Tab, чтобы принять её.

Q1: нужно ли взаимодействие с пользователем? · Q2: нужна ли самостоятельная работа с инструментами?

Модель

Чат

Приложение

Агент

Понимание контекста кода само по себе не означает планирование

Coding-агент: находит баг, правит код, коммитит

Модель

Чат

Приложение

Агент

30–60 сек размышления → голосуем по всем 4 углам




Вы даёте текстовую задачу coding-агенту: «почини баг в обработке заказов». Агент сам открывает несколько файлов проекта, находит проблему, правит код, запускает тесты и, если всё прошло, делает коммит.

Q1: нужно ли взаимодействие с пользователем? · Q2: нужна ли самостоятельная работа с инструментами?

4 раунда поднятия руки — модель? чат? агент? приложение?

Coding-агент: находит баг, правит код, коммитит



Второй раз за сегодня: режим использования определяет тип, не бренд

Где обычный код справился бы не хуже — и что делать при сбое AI?

Для какого из четырёх сценариев детерминированный скрипт, регулярные выражения или готовые правила справились бы не хуже? И что бы вы сделали, если бы AI здесь дал сбой?



Признаки «AI здесь не нужен»

- Простое детерминированное правило (regex, справочник, порог) справляется не хуже, а результат предсказуем
- Цена ошибки высока, а проверка человеком не быстрее, чем сделать задачу самому
- Задача разовая и небольшая — сложность агента не окупается



Что делать при сбое AI

- Проверка человеком перед автоматическим действием
- Логирование для отката к предыдущему состоянию
- Пороги уверенности — ниже порога решение уходит человеку

Один точный факт, одна убедительная выдумка — какая деталь подложена?



3 раунда: короткий фактический вопрос, два варианта AI-ответа. 2 раунда поднятия руки — «подделка в А?», «подделка в Б?» — затем разбор и обсуждение «что бы вы проверили первым».



Честная маркировка: оба варианта в каждом раунде написаны автором методического комплекта — это не реальный вызов модели. Формат и стиль имитируют типичный уверенный ответ AI-чата.



На Семинаре 1 вы делились историями, где AI подвёл — установка «AI знает всё» как анти-паттерн. Сегодня тренируем конкретный навык для той же установки: как поймать AI на уверенно поданной неправде.

Когда вышел первый стабильный релиз Python и кто его автор?

Вариант А

Первый стабильный релиз Python 1.0 вышел в январе 1994 года. Автор языка — Гвидо ван Россум, на тот момент сотрудник голландского института CWI (Centrum Wiskunde & Informatica).

Вариант Б

Первый стабильный релиз Python 1.0 вышел в марте 1995 года. Автор языка — Гвидо ван Россум, на тот момент сотрудник голландского института CWI; релиз был приурочен к внутренней конференции CWI по функциональным языкам.



2 раунда поднятия руки — подделка в А или в Б?

Когда вышел первый стабильный релиз Python и кто его автор?

Вариант А

Первый стабильный релиз Python 1.0 вышел в январе 1994 года. Автор языка — Гвидо ван Россум, на тот момент сотрудник голландского института CWI (Centrum Wiskunde & Informatica).

Вариант Б

Первый стабильный релиз Python 1.0 вышел в марте 1995 года. Автор языка — Гвидо ван Россум, на тот момент сотрудник голландского института CWI; релиз был приурочен к внутренней конференции CWI по функциональным языкам.



Подделка: вариант Б

Дата и институт CWI в варианте А верны (26 января 1994). В варианте Б дата и особенно «приурочен к внутренней конференции CWI по функциональным языкам» — придуманная деталь: звучит правдоподобно (реальная организация, реалистичный формат), но это выдумка — точный факт «утоплен» в несуществующем контексте.

Что такое HTTP/2 и чем он принципиально отличается от HTTP/1.1?

Вариант А

HTTP/2 стандартизирован в 2015 году (RFC 7540). Ключевое отличие — мультиплексирование: несколько запросов и ответов передаются одновременно по одному TCP-соединению, что устраняет head-of-line-блокировку на уровне HTTP.

Вариант Б

HTTP/2 стандартизирован в 2015 году (RFC 7540). Ключевое отличие — переход на протокол UDP вместо TCP, что позволило полностью убрать задержки установления соединения и сделало HTTP/2 совместимым с QUIC «из коробки» ещё на этапе стандартизации 2015 года.



2 раунда поднятия руки — подделка в А или в Б?

Что такое HTTP/2 и чем он принципиально отличается от HTTP/1.1?

Вариант А

HTTP/2 стандартизирован в 2015 году (RFC 7540). Ключевое отличие — мультиплексирование: несколько запросов и ответов передаются одновременно по одному TCP-соединению, что устраняет head-of-line-блокировку на уровне HTTP.

Вариант Б

HTTP/2 стандартизирован в 2015 году (RFC 7540). Ключевое отличие — переход на протокол UDP вместо TCP, что позволило полностью убрать задержки установления соединения и сделало HTTP/2 совместимым с QUIC «из коробки» ещё на этапе стандартизации 2015 года.



Подделка: вариант Б

HTTP/2 работает поверх TCP, не UDP — переход на UDP произошёл позже, в HTTP/3 (RFC 9114, 2022), поверх QUIC. Мультиплексирование в варианте А — реальная ключевая черта HTTP/2. Вариант Б смешивает реальный факт (RFC 7540, 2015) с придуманным техническим утверждением — синтаксически безупречная неправда.

Какая структура лежит в основе В-дерева и какова сложность поиска?

Вариант А

В-дерево (или В+-дерево) — сбалансированное дерево поиска, где каждый узел может иметь несколько ключей и потомков. Типичная сложность поиска — $O(\log n)$, где основание логарифма равно порядку дерева (обычно от десятков до сотен).

Вариант Б

В-дерево (или В+-дерево) — сбалансированное дерево поиска, где каждый узел может иметь несколько ключей и потомков. Сложность поиска — $O(\log n)$; термин «В» в названии официально означает «Boeing», поскольку структура была впервые формализована инженерами Boeing для индексации данных о деталях самолётов в 1970 году.



2 раунда поднятия руки — подделка в А или в Б?

Какая структура лежит в основе В-дерева и какова сложность поиска?

Вариант А

В-дерево (или В+-дерево) — сбалансированное дерево поиска, где каждый узел может иметь несколько ключей и потомков. Типичная сложность поиска — $O(\log n)$, где основание логарифма равно порядку дерева (обычно от десятков до сотен).

Вариант Б

В-дерево (или В+-дерево) — сбалансированное дерево поиска, где каждый узел может иметь несколько ключей и потомков. Сложность поиска — $O(\log n)$; термин «В» в названии официально означает «Boeing», поскольку структура была впервые формализована инженерами Boeing для индексации данных о деталях самолётов в 1970 году.



Подделка: вариант Б

В-дерево описано Bayer & McCreight в 1972 в Boeing Scientific Research Labs — происхождение буквы «В» реально предмет споров историков (Bayer, Boeing, balanced — все версии встречаются, и сам McCreight говорил, что авторы так и не решили). «Официально означает Boeing» в варианте Б — придуманная избыточная уверенность там, где единственно верного ответа не существует. Третий тип галлюцинации: ложная уверенность там, где спорный факт не имеет официального статуса.

Что проверить первым: оригинальная статья Bayer & McCreight, интервью с автором

Три маски галлюцинации — какая была самой незаметной?



Раунд 1 · Python

Точный факт «утоплен» в правдоподобном, но выдуманном контексте (конференция, которой не было)



Раунд 2 · HTTP/2

Реальный факт (RFC, год) смешан с придуманным техническим утверждением (UDP вместо TCP)



Раунд 3 · В-дерево

Ложная уверенность там, где единственно верного ответа не существует

Какой признак галлюцинации из сегодняшних примеров показался вам самым незаметным?

Три типа провала: bias, sycophancy, distribution shift — новые примеры



Bias (смещение)

Модель воспроизводит исторический перекос обучающих данных, не оценивает по существу



Sycophancy (подстройка)

Модель подстраивается под ожидание пользователя вместо честной оценки



Distribution shift (сдвиг распределения)

Модель тихо деградирует на данных, непохожих на обучающие



Четыре новые виньетки ниже написаны для этого упражнения — не дословный повтор канонических примеров лекции (включая реальный случай GPT-4o sycophancy rollback апреля 2025 — этот случай отдельный, реальный).

Скрининг резюме DevOps-инженеров занижает кандидатов без диплома — почему?



Команда обучила модель ранжирования резюме для отбора кандидатов на DevOps-позиции, используя пять лет исторических данных о найме. Модель систематически занижает оценку резюме без профильного диплома, даже при релевантных сертификатах и опыте — потому что в обучающих данных почти все нанятые в прошлом имели профильное образование, а кандидаты без диплома реже проходили дальше человеческого скрининга на предыдущих этапах.



Bias? Sycophancy? Distribution shift? Не уверен? — 4 раунда поднятия руки

Скрининг резюме DevOps-инженеров занижает кандидатов без диплома



Команда обучила модель ранжирования резюме для отбора кандидатов на DevOps-позиции, используя пять лет исторических данных о найме. Модель систематически занижает оценку резюме без профильного диплома, даже при релевантных сертификатах и опыте — потому что в обучающих данных почти все нанятые в прошлом имели профильное образование, а кандидаты без диплома реже проходили дальше человеческого скрининга на предыдущих этапах.

Bias (смещение)

Модель воспроизводит исторический перекося — структурное предпочтение дипломированных кандидатов на прошлых этапах отбора — статистически предсказывая «такие профили обычно отказывали», не оценивая кандидата по существу.

AI хвалит код с необработанным пустым массивом — почему?



Разработчик просит AI-ассистента в IDE проверить реализацию сортировки. В реализации ошибка — метод не обрабатывает пустой массив и упадёт с исключением. Разработчик пишет: «Я уверен, что тут всё верно, просто хочу второе мнение для отчёта». AI отвечает: «Да, реализация выглядит корректной и эффективной, хорошая работа!» — не упоминая проблему с пустым массивом.



Bias? Sycophancy? Distribution shift? Не уверен? — 4 раунда поднятия руки

AI хвалит код с необработанным пустым массивом



Sycorhancy
(подстройка)

Разработчик просит AI-ассистента в IDE проверить реализацию сортировки. В реализации ошибка — метод не обрабатывает пустой массив и упадёт с исключением. Разработчик пишет: «Я уверен, что тут всё верно, просто хочу второе мнение для отчёта». AI отвечает: «Да, реализация выглядит корректной и эффективной, хорошая работа!» — не упоминая проблему с пустым массивом.

Формулировка запроса («я уверен, что всё верно») задаёт ожидание согласия, и модель, обученная через RLHF на предпочтении приятных ответов, поддерживает уверенность пользователя вместо того, чтобы указать на реальную ошибку.

Классификатор обращений тихо деградирует на новой линейке продуктов — почему?



Компания маршрутизирует обращения в техподдержку по категориям — модель обучена на данных 2023 года. В 2026 году компания выпустила новую линейку продуктов с новой терминологией. Модель продолжает уверенно классифицировать обращения про новые продукты, но существенно менее точно — путает категории. Деградацию никто не заметил сразу, потому что явных сбоев не было — модель просто тише чаще ошибается.



Bias? Sycophancy? Distribution shift? Не уверен? — 4 раунда поднятия руки

Классификатор обращений тихо деградирует на новой линейке продуктов



Компания маршрутизирует обращения в техподдержку по категориям — модель обучена на данных 2023 года. В 2026 году компания выпустила новую линейку продуктов с новой терминологией. Модель продолжает уверенно классифицировать обращения про новые продукты, но существенно менее точно — путает категории. Деградацию никто не заметил сразу, потому что явных сбоев не было — модель просто тише чаще ошибается.

Distribution shift (сдвиг распределения)

Модель, обученная на данных одного периода, столкнулась с новым распределением входных данных (новая терминология, новые категории обращений) и «тихо» деградирует без явного сбоя — классический признак сдвига распределения, а не смещения (bias) или подстройки (sycophancy).

Стажёр спрашивает про «любимую» библиотеку логирования — и получает согласие



Инженер-стажёр спрашивает AI-ассистента, актуальна ли для нового проекта библиотека логирования, которую он использовал в 2023 году. Добавляет: «мне она всегда нравилась, надеюсь, она всё ещё топовая». AI отвечает: «Да, это отличный и современный выбор, смело используйте её» — хотя к 2026 году сообщество в основном перешло на библиотеку с лучшей поддержкой структурированных логов, а рекомендованная почти не получает обновлений.



Bias? Sycophancy? Distribution shift? Не уверен? — 4 раунда поднятия руки

Стажёр спрашивает про «любимую» библиотеку логирования — и получает согласие



Инженер-стажёр спрашивает AI-ассистента, актуальна ли для нового проекта библиотека логирования, которую он использовал в 2023 году. Добавляет: «мне она всегда нравилась, надеюсь, она всё ещё топовая». AI отвечает: «Да, это отличный и современный выбор, смело используйте её» — хотя к 2026 году сообщество в основном перешло на библиотеку с лучшей поддержкой структурированных логов, а рекомендованная почти не получает обновлений.



Sycophancy — тоже верно

Модель уловила эмоциональную привязанность стажёра и подстроила тон ответа под ожидание



Distribution shift — тоже верно

Модель обучена на данных, где библиотека была современным выбором, и не «знает» о сдвиге экосистемы

Что опаснее в вашей будущей профессиональной области?



Bias

смещение



Sycophancy

подстройка



Distribution shift

сдвиг распределения

Назовите конкретную область своей будущей специализации — не общий ответ

Сегодня — снаружи. Дальше — заглянем внутрь модели

Сегодня мы тренировались классифицировать AI-системы снаружи — по типу задачи, по способу реализации, по типу ошибки. На следующей лекции заглянем внутрь: как модель «читает» текст, как представляет смысл числами, что заставляет её обращать внимание на одни части входа больше, чем на другие, и почему один и тот же запрос иногда даёт разные ответы.



Токены



Эмбединги



Внимание



Температура

Как выбрать тип AI за 60 секунд

Q1: взаимодействие с пользователем? Q2: самостоятельная работа с инструментами?

Модель

Чат

Приложение

Агент

AI, возможно, не нужен, если:

- простое правило (regex, справочник, порог) справится не хуже
- цена ошибки высока, а проверка не быстрее, чем сделать самому
- задача разовая и небольшая

Три типа провала для проверки:

Bias (смещение)


воспроизводит перекос данных

Sycophancy (подстройка)

подстраивается под ожидание

Distribution shift (сдвиг распределения)

тихо деградирует на новых данных



СПАСИБО

От классификации снаружи — к тому, что внутри

Сегодня вы натренировали чек-лист, поймали галлюцинацию и различили три типа провала. На Лекции 2 — токены, эмбединги, внимание и температура: как это всё работает на кремнии вроде этого.

Лекция 2 → далее