



СЕМИНАР 2

Воронка решений: когда ИИ, каким и на чём

Четыре выбора, которые инженер проходит прежде, чем открыть редактор кода

Воронка из четырёх выборов

Правильный ответ зависит от вводных, которых в постановке почти никогда нет

Задача от заказчика

1

ИИ или обычный код?

2

Встроить в существующее приложение или
делать своё?

3

Разовый вызов модели, RAG или
агент?

4

Внешний API или
локальный инференс?



Ни один выбор не решается «по умолчанию» — он решается заново для каждой задачи

Главный навык — не помнить схему, а
вовремя задать вопрос, который изменит
ответ

*Сегодня — 7 постановок, почти в каждой ответ
поменяется хотя бы раз*

RAG одним потоком

Нужен, когда база знаний большая и меняется — и не помещается в один запрос

Лекция 3 →




Когда нужен: база большая и меняется

Агент циклом

Нужен, когда несколько шагов и действия во внешних системах

Лекция 3 →



Когда нужен: несколько шагов и действия во внешних системах

ИИ или обычный код?

Полный кейс · блиц-кейс · два случая из жизни

ИИ или обычный код?

Встроить или делать своё?

Разовый вызов, RAG или агент?

Внешний API или локальный
инференс?

воронка решений

Документы поставщиков

99

«Вот два примера входящих документов от двух наших поставщиков за последний месяц. Форматы почти идентичные. Напишите нам автоматическое извлечение данных из таких документов».

Документ поставщика А

Дата	№ накладной	Позиция	Сумма
24.03.2026	—	—	—
24.03.2026	—	—	—

Документ поставщика Б

Дата	№ накладной	Позиция	Сумма
24.03.2026	—	—	—
24.03.2026	—	—	—

Одинаковые колонки, одинаковый формат дат

Нужен ли здесь ИИ?

Полный корпус — три года, все поставщики



«Запросили полный корпус: три года, все поставщики».

Поставщик А

Дата	№ наклад.	Сумма

Поставщик Б

Date	Invoice#	Total

Поставщик В

Период	Заказ	Итого, Р

Поставщик Г

№	от	итого

Форматы разъехались — разные колонки, разные форматы дат

Кто передумал? Почему?



Гибрид: LLM-извлечение по вариативному входу + жёсткая валидация кодом на выходе

Урок: два примера — не выборка

Персоналка в логах



«Нужно вычистить персональные данные из логов приложения перед передачей их внешнему подрядчику на анализ производительности».

Одна технология на всё, или нет?



Regex

Телефоны, email — чёткий формат, дешево и надёжно



NER / LLM

Имена людей, косвенные упоминания в свободном тексте — нужен контекст

Ответ — гибрид, и граница проходит внутри одной задачи

Из жизни: провал и успех

Vendor-метрика точности $\neq$ метрика, измеренная независимо на своих данных

⊗ Epic Sepsis Model

Заявленный AUC 0.76–0.83 vs реальный 0.63 (Michigan Medicine, 38 455 госпитализаций)

Пропущено 67% реальных случаев сепсиса

Алерты — на 18% всех госпитализированных пациентов

✓ Ramp, merchant classification

Вручную: покрытие 3% заявок (2023) → 1,5% (2024)

После LLM-агента: обработка < 10 сек

~99% изменений корректны · ~25% заявок обоснованно отклоняются

Ramp — замена ручной обработки с мизерным покрытием, не замена работавшего regex-решения



Встроить или делать своё?

Полный кейс без единственного ответа · блиц-кейс · случаи из жизни

ИИ или обычный код?

Встроить или делать своё?

Разовый вызов, RAG или агент?

Внешний API или локальный инференс?

воронка решений

Помощник поддержки



«Сделайте нам ИИ-помощника для операторов техподдержки — подсказки ответов на тикеты, поиск похожих обращений в истории».



Операторы весь рабочий день живут в интерфейсе helpdesk-системы

Где должен жить этот помощник?

Закрытый вендор



«У вендора вашей helpdesk-системы нет открытого API и нет возможности кастомизации».



Решение сбоку

Расширение браузера или вторая панель

Цена: Два места одновременно, риск: оператор не будет пользоваться



Смена вендора

Helpdesk-система с открытым API

Цена: Миграция данных, переобучение команды, риск простоя



Пересмотр задачи

Асинхронный помощник, готовит черновики заранее

Цена: Оператор открывает готовое там, где удобно, но нужен отдельный процесс

Единственно верного ответа нет

Описания товаров



«Маркетинг просит отдельный ИИ-сервис для генерации описаний товаров».



Кнопка «сгенерировать описание»

в существующей админке каталога, которой маркетинг и так пользуется каждый день

Отдельный продукт — не отдельный продукт: второй логин и вкладка убивают использование

Из жизни: Kite vs GitHub Copilot

⊗ Kite (standalone)

~500 000 бесплатных пользователей на пике

Закрылся в ноябре 2022 года

«Разработчики не платят за инструменты»

✓ GitHub Copilot (встроен)

~20 млн пользователей к июлю 2025 (из 100+ млн на GitHub)

~4,7 млн платных подписчиков к январю 2026

~90% компаний Fortune 100

Встроенность в уже существующий рабочий поток победила отдельный продукт при технологии сравнимого класса

Humane AI Pin — привлечено ~\$241 млн, продан за \$116 млн · Rabbit R1 — ~100 000 устройств, активно пользуются ~5%



Разовый вызов, RAG или агент?

Кейс-лестница из трёх ступеней · блиц-кейс · случаи из жизни



Протоколы встреч



Транскрипт встречи → структурированный протокол

Какие решения приняты, какие поручения даны, какие сроки

У вас есть полный транскрипт одной встречи целиком

Один разовый вызов модели — RAG и агент были бы избыточным усложнением

Разовый вызов



RAG



Агент

База протоколов растёт



«Теперь хотим спрашивать: что мы решали по проекту X за последние полгода?»



растёт со временем →



Весь объём уже не помещается
в один запрос к модели

Кто передумал? Почему?

Теперь обоснован RAG

Разовый вызов



RAG



Агент

Поручения — сами в таск-трекер



«И пусть поручения из протокола сами автоматически раскладываются по задачам в таск-трекере».



создать задачу → назначить исполнителя → проверить срок

Архитектурный выбор двигают конкретные новые требования

Начинайте с простейшего варианта и усложняйте только тогда, когда простой закрыть требование не может

Разовый вызов



RAG



Агент

Еженедельный дайджест



«Нужен еженедельный дайджест по рабочим чатам и почте команды — что обсуждали, что решили».



Агент — нужен

Обход нескольких источников по расписанию

Многошаговая задача с обращением к внешним системам



RAG — не нужен

Источники обходятся напрямую по расписанию, не по произвольному запросу

Суммаризация — один вызов модели после сбора

RAG ≠ «у нас много источников»

Из жизни: фреймворк и класс задач для агента

⊗ Octomind: «Why we no longer use LangChain»

12+ месяцев LangChain в проде → отказ (17.06.2024)

Дебаг фреймворка дороже разработки фич

Негибкие абстракции → замена на прямые модульные вызовы LLM API

✓ Где агент необходим

Deep Research — поиск и синтез по многим источникам с уточнением запроса

Coding-агенты — правка кода → запуск тестов → итерация по результату


В обоих случаях одного вызова физически недостаточно

Прямые вызовы API иногда дают больше контроля, чем абстракция, которая должна была его упростить

4

Внешний API или локальный инференс?

Кейс-трёхходовка · случаи из жизни



воронка решений

Саммаризация звонков продаж



Записи звонков менеджеров по продажам →

карточка звонка: выявленная потребность клиента, возражения, договорённости

Какая архитектура? Где считать?

Ход 1: Облачный frontier?



Ход 2: Персональные данные



Ход 3: Шаблон полей → локальная модель

Персональные данные в звонках



«Мы прослушали несколько реальных звонков внимательно. Клиенты в разговоре иногда диктуют номера телефонов, адреса доставки, а в паре случаев — паспортные данные для оформления договора».



ФЗ № 420-ФЗ (с 30.05.2025)

Повторная утечка персональных данных — оборотный штраф 1-3% годовой выручки

(минимум 20 млн, максимум 500 млн ₽)

Обязанность уведомить Роскомнадзор в течение 24 часов

Кто передумал? Почему?

Ход 1: Облачный frontier?



Ход 2: Персональные данные



Ход 3: Шаблон полей → локальная модель

Задача сузилась до шаблона



«Давайте посмотрим на задачу трезво: на выходе нам нужна не свободная беседа, а структурированная выжимка по фиксированному шаблону из нескольких полей».



Небольшая локальная модель (7-8 млрд параметров) справляется — данные не покидают периметр компании

(а) «сложно для человека» $\neq$ «сложно для модели»

(б) чувствительность данных выясняется вопросами, а не предполагается

Ход 1: Облачный frontier?



Ход 2: Персональные данные



Ход 3: Шаблон полей → локальная модель

Из жизни: утечка и малые модели в проде

⊗ Samsung, 2023

Разрешили ChatGPT 11.03.2023

К 30.03 (~19 дней) — 3 утечки: 2× код производства, 1× транскрипт совещания

Полный запрет генеративного ИИ на устройствах (май 2023) + своя внутренняя система

✓ Малые модели в проде

JetBrains full-line completion — локальная модель ~100 МБ, в проде с апреля 2024

Apple on-device — ~3 млрд параметров (WWDC 2024)

Frontier (GPT/Claude/Gemini) — сотни миллиардов параметров, только облако

Frontier-модели — сотни миллиардов параметров, доступны только через облако. Малые модели уже работают локально в проде

Разберите вашу задачу

ИИ или обычный код?

Встроить или делать своё?

Разовый вызов, RAG или агент?

Внешний API или локальный
инференс?

1 Какой выбор воронки здесь стоит острее всего?

2 Каких вводных не хватает, чтобы сделать этот выбор обоснованно?

3 Что было на самом деле — изменило ли это выбор?

4 Какие риски у выбранного решения (лексика Лекции 1)?

Кто может поделиться реальной задачей со своей работы?

Памятка «Воронка решений + красные флаги»

Четыре вопроса воронки

1

Нужен ли здесь ИИ вообще, или задачу лучше решает обычный код?

2

Встраиваем в существующее приложение или делаем своё?

3

Если своё — разовый вызов модели, RAG или агент?

4

Внешний API или локальный инференс?

Красный флаг на каждый вопрос



Выбор по 2-3 показанным примерам без запроса на весь объём данных



Vendor-KPI без знаменателя — цифра эффекта без базы расчёта



Отдельный продукт там, где нужна кнопка в существующем интерфейсе



RAG или агент выбраны потому что модно, а не по новому требованию



Чувствительность данных не проверена до архитектурного выбора



«Сложно для человека» принято за «сложно для модели» без проверки

Домашнее чтение (необязательное)



ГЛАВНОЕ

Cara Klarna, 2023-2025

AI-ассистент поддержки: от впечатляющего старта до признания «мы зашли слишком далеко» и возврата к найму людей.



NYC MyCity chatbot, 2024

Городской чат-бот для малого бизнеса, дававший юридически некорректные советы. Расследование The Markup.



Бонус, для настроения

Автосалон подключил чат-бот на стороннем API без ограждений — и чат-бот «продал» внедорожник за один доллар.

Ссылки — в брифе семинара. Klarna — редкий случай, когда одна компания прошла все четыре выбора воронки на одном продукте

Klarna, 2023-2025: одна история — четыре развилки

1 ИИ или нет

Типовые тикеты — формализуемы, хороший кандидат; но оптимизация по стоимости уронила качество

2 Встроить или своё

Ассистент в существующем канале поддержки, внешний API (OpenAI) — не отдельный продукт

3 Паттерн

Чат-ассистент с эскалацией к человеку, не автономный агент

4 Инференс

Внешний облачный API с клиентскими данными поддержки

Запуск февраль 2024 · 30 дней: 2,3 млн чатов, 67% обращений автоматизировано · заявлено «700 агентов»/\$40M (2024) → «853 агента»/\$60M (Q3 2025) — знаменатель не раскрыт

«We went too far» — CEO Себастьян Семятковски, Bloomberg, май 2025

Дедупликация новостей



«Поток новостей из многих источников — нужно склеивать сообщения об одном и том же событии в одну карточку».



Fuzzy-matching / shingling — ~90%

Сравнение текстов по перекрывающимся фрагментам без обращения к модели

Дёшево и предсказуемо



LLM — только остаток

Два сообщения об одном событии написаны разными словами почти без общих фрагментов

Перифраз без лексического пересечения

Сначала дешёвый детерминированный фильтр — ИИ на то, что он не взял



Сегодня вы решали, что строить.

Лекция 2 — как модель устроена внутри