



## СЕМИНАР 2

# Когда ИИ, каким и на чём

*Семь реальных рабочих ситуаций — и в каждой решение, которое инженер принимает раньше, чем открывает редактор кода*

*NASA / Cory Huston · Wikimedia Commons · общественное достояние*

# Сегодня — семь кейсов

*В каждом — решение, которое инженер принимает раньше, чем открывает редактор кода*



Документы поставщиков



Персоналка в логах



Помощник поддержки



Описания товаров



Протоколы встреч



Дайджест по чатам



Звонки продаж

В каждом кейсе появится деталь, которой не было в первой постановке



# Документы поставщиков

ИИ или обычный код?

# Документы поставщиков



«Бухгалтерия тонет. Вот два примера — можно это автоматом разбирать?»



Pizarros · Wikimedia Commons · CC BY-SA 3.0

## Документ поставщика А

| Дата       | № накладной | Позиция | Сумма |
|------------|-------------|---------|-------|
| 24.03.2026 | —           | —       | —     |

## Документ поставщика Б

| Дата       | № накладной | Позиция | Сумма |
|------------|-------------|---------|-------|
| 24.03.2026 | —           | —       | —     |

Что предложите?

# Документы поставщиков

99

«Попросили архив — прислали за три года, сорок поставщиков»

## Поставщик А

| Дата | № наклад. | Сумма |
|------|-----------|-------|
|      |           |       |

## Поставщик Б

| Date | Invoice# | Total |
|------|----------|-------|
|      |          |       |

## Поставщик В

| Период | Заказ | Итого, ₽ |
|--------|-------|----------|
|        |       |          |

## Поставщик Г

| № | от | итого |
|---|----|-------|
|   |    |       |

Форматы разъехались — разные колонки, разные форматы дат, один документ на английском

Меняет ли это ваш ответ?

# Документы поставщиков — разбор



## Гибрид: LLM-извлечение по вариативному входу + жёсткая валидация кодом на выходе

Документ (любой формат) → LLM извлекает поля → код проверяет типы/обязательные значения/диапазоны → данные в 1С

**Два примера — не выборка. Просите представление полного объёма данных**

*Держите в голове риск из Лекции 1: модель на форматах, которые видела, тихо деградирует на новых — тот же механизм, что distribution shift*

# Персоналка в логах



«Нужно вычистить персональные данные из логов перед передачей подрядчику»



Одна строка лога — телефон, email и фраза «передайте это Ивану из бухгалтерии»

Подрядчику нужны структура запросов, тайминги, ошибки — не данные людей

Одна технология на всё, или нет?



# Персоналка в логах — разбор

## # Regex

Телефоны, email — чёткий формат, дёшево и надёжно  
вычищает обычный regex

## 🔍 NER / LLM

Имена людей, косвенные упоминания в свободном  
тексте — нужен контекст

**Граница между regex и моделью проходит внутри одной задачи, не между задачами**



# Из жизни: провал и успех

*Vendor-метрика точности  $\neq$  метрика, измеренная независимо на своих данных*

## ⊗ Epic Sepsis Model

Заявленный AUC 0.76–0.83 vs реальный 0.63 (Michigan Medicine, 38 455 госпитализаций)

**Пропущено 67% реальных случаев сепсиса**

Алерты — на 18% всех госпитализированных пациентов

## ✓ Ramp, merchant classification

Вручную: покрытие 3% заявок (2023) → 1,5% (2024)

**После LLM-агента: обработка < 10 сек**

~99% изменений корректны · ~25% заявок обоснованно отклоняются

**Ramp — замена ручной обработки с мизерным покрытием, не замена работавшего regex-решения**



# Помощник поддержки

Встроить или своё?

# Помощник поддержки



*«Сделайте нам ИИ-помощника для операторов — подсказки по тикетам, поиск похожих обращений»*



FiveOne51 · Wikimedia Commons · CC BY-SA 3.0

*Операторы весь рабочий день живут в одном и том же интерфейсе helpdesk-системы*

**Где должен жить этот помощник?**

# Помощник поддержки



«Открытого API нет, кастомизаций нет — вендор и на письма не отвечает»



## Что делаем?



### Коробочный helpdesk — закрытый вендор

Нет открытого API, нет возможности кастомизации, вендор не отвечает даже на письма об интеграции

# Помощник поддержки — разбор



## Решение сбоку

Расширение браузера или вторая панель

*Цена: Два места одновременно, риск: оператор не будет пользоваться*



## Смена вендора

Helpdesk-система с открытым API

*Цена: Миграция данных, переобучение команды, риск простоя*



## Пересмотр задачи

Асинхронный помощник, готовит черновики заранее

*Цена: Оператор открывает готовое там, где удобно, но нужен отдельный процесс*

***Единственно верного ответа нет***

# Описания товаров



«Маркетинг просит отдельный ИИ-сервис для генерации описаний товаров»



Новый отдельный инструмент: логин, вкладка, форма ввода характеристик товара → готовое описание

Отдельный сервис — хорошая идея?

## Описания товаров — разбор



### Кнопка «сгенерировать описание»

в существующей админке каталога, которой маркетинг и так пользуется каждый день

Отдельный продукт — второй логин и вкладка, цена, о которой не подумали



# Из жизни: Kite vs GitHub Copilot

## ⊗ Kite (standalone)

~500 000 бесплатных пользователей на пике

**Закрылся в ноябре 2022 года**

*«Разработчики не платят за инструменты»*

## ✓ GitHub Copilot (встроен)

~20 млн пользователей к июлю 2025 (из 100+ млн на GitHub)

**~4,7 млн платных подписчиков к январю 2026**

~90% компаний Fortune 100

**Встроенность в уже существующий рабочий поток победила отдельный продукт при технологии сравнимого класса**

*Humane AI Pin — привлечено ~\$241 млн, продан за \$116 млн · Rabbit R1 — ~100 000 устройств, активно пользуются ~5%*

# Два слова про RAG

Поиск по базе знаний подкладывает нужные фрагменты в контекст модели

Лекция 3 →




Когда нужен: база большая, меняется, весь объём не помещается в один запрос

# Два слова про агента

Модель работает циклом с внешними инструментами, а не одним вызовом

Лекция 3 →



Когда нужен: несколько шагов и действия во внешних системах



# Протоколы встреч

Разовый вызов, RAG или агент?

# Протоколы встреч

99

«После каждой встречи кто-то полчаса пишет протокол руками. Транскрипты есть — сделаем автоматом?»



*Amtec Photos · Wikimedia Commons · CC BY 2.0*

Транскрипт одной встречи целиком →  
структурированные решения, поручения и сроки

**Какая архитектура?**

ступени архитектуры

**Разовый вызов**



**RAG**



**Агент**

# Протоколы встреч



*«А можно искать — что мы решали по проекту X за полгода?»*



*Прошёл месяц — накопились десятки протоколов с разных встреч, по разным проектам*

**Меняет ли это архитектуру?**

# Протоколы встреч — разбор 1



«Растущий и меняющийся архив — вот когда нужен RAG»



растёт со временем →



Весь объём уже не помещается  
в один запрос к модели

Теперь обоснован RAG

ступени архитектуры

Разовый вызов



RAG



Агент

# Протоколы встреч

99

*«Поручения из протоколов мы всё равно руками переносим в таск-трекер...»*



*Система находит поручения в тексте протокола, но кто-то вручную открывает таск-трекер и заводит задачи одну за другой*

**Меняет ли это архитектуру ещё раз?**



# Протоколы встреч — разбор 2



*извлечь поручение → вызвать API task-трекера → создать задачу и проверить*



Действие во внешней системе — нужен workflow или агент. Начинайте с простейшего, усложняйте только когда требование не закрыть иначе

ступени архитектуры

Разовый вызов



RAG



Агент

# Дайджест по чатам и почте



«Нужен еженедельный дайджест по рабочим чатам и почте команды»



**Что обсуждали, что решили за неделю**

Коротко, одним сообщением по пятницам

**Какая архитектура здесь нужна?**

# Дайджест — разбор

## ✓ Агент — нужен

Обход нескольких источников по расписанию

Многошаговая задача с обращением к внешним системам

## ✗ RAG — не нужен

Источники обходятся напрямую по расписанию, не по произвольному запросу

Суммаризация — один вызов модели после сбора

***Много источников — не то же самое, что RAG***

# Из жизни: фреймворк и класс задач для агента

## ⊗ Octomind: «Why we no longer use LangChain»

12+ месяцев LangChain в проде → отказ (17.06.2024)

**Дебаг фреймворка дороже разработки фич**

Негибкие абстракции → замена на прямые модульные вызовы LLM API

## ✓ Где агент необходим

Deep Research — поиск и синтез по многим источникам с уточнением запроса

Coding-агенты — правка кода → запуск тестов → итерация по результату

**В обоих случаях одного вызова физически недостаточно**

**Прямые вызовы API иногда дают больше контроля, чем абстракция, которая должна была его упростить**



# Звонки продаж

Внешний API или локально?

# Звонки продаж



*«Хочу карточку по каждому звонку — потребность, возражения, договорённости»*



OddibeKerfeld · Wikimedia Commons · CC BY-SA 3.0

*Запись обычного свободного разговора менеджера с клиентом, без структуры*

**Какая архитектура, где считать?**

# Звонки продаж



*«Стоп. Клиенты диктуют телефоны, адреса, иногда паспортные данные»*



*Никто из инженеров не думал об этом заранее — все слушали только про потребности и возражения*

## Кто передумал?

# Звонки продаж — разбор 1

*Персональные данные меняют расчёт — и цена ошибки не абстрактная*



**420-ФЗ (принят 30.11.2024, вступил в силу 30.05.2025)**

**Повторная утечка персональных данных — оборотный штраф 1-3% годовой выручки**

(минимум 20 млн, максимум 500 млн ₽)

*Обязанность уведомить Роскомнадзор в течение 24 часов*

**Тот же организационный вопрос, что был в кейсе про логи — только ставки выше**



# Звонки продаж



*«GPU-сервера у нас нет, и бюджета на него в этом году нет»*



— СТО



*«Мне не беседа нужна — пять полей в CRM по каждому звонку»*



— руководитель отдела продаж

**Меняет ли это архитектуру ещё раз?**

# Звонки продаж — разбор 2



Небольшая локальная модель (7-8 млрд параметров) справляется — данные не покидают периметр компании

(а) «сложно для человека»  $\neq$  «сложно для модели»

(б) чувствительность данных выясняется вопросами, а не предполагается

*ходы разбора кейса*

Ход 1: Облачный frontier?

Ход 2: Персональные данные

Ход 3: Шаблон полей → локальная модель

# Из жизни: утечка и малые модели в проде

## ✗ Samsung, 2023

Разрешили ChatGPT 11.03.2023

**К 30.03 (~19 дней) — 3 утечки: 2× код производства, 1× транскрипт совещания**

Полный запрет генеративного ИИ на устройствах (май 2023) + своя внутренняя система

## ✓ Малые модели в проде

JetBrains full-line completion — локальная модель ~100 МБ, в проде с апреля 2024

**Apple on-device — ~3 млрд параметров (WWDC 2024)**

*Frontier (GPT/Claude/Gemini) — сотни миллиардов параметров, только облако*

**Frontier-модели — сотни миллиардов параметров, доступны только через облако. Малые модели уже работают локально в проде**

# Ваши задачи



У кого есть похожая задача с работы — там, где стоял вопрос, нужен ли ИИ, и какой?

*Достаточно сформулировать в двух-трёх предложениях, как её принёс бы заказчик*

# Что унести

Семь уроков, по одному на кейс — ничего нового, только компиляция



## Документы поставщиков

- Два примера — не выборка



## Персоналка в логах

- Граница regex/модель — внутри задачи



## Помощник поддержки

- Организационное ограничение решает не хуже техники



## Описания товаров

- Встроенность бьёт отдельный продукт



## Протоколы встреч

- Архитектуру двигают требования, не мода



## Дайджест

- Много источников ≠ RAG



## Звонки продаж

- Сложно для человека ≠ сложно для модели

# Домашнее чтение

*Необязательно, но по каждой истории будет что обсудить*



ГЛАВНОЕ

## Cara Klarna, 2023-2025

AI-ассистент поддержки: от впечатляющего старта до признания «мы зашли слишком далеко» и возврата к найму людей.



## NYC MyCity chatbot, 2024

Городской чат-бот для малого бизнеса, дававший юридически некорректные советы. Расследование The Markup.



## Бонус, для настроения

Автосалон подключил чат-бот на стороннем API без ограждений — и чат-бот «продал» внедорожник за один доллар.

*Если сегодня останется время — часть этого разберём вживую*

# Klarna, 2023-2025: одна история — четыре развилки

## 1 ИИ или нет

Типовые тикеты — формализуемы, хороший кандидат; но оптимизация по стоимости уронила качество

## 2 Встроить или своё

Ассистент в существующем канале поддержки, внешний API (OpenAI) — не отдельный продукт

## 3 Архитектура

Чат-ассистент с эскалацией к человеку, не автономный агент

## 4 Инференс

Внешний облачный API с клиентскими данными поддержки

Запуск февраль 2024 · 30 дней: 2,3 млн чатов, 67% обращений автоматизировано · заявлено «700 агентов»/\$40M (2024) → «853 агента»/\$60M (Q3 2025) — знаменатель не раскрыт

**«We went too far» — CEO Себастьян Семятковски, Bloomberg, май 2025**

# Дедупликация новостей



«Поток новостей из многих источников — нужно склеивать одинаковые в одну карточку»



**Десять почти одинаковых заголовков от разных изданий**

→ одна объединённая карточка события

**Какая технология нужна?**



# Дедупликация — разбор



Fuzzy-matching / shingling — ~90%

Сравнение текстов по перекрывающимся фрагментам без обращения к модели

**Дёшево и предсказуемо**



LLM — только остаток

Два сообщения об одном событии написаны разными словами почти без общих фрагментов

*Перифраз без лексического пересечения*

**Сначала дешёвый детерминированный фильтр — ИИ на то, что он не взял**



Сегодня вы решали, что строить.

**Лекция 2 — как модель устроена внутри**