



СЕМИНАР 2

Когда ИИ, каким и на чём

Семь реальных рабочих ситуаций — и в каждой решение, которое инженер принимает раньше, чем открывает редактор кода

Сегодня — четыре выбора, семь кейсов



ИИ или обычный код



Встроить или делать своё



Разовый вызов, RAG или агент



Внешний API или локальный инференс

Семь кейсов, на которых сегодня разбираем эти выборы



Документы поставщиков



Персоналка в логах



Помощник поддержки



Описания товаров



Протоколы встреч



Дайджест по чатам



Звонки продаж

В каждом кейсе появится деталь, которой не было в первой постановке

ИИ или обычный код?

Кейс: документы поставщиков

Инженеры часто решают это на глаз, по ощущению сложности задачи

Документы поставщиков



«Три человека, около 400 накладных в месяц, всё руками в 1С — можно автоматом?»



Документ поставщика А

Дата	№ накл.	Позиция	Сумма
24.03.2026	—	—	—
—	—	—	—

Документ поставщика Б

Дата	№ накл.	Позиция	Сумма
24.03.2026	—	—	—
—	—	—	—

Целевая таблица в 1С

Дата	№ накладной	Позиция	Сумма
24.03.2026	—	—	—
—	—	—	—

Что предложите?

Документы поставщиков

99

«Прислали ZIP на 4,2 ГБ — внутри и сканы актов сверки, и договоры, нужны только накладные»

Поставщик А

Дата	№ наклад.	Сумма

Поставщик Б

Date	Invoice#	Total

Поставщик В

Период	Заказ	Итого, Р

Поставщик Г

№	от	итого

Форматы разъехались — разные колонки, разные форматы дат, один документ на английском

Меняет ли это ваш ответ?

Документы поставщиков — разбор



Гибрид: LLM-извлечение по вариативному входу + жёсткая валидация кодом на выходе

Документ (любой формат) → LLM извлекает поля → код проверяет типы/обязательные значения/диапазоны → данные в 1С

Разумный ответ здесь — гибрид, а не выбор одного из двух подходов



изучайте данные, не верьте на слово

Два примера — не выборка. Просите представление полного объёма данных

Персоналка в логах

99

«40 ГБ логов за квартал — подрядчик ждёт архив в пятницу»



Одна строка лога — телефон, email и фраза «передайте это Ивану из бухгалтерии»

Подрядчику нужны структура запросов, тайминги, ошибки — не данные людей

Как максимально быстро и дешево очистить?

Персоналка в логах — разбор

Regex

Телефоны, email — чёткий формат, дёшево и надёжно
вычищает обычный regex

Детерминированная логика — модель не нужна

*Никакая модель здесь не нужна и только замедлила бы обработку 40
ГБ логов*



NER / малая модель

Имена людей, косвенные упоминания в свободном тексте
— нужен контекст

slovnet (Natasha) · ~30 МБ · CPU · ~25 строк/сек

~60× меньше BERT сравнимого класса, потеря качества 1-2 п.п.

Граница между regex и моделью проходит внутри одной задачи, не между задачами

Когда нужна была формула — и когда ИИ закрыл нерешаемое

⊗ CNET, январь 2023

Из 77 ИИ-сгенерированных статей о финансах исправления потребовались 41

**«10 000 \$ под 3% годовых → 10 300 \$ за год» вместо
корректных 300 \$ дохода**

*Расчёт должен делать детерминированная формула, а не LLM
«на глаз»*

✓ Ramp, merchant classification

Вручную: покрытие заявок 1,5-3% → после LLM-агента почти полное

Обработка < 10 сек, ~99% решений корректны

~25% заявок агент обоснованно отклоняет

Ramp — замена ручной обработки с мизерным покрытием, не замена работавшего regex-решения

2

Встроить или делать своё?

Кейс: помощник поддержки

Скрытая цена почти никогда не видна в демо на презентации идеи

Помощник поддержки



«Сделайте нам ИИ-помощника для операторов — подсказки по тикетам, поиск похожих обращений»



12 операторов на линии, около 300 тикетов в день, пик 10:00-13:00

Где должен жить этот помощник?

Помощник поддержки



«Открытого API нет, кастомизаций нет — вендор и на письма не отвечает»



Что делаем?



Коробочный helpdesk — систему купили 4 года назад

На ней же тикеты HR и фасилити, контракт с вендором ещё на 2 года — нет открытого API, нет кастомизаций, вендор не отвечает даже на письма

Компания написала вендору с вопросом об интеграции — ответа так и не получила

Помощник поддержки — разбор



Решение сбоку

Расширение браузера или вторая панель

Цена: Два места одновременно, риск: оператор не будет пользоваться



Смена вендора

Helpdesk-система с открытым API

Цена: Миграция данных, переобучение команды, риск простоя



Пересмотр задачи

Асинхронный помощник, готовит черновики заранее

Цена: Оператор открывает готовое там, где удобно, но нужен отдельный процесс

Единственно верного ответа нет

Описания товаров

99

«Маркетинг просит отдельный ИИ-сервис для генерации описаний товаров»



12 000 товарных позиций, сейчас описания пишет один копирайтер на аутсорсе

Новый отдельный инструмент: логин, вкладка, форма ввода характеристик товара

Отдельный сервис — хорошая идея?

Описания товаров — разбор




Кнопка «сгенерировать описание»

в существующей админке каталога, которой маркетинг и так пользуется каждый день

Отдельный продукт — второй логин и вкладка, цена, о которой не подумали

Kite и Copilot

Одна технология, разная встроенность — 17 месяцев прямой конкуренции



Kite — ~500 000 пользователей на пике

Copilot — ~20 млн пользователей · 4,7 млн платных · ~90% Fortune 100

Встроенность в уже существующий рабочий поток победила отдельный продукт при технологии сравнимого класса

Отдельное устройство против фиши в телефоне



Humane AI Pin

Носимый значок без экрана, лазерный проектор на ладонь, голосовое управление · \$699 + подписка \$24/мес

Продажи с апреля 2024

Привлечено ~\$241 млн → активы проданы HP за \$116 млн (февраль 2025) → серверы отключены 28.02.2025



Rabbit R1

Продано ~100 000 устройств, по оценкам активно пользуются около 5% купивших

Отдельное устройство конкурирует не только с технологией, но и с привычкой не переключаться, когда функция уже есть в телефоне



Разовый вызов, RAG или агент?

Кейс: протоколы встреч

Чем внушительнее задача, тем сложнее архитектура — интуицию стоит проверять

Два слова про RAG

Поиск по базе знаний подкладывает нужные фрагменты в контекст модели

Лекция 3 →




Когда нужен: база большая, меняется, весь объём не помещается в один запрос

Два слова про агента

Модель работает циклом с внешними инструментами, а не одним вызовом

Лекция 3 →



Когда нужен: несколько шагов и действия во внешних системах

Протоколы встреч



«После каждого созвона транскрипт приходит письмом, нужен протокол: решения, поручения, сроки»



Около 15 встреч в неделю, протокол сейчас пишет проджект вручную

Какая архитектура нужна?

Протоколы встреч — разбор



«Один вызов, ни хранилища, ни цикла»



Письмо с транскриптом



Вызов модели с шаблоном



Протокол

Весь транскрипт помещается в один запрос — усложнять сейчас означало бы решать проблему, которой не существует

Протоколы встреч

»»

«На планёрке спросили: что мы решали по подрядчику X в мае?»




Прошёл месяц — накопились десятки протоколов с разных встреч, по разным проектам

Меняет ли это архитектуру?

Протоколы встреч — разбор 1



«Растущий и меняющийся архив — вот когда нужен RAG»



Прежний путь никуда не делся — просто дополнен хранилищем, индексацией и поиском перед тем же вызовом модели

Протоколы встреч

»»

«Поручения из протоколов мы всё равно руками переносим в task-трекер...»




Половина поручений из майских протоколов до сих пор без исполнителя — руки до переноса просто не доходят

Меняет ли это архитектуру ещё раз?

Протоколы встреч — разбор 2



«Действие во внешней системе — нужен агент поверх RAG»



Начинайте с простейшего варианта, усложняйте только когда требование не закрыть иначе

Дайджест по чатам и почте



«Нужен еженедельный дайджест по рабочим чатам и почте команды»



Что обсуждали, что решили за неделю

Дайджест нужен по пятницам, к 17:00

Какая архитектура здесь нужна?

Дайджест — разбор

✓ Агент — нужен

Обход нескольких источников по расписанию

Многошаговая задача с обращением к внешним системам

✗ RAG — не нужен

Источники обходятся напрямую по расписанию, не по произвольному запросу

Суммаризация — один вызов модели после сбора

Много источников — не то же самое, что RAG

RAG и агент в проде



AI @ Morgan Stanley Assistant

Партнёрство с OpenAI (март 2023), запуск в сентябре 2023

RAG по базе ~100 000 research-документов

К середине 2024 — используют более 98% команд финансовых советников

Доступность нужного документа: 20% → 80%



Replit, июль 2025

Агент удалил продакшен-базу (~1200 руководителей компаний затронуты) во время code freeze, вопреки прямой инструкции

Затем неверно утверждал, что откат невозможен — данные восстановили

После инцидента: разделение dev/prod + режим агента «только планирование»

Ещё: Octomind — сняли LangChain после года в проде, вернулись к прямым вызовам (17.06.2024)



Внешний API или локальный инференс?

Кейс: звонки продаж

Это про то, где физически обрабатываются данные, а не какая модель лучше

Звонки продаж



«Хочу карточку по каждому звонку — потребность, возражения, договорённости»



8 менеджеров, по 15-20 звонков в день, записи лежат в телефонии

Как это построить?

Звонки продаж



«Стоп. Вы эти записи в какой сервис отправляете?»



РФ

152-ФЗ + 420-ФЗ (с 30.05.2025)

Первая утечка: штраф 3-5 млн ₽

Повторная: 1-3% годовой выручки (мин. 20 млн, макс. 500 млн ₽)



ЕС

GDPR

До €20 млн или 4% мирового оборота (что больше)

Рекорд: Meta, €1,2 млрд, 2023



США

Единого федерального закона нет

Штатные (Калифорния — CCPA/CPRA)

Секторальные (например, HIPAA)

За сохранность персональных данных всерьёз борются все крупные юрисдикции

Звонки продаж



«GPU-сервера у нас нет, и бюджета на него в этом году нет»



— СТО



«Мне не беседа нужна — пять полей в CRM по каждому звонку»



— руководитель отдела продаж

Меняет ли это архитектуру ещё раз?

Звонки продаж — разбор



Задача сузилась до шаблона — локальная модель 7-8 млрд параметров справляется, данные не покидают периметр компании

Открытые модели 7-8B:

Qwen3 · Llama · Gemma · Mistral · T-lite · T-pro (Т-Банк, Apache 2.0, на базе Qwen)

4-bit квантование → 4-6 ГБ памяти, обычный сервер без GPU (Ollama / llama.cpp) · тонкая подстройка — LoRA на одной GPU

«Сложно для человека» ≠ «сложно для модели»

Чувствительность данных выясняется вопросами, а не предполагается

Утечка в Samsung — и модели, которые уже в кармане

⊗ Samsung, 2023

Разрешили ChatGPT 11.03.2023

К 30.03 (~19 дней) — 3 утечки: 2× код производства, 1× транскрипт совещания

Полный запрет генеративного ИИ на устройствах (май 2023)

✓ Малые модели в кармане

Apple Intelligence — ~3 млрд параметров на устройстве (iOS 18.1, октябрь 2024, iPhone 15 Pro+): суммаризация и правка текста офлайн

Google Gemini Nano — 1,8-3,25 млрд параметров (Pixel/Android): суммаризация в Recorder, Magic Compose — офлайн

Малые модели уже в кармане у половины аудитории

Ваши задачи



У кого есть похожая задача с работы — там, где стоял вопрос, нужен ли ИИ, и какой?

Достаточно сформулировать в двух-трёх предложениях, как её принёс бы заказчик

Что унести

Семь уроков, по одному на кейс — ничего нового, только компиляция



Документы поставщиков

- Два примера — не выборка



Персоналка в логах

- Граница regex/модель — внутри задачи



Помощник поддержки

- Организационное ограничение решает не хуже техники



Описания товаров

- Встроенность бьёт отдельный продукт



Протоколы встреч

- Архитектуру двигают требования, не мода



Дайджест

- Много источников ≠ RAG



Звонки продаж

- Сложно для человека ≠ сложно для модели

Домашнее чтение

Необязательно, но по каждой истории будет что обсудить



ГЛАВНОЕ

Cara Klarna, 2023-2025

AI-ассистент поддержки: от впечатляющего старта до признания «мы зашли слишком далеко» и возврата к найму людей.



NYC MyCity chatbot, 2024

Городской чат-бот для малого бизнеса, дававший юридически некорректные советы. Расследование The Markup.



Бонус, для настроения

Автосалон подключил чат-бот на стороннем API без ограждений — и чат-бот «продал» внедорожник за один доллар.

Если сегодня останется время — часть этого разберём вживую

Klarna, 2023-2025: одна история — четыре развилки

1 ИИ или нет

Типовые тикеты — формализуемы, хороший кандидат; но оптимизация по стоимости уронила качество

2 Встроить или своё

Ассистент в существующем канале поддержки, внешний API (OpenAI) — не отдельный продукт

3 Архитектура

Чат-ассистент с эскалацией к человеку, не автономный агент

4 Инференс

Внешний облачный API с клиентскими данными поддержки

Запуск февраль 2024 · 30 дней: 2,3 млн чатов, 67% обращений автоматизировано · заявлено «эквивалент 700 агентов»/\$40M (2024) → «853 агента»/\$60M (Q3 2025) — знаменатель не раскрыт

«We went too far» — CEO Себастьян Семятковски, Bloomberg, май 2025

Дедупликация новостей



«Поток новостей из многих источников — нужно склеивать одинаковые в одну карточку»



Десять почти одинаковых заголовков от разных изданий

→ одна объединённая карточка события

Какая технология нужна?

Дедупликация — разбор



Fuzzy-matching / shingling — ~90%

Сравнение текстов по перекрывающимся фрагментам без обращения к модели

Дёшево и предсказуемо



LLM — только остаток

Два сообщения об одном событии написаны разными словами почти без общих фрагментов

Перифраз без лексического пересечения

Сначала дешёвый детерминированный фильтр — ИИ на то, что он не взял



Сегодня вы решали, что строить.

Лекция 2 — как модель устроена внутри