



СЕМИНАР 2

Когда ИИ, каким и на чём

Семь реальных рабочих ситуаций — и в каждой решение, которое инженер принимает раньше, чем открывает редактор кода

Сегодня — четыре выбора, семь кейсов



ИИ или обычный код



Встроить или делать своё



Разовый вызов, RAG или агент



Внешний API или локальный инференс

Семь кейсов, на которых сегодня разбираем эти выборы



Документы поставщиков



Персоналка в логах



Помощник поддержки



Описания товаров



Протоколы встреч



Дайджест по чатам



Звонки продаж

В каждом кейсе появится деталь, которой не было в первой постановке

ИИ или обычный код?

Кейс: документы поставщиков

Инженеры часто решают это на глаз, по ощущению сложности задачи

Документы поставщиков

Марина, и.о. продавца по фин.процессам

99

«Марина, продакт по фин.процессам. Бухгалтерия тонет: три человека руками забивают накладные поставщиков в 1С, около 400 штук в месяц, к концу квартала завал и ошибки в суммах. Приложила два примера накладных за прошлую неделю — форматы вроде одинаковые. Можно это как-то автоматом сделать? Кстати, маркетинг уже полгода гоняет YandexGPT по API для описаний товаров, договор с ними есть — может, тот же контур подойдёт и нам. Отдельно у нас идёт миграция почты на новый сервер, но это не к вам. По срокам — прикидка хотя бы до пятницы была бы супер».

Документ поставщика А

Дата	№ наклад.	Позиция	Сумма
24.03.2026	—	—	—
—	—	—	—

Документ поставщика Б

Дата	№ наклад.	Позиция	Сумма
24.03.2026	—	—	—
—	—	—	—

Целевая таблица в 1С

Дата	№ накладной	Позиция	Сумма
24.03.2026	—	—	—
—	—	—	—

Что предложите?

Документы поставщиков



«Коллеги, выгрузила архив, как просили, ZIP на 4,2 ГБ. Внутри вперемешку: сканы актов сверки, договоры и сами накладные — не сортировала, как было в папке за год, так и заархивировала. Два наших крупнейших поставщика вообще подключены через ЭДО и присылают накладные уже структурированными XML-файлами, без разбора обойдётся. Остальное — сканы со старых сканеров на складе, они дают 200dpi и уже сжаты. Кстати, бухгалтерия параллельно переходит на ЭДО с ФНС по счетам-фактурам, но это отдельный проект, не про накладные поставщиков».

Поставщик А

Дата	№ накл.	Сумма

Поставщик Б

Date	Invoice#	Total

Поставщик В

Период	Заказ	Итого, Р

Поставщик Г

№	от	итого

Меняет ли это ваш ответ?

Документы поставщиков — разбор



Гибрид: LLM-извлечение по вариативному входу + жёсткая валидация кодом на выходе

Документ (любой формат) → LLM извлекает поля → код проверяет типы/обязательные значения/диапазоны → данные в 1С

Разумный ответ здесь — гибрид, а не выбор одного из двух подходов



изучайте данные, не верьте на слово

Два примера — не выборка. Просите представление полного объёма данных

Персоналка в логах



«Подрядчик по перфомансу просит логи прода за квартал — без них не смогут найти просадки на пиках. Выгрузил около 40 ГБ, архив уже на сервере. Внутри вперемешку телефоны, почты клиентов, один раз фраза „передайте это Ивану из бухгалтерии“ — залогировалось из тела запроса. Логи уже в стандартном JSON построчно, структуру парсить легко. Подрядчику нужны тайминги и коды ошибок, не данные людей. Отдельно тестируем новое VPN-решение для удалёнки, но это не к логам. Ждут архив в пятницу».



Подрядчику нужны структура запросов, тайминги, ошибки — не данные людей

Как максимально быстро и дёшево очистить?

Персоналка в логах — разбор

Regex

Телефоны, email — чёткий формат, дёшево и надёжно
вычищает обычный regex

Детерминированная логика — модель не нужна

*Никакая модель здесь не нужна и только замедлила бы обработку 40
ГБ логов*



NER / малая модель

Имена людей, косвенные упоминания в свободном тексте
— нужен контекст

slovnet (Natasha) · ~30 МБ · CPU · ~25 строк/сек

~60× меньше BERT сравнимого класса, потеря качества 1-2 п.п.

Граница между regex и моделью проходит внутри одной задачи, не между задачами

Когда нужна была формула — и когда ИИ закрыл нерешаемое

⊗ CNET, январь 2023

Из 77 ИИ-сгенерированных статей о финансах исправления потребовались 41

**«10 000 \$ под 3% годовых → 10 300 \$ за год» вместо
корректных 300 \$ дохода**

*Расчёт должен делать детерминированная формула, а не LLM
«на глаз»*

✓ Ramp, merchant classification

Вручную: покрытие заявок 1,5-3% → после LLM-агента почти полное

Обработка < 10 сек, ~99% решений корректны

~25% заявок агент обоснованно отклоняет

Ramp — замена ручной обработки с мизерным покрытием, не замена работавшего regex-решения

2

Встроить или делать своё?

Кейс: помощник поддержки

Скрытая цена почти никогда не видна в демо на презентации идеи

Помощник поддержки



«Идея простая: ИИ-помощник для операторов — подсказки ответов на тикеты, поиск похожих обращений в истории. На линии 12 операторов, поток около 300 тикетов в день, пик с 10:00 до 13:00. Часть тех же операторов параллельно отвечает клиентам в Telegram — там отдельный чат-канал, человек 4 держат его постоянно открытым. Вход у всех через корпоративный SSO, так что с авторизацией проблем быть не должно. Отдельно у нас сейчас обновляют парк ноутбуков в поддержке, но это не к вам. Было бы здорово успеть показать на квартальном ревью».



12 операторов на линии, около 300 тикетов в день, пик 10:00-13:00

Где должен жить этот помощник?

Помощник поддержки

ИТ-директор



«У нас коробочный helpdesk, открытого API нет, кастомизаций нет — писали вендору ещё в марте, ответа так и не получили. Систему купили 4 года назад, на ней же тикеты от HR и фасилити-менеджмента. Контракт ещё на 2 года. Telegram-канал поддержки — отдельная история, там своя простая интеграция через бота, если вдруг понадобится. В следующем квартале редизайним корпоративный портал, но это отдельный процесс и не про helpdesk».



Коробочный helpdesk 4 года без открытого API — контракт с вендором ещё на 2 года

Что делаем?

Помощник поддержки — разбор



Решение сбоку

Расширение браузера или вторая панель

Цена: Два места одновременно, риск: оператор не будет пользоваться



Смена вендора

Helpdesk-система с открытым API

Цена: Миграция данных, переобучение команды, риск простоя



Пересмотр задачи

Асинхронный помощник, готовит черновики заранее

Цена: Оператор открывает готовое там, где удобно, но нужен отдельный процесс

Единственно верного ответа нет

Описания товаров



«Руководитель был на конференции ритейла, увидел у конкурента сервис для генерации описаний товаров — отдельное приложение, вбил характеристики, получил текст под карточку. Хочет похожее к концу месяца. Каталог большой — около 12 000 товарных позиций, все заводятся через общую админку каталога, копирайтер на аутсорсе пишет описания прямо там же. Отдельно нужно бы обновить баннеры на главной, но это к другому разговору. Заодно в другом отделе параллельно внедряют новую CRM — не про нас».



12 000 товарных позиций, сейчас описания пишет один копирайтер на аутсорсе

Отдельный сервис — хорошая идея?

Описания товаров — разбор




Кнопка «сгенерировать описание»

в существующей админке каталога, которой маркетинг и так пользуется каждый день

Отдельный продукт — второй логин и вкладка, цена, о которой не подумали

Kite и Copilot

Одна технология, разная встроенность — 17 месяцев прямой конкуренции



Kite — ~500 000 пользователей на пике

Copilot — ~20 млн пользователей · 4,7 млн платных · ~90% Fortune 100

Встроенность в уже существующий рабочий поток победила отдельный продукт при технологии сравнимого класса

Отдельное устройство против фиши в телефоне



Humane AI Pin

Носимый значок без экрана, лазерный проектор на ладонь, голосовое управление · \$699 + подписка \$24/мес

Продажи с апреля 2024

Привлечено ~\$241 млн → активы проданы HP за \$116 млн (февраль 2025) → серверы отключены 28.02.2025



Rabbit R1

Продано ~100 000 устройств, по оценкам активно пользуются около 5% купивших

Отдельное устройство конкурирует не только с технологией, но и с привычкой не переключаться, когда функция уже есть в телефоне



Разовый вызов, RAG или агент?

Кейс: протоколы встреч

Чем внушительнее задача, тем сложнее архитектура — интуицию стоит проверять

Два слова про RAG

Поиск по базе знаний подкладывает нужные фрагменты в контекст модели

Лекция 3 →




Когда нужен: база большая, меняется, весь объём не помещается в один запрос

Два слова про агента

Модель работает циклом с внешними инструментами, а не одним вызовом

Лекция 3 →



Когда нужен: несколько шагов и действия во внешних системах

Протоколы встреч



«После каждого созвона Zoom кладёт транскрипт в письмо, руки не доходят. Протокол по-прежнему пишет проджект руками, минут по 30-40. Встреч штук 15 в неделю, часть на английском с подрядчиком — Zoom их тоже транскрибирует, просто на другом языке. Готовые протоколы уже складываем на общий корпоративный диск, папка по проектам. Задачи из встреч ведём в YouTrack, у него открытый REST API, если понадобится. Можно из транскрипта автоматом делать протокол — решения, поручения, сроки? В идеале до конца квартала».



Около 15 встреч в неделю, протокол сейчас пишет проджект вручную

Какая архитектура нужна?

Протоколы встреч — разбор



«Один вызов, ни хранилища, ни цикла»



Письмо с транскриптом



Вызов модели с шаблоном



Протокол

Весь транскрипт помещается в один запрос — усложнять сейчас означало бы решать проблему, которой не существует

транскрипт уже приходит готовым письмом — отдельный шаг сборки входных данных не нужен

Протоколы встреч



«Было на планёрке сегодня, неловко пересказывать. Обсуждали бюджет на квартал, и кто-то из финансов спрашивает: „А что мы вообще решали по подрядчику X ещё в мае, там были договорённости про скидку?“ Повисла пауза. Протоколы копятся в общей папке на диске, названы более-менее по датам, искать по ним руками — то ещё удовольствие, особенно если помнишь только тему, а не дату. Сама папка растёт где-то на полгигабайта в квартал. Кстати, там же обсуждали отпускной график на лето, и отдельно — редизайн корпоративного портала, но это другая история».




Прошёл месяц — накопились десятки протоколов с разных встреч, по разным проектам

Меняет ли это архитектуру?

Протоколы встреч — разбор 1



«Растущий и меняющийся архив — вот когда нужен RAG»



Прежний путь никуда не делся — просто дополнен хранилищем, индексацией и поиском перед тем же вызовом модели

Протоколы встреч



«Спасибо за поиск по протоколам, реально экономит время перед ретро. Но вот что заметила: поручения из протоколов мы всё равно руками переносим в YouTrack — открываем протокол, читаем, что нашла система, заводим карточки, проставляем исполнителя и срок. У YouTrack, я узнавала, открытый REST API, задачу можно создать одним вызовом. Прошлась по майским протоколам вчера вечером — примерно половина поручений так и висит без исполнителя, руки не дошли перенести. Отдельно хотела спросить про цвет тегов в трекере, но это, наверное, к админу инструмента».




Половина поручений из майских протоколов до сих пор без исполнителя — руки до переноса просто не доходят

Меняет ли это архитектуру ещё раз?

Протоколы встреч — разбор 2



«Действие во внешней системе — нужен агент поверх RAG»



Начинайте с простейшего варианта, усложняйте только когда требование не закрыть иначе

у task-трекера открытый API — интеграция дешёвая, а не гипотетическая

Дайджест по чатам и почте



«Обсуждали на планёрке — хотим еженедельный дайджест по рабочим чатам и почте команды: что обсуждали, что решили за неделю, одним сообщением. Нужен по пятницам к 17:00. Источников несколько: рабочий чат команды и почта, у обоих есть API для выгрузки истории сообщений. Надо свести в одно связное сообщение, а не склеить куски подряд. Кстати, отдельно обсуждали, стоит ли переезжать на другой мессенджер, и параллельно тестируем новое VPN-решение для удалёнщиков — но это не к дайджесту».



Из чата и почты — одно связное сообщение, по пятницам к 17:00

Какая архитектура здесь нужна?

Дайджест — разбор

✓ Агент — нужен

Обход нескольких источников по расписанию

Многошаговая задача с обращением к внешним системам

✗ RAG — не нужен

Источники обходятся напрямую по расписанию, не по произвольному запросу

Суммаризация — один вызов модели после сбора

Много источников — не то же самое, что RAG

RAG и агент в проде



AI @ Morgan Stanley Assistant

Партнёрство с OpenAI (март 2023), запуск в сентябре 2023

RAG по базе ~100 000 research-документов

К середине 2024 — используют более 98% команд финансовых советников

Доступность нужного документа: 20% → 80%



Replit, июль 2025

Агент удалил продакшен-базу (~1200 руководителей компаний затронуты) во время code freeze, вопреки прямой инструкции

Затем неверно утверждал, что откат невозможен — данные восстановили

После инцидента: разделение dev/prod + режим агента «только планирование»

Ещё: Octomind — сняли LangChain после года в проде, вернулись к прямым вызовам (17.06.2024)



Внешний API или локальный инференс?

Кейс: звонки продаж

Это про то, где физически обрабатываются данные, а не какая модель лучше

Звонки продаж



«Хочу по каждому звонку менеджера получать карточку: потребность, возражения, договорённости. Менеджеры перематывают запись, ищут, на чём остановились в прошлый раз. В отделе 8 менеджеров, по 15-20 звонков в день, телефония пишет разговор в трз и сама кладёт файл в облако — выгружать вручную не нужно. CRM у нас Битрикс24, открытый REST API. Аналитики отдела уже используют облачный ИИ по API для черновиков квартальных отчётов. CRM, кстати, тоже пора почистить от дублей контактов, но это отдельная головная боль».



8 менеджеров, по 15-20 звонков в день, записи лежат в телефонии

Как это построить?

Звонки продаж



«Стоп. Вы эти записи в какой сервис отправляете?»



РФ

152-ФЗ + 420-ФЗ (с 30.05.2025)

Первая утечка: штраф 3-5 млн ₽

Повторная: 1-3% годовой выручки (мин. 20 млн, макс. 500 млн ₽)



ЕС

GDPR

До €20 млн или 4% мирового оборота (что больше)

Рекорд: Meta, €1,2 млрд, 2023



США

Единого федерального закона нет

Штатные (Калифорния — CCPA/CPRA)

Секторальные (например, HIPAA)

За сохранность персональных данных всерьёз борются все крупные юрисдикции

Звонки продаж



«Разговор случился на созвоне по бюджету. Обозначу ограничение по инфраструктуре: GPU-сервера у нас нет, и бюджета на него в этом году тоже нет — приоритеты на квартал утверждены, туда попали миграция на новую почтовую систему и обновление парка ноутбуков в поддержке. Если модель тяжёлая, придётся идти через облачный API, но там свои вопросы по данным, мы их уже обсуждали. В следующем году, может, вернёмся к разговору про свой сервер».

— СТО



«Мне для работы нужно простое: пять полей в CRM по каждому звонку — потребность, возражения, договорённости, следующий шаг, оценка вероятности сделки. Не пересказ разговора целиком, не анализ тона голоса. Просто эти пять полей должны заполняться сами прямо в Битрикс24, чтобы я видел их у себя в отчёте по отделу, который и так каждый понедельник собираю руками из заметок ребят».

— руководитель отдела продаж

Меняет ли это архитектуру ещё раз?

Звонки продаж — разбор



Задача сузилась до шаблона — локальная модель 7-8 млрд параметров справляется, данные не покидают периметр компании

Открытые модели 7-8B:

Qwen3 · Llama · Gemma · Mistral · T-lite · T-pro (Т-Банк, Apache 2.0, на базе Qwen)

4-bit квантование → 4-6 ГБ памяти, обычный сервер без GPU (Ollama / llama.cpp) · тонкая подстройка — LoRA на одной GPU

«Сложно для человека» ≠ «сложно для модели»

Чувствительность данных выясняется вопросами, а не предполагается

Утечка в Samsung — и модели, которые уже в кармане

✗ Samsung, 2023

Разрешили ChatGPT 11.03.2023

К 30.03 (~19 дней) — 3 утечки: 2× код производства, 1× транскрипт совещания

Полный запрет генеративного ИИ на устройствах (май 2023)

✓ Малые модели в кармане

Apple Intelligence — ~3 млрд параметров на устройстве (iOS 18.1, октябрь 2024, iPhone 15 Pro+): суммаризация и правка текста офлайн

Google Gemini Nano — 1,8-3,25 млрд параметров (Pixel/Android): суммаризация в Recorder, Magic Compose — офлайн

Малые модели уже в кармане у половины аудитории

Ваши задачи



У кого есть похожая задача с работы — там, где стоял вопрос, нужен ли ИИ, и какой?

Достаточно сформулировать в двух-трёх предложениях, как её принёс бы заказчик

Что унести

Семь уроков, по одному на кейс — ничего нового, только компиляция



Документы поставщиков

- Два примера — не выборка



Персоналка в логах

- Граница regex/модель — внутри задачи



Помощник поддержки

- Организационное ограничение решает не хуже техники



Описания товаров

- Встроенность бьёт отдельный продукт



Протоколы встреч

- Архитектуру двигают требования, не мода



Дайджест

- Много источников ≠ RAG



Звонки продаж

- Сложно для человека ≠ сложно для модели

Домашнее чтение

Необязательно, но по каждой истории будет что обсудить



ГЛАВНОЕ

Cara Klarna, 2023-2025

AI-ассистент поддержки: от впечатляющего старта до признания «мы зашли слишком далеко» и возврата к найму людей.



NYC MyCity chatbot, 2024

Городской чат-бот для малого бизнеса, дававший юридически некорректные советы. Расследование The Markup.



Бонус, для настроения

Автосалон подключил чат-бот на стороннем API без ограждений — и чат-бот «продал» внедорожник за один доллар.

Если сегодня останется время — часть этого разберём вживую

Klarna, 2023-2025: одна история — четыре развилки

1 ИИ или нет

Типовые тикеты — формализуемы, хороший кандидат; но оптимизация по стоимости уронила качество

2 Встроить или своё

Ассистент в существующем канале поддержки, внешний API (OpenAI) — не отдельный продукт

3 Архитектура

Чат-ассистент с эскалацией к человеку, не автономный агент

4 Инференс

Внешний облачный API с клиентскими данными поддержки

Запуск февраль 2024 · 30 дней: 2,3 млн чатов, 67% обращений автоматизировано · заявлено «эквивалент 700 агентов»/\$40M (2024) → «853 агента»/\$60M (Q3 2025) — знаменатель не раскрыт

«We went too far» — CEO Себастьян Семятковски, Bloomberg, май 2025

Дедупликация новостей



«Пользователи жалуются в поддержку, что лента забита — по одному событию видят десять почти одинаковых заголовков подряд от разных изданий. Хотим склеивать в одну карточку. Источников уже больше сотни, все приходят через единый RSS-агрегатор, формат заголовка и времени публикации у всех одинаковый. Подключаем ещё несколько в этом месяце. Отдельно редактор попросил обновить дизайн карточки источника на сайте, но это не к дедупликации. Бюджет на новые фишки в этом квартале скромный».



Десять почти одинаковых заголовков → одна объединённая карточка события

Какая технология нужна?

Дедупликация — разбор



Fuzzy-matching / shingling — ~90%

Сравнение текстов по перекрывающимся фрагментам без обращения к модели

Дёшево и предсказуемо



LLM — только остаток

Два сообщения об одном событии написаны разными словами почти без общих фрагментов

Перифраз без лексического пересечения

Сначала дешёвый детерминированный фильтр — ИИ на то, что он не взял



Сегодня вы решали, что строить.

Лекция 2 — как модель устроена внутри