



СЕМИНАР 2

Когда ИИ, каким и на чём

Семь реальных рабочих ситуаций — и в каждой решение, которое инженер принимает раньше, чем открывает редактор кода

NASA / Cory Huston · Wikimedia Commons · общественное достояние

Сегодня — семь кейсов

В каждом — решение, которое инженер принимает раньше, чем открывает редактор кода



Документы поставщиков



Персоналка в логах



Помощник поддержки



Описания товаров



Протоколы встреч



Дайджест по чатам



Звонки продаж

В каждом кейсе появится деталь, которой не было в первой постановке



Документы поставщиков

ИИ или обычный код?

Документы поставщиков



«Бухгалтерия тонет. Вот два примера — можно это автоматом разбирать?»



Pizarros · Wikimedia Commons · CC BY-SA 3.0

Документ поставщика А

Дата	№ накладной	Позиция	Сумма
24.03.2026	—	—	—

Документ поставщика Б

Дата	№ накладной	Позиция	Сумма
24.03.2026	—	—	—

Что предложите?

Документы поставщиков

99

«Попросили архив — прислали за три года, сорок поставщиков»

Поставщик А

Дата	№ наклад.	Сумма

Поставщик Б

Date	Invoice#	Total

Поставщик В

Период	Заказ	Итого, Р

Поставщик Г

№	от	итого

Форматы разъехались — разные колонки, разные форматы дат, один документ на английском

Меняет ли это ваш ответ?

Документы поставщиков — разбор



Гибрид: LLM-извлечение по вариативному входу + жёсткая валидация кодом на выходе

Документ (любой формат) → LLM извлекает поля → код проверяет типы/обязательные значения/диапазоны → данные в 1С

Два примера — не выборка. Просите представление полного объёма данных

Держите в голове риск из Лекции 1: модель на форматах, которые видела, тихо деградирует на новых — тот же механизм, что distribution shift

Персоналка в логах



«Нужно вычистить персональные данные из логов перед передачей подрядчику»



Одна строка лога — телефон, email и фраза «передайте это Ивану из бухгалтерии»

Подрядчику нужны структура запросов, тайминги, ошибки — не данные людей

Одна технология на всё, или нет?

Персоналка в логах — разбор

Regex

Телефоны, email — чёткий формат, дёшево и надёжно
вычищает обычный regex

🔍 NER / LLM

Имена людей, косвенные упоминания в свободном
тексте — нужен контекст

Граница между regex и моделью проходит внутри одной задачи, не между задачами

Из жизни: провал и успех

Vendor-метрика точности $\neq$ метрика, измеренная независимо на своих данных

⊗ Epic Sepsis Model

Заявленный AUC 0.76–0.83 vs реальный 0.63 (Michigan Medicine, 38 455 госпитализаций)

Пропущено 67% реальных случаев сепсиса

Алерты — на 18% всех госпитализированных пациентов

✓ Ramp, merchant classification

Вручную: покрытие 3% заявок (2023) → 1,5% (2024)

После LLM-агента: обработка < 10 сек

~99% изменений корректны · ~25% заявок обоснованно отклоняются

Ramp — замена ручной обработки с мизерным покрытием, не замена работавшего regex-решения



Помощник поддержки

Встроить или своё?

Помощник поддержки



«Сделайте нам ИИ-помощника для операторов — подсказки по тикетам, поиск похожих обращений»



FiveOne51 · Wikimedia Commons · CC BY-SA 3.0

Операторы весь рабочий день живут в одном и том же интерфейсе helpdesk-системы

Где должен жить этот помощник?

Помощник поддержки



«Открытого API нет, кастомизаций нет — вендор и на письма не отвечает»



Что делаем?



Коробочный helpdesk — закрытый вендор

Нет открытого API, нет возможности кастомизации, вендор не отвечает даже на письма об интеграции

Помощник поддержки — разбор



Решение сбоку

Расширение браузера или вторая панель

Цена: Два места одновременно, риск: оператор не будет пользоваться



Смена вендора

Helpdesk-система с открытым API

Цена: Миграция данных, переобучение команды, риск простоя



Пересмотр задачи

Асинхронный помощник, готовит черновики заранее

Цена: Оператор открывает готовое там, где удобно, но нужен отдельный процесс

Единственно верного ответа нет

Описания товаров



«Маркетинг просит отдельный ИИ-сервис для генерации описаний товаров»



Новый отдельный инструмент: логин, вкладка, форма ввода характеристик товара → готовое описание

Отдельный сервис — хорошая идея?

Описания товаров — разбор



Кнопка «сгенерировать описание»

в существующей админке каталога, которой маркетинг и так пользуется каждый день

Отдельный продукт — второй логин и вкладка, цена, о которой не подумали

Из жизни: Kite vs GitHub Copilot

⊗ Kite (standalone)

~500 000 бесплатных пользователей на пике

Закрылся в ноябре 2022 года

«Разработчики не платят за инструменты»

✓ GitHub Copilot (встроен)

~20 млн пользователей к июлю 2025 (из 100+ млн на GitHub)

~4,7 млн платных подписчиков к январю 2026

~90% компаний Fortune 100

Встроенность в уже существующий рабочий поток победила отдельный продукт при технологии сравнимого класса

Humane AI Pin — привлечено ~\$241 млн, продан за \$116 млн · Rabbit R1 — ~100 000 устройств, активно пользуются ~5%

Два слова про RAG

Поиск по базе знаний подкладывает нужные фрагменты в контекст модели

Лекция 3 →




Когда нужен: база большая, меняется, весь объём не помещается в один запрос

Два слова про агента

Модель работает циклом с внешними инструментами, а не одним вызовом

Лекция 3 →



Когда нужен: несколько шагов и действия во внешних системах



Протоколы встреч

Разовый вызов, RAG или агент?

Протоколы встреч

99

«После каждой встречи кто-то полчаса пишет протокол руками. Транскрипты есть — сделаем автоматом?»



Amtec Photos · Wikimedia Commons · CC BY 2.0

Транскрипт одной встречи целиком →
структурированные решения, поручения и сроки

Какая архитектура?

Разовый вызов



RAG



Агент

Протоколы встреч



«А можно искать — что мы решали по проекту X за полгода?»



Прошёл месяц — накопились десятки протоколов с разных встреч, по разным проектам

Меняет ли это архитектуру?

Протоколы встреч — разбор 1



«Растущий и меняющийся архив — вот когда нужен RAG»



растёт со временем →



Весь объём уже не помещается
в один запрос к модели

Теперь обоснован RAG

Разовый вызов



RAG



Агент

Протоколы встреч

»»

«Поручения из протоколов мы всё равно руками переносим в таск-трекер...»



Система находит поручения в тексте протокола, но кто-то вручную открывает таск-трекер и заводит задачи одну за другой

Меняет ли это архитектуру ещё раз?

Протоколы встреч — разбор 2



извлечь поручение → вызвать API task-трекера → создать задачу и проверить



Действие во внешней системе — нужен workflow или агент. Начинайте с простейшего, усложняйте только когда требование не закрыть иначе

Разовый вызов



RAG



Агент

Дайджест по чатам и почте



«Нужен еженедельный дайджест по рабочим чатам и почте команды»



Что обсуждали, что решили за неделю

Коротко, одним сообщением по пятницам

Какая архитектура здесь нужна?

Дайджест — разбор

✓ Агент — нужен

Обход нескольких источников по расписанию

Многошаговая задача с обращением к внешним системам

✗ RAG — не нужен

Источники обходятся напрямую по расписанию, не по произвольному запросу

Суммаризация — один вызов модели после сбора

Много источников — не то же самое, что RAG

Из жизни: фреймворк и класс задач для агента

⊗ Octomind: «Why we no longer use LangChain»

12+ месяцев LangChain в проде → отказ (17.06.2024)

Дебаг фреймворка дороже разработки фич

Негибкие абстракции → замена на прямые модульные вызовы LLM API

✓ Где агент необходим

Deep Research — поиск и синтез по многим источникам с уточнением запроса

Coding-агенты — правка кода → запуск тестов → итерация по результату

В обоих случаях одного вызова физически недостаточно

Прямые вызовы API иногда дают больше контроля, чем абстракция, которая должна была его упростить



Звонки продаж

Внешний API или локально?

Звонки продаж



«Хочу карточку по каждому звонку — потребность, возражения, договорённости»



OddibeKerfeld · Wikimedia Commons · CC BY-SA 3.0

Запись обычного свободного разговора менеджера с клиентом, без структуры

Какая архитектура, где считать?

Звонки продаж



«Стоп. Клиенты диктуют телефоны, адреса, иногда паспортные данные»



Никто из инженеров не думал об этом заранее — все слушали только про потребности и возражения

Кто передумал?

Звонки продаж — разбор 1

Персональные данные меняют расчёт — и цена ошибки не абстрактная



420-ФЗ (принят 30.11.2024, вступил в силу 30.05.2025)

Повторная утечка персональных данных — оборотный штраф 1-3% годовой выручки

(минимум 20 млн, максимум 500 млн ₽)

Обязанность уведомить Роскомнадзор в течение 24 часов

Тот же организационный вопрос, что был в кейсе про логи — только ставки выше

Звонки продаж



«GPU-сервера у нас нет, и бюджета на него в этом году нет»



— СТО



«Мне не беседа нужна — пять полей в CRM по каждому звонку»



— руководитель отдела продаж

Меняет ли это архитектуру ещё раз?

Звонки продаж — разбор 2



Небольшая локальная модель (7-8 млрд параметров) справляется — данные не покидают периметр компании

(а) «сложно для человека» $\neq$ «сложно для модели»

(б) чувствительность данных выясняется вопросами, а не предполагается

Ход 1: Облачный frontier?



Ход 2: Персональные данные



Ход 3: Шаблон полей → локальная модель

Из жизни: утечка и малые модели в проде

⊗ Samsung, 2023

Разрешили ChatGPT 11.03.2023

К 30.03 (~19 дней) — 3 утечки: 2× код производства, 1× транскрипт совещания

Полный запрет генеративного ИИ на устройствах (май 2023) + своя внутренняя система

✓ Малые модели в проде

JetBrains full-line completion — локальная модель ~100 МБ, в проде с апреля 2024

Apple on-device — ~3 млрд параметров (WWDC 2024)

Frontier (GPT/Claude/Gemini) — сотни миллиардов параметров, только облако

Frontier-модели — сотни миллиардов параметров, доступны только через облако. Малые модели уже работают локально в проде

Ваши задачи



У кого есть похожая задача с работы — там, где стоял вопрос, нужен ли ИИ, и какой?

Достаточно сформулировать в двух-трёх предложениях, как её принёс бы заказчик

Что унести

Семь уроков, по одному на кейс — ничего нового, только компиляция



Документы поставщиков

- Два примера — не выборка



Персоналка в логах

- Граница regex/модель — внутри задачи



Помощник поддержки

- Организационное ограничение решает не хуже техники



Описания товаров

- Встроенность бьёт отдельный продукт



Протоколы встреч

- Архитектуру двигают требования, не мода



Дайджест

- Много источников ≠ RAG



Звонки продаж

- Сложно для человека ≠ сложно для модели

Домашнее чтение

Необязательно, но по каждой истории будет что обсудить



ГЛАВНОЕ

Cara Klarna, 2023-2025

AI-ассистент поддержки: от впечатляющего старта до признания «мы зашли слишком далеко» и возврата к найму людей.



NYC MyCity chatbot, 2024

Городской чат-бот для малого бизнеса, дававший юридически некорректные советы. Расследование The Markup.



Бонус, для настроения

Автосалон подключил чат-бот на стороннем API без ограждений — и чат-бот «продал» внедорожник за один доллар.

Если сегодня останется время — часть этого разберём вживую

Klarna, 2023-2025: одна история — четыре развилки

1 ИИ или нет

Типовые тикеты — формализуемы, хороший кандидат; но оптимизация по стоимости уронила качество

2 Встроить или своё

Ассистент в существующем канале поддержки, внешний API (OpenAI) — не отдельный продукт

3 Архитектура

Чат-ассистент с эскалацией к человеку, не автономный агент

4 Инференс

Внешний облачный API с клиентскими данными поддержки

Запуск февраль 2024 · 30 дней: 2,3 млн чатов, 67% обращений автоматизировано · заявлено «700 агентов»/\$40M (2024) → «853 агента»/\$60M (Q3 2025) — знаменатель не раскрыт

«We went too far» — CEO Себастьян Семятковски, Bloomberg, май 2025

Дедупликация новостей



«Поток новостей из многих источников — нужно склеивать одинаковые в одну карточку»



Десять почти одинаковых заголовков от разных изданий

→ одна объединённая карточка события

Какая технология нужна?

Дедупликация — разбор



Fuzzy-matching / shingling — ~90%

Сравнение текстов по перекрывающимся фрагментам без обращения к модели

Дёшево и предсказуемо



LLM — только остаток

Два сообщения об одном событии написаны разными словами почти без общих фрагментов

Перифраз без лексического пересечения

Сначала дешёвый детерминированный фильтр — ИИ на то, что он не взял



Сегодня вы решали, что строить.

Лекция 2 — как модель устроена внутри