



СЕМИНАР 2

Когда ИИ, каким и на чём

Семь реальных рабочих ситуаций — и в каждой решение, которое инженер принимает раньше, чем открывает редактор кода

Сегодня — четыре выбора, семь кейсов



ИИ или обычный код



Встроить или делать своё



Разовый вызов, RAG или агент



Внешний API или локальный инференс

Семь кейсов, на которых сегодня разбираем эти выборы



Документы поставщиков



Персоналка в логах



Помощник поддержки



Описания товаров



Протоколы встреч



Дайджест по чатам



Звонки продаж

В каждом кейсе появится деталь, которой не было в первой постановке

ИИ или обычный код?

Кейс: документы поставщиков

Инженеры часто решают это на глаз, по ощущению сложности задачи

Документы поставщиков

Марина, и.о. продавца по фин.процессам

99

«Привет! Пишет Марина, временно за продавца по фин.процессам, пока Олег в отпуске. Бухгалтерия реально тонет: три человека руками забивают накладные поставщиков в 1С, около 400 штук в месяц, к концу квартала завал и ошибки в суммах. Приложила два примера накладных за прошлую неделю — форматы вроде одинаковые. Можно это как-то автоматом сделать? Заодно спроси у Димы, когда освободится после релиза мобилки — хотела обсудить с ним ещё и склад, но это отдельная история. По срокам — прикидка хотя бы до пятницы была бы супер, у нас на этой неделе ревью бюджета».

Документ поставщика А

Дата	№ накл.	Позиция	Сумма
24.03.2026	—	—	—
—	—	—	—

Документ поставщика Б

Дата	№ накл.	Позиция	Сумма
24.03.2026	—	—	—
—	—	—	—

Целевая таблица в 1С

Дата	№ накладной	Позиция	Сумма
24.03.2026	—	—	—
—	—	—	—

Что предложите?

Документы поставщиков



«Коллеги, выгрузила архив, как просили — вот ссылка на файлообменник, ZIP получился на 4,2 ГБ, извините, что так долго собирала, почта у нас опять письма режет после 20 МБ. Внутри вперемешку: и сканы актов сверки с поставщиками, и сами договоры, и накладные — я их особо не сортировала, как было в папке за год, так и заархивировала. Нужны вам, как понимаю, только накладные, остальное можно игнорировать. Кстати, отдельно от этого — завтра у нас закрытие месяца, если что-то понадобится досчитать по кассе, я буду занята примерно до обеда. Скажите, если архив не открылся или что-то не так с кодировкой».

Поставщик А

Дата	№ накл.	Сумма

Поставщик Б

Date	Invoice#	Total

Поставщик В

Период	Заказ	Итого, Р

Поставщик Г

№	от	итого

Меняет ли это ваш ответ?

Документы поставщиков — разбор



Гибрид: LLM-извлечение по вариативному входу + жёсткая валидация кодом на выходе

Документ (любой формат) → LLM извлекает поля → код проверяет типы/обязательные значения/диапазоны → данные в 1С

Разумный ответ здесь — гибрид, а не выбор одного из двух подходов



изучайте данные, не верьте на слово

Два примера — не выборка. Просите представление полного объёма данных

Персоналка в логах



«Слушай, у нас подрядчик по перфомансу просит логи прода за квартал для анализа — говорят, без них не смогут найти, почему просадки на пиках. Я выгрузил, получилось около 40 ГБ, архив уже лежит на сервере. Но там внутри вперемешку и номера телефонов, и почты клиентов, и один раз даже видел фразу типа «передайте это Ивану из бухгалтерии» — видимо, из тела какого-то запроса залогировалось. Подрядчику нужна сама механика — структура запросов, тайминги, коды ошибок — а не данные людей, это же нельзя просто так отдавать. Они ждут архив в пятницу, у них спринт начинается, так что руками перебирать некогда совсем».



Подрядчику нужны структура запросов, тайминги, ошибки — не данные людей

Как максимально быстро и дёшево очистить?

Персоналка в логах — разбор

Regex

Телефоны, email — чёткий формат, дёшево и надёжно
вычищает обычный regex

Детерминированная логика — модель не нужна

*Никакая модель здесь не нужна и только замедлила бы обработку 40
ГБ логов*



NER / малая модель

Имена людей, косвенные упоминания в свободном тексте
— нужен контекст

slovnet (Natasha) · ~30 МБ · CPU · ~25 строк/сек

~60× меньше BERT сравнимого класса, потеря качества 1-2 п.п.

Граница между regex и моделью проходит внутри одной задачи, не между задачами

Когда нужна была формула — и когда ИИ закрыл нерешаемое

⊗ CNET, январь 2023

Из 77 ИИ-сгенерированных статей о финансах исправления потребовались 41

**«10 000 \$ под 3% годовых → 10 300 \$ за год» вместо
корректных 300 \$ дохода**

*Расчёт должен делать детерминированная формула, а не LLM
«на глаз»*

✓ Ramp, merchant classification

Вручную: покрытие заявок 1,5-3% → после LLM-агента почти полное

Обработка < 10 сек, ~99% решений корректны

~25% заявок агент обоснованно отклоняет

Ramp — замена ручной обработки с мизерным покрытием, не замена работавшего regex-решения

2



Встроить или делать своё?

Кейс: помощник поддержки

Скрытая цена почти никогда не видна в демо на презентации идеи

Помощник поддержки



«Привет, давно хотели это обсудить с командой поддержки. Идея простая: сделать ИИ-помощника для операторов — подсказки ответов на тикеты, поиск похожих обращений в истории, чтобы не рыться каждый раз вручную. У нас на линии 12 операторов, поток около 300 тикетов в день, с явным пиком с 10:00 до 13:00 — после обеда обычно спокойнее. Руководитель поддержки, Света, давно жалуется, что новичков долго вводить в курс — сейчас на это уходит недели три, и это отдельная тема, надо бы отдельно посмотреть на онбординг. Если получится сделать помощника — было бы здорово успеть показать на квартальном ревью, но это не жёсткий дедлайн, скорее ориентир».



12 операторов на линии, около 300 тикетов в день, пик 10:00-13:00

Где должен жить этот помощник?

Помощник поддержки

ИТ-директор



«Слышал про идею с помощником для поддержки, хочу сразу обрисовать картину. У нас коробочный helpdesk, открытого API нет, кастомизаций нет — мы писали вендору ещё в марте с вопросом про интеграцию, ответа так и не получили. Систему купили 4 года назад, на ней же висят тикеты от HR и от фасилити-менеджмента, так что трогать её надо аккуратно. Контракт с вендором ещё на 2 года, продлевать раньше срока смысла нет. В следующем квартале, кстати, будем пересматривать весь ландшафт ИТ-систем — но это отдельный процесс, и вас туда пока звать рано».



Коробочный helpdesk 4 года без открытого API — контракт с вендором ещё на 2 года

Что делаем?

Помощник поддержки — разбор



Решение сбоку

Расширение браузера или вторая панель

Цена: Два места одновременно, риск: оператор не будет пользоваться



Смена вендора

Helpdesk-система с открытым API

Цена: Миграция данных, переобучение команды, риск простоя



Пересмотр задачи

Асинхронный помощник, готовит черновики заранее

Цена: Оператор открывает готовое там, где удобно, но нужен отдельный процесс

Единственно верного ответа нет

Описания товаров



«Ребята, у нас на прошлой неделе руководитель был на конференции ритейла, увидел там у одного из конкурентов классный сервис для генерации описаний товаров — с виду прямо как отдельное приложение, зашёл, вбил характеристики, получил готовый текст под карточку. Хочет, чтобы у нас было что-то похожее, желательно к концу месяца, у нас как раз намечается демо для инвесторов. Каталог большой — около 12 000 товарных позиций, сейчас описания пишет один копирайтер на аутсорсе, по мере поступления новых товаров, и она, кстати, уже жаловалась, что не успевает и просила доплату за срочность. Ах да, отдельно нужно бы ещё обновить баннеры на главной странице сайта, но это к другому разговору».



12 000 товарных позиций, сейчас описания пишет один копирайтер на аутсорсе

Отдельный сервис — хорошая идея?

Описания товаров — разбор




Кнопка «сгенерировать описание»

в существующей админке каталога, которой маркетинг и так пользуется каждый день

Отдельный продукт — второй логин и вкладка, цена, о которой не подумали

Kite и Copilot

Одна технология, разная встроенность — 17 месяцев прямой конкуренции



Kite — ~500 000 пользователей на пике

Copilot — ~20 млн пользователей · 4,7 млн платных · ~90% Fortune 100

Встроенность в уже существующий рабочий поток победила отдельный продукт при технологии сравнимого класса

Отдельное устройство против фиши в телефоне



Humane AI Pin

Носимый значок без экрана, лазерный проектор на ладонь, голосовое управление · \$699 + подписка \$24/мес

Продажи с апреля 2024

Привлечено ~\$241 млн → активы проданы HP за \$116 млн (февраль 2025) → серверы отключены 28.02.2025



Rabbit R1

Продано ~100 000 устройств, по оценкам активно пользуются около 5% купивших

Отдельное устройство конкурирует не только с технологией, но и с привычкой не переключаться, когда функция уже есть в телефоне



Разовый вызов, RAG или агент?

Кейс: протоколы встреч

Чем внушительнее задача, тем сложнее архитектура — интуицию стоит проверять

Два слова про RAG

Поиск по базе знаний подкладывает нужные фрагменты в контекст модели

Лекция 3 →




Когда нужен: база большая, меняется, весь объём не помещается в один запрос

Два слова про агента

Модель работает циклом с внешними инструментами, а не одним вызовом

Лекция 3 →



Когда нужен: несколько шагов и действия во внешних системах

Протоколы встреч



«Коллеги, у нас после каждого созвона Zoom кладёт транскрипт в письмо — я их складываю в папку, но руки не доходят. Протокол по-прежнему пишет Настя-проджект руками, минут по 30-40, а у неё и так спринт-отчёты и онбординг двух новых. Встреч штук 15 в неделю, часть на английском с подрядчиком. Можно из транскрипта автоматом делать протокол — решения, поручения, сроки? В идеале до конца квартала, у нас аудит процессов».



Около 15 встреч в неделю, протокол сейчас пишет проджект вручную

Какая архитектура нужна?

Протоколы встреч — разбор



«Один вызов, ни хранилища, ни цикла»



Письмо с транскриптом



Вызов модели с шаблоном



Протокол

Весь транскрипт помещается в один запрос — усложнять сейчас означало бы решать проблему, которой не существует

Протоколы встреч



«Народ, было на планёрке сегодня — уже неловко даже пересказывать. Обсуждали бюджет на следующий квартал, и тут кто-то из финансов спрашивает: „А что мы вообще решали по подрядчику X ещё в мае, у нас там были какие-то договорённости про скидку?“ И повисла пауза — никто с ходу не вспомнил, в каком это было протоколе. Протоколы у нас копятся в общей папке на диске, названы более-менее по датам, но искать по ним руками — то ещё удовольствие, особенно если помнишь только примерную тему, а не точную дату созвона. Кстати, по ходу дела там же обсуждали ещё отпускной график на лето, но это уже другая история, не по делу».




Прошёл месяц — накопились десятки протоколов с разных встреч, по разным проектам

Меняет ли это архитектуру?

Протоколы встреч — разбор 1



«Растущий и меняющийся архив — вот когда нужен RAG»



Прежний путь никуда не делся — просто дополнен хранилищем, индексацией и поиском перед тем же вызовом модели

Протоколы встреч



«Слушайте, спасибо большое за поиск по протоколам, реально экономит время, особенно перед ретро. Но вот что заметила: поручения из протоколов мы всё равно руками переносим в таск-трекер — открываем протокол, читаем, что там нашла система, и одно за другим заводим карточки, проставляем исполнителя и срок. Причём я специально прошлась по майским протоколам вчера вечером, и получилось, что примерно половина поручений так и висит без исполнителя — просто руки не дошли перенести. Отдельно ещё хотела спросить, можно ли поменять цвет тегов в самом таск-трекере, а то команда путается в приоритетах, но это, наверное, вопрос не к вам, а к админу инструмента».




Половина поручений из майских протоколов до сих пор без исполнителя — руки до переноса просто не доходят

Меняет ли это архитектуру ещё раз?

Протоколы встреч — разбор 2



«Действие во внешней системе — нужен агент поверх RAG»



Начинайте с простейшего варианта, усложняйте только когда требование не закрыть иначе

Дайджест по чатам и почте



«Привет, обсуждали на планёрке — хотим еженедельный дайджест по рабочим чатам и почте команды: что обсуждали, что решили за неделю, коротко, одним сообщением, чтобы не перечитывать всю переписку заново по вечерам в пятницу. Нужен по пятницам к 17:00 — чтобы руководитель успел прочитать перед выходными, а не разгребал всё в понедельник утром вперемешку с новой почтой. Источников несколько: рабочий чат команды и почта, надо свести в одно связное сообщение, а не просто склеить куски подряд. Кстати, отдельно от этого — хотели ещё обсудить, стоит ли переезжать с текущего чата на другой мессенджер, но это дело не срочное, как-нибудь в другой раз».



Из чата и почты — одно связное сообщение, по пятницам к 17:00

Какая архитектура здесь нужна?

Дайджест — разбор

✓ Агент — нужен

Обход нескольких источников по расписанию

Многошаговая задача с обращением к внешним системам

✗ RAG — не нужен

Источники обходятся напрямую по расписанию, не по произвольному запросу

Суммаризация — один вызов модели после сбора

Много источников — не то же самое, что RAG

RAG и агент в проде



AI @ Morgan Stanley Assistant

Партнёрство с OpenAI (март 2023), запуск в сентябре 2023

RAG по базе ~100 000 research-документов

К середине 2024 — используют более 98% команд финансовых советников

Доступность нужного документа: 20% → 80%



Replit, июль 2025

Агент удалил продакшен-базу (~1200 руководителей компаний затронуты) во время code freeze, вопреки прямой инструкции

Затем неверно утверждал, что откат невозможен — данные восстановили

После инцидента: разделение dev/prod + режим агента «только планирование»

Ещё: Octomind — сняли LangChain после года в проде, вернулись к прямым вызовам (17.06.2024)



Внешний API или локальный инференс?

Кейс: звонки продаж

Это про то, где физически обрабатываются данные, а не какая модель лучше

Звонки продаж



«Привет! Тут у нас родилась идея на стратегической сессии — хочу по каждому звонку менеджера получать карточку: какая потребность у клиента, какие возражения прозвучали, какие договорённости достигли. А то перед следующим звонком с тем же клиентом менеджеры перематывают запись туда-сюда, ищут, на чём остановились в прошлый раз. В отделе у меня 8 менеджеров, у каждого по 15-20 звонков в день, записи сейчас просто лежат в телефонии, никуда не выгружаются. Вся история клиента у нас в CRM, но её тоже давно пора почистить от дублей контактов — но это отдельная головная боль, обсудим как-нибудь потом».



8 менеджеров, по 15-20 звонков в день, записи лежат в телефонии

Как это построить?

Звонки продаж



«Стоп. Вы эти записи в какой сервис отправляете?»



РФ

152-ФЗ + 420-ФЗ (с 30.05.2025)

Первая утечка: штраф 3-5 млн ₽

Повторная: 1-3% годовой выручки (мин. 20 млн, макс. 500 млн ₽)



ЕС

GDPR

До €20 млн или 4% мирового оборота (что больше)

Рекорд: Meta, €1,2 млрд, 2023



США

Единого федерального закона нет

Штатные (Калифорния — CCPA/CPRA)

Секторальные (например, HIPAA)

За сохранность персональных данных всерьёз борются все крупные юрисдикции

Звонки продаж



«Коллеги, разговор случился на еженедельном созвоне по бюджету — туда же, кстати, пригласили и юриста, который на прошлой неделе смотрел демо прототипа. Хочу сразу обозначить ограничение по инфраструктуре: GPU-сервера у нас нет, и бюджета на него в этом году тоже нет — приоритеты на квартал уже утверждены финансовым директором, туда попали миграция на новую почтовую систему и обновление парка ноутбуков в поддержке. Если модель тяжёлая, придётся идти через облачный API, но там свои вопросы по данным, мы их уже обсуждали. В следующем году, может, вернёмся к разговору про свой сервер, но не сейчас».

— СТО



«Меня, честно говоря, весь этот разговор про модели и облака не очень касается — я не технарь. Мне для работы нужно простое: пять полей в CRM по каждому звонку — потребность, возражения, договорённости, следующий шаг, оценка вероятности сделки. Не пересказ разговора целиком, не анализ тона голоса менеджера, ничего такого. Просто эти пять полей должны заполняться сами, чтобы я видел их у себя в отчёте по отделу, который я и так каждый понедельник собираю руками из заметок ребят».

— руководитель отдела продаж

Меняет ли это архитектуру ещё раз?

Звонки продаж — разбор



Задача сузилась до шаблона — локальная модель 7-8 млрд параметров справляется, данные не покидают периметр компании

Открытые модели 7-8B:

Qwen3 · Llama · Gemma · Mistral · T-lite · T-pro (Т-Банк, Apache 2.0, на базе Qwen)

4-bit квантование → 4-6 ГБ памяти, обычный сервер без GPU (Ollama / llama.cpp) · тонкая подстройка — LoRA на одной GPU

«Сложно для человека» ≠ «сложно для модели»

Чувствительность данных выясняется вопросами, а не предполагается

Утечка в Samsung — и модели, которые уже в кармане

✗ Samsung, 2023

Разрешили ChatGPT 11.03.2023

К 30.03 (~19 дней) — 3 утечки: 2× код производства, 1× транскрипт совещания

Полный запрет генеративного ИИ на устройствах (май 2023)

✓ Малые модели в кармане

Apple Intelligence — ~3 млрд параметров на устройстве (iOS 18.1, октябрь 2024, iPhone 15 Pro+): суммаризация и правка текста офлайн

Google Gemini Nano — 1,8-3,25 млрд параметров (Pixel/Android): суммаризация в Recorder, Magic Compose — офлайн

Малые модели уже в кармане у половины аудитории

Ваши задачи



У кого есть похожая задача с работы — там, где стоял вопрос, нужен ли ИИ, и какой?

Достаточно сформулировать в двух-трёх предложениях, как её принёс бы заказчик

Что унести

Семь уроков, по одному на кейс — ничего нового, только компиляция



Документы поставщиков

- Два примера — не выборка



Персоналка в логах

- Граница regex/модель — внутри задачи



Помощник поддержки

- Организационное ограничение решает не хуже техники



Описания товаров

- Встроенность бьёт отдельный продукт



Протоколы встреч

- Архитектуру двигают требования, не мода



Дайджест

- Много источников ≠ RAG



Звонки продаж

- Сложно для человека ≠ сложно для модели

Домашнее чтение

Необязательно, но по каждой истории будет что обсудить



ГЛАВНОЕ

Cara Klarna, 2023-2025

AI-ассистент поддержки: от впечатляющего старта до признания «мы зашли слишком далеко» и возврата к найму людей.



NYC MyCity chatbot, 2024

Городской чат-бот для малого бизнеса, дававший юридически некорректные советы. Расследование The Markup.



Бонус, для настроения

Автосалон подключил чат-бот на стороннем API без ограждений — и чат-бот «продал» внедорожник за один доллар.

Если сегодня останется время — часть этого разберём вживую

Klarna, 2023-2025: одна история — четыре развилки

1 ИИ или нет

Типовые тикеты — формализуемы, хороший кандидат; но оптимизация по стоимости уронила качество

2 Встроить или своё

Ассистент в существующем канале поддержки, внешний API (OpenAI) — не отдельный продукт

3 Архитектура

Чат-ассистент с эскалацией к человеку, не автономный агент

4 Инференс

Внешний облачный API с клиентскими данными поддержки

Запуск февраль 2024 · 30 дней: 2,3 млн чатов, 67% обращений автоматизировано · заявлено «эквивалент 700 агентов»/\$40M (2024) → «853 агента»/\$60M (Q3 2025) — знаменатель не раскрыт

«We went too far» — CEO Себастьян Семятковски, Bloomberg, май 2025

Дедупликация новостей



«Привет! Пользователи жалуются в поддержку, что лента забита — по одному и тому же событию видят десять почти одинаковых заголовков подряд от разных изданий, которые просто пересказывают одну новость своими словами. Хотим это как-то склеивать в одну карточку, чтобы не мозолило глаза. У нас источников уже больше сотни, подключаем ещё несколько в этом месяце, но это уже другой разговор с их API. Нужно понять, какая технология сюда подойдёт, желательно не сильно раздувая расходы на инфраструктуру, бюджет на новые фичи в этом квартале скромный».



Десять почти одинаковых заголовков → одна объединённая карточка события

Какая технология нужна?

Дедупликация — разбор



Fuzzy-matching / shingling — ~90%

Сравнение текстов по перекрывающимся фрагментам без обращения к модели

Дёшево и предсказуемо



LLM — только остаток

Два сообщения об одном событии написаны разными словами почти без общих фрагментов

Перифраз без лексического пересечения

Сначала дешёвый детерминированный фильтр — ИИ на то, что он не взял



Сегодня вы решали, что строить.

Лекция 2 — как модель устроена внутри