


Смысл, фокус, случайность

Три механизма внутри модели

Эмбединги, внимание, сэмплинг — три механизма Лекции 2 сегодня становятся инструментом предсказания. Вы предсказываете, что сделает модель, до того как увидите ответ.

БЛИЗОСТЬ В ПРОСТРАНСТВЕ = БЛИЗОСТЬ СМЫСЛА



Четыре этапа конвейера — сегодня фокус на трёх последних

На Семинаре 2 вы классифицировали AI снаружи. Сегодня — то же умение предсказания, но изнутри: эмбединги, внимание, сэмплинг становятся инструментом.



«strawberry» — три токена, поэтому модель плохо считает буквы — этап 1, сегодня не тренируем отдельно

Косинусная близость — угол между векторами смысла



Повтор с Лекции 2

«Как настроить SSL» / «Установка HTTPS-сертификата»

cosine $\approx$ 0.85

«Деплой React-компонента» / «Сборка React-приложения»

cosine $\approx$ 0.78

«Рецепт борща» против любого технического

cosine $\approx$ 0.05–0.15

illustrative — порядок значений устойчив, точные числа зависят от модели

Блок 1 — эмбединги и семантическая близость

Сегодня проверим эту интуицию на новых, более коварных примерах

«МЫШЬ» И «КЛЮЧ» — одно слово, два смысла. Близко или далеко?

Пара А

«Кот поймал мышь во дворе»

«Я купил беспроводную мышь для ноутбука»

Пара Б

«Скрипичный ключ в начале нотного стана»

«Забыл ключ от квартиры дома»



3 раунда поднятия руки на пару — близко? далеко? не уверен?

Слово совпало — смысл разошёлся

Пара А

«Кот поймал мышь во дворе»

«Я купил беспроводную мышь для ноутбука»

cosine $\approx$ 0.1–0.2

мышь-животное vs мышь-устройство

Пара Б

«Скрипичный ключ в начале нотного стана»

«Забыл ключ от квартиры дома»

cosine $\approx$ 0.1–0.2

нотный знак vs предмет для замка

Одинаковые слова — разное значение → низкая близость несмотря на 100% совпадение

«Продакшн-сервер» и «бэкенд» — разные слова. Близко или далеко?

Пара В

«Почему упал продакшн-сервер сегодня ночью»

«Причина падения бэкенда прошлой ночью»

Пара Г

«Исправить баг в обработке платежей»

«Починить дефект в модуле оплаты»



3 раунда поднятия руки на пару — близко? далеко? не уверен?

Слова разные — смысл совпал

Пара В

«Почему упал продакшн-сервер сегодня ночью»

«Причина падения бэкенда прошлой ночью»

cosine $\approx$ 0.8+

«упал»/«падения», «сервер»/«бэкенд»

Пара Г

«Исправить баг в обработке платежей»

«Починить дефект в модуле оплаты»

cosine $\approx$ 0.8+

«исправить»/«починить», «баг»/«дефект»

Эмбединг ловит то, что важно для смысла, а не поверхностную форму

Пять документов, запрос «клубника» — кто их найдёт?

Запрос «клубника» в корпоративном wiki — тот же пример, что на Лекции 2, теперь на пяти документах

Документ	Полнотекстовый?	Семантический?
1 «Инструкция по выращиванию клубники на даче»	?	?
2 «Strawberry fields: a guide to growing your own»	?	?
3 «Сезонные ягоды средней полосы: сроки созревания»	?	?
4 «Клубный вечер для сотрудников: программа мероприятия»	?	?
5 «Рецепт варенья из лесной земляники»	?	?

Общий корень — не то же самое, что общий смысл

Документ	Полнотекст	Семантика	Заметка
1 «Инструкция по выращиванию клубники на даче»	✓	✓	
2 «Strawberry fields: a guide to growing your own»	✗	✓	перевод через эмбединг
3 «Сезонные ягоды средней полосы: сроки созревания»	✗	✓	родовое понятие
4 «Клубный вечер для сотрудников: программа мероприятия»	✗	✗	ловушка: общий корень «клуб-»
5 «Рецепт варенья из лесной земляники»	✗	✓	близкий, не максимальный cosine

Документ 4 — та же логика, что пары А/Б, в обратную сторону: общая часть слова тоже не гарантирует общий смысл

Когда полнотекстовый поиск лучше семантического?



Разобранный пример: юридический поиск по договорам

Запрос: «пункт об одностороннем расторжении». Полнотекстовый поиск по точной фразе находит пункты, где формулировка встречается дословно — критично, потому что основание расторжения зафиксировано конкретной формулировкой с юридическими последствиями. Семантический поиск дополнительно найдёт релевантный перифраз «отказ от договора в одностороннем порядке» — но с не меньшей вероятностью подмешает «расторжение по соглашению сторон» (близко по теме, но юридически другое основание). Подмена основания расторжения для юриста — не «почти то же самое», а содержательная ошибка.

Здесь семантическая близость — источник риска, а не преимущество: задаче нужна точность формулировки, а не близость темы.

Каким ещё инженерным задачам, где формулировка/точное значение важнее общей темы, нужна именно точность?



Точность важнее похожести

- Точный поиск по ID / артикулу / номеру заказа
- Код ошибки (`NullPointerException`) — семантика может увести к похожим, но не точным совпадениям



Мост к Лекции 3

- Упражнение «клубника» и семантический поиск — база RAG (Retrieval-Augmented Generation)

Фонарик в тёмной комнате — внимание распределяет вес между токенами



Повтор с Лекции 2

Внимание (attention) — фонарик в тёмной комнате: луч направлен на релевантные сейчас токены, остальное — на периферии

«Кот съел мышь, потому что она была голодна»



мышь



была



голодна

Блок 2 — механизм внимания: угадай, куда «смотрит» модель

Сегодня вы предсказываете этот вес сами — до того, как увидите разбор

Трофей не влез в чемодан, потому что он был слишком большой — кто «ОН»?



«Трофей не влез в чемодан, потому что он был слишком большой»

Реальный академический бенчмарк — Levesque, Davis, Morgenstern, The Winograd Schema Challenge (2011/2012)



3 раунда — он = трофей? он = чемодан? не уверен?

«Он» = трофей — большой предмет не влезает в чемоданище



«Трофей не влез в чемодан, потому что он был слишком большой»

он = трофей



Трофей большой, поэтому не влез в чемодан. Иллюстрация распределения весов — не настоящий работающий вживую инструмент.

Трофей не влез в чемодан, потому что он был слишком маленький — кто «он» теперь?



«Трофей не влез в чемодан, потому что он был слишком маленький»



3 раунда — он = трофей? он = чемодан? не уверен?

Одна грамматика — разный ответ



«Трофей не влез в чемодан, потому что он был слишком маленький»

он = чемодан



Одна и та же грамматика в обоих предложениях — а ответ разный. Для правильного ответа нужны мировые знания, не только синтаксический разбор.

Менеджер поругал стажёра, потому что он не проверил тесты — кто «он»?



«Менеджер поругал стажёра, потому что он не проверил тесты перед коммитом»



3 раунда — он = менеджер? он = стажёр? не уверен?

«Он» = стажёр — вес внимания на «стажёр» и «коммит»



«Менеджер поругал стажёра, потому что он не проверил тесты перед коммитом»

он = стажёр



Сущность, которую ругают, связана с конкретным упущенным действием — типичная обязанность того, кто делает коммит.

Пилот сказал диспетчеру, что он ошибся в расчётах — кто «он»?



«Пилот сказал диспетчеру, что он ошибся в расчётах»

Оба существительных мужского рода — согласование рода не подсказывает ответ



3 раунда — он = пилот? он = диспетчер? не уверен?

Оба прочтения разумны



«Пилот сказал диспетчеру, что он ошибся в расчётах»

ОН = ПИЛОТ

пилот признал свою ошибку диспетчеру

тоже верно

он = диспетчер

пилот указал диспетчеру на его ошибку

тоже верно

Уверенный ответ — это понимание или угадывание?



Документированный провал: WinoBias

Zhao, Wang, Yatskar, Ordonez, Chang (2018), NAACL — отдельный от Winograd Schema бенчмарк именно на систематическую ошибку. WinoBias показал: модели разрешения кореференции систематически резолвят неоднозначное местоимение через профессионально-гендерные стереотипы обучающего корпуса — например, чаще связывают «врач» с мужским местоимением, а «медсестра» — с женским, даже когда контекст и грамматика этого не требуют.

Прямое следствие примера «пилот/диспетчер»: внимание статистически смотрит на корпус, и если корпус несёт социальный перекося (bias — тот же термин, что на Семинаре 2), модель воспроизводит его уверенно, а не осторожно.

Если модель уверенно называет референт «он» — значит ли это, что она «понимает» предложение, как человек? Чем понимание отличается от угадывания?



Корреляция

— Внимание — статистика совместной встречаемости токенов



Причинность

— Человек опирается на модель мира — уровни Перла, Лекция 1



Пограничный случай

— Модель угадывает не хуже человека там, где сам человек не уверен

Четыре ручки API — предсказуемость против разнообразия



Повтор с Лекции 2




Классификация



$T = 0$




Кодогенерация



$T \approx 0.2-0.3$



Чат-объяснение



$T \approx 0.7$



Творческое письмо



$T \approx 0.9-1.2$

Блок 3 — сэмплинг: температура и параметры

Сегодня вы проверите эту логику на собственном эксперименте

$T=0$ / $T=0.7$ / $T=1.5$ — что изменилось в вашем эксперименте?

Домашнее задание из Лекции 2



$T = 0$

детерминированный argmax



$T = 0.7$

естественная вариативность



$T = 1.5$

на грани распада связности

1. Что изменилось от $T=0$ к $T=1.5$?
2. Что осталось одинаковым во всех трёх запусках?
3. Какую T вы выбрали для боевого режима и почему?

Три ответа на один промпт — какой температуре какой соответствует?

Три ответа ниже написаны автором методического комплекта для иллюстрации — это не реальный вызов модели

Промпт: «Напиши короткое приветствие для email-рассылки студентам о начале нового курса»

Ответ А

Уважаемые студенты! Рады сообщить вам о начале нового курса. Занятия начинаются согласно расписанию. Желаем успехов в обучении!

Ответ Б

Привет! Новый курс стартует уже на следующей неделе — будет практика, разбор реальных кейсов и, чего уж скрывать, немного домашних заданий. Ждём вас на первом занятии.

Ответ В

Курс! Начинается! Проверьте расписание — а может, и не проверяйте, жизнь непредсказуема, как и первое занятие, где кофе важнее конспекта, но конспект тоже важен, наверное.



3 раунда — для каждого ответа: низкая / средняя / высокая температура?

Повторяемость → вариативность → распад связности

Ответ А

Уважаемые студенты! Рады сообщить вам о начале нового курса. Занятия начинаются согласно расписанию. Желаем успехов в обучении!

$T \approx 0$

полная предсказуемость, текст почти не меняется при повторной генерации

Ответ Б

Привет! Новый курс стартует уже на следующей неделе — будет практика, разбор реальных кейсов и, чего уж скрывать, немного домашних заданий. Ждём вас на первом занятии.

$T \approx 0.7$

конкретные детали, живая интонация, связный текст без странностей

Ответ В

Курс! Начинается! Проверьте расписание — а может, и не проверяйте, жизнь непредсказуема, как и первое занятие, где кофе важнее конспекта, но конспект тоже важен, наверное.

$T \approx 1.5-2.0$

неожиданные обороты, резкие смены тона, на грани распада связности

Признак — не подпись, а наблюдаемое поведение текста

Когда стохастичность — риск, а не удобство?



Разобраный пример: когда НЕ LLM вообще

Банковский чат-бот использует LLM для диалога, но для детекции номеров банковских карт в переписке (чтобы замаскировать их перед логированием) — не полагается на LLM ни при каком значении температуры. Используется regex по формату номера карты + Luhn-алгоритм проверки контрольной суммы. Причина: нужна гарантия срабатывания на 100% известных случаев, а не вероятностное соответствие — даже при $T=0$ LLM может пропустить нестандартно отформатированный номер или ложно среагировать на похожую последовательность цифр, а regex — нет.

Тот же принцип, что в Блоке 1 с полнотекстовым поиском: если задаче нужна гарантия, а не вероятностное приближение — классический инструмент с фиксированной грамматикой правильнее LLM при любом параметре сэмплинга.

В каких сценариях вашей будущей работы стохастичность ответа ($T>0$) — это риск, а не удобство?



Где нужна воспроизводимость

- Классификация с аудитом — почему в прошлый раз результат был другим
- Тестирование ПО — нужен детерминированный оракул для сравнения



Оговорка про $T=0$

- Даже $T=0$ не даёт стопроцентной побитовой детерминированности
- $T=0$ — инженерное приближение, не абсолютная гарантия

Сегодня — три механизма поодиночке. Дальше — модель выходит за пределы цикла

Сегодня мы натренировали три механизма внутри модели поодиночке: эмбединги — для поиска смысла, внимание — для фокуса, сэмплинг — для выбора токена. На Лекции 3 модель выходит за пределы этого замкнутого цикла — ищет во внешней базе знаний, вызывает инструменты, действует в цикле агента.



RAG



Function calling



MCP



Agent loop

Три механизма внутри модели — что помнить



Эмбединги = близость по смыслу, не по буквам

- Одинаковые слова могут означать разное — низкая близость несмотря на лексическое совпадение
- Разные слова могут означать одно и то же — высокая близость несмотря на отсутствие общих слов
- Полнотекстовый поиск иногда точнее семантического: точные ID, юридические цитаты, коды ошибок



Внимание = статистическая корреляция, не понимание причинности

- Модель предсказывает референт через статистику совместной встречаемости токенов
- Иногда однозначного ответа не существует — честный результат тогда распределение вероятностей



Сэмплинг = баланс предсказуемость ↔ разнообразие

- $T=0$ — для задач, где важна воспроизводимость, но без стопроцентной гарантии
- $T>0.7$ — для задач, где ценно разнообразие
- Правильная T — результат эмпирической калибровки, не константа



СПАСИБО

От механизмов внутри — к тому, что снаружи

Сегодня вы натренировали предсказание эмбеддингов, внимания и сэмплинга. На Лекции 3 — как модель выходит за пределы этого цикла и действует в мире через RAG, инструменты, MCP, цикл агента.

Лекция 3 → далее