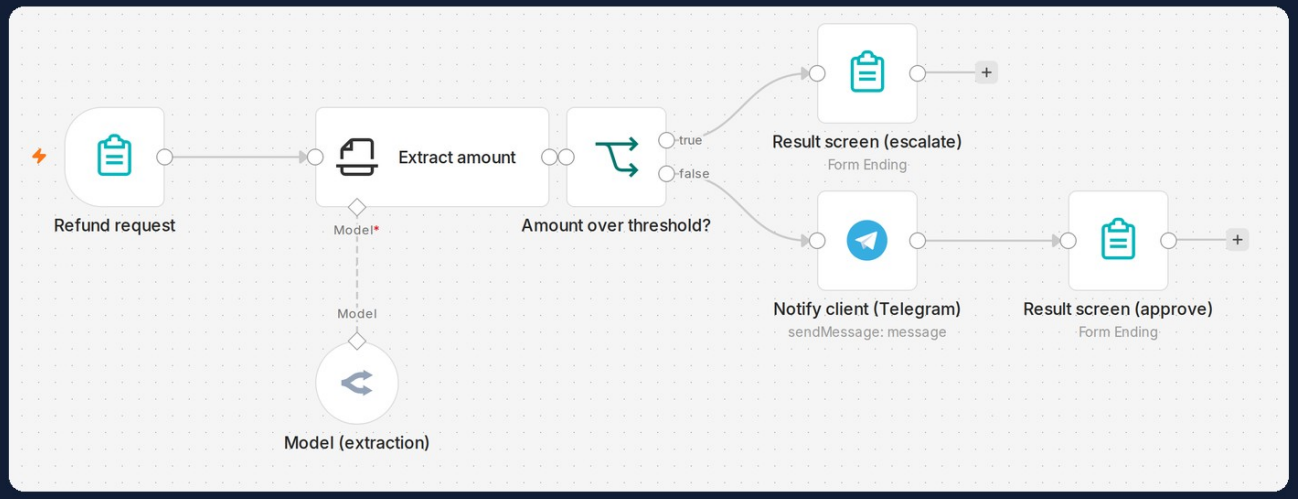
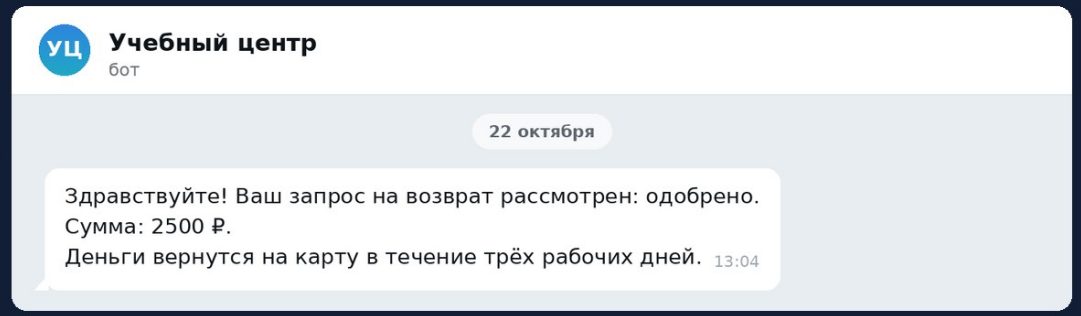
Где решает модель, а где должен — код

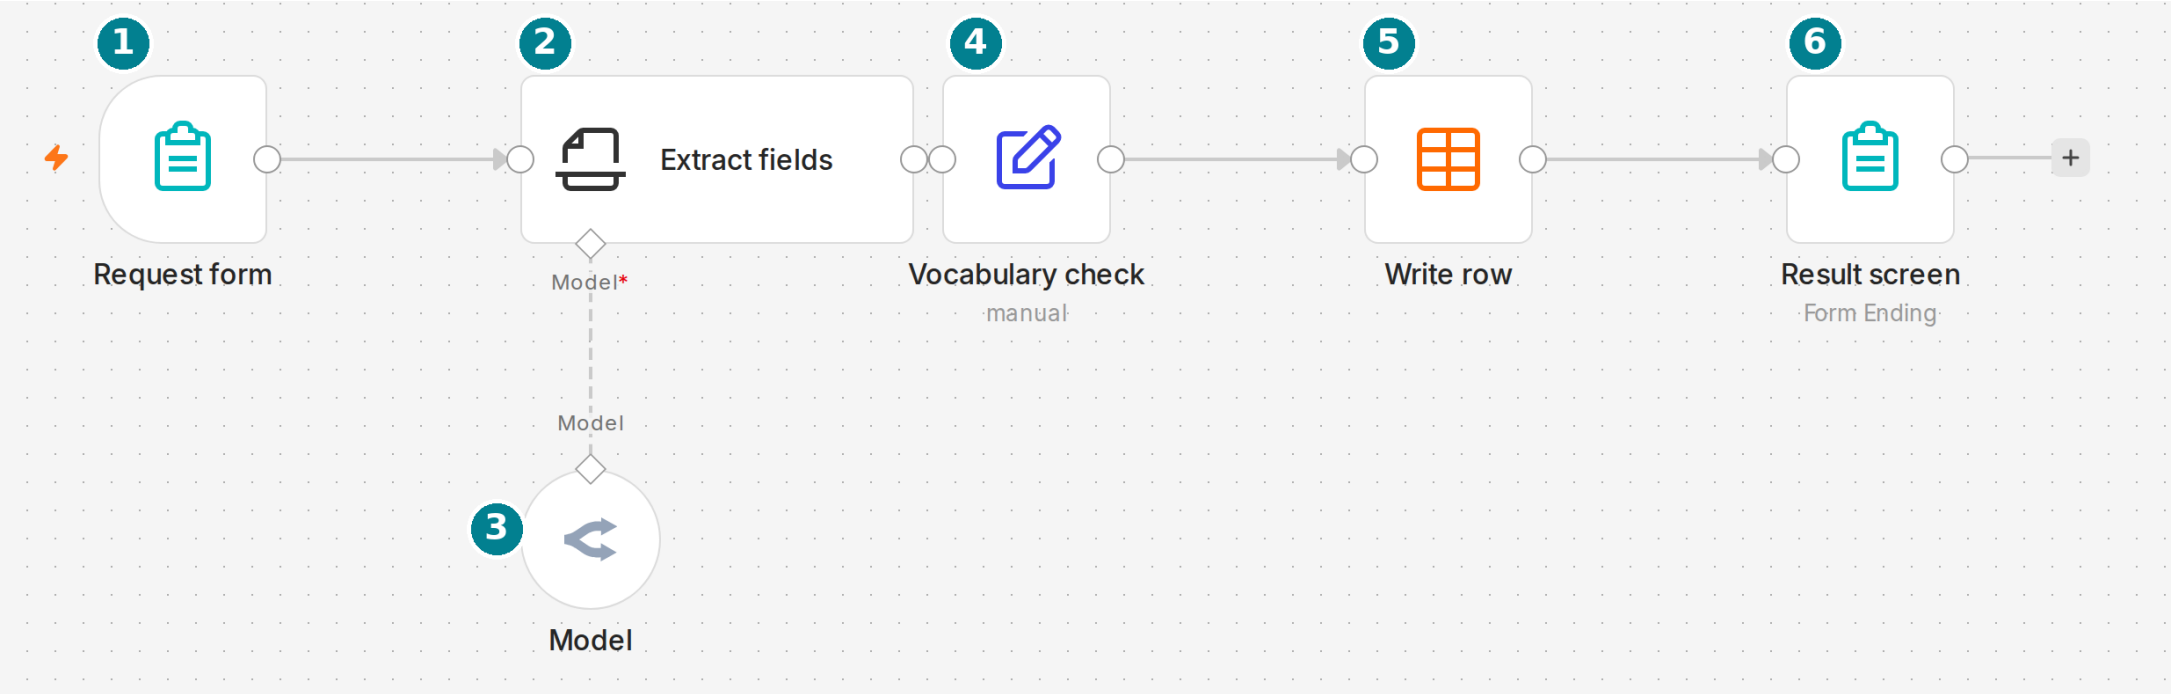
Процессы на больших языковых моделях: второе занятие дуги.

Автоматика отчиталась: всё отправлено. Человек не получил ничего. Сегодня это случится на экране четыре раза — и каждый раз по разной причине.





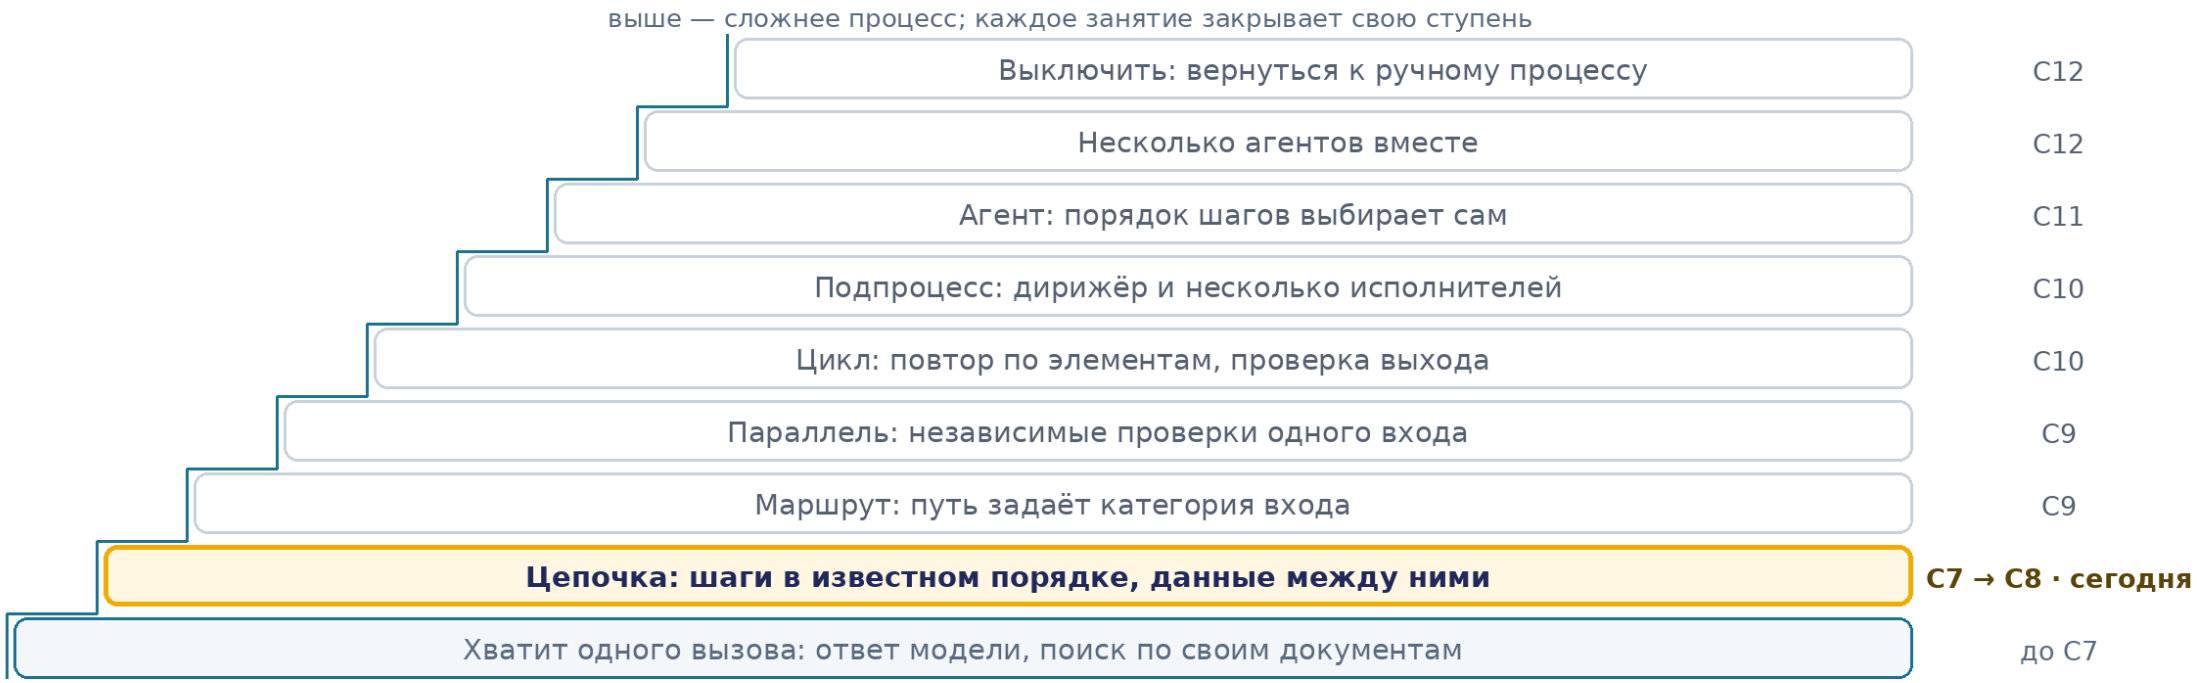
Входное состояние: процесс с прошлого занятия



1 форма — вход процесса · 2 извлечение — достаёт значения из текста · 3 модель — второй узел шага
4 сверка со списком · 5 запись строки · 6 экран результата — печатает всю дорогу

Это настоящий холст n8n, а не схема. У нас есть процесс по классификации входящих обращений — шесть узлов, тот же порядок, те же имена, что и в конце прошлого занятия.

Та же ступень: цепочка



Золотая полоса стоит там же, где и в прошлый раз. Сегодняшние четыре кейса происходят внутри одной и той же ступени: к цепочке добавляют новые шаги, а выше она не поднимается.

Ось занятия: где решает модель, где должен — код

ВЫГЛЯДИТ НАДЁЖНЫМ	ЧЕМ ОКАЗАЛСЯ
сообщение ушло координатору, цепочка короче и дешевле без LLM	
заявка про тот же вопрос пришла снова — обработали как новую	
в промте написано «не возвращай больше суммы X»	
картинка собралась и ушла в Telegram	

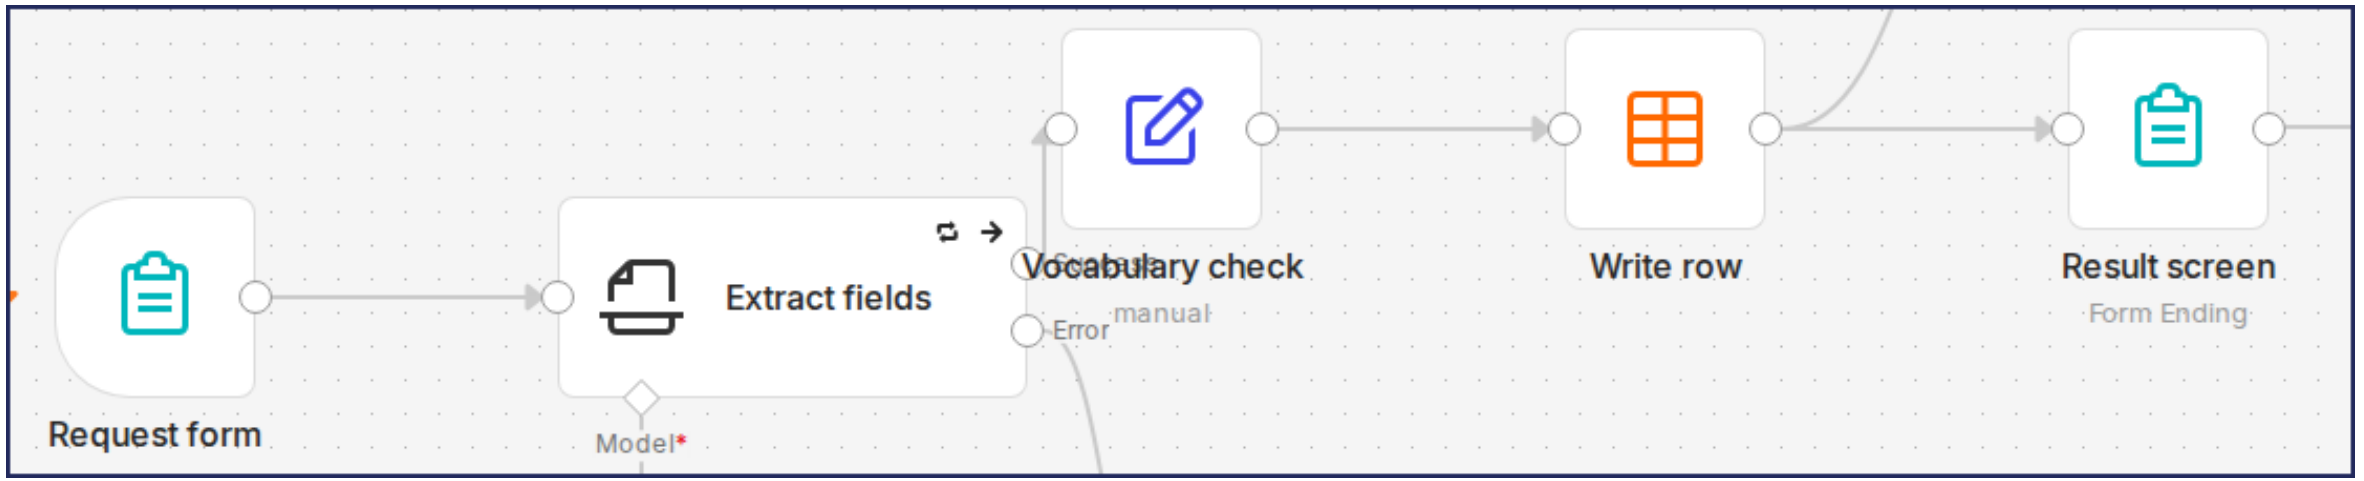
Правая колонка закрывается по одной строке — сразу после того кейса, который её закрывает. И каждую строку впишет экран, не мой рассказ.

Кейс 1. Уведомления

«Пришлите мне в Telegram одну строку: кто написал и про что — чтобы не лезть в таблицу на каждую заявку.»

Уведомления | Проверка на повтор | Одобрение возврата | Карточка в Telegram

Экран результата и многотемная заявка



20 заявок

в день — и почти все про одну тему

несколько часов

столько многотемная заявка лежит в таблице, пока её никто не читает

> *Ольга: «Пришлите мне в Telegram одну строку на каждую такую заявку — кто написал, по какой теме и что ещё упомянул, — чтобы не идти проверять экран результата из-за одной многотемной заявки среди двадцати обычных.»*

Как собрать уведомление из трёх значений

3 значения

уже извлечены на прошлом занятии: имя · тема · дополнительные темы

1 строка

столько Ольга просила на каждую такую заявку

Как собрать текст уведомления из этих трёх значений?

модель пишет весь текст уведомления целиком, свободно

заполняем готовую форму сообщения алгоритмом целиком — только подстановка значений

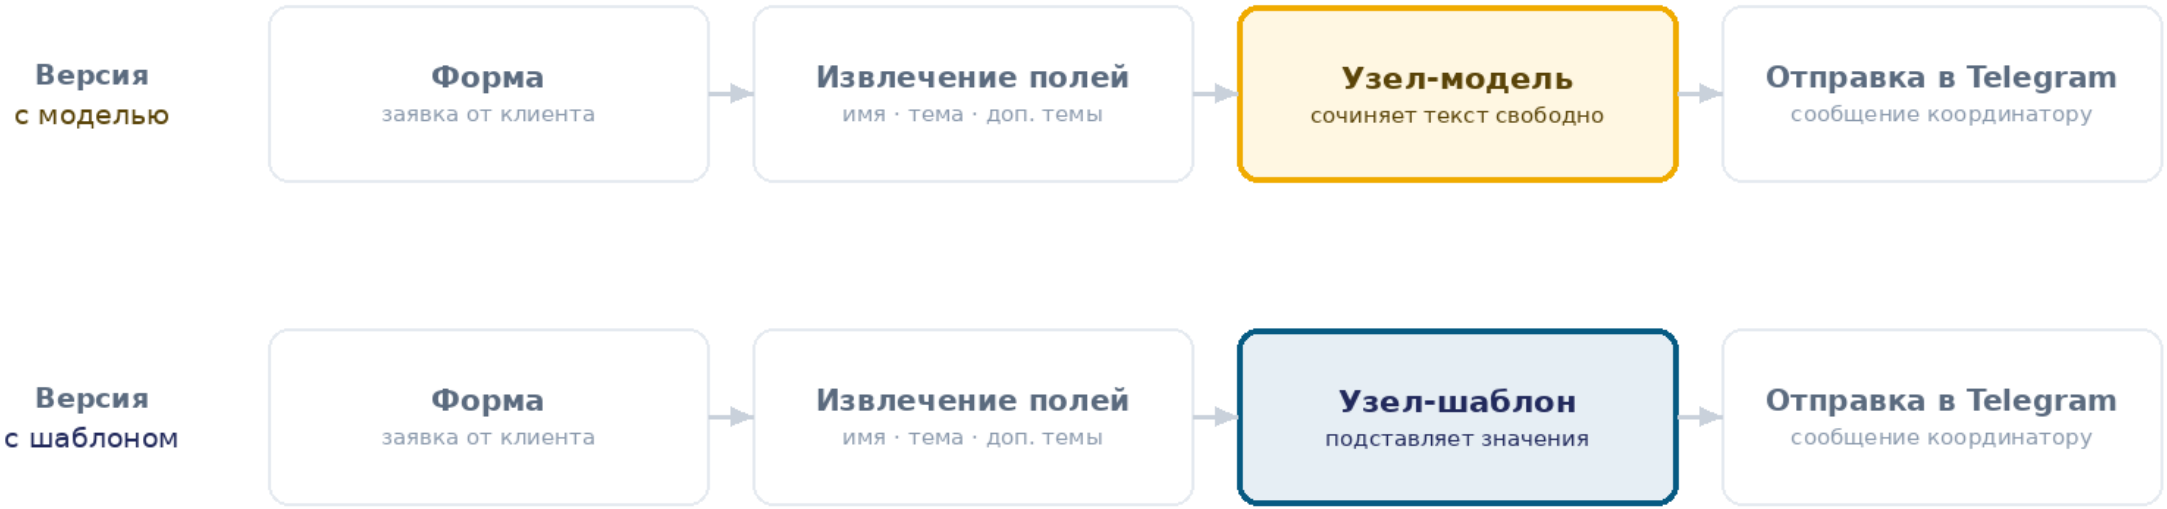
то, что можно закрыть алгоритмом, закрываем им; то, что требует интерпретации текста заявки, на то отдельно зовём модель

берём алгоритмически собранный текст как основу и добавляем к нему одну фразу тона от модели поверх

Что делает каждое действие

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
модель пишет весь текст целиком	получает три уже извлечённых значения и сочиняет текст уведомления свободно, без заданной формы	текст звучит живо — модель умеет писать по-человечески	значения уже извлечены, интерпретировать нечего; а текст собирается заново на каждом прогоне, с риском вписать деталь, которой в заявке не было
алгоритм заполняет форму целиком	подставляет три уже структурированных значения в один раз заданный шаблон текста, без обращения к модели	результат детерминированный: совпадает с заданным примером текста на любой заявке, не только на удачной	нет пространства для вариативности: если форме сообщения однажды понадобится меняться по смыслу, а не только по значениям, выражение придётся переписывать руками
алгоритм + модель на то, что требует интерпретации	структурированные значения подставляются алгоритмом; то, что осталось неструктурированным и требует интерпретации текста заявки, отдельно передаётся модели	работало бы честно при смешанном случае: когда хотя бы одно значение требует интерпретации, а не просто известно	для этой конкретной потребности интерпретировать нечего: все три значения, включая срочность, уже извлечены структурно на прошлом занятии — модели здесь просто не находится работы
алгоритм + тон модели поверх	алгоритмический костяк текста собирается подстановкой значений, модель добавляет сверху одну короткую фразу тона или комментария	масштаб свободы меньше, чем у первого действия — риск и цена вызова модели пропорционально ниже	риск той же природы, что у первого действия, просто меньшего размера: модель всё равно генерирует текст и может вписать в него деталь, которой не было

Архитектура: один узел против другого

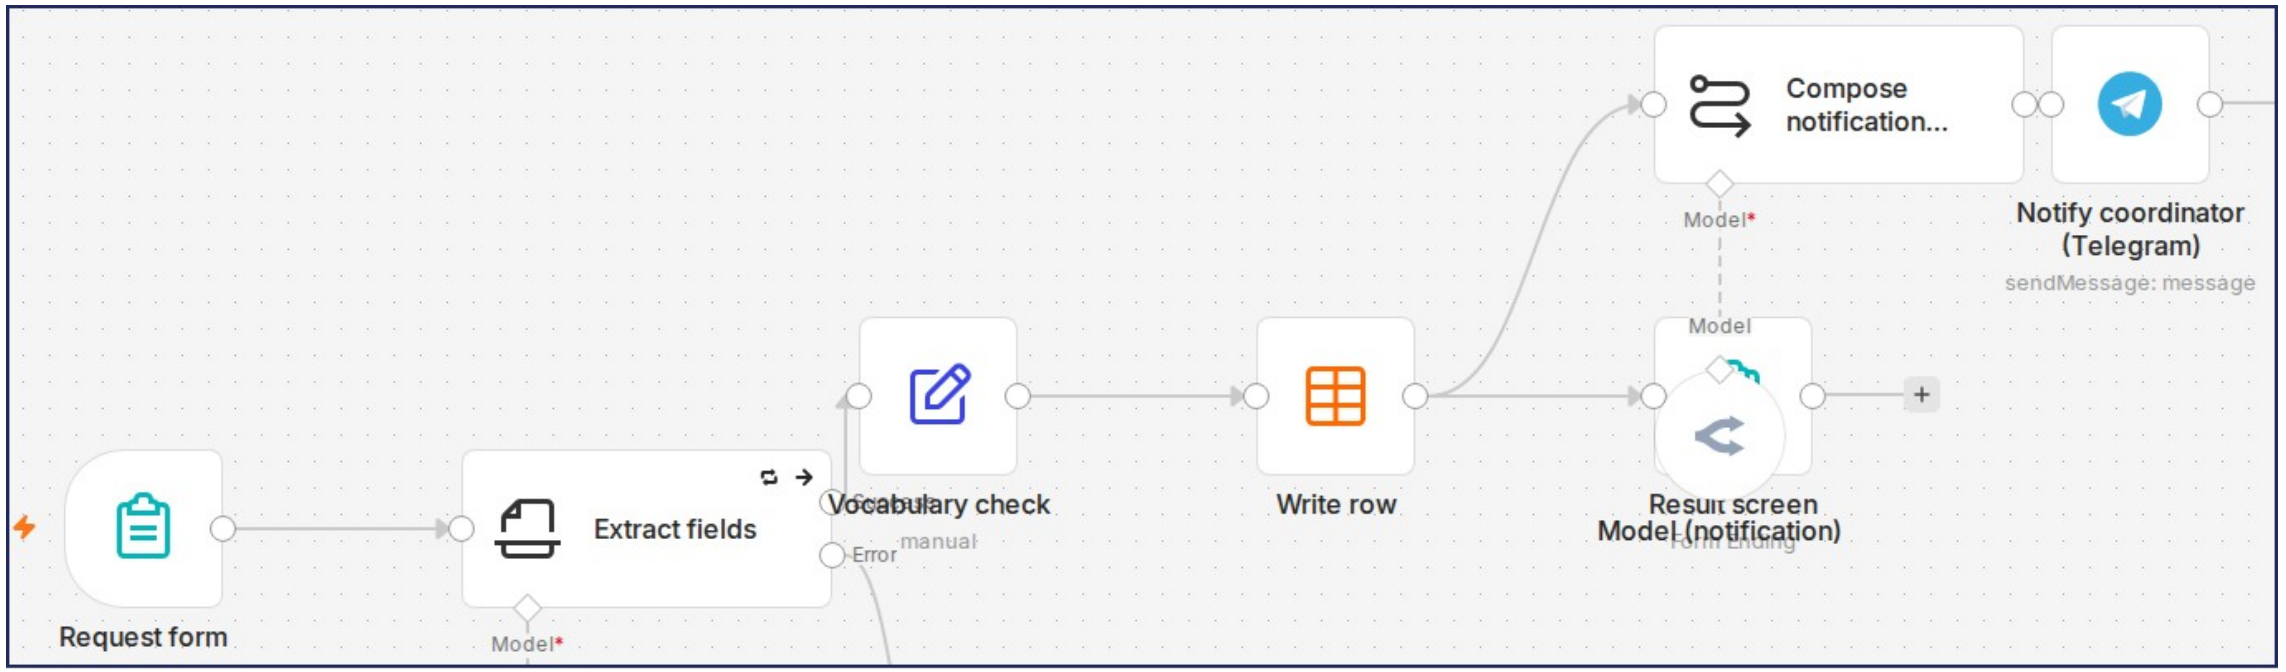


Различие — ровно один узел из четырёх; остальные три одинаковы.

В верхней строке форма текста выбирается заново на каждой заявке, в нижней — выбрана один раз.

Решение о форме текста принимается либо заново на каждой заявке, либо один раз заранее. Всё остальное — те же три узла в том же порядке.

Версия с моделью на стенде: путь и настройка узла



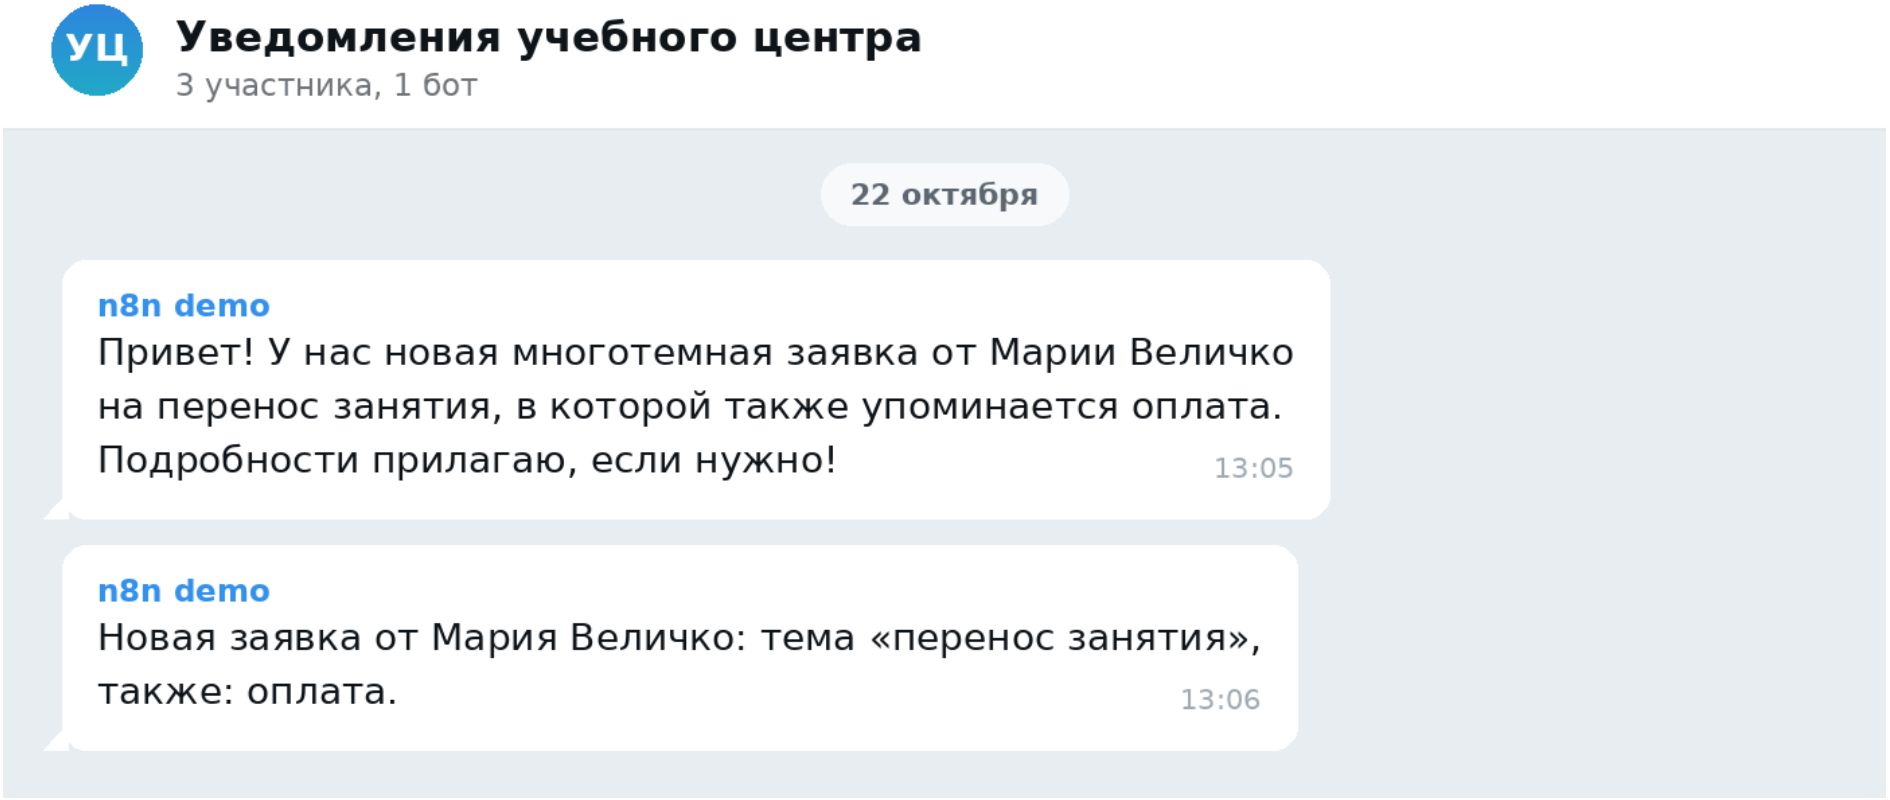
Prompt (User Message)

```
Напиши короткое дружелюбное уведомление координат
ору учебного центра в Telegram о новой многотемно
й заявке. Имя заявителя: {{ $('Request form').ite
m.json['Имя'] }}. Основная тема: {{ $('Vocabulary
check').item.json.topic }}. Также в заявке упом...
то: {{ $('Vocabulary check').item.json.extra_to
```

Require Specific Output Format

Enable Fallback Model

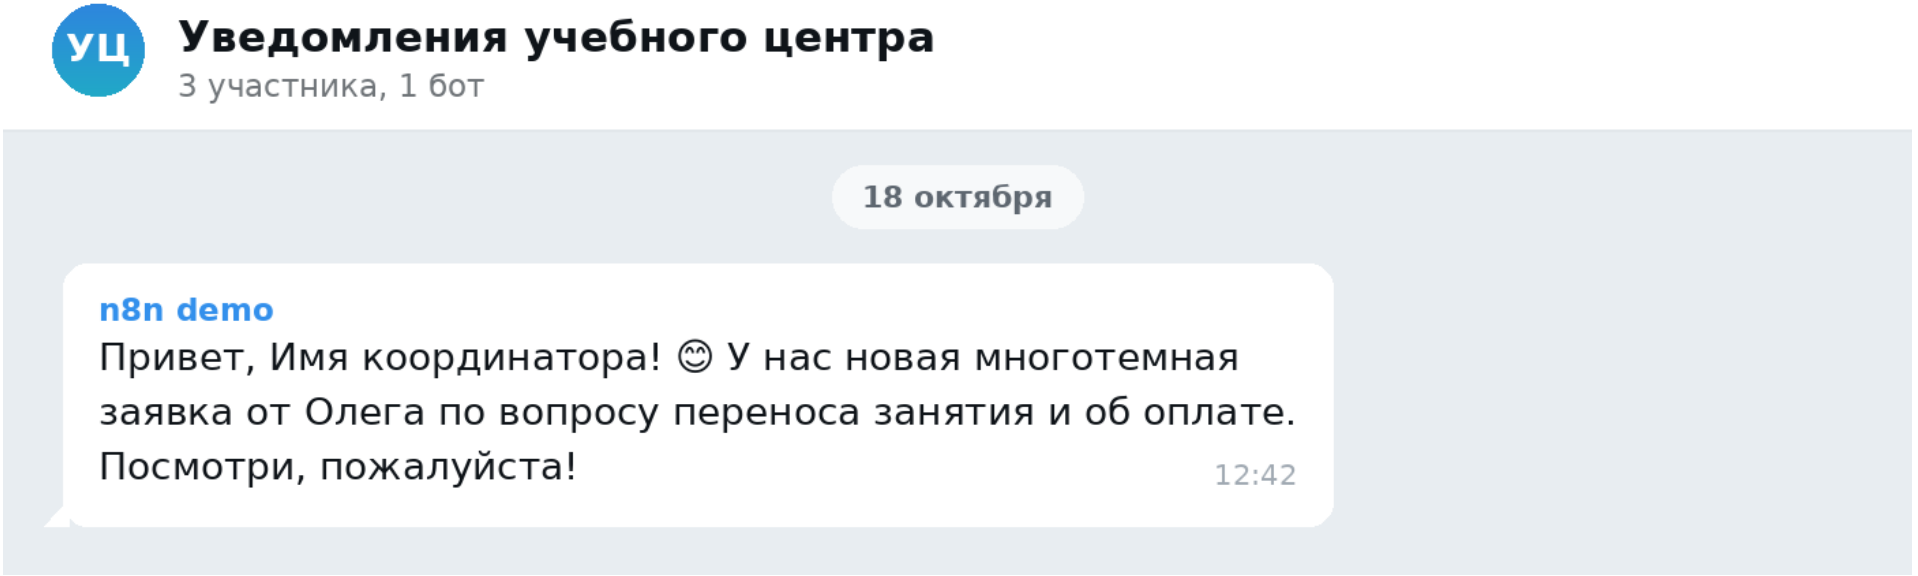
Как сообщение выглядит у Ольги в телефоне



Одна и та же заявка, два настоящих прогона подряд: верхнее сообщение сочинила модель, нижнее собрал шаблон из тех же трёх значений.

Имя: у модели — «от Марии Величко», у шаблона — «от Мария Величко». Подставить поле шаблон умеет, склонять — нет.

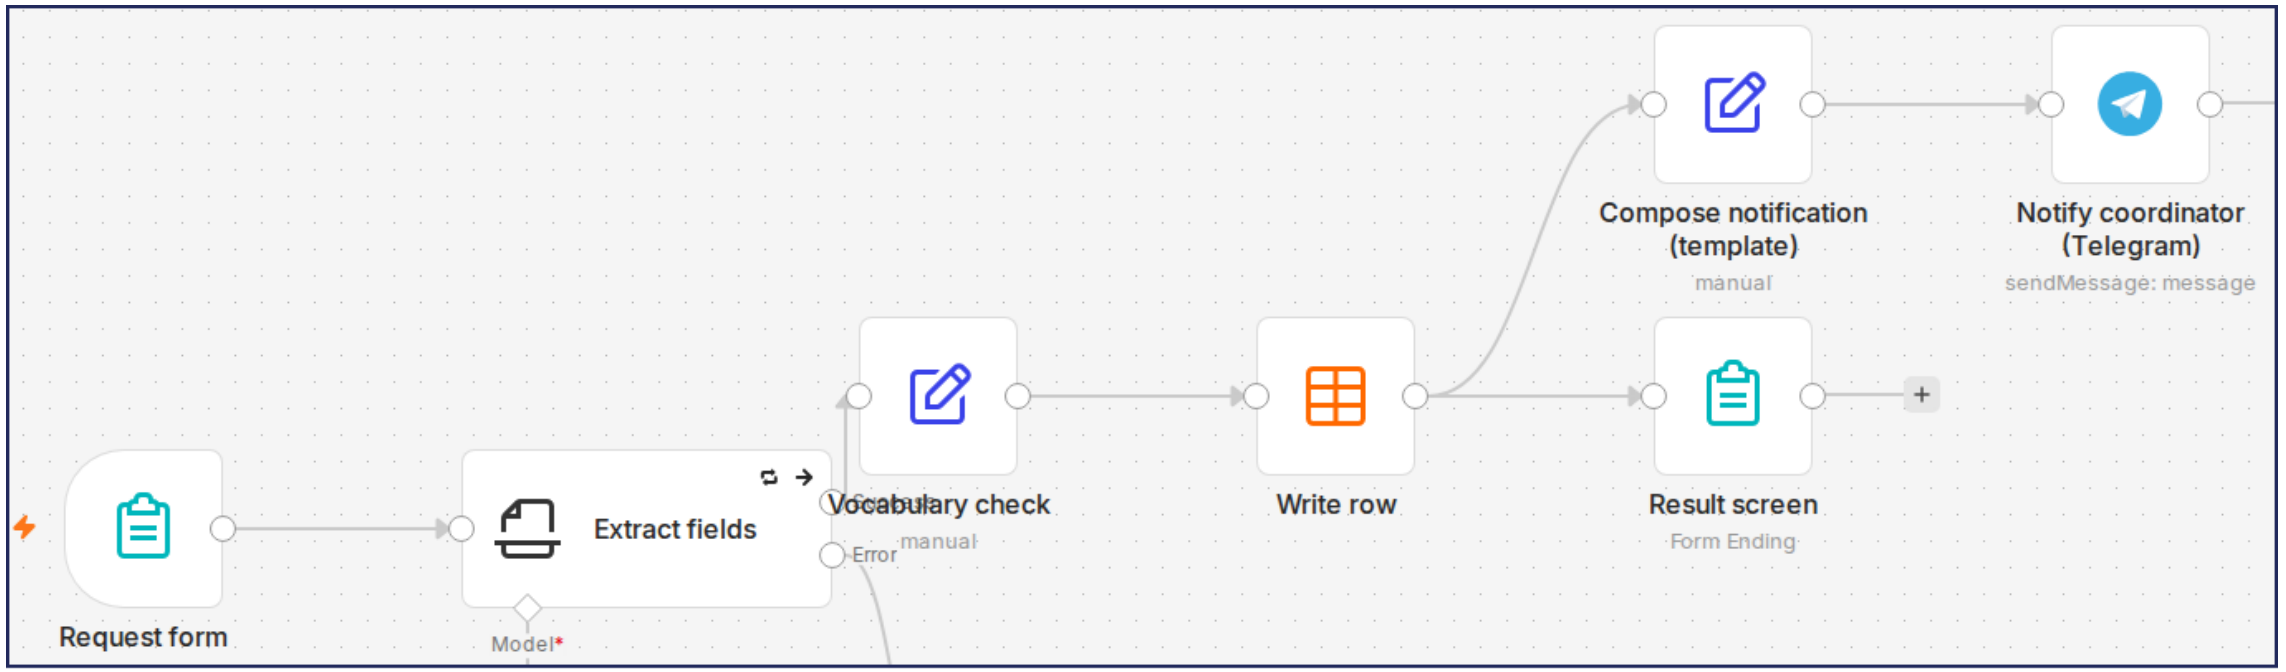
Что реально получилось на двух прогонах



ТЕКСТ ЗАЯВКИ	ЧТО ПОЛУЧИЛОСЬ И ПОЧЕМУ
Мария: «хочу на курс по аналитике и ещё спросить про оплату, перезвоните сегодня»	Текст свободный, но по смыслу тот, что просила Ольга: модели хватило инструкции и трёх значений.
Олег: «хочу перенести занятие на пятницу и спросить про оплату курса»	Сообщение на кадре выше: модель обратилась к человеку словами из собственной инструкции. Узел не упал, статус зелёный.

Проверка форматом этого не ловит. Оба прогона технически успешны: оба узла отработали, оба сообщения дошли. Единственный способ заметить разницу — прочитать сам текст, который получил живой человек.

Версия с шаблоном на стенде: путь и настройка узла



notification_text

String

```
Новая заявка от {{ $('Request form').item.json['Имя'] }}: тема «{{ $('Vocabulary check').item.json.topic }}»{{ $('Vocabulary check').item.json.extra_topics ? ', также: ' + $('Vocabulary check').item.json.extra_topics : '' }}.
```

Include Other Input Fields

Input Fields to Include

All

Когда нужна модель, когда достаточно шаблона

Класс задачи — сборка сообщения из уже извлечённых значений по фиксированной форме. Признак, по которому вы узнаете её в своей цепочке: шаблон итогового сообщения можно написать, не видя ни одной конкретной заявки.

НЮАНС

Лишний шаг — риск, а не только цена

Шаблон не навсегда безопасен

ЧТО ЭТО ЗНАЧИТ

Каждый вызов модели — точка, где может появиться галлюцинация, даже в тривиальной задаче форматирования.

Если форма сообщения начнёт требовать реальной вариативности (разные языки, разная степень детализации), шаблон придётся переписывать руками на каждый новый случай — цена другого типа, инженерная.

Критерий. Модель нужна при реальной вариативности контента или когда значение требует интерпретации текста, которой не было на предыдущем шаге. Шаблон достаточен, когда форма сообщения одна и все значения уже структурированы.

Первая строка оси закрыта. Сообщение действительно ушло координатору — а цепочка оказалась короче и дешевле без узла модели. LLM здесь был просто лишним шагом: то же самое получилось шаблоном, без его цены и риска.

Кейс 2. Проверка на повтор

«Это ведь тот же вопрос, с которым он писал два часа назад?»

Заявки дублируются

1. Понедельник, утро. Ольга, администратор учебного центра, открывает таблицу заявок и видит вопрос от клиента: «когда можно оплатить занятие?» Она отвечает.
2. Через два часа — вторая заявка от того же контакта: «как мне внести оплату за курс». По смыслу это тот же вопрос. Ольга не узнаёт перефразировку и обрабатывает её как новую: отвечает ещё раз.
3. Клиент получает два разных ответа от центра с разницей в два часа — и это выглядит так, будто первый ответ потерялся.

Это не редкость. По собственной оценке Ольги, такие повторы случаются примерно 10 раз в день: кто-то забыл, что уже спрашивал, кто-то не увидел ответа и переспросил другими словами.

Цена ошибки не абстрактная. Двойная работа администратора — плюс недоверие клиента: «они не видят, что я уже спрашивал?»

Как построить проверку на повтор

Как построить проверку на повтор?

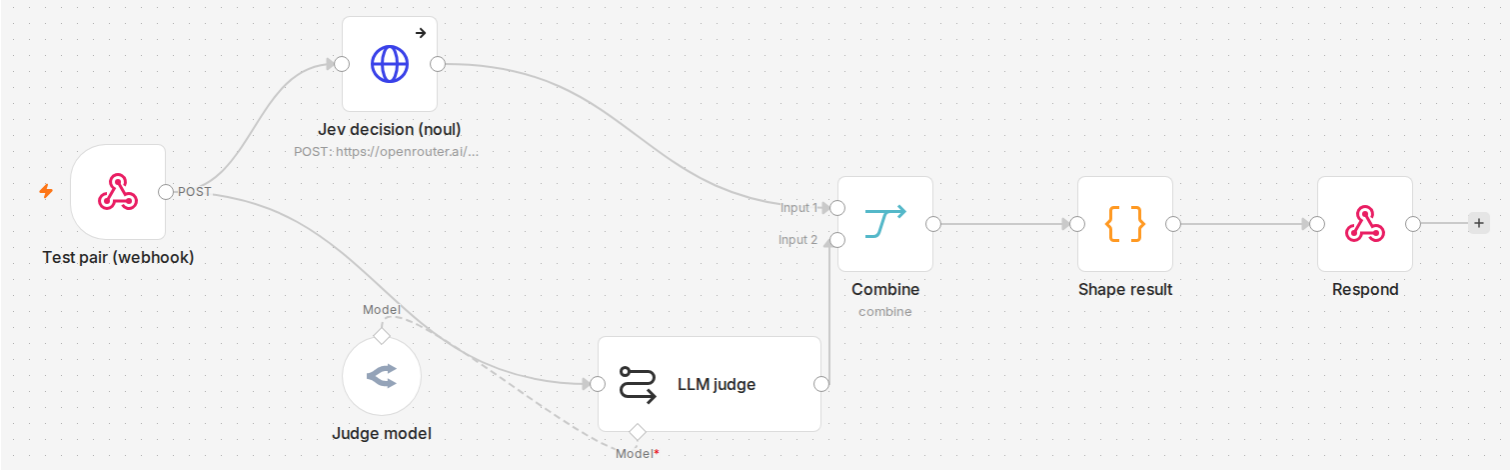
- сравнивать тексты буквально — точное совпадение после нормализации
- сравнивать тексты по общим словам — классический векторный подход с порогом
- спросить у модели общего назначения, один ли это вопрос, просто сформулированный иначе
- спросить у специализированного сервиса сравнения вопросов, а не у модели общего назначения
- сначала проверить точное совпадение дёшево, а дальше пускать только то, что осталось

Что поймала каждая схема

СХЕМА	ВЕРНО ИЗ 20	ЧТО ПОЙМАЛА	ЧТО ПРОПУСТИЛА / ГДЕ ОШИБЛАСЬ	СТОИМОСТЬ (ОЦЕНКА ПО ПРАЙСУ)
Хэш (точное совпадение)	**15/20**	все 5 повторов и все 10 разных	все 5 перефразировок	дёшево и мгновенно, без вызова модели
TF-IDF + косинус (порог 0,3)	**13/20** — хуже хэша	повторы, часть разных вопросов	те же 5 перефразировок + 2 ложных срабатывания на близких темах	дёшево и мгновенно, без вызова модели
Модель-судья (gpt-4o-mini)	**17/20**	все 10 дублей	3 ложных срабатывания, включая пару без общих слов	~$0,15/млн вход · $0,60/млн выход; на кейсе (≈300/мес) ≈$0,006/мес
Сервис jev	**20/20**	все 20	ошибок нет	$0,042/млн вход, $0 выход; на кейсе ≈$0,003/мес

jev — внешний сервис типизированных решений: отвечает только в заданной форме (да/нет, выбор, шкала), не свободным текстом.

Честная находка. Одно измерение на 20 парах мало, чтобы менять работающую архитектуру; обе платные схемы дешевле цента в месяц — решает точность.



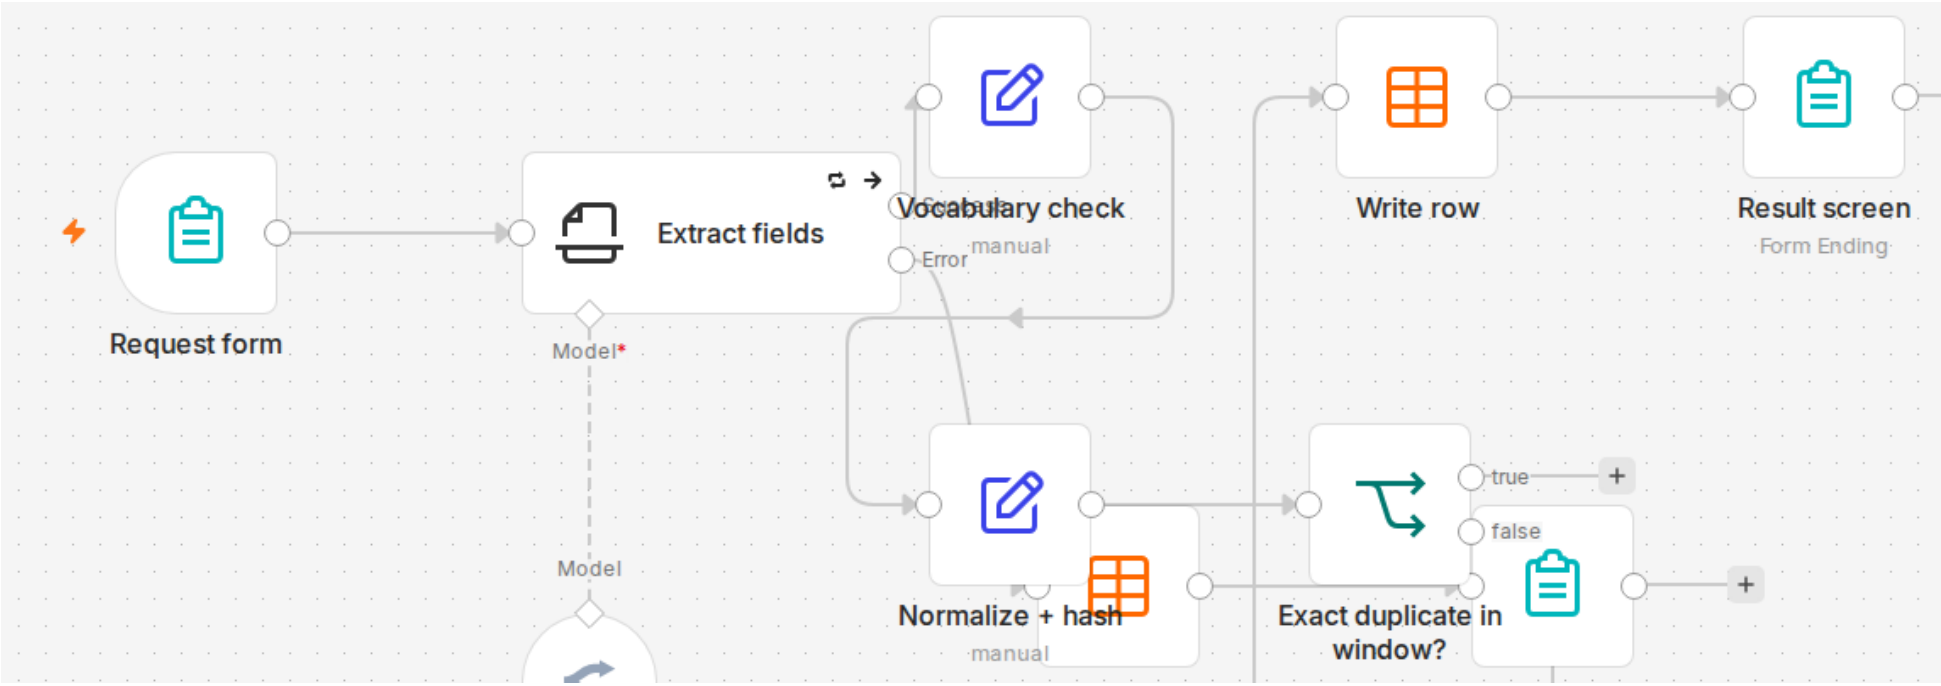
Решение: хэш первым, jev — на дорогом шаге



Фигура: шаг 1 — дешёвый механический предфильтр, берёт на себя буквальные повторы бесплатно. Шаг 2 — проверка смыслом, решение по измерению — специализированный сервис (jev), точнее и дешевле модели общего назначения на этом тесте. Узел собран и стоит на стенде.

Честная оговорка — на самой схеме. *Измерение одно, на 20 парах одного языка и одной тематики (запись на курсы). Обобщаемость за пределы этого набора не проверена — это граница измерения, а не повод не внедрять решение.*

Настройка: нормализация и точное совпадение



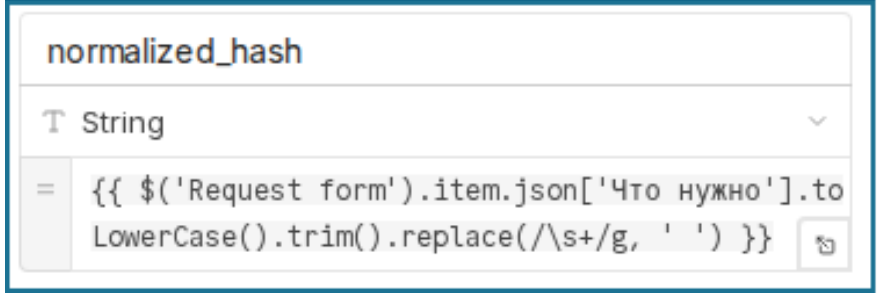
Узел `Normalize + hash (Set)`. Берёт текст заявки, приводит к нижнему регистру, убирает пробелы по краям, схлопывает повторные пробелы внутри: `normalized_hash = текст.toLowerCase().trim().replace(/\s+/g, ' ')`. Рядом — тот же расчёт для недавнего сообщения того же контакта.

Узел `Exact duplicate in window? (IF)`. Условие: `normalized_hash` строго равен хэшу недавнего обращения — строковое сравнение, оба значения уже в нижнем регистре. Совпало → повтор найден, гасится бесплатно, без записи. Не совпало → заявка идёт дальше по цепочке.

Панели настройки: нормализация и точное сравнение

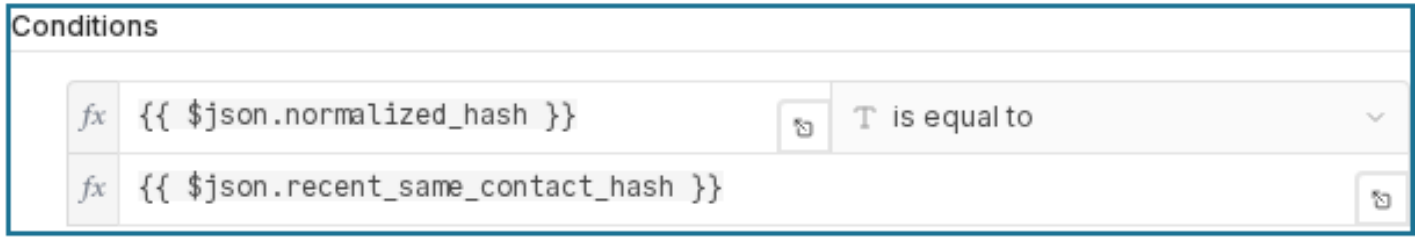
Узел «Normalize + hash» (Set)

Поле normalized_hash: нижний регистр, пробелы схлопнуты



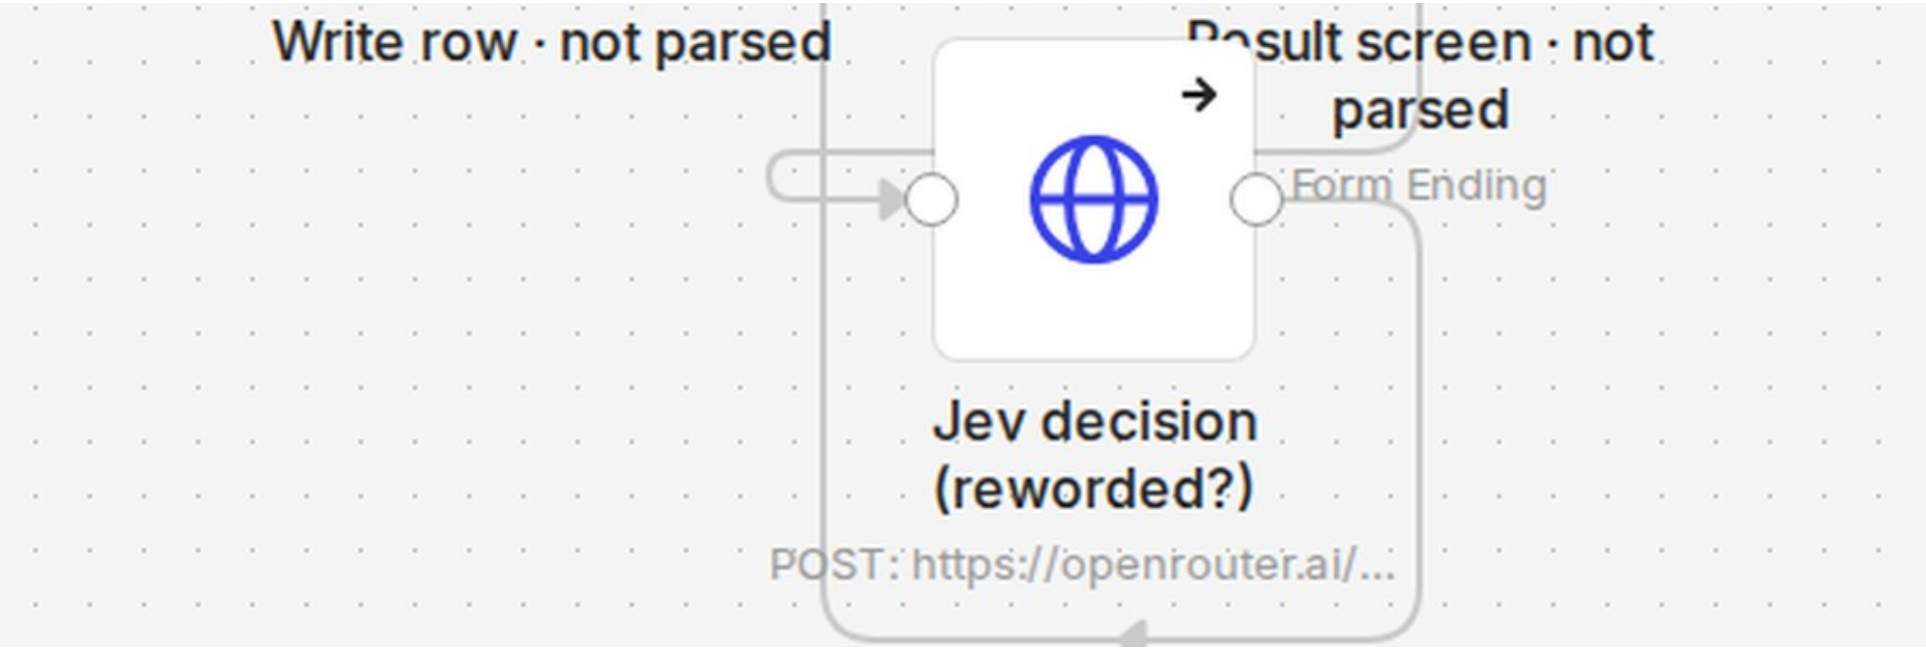
Узел «Exact duplicate in window?» (IF)

Одно условие: хэш равен хэшу предыдущей заявки



Весь дешёвый слой — это одна строка приведения текста к общему виду и один знак равенства. Ни модели, ни порога, ни настройки, которую можно подобрать неудачно.

Настройка: структурированный запрос вместо текстового промпта



Узел `Jev decision (reworded?)` (`httpRequest`). `POST .../api/alpha/decisions`, модель `typesafe/jev-1.13`. Вопрос — тип `noul`: «да/нет» с вероятностью, не свободный текст. Критерии заданы явно: «да» — тот же вопрос другими словами, «нет» — другой вопрос, даже если похожи темы или слова.

Результат на 20 реальных парах. Дубли — jev_noul 0.70–0.97. Разные вопросы — 0.02–0.08. Порог ≥ 0.5 → дубль, разрыв чистый на промежутке 0.08–0.70 — счёт 20 из 20.

Что видит Ольга при повторной заявке — и чего не видит

id	received_at	name	contact	request_text
⋯ строки 1–14 той же страницы таблицы пропущены ⋯				
15	2026-10-12T17:40:23.803+03:00	Пётр	petr@example.com	Здравствуйте! Хочу записаться на к
16	2026-10-13T18:45:32.489+03:00	Пётр	petr@example.com	Здравствуйте! Хочу записаться на к
17	2026-10-15T10:15:01.752+03:00	Анна	anna@example.com	Можно перенести занятие со вторни
18	2026-10-15T10:15:01.767+03:00	Анна	anna@example.com	Можно перенести занятие со вторни
19	2026-10-15T10:15:40.859+03:00	Анна	anna@example.com	Можно перенести занятие со вторни
20	2026-10-15T10:15:40.873+03:00	Анна	anna@example.com	Можно перенести занятие со вторни

15 и 16 — один человек, один текст слово в слово. Между ними сутки.

17–20 — тот же текст ещё четырежды: две пары, внутри каждой меньше двадцати миллисекунд. Так выглядит двойной щелчок по кнопке формы.

Даты на кадре старше проверки на повтор: все эти строки записаны до того, как она появилась в цепочке. Пометки «похоже на повтор» в таблице нет и не будет — колонки под неё не существует, и ответ проверки смыслом никуда не сохраняется. Буквальный повтор с проверкой до таблицы больше не доходит; тот же вопрос другими словами доходит — и ложится строкой, неотличимой от первой.

Механика и смысл — разные инструменты, не версии друг друга

Системный приём. Точное совпадение остаётся в финальном решении — но как первый дешёвый фильтр, экономящий 5 из 20 вызовов модели бесплатно, не как альтернатива LLM.

Дальше по курсу. На Семинаре 10 эта же механика — сравнение смысла заявок — расширяется до поиска ответа в базе знаний.

Нюансы проверки на повтор

1. **Интервал времени — параметр с ценой в обе стороны.** Слишком короткий интервал пропустит повтор, разнесённый на день-два. Слишком длинный начнёт путать разные последовательные обращения одного человека с повтором одного обращения.

2. **У модели-судьи своя асимметрия ошибок**, не ноль (Wataoka, Takahashi, Ri — NeurIPS 2024 Safe GenAI Workshop, arXiv:2410.21819, self-preference bias): модель-судья систематически не нейтральна, даже отвечая формально «да» или «нет». Наш тест это подтвердил напрямую: 3 ложных срабатывания из 20, и не все объясняются совпадением слов в вопросах.

3. **«Что считать дублем» — продуктовое решение, не только техническое.** Иногда «тот же вопрос другими словами» стоит обработать как новое обращение — человек ждёт ответа срочнее второй раз. Не всякий технический повтор должен схлопываться в один в интерфейсе.

Когда точного совпадения достаточно

ТОЧНОГО СОВПАДЕНИЯ ДОСТАТОЧНО

повторы в основном буквальные, как первый вопрос Бориса

нужен бесплатный и мгновенный фильтр на весь поток заявок

классический векторный подход не стоит добавлять «на всякий случай» — измерение показало результат ХУЖЕ хэша, не тот же самый

ПРОВЕРКА СМЫСЛОМ НУЖНА СВЕРХУ

ожидаются переформулировки, как его второй вопрос

цена необнаруженного дубля выше цены одного вызова модели на спорные случаи

частота ошибок самой модели — измеренная цена (у нас 3 ложных срабатывания из 20), а не ноль, и её тоже нужно закладывать

ни хэш, ни классический векторный подход не решают переформулировку на русском языке целиком сами по себе

конкретный инструмент смысловой проверки — тоже выбор: дешёвая модель общего назначения (17/20 на нашем тесте) или специализированный сервис jev (20/20) — не угадывается по умолчанию, нужна своя проверка

Закрывает строку оси. Выглядело надёжным: заявка про тот же вопрос пришла снова — обработали как новую. Чем оказалось: без проверки на дубль каждое повторное обращение запускает цепочку с нуля; ни хэш, ни классический векторный подход не решают это целиком для живого русского текста — нужна модель, с её собственной, измеренной ценой ошибки.

Кейс 3. Одобрение возврата

Месяц в работе. Ни одной жалобы. Сколько раз правило ошиблось — не знает никто.

«Автоматический возврат средств — до заданного порога суммы. Выше порога — только через руководителя.»

Версия 1: продолжение процесса классификации

Та же форма обращения, которой мы уже пользовались в предыдущих кейсах: человек описывает ситуацию своими словами — «прошу вернуть 2500 рублей за пропущенное занятие».

1. Человек пишет заявку свободным текстом — внутри него и просьба, и сумма.
2. Процесс, который в Семинаре 7 определял тему обращения, здесь идёт на шаг дальше: читает текст и сам решает — одобрить сумму автоматически или передать её руководителю (модель `qwen/qwen-2.5-7b-instruct`).
3. Решение «одобрить» — деньги автоматически уходят на карту клиента, без участия человека.
4. Решение «эскалировать» — заявка уходит руководителю, и дальше решает он.

На чём стоит доверие. Версия работает уже месяц. Никто не пожаловался, что одобрено то, что следовало эскалировать, или наоборот. Команда считает правило надёжным — и ровно на этом основании: ничего плохого не заметили.

Как добиться, чтобы решение о пороге не ошибалось

Как добиться, чтобы решение о пороге никогда не принималось неверно?

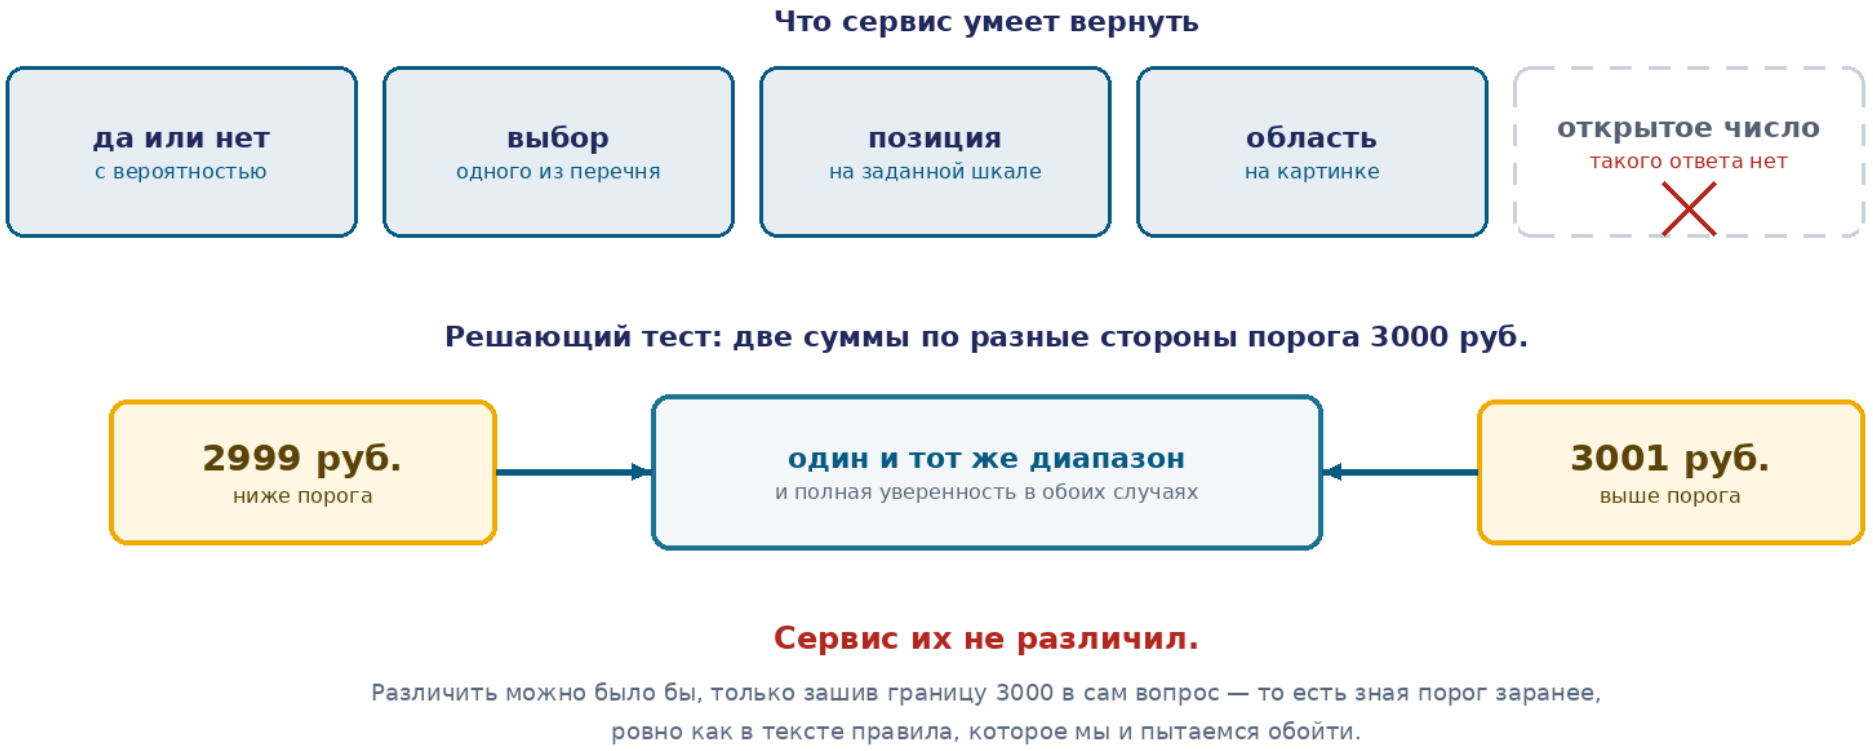
- написать правило яснее в промте
- дать модели инструмент-калькулятор для сравнения сумм
- поставить IF-узел после извлечения суммы
- сделать сумму явным числовым полем формы

Что даёт каждое из четырёх действий

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Написать правило яснее в промте	Переформулировать правило, явно развести «≤3000 → одобрить» и «>3000 → эскалировать»	Измерено: версия 1 ошибалась 9/101 на границе, уточнённая формулировка — **100/100** на расширенном наборе	Факт на конкретном наборе/модели, не структурная гарантия — решение всё ещё текстовое, не код; другая формулировка или модель может разойтись снова
Дать модели инструмент-калькулятор	Модель получает функцию сравнения чисел вместо сравнения «в уме» и сама решает, вызывать её или нет	В теории разделяет извлечение числа и сравнение на две операции	Модель сначала извлекает сумму из текста — тот же вероятностный шаг, затем сама решает, вызывать ли инструмент: вероятностность не исчезает, переезжает раньше. Измерено: **56/100** — хуже всех; калькулятор не умеет сравнений (11/100 отказов), 30/100 ответов не сводятся к слову, 9/100 ошибок разбросаны по диапазону
Поставить `IF`-узел после извлечения суммы	Сумму достаёт модель, сравнивает с порогом код — условие, не текстовый вызов	Устраняет вероятностность из точки решения. Измерено: **0/101** на расширенном наборе, включая граничные случаи	Сумму всё ещё извлекает модель — ошибка извлечения (не сравнения) этим узлом не закрыта, хотя на наборе её не нашлось
Сделать сумму явным числовым полем формы	Собирать сумму цифрами в поле заявки — не извлекать из текста вовсе	Устраняет неопределённость раньше: извлекать нечего — риска неверного извлечения нет	Работает только если форму можно менять; письмо/чат/другой канал всё равно требует извлечения из текста. Метрика — применимость, не точность: шага извлечения нет, точности тоже

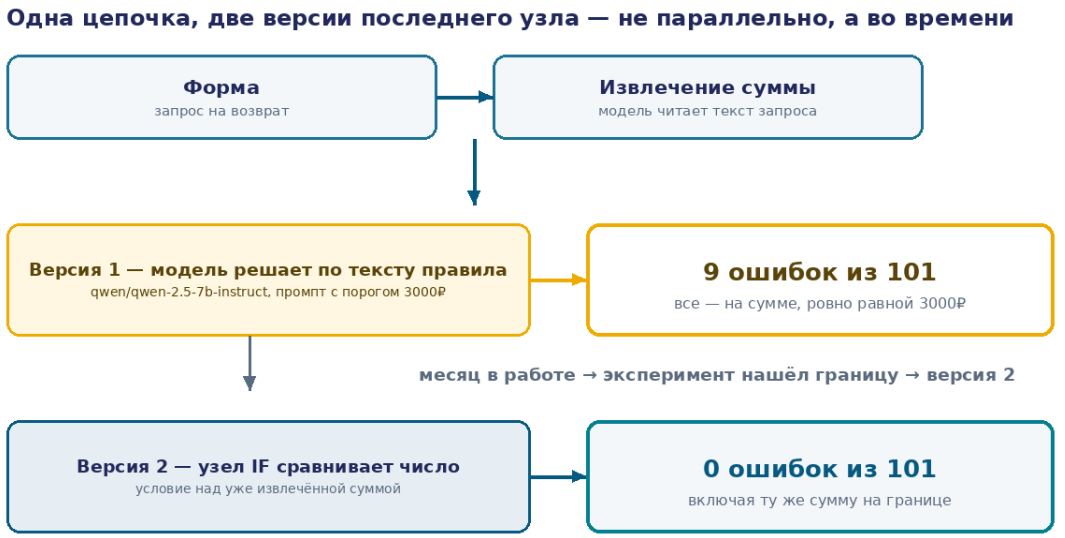
Мостик дальше. Одно действие измеримо исправило конкретную находку, одно измеримо провалилось, одно устраняет риск структурно и подтверждено измерением, одно меняет вход раньше решения и не нуждается в метрике точности. Какое из них нужно здесь, показывает измерение — то самое, что уже стоит в этой таблице. Следующий такт — как оно было устроено.

Проверка идеи: сервис jev для извлечения суммы



Урок. Сначала проверяют, что сервис умеет делать то, что от него хотят. Проектируют шаг вокруг него только потом.

Версия 2: тот же путь, одна точка меняется



Версия 1 (было). Форма со свободным текстом → модель извлекает сумму → модель же решает по тексту правила → результат.

Версия 2 (стало, прямой ответ на находку эксперимента). Та же форма → модель извлекает сумму → `IF`-узел сравнивает число с порогом → результат.

Цепочка не перестроена. Разница — ровно в одном узле, том самом, где раньше принималось решение. Всё остальное — форма, извлечение суммы, дальнейшая маршрутизация заявки — осталось тем же.

Проверка на практике, а не на веру

Жалоба — не мера: тихая ошибка её не вызывает. Поэтому правило, месяц работавшее без единой жалобы, прогнали спроектированным набором из 101 запроса — 51 исходный плюс 50 сложнее: у самой границы, с двумя числами в тексте, с суммой, которую надо посчитать. Правильность каждого прогона читают из его данных, а не на глаз.





Сколько ошибок на 101 запросе

9 из 101

правило в промте (версия 1)

0 из 101

условие в коде (версия 2)

И все девять — на сумме ровно 3000 руб.

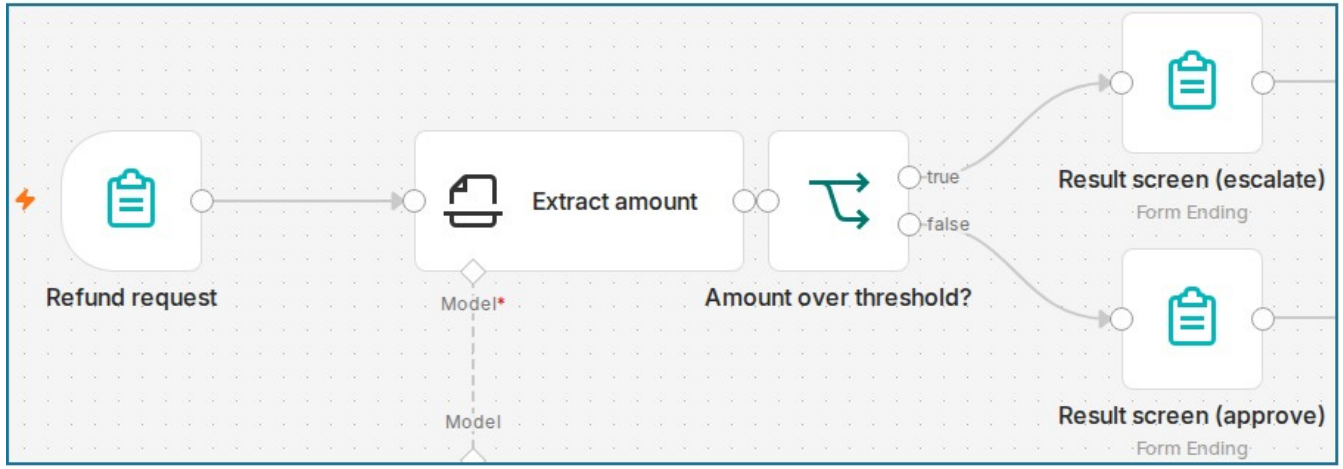
Результат: 9 ошибок из 101, и все девять в одной точке

БЛОК ТЕСТА	ЗАПРОСОВ	ОШИБОК В.1	ОШИБОК В.2	ПРИМЕР ЗАПРОСА
У границы и ниже (1000–3000 руб.)	25	**3** (= 3000 руб.)	0	«можно возврат 3000 рублей за один пропуск?»
Явно выше (3200–9000 руб.)	25	0	0	«возврат 3200 рублей, иначе буду писать жалобу»
Ручной тест	1	0	0	текст не сохранён как данные
У самой границы (±20 руб. от 3000 руб.)	15	0	0	«прошу вернуть 2999 рублей, занятие отменили в последний момент»
Два числа в одном тексте	20	0	0	«курс обошёлся в 12000 руб., хочу возврат 2400 рублей за один блок»
Непрямая формулировка (арифметика/«около»)	15	**6** (= 3000 руб.)	0	«занятие стоило 1500 рублей, прошу вернуть за два таких занятия»
Итого	**101**	**9**	**0**	

Что решила модель на границе. На сумме ровно 3000 руб. — в любой из формулировок, прямой или арифметической, — модель версии 1 отвечала «эскалировать», хотя правило («не возвращай больше 3000 рублей») подразумевает, что сама граница — «можно одобрить». Все 9 ошибок без исключения — на этой одной сумме; ни одна ошибка не случилась ни на 2999 руб., ни на 3001 руб., ни где-либо ещё в диапазоне.

Настройка: IF-узел против текста правила

Узел «Amount over threshold?» (IF) — версия 2
Условие в коде: число сравнивается с числом



Узел «Decide refund (model)» — версия 1
Правило — внутри текста промпта

Source for Prompt (User Message)

Define below

Prompt (User Message)

```
Правило: не возвращай больше 3000 рублей автомати
чески, иначе эскалируй руководителю. Сумма запрос
а: {{ $json.output.amount_rub }} рублей. Ответь ст
рого одним словом: «одобрить» или «эскалироват
```

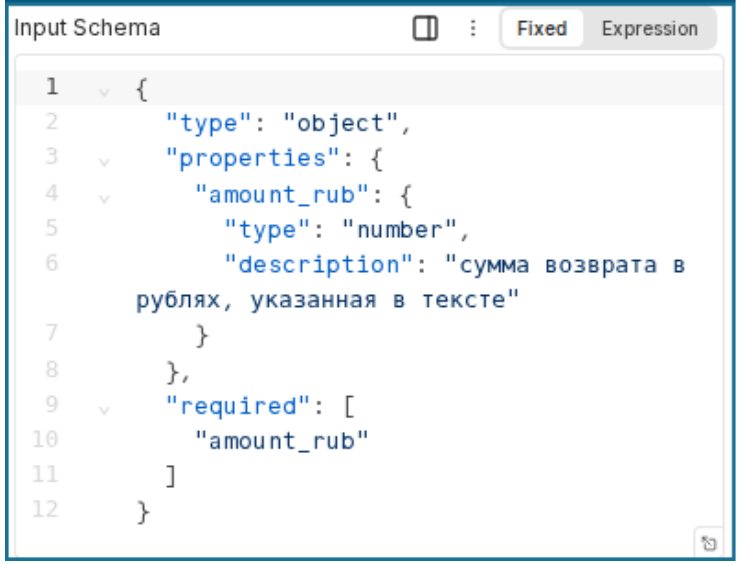
Слева — узел `IF` («Amount over threshold?») на холсте, версия 2. Условие: извлечённая сумма (число) строго больше 3000. Ветка «да» → эскалировать руководителю. Ветка «нет» → одобрить. Сравнение — операция над числом, не текст, который нужно понять.

Справа — настоящая открытая панель узла `Decide refund (model)`, версия 1. Поле `Prompt (User Message)`: то же правило «не больше 3000 — иначе эскалируй», но как текст, который модель должна прочитать и понять, а не как условие в коде. Экран, а не пересказ.

Панели настройки: «Extract amount» и «Amount over threshold?»

Узел «Extract amount» (Information Extractor)

Схема ответа: одно число amount_rub, обязательное



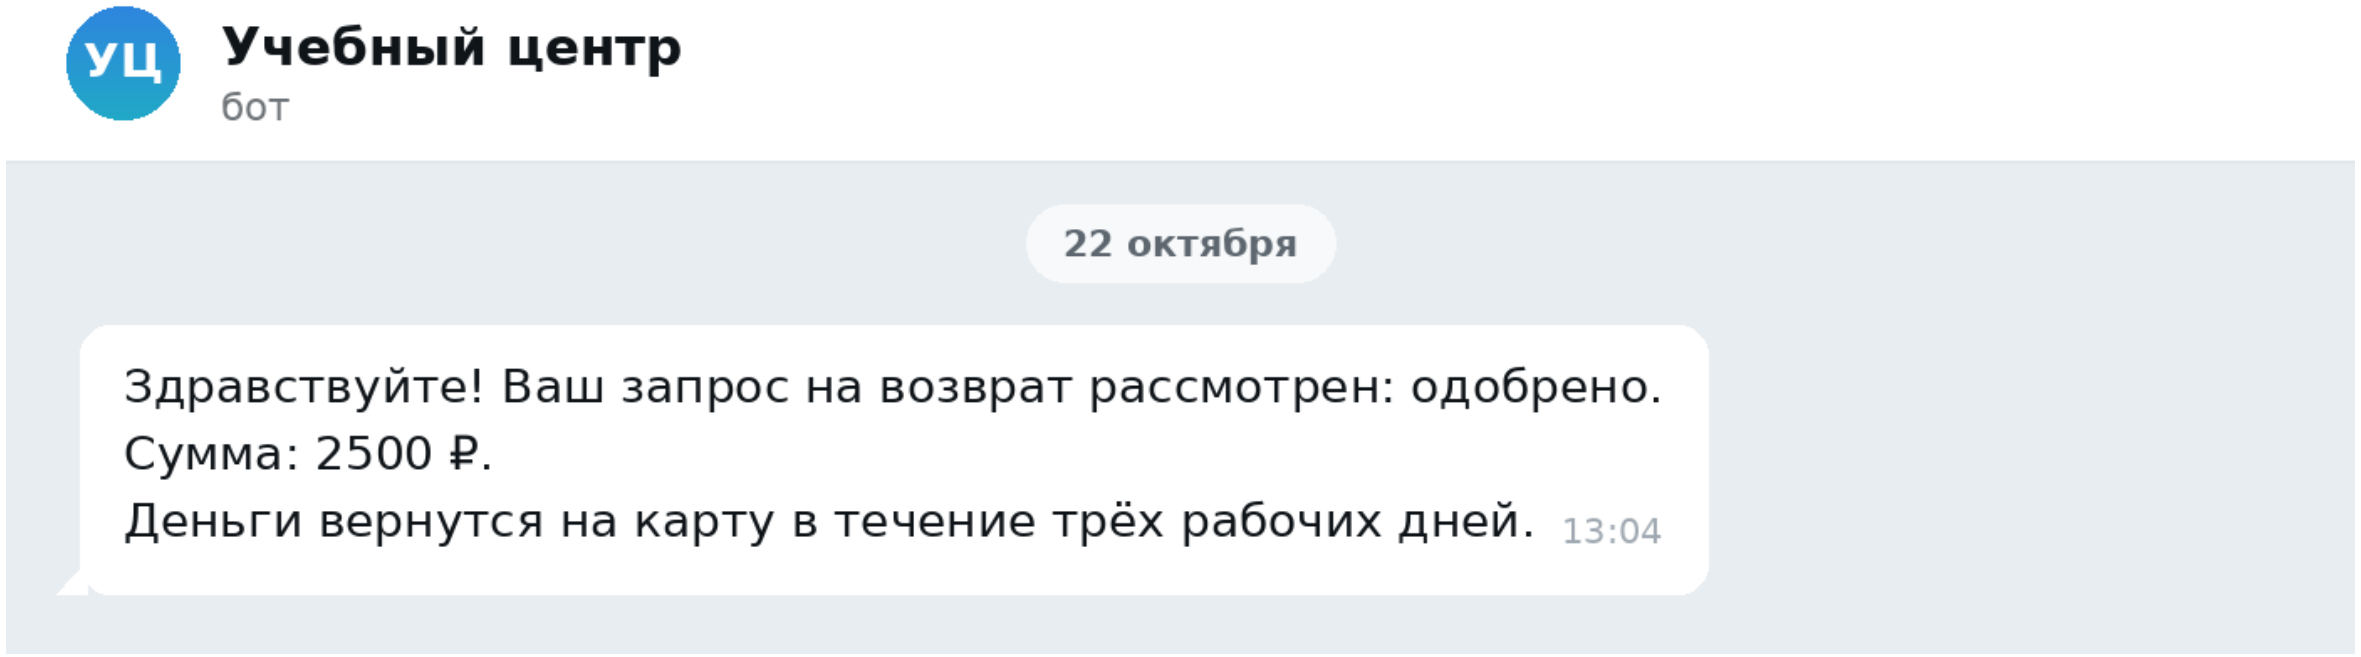
Узел «Amount over threshold?» (IF)

Условие: amount_rub строго больше 3000



Тип ответа задаёт схема, границу задаёт условие. Ни то, ни другое не оставлено тексту, который модель читает заново на каждом прогоне.

Что видит клиент при автоматическом одобрении



Та же заявка, что в сцене кейса, — «прошу вернуть 2500 рублей за пропущенное занятие», пример ниже порога: версия 2 одобряет его сама, без руководителя. Число в сообщении — то самое, которое из заявки достала модель извлечения; клиент видит результат, а не устройство решения.

Разбор версий после теста

	ВЕРСИЯ 1 (ПРАВИЛО В ПРОМТЕ)	ВЕРСИЯ 2 (IF-УЗЕЛ)
Ошибок на 101 запросе	**9** — все на сумме 3000 руб.	**0**
На границе (3000 руб.)	«эскалировать», хотя правило подразумевает «можно одобрить»	«одобрить» — условие `> 3000` не допускает двойного толкования
Вне границы	верно во всех случаях, включая суммы в 20 руб. от границы и тексты с двумя числами	верно во всех случаях

Где решение должно быть кодом

Точная формулировка находки. Не «модель иногда вероятностно ошибается» — точнее: модель систематически промахивается именно на границе условия, там, где текст правила и его формальная интерпретация расходятся, а в остальном диапазоне безупречна.

Класс задачи. Решение, формализуемое как условие над числом, — не задача модели в точке принятия решения. Граничные значения — первое, что нужно проверить прогоном, прежде чем доверять любому похожему правилу.

Три нюанса, прежде чем применять вывод

1. **Инструмент-калькулятор у модели — не гарантия, и на практике измеримо хуже.** Вероятностность не исчезает, она переехала на шаг раньше: вызовет ли модель калькулятор и как передаст в него значения. Измерено: 56 из 100 — хуже всех остальных вариантов, с новыми отказами (смешанный алфавит в ответе, инструмент не умеет сравнений, ошибки разбросаны по всему диапазону).
2. **Порог X — единственный источник правды.** Если он живёт в двух копиях — тексте промпта и условии `IF` — расхождение этих копий — тот же класс проблемы, что рвущийся контракт между шагами.
3. **Модель-экстрактор всё ещё может ошибиться.** Вывод не «модель нигде не нужна», а «модель не должна быть точкой решения»; явное числовое поле формы убирает и эту часть риска — но только если форму самого запроса можно менять, иначе извлечение остаётся задачей модели.

Критерий: когда решение обязано быть кодом

Критерий. Решение обязано быть кодом, когда оно формализуется как условие над уже структурированным значением. Ещё лучше — устранить саму потребность в извлечении, если источник данных можно сделать структурированным с самого начала.

Строка оси закрыта. Решение, оставленное модели, обходило правило в измеренной доле прогонов — девять из ста одного, и ровно на границе условия. Решение, отданное алгоритмическому гейту, — никогда.

Zillow Offers: алгоритмическая закупка жилья

«Непредсказуемость прогнозирования цен на жильё намного превышает то, что мы ожидали… частота ошибок оказалась гораздо более волатильной, чем мы считали возможным.»

Рич Бартон, CEO Zillow, 2 ноября 2021

$304 млн

списание за квартал

~2000 человек

четверть штата

~$80 000

убыток на каждый проданный дом

Тот же порог без гейта, что в «Одобрении возврата», — на масштабе компании.

Кейсы

Как решение о покупке работало на самом деле



Zestimate (алгоритмическая оценка) → решение о покупке без обязательного гейта выше порога риска → покупка исполняется → без короткого периода мониторинга точности (часы-дни) → ошибка накапливается незаметно → видна только в квартальной отчётности перед SEC.

Чего не хватало в контуре решения Zillow

Чего не хватало в контуре принятия решения?

- **откалибровать модель точнее**
- **поставить runtime-мониторинг дрейфа с автоматическим порогом остановки**
- **привязать решение о покупке выше определённой суммы риска к конкретному человеку-андеррайтеру**
- **заранее знать, что рынок жилья поведёт себя непредсказуемо**

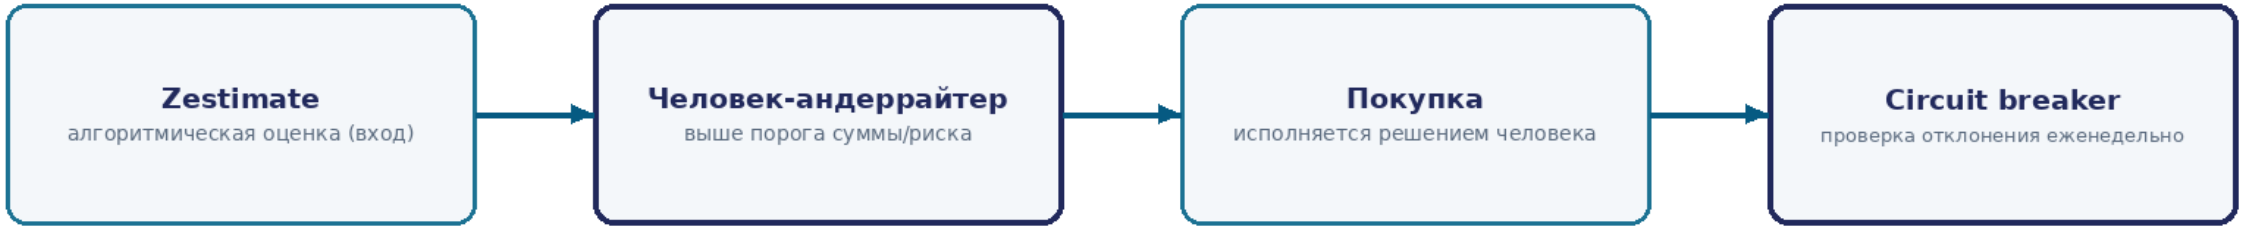
Что решает каждый вариант

ВАРИАНТ	ЧТО ДЕЛАЕТ	ЧЕГО НЕ ДЕЛАЕТ
откалибровать модель точнее	повышает точность на стабильных исторических данных	не относится к находке: модель и так была откалибрована корректно — ошиблась не калибровка, а режим рынка, которого не было в обучающей истории
runtime-мониторинг дрейфа с автоматическим порогом остановки	ловит резкий скачок частоты ошибки за часы или дни, пока убыток ещё маленький	не был поставлен на реальном контуре закупки: единственным контролем оставалась квартальная отчётность перед SEC — архив, а не период наблюдения
привязать решение выше порога риска к человеку-андеррайтеру	возвращает решение с крупной ставкой человеку именно в точке принятия решения	не было сделано структурно: алгоритм решал о покупке дома сам, вне зависимости от суммы риска
заранее знать, что рынок поведёт себя непредсказуемо	—	не инженерное решение, а пожелание: волатильность рынка — внешний факт, которым нельзя управлять на стороне модели

Решающее. Модель не подвела — подвёл контур вокруг неё: не было ни короткого периода мониторинга, ни структурной привязки крупных решений к человеку. Решение, управляющее сотнями миллионов долларов, оставалось вероятностным там, где давно стоило стать гейтированным.

Архитектурная альтернатива: андеррайтер и circuit breaker

Альтернатива с гейтом: человек выше порога риска + circuit breaker



Решение выше порога риска — у человека, не у модели.

Окно контроля — неделя, не квартал.

Zestimate (алгоритмическая оценка, вход, не решение) → человек-андеррайтер принимает финальное решение о покупке выше порога суммы/риска → явный circuit breaker на отклонение фактической цены от прогнозной, проверяемый еженедельно или чаще — не поквартально.

Когда снижать объём автоматизации

СНИЖАТЬ ОБЪЁМ АВТОМАТИЧЕСКИХ РЕШЕНИЙ

- цена одной ошибки — десятки или сотни тысяч долларов реального капитала
- внешние условия показывают растущую волатильность относительно того режима, на котором модель обучена
- решение выше порога суммы или риска не привязано ни к одному конкретному человеку
- единственный контроль качества — отчётность раз в квартал

МОЖНО ПРОДОЛЖАТЬ МАСШТАБИРОВАТЬ

- цена одной ошибки — один неприятный разговор с клиентом, не капитал
- рынок и данные стабильны, режим совпадает с тем, что модель видела при обучении
- решение выше порога структурно идёт через человека, и есть работающий circuit breaker
- есть короткий период мониторинга (часы-дни) с автоматическим порогом остановки

Предел. Если стоимость одной ошибки модели — десятки тысяч долларов реального капитала, а внешние условия демонстрируют растущую волатильность, снижайте объём автоматизированных решений до подтверждения устойчивости модели к новому режиму — не масштабируйте «пока не увидим цифры за квартал».

Та же мысль, что в «Одобрении возврата», на другом масштабе. Там гейтом было решение по одной заявке на возврат, ценой ошибки — неловкий разговор с клиентом. У Zillow гейтом стала каждая покупка дома, а ценой пропущенного порога — реализованный убыток в сотни миллионов долларов и примерно четверть всего штата. Порог существовал в обоих случаях; алгоритмическим гейтом он не стал ни там, ни там, пока это не проверили.

Кейс 4. Карточка в Telegram

Журнал выполнения — зелёный. Отправка подтверждена. У координатора в Telegram — ничего.

Потребность маркетинга и первая версия

Учебный центр уже отправляет координатору текстовое уведомление о новой заявке (кейс «Уведомления»). Маркетинг просит: вместо сухого текста — карточка, текст поверх картинки, в том же канале.

1. Собрали цепочку: текст уведомления готовится тем же приёмом подстановки значений, что в «Уведомлениях»; следующий шаг забирает картинку по ссылке; последний шаг отправляет картинку в Telegram с этим текстом как подписью.
2. На тестовых картинках цепочка работает без замечаний: карточка собирается и уходит, координатор видит её в Telegram.
3. Маркетинг присылает первую настоящую карточку для реальной рассылки — скан высокого разрешения прямо с телефона, заметно больше тестовых картинок.
4. Прогон завершается успешно: журнал n8n зелёный, узел отправки получил от Telegram API положительный ответ. У координатора в Telegram карточки нет — либо она не пришла вовсе, либо пришла обрезанной.

Цена, которую не видно в журнале. Это не отказ узла и не ошибка вызова — такие мы уже умеем ловить. Это тихая потеря результата при формально успешном прогоне, и до сих пор у нас не было повода проверять бинарные данные иначе, чем сам факт, что они сформировались.

Что должно быть верно, прежде чем карточка считается готовой. Два класса требований, разных по природе:

КЛАСС ТРЕБОВАНИЯ	ЧТО ПРОВЕРЯЕТСЯ
Механическое	размер файла, формат, разрешение — у файла есть численные и перечислимые свойства
Смысловое / по содержанию	картинка на самом деле показывает то, что нужно — не битый файл-заглушка, не чужое изображение, не пустой кадр

Как проверить, что картинка соответствует требованиям

Как проверить, что картинка соответствует требованиям?

- проверить размер и формат файла перед отправкой — программно
- проверить, что картинка открывается без ошибок — программно
- проверить, что на картинке действительно то, что нужно показать — моделью с распознаванием изображений
- ничего не проверять — доверять тому, что узел отправки сам разберётся

Какая проверка закрывает какое требование

КАРТОЧКА	КАКОЕ ТРЕБОВАНИЕ ЗАКРЫВАЕТ	ЗАКРЫТО СЕГОДНЯ?
проверить размер и формат файла перед отправкой	механическое	да — код, детерминированно, до отправки
проверить, что картинка открывается без ошибок	механическое (тот же класс)	да — тем же способом
проверить, что на картинке действительно то, что нужно	смысловое / по содержанию	нет — в цепочке сегодня нет шага, который это умеет
ничего не проверять	ни одно	нет — это и случилось в сцене кейса

Технически исправный файл (правильный размер, правильный формат) всё равно может показывать не то, что нужно — например если узел получения картинки получил страницу ошибки хостинга вместо самой картинки: формат и размер пройдут механическую проверку, а содержимое будет не тем.

Дальше — как первые два пункта реализуются технически: архитектура без привязки к инструменту, а следом настоящая конфигурация в n8n.

Архитектура: два класса требований к файлу

Два класса требований к картинке — одна и та же ось «модель или код»

Механическое

- размер файла
- формат
- разрешение

код проверяет — у файла есть измеримые свойства

Смысловое / по содержанию

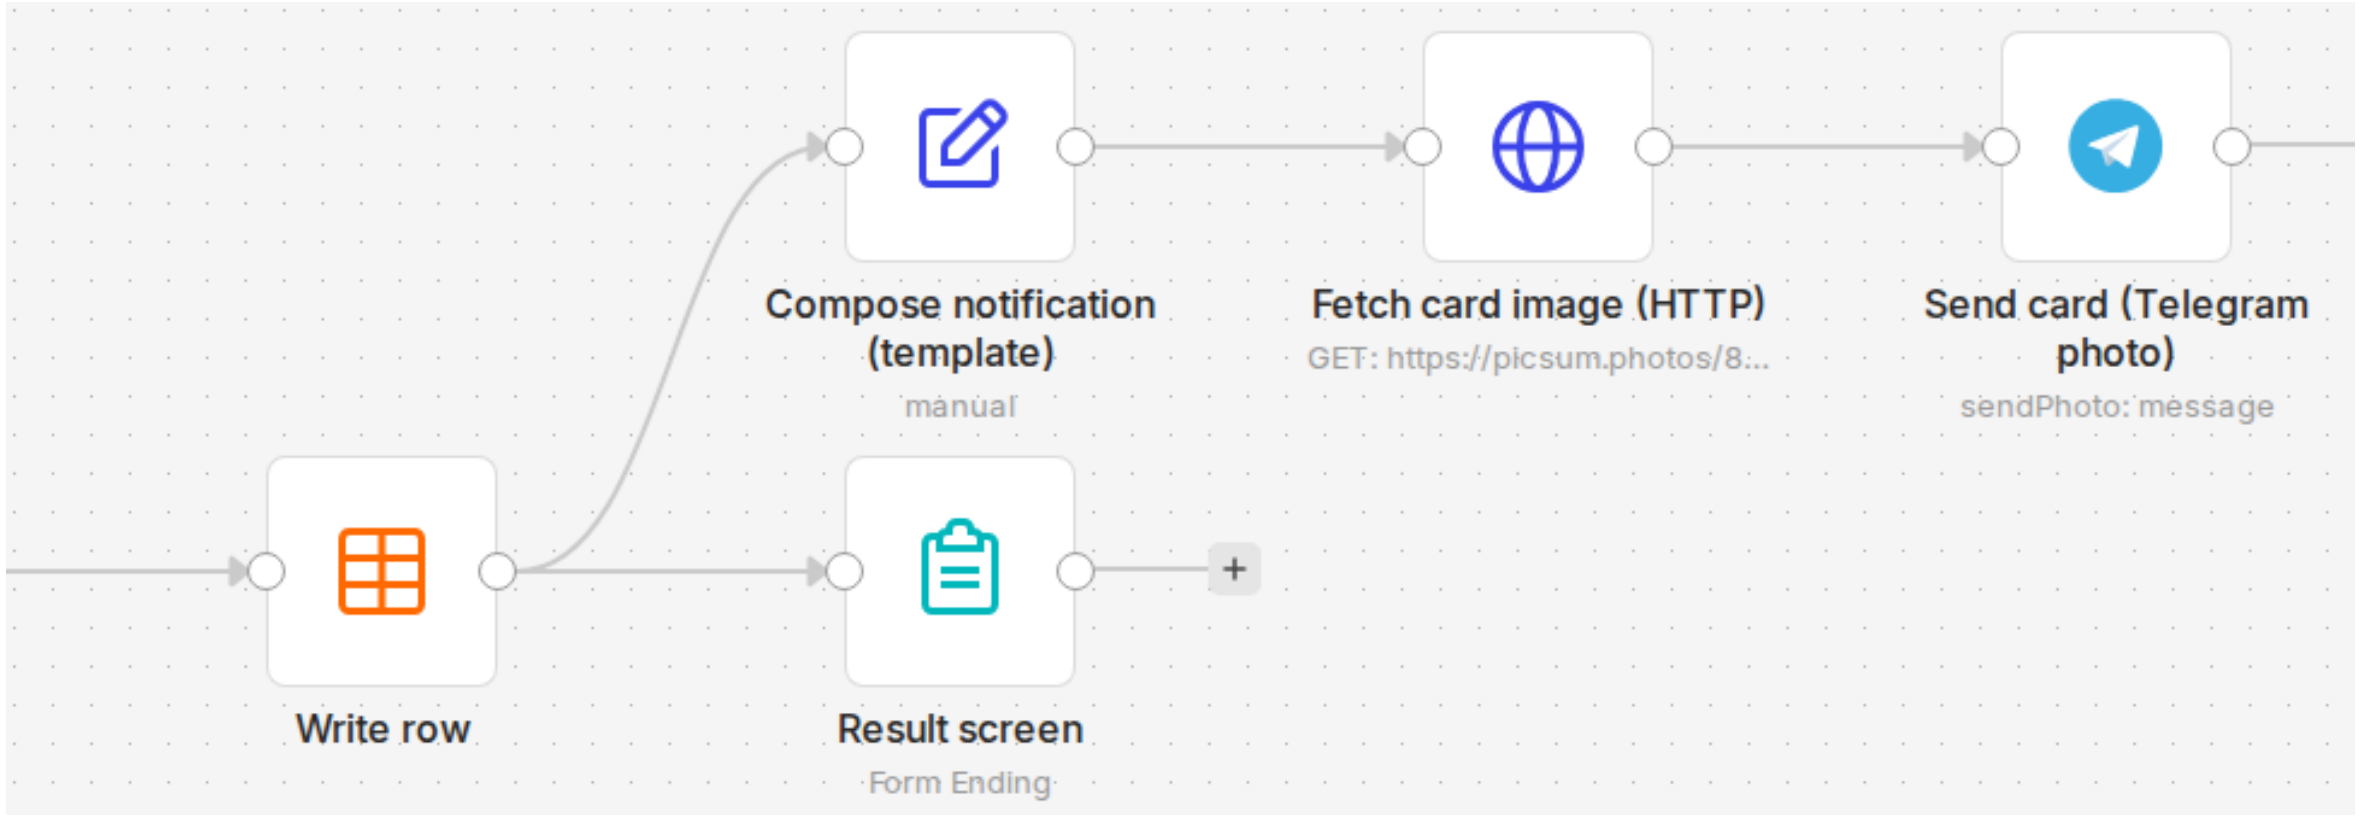
картинка на самом деле показывает то, что нужно — не битый файл-заглушка, не чужое изображение

нужна модель с распознаванием
не покрыто сегодня

Технически исправный файл всё равно может показывать не то, что нужно.

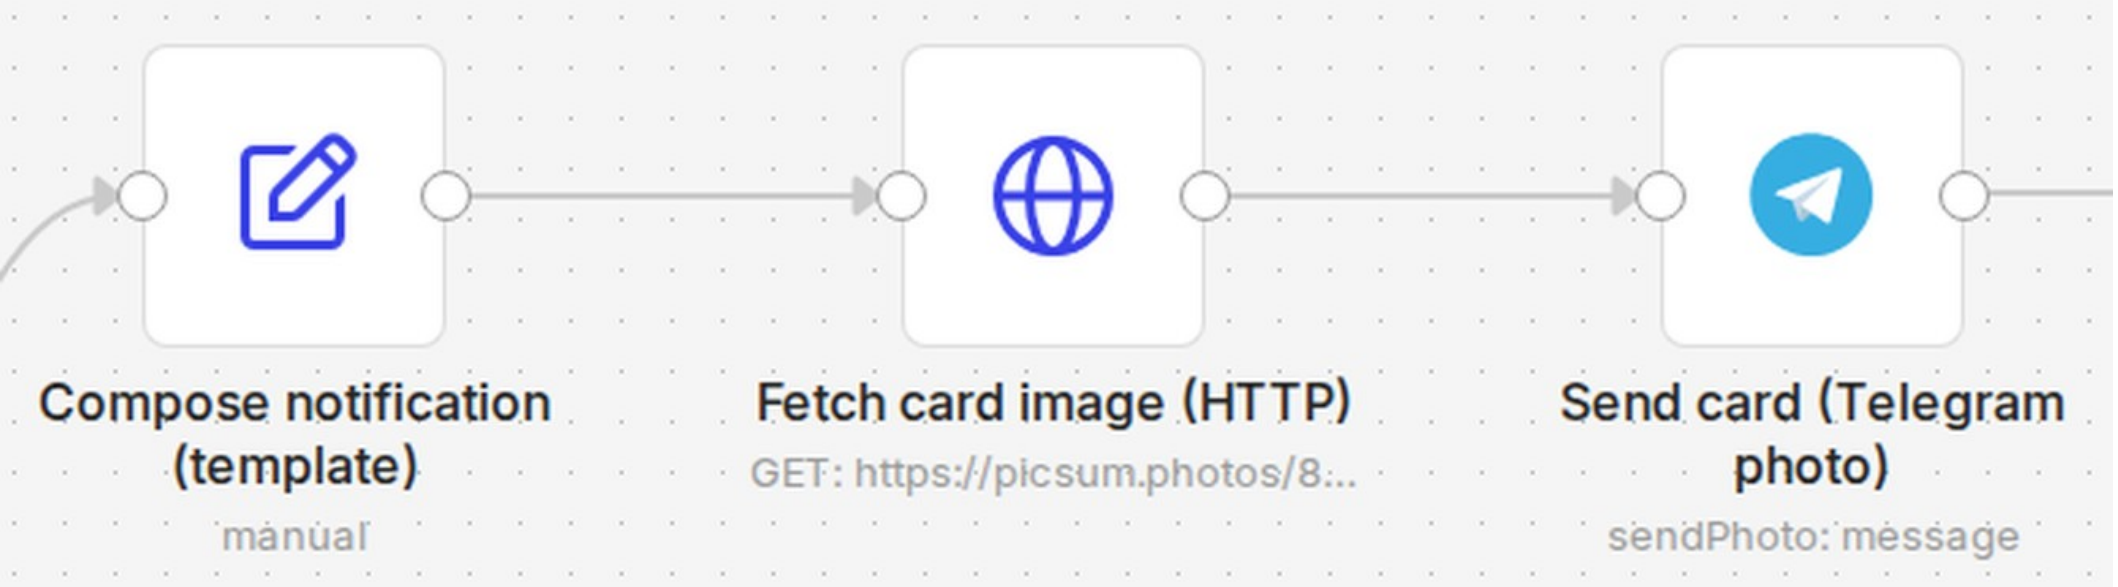
Файл → механическое требование (размер, формат, разрешение) → проверяет код, детерминированно, до отправки. Файл → смысловое требование (показывает ли нужное) → проверяет модель с распознаванием изображений — сегодня этого шага в цепочке нет.

Точка ветвления на реальном канвасе



Воркфлоу «C8 · Кейс 4 — картинка в Telegram», живой стенд. `Write row` → `Result screen` — тот же главный путь приёма заявки, что в Кейсе 1. От развилки после `Write row` стрелка уходит вверх, в `Compose notification (template)` → `Fetch card image (HTTP)` → `Send card (Telegram photo)` — три узла, которые кейс разбирает дальше.

Цепочка в n8n и граница размера, проверенная настоящим вызовом



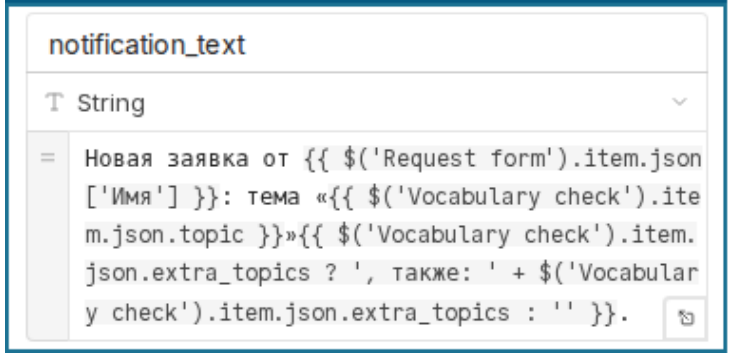
ЧТО	БАЙТ
Проверенный файл	**12 812 355** (~12,8 МБ)
Лимит Telegram на фото	**10 485 760** (10 МБ)

Ответ Telegram Bot API: "`Bad Request: file of size 12812355 bytes is too big for a photo; the maximum size is 10485760 bytes`"

Панели настройки: текст, картинка и отправка фото

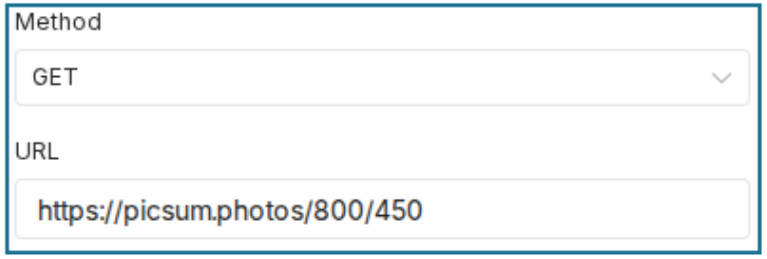
Узел «Compose notification (template)»

Поле notification_text: подстановка значений в шаблон



Узел «Fetch card image (HTTP)»

Запрос GET по адресу картинки



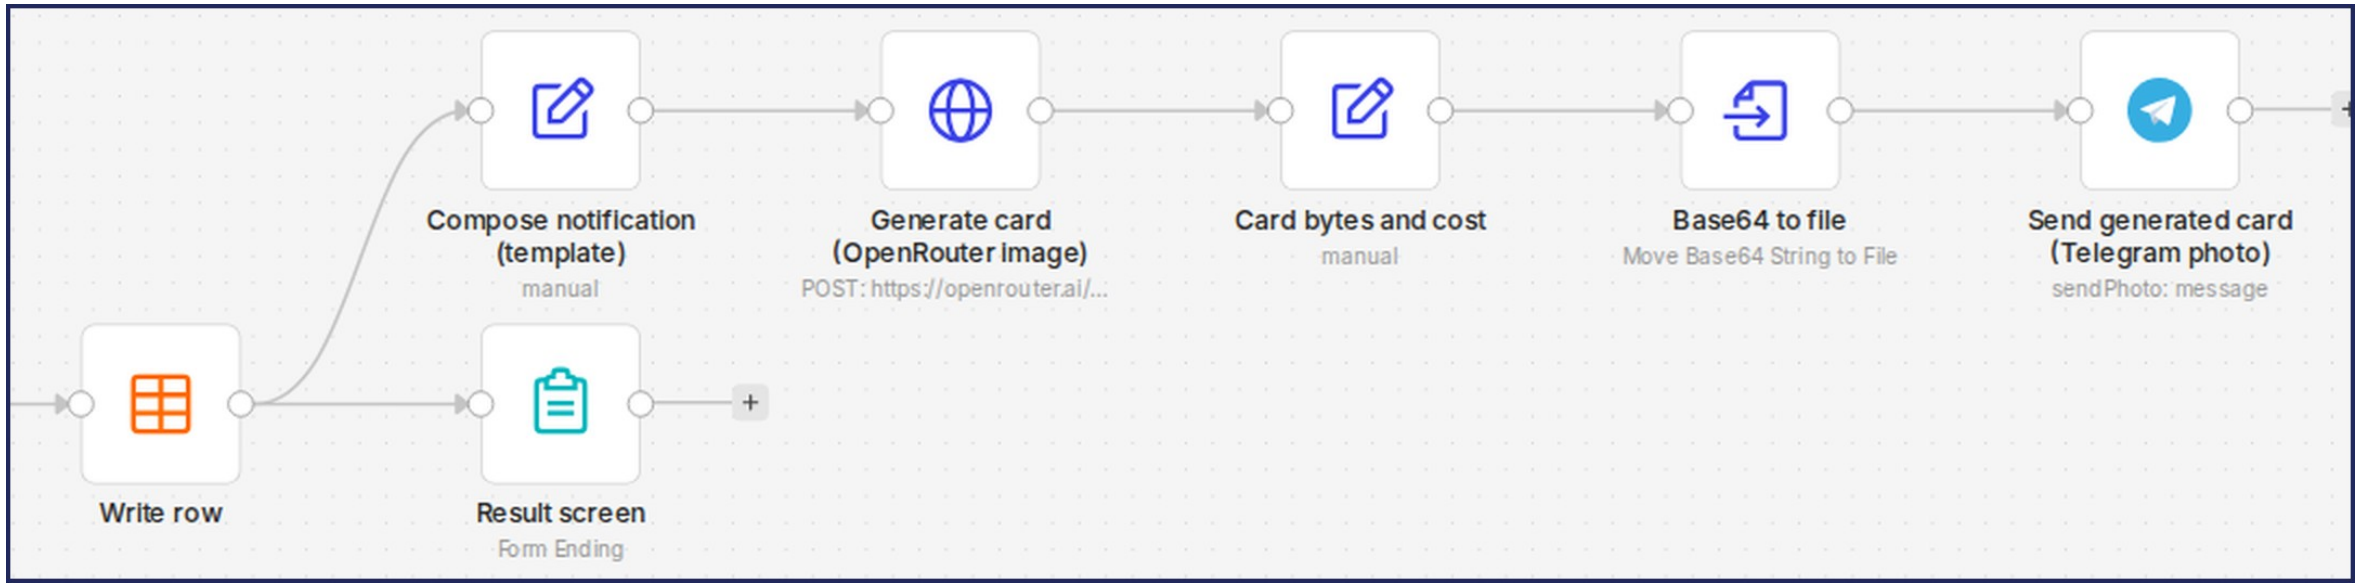
Узел «Send card (Telegram photo)»

Операция Send Photo — картинка, а не текст



Картинку забирают отдельным запросом, а отправляют отдельной операцией: текстовое сообщение и фотография — два разных вызова, а не один с вложением.

Генерация карточки: текст внутри изображения



$0,0387

за одну карточку — по счёту самого сервиса; оценка по прайсу давала $0,034

≈$23,2 в месяц

при шестистах карточках — том же потоке заявок, что в Кейсе 1

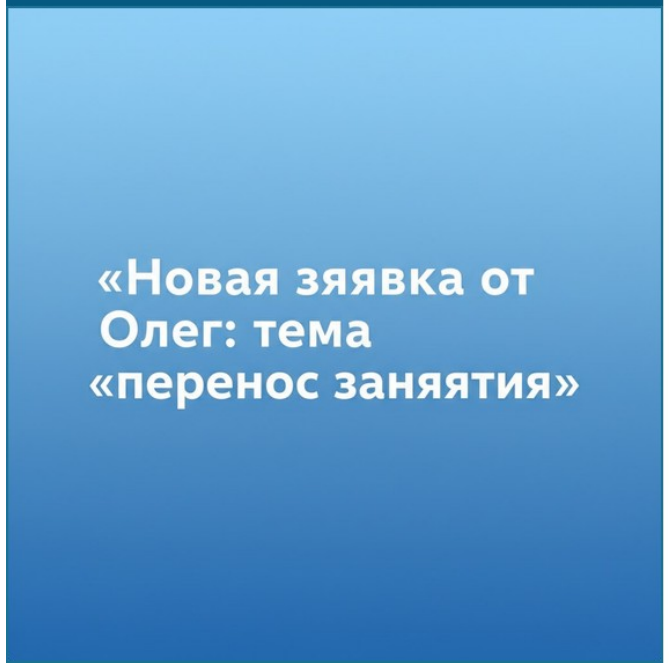
≈870 КБ

PNG 1024×1024 — в двенадцать раз ниже лимита Telegram на фото

Перекодировать пришлось не из-за веса. Модель отдаёт картинку текстом, а узел отправки принимает бинарное вложение — шаг `Base64 to file` стоит в цепочке ради формата, а не ради размера.

Что модель написала внутри картинки

Карточка, которую нарисовала модель
доставлена в Telegram, выполнение 600



Текст внутри картинки — рисует модель
«зяявка» · «заняятия»: так во всех пяти карточках

«Новая зяявка от
«перенос заняятия»

Подпись к тому же фото — собирает шаблон
верна слово в слово

Новая заявка от Олег: тема «перенос занятия».

Так на всех пяти карточках, которые дошли до чата. Модель получала точную строку и требование написать её дословно.

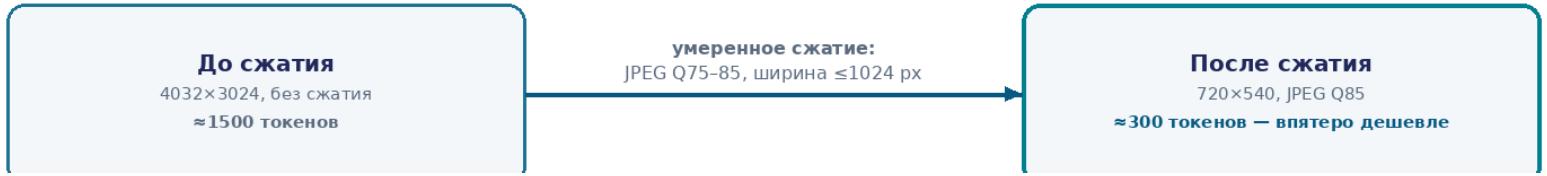
Ошибка живёт в пикселях: ни размер, ни формат, ни зелёный прогон её не видят. Видит только человек, который посмотрит на картинку.

Порядок проверки и вопрос сжатия

Механическая проверка → модель содержимого, и вопрос сжатия

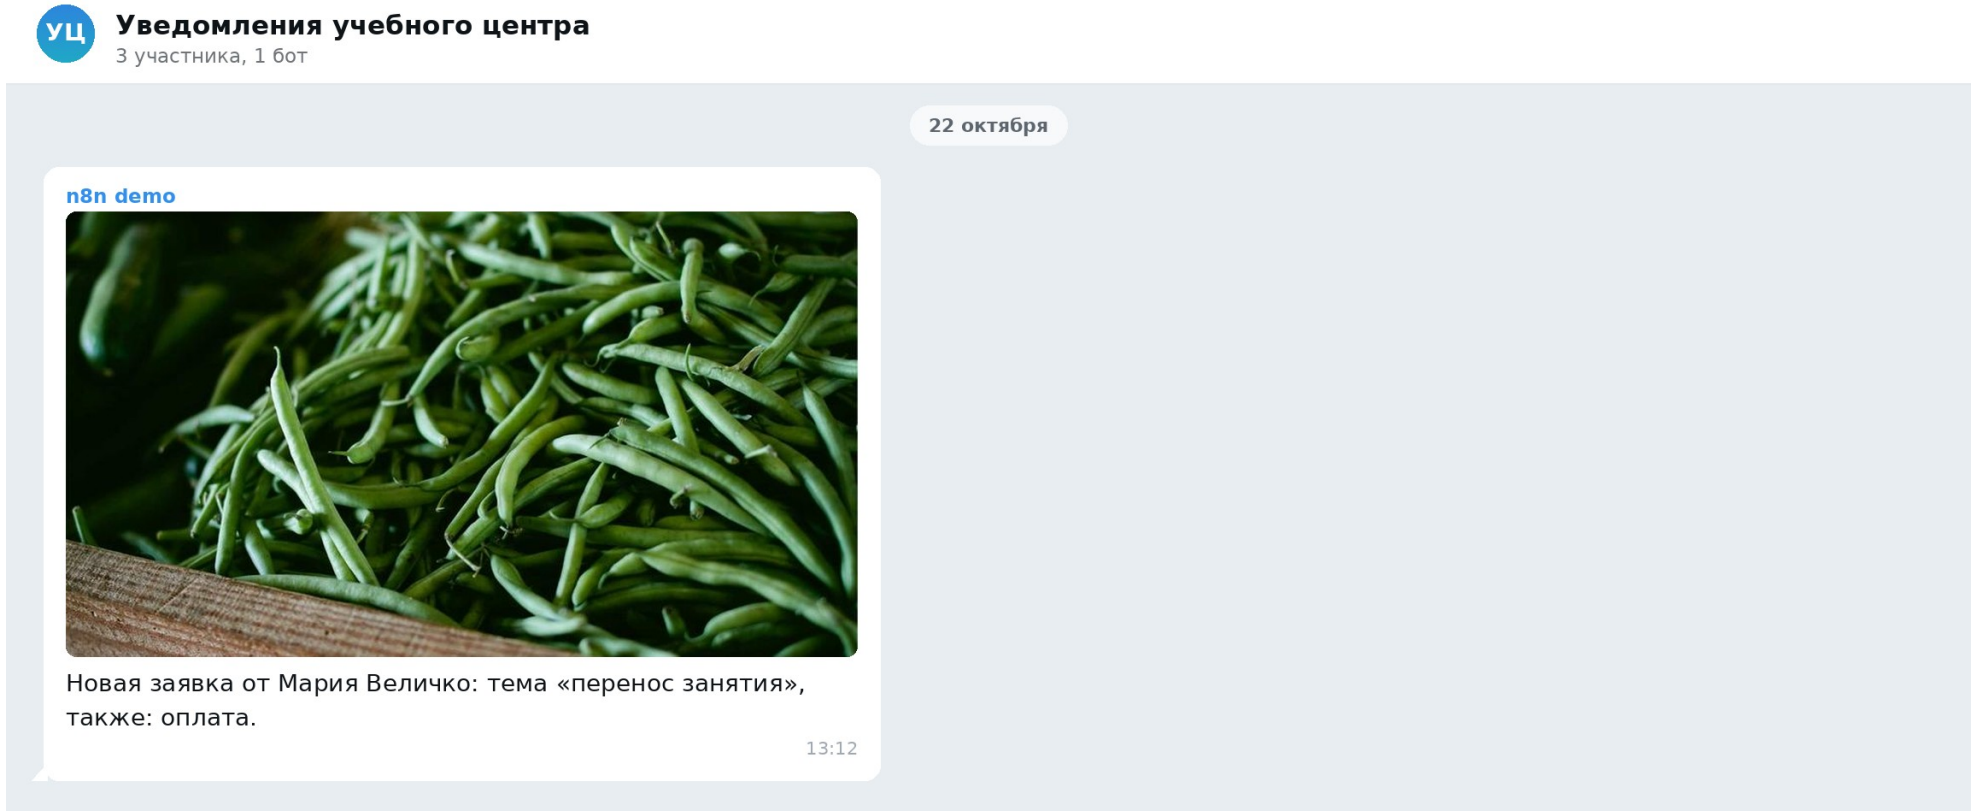


Сжатие перед отправкой в модель-проверяющую



ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Без сжатия	как есть (4032×3024)	максимум деталей	дорого — ≈1500 токенов
Умеренное сжатие	Q75–85, ≤1024 px	≈300 токенов, впятеро дешевле	режет мелкий текст у предела
Агрессивное сжатие	низкое качество, < ~1024 px	ещё дешевле	текст и детали не распознать

Что видит координатор при успешной отправке



Тот же чат и тот же шаблон подписи, что в Кейсе 1, — только теперь текст приходит не отдельным сообщением, а подписью к фотографии. Это успешный случай: файл уложился в измеренную границу, и карточка дошла целиком.

Контракт на бинарных данных и граница вводного уровня

Бинарные данные в n8n — отдельная модель данных, не просто ещё одно значение поля. Контракт между шагами, который в «Уведомлениях» рвался на тексте (узел не падал, результат тихо не тот), здесь рвётся на формате и размере — по той же причине: формально успешный прогон ничего не говорит о том, дошёл ли результат до получателя.

НА ЭТОМ УРОВНЕ ДОСТАТОЧНО	СЛЕДУЮЩИЙ УРОВЕНЬ — СЕМИНАР 10
один файл, один известный лимит, одна отправка	хранение и поиск среди множества файлов
проверка размера и формата перед отправкой	обработка содержимого файла моделью (поиск по смыслу изображений)
явное условие в цепочке на каждый шаг с бинарными данными	векторное хранилище и индексация вложений

Когда бинарные данные требуют отдельной заботы

НУЖНО ВСЕГДА

проверка размера и формата перед отправкой любого файла или изображения в цепочке

знание лимита канала доставки, а не только лимита самого оркестратора

НЕ ТРЕБУЕТ ЭТОГО ЗАНЯТИЯ

хранение множества файлов

поиск среди вложений и обработка их содержимого моделью

Четвёртая строка оси закрыта. Выглядело надёжным: картинка собралась и ушла в Telegram. Чем оказалось: до тех пор, пока помещается в лимит — большой файл уходит не полностью или не уходит вовсе, а прогон при этом остаётся зелёным.

1. **Собственный лимит n8n по умолчанию — 16 МБ** на бинарные данные. Для фотографии с текстом этого обычно достаточно, но скан высокого разрешения или фото прямо с телефона — не всегда.
2. **Лимиты Telegram — отдельный, более узкий потолок**, и они разные для фото и для документа. То, что прошло мимо лимита n8n, может всё равно не пройти мимо лимита канала доставки — два независимых порога, не один.
3. **Ручной прогон с бинарными данными потребляет заметно больше памяти**, чем автоматический, — разница заметнее, чем на текстовых полях, и стоит иметь это в уме при отладке такого узла вживую.

Четыре строки оси: что оказалось

ВЫГЛЯДИТ НАДЁЖНЫМ	ЧЕМ ОКАЗАЛСЯ
сообщение ушло координатору, цепочка короче и дешевле без LLM	LLM здесь был просто лишним шагом — то же самое сделал шаблон, без модели и без риска галлюцинации (**«Уведомления»**)
заявка про тот же вопрос пришла снова — обработали как новую	без проверки на дубль каждое повторное обращение запускает цепочку с нуля; ни точное совпадение, ни похожесть по словам не решают это целиком — для переформулировки нужна проверка смыслом (**«Проверка на повтор»**)
в промте написано «не возвращай больше суммы X»	решение оставалось вероятностным: модель обходила правило в измеренной доле прогонов, ровно на границе условия; алгоритмический гейт — никогда (**«Одобрение возврата»**, подтверждено на масштабе компании — Zillow)
картинка собралась и ушла в Telegram	до тех пор, пока помещается в лимит — большой файл уходит не полностью или не уходит вовсе, а прогон всё равно зелёный (**«Карточка в Telegram»**)

Из четырёх новых шагов узел языковой модели пережил проверку в одном — в «Одобрении возврата», и там он только извлекает сумму: решает условие в коде.

Где в цепочке решение принимает модель, а где должен — код, и что молчит, когда эту границу не назвали явно?

Что уносим с занятия

ФАЙЛ	ПРОДОЛЖЕНИЕ `student.json`, С КОТОРЫМ ВЫ ЗАКОНЧИЛИ ПРОШЛОЕ ЗАНЯТИЕ
что добавилось	уведомление координатору шаблоном, а не моделью · проверка на повтор в два уровня · решение о возврате условием в коде, а не правилом в тексте · доставка картинки с проверкой размера перед отправкой
как поставить	тот же импорт, что и в прошлый раз: меню сценария → Import from File
что нужно	свой n8n и ключ провайдера модели, как и раньше, плюс бот и токен в Telegram для уведомления и картинки
что делать	прогнать несколько заявок, включая повтор и крупную картинку, и посмотреть, где какое из четырёх решений ведёт себя не так, как на экране

Что дальше



Семинар 9: условие против переключателя · классификация как отдельный шаг цепочки · что делать со входом, который не подошёл ни под одну ветку · как ветки, которые выглядят параллельными на холсте, выполняются на самом деле