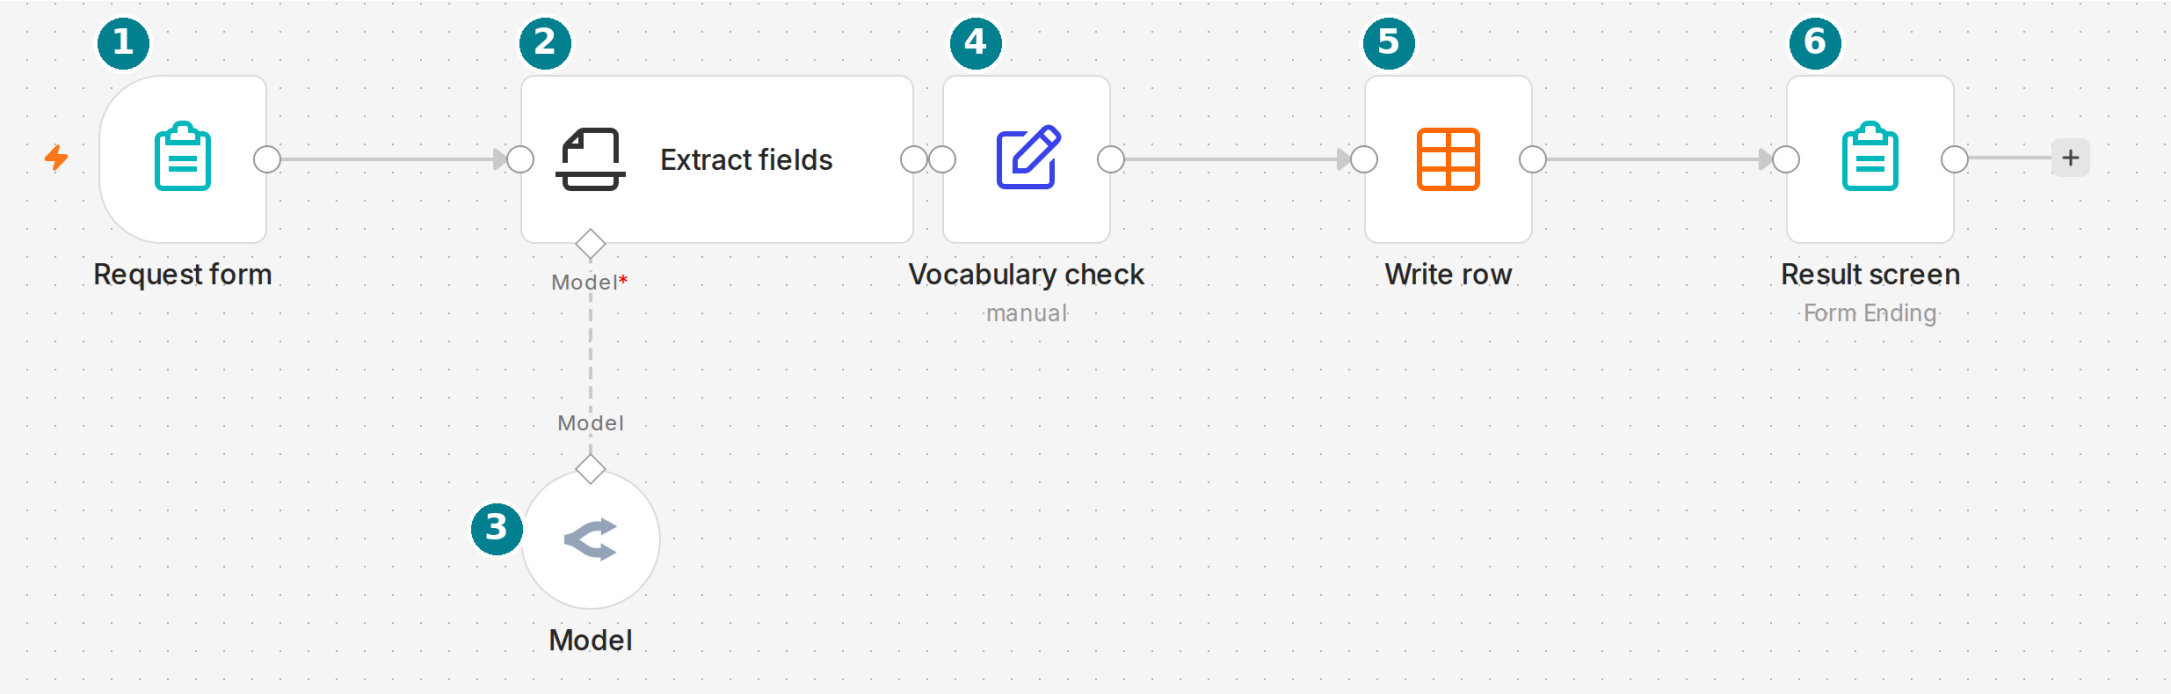
Где решает модель, а где должен — код

Процессы на больших языковых моделях: второе занятие дуги.

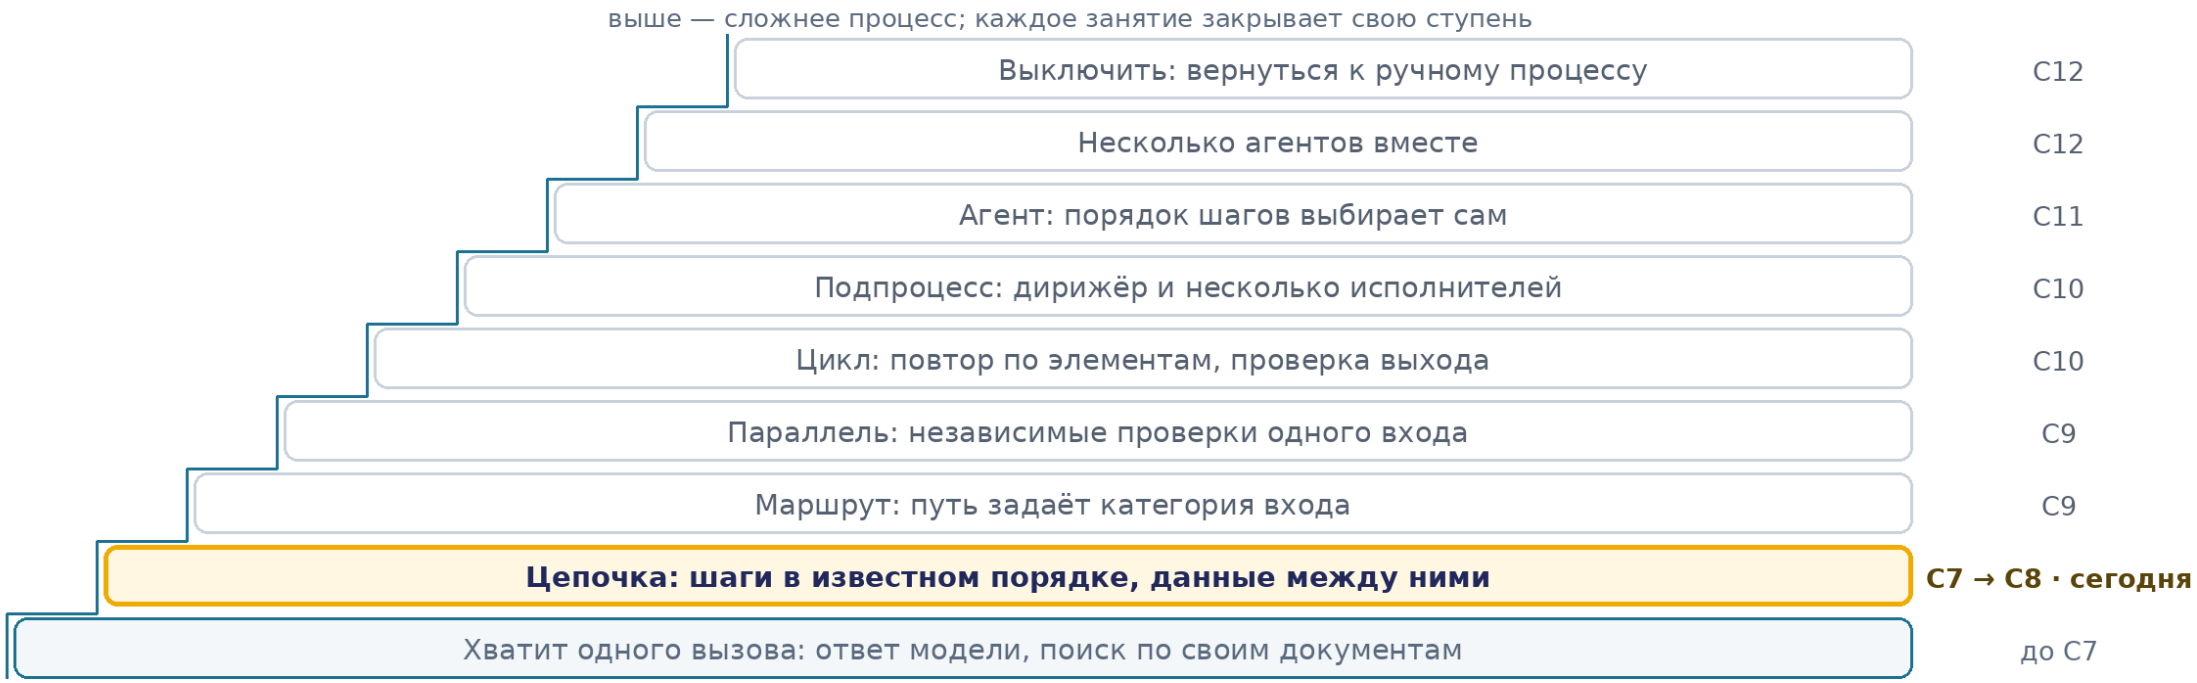
Входное состояние: процесс с прошлого занятия



1 форма — вход процесса · 2 извлечение — достаёт значения из текста · 3 модель — второй узел шага
4 сверка со списком · 5 запись строки · 6 экран результата — печатает всю дорогу

Это настоящий холст n8n, а не схема. У нас есть процесс по классификации входящих обращений — шесть узлов, тот же порядок, те же имена, что и в конце прошлого занятия.

Та же ступень: цепочка



Золотая полоса стоит там же, где и в прошлый раз. Сегодняшние четыре кейса — не подъём выше, а то, что происходит внутри одной и той же ступени, когда к цепочке добавляют новые шаги.

Ось занятия: где решает модель, где должен — код

ВЫГЛЯДИТ НАДЁЖНЫМ	ЧЕМ ОКАЗАЛСЯ
сообщение ушло координатору, цепочка короче и дешевле без LLM	
заявка про тот же вопрос пришла снова — обработали как новую	
в промте написано «не возвращай больше суммы X»	
картинка собралась и ушла в Telegram	

Правая колонка закроется не вся разом в конце, а по одной строке — сразу после того кейса, который её закрывает. И каждый раз не моим рассказом, а тем, что мы увидим на экране.

Кейс 1. Уведомления

«Пришлите мне в Telegram одну строку: кто написал и про что — чтобы не лезть в таблицу на каждую заявку.»

Уведомления | Проверка на повтор | Одобрение возврата | Карточка в Telegram

Экран результата и многотемная заявка

Учебный центр, тот же процесс, что заработал на прошлом занятии: форма → извлечение полей → запись в таблицу с темой, дополнительными темами и срочностью → экран результата. Дальше с этим экраном работает Ольга, администратор — двадцать заявок в день, и большую часть она разбирает по экрану результата спокойно: тема и срочность уже там, кому передать — понятно сразу.

1. Раз в несколько заявок текст короче обычного не получается: человек упомянул не только основной вопрос, а что-то ещё — спросил про оплату, попросил перенести занятие, уточнил расписание. Поле «дополнительные темы» в таблице это ловит и честно записывает.
2. Экран результата Ольга открывает не на каждую заявку сразу — за день их двадцать, и открывать каждую по готовности было бы ровно той же работой руками, которую процесс должен был снять. Она проверяет пачками, несколько раз за смену.
3. Если многотемная заявка пришла между проверками, она лежит в таблице с правильными полями — и ничем не выделяется среди обычных заявок, пока Ольга не откроет экран сама и не прочитает именно эту строку.
4. К вечеру, если день был плотным, она честно признаёт: часть многотемных заявок она заметила не в момент прихода, а при следующей пачке проверки — иногда через несколько часов.

Чем платит учебный центр за задержку. Многотемная заявка почти всегда срочнее обычной: человек не просто спрашивает про курс, он ещё и хочет перенести оплаченное занятие на сегодня или уточнить то, что должно случиться до конца дня. Пачка проверки раз в несколько часов превращает именно эту срочность в обычную очередь.

Ольга формулирует желание предельно конкретно: «Пришлите мне в Telegram одну строку на каждую такую заявку — кто написал, по какой теме и что ещё упомянул, — чтобы не идти проверять экран результата из-за одной многотемной заявки среди двадцати обычных.»

Как собрать уведомление из трёх значений

Как собрать текст уведомления из этих трёх значений?

модель пишет весь текст уведомления целиком, свободно

заполняем готовую форму сообщения алгоритмом целиком — только подстановка значений

то, что можно закрыть алгоритмом, закрываем им; то, что требует интерпретации текста заявки, на то отдельно зовём модель

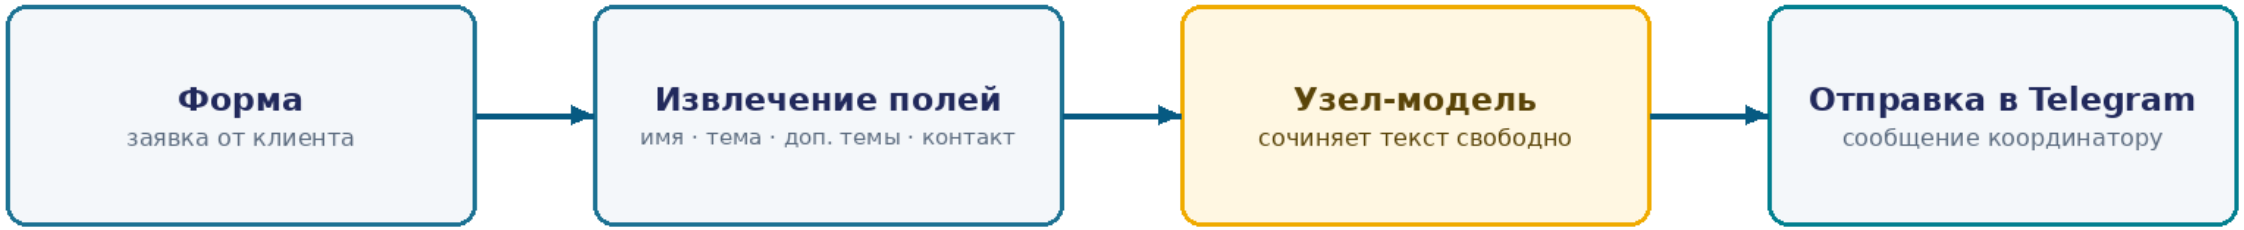
берём алгоритмически собранный текст как основу и добавляем к нему одну фразу тона от модели поверх

Что делает каждое действие

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
модель пишет весь текст целиком	получает три уже извлечённых значения и сочиняет текст уведомления свободно, без заданной формы	текст звучит живо, не казённой фразой — умеет писать по-человечески	значения уже извлечены — интерпретировать нечего; текст собирается заново на каждом прогоне, с риском вписать деталь, которой в заявке не было
алгоритм заполняет форму целиком	подставляет три уже структурированных значения в один раз заданный шаблон текста, без обращения к модели	результат детерминированный: совпадает с заданным примером текста на любой заявке, не только на удачной	нет пространства для вариативности: если форма сообщения когда-нибудь должна будет меняться по смыслу, а не только по значениям, выражение придётся переписывать руками
алгоритм + модель на то, что требует интерпретации	структурированные значения подставляются алгоритмом; то, что осталось неструктурированным и требует интерпретации текста заявки, отдельно передаётся модели	работало бы честно при реальном смешанном случае — когда хотя бы одно значение правда требует интерпретации, а не просто известно	для этой конкретной потребности интерпретировать нечего: все три значения, включая срочность, уже извлечены структурно на прошлом занятии — модели здесь просто не находится работы
алгоритм + тон модели поверх	алгоритмический костяк текста собирается подстановкой значений, модель добавляет сверху одну короткую фразу тона или комментария	масштаб свободы меньше, чем у первого действия — риск и цена вызова модели пропорционально ниже	риск той же природы, что у первого действия, просто меньшего размера: модель всё равно генерирует текст и может вписать в него деталь, которой не было

Архитектура: шаг-модель сочиняет текст

Решение с LLM: модель сочиняет текст



Риск: модель может добавить деталь, которой не было в заявке.

Плюс цена и задержка вызова модели на каждый прогон.

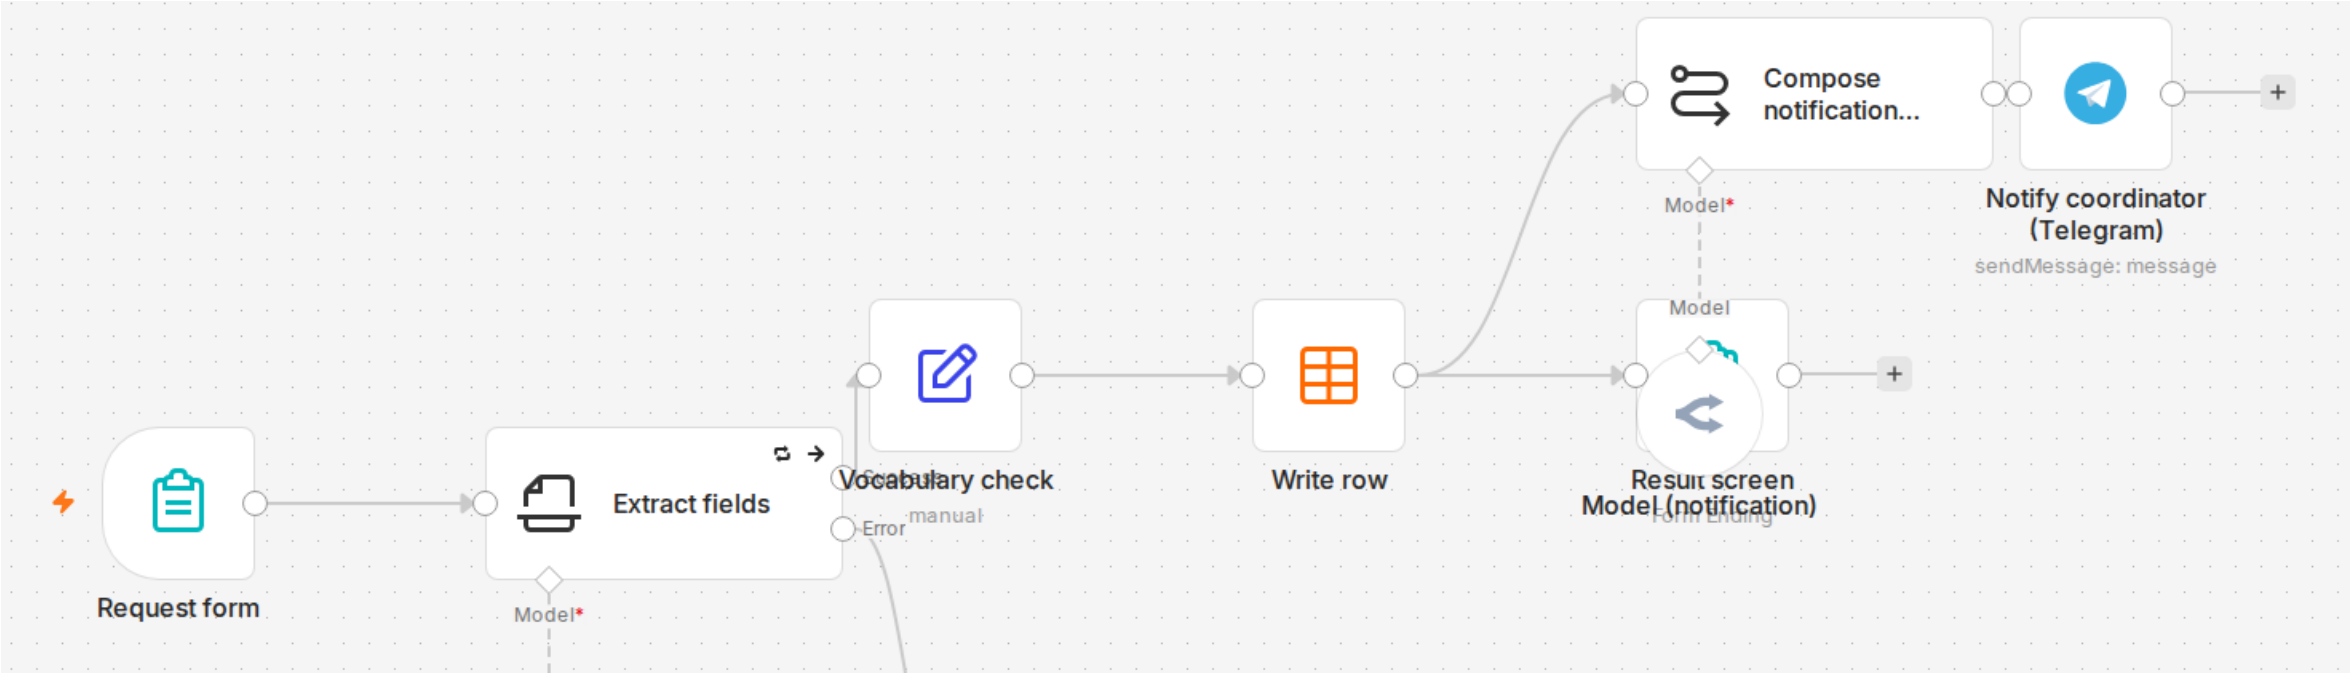
Четыре блока: форма → извлечение полей → шаг, вызывающий модель на каждый прогон → Telegram. Решение о форме текста принимается заново при каждой заявке.

Архитектура: шаг-шаблон подставляет значения



Та же цепочка: форма → извлечение полей → подстановка значений в фиксированную форму → Telegram. Решение о форме текста принято один раз, заранее, а не на каждом прогоне.

Весь путь на стенде: версия с моделью



Форма заявки → извлечение полей (вызывает модель) → проверка по словарю тем → запись строки → «Compose notification…» (вызывает модель второй раз, подпись обрывается многоточием — так ведёт себя интерфейс n8n при узкой карточке) → отправка координатору в Telegram.

Настройка узла: промпт версии с моделью



Узел «Compose notification (LLM)», вкладка Parameters. Поле Prompt (User Message): «Напиши короткое дружелюбное уведомление координатору учебного центра в Telegram о новой многотемной заявке. Имя заявителя: `{{ $('Request form').item.json['Имя'] }}`. Основная тема: `{{ $('Vocabulary check').item.json.topic }}`. Также в заявке упомянуто: `{{ $('Vocabulary check').item.json.extra_topics }}`. Пиши по-человечески, одно-два предложения.»

Переключатели Require Specific Output Format и Enable Fallback Model — оба выключены: никакой заданной структуры ответа, никакой резервной модели на случай сбоя.

Как сообщение выглядит у Ольги в телефоне

Telegram, чат «Уведомления учебного центра».

Новая заявка от Марии: тема «курс», также упомянуто: оплата.

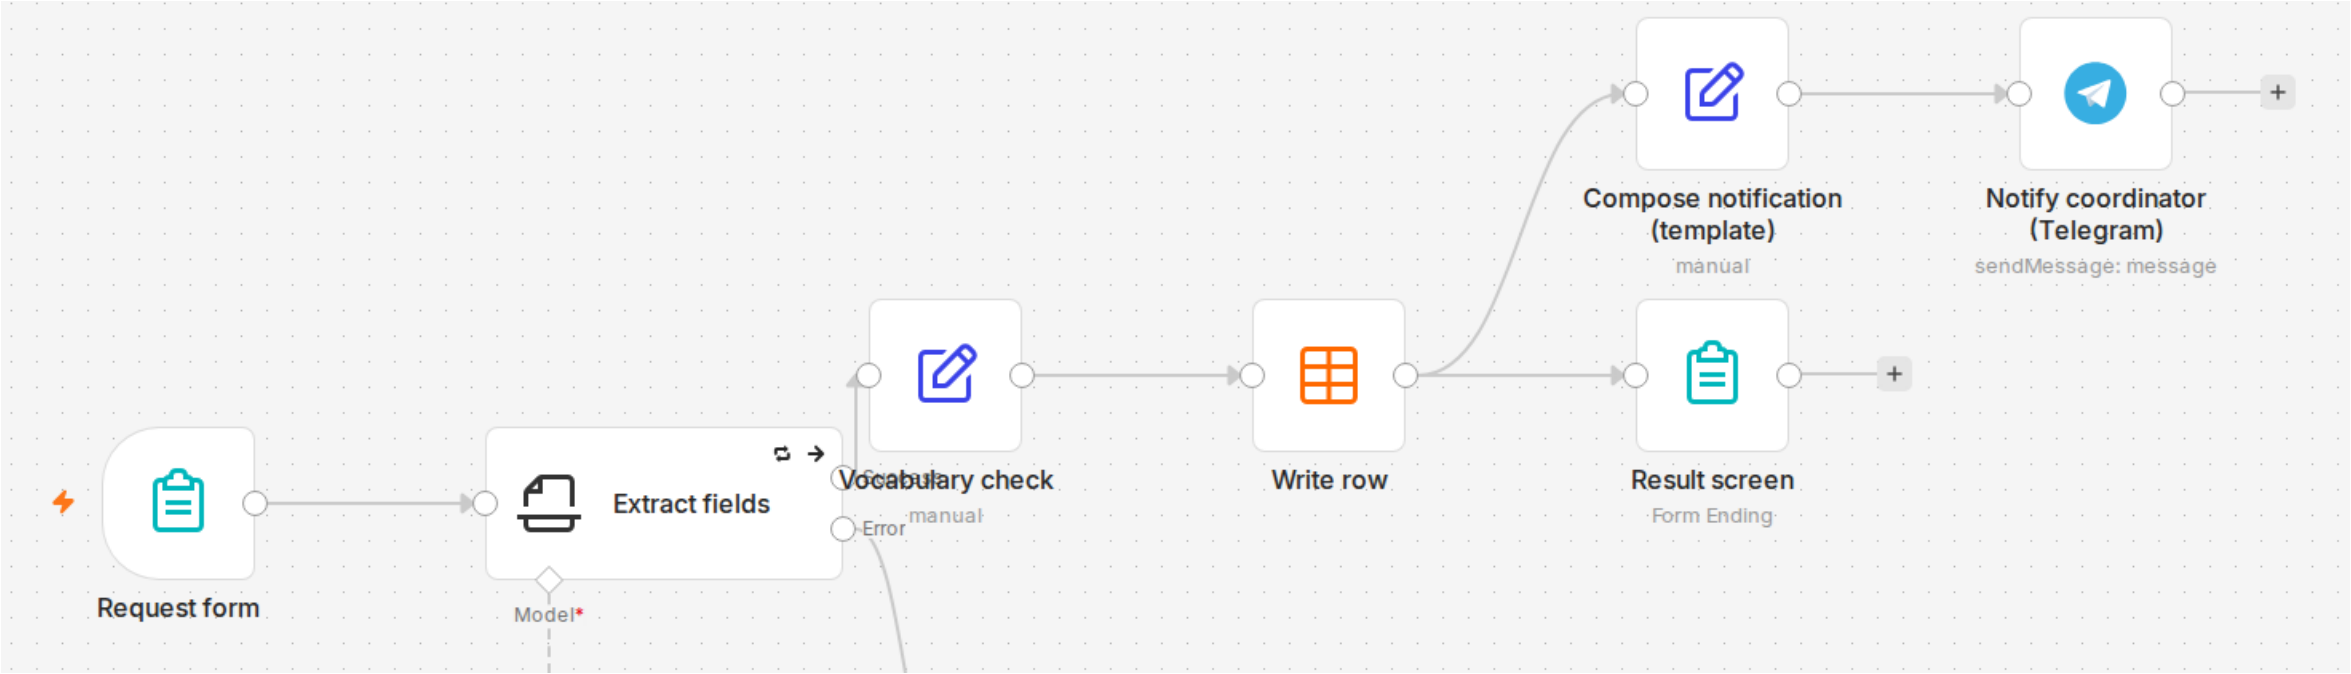
Ровно то, что Ольга описала в прошлой сцене, слово в слово: кто написал, по какой теме и что упомянул ещё — одна строка, без необходимости открывать экран результата.

Что реально получилось на двух прогонах

ТЕКСТ ЗАЯВКИ	ЧТО ПОЛУЧИЛОСЬ И ПОЧЕМУ
Мария: «хочу на курс по аналитике и ещё спросить про оплату, перезвоните сегодня»	Пришло: «Новая заявка от Марии: тема «курс», также упомянуто: оплата.» Текст свободный, но совпал по смыслу с целью — модели хватило инструкции и трёх значений, интерпретировать было действительно просто.
Олег: «хочу перенести занятие на пятницу и спросить про оплату курса»	Пришло: «Привет, **[Имя координатора]**! У нас новая многотемная заявка от Олега по вопросу переноса занятия и об оплате.» Модель вписала в текст буквальный кусок собственного шаблона-инструкции — слова, адресованные ей самой, а не Ольге. Узел не упал, сообщение доставлено, статус зелёный: расхождение видно только по содержанию.

Проверка форматом этого не ловит. Оба прогона технически успешны: оба узла отработали, оба сообщения дошли. Единственный способ заметить разницу — прочитать сам текст, который получил живой человек.

Весь путь на стенде: версия с шаблоном



Форма заявки → извлечение полей (вызывает модель) → проверка по словарю тем → запись строки → «Compose notification (template)» (подпись читается целиком, без обращения к модели) → отправка координатору в Telegram напрямую.

Настройка узла: выражение версии с шаблоном



Узел «Compose notification (template)» (`Set / Edit Fields`), Mode — Manual Mapping. Поле `notification_text` (String): «Новая заявка от `{{ $('Request form').item.json['Имя'] }}`: тема «`{{ $('Vocabulary check').item.json.topic }}`»`{{ $('Vocabulary check').item.json.extra_topics ? ', также: ' + $('Vocabulary check').item.json.extra_topics : '' }}`.»

«Include Other Input Fields» — включено, «Input Fields to Include» — All: остальные поля заявки проходят дальше по цепочке без изменений.

Не каждый текстовый вывод — это генерация

ПРИНЦИП	**ЕСЛИ ВСЕ НУЖНЫЕ ЗНАЧЕНИЯ УЖЕ СТРУКТУРИРОВАНЫ И ФОРМА СООБЩЕНИЯ НЕ МЕНЯЕТСЯ ПО СУТИ — ЭТО ЗАДАЧА ФОРМАТИРОВАНИЯ, А НЕ ЗАДАЧА МОДЕЛИ.**
Класс задачи	Сборка сообщения из уже извлечённых значений по фиксированной форме.

Когда нужна модель, когда достаточно шаблона

НЮАНС

Лишний шаг — риск, а не только цена

Шаблон не навсегда безопасен

ЧТО ЭТО ЗНАЧИТ

Каждый вызов модели — точка, где может появиться галлюцинация, даже в тривиальной задаче форматирования.

Если форма сообщения начнёт требовать реальной вариативности (разные языки, разная степень детализации), шаблон придётся переписывать руками на каждый новый случай — цена другого типа, инженерная.

Критерий. Модель нужна при реальной вариативности контента или когда значение требует интерпретации текста, которой не было на предыдущем шаге. Шаблон достаточен, когда форма сообщения одна и все значения уже структурированы.

Первая строка оси закрыта. Сообщение действительно ушло координатору — а цепочка оказалась короче и дешевле без узла модели. LLM здесь был просто лишним шагом: то же самое получилось шаблоном, без его цены и риска.

Кейс 2. Проверка на повтор

«Это ведь тот же вопрос, с которым он писал два часа назад?»

Уведомления | **Проверка на повтор** | Одобрение возврата | Карточка в Telegram

Заявки дублируются

1. Понедельник, утро. Ольга, администратор учебного центра, открывает таблицу заявок и видит вопрос от клиента: «когда можно оплатить занятие?» Она отвечает.
2. Через два часа — вторая заявка от того же контакта: «как мне внести оплату за курс». По смыслу это тот же вопрос. Ольга не узнаёт перефразировку и обрабатывает её как новую: отвечает ещё раз.
3. Клиент получает два разных ответа от центра с разницей в два часа — и это выглядит так, будто первый ответ потерялся.

Это не редкость. По собственной оценке Ольги, такие повторы случаются примерно 10 раз в день: кто-то забыл, что уже спрашивал, кто-то не увидел ответа и переспросил другими словами.

Цена ошибки не абстрактная. Двойная работа администратора — плюс недоверие клиента: «они не видят, что я уже спрашивал?»

Как построить проверку на повтор

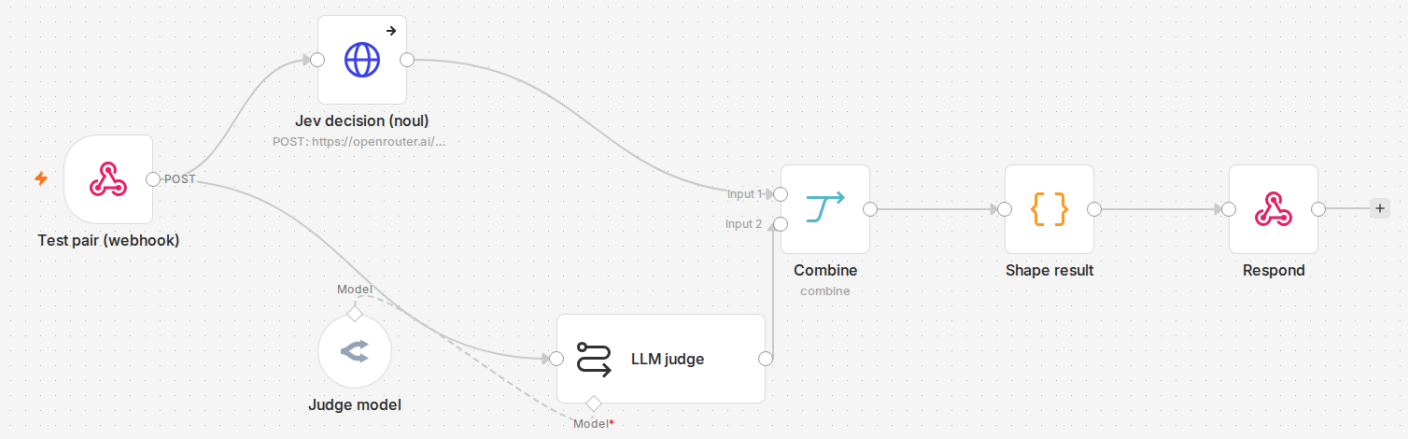
Как построить проверку на повтор?

- сравнивать тексты буквально — точное совпадение после нормализации
- сравнивать тексты по общим словам — классический векторный подход с порогом
- спросить у модели общего назначения, один ли это вопрос, просто сформулированный иначе
- спросить у специализированного сервиса сравнения вопросов, а не у модели общего назначения
- сначала проверить точное совпадение дёшево, а дальше пускать только то, что осталось

Что поймала каждая схема

СХЕМА	ВЕРНО ИЗ 20	ЧТО ПОЙМАЛА	ЧТО ПРОПУСТИЛА / ГДЕ ОШИБЛАСЬ	СТОИМОСТЬ И СКОРОСТЬ
Хэш (точное совпадение)	**15/20**	все 5 повторов, все 10 разных	все 5 перефразировок (0/5)	дёшево и мгновенно — без вызова модели
TF-IDF + косинус (порог 0,3)	**13/20** — хуже хэша	повторы, часть разных вопросов	те же 5 перефразировок + 2 ложных срабатывания на близких темах (хэш здесь не ошибается)	дёшево и мгновенно — без вызова модели
Модель-судья (gpt-4o-mini)	**17/20**	все 10 дублей	3 ложных срабатывания, включая пару без общих слов	~$0,15/млн вход · $0,60/млн выход — на кейсе (≈300/мес) ≈$0,006/мес (оценка по прайсу)
Сервис jev	**20/20**	все 20 без ошибок	чистое разделение, без пересечений	$0,042/млн вход, $0 выход — на кейсе ≈$0,003/мес (оценка по прайсу)

Честная находка. Порог 0,3 у TF-IDF пропускает все перефразировки и добавляет 2 ложных срабатывания там, где хэш не ошибается никогда. Лучший результат дал сервис jev — точнее и дешевле модели-судьи, но одно измерение на 20 парах недостаточно для смены уже работающей архитектуры. На объёме кейса (≈10 случаев в день) обе платные схемы стоят меньше цента в месяц: решает точность.



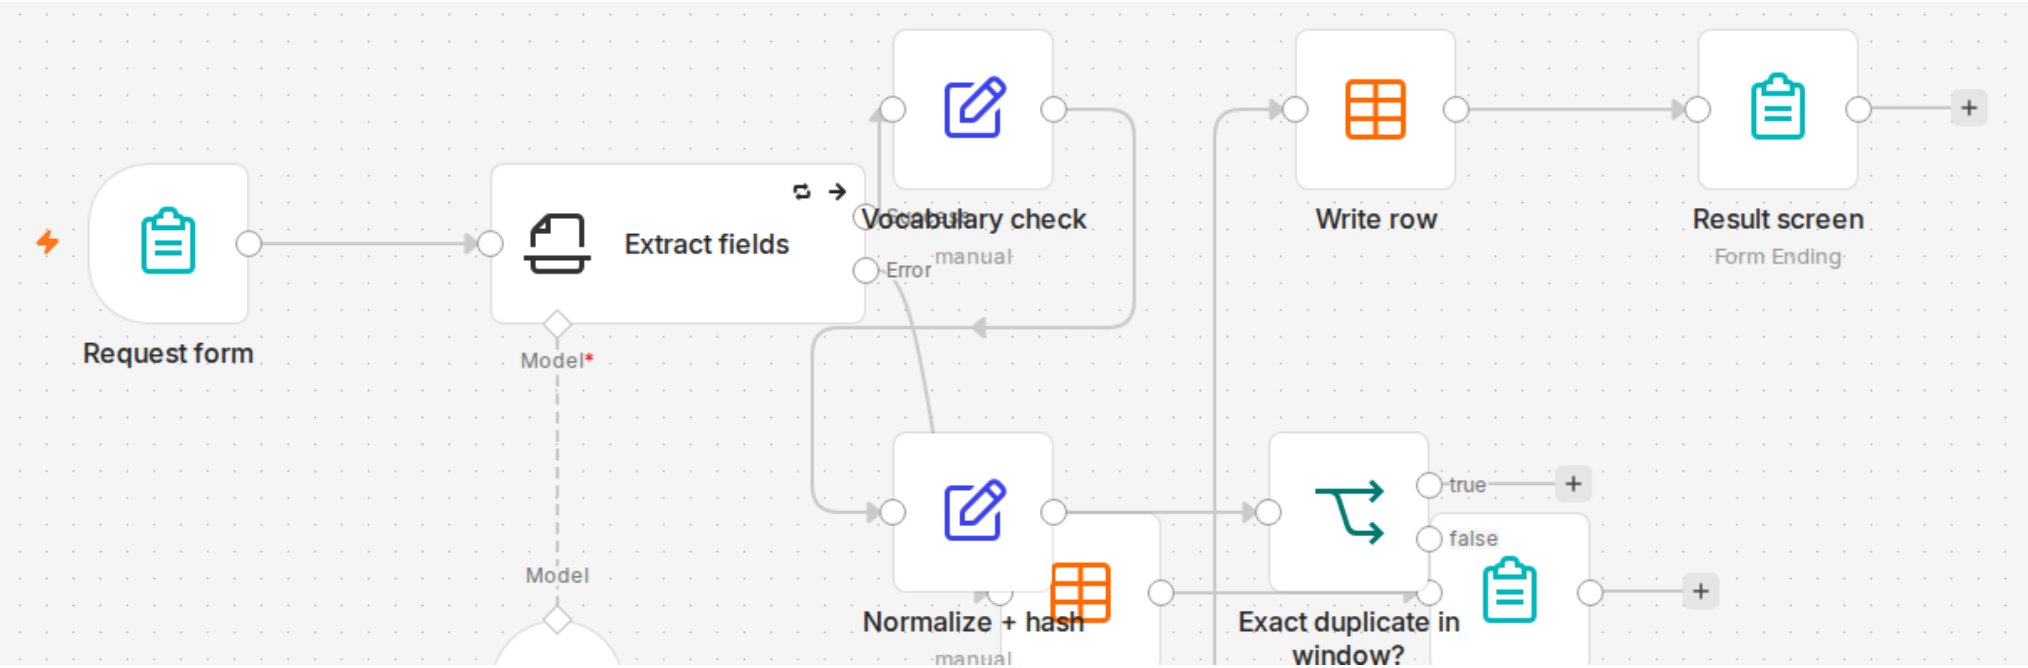
Решение: хэш первым, jev — на дорогом шаге



Фигура: шаг 1 — дешёвый механический предфильтр, берёт на себя буквальные повторы бесплатно. Шаг 2 — проверка смыслом, решение по измерению — специализированный сервис (jev), точнее и дешевле модели общего назначения на этом тесте. Узел собран и стоит на стенде.

Честная оговорка — на самой схеме. *Измерение одно, на 20 парах одного языка и одной тематики (запись на курсы). Обобщаемость за пределы этого набора не проверена — это граница измерения, а не повод не внедрять решение.*

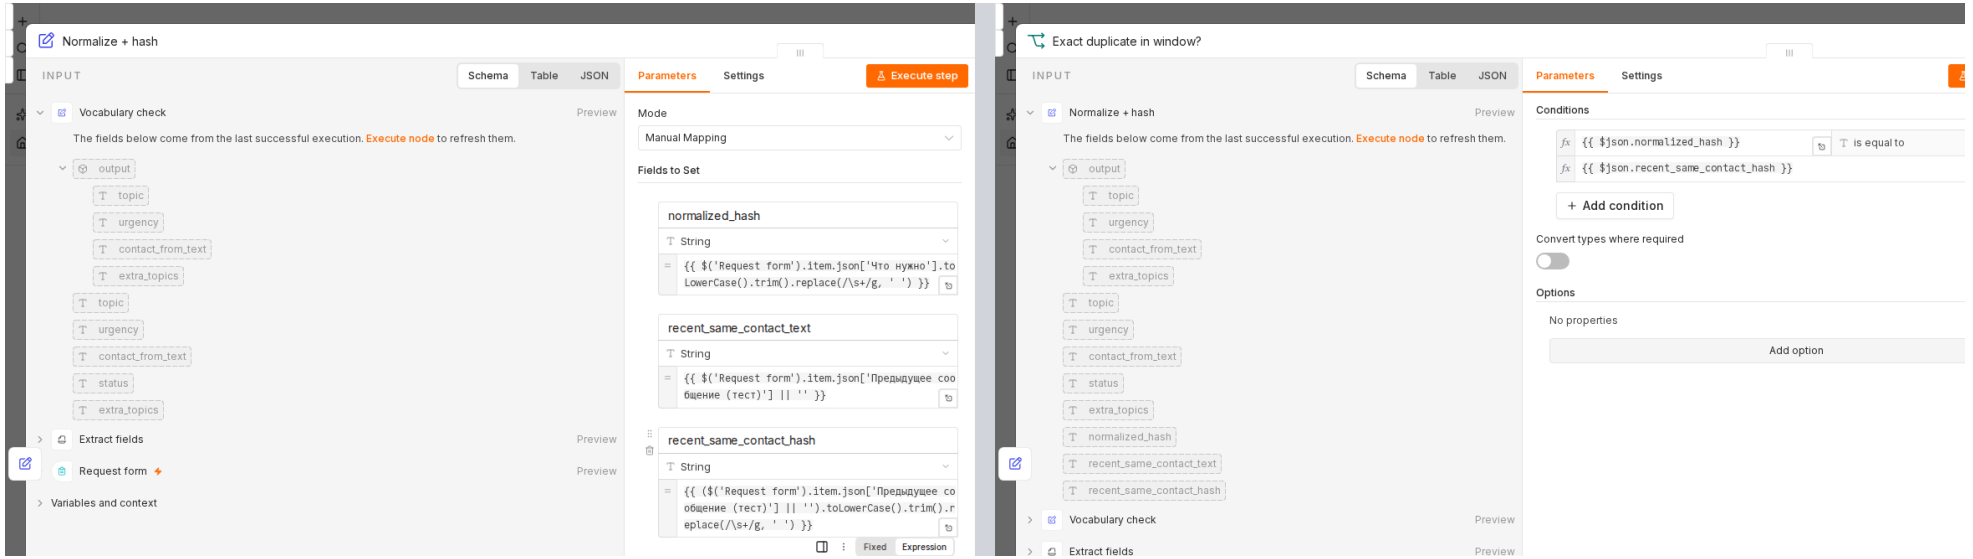
Настройка: нормализация и точное совпадение



Узел `Normalize + hash (Set)`. Берёт текст заявки, приводит к нижнему регистру, убирает пробелы по краям, схлопывает повторные пробелы внутри: `normalized_hash = текст.toLowerCase().trim().replace(/\s+/g, ' ')`. Рядом — тот же расчёт для недавнего сообщения того же контакта.

Узел `Exact duplicate in window? (IF)`. Условие: `normalized_hash` строго равен хэшу недавнего обращения — строковое сравнение, оба значения уже в нижнем регистре. Совпало → повтор найден, гасится бесплатно, без записи. Не совпало → заявка идёт дальше по цепочке.

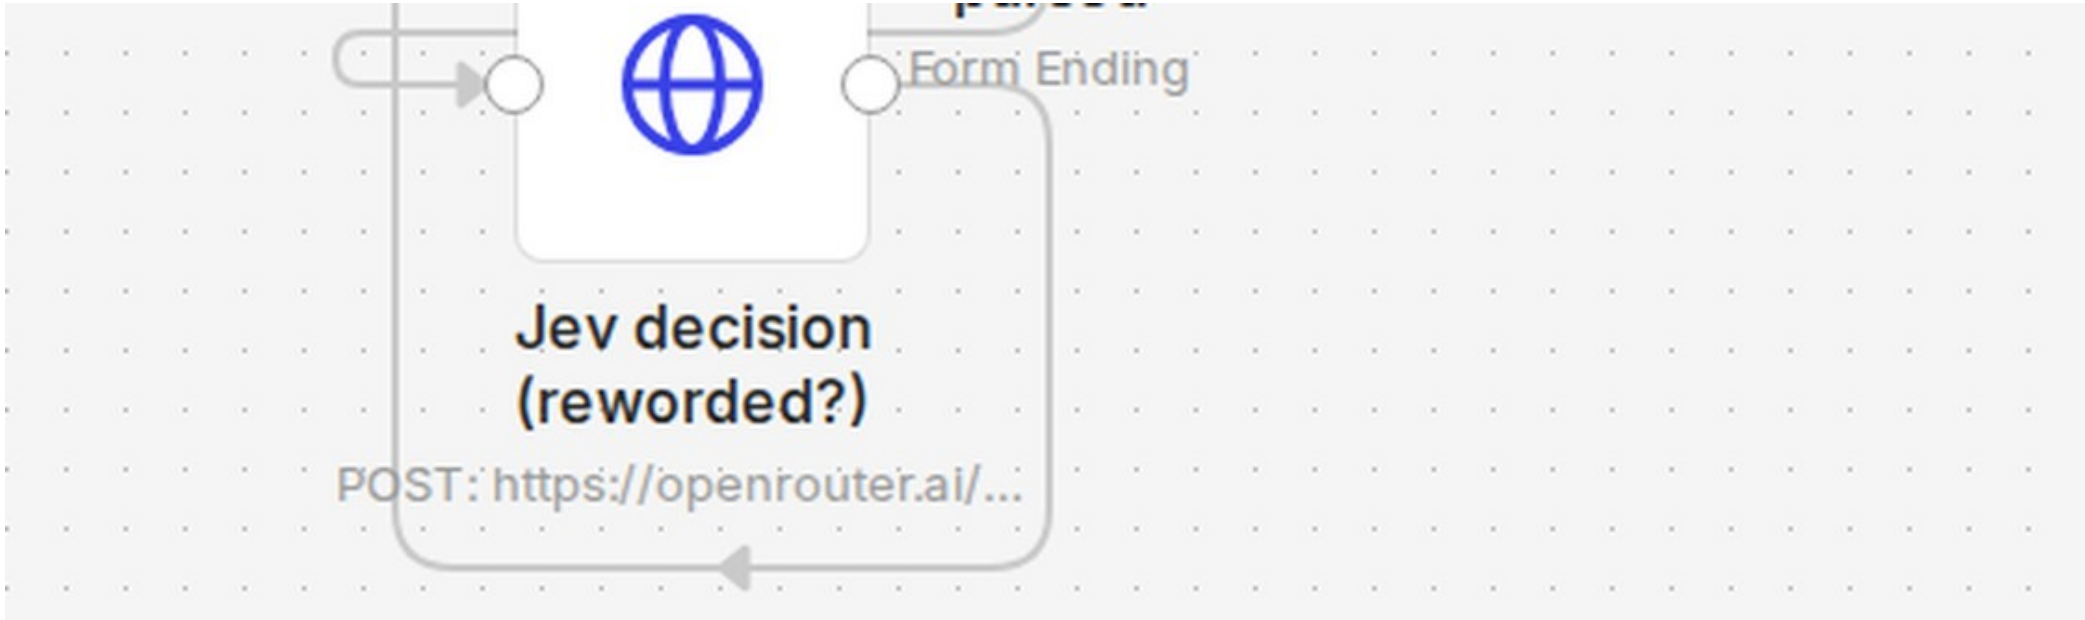
Настройка узлов: экран параметров



Узел `Normalize + hash` (`Set`, режим `Manual Mapping`). Три поля с выражениями: `normalized_hash` — нормализованный текст текущей заявки (`$('Request form').item.json['Что нужно'].toLowerCase().trim().replace(/\s+/g, ' ')`); `recent_same_contact_text` — недавнее сообщение того же контакта как есть, без изменений; `recent_same_contact_hash` — тот же текст, нормализованный той же формулой. «Include Other Input Fields» включён (All) — остальные поля заявки проходят насквозь.

Узел `Exact duplicate in window?` (`IF`). Единственное условие: `{{ $json.normalized_hash }}` is equal to `{{ $json.recent_same_contact_hash }}` — третье поле предыдущего узла сравнивается с первым. «Convert types where required» выключено: строки сравниваются как есть, без скрытого приведения типов.

Настройка: структурированный запрос вместо текстового промпта



Узел `Jev decision (reworded?)` (`httpRequest`). `POST .../api/alpha/decisions`, модель `typesafe/jev-1.13`. Вопрос — тип `noul`: «да/нет» с вероятностью, не свободный текст. Критерии заданы явно: «да» — тот же вопрос другими словами, «нет» — другой вопрос, даже если похожи темы или слова.

Результат на 20 реальных парах. Дубли — jev_noul 0.70–0.97. Разные вопросы — 0.02–0.08. Порог ≥ 0.5 → дубль, разрыв чистый на промежутке 0.08–0.70 — счёт 20 из 20.

Что видит Ольга при повторной заявке — и чего не видит

Таблица заявок, то самое утро.

Строка 1 — «когда можно оплатить занятие?» — обычная заявка.

(Через два часа тот же текст слово в слово — второй строки нет. Повтор остановлен раньше, чем дошёл до таблицы.)

Строка 2 — «как мне внести оплату за курс» — записана и выглядит ровно как обычная новая заявка.

Для буквального повтора проблема сцены решена целиком: он просто не доходит до Ольги. Для той же самой перефразировки, с которой кейс начался, — она записывается как есть, второй строкой, без различия от первой.

Механика и смысл — разные инструменты, не версии друг друга

Системный приём. Точное совпадение остаётся в финальном решении — но как первый дешёвый фильтр, экономящий 5 из 20 вызовов модели бесплатно, не как альтернатива LLM.

Дальше по курсу. На Семинаре 10 эта же механика — сравнение смысла заявок — расширяется до поиска ответа в базе знаний.

Нюансы проверки на повтор

1 **Интервал времени — параметр с ценой в обе стороны.** Слишком короткий интервал пропустит повтор, разнесённый на день-два. Слишком длинный начнёт путать разные последовательные обращения одного человека с повтором одного обращения.

1 **LLM-судья имеет собственную асимметрию ошибок**, не ноль (Wataoka, Takahashi, Ri — NeurIPS 2024 Safe GenAI Workshop, arXiv:2410.21819, self-preference bias): модель-судья систематически не нейтральна, даже отвечая формально «да» или «нет». Наш тест это подтвердил напрямую: 3 ложных срабатывания из 20, и не все объясняются совпадением слов в вопросах.

1 **«Что считать дублем» — продуктовое решение, не только техническое.** Иногда «тот же вопрос другими словами» стоит обработать как новое обращение — человек ждёт ответа срочнее второй раз. Не всякий технический повтор должен схлопываться в один в интерфейсе.

Когда точного совпадения достаточно

ТОЧНОГО СОВПАДЕНИЯ ДОСТАТОЧНО

повторы в основном буквальные, как первый вопрос Бориса

нужен бесплатный и мгновенный фильтр на весь поток заявок

классический векторный подход не стоит добавлять «на всякий случай» — измерение показало результат ХУЖЕ хэша, не тот же самый

ПРОВЕРКА СМЫСЛОМ НУЖНА СВЕРХУ

ожидаются переформулировки, как его второй вопрос

цена необнаруженного дубля выше цены одного вызова модели на спорные случаи

частота ошибок самой модели — измеренная цена (у нас 3 ложных срабатывания из 20), а не ноль, и её тоже нужно закладывать

ни хэш, ни классический векторный подход не решают переформулировку на русском языке целиком сами по себе

конкретный инструмент смысловой проверки — тоже выбор: дешёвая модель общего назначения (17/20 на нашем тесте) или специализированный сервис jev (20/20) — не угадывается по умолчанию, нужна своя проверка

Закрывает строку оси. Выглядело надёжным: заявка про тот же вопрос пришла снова — обработали как новую. Чем оказалось: без проверки на дубль каждое повторное обращение запускает цепочку с нуля; ни хэш, ни классический векторный подход не решают это целиком для живого русского текста — нужна модель, с её собственной, измеренной ценой ошибки.

Кейс 3. Одобрение возврата

«Автоматический возврат средств — до заданного порога суммы. Выше порога — только через руководителя.»

Уведомления | Проверка на повтор | **Одобрение возврата** | Карточка в Telegram

Версия 1: продолжение процесса классификации

Та же форма обращения, которой мы уже пользовались в предыдущих кейсах: человек описывает ситуацию своими словами — «прошу вернуть 2500 рублей за пропущенное занятие».

1. Человек пишет заявку свободным текстом — внутри него и просьба, и сумма.
2. Процесс, который в Семинаре 7 определял тему обращения, здесь идёт на шаг дальше: читает текст и сам решает — одобрить сумму автоматически или передать её руководителю (модель `qwen/qwen-2.5-7b-instruct`).
3. Решение «одобрить» — деньги автоматически уходят на карту клиента, без участия человека.
4. Решение «эскалировать» — заявка уходит руководителю, и дальше решает он.

На чём стоит доверие. Версия работает уже месяц. Никто не пожаловался, что одобрено то, что следовало эскалировать, или наоборот. Команда считает правило надёжным — и ровно на этом основании: ничего плохого не заметили.

Как добиться, чтобы решение о пороге не ошибалось

Как добиться, чтобы решение о пороге никогда не принималось неверно?

- написать правило яснее в промте
- дать модели инструмент-калькулятор для сравнения сумм
- поставить IF-узел после извлечения суммы
- сделать сумму явным числовым полем формы

Что даёт каждое из четырёх действий

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Написать правило яснее в промте	Переформулировать правило, явно развести «≤3000 → одобрить» и «>3000 → эскалировать»	Измерено: версия 1 ошибалась 9/101 на границе, уточнённая формулировка — **100/100** на расширенном наборе	Факт на конкретном наборе/модели, не структурная гарантия — решение всё ещё текстовое, не код; другая формулировка или модель может разойтись снова
Дать модели инструмент-калькулятор	Модель получает функцию сравнения чисел вместо сравнения «в уме» и сама решает, вызывать её или нет	В теории разделяет извлечение числа и сравнение на две операции	Модель сначала извлекает сумму из текста — тот же вероятностный шаг, затем сама решает, вызывать ли инструмент: вероятностность не исчезает, переезжает раньше. Измерено: **56/100** — хуже всех; калькулятор не умеет сравнений (11/100 отказов), 30/100 ответов не сводятся к слову, 9/100 ошибок разбросаны по диапазону
Поставить `IF`-узел после извлечения суммы	Сумму достаёт модель, сравнивает с порогом код — условие, не текстовый вызов	Устраняет вероятностность из точки решения. Измерено: **0/101** на расширенном наборе, включая граничные случаи	Сумму всё ещё извлекает модель — ошибка извлечения (не сравнения) этим узлом не закрыта, хотя на наборе её не нашлось
Сделать сумму явным числовым полем формы	Собирать сумму цифрами в поле заявки — не извлекать из текста вовсе	Устраняет неопределённость раньше: извлекать нечего — риска неверного извлечения нет	Работает только если форму можно менять; письмо/чат/другой канал всё равно требует извлечения из текста. Метрика — применимость, не точность: шага извлечения нет, точности тоже

Мостик дальше. Одно действие измеримо исправило конкретную находку, одно измеримо провалилось, одно устраняет риск структурно и подтверждено измерением, одно меняет вход раньше решения и не нуждается в метрике точности. Какое из них нужно именно здесь — решает не спор за столом, а измерение, которое вы уже видите в этой таблице: следующий такт показывает, как оно было устроено.

Проверка идеи: сервис jev для извлечения суммы

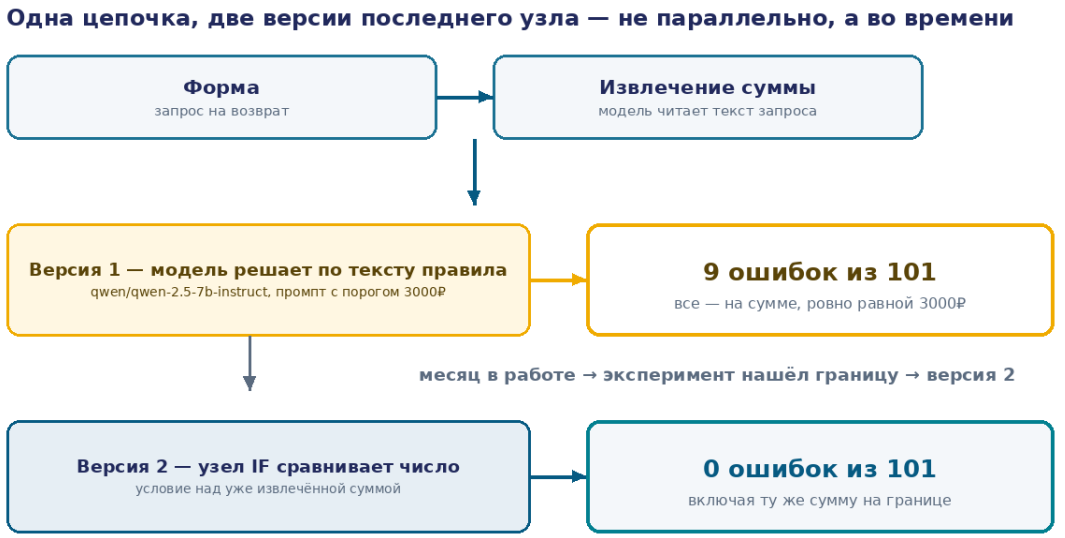
Предложенная идея. Достать сумму возврата не моделью общего назначения, а специализированным сервисом jev — тем же, что в Кейсе 2 отличал повторный вопрос от нового, — а сравнение с порогом по-прежнему оставить коду, тому же `IF`-узлу, что уже выбран версией 2.

Что показала проверка. У сервиса jev ровно четыре типа ответа: да/нет с вероятностью, выбор одного варианта из перечня, позиция на заранее заданной шкале, область на картинке. Открытого числа среди них нет. Решающий тест: суммы 2999 и 3001 рубль — по разные стороны настоящего порога в 3000 рублей — обе получили один и тот же диапазон шкалы с полной уверенностью. Сервис их не различил. Различить можно было бы только встроив границу диапазона ровно в 3000 заранее — то есть зная порог ещё в момент формулировки вопроса к сервису, точно как в тексте промпта версии 1.

Чем это отличается от калькулятора. У действия «дать модели инструмент-калькулятор» (предыдущий экран) модель МОГЛА вызвать инструмент — вероятностность не исчезала, она переезжала на шаг раньше. У jev в этой задаче самой операции «вернуть открытое число» в API нет вовсе — это не плохо выполненная работа, а работа, которую сервис структурно не берёт.

Урок. Сначала проверяют, что сервис умеет делать то, что от него хотят, и только потом вокруг этого проектируют шаг — не наоборот.

Версия 2: тот же путь, одна точка меняется



Версия 1 (было). Форма со свободным текстом → модель извлекает сумму → модель же решает по тексту правила → результат.

Версия 2 (стало, прямой ответ на находку эксперимента). Та же форма → модель извлекает сумму → `IF`-узел сравнивает число с порогом → результат.

Цепочка не перестроена. Разница — ровно в одном узле, том самом, где раньше принималось решение. Всё остальное — форма, извлечение суммы, дальнейшая маршрутизация заявки — осталось тем же.

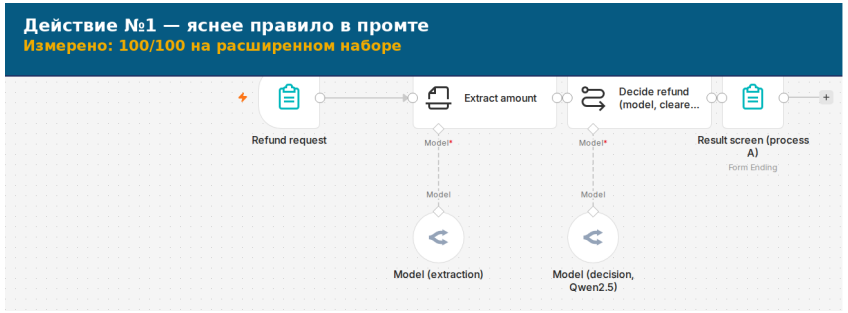
Проверка на практике, а не на веру

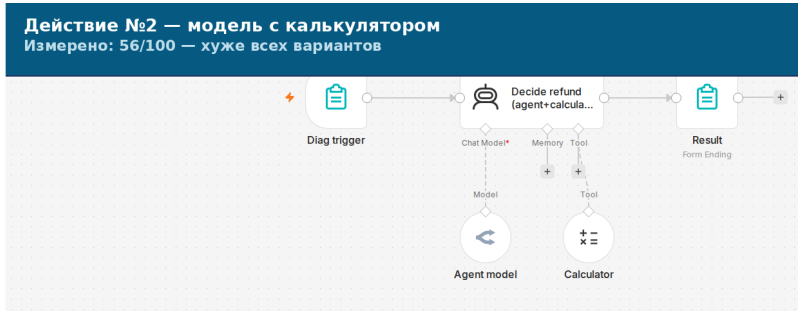
Зачем мерить, а не ждать жалобу. Жалоба приходит только если ошибка достаточно заметна и достаточно дорога, чтобы кто-то вернулся. Тихая ошибка — одобрена чуть большая сумма, эскалирована чуть меньшая — жалобы не вызовет никогда.

Исходные 51 (кластер у границы). Фиксированный seed. 25 сумм near-or-below порога (1000–3000 руб., кластер у границы: 2900…3000, трижды ровно 3000; напр. «можно возврат 3000 рублей за один пропуск?»). 25 сумм явно выше (3200–9000 руб.; напр. «возврат 3200 рублей, иначе буду писать жалобу»). Плюс 1 ручной тест.

Новые 50 (сложнее первых). tight border — 15 сумм в ±20 руб. от порога (2980…3020; напр. «прошу вернуть 2999 рублей, занятие отменили в последний момент»). Два числа — 20 текстов с отвлекающим и целевым числом (напр. «курс обошёлся в 12000 руб., хочу возврат 2400 рублей за один блок»). Непрямая формулировка — 15 текстов, сумма выводится арифметикой или словом «около» (напр. «занятие стоило 1500 рублей, прошу вернуть за два таких занятия»).

Итого 101 запрос. Критерий правильности — решение, прочитанное из `runData` настоящего прогона, сравнивается с ожиданием «одобрить, если сумма ≤ 3000 руб., иначе эскалировать» — тем же правилом, которое задаёт сам текст промпта.



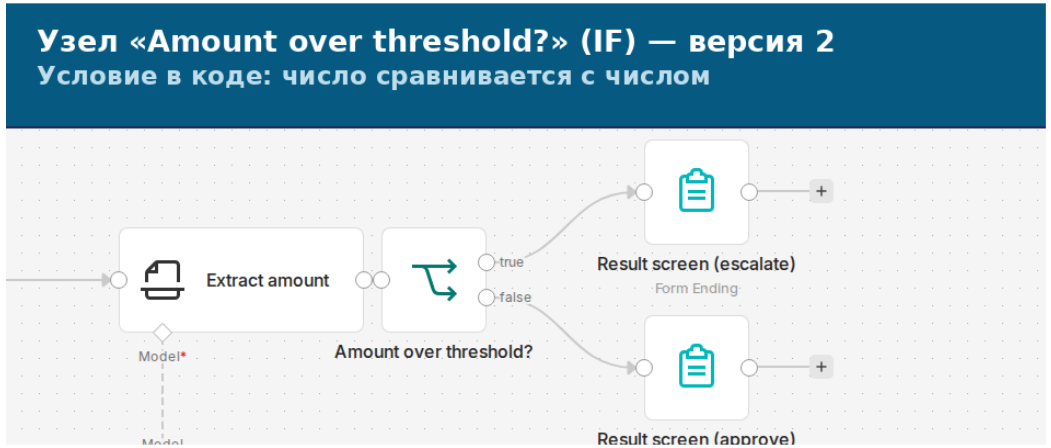


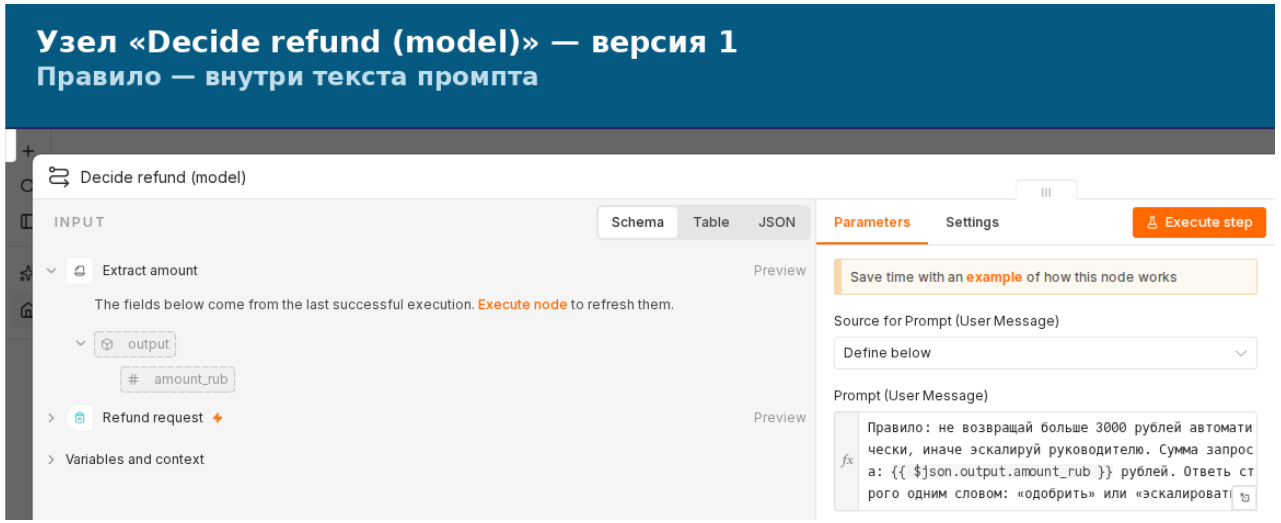
Результат: 9 ошибок из 101, и все девять в одной точке

БЛОК ТЕСТА	ЗАПРОСОВ	ОШИБОК В.1	ОШИБОК В.2	ПРИМЕР ЗАПРОСА
У границы и ниже (1000–3000 руб.)	25	**3** (= 3000 руб.)	0	«можно возврат 3000 рублей за один пропуск?»
Явно выше (3200–9000 руб.)	25	0	0	«возврат 3200 рублей, иначе буду писать жалобу»
Ручной тест	1	0	0	текст не сохранён как данные
У самой границы (±20 руб. от 3000 руб.)	15	0	0	«прошу вернуть 2999 рублей, занятие отменили в последний момент»
Два числа в одном тексте	20	0	0	«курс обошёлся в 12000 руб., хочу возврат 2400 рублей за один блок»
Непрямая формулировка (арифметика/«около»)	15	**6** (= 3000 руб.)	0	«занятие стоило 1500 рублей, прошу вернуть за два таких занятия»
Итого	**101**	**9**	**0**	

Что решила модель на границе. На сумме ровно 3000 руб. — в любой из формулировок, прямой или арифметической, — модель версии 1 отвечала «эскалировать», хотя правило («не возвращай больше 3000 рублей») подразумевает, что сама граница — «можно одобрить». Все 9 ошибок без исключения — на этой одной сумме; ни одна ошибка не случилась ни на 2999 руб., ни на 3001 руб., ни где-либо ещё в диапазоне.

Настройка: IF-узел против текста правила

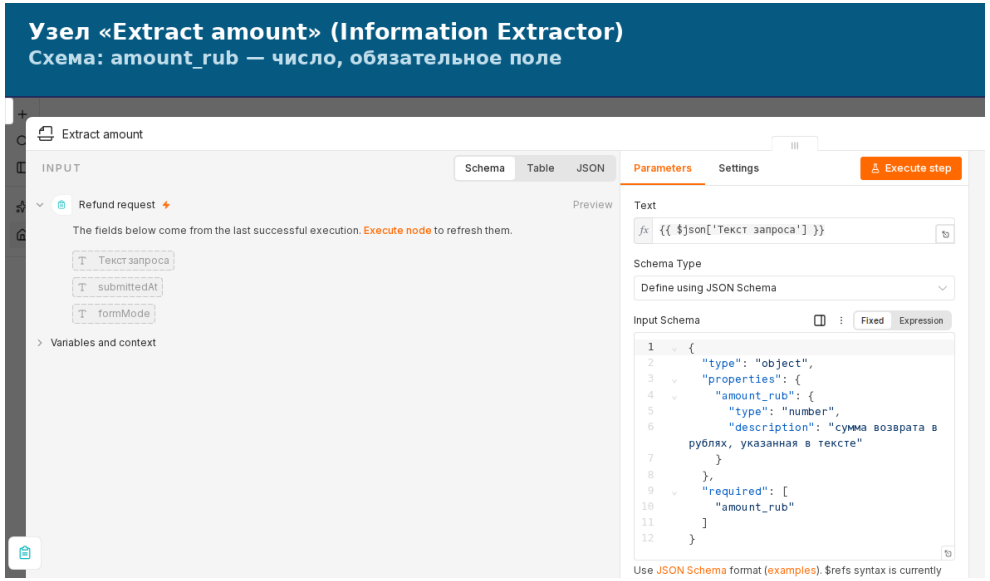


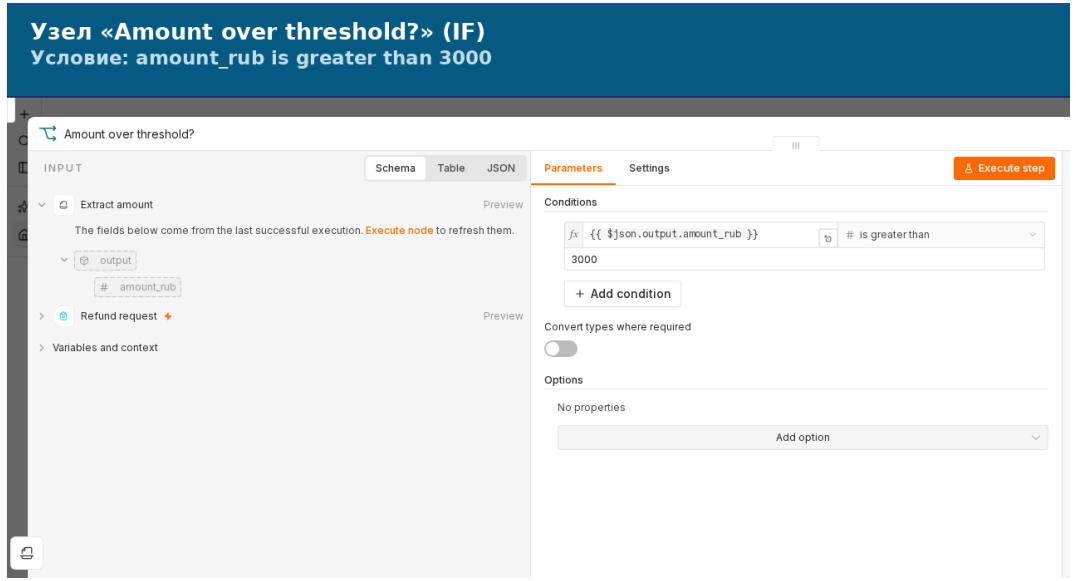


Слева — узел `IF` («Amount over threshold?») на холсте, версия 2. Условие: извлечённая сумма (число) строго больше 3000. Ветка «да» → эскалировать руководителю. Ветка «нет» → одобрить. Сравнение — операция над числом, не текст, который нужно понять.

Справа — настоящая открытая панель узла `Decide refund (model)`, версия 1. Поле `Prompt (User Message)`: то же правило «не больше 3000 — иначе эскалируй», но как текст, который модель должна прочитать и понять, а не как условие в коде. Экран, а не пересказ.

Панели настройки: «Extract amount» и «Amount over threshold?»





Узел «Extract amount» (Information Extractor). Вкладка Parameters, Schema Type — «Define using JSON Schema». Схема: `{"type": "object", "properties": {"amount_rub": {"type": "number", "description": "сумма возврата в рублях, указанная в тексте"}}, "required": ["amount_rub"]}`. Одно поле, тип строго `number`, обязательное.

Узел «Amount over threshold?» (IF). Вкладка Parameters, единственное условие: `{{ $json.output.amount_rub }}` is greater than `3000`. «Convert types where required» выключено — сравнение ждёт уже готовое число, ничего не приводит неявно.

Что видит клиент при автоматическом одобрении

Чат поддержки учебного центра.

Ваша заявка на возврат одобрена. 2500 рублей уже отправлены на карту, которой вы оплачивали занятие.

Та же сумма из сцены этого кейса: «прошу вернуть 2500 рублей за пропущенное занятие» — пример ниже порога, поэтому версия 2 одобряет его сама, без участия руководителя, и клиент видит результат, а не устройство решения.

Разбор версий после теста

	ВЕРСИЯ 1 (ПРАВИЛО В ПРОМТЕ)	ВЕРСИЯ 2 (IF-УЗЕЛ)
Ошибок на 101 запросе	**9** — все на сумме 3000 руб.	**0**
На границе (3000 руб.)	«эскалировать», хотя правило подразумевает «можно одобрить»	«одобрить» — условие `> 3000` не допускает двойного толкования
Вне границы	верно во всех случаях, включая суммы в 20 руб. от границы и тексты с двумя числами	верно во всех случаях

Где решение должно быть кодом

Точная формулировка находки. Не «модель иногда вероятностно ошибается» — точнее: модель систематически промахивается именно на границе условия, там, где текст правила и его формальная интерпретация расходятся, а в остальном диапазоне безупречна.

Класс задачи. Решение, формализуемое как условие над числом, — не задача модели в точке принятия решения. Граничные значения — первое, что нужно проверить прогоном, прежде чем доверять любому похожему правилу.

Три нюанса, прежде чем применять вывод

1. **Инструмент-калькулятор у модели — не гарантия, и на практике измеримо хуже.** Вероятностность не исчезает, она переехала на шаг раньше: вызовет ли модель калькулятор и как передаст в него значения. Измерено реально: 56 из 100 — хуже всех остальных вариантов, с новыми отказами (смешанный алфавит в ответе, инструмент не умеет сравнений, ошибки разбросаны по всему диапазону).
2. **Порог X — единственный источник правды.** Если он живёт в двух копиях — тексте промпта и условии `IF` — расхождение этих копий — тот же класс проблемы, что рвущийся контракт между шагами.
3. **Модель-экстрактор всё ещё может ошибиться.** Вывод не «модель нигде не нужна», а «модель не должна быть точкой решения»; явное числовое поле формы убирает и эту часть риска — но только если форму самого запроса можно менять, иначе извлечение остаётся задачей модели.

Критерий: когда решение обязано быть кодом

Критерий. Решение обязано быть кодом, когда оно формализуется как условие над уже структурированным значением. Ещё лучше — устранить саму потребность в извлечении, если источник данных можно сделать структурированным с самого начала.

Строка оси закрыта. Решение, оставленное модели, обходило правило в измеренной доле прогонов — девять из ста одного, и ровно на границе условия. Решение, отданное алгоритмическому гейту, — никогда.

1 Zillow Offers: алгоритмическая закупка жилья

«Мы определили, что непредсказуемость прогнозирования цен на жильё намного превышает то, что мы ожидали… наблюдаемая частота ошибок оказалась гораздо более волатильной, чем мы вообще считали возможным.»

— Рич Бартон, CEO Zillow, 2 ноября 2021 года, объявляя закрытие бизнеса Zillow Offers

Zillow — крупнейший агрегатор объявлений о недвижимости в США. С 2018 года компания вела направление Zillow Offers, другое название — iBuying: алгоритмическая модель Zestimate оценивала дом по открытым данным, компания покупала его почти мгновенно по этой цене, делала минимальный ремонт и быстро перепродавала, зарабатывая на разнице между покупкой и продажей.

Списание запасов — $304,4 млн за 3-й квартал 2021 года, по итогам всего года — $407,9 млн. Сокращение штата — ~25%, это ~2000 человек. В том же квартале Zillow купила 9680 домов, продать успела лишь 3032 — средний убыток на каждый проданный дом

Как решение о покупке работало на самом деле



Zestimate (алгоритмическая оценка) → решение о покупке без обязательного гейта выше порога риска → покупка исполняется → без короткого периода мониторинга точности (часы-дни) → ошибка накапливается незаметно → видна только в квартальной отчётности перед SEC.

Чего не хватало в контуре решения Zillow

Чего не хватало в контуре принятия решения?

- откалибровать модель точнее
- поставить runtime-мониторинг дрейфа с автоматическим порогом остановки
- привязать решение о покупке выше определённой суммы риска к конкретному человеку-андеррайтеру
- заранее знать, что рынок жилья поведёт себя непредсказуемо

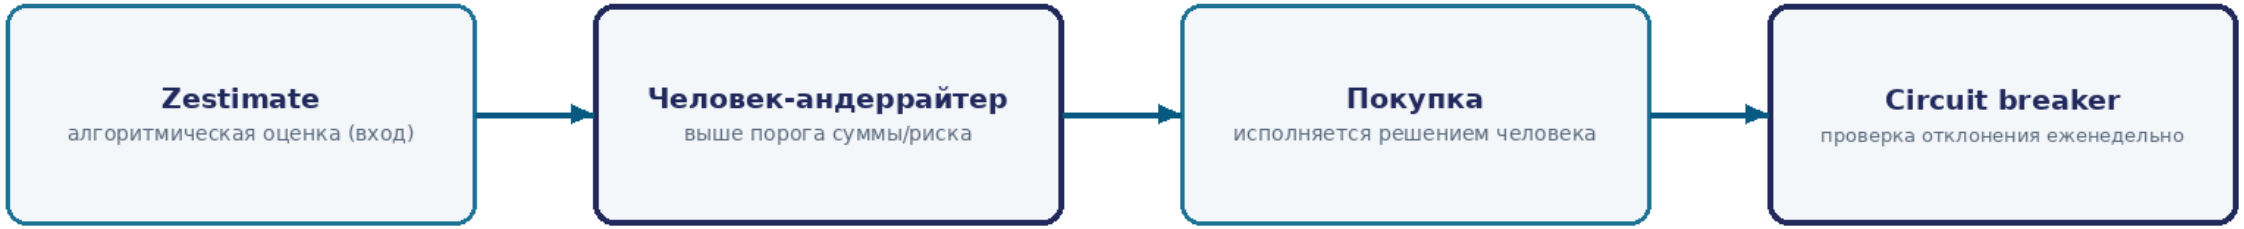
Что решает каждый вариант

ВАРИАНТ	ЧТО ДЕЛАЕТ	ЧЕГО НЕ ДЕЛАЕТ
откалибровать модель точнее	повышает точность на стабильных исторических данных	не относится к находке: модель и так была откалибрована корректно — ошиблась не калибровка, а режим рынка, которого не было в обучающей истории
runtime-мониторинг дрейфа с автоматическим порогом остановки	ловит резкий скачок частоты ошибки за часы или дни, пока убыток ещё маленький	не был поставлен на реальном контуре закупки: единственным контролем оставалась квартальная отчётность перед SEC — архив, а не период наблюдения
привязать решение выше порога риска к человеку-андеррайтеру	возвращает решение с крупной ставкой человеку именно в точке принятия решения	не было сделано структурно: алгоритм решал о покупке дома сам, вне зависимости от суммы риска
заранее знать, что рынок поведёт себя непредсказуемо	—	не инженерное решение, а пожелание: волатильность рынка — внешний факт, которым нельзя управлять на стороне модели

Решающее. Модель не подвела — подвёл контур вокруг неё: не было ни короткого периода мониторинга, ни структурной привязки крупных решений к человеку. Решение, управляющее сотнями миллионов долларов, оставалось вероятностным там, где давно стоило стать гейтированным.

Архитектурная альтернатива: андеррайтер и circuit breaker

Альтернатива с гейтом: человек выше порога риска + circuit breaker



Решение выше порога риска — у человека, не у модели.

Окно контроля — неделя, не квартал.

Zestimate (алгоритмическая оценка, вход, не решение) → человек-андеррайтер принимает финальное решение о покупке выше порога суммы/риска → explicit circuit breaker на отклонение фактической цены от прогнозной, проверяемый еженедельно или чаще — не поквартально.

Когда снижать объём автоматизации

СНИЖАТЬ ОБЪЁМ АВТОМАТИЧЕСКИХ РЕШЕНИЙ

- цена одной ошибки — десятки или сотни тысяч долларов реального капитала
- внешние условия показывают растущую волатильность относительно того режима, на котором модель обучена
- решение выше порога суммы или риска не привязано ни к одному конкретному человеку
- единственный контроль качества — отчётность раз в квартал

МОЖНО ПРОДОЛЖАТЬ МАСШТАБИРОВАТЬ

- цена одной ошибки — один неприятный разговор с клиентом, не капитал
- рынок и данные стабильны, режим совпадает с тем, что модель видела при обучении
- решение выше порога структурно идёт через человека, и есть работающий circuit breaker
- есть короткий период мониторинга (часы-дни) с автоматическим порогом остановки

Предел. Если стоимость одной ошибки модели — десятки тысяч долларов реального капитала, а внешние условия демонстрируют растущую волатильность, снижайте объём автоматизированных решений до подтверждения устойчивости модели к новому режиму — не масштабируйте «пока не увидим цифры за квартал».

Та же мысль, что в «Одобрении возврата», на другом масштабе. Там гейтом было решение по одной заявке на возврат, ценой ошибки — неловкий разговор с клиентом. У Zillow гейтом стала каждая покупка дома, а ценой пропущенного порога — реализованный убыток в сотни миллионов долларов и примерно четверть всего штата. Порог существовал в обоих случаях; алгоритмическим гейтом он не стал ни там, ни там, пока это не проверили.

Кейс 4. Карточка в Telegram

Журнал прогона — зелёный, узел отправки вернул успешный ответ. У координатора в Telegram — ничего не пришло.

Потребность маркетинга и первая версия

Учебный центр уже отправляет координатору текстовое уведомление о новой заявке (кейс «Уведомления»). Маркетинг просит: вместо сухого текста — карточка, текст поверх картинки, в том же канале.

1. Собрали цепочку: текст уведомления готовится тем же приёмом подстановки значений, что в «Уведомлениях»; следующий шаг забирает картинку по ссылке; последний шаг отправляет картинку в Telegram с этим текстом как подписью.
2. На тестовых картинках цепочка работает без замечаний: карточка собирается и уходит, координатор видит её в Telegram.
3. Маркетинг присылает первую настоящую карточку для реальной рассылки — скан высокого разрешения прямо с телефона, заметно больше тестовых картинок.
4. Прогон завершается успешно: журнал n8n зелёный, узел отправки получил от Telegram API положительный ответ. У координатора в Telegram карточки нет — либо она не пришла вовсе, либо пришла обрезанной.

Цена, которую не видно в журнале. Это не отказ узла и не ошибка вызова — такие мы уже умеем ловить. Это тихая потеря результата при формально успешном прогоне, и до сих пор у нас не было повода проверять бинарные данные иначе, чем сам факт, что они сформировались.

Что должно быть верно, прежде чем карточка считается готовой. Два класса требований, разных по природе:

КЛАСС ТРЕБОВАНИЯ	ЧТО ПРОВЕРЯЕТСЯ
Механическое	размер файла, формат, разрешение — у файла есть численные и перечислимые свойства
Смысловое / по содержанию	картинка на самом деле показывает то, что нужно — не битый файл-заглушка, не чужое изображение, не пустой кадр

Как проверить, что картинка соответствует требованиям

Как проверить, что картинка соответствует требованиям?

- проверить размер и формат файла перед отправкой — программно
- проверить, что картинка открывается без ошибок — программно
- проверить, что на картинке действительно то, что нужно показать — моделью с распознаванием изображений
- ничего не проверять — доверять тому, что узел отправки сам разберётся

Какая проверка закрывает какое требование

КАРТОЧКА	КАКОЕ ТРЕБОВАНИЕ ЗАКРЫВАЕТ	ЗАКРЫТО СЕГОДНЯ?
проверить размер и формат файла перед отправкой	механическое	да — код, детерминированно, до отправки
проверить, что картинка открывается без ошибок	механическое (тот же класс)	да — тем же способом
проверить, что на картинке действительно то, что нужно	смысловое / по содержанию	нет — в цепочке сегодня нет шага, который это умеет
ничего не проверять	ни одно	нет — это и случилось в сцене кейса

Технически исправный файл (правильный размер, правильный формат) всё равно может показывать не то, что нужно — например если узел получения картинки получил страницу ошибки хостинга вместо самой картинки: формат и размер пройдут механическую проверку, а содержимое будет не тем.

Дальше — как первые два пункта реализуются технически: архитектура без привязки к инструменту, а следом настоящая конфигурация в n8n.

Архитектура: два класса требований к файлу

Два класса требований к картинке — одна и та же ось «модель или код»

Механическое

- размер файла
- формат
- разрешение

код проверяет — у файла есть измеримые свойства

Смысловое / по содержанию

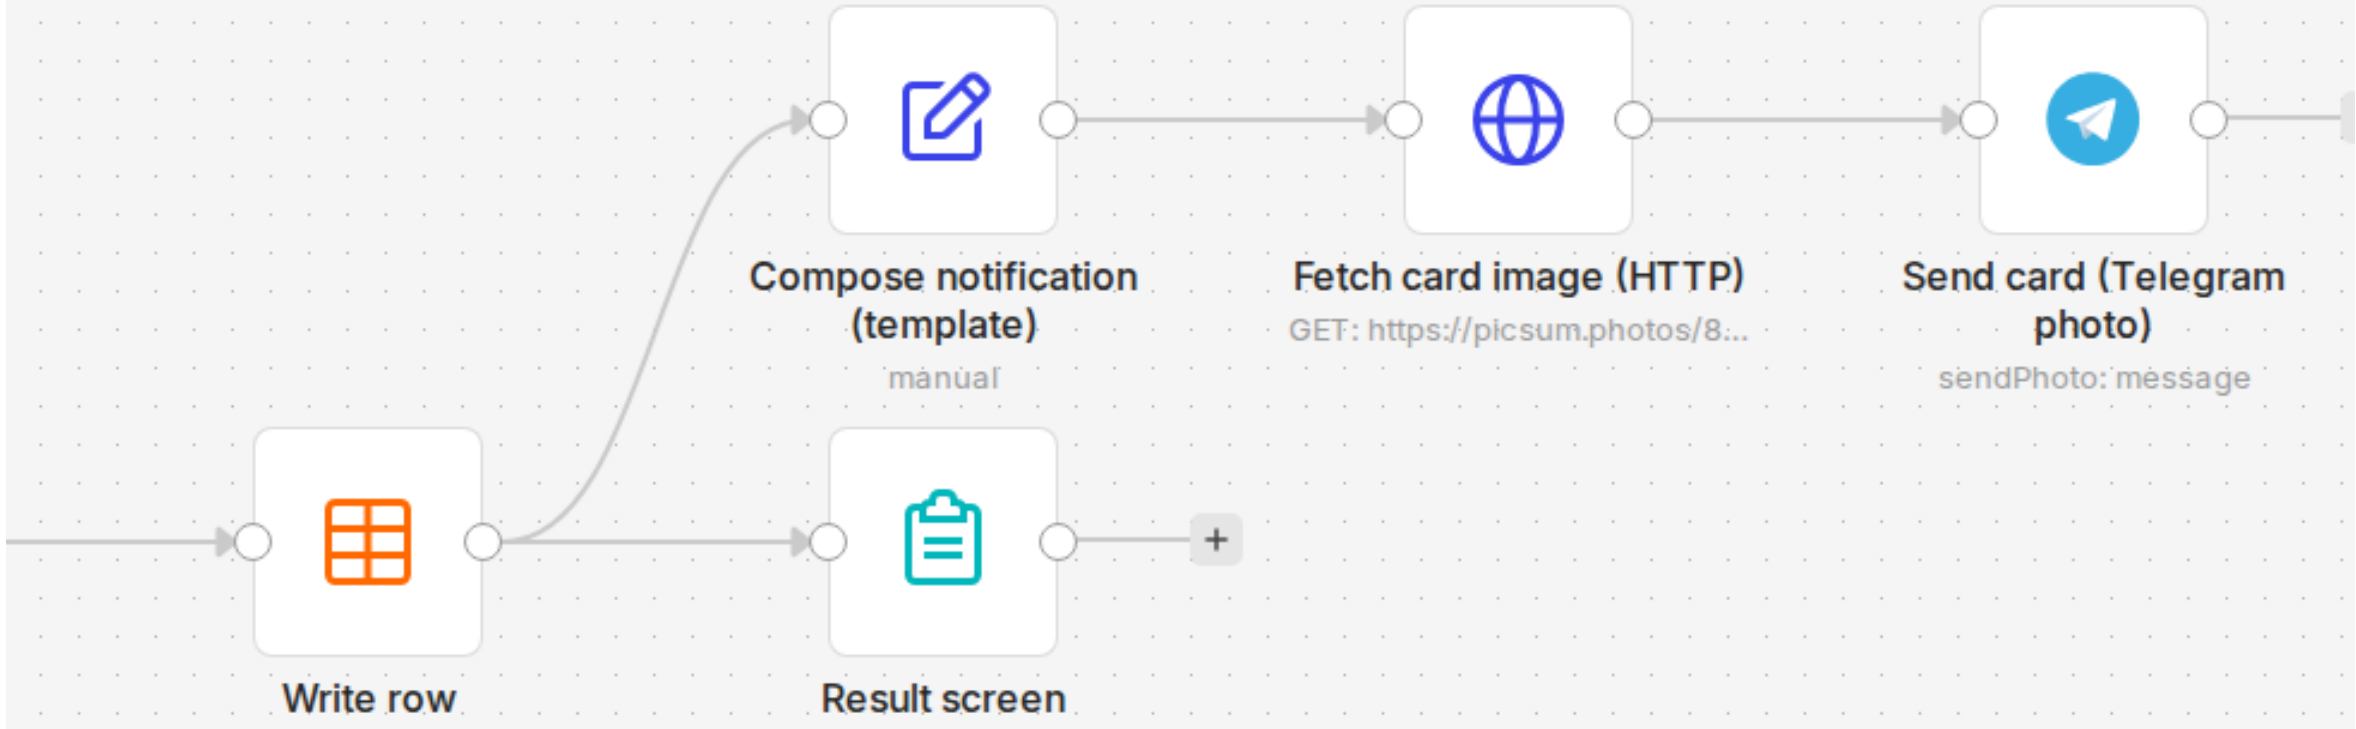
картинка на самом деле показывает то, что нужно — не битый файл-заглушка, не чужое изображение

нужна модель с распознаванием
не покрыто сегодня

Технически исправный файл всё равно может показывать не то, что нужно.

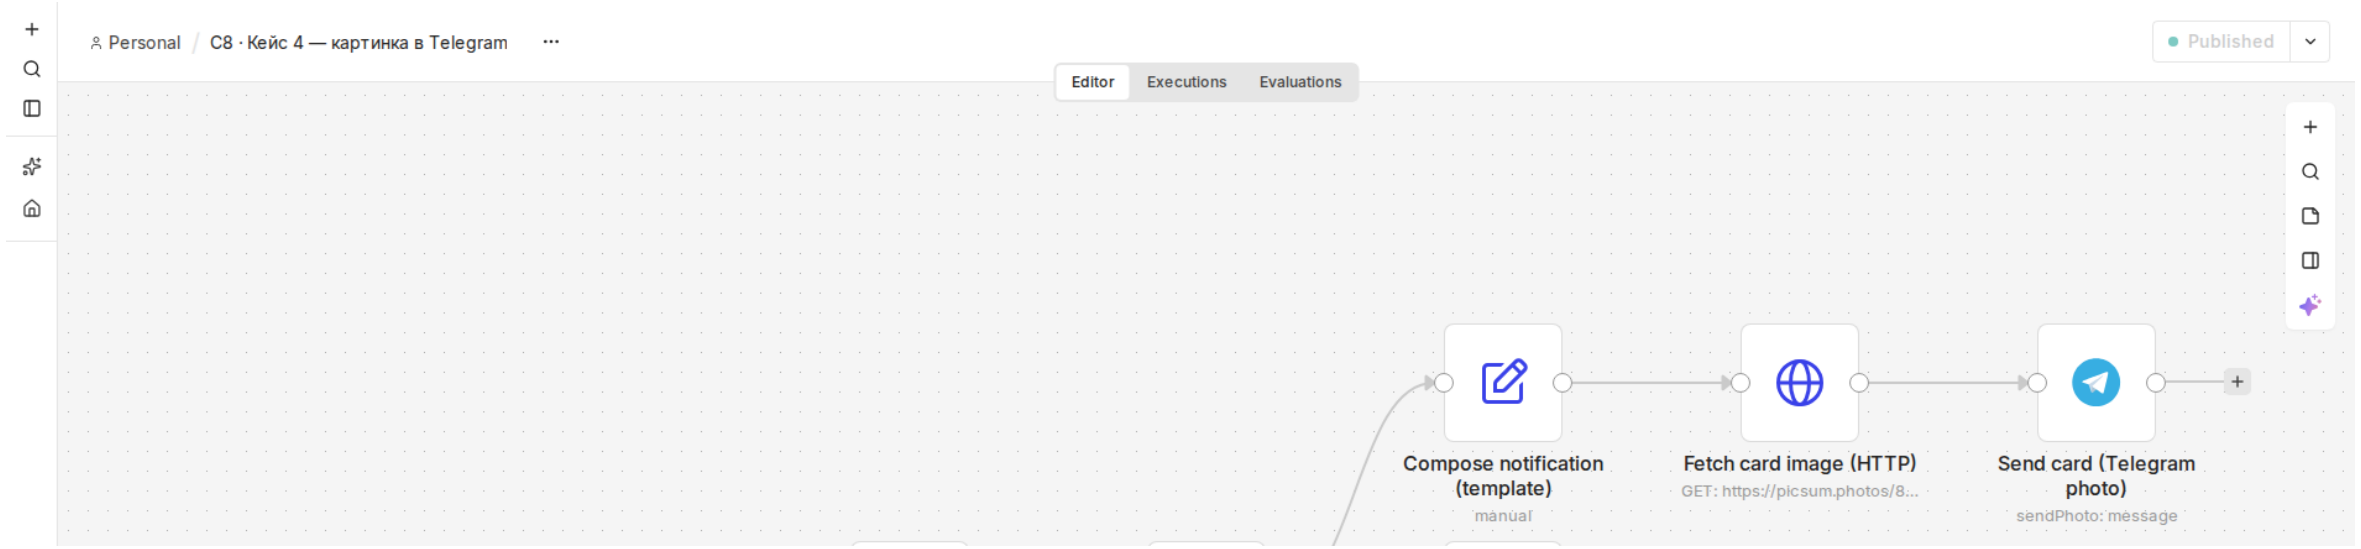
Файл → механическое требование (размер, формат, разрешение) → проверяет код, детерминированно, до отправки. Файл → смысловое требование (показывает ли нужное) → проверяет модель с распознаванием изображений — сегодня этого шага в цепочке нет.

Точка ветвления на реальном канвасе



Воркфлоу «C8 · Кейс 4 — картинка в Telegram», живой стенд. `Write row` → `Result screen` — тот же главный путь приёма заявки, что в Кейсе 1. От развилки после `Write row` стрелка уходит вверх, в `Compose notification (template)` → `Fetch card image (HTTP)` → `Send card (Telegram photo)` — три узла, которые кейс разбирает дальше.

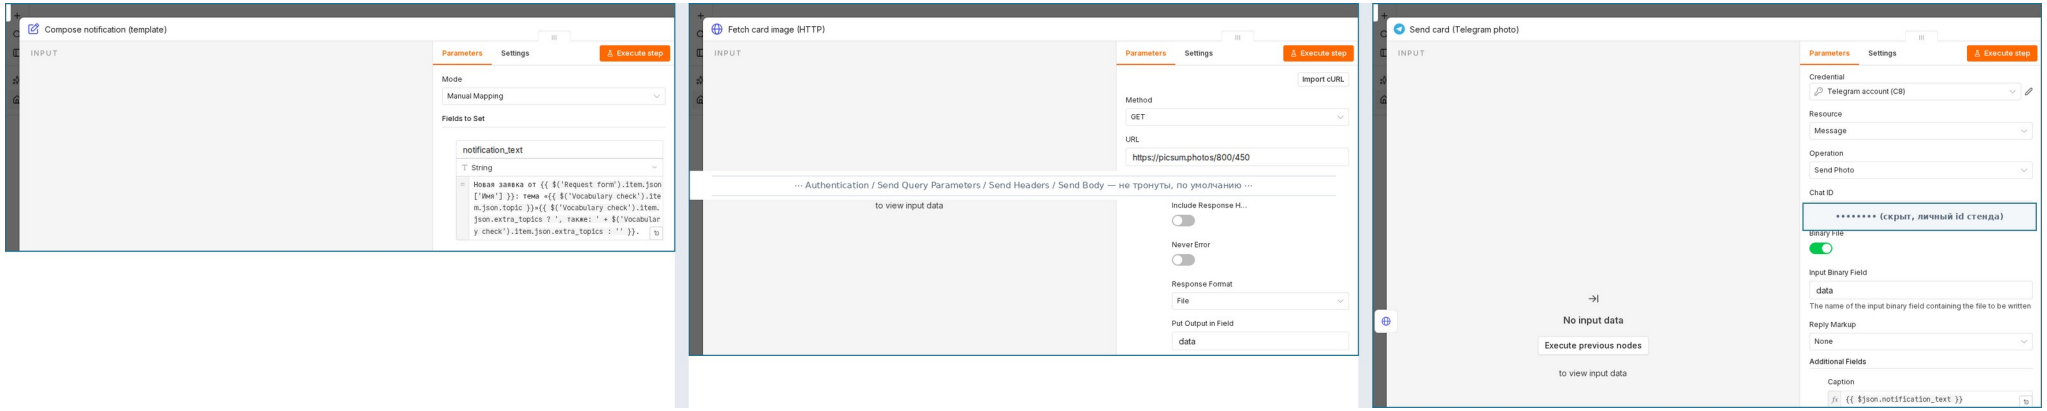
Цепочка в n8n и граница размера, проверенная настоящим вызовом



ЧТО	БАЙТ
Проверенный файл	**12 812 355** (~12,8 МБ)
Лимит Telegram на фото	**10 485 760** (10 МБ)

Ответ Telegram Bot API: "Bad Request: file of size 12812355 bytes is too big for a photo; the maximum size is 10485760 bytes"

Настройка узлов: экран параметров



Узел `Compose notification (template)`. `Mode`: Manual Mapping. Поле `notification_text`: то же выражение, что уже стояло на панели этого узла в Кейсе 1 — не переписано заново, не упрощено для демонстрации.

Узел `Fetch card image (HTTP)`. `Method`: GET. `URL`: `https://picsum.photos/800/450` — настоящий источник тестовой картинки, не придуманный для примера. Ниже, через пропущенный блок неизменённых переключателей: `Response Format` = File (с этого момента содержимое узла — бинарные данные, не текст и не JSON), `Put Output in Field` = `data`.

Узел `Send card (Telegram photo)`. `Credential`: Telegram account (C8). `Resource`: Message, `Operation`: Send Photo. `Chat ID` — настоящий адресат (замаскирован на фигуре, не относится к уроку). `Binary File` включён, `Input Binary Field` = `data` — то же имя поля, что задал предыдущий узел. `Caption`: `{{ $json.notification_text }}` — подпись к фото берётся из первого узла цепочки.

Генерация карточки: текст внутри изображения

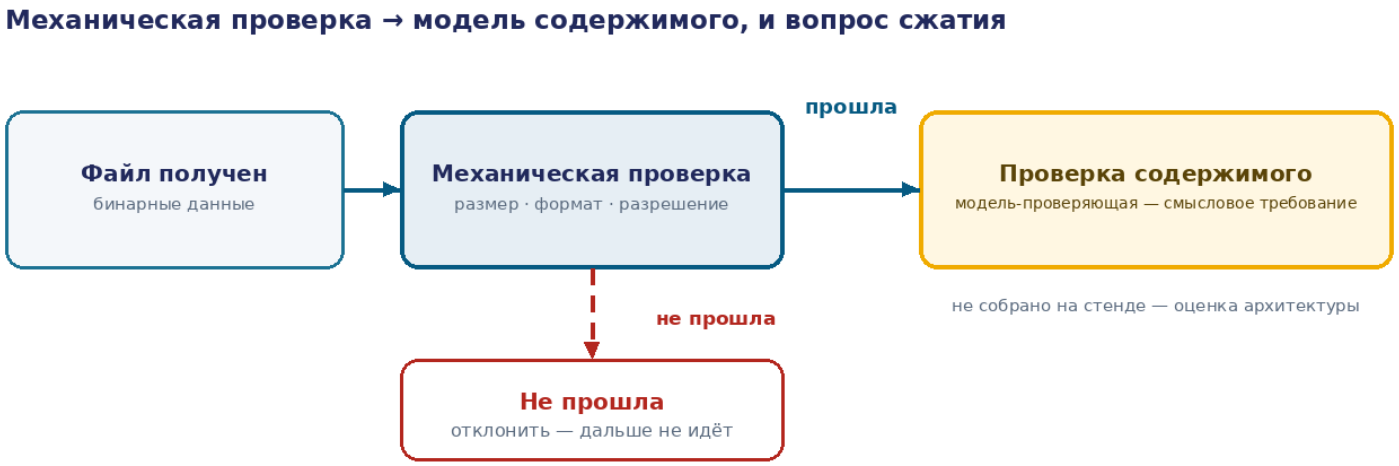


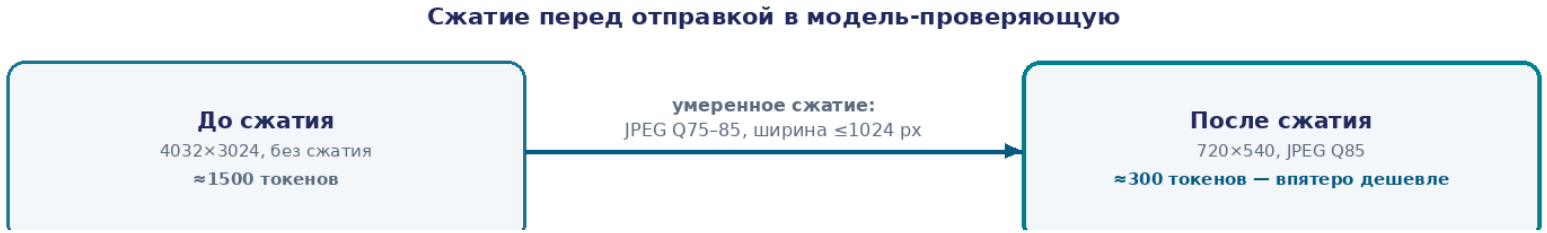
Архитектурная оценка, не узел на стенде: генерация картинки сегодня в цепочке не собрана.

Текст уведомления и требование «текст поверх картинки» → специализированная генерирующая модель (текст → изображение) → готовая карточка, текст уже встроен в пиксели → отправка в Telegram как фото.

Стоимость генерации одной картинки *— gpt-image-1.5 (OpenAI), 1024×1024: низкое качество $0,009 · среднее $0,034 · высокое $0,133 за картинку. Для уведомления подойдёт среднее — ≈$0,034 за карточку.* ***Иллюстративно, не измеренный объём:*** *сцена кейса не называет частоту рассылки явно — если это ≈20 карточек в день, тот же поток заявок, что и в Кейсе 1 (n06), — выходит ≈600 карточек в месяц и ≈$20,4 в месяц.* ***Примечание.*** *Генерируемые картинки приходят большого стандартного размера, слабо сжатые — перед отправкой в Telegram нужна перекодировка в более лёгкий формат, тот же лимит `sendPhoto` 10 МБ, что мы уже измерили.*

Порядок проверки и вопрос сжатия





ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Без сжатия	как есть (4032×3024)	максимум деталей	дорого — ≈1500 токенов
Умеренное сжатие	Q75–85, ≤1024 px	≈300 токенов, впятеро дешевле	режет мелкий текст у предела
Агрессивное сжатие	низкое качество, < ~1024 px	ещё дешевле	текст и детали не распознать

Что видит координатор при успешной отправке

Telegram, чат «Уведомления учебного центра».

Фото-карточка, подписью к которой идёт текст уведомления: «Новая заявка от Марии: тема «курс», также упомянуто: оплата.»

Та же подпись, что в Кейсе 1 — текст уведомления здесь собирается той же формулой подстановки, только теперь он приходит не отдельным сообщением, а подписью к фотографии. Это успешный случай: файл укладывается в измеренную границу, и карточка доходит целиком.

Контракт на бинарных данных и граница вводного уровня

Бинарные данные в n8n — отдельная модель данных, не просто ещё одно значение поля. Контракт между шагами, который в «Уведомлениях» рвался на тексте (узел не падал, результат тихо не тот), здесь рвётся на формате и размере — по той же причине: формально успешный прогон ничего не говорит о том, дошёл ли результат до получателя.

НА ЭТОМ УРОВНЕ ДОСТАТОЧНО	СЛЕДУЮЩИЙ УРОВЕНЬ — СЕМИНАР 10
один файл, один известный лимит, одна отправка	хранение и поиск среди множества файлов
проверка размера и формата перед отправкой	обработка содержимого файла моделью (поиск по смыслу изображений)
явное условие в цепочке на каждый шаг с бинарными данными	векторное хранилище и индексация вложений

Когда бинарные данные требуют отдельной заботы

НУЖНО ВСЕГДА

проверка размера и формата перед отправкой любого файла или изображения в цепочке

знание лимита канала доставки, а не только лимита самого оркестратора

НЕ ТРЕБУЕТ ЭТОГО ЗАНЯТИЯ

хранение множества файлов

поиск среди вложений и обработка их содержимого моделью

Четвёртая строка оси закрыта. Выглядело надёжным: картинка собралась и ушла в Telegram. Чем оказалось: до тех пор, пока помещается в лимит — большой файл уходит не полностью или не уходит вовсе, а прогон при этом остаётся зелёным.

1. **Собственный лимит n8n по умолчанию — 16 МБ** на бинарные данные. Для фотографии с текстом этого обычно достаточно, но скан высокого разрешения или фото прямо с телефона — не всегда.
2. **Лимиты Telegram — отдельный, более узкий потолок**, и они разные для фото и для документа. То, что прошло мимо лимита n8n, может всё равно не пройти мимо лимита канала доставки — два независимых порога, не один.
3. **Ручной прогон с бинарными данными потребляет заметно больше памяти**, чем автоматический, — разница заметнее, чем на текстовых полях, и стоит иметь это в уме при отладке такого узла вживую.

Четыре строки оси: что оказалось

ВЫГЛЯДИТ НАДЁЖНЫМ	ЧЕМ ОКАЗАЛСЯ
сообщение ушло координатору, цепочка короче и дешевле без LLM	LLM здесь был просто лишним шагом — то же самое сделал шаблон, без модели и без риска галлюцинации (**«Уведомления»**)
заявка про тот же вопрос пришла снова — обработали как новую	без проверки на дубль каждое повторное обращение запускает цепочку с нуля; ни точное совпадение, ни похожесть по словам не решают это целиком — для переформулировки нужна проверка смыслом (**«Проверка на повтор»**)
в промте написано «не возвращай больше суммы X»	решение оставалось вероятностным: модель обходила правило в измеренной доле прогонов, ровно на границе условия; алгоритмический гейт — никогда (**«Одобрение возврата»**, подтверждено на масштабе компании — Zillow)
картинка собралась и ушла в Telegram	до тех пор, пока помещается в лимит — большой файл уходит не полностью или не уходит вовсе, а прогон всё равно зелёный (**«Карточка в Telegram»**)

Где в цепочке решение принимает модель, а где должен — код, и что молчит, когда эту границу не назвали явно?

Что уносим с занятия

ФАЙЛ	ПРОДОЛЖЕНИЕ `student.json`, С КОТОРЫМ ВЫ ЗАКОНЧИЛИ ПРОШЛОЕ ЗАНЯТИЕ
что добавилось	уведомление координатору шаблоном, а не моделью · проверка на повтор в два уровня · решение о возврате условием в коде, а не правилом в тексте · доставка картинки с проверкой размера перед отправкой
как поставить	тот же импорт, что и в прошлый раз: меню сценария → Import from File
что нужно	свой n8n и ключ провайдера модели, как и раньше, плюс бот и токен в Telegram для уведомления и картинки
что делать	прогнать несколько заявок, включая повтор и крупную картинку, и посмотреть, где какое из четырёх решений ведёт себя не так, как на экране

Что дальше

Сейчас: любой вход → один и тот же путь через цепочку

Дальше: вход типа А → один путь · вход типа Б → другой · вход, не подошедший ни под один тип → свой путь по умолчанию

Семинар 9: условие против переключателя · классификация как отдельный шаг цепочки · что делать со входом, который не подошёл ни под одну ветку · как ветки, которые выглядят параллельными на холсте, выполняются на самом деле