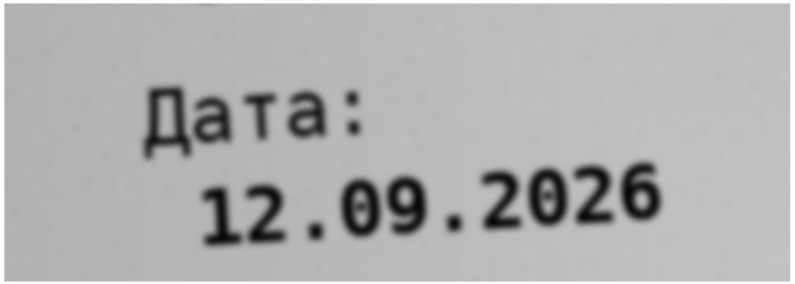
Модель, сжатие и во что обходится вызов

Полный размер — дата читается



53×64 px — то же поле



Модель. `qwen/qwen3-vl-8b-instruct`, тот же стенд, что и везде на этом семинаре.

РАЗРЕШЕНИЕ	ПИКСЕЛЕЙ	ТОКЕНОВ	ЦЕНА
полный	1698×2074	3673	$0,00096
половина	849×1037	1092	$0,00028
четверть	424×518	436	$0,00012
1/8	**212×259**	**300**	**$0,00009**
1/16	106×129	300	$0,00009
1/32	**53×64**	**300**	**$0,00009**

Порог цены наступает раньше порога чтения. До 1/8 токены падают в 12 раз, дальше — ни одного токена экономии. Дата ломается уже на этом пороге (1/8); сумма держится ещё на шаг дольше, но тоже ломается внутри той же бесплатной зоны, на последнем проверенном разрешении (1/32) — сжимать до предела цены можно совершенно бесплатно по деньгам, а вот по точности — платить уже приходится, и для обоих полей.