Что поймала проверка формата и что поймала сверка

Проверка формата ответа: 0 из 15 неверных дат поймано. Каждое из пятнадцати неверных значений — синтаксически правильная дата нужного вида «ДД.ММ.ГГГГ». Проверка схемы, если бы её применили, прошла бы все пятнадцать раз: формат в порядке, содержание — нет.

Сверка с независимо известным значением: 15 из 15 неверных дат поймано. Сравнение прочитанной даты с заранее известной истинной датой того же документа ловит каждое из пятнадцати расхождений мгновенно.

Ложных срабатываний нет на верных датах. На пятнадцати случаях, где дата была прочитана верно, та же сверка не сработала ни разу — 15 из 15 ВЕРНЫХ совпадений прошли проверку спокойно. (Знаменатель тот же, что у неверных дат выше, — совпадение после добора измерения; методической связи здесь нет: там считали расхождения, здесь — их отсутствие.)

Честно: почему демонстрация построена именно на дате. В этом же замере у суммы отказов заметно меньше — пять из тридцати, только на самом мелком разрешении, против пятнадцати у даты. Демонстрация построена на поле с бóльшим числом расхождений. В настоящей заявке независимое значение — это сумма, которую клиент сам написал текстом. Этот замер сверял прочитанное с заранее известной истиной генератора квитанции; текст клиента в вебхуке измерения отдельно не собирался.

Один вызов вместо двух: структура замера



Вопрос и устройство. Шаг чтения на стенде ведёт модель `qwen/qwen3-vl-8b-instruct` — зачем тогда разводить чтение и сверку на два шага? Этот замер даёт модели фотографию и текст заявки одним запросом: она сама называет сумму и дату и сама выносит вердикт. Температура вызова — 0,2, та же, что в двухшаговом устройстве.

30 вызовов: шесть размеров файла × пять повторов. На пятнадцати вызовах заявка несёт верную сумму — 18 990 рублей, ровно как на квитанции. На пятнадцати — одну из пяти других реальных сумм, заведомо неверную. Пример: файл уменьшен в 32 раза, заявлено 9800 — ожидаемый честный ответ модели: сумма 18990, вердикт «не совпало».

Свод: один и тот же итоговый счёт, разные причины

УСТРОЙСТВО	СУММА ВЕРНА	ДАТА ВЕРНА	ВЕРДИКТ СВЕРКИ ВЕРЕН
Два шага (модель читает, код сравнивает)	25 из 30	15 из 30	25 из 30
Единый вызов (модель читает и сама сравнивает)	27 из 30	15 из 30	25 из 30

Формальный выигрыш суммы требует проверки. У единого вызова сумма читается верно два раза чаще, чем у двухшагового устройства, — 27 против 25. Разбор на следующих двух экранах показывает: оба лишних «верных» ответа получены на самом тяжёлом разрешении — модель скопировала число прямо из заявки вместо того, чтобы прочитать его с фотографии.

Дата не меняется вовсе — и это ожидаемо. Заявка в этом замере несёт только сумму платежа, текста даты в ней нет. Единому вызову попросту нечем «подтянуть» дату к заявленному значению — у неё нет второго числа рядом. Порог даты держится там же, где и в чтении без всякой сверки.

Вердикт сходится по счёту, причины расходятся. Оба устройства дают 25 верных вердиктов из 30, но это два разных отказа под одним числом: у двухшагового кода ошибка вердикта в точности равна ошибке чтения; у единого вызова — свои, новые классы отказа поверх чтения.

Эхо заявки на самом тяжёлом разрешении

ПОВТОР	ЗАЯВКА ВЕРНА?	ЗАЯВЛЕНО В ТЕКСТЕ	СУММА, НАЗВАННАЯ «ПРОЧИТАННОЙ»	ЧТО МОДЕЛЬ ПИШЕТ, ЧТО ВИДИТ
1	нет	9800	**9800**	«9800»
2	да	18 990	18 990	«18 990,00 ₽»
3	нет	12 450	**12 450**	«12 450 ₽»
4	да	18 990	18 990	«18 990,00 ₽»
5	нет	27 300	**27 300**	«27 300»

Истинная сумма квитанции на всех пяти повторах — 18 990. Ни в одном из пяти ответов модель не называет это число, кроме случаев, где оно же стоит в заявке. Вердикт во всех пяти — «совпало», включая три случая с заведомо неверной заявкой (строки 1, 3, 5).

Безопасный отказ против опасного. На этом же разрешении двухшаговое устройство — без текста заявки под рукой — во всех пяти повторах называет одно и то же число, 1600, никак не связанное ни с истиной, ни с заявкой. Детерминированный код почти никогда не находит совпадения с этим числом, и заявка уходит на ручную проверку — отказ чтения оборачивается осторожностью. Единый вызов превращает тот же отказ чтения в подтверждение: неверная заявка получает штамп «совпало» и уходит дальше без проверки.

Самопротиворечие на самом чётком разрешении

ПОВТОР	СУММА, ПРОЧИТАННАЯ С ФОТО	СУММА ИЗ ЗАЯВКИ	ВЕРДИКТ МОДЕЛИ	ВЕРНО?
1	«18990,00»	«18990»	не совпало	**нет**
3	«18990,00»	«18990»	совпало	да
5	«18990,00»	«18990»	не совпало	**нет**

Три живых вызова, одна и та же фотография, одна и та же заявка — два разных исхода. Прочитанное число идентично во всех трёх повторах. Формат записи — разный: с «,00» у одного поля, без — у другого. Содержательно это одно и то же число. Модель дважды из трёх решает иначе.

Детерминированный код такой ошибки не делает. В двухшаговом устройстве тот же шаг сравнения — обычный код, который приводит оба значения к числу перед сравнением: «18990,00» и «18990» для него всегда равны. У единого вызова сравнение — ещё один языковой шаг той же модели, и у него собственная, отдельная частота отказа — на этих пяти повторах 2 из 5, при полностью исправном чтении.

Цена и итог: что на самом деле выигрывает слияние

РАЗМЕР ФАЙЛА	ЦЕНА: ДВА ШАГА	ЦЕНА: ЕДИНЫЙ ВЫЗОВ	РОСТ
исходный	$0,003803	$0,005089	+33,8%
вдвое меньше	$0,001192	$0,001835	+53,9%
в 4 раза	$0,000516	$0,000965	+87,1%
в 8 раз	$0,000383	$0,000754	+96,9%
в 16 раз	$0,000383	$0,000837	+118,3%
в 32 раза	$0,000372	$0,000722	+94,1%
Итого, 30 вызовов	**$0,006649**	**$0,010201**	**+53,4%**

Итог замера. Точность чтения — та же в обоих режимах, пороги деградации совпадают числом в число. Сверка в едином вызове ломается ровно там, где это дороже всего: опасным подтверждением на тяжёлом разрешении (прошлый такт) и самопротиворечием на самом чистом (позапрошлый такт). Цена выше на 34–118% по разрешениям, в среднем на 53%. Вывод: сверку суммы платежа стоит оставить детерминированным кодом после отдельного вызова чтения.