Один вызов вместо двух: структура замера



Вопрос и устройство. Шаг чтения на стенде ведёт модель `qwen/qwen3-vl-8b-instruct` — зачем тогда разводить чтение и сверку на два шага? Этот замер даёт модели фотографию и текст заявки одним запросом: она сама называет сумму и дату и сама выносит вердикт. Температура вызова — 0,2, та же, что в двухшаговом устройстве.

30 вызовов: шесть размеров файла × пять повторов. На пятнадцати вызовах заявка несёт верную сумму — 18 990 рублей, ровно как на квитанции. На пятнадцати — одну из пяти других реальных сумм, заведомо неверную. Пример: файл уменьшен в 32 раза, заявлено 9800 — ожидаемый честный ответ модели: сумма 18990, вердикт «не совпало».