Когда нужна сверка с независимым значением

КОГДА НУЖНО

У числа с фотографии есть второй, независимый способ узнать то же самое — например, то, что клиент написал текстом в той же заявке

Поле на документе набрано мельче остальных — у него свой, более ранний порог деградации, и именно оно чаще всего подведёт первым

Решение по прочитанному числу уходит дальше без второго чтения человеком

Цена неверно принятого числа — деньги или дата, которые нельзя тихо отменить постфактум

КОГДА НЕ НУЖНО

Второго независимого источника того же факта не существует вовсе — сравнивать не с чем, остаётся доверие единственному прочтению

Все поля документа набраны одинаково крупно, и запас по высоте символа большой на любом реалистичном сжатии

Документ в любом случае открывает и читает сотрудник до того, как решение на нём отправится

Цена ошибки ниже цены самой сверки, и расхождение, если оно случится, будет замечено и исправлено другим путём до того, как оно что-то стоило

Квитанции этого замера — синтетические. Все шесть сделаны для демонстрации механизма на управляемом примере с заранее известным ответом — это не замер качества модели на потоке живых документов учебного центра, где повторить именно эти числа нельзя.

Ломаются оба поля, но при разной высоте символа. Дата сломалась раньше, на восьмой доле (0 из 15), сумма — позже, только на самом мелком из размеров (0 из 5). «Фотографии читаются плохо» — обобщение шире измеренного: крупно набранное поле держится дольше мелкого, но не вечно.

1 **У чисел и денежных сумм — наименьший запас прочности среди типов данных документа.** На независимой проверке разборов финансовой отчётности точность по числовым факт-полям у разных моделей держится в диапазоне **52,65–66,83%** (FinCriticalED) — заметно ниже, чем можно было бы ожидать от поля, где цена неверного прочтения высока.

Шесть кейсов — шесть разных метрик

Оговорка: шкалы не сравнимы. *Разные задачи, базовые линии и N — это свод того, что каждый кейс измерил как главный результат. Рейтингом «кейс X лучше Y» это не является.*

КЕЙС	ЧТО ИЗМЕРЕНО	ЧИСЛО	N
Кейс 1. Отвечать или промолчать	доля плохих исходов, 3 устройства ответа	в.1 — 6 (40%) · в.1.5 — 8 (53%, худшая) · в.2 — 6 (40%)	15×3
Кейс 2. Оптимизация промта	доля верных на вопросе-границе, 5 форматов промта	0 из 8 верно во всех пяти — ни один не почистил ошибку	8 (84 всего)
Кейс 3. Проверка ответа	доля из 20 годных, 3 проверяющих	код — 20 (100%) · судья — 18 (90%, самопротиворечие) · код+судья — 17 (85%)	20
Кейс 4. Защита от инъекций и манипуляций	доля верных решений, правило в коде против лучшей защиты на модели	правило в коде — 64 из 64 (100%) · лучшая защита на модели (промт+механика) — 53 из 64 (83%)	64 · 64×8
Кейс 5. Повторяемость ответа	доля верных повторов, few-shot против описания	в.1: 0/10 · 10/10 — в.2: 0/10 · 6/10 (few-shot · описание)	10×2×2
Кейс 6. Чтение фотографии	доля верных прочтений поля, 6 уровней сжатия	сумма — 25/30, ломается на 53×64 px · дата верна до 424×518, 0/15 мельче	30 (6×5)

Что честно читается из всех шести вместе. Там, где решающий сигнал оставался внутри текста, который модель пишет о себе, — самооценка уверенности, промт-инструкция, пример-демонстрация, второй вызов той же модели в роли судьи, — лучший измеренный результат нигде не дошёл до безошибочного: потолок Кейса 1 — 40%, Кейс 2 — 0 из 8 на всех пяти направлениях, few-shot Кейса 5 — 0 из 10 дважды. Там, где решение вынесено туда, где его проверяет что-то кроме текста модели — код, отдельное числовое поле формы, прямое описание вместо примера, — три из шести измерений оказались безошибочными: код Кейса 3 (20 из 20), то же правило, посчитанное кодом, в Кейсе 4 (64 из 64), описание на первом вопросе (10 из 10). Четвёртое похожее измерение, сумма Кейса 6 по шести сжатиям, тоже вынесено за пределы самоотчёта модели — но после честного повтора 2026-10-27 уже не безошибочно: 25 из 30. Это и есть живой пример того, что вывод не гарантирует будущее: та же комбинация код+судья просела до 85%; то же описание на втором вопросе Кейса 5 дало уже 6 из 10 вместо 10; и сумма Кейса 6, державшаяся без ошибок на пяти разрешениях из шести, в итоге сломалась на самом мелком. Кейс 2 в эту закономерность не укладывается вовсе — там ни один вынесенный вариант правила (включая явную условную форму) не помог.