Знание вне промта

Процессы на больших языковых моделях: четвёртое занятие дуги.

Что остаётся от прошлого занятия

Процесс, с которым вы ушли с прошлого занятия, умел пять вещей: отвечать обратившемуся вместо того, чтобы молчать; проверять собственный ответ перед отправкой; решать по сумме возврата правилом, записанным в коде, вместо угадывания моделью; отвечать в одном устойчивом формате на каждый вызов; и, если к заявке приложена фотография, читать её вместо того, чтобы просто сохранять как вложение.

Вопрос, которым закончился С9, дословно: «При каком размере и изменчивости базы знаний „всё в промт“ перестаёт быть разумным?»

Учебный центр Ольги не стоит на месте: к базе каждую неделю что-то добавляется — новый регламент, обновлённый FAQ, разбор очередного спорного случая. Десять пунктов С9 — это база на момент запуска процесса; дальше она растёт.

Ось занятия: откуда процесс берёт факты и почему считает их верными

ВЫГЛЯДИТ НАДЁЖНЫМ	ЧЕМ ОКАЗЫВАЕТСЯ
если база выросла — просто перечислим её всю в промте, как на С9	
порезать документ на части можно как угодно, главное чтобы кусок попал в хранилище	
поиск по смыслу (вектор) и так находит то же самое, что поиск по словам, только умнее	
если умеем искать текст — картинку найдём тем же способом, просто подписав её словами	

Откуда процесс берёт факты и почему считает их верными?

Четыре строки — четыре кейса занятия. Правая колонка заполняется измеренным: прогоном нашего собственного стенда на реальных данных.

Четыре кейса и один разбавитель

1. **Хранение базы знаний** — что происходит с точностью и стоимостью ответа, когда база растёт с десяти пунктов до сотен документов.
2. **Разбиение документа на части** — когда база знаний превращается из десяти строчек в настоящие документы, их нужно сначала разрезать; от места разреза зависит, останется ли ответ на вопрос целым.
3. **Чем искать нужный кусок** — кусков в базе становится много, и способ поиска (по словам или по смыслу) не взаимозаменяем.
4. **Поиск по изображениям** — та же задача хранения и поиска, только для сканов и фотографий, которые учебный центр получает в заявках.

Разбавитель: система способна найти топически релевантный фрагмент и всё равно дать неверный ответ. «Найдено» и «верно» — разные вещи.

Кейс 1. Хранение базы знаний

Справочник учебного центра растёт каждую неделю: новый регламент, обновлённый пункт FAQ, разбор очередного спорного случая. Десять пунктов C9 — стартовая точка; дальше справочник только растёт.

Хранение базы знаний

Разбиение документа на части

Чем искать нужный кусок

Поиск по изображениям

Что Ольге нужно от растущей базы



Потребность. Ответ остаётся точным и дешёвым, даже когда база вырастет с десяти пунктов до сотен документов.

1. Версия 1 — естественное продолжение С9: дописывать базу в тот же промт, без ограничения сверху.
2. Ещё два реальных способа: искать по совпадению слов; искать по смыслу — через векторное хранилище.

Все три — реальные инженерные варианты. Какой выдержит рост базы — вопрос следующего экрана.

Как устроить базу знаний, которая растёт

Как устроить базу знаний, которая растёт?

продолжать дописывать базу в тот же промт

искать по ключевым словам

положить в векторное хранилище и вытаскивать нужный документ

Что делает каждое из трёх действий

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Продолжать дописывать базу в тот же промт	Весь текст базы на каждый вопрос заново уходит модели целиком	Не требует вообще никакой подготовки заранее — база просто лежит текстом в настройках процесса	Чем больше база, тем больше текста уходит на каждый вопрос — расход растёт вместе с базой
Искать по ключевым словам	Пересечение слов запроса и текста документа, без единого обращения к модели	Дёшево и быстро независимо от размера базы; подготовка — индексация по словам — делается один раз до прихода первого вопроса	Находит совпадение слов: смысл при этом не учитывается — вопрос, заданный другими словами, может не найти документ, в котором ответ на самом деле есть
Положить в векторное хранилище и вытаскивать нужный документ	База заранее превращается в числовые представления смысла; по запросу находится то, что ближе всего по смыслу, без точного совпадения слов	В промт попадает только найденный документ — объём всей базы на расход не влияет	Требует отдельного шага подготовки заранее: для каждого документа базы нужно посчитать эмбеддинг, прежде чем придёт первый вопрос

Структура замера: десять вопросов, четыре размера, три действия

Что в замере. База — 10 · 50 · 200 · 500 документов, один и тот же набор из 10 вопросов. Модели: `gpt-4o-mini` и `text-embedding-3-small`, без явно заданных настроек. Пример: «Как называется круг кровообращения, функционирующий через лёгкие?» — ответ «малый», документ `needle-1`.

ДЕЙСТВИЕ	КАК НАХОДИТСЯ ТЕКСТ ДЛЯ ОТВЕТА	ВЫЗОВОВ МОДЕЛИ
Промт целиком	ничего не ищется: вся база уходит в промт	**1**
Поиск по словам	**полнотекстовый.** Вопрос и документ **целиком** режутся на слова, побеждает наибольшее число совпавших. Модели на этом шаге нет — это обычный код	**1**
Поиск по смыслу	**векторный.** Документ **целиком** заранее переведён моделью в вектор, вопрос — тоже; побеждает ближайший. На куски не режется — это Кейс 2	**2**

Что дальше с найденным. Документ целиком уходит в промт второго вызова — модель отвечает только по нему. У поиска по смыслу первый вызов считает вектор вопроса, второй отвечает.

Что показал прогон на четырёх размерах базы

ДОЛЯ ИЗ 10 ВОПРОСОВ	10 ДОКУМ.	50 ДОКУМ.	200 ДОКУМ.	500 ДОКУМ.
Промт целиком — ответил верно	0,7	0,7	0,7	**отказ, HTTP 400**: ≈160 000 токенов при контексте модели 128 000
Поиск по словам — нашёл нужный документ	0,8	0,8	0,8	0,8
Поиск по словам — ответил верно	0,5	0,5	0,4	0,5
Поиск по смыслу — нашёл нужный документ	1,0	1,0	1,0	0,9
Поиск по смыслу — ответил верно	0,6	0,7	0,6	0,7

ЦЕНА ОДНОГО ВОПРОСА	10 ДОКУМ.	50 ДОКУМ.	200 ДОКУМ.	500 ДОКУМ.
Промт целиком	$0,000189	$0,000809	$0,003204	запрос отклонён
Поиск по словам	$0,0000484	$0,0000484	$0,0000501	$0,00005
Поиск по смыслу	$0,0000486	$0,0000482	$0,0000481	$0,000049

Систематическая ошибка поиска по словам: падежные формы

Ошибка 1 — падежные формы на всех размерах базы, включая 10 документов без дистракторов.

ВОПРОС И ВЕРДИКТ	КАКОЙ ДОКУМЕНТ ОЖИДАЛСЯ	КАКОЙ ДОКУМЕНТ ВЫБРАН	ПОЧЕМУ ВЫБОР УШЁЛ В СТОРОНУ
«В каком году была возрождена дискуссия палеонтологами Нильсов Элдриджем и Стивеном Гулдом?» Правильный ответ — «1972». Вердикт: **НЕВЕРНО**	`needle-4`, о современном синтезе в эволюционной биологии: «…в 1972 году палеонтологи Элдридж и Гулд…». Совпало **одно** слово — «году»	`needle-2`, о материальном положении Моцарта в 1789 году. Совпало тоже **одно** слово — «году»	Имена в вопросе в творительном падеже, в документе — в именительном: для метода «палеонтологами» и «палеонтологи» разные слова. Счёт 1 : 1, при ничьей берётся тот, что в базе раньше
«Как звали учёного, модель системы мира которого была взята за основу Кеплером?» Правильный ответ — «Коперник». Вердикт: **НЕВЕРНО**	`needle-10`, о кеплеровской системе мира: «…система мира основана на модели Коперника…». Совпало **одно** слово — «мира»	`needle-3`, о марафоне как олимпийской дисциплине. Совпало **два** — «модель» и «мира»	В верном документе те же слова стоят в других формах: «модели» против «модель», «система» против «системы». Счёт 2 : 1 в пользу марафона

Один вопрос, на котором промахнулись оба способа: температура на марафоне

Вопрос. «Какая температура летом не даёт возможности марафонцам показывать наилучшие результаты?» Правильный ответ — «высокая»; размечен он в документе `needle-3`, о марафоне как олимпийской дисциплине.

СПОСОБ ПОИСКА	КАКОЙ ДОКУМЕНТ НАШЁЛ	ЧТО ОТВЕТИЛА МОДЕЛЬ	ВЕРДИКТ И ПОЧЕМУ
Поиск по словам, одинаково на всех четырёх размерах	`needle-3` — **нужный**. Последняя фраза: «…это высокая температура летом, которая не позволяет показывать марафонцам наилучшие результаты»	«нет информации»	**НЕВЕРНО.** Ответ стоял в найденном тексте дословно. Судя по ответу, вопрос «какая температура» прочитан как просьба назвать градусы, а градусов в этом абзаце нет
Поиск по смыслу, только на 500 документах (на 10 · 50 · 200 — тот же `needle-3` и тот же ответ)	`distractor-237` — по общей сноске [17] это соседний абзац той же статьи про марафон. Градусы есть в нём: «… выше 14—16 °C результат ухудшается»	«Температура выше 14—16 °C ухудшает результаты марафонцев»	**НЕВЕРНО.** По существу ответ разумен, но эталон ждал слова «высокая», а оно размечено в другом абзаце

Что подтвердил замер: дописывать всё в промт

Модель, которая формирует финальный ответ во всех трёх действиях, — одна и та же: `gpt-4o-mini`, без явно заданных настроек вызова. Действие 3 дополнительно использует `text-embedding-3-small` для поиска.

Accuracy (точность ответа) — в скольких из десяти вопросов эталонный ответ встретился в ответе модели дословно.

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Дописывать всё в промт	Весь текст базы на каждый вопрос заново уходит модели целиком	Accuracy держится на одном уровне, 0,7, на 10/50/200 документах — без видимого предупреждающего сигнала	Стоимость растёт в 17,0 раза на 10→200 документах при той же точности; на 500 документах не работает вовсе — запрос превышает контекст модели, без предварительного падения качества

Что подтвердил замер: искать по словам и по смыслу

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Искать по ключевым словам	Пересечение слов запроса и документа, без модели	Цена не зависит от размера базы: ~$0,00005 на любом из четырёх	recall@1 = 0,8 на всех четырёх размерах, с ростом базы не меняется: сравнение слов без учёта падежных форм
Класть в векторное хранилище	Сравнение эмбеддингов вопроса и документов; в промт идёт найденный документ	~270 токенов и ~$0,00005 на любом размере базы; recall@1 = 1,0 на 10/50/200 документах	Нужен отдельный шаг подготовки — эмбеддинг каждого документа до первого вопроса; recall@1 проседает до 0,9 на 500 документах

Точность ответа на 10/50/200 документах: промт целиком 0,7 · поиск по смыслу 0,6–0,7 · поиск по словам 0,4–0,5. По точности поиск на малых базах промту целиком не выигрывает: выигрыш — в цене и в работе на 500 документах, где промт целиком отказывает. recall@1 — доля вопросов, где нужный документ нашёлся первым.

Где хранится база и что видит модель

Вместо того чтобы на каждый вопрос передавать модели всю базу целиком, процесс хранит базу отдельно от разговора. По каждому новому запросу он сначала находит в этом хранилище подходящий текст — в Кейсе 1 это один документ целиком — и только его кладёт в промт, оставляя остальную базу в стороне.

Настоящий холст: векторное хранилище в n8n



И шаг эмбеддинга, и финальный вызов модели собраны обычным узлом HTTP Request с предустановленным типом учётных данных — отдельного штатного узла «эмбеддинг через OpenRouter» в каталоге n8n нет.

Прогон на этом холсте. Вопрос: «При каком давлении удалось получить кристаллы гелия?» · найден документ про кристаллы гелия у Камерлинг-Оннеса, сходство 0,590, первое место среди десяти документов · ответ модели: «При давлении выше 35 атм.»

Настоящая панель: код узла поиска

JavaScript

```
const payload = JSON.parse($('Вопрос + корпус с векторами').first().json.payload);
const qvec = $input.first().json.data[0].embedding;
function cos(a,b){let d=0,na=0,nb=0;for(let i=0;i<a.length;i++){d+=a[i]*b[i];na+=a[i]*a[i];nb+=b[i]*b[i];}return d/(Math.sqrt(na)*Math.sqrt(nb));}
let best=null,bestScore=-1;
for(const doc of payload.corpus){const s=cos(qvec,doc.embedding);if(s>bestScore){bestScore=s;best=doc;}}
return [{json:{question:payload.question,chunk:best.text,doc_id:best.id,score:bestScore,model:payload.model}}];
```

Узел «Simple Vector Store» — это цикл по всем документам корпуса и ручная функция косинусного сходства: без вызова отдельного сервиса.

Настоящая панель: промт узла ответа

Prompt (User Message)

```
Отвечай ТОЛЬКО по тексту ниже. Если ответа нет в тексте — напиши «нет информации».

Текст:
{{ $json.chunk }}
```

> *«Отвечай ТОЛЬКО по тексту ниже. Если ответа нет в тексте — напиши «нет информации». Текст: `{{ $json.chunk }}`»*

Что видно Ольге, а что — обратившемуся

Обратившемуся разница не видна. По точности ответа на 10, 50 и 200 документах промт целиком держит 0,7, поиск по смыслу — 0,6–0,7, поиск по словам — 0,4–0,5. На 500 документах промт целиком отказывает совсем, и там отвечает только поиск, с прежней точностью. Выигрыш поиска — в цене и в том, что на большой базе он продолжает отвечать; в точности выигрыша нет. Ольге видно именно это: от выбора зависит цена каждого следующего ответа, когда база вырастет.

Принцип переносится на любой оркестратор: n8n здесь просто пример. Промт, в который целиком кладётся база знаний, растёт в стоимости линейно с размером базы и не гарантирует роста точности — внешнее хранилище, из которого на каждый вопрос достаётся только нужный документ, держит стоимость и объём промта постоянными независимо от того, сколько документов накопилось.

Когда хранилище окупается, а когда — нет

Критерий. Внешнее хранилище окупается, когда рост базы делает промт-стаффинг либо заметно дороже, либо структурно невозможным — а не самим фактом наличия базы.

КОГДА НУЖНО

- База растёт заметно быстрее, чем раз в год, и счёт идёт на сотни документов
- Стоимость вызова уже измеримо больше нуля и видна на счёте за месяц
- Размер базы может однажды превысить контекст модели

КОГДА НЕ НУЖНО

- База — те же десять-двадцать пунктов FAQ, что и на прошлом занятии, и расти не планирует
- Разница по стоимости ($0,0002 против $0,00005) ещё не оправдывает отдельный шаг подготовки
- До предела контекста далеко, и структурного отказа не предвидится

Устаревший индекс — типовая проблема ступени

Устаревший индекс — типовая проблема ступени, и эта находка касается не только этого прогона. Векторное хранилище — копия базы на момент, когда её туда положили: живой ссылки на источник оно не держит. Если регламент в исходном документе поменялся, а переиндексация ещё не прошла, хранилище честно находит и отдаёт документ — только устаревший.

Первая строка оси занятия закрыта. Промт целиком: точность — 0,7 на 10, 50 и 200 документах, а стоимость одного ответа за тот же путь растёт в 17,0 раза, с $0,000189 до $0,003204; на 500 документах запрос отклоняется целиком, и предупреждающего сигнала перед этим нет. Внешнее хранилище: стоимость постоянна на всех четырёх размерах, recall@1 — 1,0 на 10/50/200 и 0,9 на 500.

Кейс 2. Разбиение документа на части

Кейс 1 решил, где база будет жить, когда вырастет — в отдельном хранилище, вне промта. Но хранилище принимает текст кусками: трёхстраничный регламент одним куском в него не кладут, и от того, где пройдёт разрез, зависит, сможет ли поиск потом указать на нужное место.

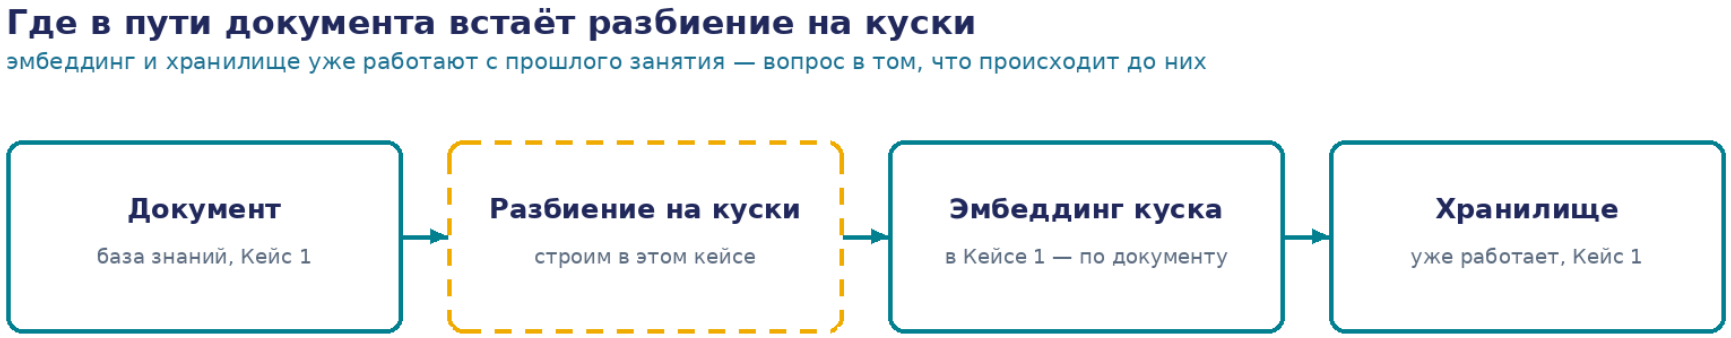
Хранение базы знаний

Разбиение документа на части

Чем искать нужный кусок

Поиск по изображениям

Как резать документ, чтобы кусок не терял смысл



Потребность. Каждый кусок хранилища несёт законченный кусок смысла — ответ на вопрос не должен оказаться разорван между двумя соседними кусками.

Версия 1 — естественная первая попытка: резать документ на части фиксированного размера, по счёту символов, безотносительно к границам предложений.

Один параметр, один проход по тексту. Сработает ли это для смысла — проверяем дальше.

Где должен проходить разрез документа

Где должен проходить разрез документа?

- **резать строго по счёту символов, без оглядки на текст**
- **резать по границам предложений**
- **резать по границам слов**
- **резать по счёту символов с перекрытием**

Два принципиальных способа: по символам и по предложениям

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Резать строго по счёту символов, без оглядки на текст	Документ рубится на части заданной длины без оглядки на текст внутри	Проще всего реализовать — один параметр, один механический проход по тексту	Разрез может прийтись ровно на середину фразы с ответом, независимо от выбранного размера куска; неочевидно заранее, какой размер «удобнее» без проверки
Резать по границам предложений	Разрез проходит только там, где заканчивается одно предложение и начинается следующее	Куски не рвут фразу посередине: разрез идёт по смысловой границе текста — счёт символов тут роли не играет	Чуть сложнее в реализации: нужен отдельный шаг, который понимает, где заканчивается предложение в конкретном языке — простого счёта символов здесь недостаточно; качество этого шага зависит от текста

Два патча над первым способом: по словам и с перекрытием

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Резать по границам слов	Документ делится на слова; кусок копится до целевого размера, разрез проходит только на границе между словами	Не рвёт слово пополам; проще разбора границ предложений — достаточно знать, где кончается слово	Про границу предложения способ не знает: разрез может пройти посередине фразы, даже если ни одно слово не задето
Резать по счёту символов с перекрытием	Та же логика, что резать по счёту символов, но соседние куски перекрываются: конец одного повторяется в начале следующего	Часть ответов, разорванных границей первого действия, попадает целиком в соседний кусок	Хранилище растёт из-за дублирования символов; гарантии для ответа любой длины нет

Перекрытие в замере — 27 символов при куске 180, это 15%: разрез идёт через каждые 153 символа вместо 180.

Цена: кусков выходит примерно на десятую часть больше, и места в хранилище ровно настолько же.

Структура замера: что и на чём проверяли

Корпус. SberQuAD, 60 документов (не короче 500 символов — иначе резать не на что), 72 вопроса с разметкой ответа, проверенной напрямую по тексту.

Находка по пути. У 22,0% строк исходного датасета (1 108 из 5 036) положение ответа не совпадало с текстом документа — такие строки исключены из замера целиком.

Пять групп — один и тот же размер куска для всех четырёх версий: 120 · 180 · 220 · 300 · 450 символов.

180 — основной размер куска: вокруг него строится весь разбор.

Перекрытие — только у четвёртой версии: 27 символов при куске 180, это 15%. У остальных трёх его нет.

Пример. Реальный прогон демо-стенда: документ про кибернетику, 587 символов.

Вопрос: «Из каких источников могут быть потоки информации в определении Гордона Паска?» Эталонный ответ — «из любых источников», позиции 528–547: буквальная подстрока документа на этом месте, её никто не придумывал.

Что считаем «разорван». Разрез куска прошёл внутри этих позиций: ответ оказался в двух разных кусках, и ни один не несёт его целиком — модель получит только половину. Доля таких вопросов — то, что меряет этот замер.

Модели на этом шаге нет. Ни одна из четырёх версий резки не вызывает ни LLM, ни эмбеддинг — все четыре узла «Нарезка» — обычный код.

Модель появится позже, на шаге эмбеддинга готового куска. Что из этого вышло — дальше.

Что показал прогон на пяти размерах куска



В клетках — доля вопросов, у которых разрез куска прошёл внутри эталонного ответа.

72 вопроса, основной размер куска — 180 символов. Версия 1 — 9 разорвано (12,5%), 63 целиком (87,5%). Версия 2 — 1 разорван (1,4%), 71 целиком (98,6%).

РАЗМЕР КУСКА, СИМВОЛОВ	V1 — СЧЁТ СИМВОЛОВ	V2 — ПО ПРЕДЛОЖЕНИЯМ	V3 — ПО СЛОВАМ	V4 — СЧЁТ СИМВОЛОВ + ПЕРЕКРЫТИЕ
120	9,7% (7 из 72)	1,4% (1 из 72)	9,7% (7 из 72)	5,6% (4 из 72)
180 (основной)	12,5% (9 из 72)	1,4% (1 из 72)	8,3% (6 из 72)	5,6% (4 из 72)
220	4,2% (3 из 72)	1,4% (1 из 72)	1,4% (1 из 72)	1,4% (1 из 72)
300	6,9% (5 из 72)	0,0% (0 из 72)	5,6% (4 из 72)	1,4% (1 из 72)
450	2,8% (2 из 72)	1,4% (1 из 72)	0,0% (0 из 72)	0,0% (0 из 72)

Итоговый ответ модели на пяти размерах куска

Что меряем. Итог всей цепочки: поиск среди тех же 60 документов и 72 вопросов, затем `gpt-4o-mini` отвечает по найденным кускам — тот же критерий правильности, что в Кейсе 1.

Все числа — при K=1, когда модель получает один, самый похожий кусок; в таблице доля верных ответов из 72 вопросов.

На основном размере куска 180 символов версия 2 отвечает правильно в 52 случаях из 72 (72,2%) против 41 из 72 (56,9%) у версии 1 — разрыв в 15,3 процентных пункта.

Размер куска влияет не меньше, чем правило резки. Резка по словам на куске в 300 символов — 69,4%; резка по предложениям на куске в 450 — 68,1%.

КУСОК, СИМВОЛОВ	V1 СЧЁТ СИМВОЛОВ	V2 ПРЕДЛОЖЕНИЯ	V3 СЛОВА	V4 С ПЕРЕКРЫТИЕМ
120	52,8%	**72,2%**	50,0%	54,2%
180	56,9%	**72,2%**	55,6%	55,6%
220	61,1%	**69,4%**	66,7%	68,1%
300	66,7%	**77,8%**	69,4%	59,7%
450	62,5%	**68,1%**	65,3%	62,5%

Разрыв между версией 1 и версией 2 при росте K

K — сколько кусков отдают модели: от одного, самого похожего, до пяти. Размер куска — 180 символов, доля верных ответов из 72 вопросов.

ВЕРСИЯ НАРЕЗКИ	K=1	K=2	K=3	K=5
v1 счёт символов	56,9%	59,7%	63,9%	73,6%
v2 предложения	**72,2%**	**83,3%**	**77,8%**	**80,6%**
v3 слова	55,6%	58,3%	63,9%	63,9%
v4 с перекрытием	55,6%	65,3%	66,7%	70,8%

От K=1 к K=5 разрыв сокращается больше чем вдвое, по дороге не убывая ровно. В процентных пунктах: 15,3 при K=1 · 23,6 при K=2 · 13,9 при K=3 · 7,0 при K=5.

Лучший результат версии 2 стоит на K=2 — 83,3% (60 из 72); при K=5 она даёт 80,6% (58 из 72).

Версии 1 нужно пять кусков, чтобы подойти к одному куску версии 2: 73,6% (53 из 72) против 72,2% (52 из 72). Число кусков выросло впятеро, цена вопроса — в 2,4 раза: с 2,6 до 6,0 цента на тысячу вопросов.

Разбор на настоящем документе: где прошёл разрез

Вопрос: «Из каких источников могут быть потоки информации в определении Гордона Паска?»

Документ: «…Гордон Паск расширил определение, включив потоки информации из любых источников, начиная со звёзд и заканчивая мозгом.»

Эталонный ответ — «из любых источников», позиции 528–547.

ВЕРСИЯ	ГДЕ ПРОХОДИТ РАЗРЕЗ РЯДОМ С ОТВЕТОМ	ВЕРДИКТ
Резать по счёту символов (180)	кусок 3 кончается на «…из любых ист», кусок 4 начинается с «очников…» — разрез на 540-м символе прошёл внутри слова	**РАЗОРВАН**
Резать по границам предложений	весь ответ — внутри одного куска [411–587): «…Гордон Паск расширил определение, включив потоки информации из любых источников…»	**ЦЕЛИКОМ**
Резать по границам слов	граница куска стоит ровно на 528-м символе — на самом начале ответа; кусок 4 [528–587) начинается словом «источников» и несёт весь ответ	**ЦЕЛИКОМ**
Резать по счёту символов с перекрытием	перекрытие сдвигает начало последнего куска до 459-го символа; весь ответ (528–547) укладывается внутрь куска [459–587)	**ЦЕЛИКОМ**

Систематическая ошибка версии 1 и почему один документ не отменяет свода

Систематическая ошибка версии 1. Резка по счёту символов не смотрит на текст вообще — граница куска может пройти где угодно, в том числе внутри одного слова.

Здесь 540-й символ документа оказался ровно в середине слова «источников».

Один документ иллюстрирует механизм; вывод на всю выборку даёт свод. На этом документе версии 3 и 4 сохраняют ответ целиком.

Но свод по шестидесяти документам, который мы уже видели, показывает их в среднем заметно хуже версии 2 — 8,3% и 5,6% разорванных ответов против 1,4%.

Вывод. Это не единичная неудача одного документа — свод по шестидесяти документам и семидесяти двум вопросам показывает тот же эффект в среднем.

Версия 1 систематически режет ответы на части, версия 2 — почти никогда.

Что подтвердил замер по каждому из четырёх действий

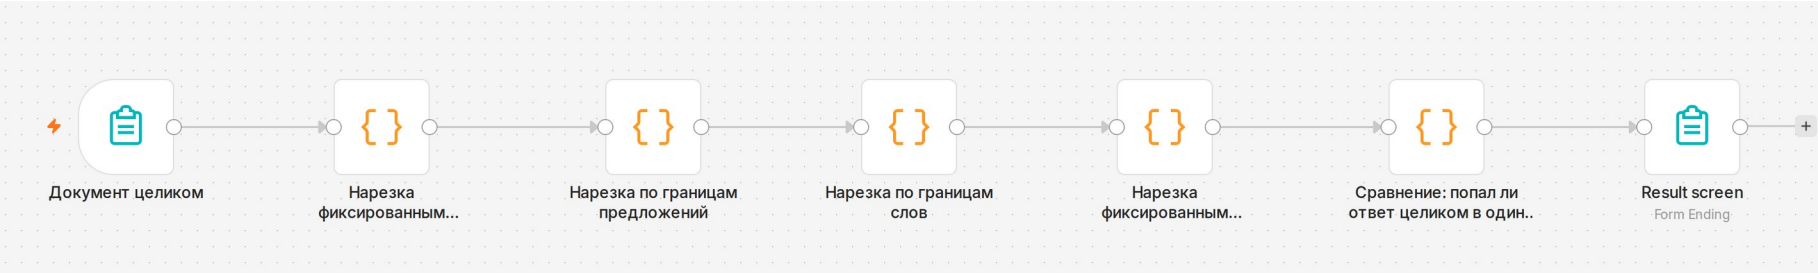
ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Резать по счёту символов	Документ рубится на части заданной длины без оглядки на текст внутри	Проще всего реализовать — один параметр, один проход	Разрывает ответ на вопрос в 2,8–12,5% случаев в зависимости от размера; неочевидно, какой размер «удобнее» без проверки
Резать по границам предложений	Разрез проходит только там, где заканчивается предложение	Доля разорванных ответов падает в разы — почти всегда 0–1,4% на всех проверенных размерах	Чуть сложнее в реализации (нужен разбор текста на предложения — одного счёта символов тут мало); зависит от качества разбивки на предложения в конкретном языке и тексте
Резать по границам слов	Документ делится на слова, кусок копится до целевого размера, разрез только на границе между словами	Дешёвая альтернатива версии 1: держит слово целым и реализуется проще разбора предложений	Разрывает ответ в 0–9,7% случаев: держит границу слова, но не знает о границе предложения
Резать по счёту символов с перекрытием	Та же логика, что версия 1, но соседние куски перекрываются на часть длины куска	Разрывает ответ реже версии 1 — 0–5,6% против 2,8–12,5%	Хранилище растёт от дублирования символов; не закрывает разрыв до уровня версии 2

Где должна проходить граница куска

Граница куска должна совпадать с границей смысла внутри документа — счёт символов тут значения не имеет. Резка, которая режет документ «как придётся», экономит один шаг подготовки и платит за это тем, что часть ответов на будущие вопросы окажется разорвана между двумя кусками.

Это решение не нуждается в модели. Все четыре версии резки — по счёту символов, по границам предложений, по границам слов и по счёту символов с перекрытием — чисто алгоритмические: место границы вычисляется кодом, без обращения к LLM.

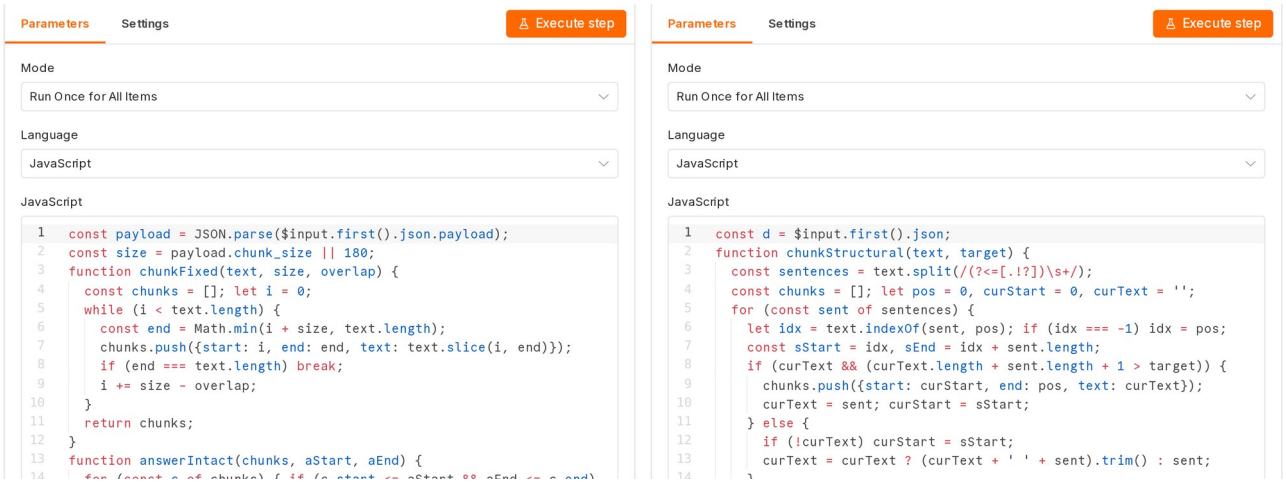
Настоящий холст: сравнение четырёх версий на одном документе



Документ целиком → Нарезка фиксированным размером → Нарезка по границам предложений → Нарезка по границам слов → Нарезка фиксированным размером с перекрытием → Сравнение: попал ли ответ целиком в один кусок → экран результата.

На этом холсте нет шага эмбеддинга и нет записи в хранилище — это отдельный демо-сценарий, который прогоняет все четыре версии нарезки на одном документе и сравнивает их прямо на экране. Шаг эмбеддинга куска (модель `text-embedding-3-small`, Кейс 1) стоит в другом сценарии, после того как кусок уже готов, и не меняется ни одной настройкой от того, какая версия нарезки его подготовила.

Настоящий экран: как устроены два узла нарезки



Нарезка фиксированным размером (слева) читает `payload.chunk_size` (по умолчанию 180), затем в цикле `while (i < text.length)` режет строку кусками по этому числу символов подряд, не глядя на содержимое — после каждого куска сдвигается на `size` символов и повторяет. Нарезка по границам предложений (справа) сначала делит текст на предложения регулярным выражением (граница — после точки, восклицательного или вопросительного знака), затем накапливает предложения в один кусок, пока суммарная длина не превысит `target` символов, — кусок обрывается только на границе предложения, никогда внутри него. Оба узла — обычный код (Code-узел, язык JavaScript, режим «Run Once for All Items»), без единого обращения к модели.

Что видно Ольге, а что — обратившемуся

Обратившемуся результат виден напрямую: если ответ на его вопрос разорван между двумя кусками, модель получает только половину нужного факта и отвечает неполно или неверно: дело тут не в качестве поиска — то, что он нашёл, само по себе было неполным. Ольге видно число — какая доля вопросов рискует получить разорванный ответ при текущей настройке резки.

Принцип общий: применим к любому инструменту резки текста, и узел нарезки в n8n здесь лишь один пример. Кусок хранилища — это единица, внутри которой должен сохраняться смысл; выбор границы разреза прямо определяет, сколько ответов придут целыми, и весит он куда больше, чем обычная техническая настройка.

Размер куска, перекрытие и резка по словам

Размер куска не ведёт себя монотонно сам по себе. У версии 1 доля разорванных ответов не снижается плавно с ростом размера куска: 9,7% → 12,5% → 4,2% → 6,9% → 2,8%. Выбор «удобного на вид» размера не гарантирует качества — требуется проверка на своих данных: чужое эмпирическое правило тут не перенести.

Перекрытие даёт частичный выигрыш. На 180 символах добавленное перекрытие снижает долю разорванных ответов версии 1 почти вдвое — с 12,5% до 5,6%. До уровня версии 2 (1,4%) разрыв не закрывается.

Резка по словам — та же картина. На том же размере доля разорванных ответов снижается с 12,5% до 8,3% — слово защищено от разрыва, предложение всё равно не защищено.

Вторая строка оси занятия закрыта: порезать документ на части МОЖНО как угодно технически — но от этого напрямую зависит, какая доля будущих ответов придёт целой, и дешёвые доработки симптома снижают эту долю, но не убирают её.

Кейс 3. Чем искать нужный кусок

Кейс 2 разрезал документы правильно, по смыслу — счёт символов тут роли не играл. Но правильно нарезанный кусок ещё нужно найти среди сотен таких же, когда приходит конкретный вопрос.

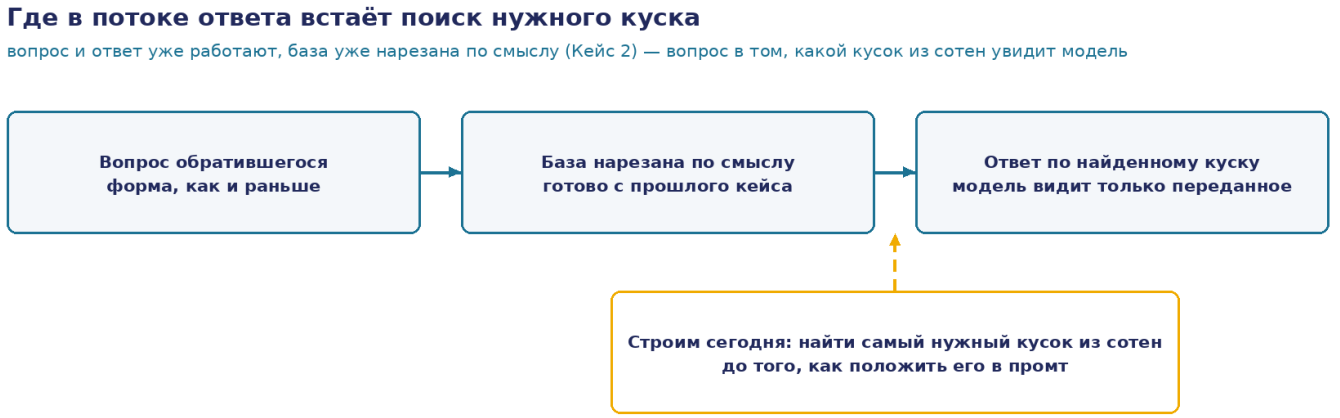
Хранение базы знаний

Разбиение документа на части

Чем искать нужный кусок

Поиск по изображениям

Как найти нужный кусок среди сотен таких же



Потребность. Среди сотен правильно нарезанных кусков базы найти ровно тот, в котором лежит ответ на заданный вопрос — и найти его именно на первом месте выдачи — десятое тут не считается.

Версия 1 — после того, что показали Кейсы 1 и 2 (поиск по смыслу работает, резка по смыслу работает), естественно предположить: искать тоже нужно по смыслу — через векторное сравнение запроса с кусками базы. Кажется, что раз такой поиск понимает смысл вопроса, он заведомо лучше поиска по совпадению слов.

Это и есть интуиция, которую кейс проверяет замером.

Чем искать нужный кусок среди сотен

Чем искать нужный кусок среди сотен?

- **полнотекстовый поиск (по словам)**
- **векторный поиск (по смыслу)**
- **гибридный поиск (слова + вектор)**
- **реранкер (пересмотр моделью)**

Три действия поиска кандидатов: что делает каждое

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Полнотекстовый поиск	Сравнивает слова запроса и слова документа, без модели	Дёшево и быстро: сам поиск ничего не стоит	Смысла не распознаёт: сбивается на вопросе почти без общих слов и на документах одной темы и разной сути
Векторный поиск (по эмбеддингам)	Эмбеддинг запроса сравнивается с эмбеддингами кусков базы по косинусному сходству	Пересказ вопроса своими словами поиску не мешает	Слабее там, где важно точное имя или число: близость эмбеддингов его не гарантирует
Гибридный поиск (RRF)	Два списка сливаются в один формулой Reciprocal Rank Fusion (RRF)	Берёт то, что нашёл хотя бы один из двух способов	Слабый сигнал слов иногда перетягивает итог туда, куда вектор сам бы не пошёл

Где здесь BM25. В промышленных системах совпадение слов считает весовая функция BM25 — редкое общее слово весит в ней больше. У нас весов нет: считается простое пересечение слов, и числа «слов» этого кейса получены так.

Как RRF считает единый список: учебный пример на пяти кандидатах

Формула: очко документа за место в списке = 1 / (60 + место).

Шестьдесят — сглаживающая константа: первое место даёт 1/61 очка, третье 1/63, десятое 1/70 — всего на восьмую часть меньше первого. Очки из обоих списков складываются, наверх выходит наибольшая сумма.

КАНДИДАТ	МЕСТО ПО СЛОВАМ	ЕГО ОЧКО	МЕСТО ПО СМЫСЛУ	ЕГО ОЧКО	СУММА ОЧКОВ	ИТОГ
А	2-е	1/62	4-е	1/64	0,0318	2-е
Б	3-е	1/63	2-е	1/62	**0,0320**	**1-е**
В	4-е	1/64	3-е	1/63	0,0315	3-е
Г	**1-е**	1/61	20-е	1/80	0,0289	4-е
Д	50-е	1/110	**1-е**	1/61	0,0255	5-е

Реранкер: пересмотр готового списка моделью

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Реранкер	После того как список кандидатов уже собран одним или несколькими способами поиска, отдельный вызов модели читает и вопрос, и всех кандидатов целиком, и пересматривает их порядок	Модель видит кандидатов целиком и может отличить нужный документ от похожих соседей там, где статистическое сравнение слов или смысла путается	Отдельный вызов модели — дороже любого из шагов без модели; имеет смысл только тогда, когда список кандидатов уже есть, то есть это шаг поверх уже готового результата — самостоятельным способом искать его не назвать

Как устроен реранкер: би-энкодер и кросс-энкодер



Почему точнее. Векторы посчитаны до вопроса — слова двух текстов в модели не встретятся.

Где это видно. Вопрос про популярные произведения 1984–1986: раздельное кодирование дало верному документу 10-е место из 500, совместное чтение — 1-е.

Структура замера: корпус, метрика, две группы

Корпус. 500 документов SberQuAD, включая 8 путающих кластеров — групп, которые делят одну редкую сущность. Пример: группа «Звёздный» — документ о звездолётах и документ о концертных программах 1980-х; слово общее, вопросы разные.

Что меряем. Попал ли верный документ на первое место (recall@1), в первую тройку (recall@3) и на какой позиции из 500 он стоит в среднем. Метрика одна на все варианты.

ГРУППА	СКОЛЬКО	ПРИМЕР ВОПРОСА	ОЖИДАЕМЫЙ ОТВЕТ	ПОЧЕМУ ЭТА ГРУППА
Лексический разрыв	16	«Когда произошло сражение?»	16 апреля 1746 года	Вопрос и документ почти не делят слов — зона поиска по смыслу
Точное совпадение	16	«Кто в 1395 году принял титул герцога Миланского?»	Джангалеаццо Висконти	Год и титул стоят в тексте буквально — зона поиска по словам

Структура замера: нейтральные вопросы, модель поиска

ГРУППА	СКОЛЬКО	ПРИМЕР ВОПРОСА	ОЖИДАЕМЫЙ ОТВЕТ	ПОЧЕМУ ЭТА ГРУППА
Нейтральные	18	«Чем был обмен по бартеру в торговле?»	Единственной доступной формой торговли	Ни разрыва, ни точного совпадения: общего числа с текстом нет, а слов вопрос и документ делят сколько придётся — от почти нуля до почти всех

Поиск по смыслу считает `text-embedding-3-small` через OpenRouter — та же модель эмбеддинга, что уже работала в Кейсе 1 этого занятия. Сравнение — косинусное сходство со всеми 500 документами, без порога отсечения: ранжируются все, заранее никого не отбрасываем. Результатов на этом кадре нет — дальше смотрим, что получилось.

Что показал прогон на 500 документах и 50 вопросах

Лучший результат по первому месту: поиск по смыслу находит верный документ сразу на 1-м месте в 43 вопросах из 50 (86%).

МЕТОД	RECALL@1	RECALL@3	СРЕДНИЙ РАНГ ВЕРНОГО (ИЗ 500)
Искать по словам	0,74	0,80	9,9
Искать по смыслу (вектор)	0,86	0,92	2,0
Искать обоими, объединить (гибрид, RRF)	0,84	0,94	1,6

Три группы вопросов: доля первых мест и средний ранг

ДОЛЯ ПЕРВЫХ МЕСТ В ГРУППЕ (RECALL@1)	СЛОВА	СМЫСЛ	ГИБРИД
Лексический разрыв (16)	0,25	**0,94**	0,69
Точное совпадение (16)	**1,00**	0,81	0,94
Нейтральные (18)	**0,94**	0,83	0,89

СРЕДНИЙ РАНГ ВЕРНОГО ИЗ 500 (МЕНЬШЕ ЛУЧШЕ)	СЛОВА	СМЫСЛ	ГИБРИД
Лексический разрыв (16)	28,4	1,1	2,8
Точное совпадение (16)	1,0	1,8	1,1
Нейтральные (18)	1,4	2,9	1,1

По recall@1 гибрид не выигрывает ни в одной из трёх групп. Его агрегатные 0,84 складываются из того, что он нигде не худший: в каждой группе есть специалист, который справляется лучше.

Что подтвердил замер по каждому из трёх сигналов

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Искать по словам	Совпадение слов запроса и документа, без модели	Дёшево и быстро — поиск сам ничего не стоит	recall@1 = 0,74 — худший из трёх; если не на первом месте, в среднем на 9,9-й позиции из 500 — лексический разрыв и путающие кластеры сбивают точное совпадение
Искать по смыслу (вектор)	Эмбеддинг запроса сравнивается с эмбеддингами кусков базы	recall@1 = 0,86 — лучший результат среди методов без модели на ранжировании; средний ранг 2,0	recall@3 (0,92) чуть ниже гибрида; слабее там, где важно точное совпадение имени или числа
Искать обоими, объединить (гибрид, RRF)	Два независимых ранжирования сливаются в одно по правилу Reciprocal Rank Fusion	Лучший recall@3 (0,94) и средний ранг (1,6) среди методов без модели на ранжировании	recall@1 = 0,84 — ниже, чем у чистого вектора (0,86). Вопрос из корпуса, дословно: «Пример водных приград?». По смыслу верный документ был 1-м, по словам — 243-м из 500, после объединения — 16-м. Слабый сигнал слов утянул вниз готовый верный ответ

Следующий шаг после гибрида: пересмотр моделью

Обе основы считает `text-embedding-3-small` (поиск по смыслу) — реранкер поверх неё добавляет отдельный вызов `gpt-4o-mini`.

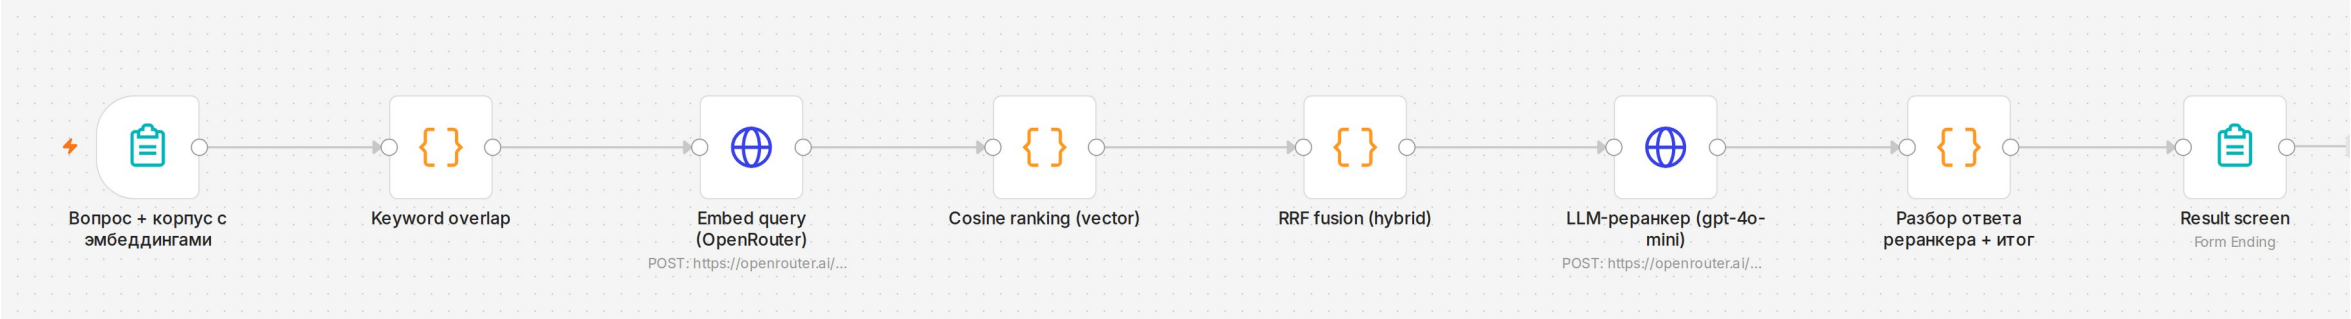
ОСНОВА + РЕРАНКЕР	RECALL@1	RECALL@3	СРЕДНИЙ РАНГ (ИЗ 500)	ЦЕНА ВОПРОСА	ЗАДЕРЖКА
Гибрид + реранкер	**0,96** (было 0,84)	0,98	1,3	$0,00033	+1,6 с
Вектор + реранкер	**0,96** (было 0,86)	0,98	1,5	$0,00033	+1,9 с

Пример исправления. Вопрос «Какие наиболее популярные произведения были созданы на протяжении 1984–1986 гг» — верный документ входит в путающий кластер: чистый вектор нашёл его на 10-м месте из 500, гибрид — на 2-м; реранкер поднял оба варианта на 1-е.

Поиск — объединение минимум двух сигналов

Поиск — объединение минимум двух разных сигналов релевантности: одного сигнала тут мало, прежде чем решать, какой кусок класть в промт. У одного сигнала (слова) своя область, где он выигрывает — точные совпадения, имена, числа; у другого (смысл) — своя — пересказ своими словами. После объединения сигналов — необязательный дополнительный шаг: отдать финальный порядок на пересмотр модели, если цена отдельного вызова и добавленная задержка оправданы ценой ошибки ранжирования.

Настоящий холст: от вопроса до реранкера



Keyword overlap считает ранжирование по словам первым узлом. Дальше — эмбеддинг вопроса и косинусное ранжирование по смыслу. Только когда оба списка готовы, RRF fusion сливает их — и лишь затем, необязательным шагом, в игру входит LLM-реранкер.

Настоящая панель: код узла слияния

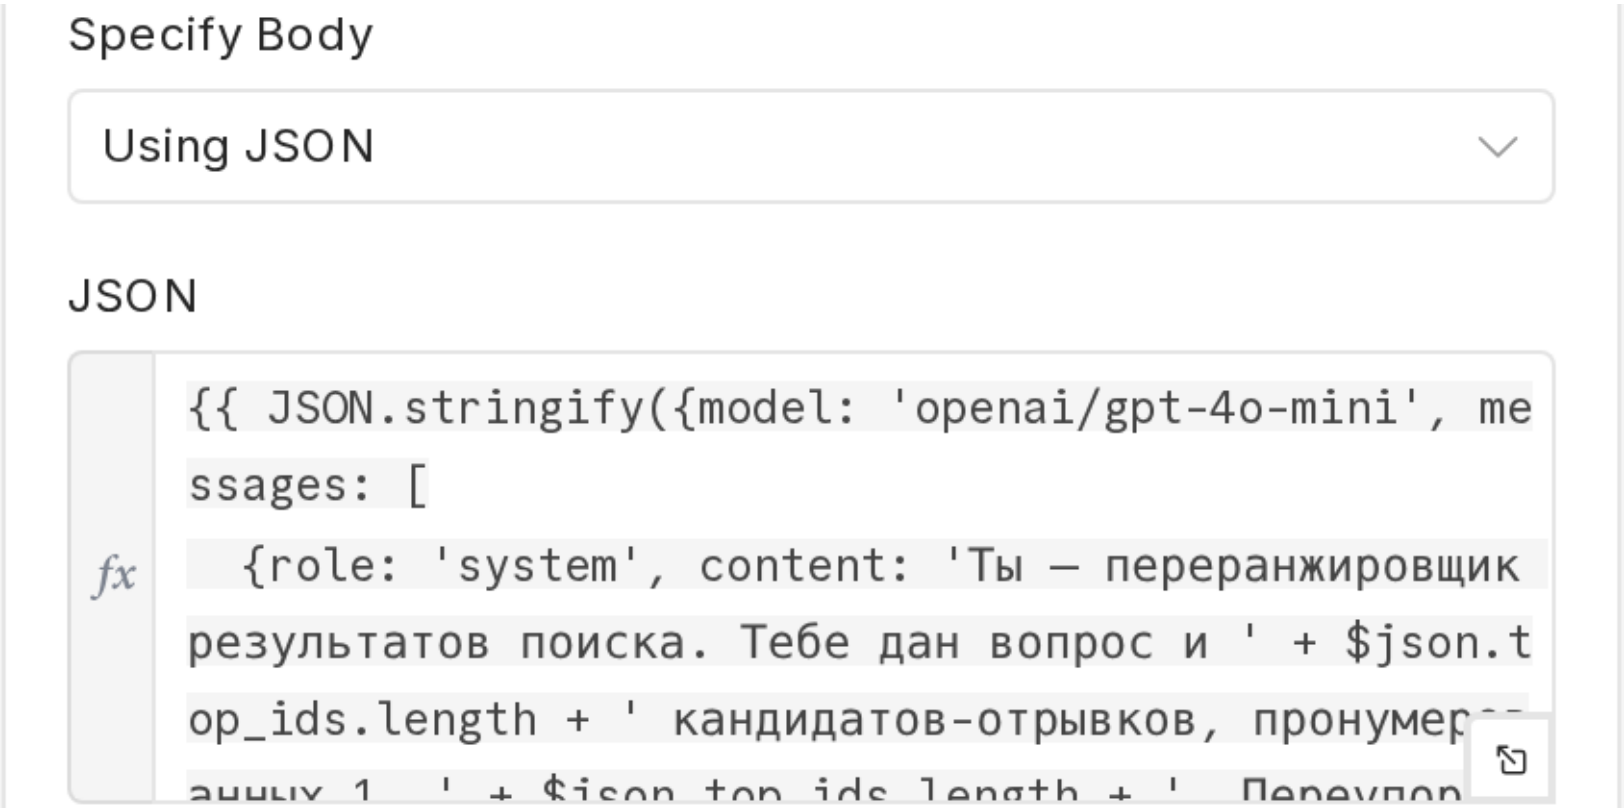
JavaScript

```
1  const d = $input.first().json;
2  function rrf(rankA, rankB, k=60) {
3    const scores = {};
4    [rankA, rankB].forEach(rank => { rank.forEach((id, i) => {
5      scores[id] = (scores[id]||0) + 1/(k+i+1); }); });
6    return Object.keys(scores).sort((a,b)=>scores[b]-scores[a]);
7  }
8  const hybrid_rank = rrf(d.keyword_rank, d.vector_rank, 60);
9  const TOP_N = Math.min(10, hybrid_rank.length);
10 const topIds = hybrid_rank.slice(0, TOP_N);
11 const byId = {}; d.corpus.forEach(c=>byId[c.id]=c.text);
12 const candidatesText = topIds.map((id,i)=>`${i+1}.
   ${byId[id]}`).join('\n\n');
13 return [{json: {...d, hybrid_rank, top_ids: topIds, candidates_text:
   candidatesText}}];
```

Строка 8 — вся идея узла: `rrf(d.keyword_rank, d.vector_rank, 60)`. Два готовых списка складываются в один: чем выше документ в обоих, тем выше в объединённом.

Что делает 60: первое место — 1/61 очка, десятое — 1/70, почти столько же.

Настоящая панель: тело запроса реранкера



> *«Ты — переранжировщик результатов поиска. Тебе дан вопрос и 10 кандидатов-отрывков, пронумерованных 1..10. Переупорядочи номера кандидатов от самого релевантного вопросу к наименее релевантному. Ответь СТРОГО JSON-массивом чисел...»*

Что видно Ольге, а что — обратившемуся

Обратившемуся гибридный поиск виден как более стабильный ответ независимо от того, как именно сформулирован вопрос — точным термином или пересказом своими словами. Ольге видно число: доля вопросов, на которые процесс нашёл верный документ среди первых результатов, выше у гибрида, чем у любого из двух способов по отдельности.

Принцип переносится на любой оркестратор: поиск по смыслу не заменяет поиск по словам и не наоборот — у каждого свой класс вопросов, на которых он сильнее, и объединение обоих результатов не требует заранее знать, какой класс вопроса придёт следующим.

Когда гибрид не нужен

Критерий. Гибридный поиск работает исправно. Его выигрыш виден на большой базе с разнородными формулировками; на небольшой однородной базе узел слияния добавляет сложность без измеримой пользы.

КОГДА НУЖНО

База большая, вопросы формулируются и точными терминами, и пересказом своими словами

Цена ошибки ранжирования высока — обратившийся получит неверный ответ по второму-третьему кандидату

КОГДА НЕ НУЖНО

База маленькая и однородная по формулировкам вопросов

Разница между одним способом и объединением двух на ней не видна

Граница реранкера: выигрыш не на каждом вопросе

Цена пересмотра. $0,00033 за вопрос — дороже всей цепочки Кейса 1 целиком.
Задержка. +1,6 с на основе гибрида, +1,9 с на основе чистого вектора.
Выигрыш. +12 процентных пунктов к recall@1 на гибриде, +10 — на чистом векторе.

ВОПРОС	ОСНОВА	ЧТО СДЕЛАЛ РЕРАНКЕР
Обмен по бартеру в торговле	гибрид	поднял верный документ со 2-го места из 500 на 1-е
Обмен по бартеру в торговле	вектор	не тронул: верный был 26-м, в десятку кандидатов не попал
Пример водных преград	вектор	уронил с 1-го места на 3-е; что встало выше, замер не сохранил

Третья строка оси закрыта: на жёстком корпусе поиск по смыслу чаще находит документ первым, но это зависит от корпуса и вопросов, а объединение сигналов по каждой метрике сразу не побеждает.

Кейс 4. Поиск по изображениям

Прошлое занятие научило процесс читать скан, приложенный к заявке. Сегодня — та же задача хранения и поиска, что в трёх предыдущих разборах, только для сканов: три разбора сошлись гладко, и этот проверяет ожидание прогоном.

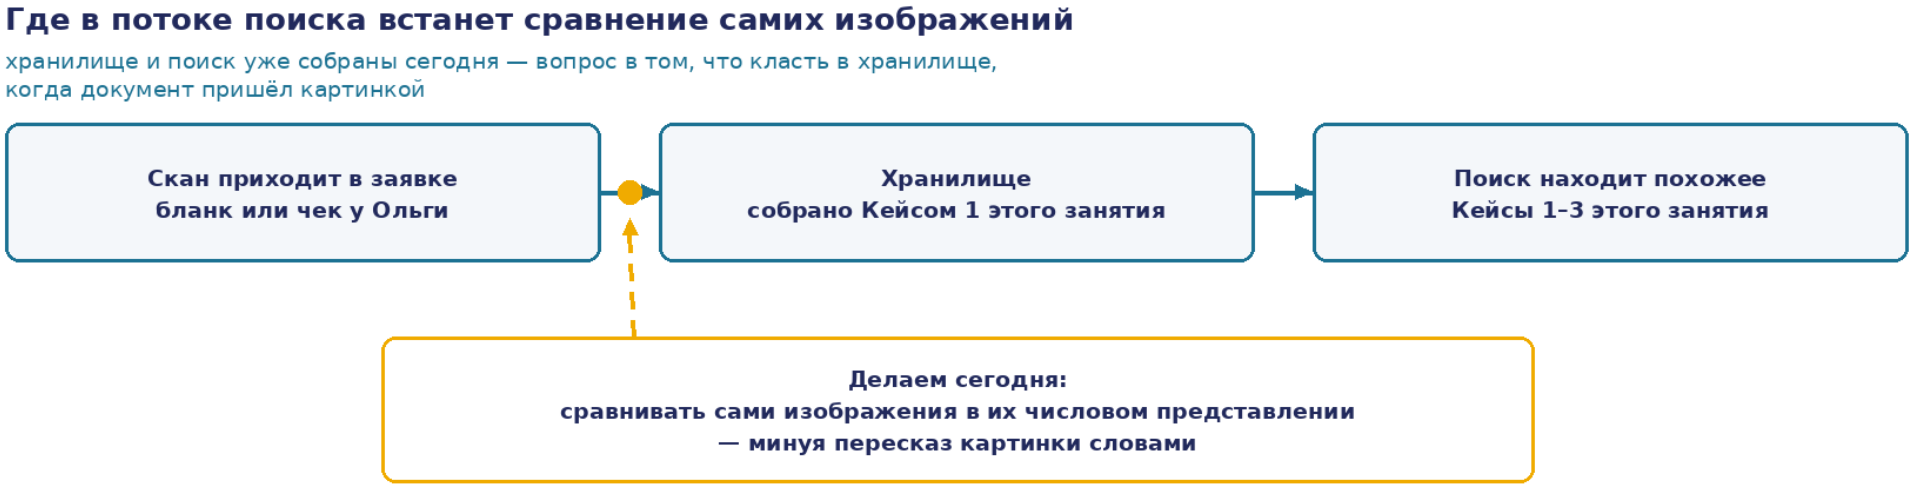
Хранение базы знаний

Разбиение документа на части

Чем искать нужный кусок

Поиск по изображениям

Поиск похожего скана среди прошлых заявок



Потребность. Сканы бланков и чеков приходят регулярно, новая часто похожа на прошлую. Распознанный текст скана ищет механизм трёх разборов; здесь сравниваются сами картинки.

Чем считается ошибка: доля запросов, где нужный скан вышел первым — recall@1. База: 1 из 30 — 0,033.

Из чего выбирают. *Ручной режим и сейчас работает — сравнить глазами;* ***цена одного промаха этим замером не измерена****.*

Как искать похожий скан среди прошлых

Как искать похожий скан среди прошлых?

подписать картинку словами и искать как текст

сравнивать сами картинки одной моделью

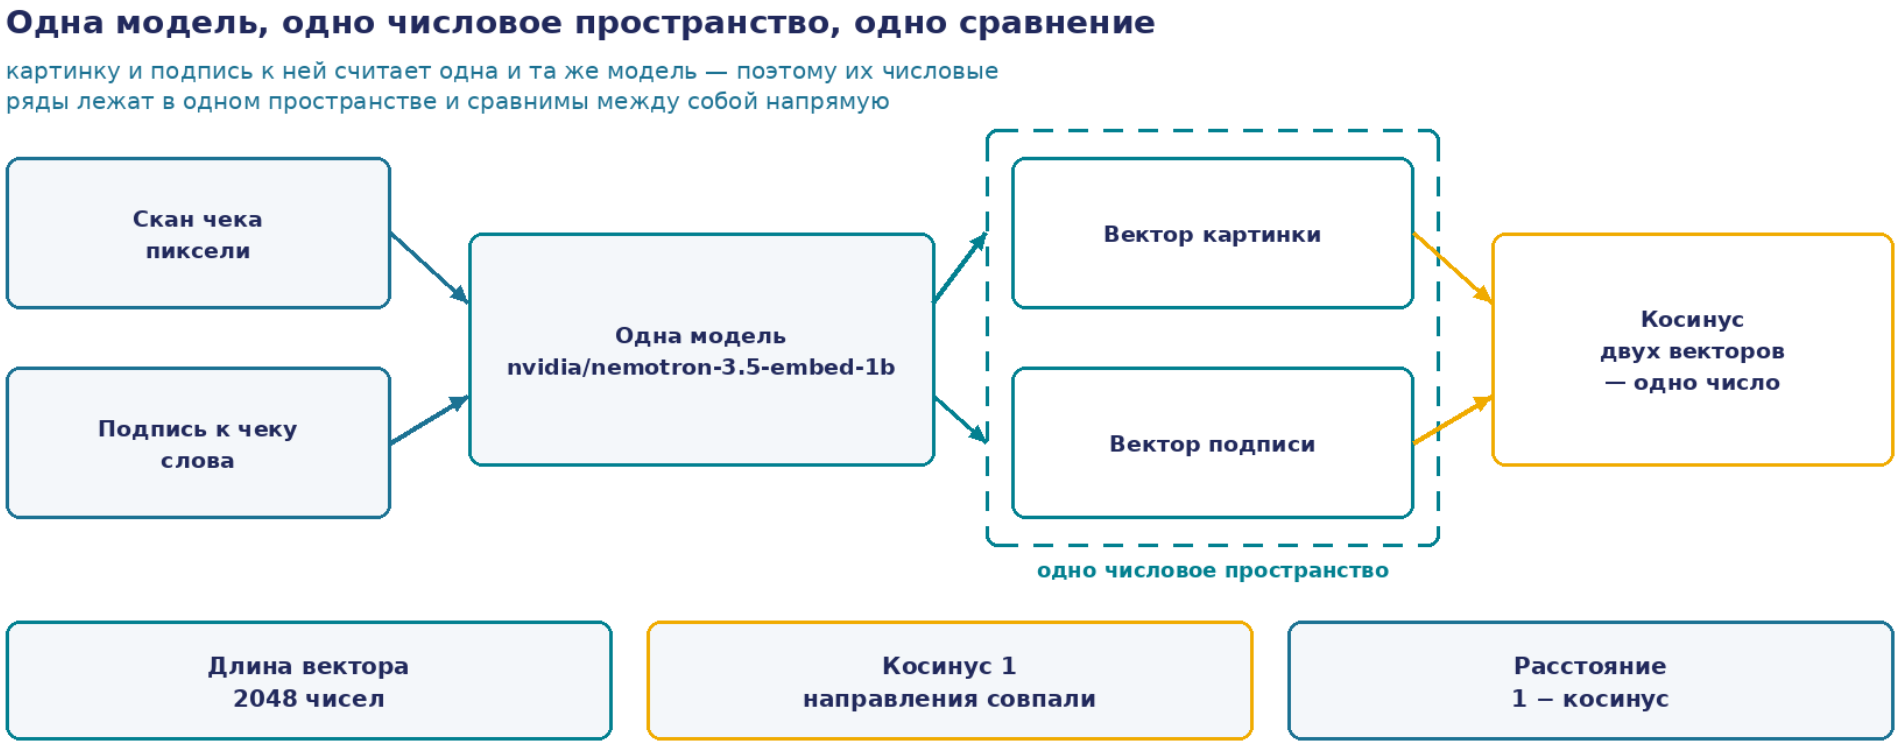
сравнивать картинки по короткому отпечатку, без обращения к модели

Что делает каждое из трёх действий

ДЕЙСТВИЕ	КАК ДЕЛАЕТ	ПРЕИМУЩЕСТВО	НЕДОСТАТКИ
Подписать и искать как текст — **работает**	Распознанный текст чека идёт в тот же эмбеддинг, что в трёх разборах до	Нового узла нет. По содержанию чека — **29 из 30** (0,967)	Вид бланка, печать, пометка теряются до поиска
Сравнивать картинки одной моделью — **работает после отбора двумя проверками**	Модель переводит картинку в числа; сравниваются числа	Повтор под поворотом — **29 из 30** (0,967) против 7 из 30 у отпечатка	Вызов на каждую картинку. Вдвое мелкий снимок — **11 из 30**
Сравнивать по короткому отпечатку — **работает в своём классе**	Картинка сводится к сетке 8 × 8 и к 64 битам	Бесплатно и локально. Пересжатый повтор — **29 из 30** (0,967)	К смыслу нечувствителен: 1 из 30 при случайности 1 из 29. Поворот — **7 из 30**

Оговорка к 0,967 первой строки. *Число измерено на другой задаче: запросом там было название позиции чека, не картинка. Меры «подпись против картинки на одном запросе» у кейса нет.*

Чем сравнивают картинку с картинкой



Эмбеддинг — перевод входа в список чисел постоянной длины; мультимодальный — когда одна модель принимает и текст, и картинку.

Поиск модели и устройство проверки

Модели из плана на стенде нет: `voyage-multimodal-3` не найдена ни под одним написанием имени. Основной каталог отдаёт 468 моделей (замер 12 ноября; восемь дней назад — 453, каталог вырос на 15) и ни одного эмбеддинга; настоящий список — на отдельном, явно не документированном адресе: 40 моделей, из них 9 принимают картинку.

Первый отвечающий кандидат — `amazon/titan-embed-image-v1`: вектор приходит без ошибки, размерность верная. Вызов — `POST /v1/embeddings`, вход строкой `…`, одна пара заведомо разных чеков CORD.

- **300 × 450** — настоящий скан, весь разбор идёт на нём: около **20 500 знаков**
- **128 × 192** — превью: около **5 000 знаков**
- **64 × 96** — мелкое превью: длина строки на этой паре не замерена

Ожидание: два разных чека обязаны дать два разных вектора — косинус обязан отличаться от 1,0.

Что показала проверка на трёх разрешениях

Свод. Ни одно из трёх разрешений не дало надёжного различения. На разрешении настоящего скана модель возвращает битово одинаковый вектор для любых двух разных чеков.

РАЗРЕШЕНИЕ	ВЕРДИКТ	ЧТО ПОКАЗАЛ ТЕСТ
300 × 450 (настоящий скан)	**ПРОВАЛ — ОДИНАКОВЫЙ ВЕКТОР**	косинусное сходство **1,0** до девятого знака для любых двух разных чеков
128 × 192 (превью)	**ПРОВАЛ — ОДИНАКОВЫЙ ВЕКТОР**	косинусное сходство **1,0**, подтверждено отдельной повторной проверкой
64 × 96 (мелкое превью)	**РАЗЛИЧАЕТ ФОРМАЛЬНО, НА УРОВНЕ ШУМА**	корреляция с текстовым сходством по всем 435 парам — **минус 0,077** при возможных значениях от −1 до +1

Контрольный факт: дело в картинке. Тот же адрес с текстовым входом корректно отдаёт разные векторы при любой длине строки. Будь причиной длина входа, испортился бы и текст.

Урок и отбор рабочей модели

Урок кейса. Ответ без ошибки не доказывает, что вход использован: нужны два заведомо разных входа.

МОДЕЛЬ	ЗАПАС	ВЕРДИКТ
`nvidia/nemotron-3.5-embed-1b:free`	**0,593**	**ВЫБРАНА**, цена ноль
`nvidia/llama-nemotron-embed-vl-1b-v2:free`	0,392	рабочая, слабее
`google/gemini-embedding-2`	0,003	**ДЛЯ ПОИСКА БЕСПОЛЕЗНА**
`cohere/embed-5-fast`	−0,007	**ДЛЯ ПОИСКА БЕСПОЛЕЗНА**
`mongodb/voyage-multimodal-3.5`	−0,010	**БЕСПОЛЕЗНА** — наследник модели из плана

Три из пяти провалили проверку на запас: свой пересжатый дубль у них не ближе чужого чека.

Структура замера: тридцать сканов, три группы, два считающих

Корпус. 30 сканов CORD (`naver-clova-ix/cord-v2`) — настоящие чеки с эталонным текстом полей; все лежат в опорном виде 300 × 450 точек, качество 80.

Чем считаем. `nvidia/nemotron-3.5-embed-1b:free` — `POST .../v1/embeddings`, вход картинкой base64, 2048 чисел, близость по косинусу. Рядом классика: отпечаток average-hash 8 × 8, расстояние Хэмминга, бесплатно и локально.

ГРУППА	ЧЕМ СПРАШИВАЕМ	ВЕРНЫЙ ОТВЕТ	СЛУЧАЙНЫЙ ВЫБОР	ЧЕГО ЖДЁМ
1. Повторный скан	уменьшен до 0,97, пересжат	свой оригинал из 30	0,033	находится почти всегда
2. Снято под углом	поворот 12°, обрезка 4%	свой оригинал из 30	0,033	главный вопрос замера
3. Похожесть по смыслу	оригинал без порчи	**другой** чек из 29 — по тексту	0,0345	выше случайности — сигнал есть

Свод: что нашли модель, отпечаток и случайный выбор

Снимок под углом: модель — 29 из 30, отпечаток — 7 из 30. Повторный скан: 30 из 30 против 29 из 30.

СЧИТАЮЩИЙ	1. ПОВТОРНЫЙ СКАН	2. СНЯТО ПОД УГЛОМ	3. ПОХОЖЕСТЬ ПО СМЫСЛУ
`nvidia/nemotron-3.5-embed-1b:free`	**1,000** (30 из 30)	**0,967** (29 из 30)	**0,267** (8 из 30)
Отпечаток average-hash 8 × 8	0,967 (29 из 30)	0,233 (7 из 30)	0,033 (1 из 30)
Поиск по распознанному тексту	не замерено	не замерено	задаёт верный ответ
Случайный выбор — база	0,033	0,033	0,0345

Своё число текстового поиска живёт в другой задаче. Запросом там служит название позиции чека, и чек-источник находится в 0,967 случаев (29 из 30 запросов). Задача другая, поэтому в таблицу выше это число не ставится. Все 30 картинок переведены в векторы без единого отказа.

Разбор: повторный скан и снимок под углом

Повторный скан того же чека: что узнаёт модель и что узнаёт отпечаток

все четыре кадра — настоящие сканы корпуса ровно в том виде, в каком они уходили в модель: 300×450 точек, JPEG



Оригинал
receipt_01 — лежит в индексе



Пересканировали
тот же чек, пережат заново



Сняли под углом
поворот 12°, края обрезаны



Чужой чек
receipt_10 — другой документ

Кого каждый метод назвал ближайшим для третьего кадра — снятого под углом

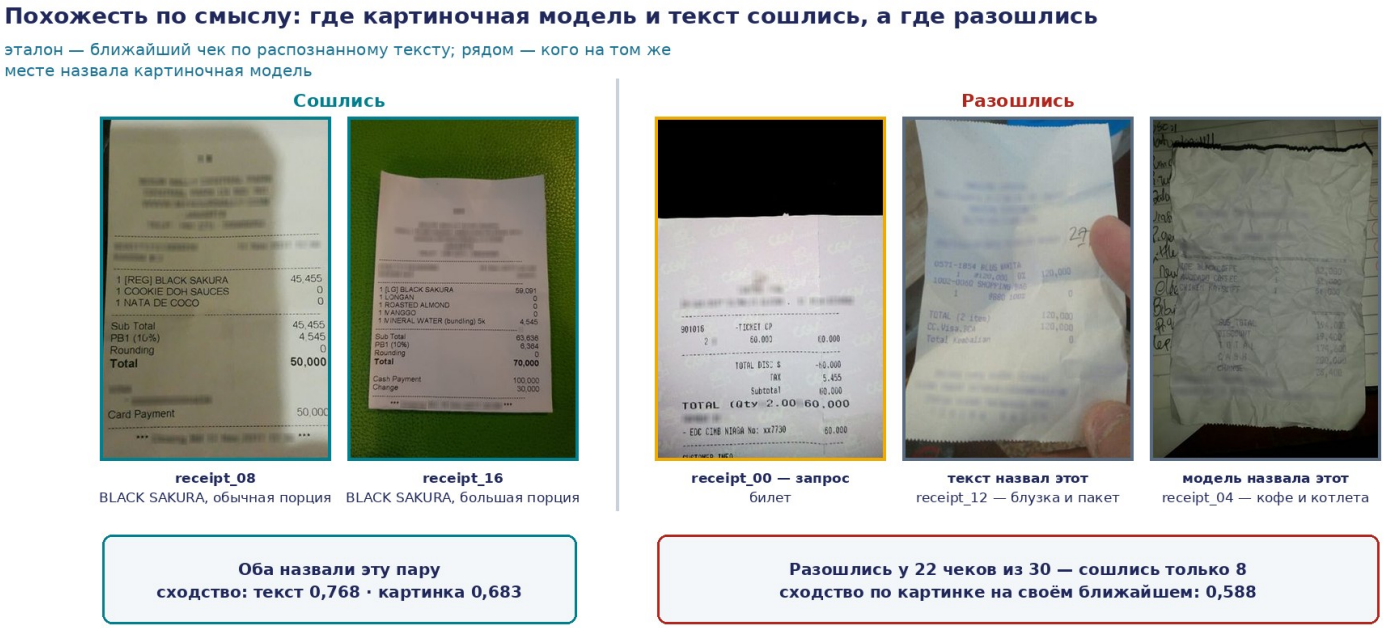
Модель назвала свой оригинал
сходство 0,935 — ближайший из 30

Отпечаток назвал чужой чек
13 бит расхождения из 64

ГРУППА	МОДЕЛЬ	ОТПЕЧАТОК	ВЕРДИКТ
1. Повторный скан	1,000 (30 из 30)	0,967 (29 из 30)	оба **верно** — разница в один скан
2. Снято под углом	0,967 (29 из 30)	0,233 (7 из 30)	модель **верно**, отпечаток **неверно**

Под углом 23 из 30 отпечаток увёл к чужому чеку — в 4,1 раза хуже модели при базе 0,033. Вывод: он ломается на геометрии — модель покупает ровно её.

Разбор: похожесть по смыслу



СЧИТАЮЩИЙ	СОВПАЛО С ТЕКСТОВЫМ ЭТАЛОНОМ	СВЯЗЬ ШКАЛ, 435 ПАР	ВЕРДИКТ
Модель	**0,267** (8 из 30)	**0,529**	сигнал **есть**
Отпечаток	0,033 (1 из 30)	−0,071	сигнала **нет**

Случайность 0,0345: модель выше неё в 7,7 раза, отпечаток стоит на ней. Разошлись 22 чека из 30. Вывод: рабочей по смыслу остаётся подпись словами.

Структура замера границ: что портим и чем считаем

Портится только запрос. 30 оригиналов остаются в хранилище в опорном виде 300 × 450, качество 80. Плохой скан в самом хранилище замером не покрыт.

База всех долей ниже: опорная строка запроса — 21 546 знаков под углом, 20 569 на повторном скане.

Считающих три: `nvidia/nemotron-3.5-embed-1b:free` (2048 чисел, вызов), локальный `openai/clip-vit-base-patch32` (512 чисел, бесплатно) и отпечаток 8 × 8.

По 630 вызовов на каждую модель, отказов ноль; шесть опорных точек из шести повторили числа предыдущего замера.

ЧТО ПОРТИМ	ЧЕТЫРЕ ТОЧКИ, ПЕРВАЯ ОБЩАЯ ДЛЯ ВСЕХ ТРЁХ ОСЕЙ
Сжатие — качество JPEG	**опора: 300 × 450, качество 80** · 50 · 25 · 10
Размер — число пикселей	**опора** · 150 × 225 · 100 × 150 · 64 × 96, качество 80
Размытие по Гауссу	**опора: размытия нет** · радиус 1 · 2 · 3 пикселя

Результат границ: вес файла и число пикселей

Вес файла сжимать можно, пиксели убирать нельзя

один и тот же скан, снятый под углом, — ровно в том виде, в каком он уходил в модель; все три кадра приведены к одному экранному размеру



300×450 точек, качество 80
опорный вид

Вес: 21 546 знаков
Нашёл свой оригинал: 29 из 30



300×450 точек, качество 25
те же точки, сильнее сжат

Вес: 9 183 знака — 43% опоры
Нашёл свой оригинал: 22 из 30
на 7 меньше опорных 29



150×225 точек, качество 80
вчетверо меньше точек

Вес: 7 692 знака — 36% опоры
Нашёл свой оригинал: 11 из 30
на 18 меньше опорных 29

Вес — средняя длина строки запроса по всем 30 сканам; на кадре один из них.
Уменьшенный кадр увеличен обратно соседним пикселем, без досочинения деталей. Индекс во всех трёх прогонах лежит в опорном виде — меняется только запрос.

При почти одинаковой экономии веса исход разный: качество 25 — 43% веса и 22 попадания из 30, кадр 150 × 225 — 36% веса и 11 из 30, при опорных 29 из 30.

Где ломается каждая ось. Сжатие — на качестве 10: 0,467 против опорных 0,967, и запас впервые уходит в минус. Размер — уже на 150 × 225, вдвое меньшем кадре, который человек ещё читает. Размытие — между радиусом 1 и 2: 0,767 и 0,200.

Перекрёст: где бесплатный отпечаток обгоняет модель

ВХОД	ОТПЕЧАТОК, БЕСПЛАТНО	МОДЕЛЬ, ЗА ВЫЗОВ	ВО СКОЛЬКО РАЗ
Повторный скан, уменьшен до 64 × 96	**0,933** (28 из 30)	0,167 (5 из 30)	5,6 за отпечаток
Повторный скан, размытие 3 пикселя	**0,967** (29 из 30)	0,133 (4 из 30)	7,3 за отпечаток
Снимок под углом, опорный вид	0,233 (7 из 30)	**0,967** (29 из 30)	4,1 за модель

Отпечаток держит ровную линию во всех 12 точках: 0,933–0,967 на повторном скане и 0,200–0,233 под углом. Average-hash сам сводит любой вход к сетке 8 × 8, и порча до него почти не доходит.

Вывод. Модель держит геометрию и сыпется на порче входа; отпечаток держит порчу и сыпется на геометрии — поэтому в решении стоят оба.

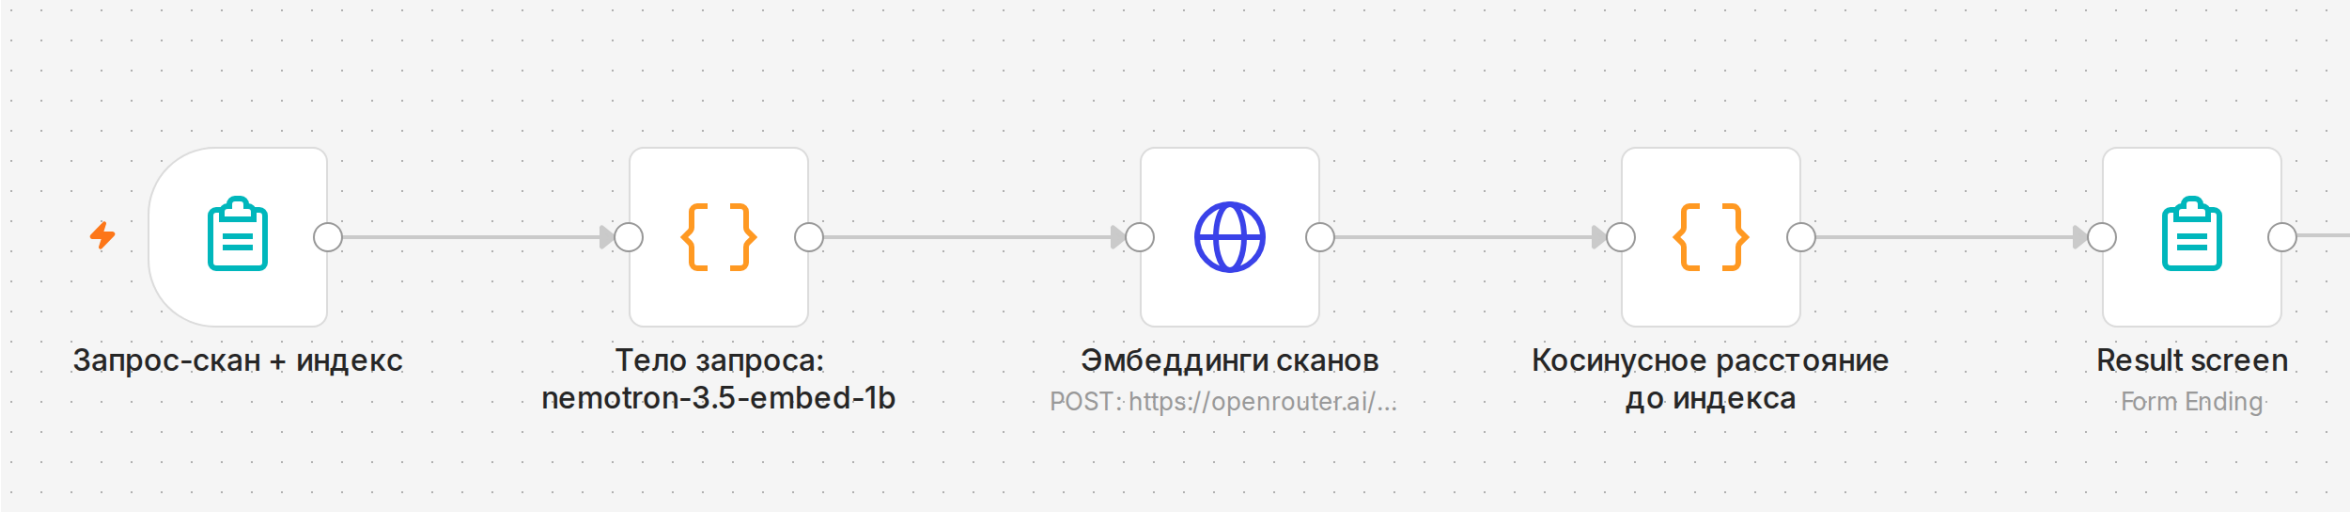
Решение: две величины на каждый скан

Хранилище держит по каждому скану две величины: числовое представление самой картинки от одной модели и короткий отпечаток её облика, посчитанный на своей машине. Поиск идёт двумя запросами: малое расстояние отпечатка — «это тот же документ», высокое сходство векторов — «это похожий». Какой ответ показать Ольге, решает правило процесса. Смысл держит третья величина — подпись: 29 из 30 против 8 из 30 у картинки.

Два последних числа измерены на разных задачах: меры «подпись против картинки на одном запросе» у кейса нет.

ЧТО УЕХАЛО ВПРАВО ВМЕСТЕ С МОДЕЛЬЮ	ЧЕМ ПЛАТИМ — С БАЗОЙ
Смена модели — пересчёт индекса	30 вызовов на тридцати сканах, миллион на миллионе
Объём против отпечатка	8 КиБ против 8 байт — **8,19 ГБ против 8 МБ** на миллион
Требование ко входу	Вдвое мельче опорных 300 × 450 — 0,967 → **0,367**
Задержка и внешний отказ	**1,13 с** на вызов, два отказа свободного тарифа

Настоящий холст: пять узлов от запроса до выдачи



Индекс считается тем же вызовом. Вектор этой модели — 2048 чисел; пять сканов индекса, положенные в узел константой, дали бы около 200 КБ нечитаемых цифр. Один вызов на обе стороны показывает то, что разбор обязан показать: сравниваются величины, полученные **одной** моделью через **один** адрес. Чего эта форма не показывает: в работе индекс считают один раз и кладут в векторную базу.

Настоящая панель: код узла сравнения

```
// Косинусное расстояние эмбеддингов — то, что сравнивается в этом кейсе.
// cos = 1 → векторы совпали по направлению; расстояние = 1 − cos.
function cos(a, b) {
  let dot = 0, na = 0, nb = 0;
  for (let i = 0; i < a.length; i++) { dot += a[i]*b[i]; na += a[i]*a[i]; nb += b[i]*b[i]; }
  return dot / (Math.sqrt(na) * Math.sqrt(nb));
}
const prep = $('Тело запроса: nemotron-3.5-embed-1b').first().json;
const resp = $input.first().json;
if (!resp.data) { throw new Error('эндпоинт не вернул векторы: ' + JSON.stringify(resp).slice(0, 300)); }
const vectors = resp.data.map(d => d.embedding);
const qvec = vectors[0];                        // вектор запроса
const indexVectors = vectors.slice(1);          // векторы проиндексированных сканов
const ranked = indexVectors
  .map((v, i) => { const s = cos(qvec, v); return {label: prep.labels.index[i], similarity: s, distance: 1 - s}; })
```

Восемь строк арифметики без единой библиотеки: сумма произведений, поделённая на произведение длин. Модель — `nvidia/nemotron-3.5-embed-1b:free`, литералом на соседней панели. Панель показывает **настройку** узла, а не состояние прогона.

Что видно Ольге и что — обратившемуся

Живой прогон холста. Запрос — скан чека, пересобранный поворотом на 12 градусов; индекс — пять оригиналов. Ближайший найден верно: сходство 0,9287, отрыв от второго 0,3572. Демо-экран механики, не замер: числа разбора живут в замере на тридцати сканах.

ВОПРОС О ДВУХ СКАНАХ	ЧЕМ РЕШАЕТСЯ — И ПОЧЁМ
«Такой же тип бланка»	Подпись и текстовый поиск — **29 из 30** (0,967) против 8 из 30 у картинки
«Тот же документ, переснятый»	Отпечаток, бесплатно и на своей машине — **29 из 30** (0,967)
«Тот же, но снятый под углом»	Модель `nvidia/nemotron-3.5-embed-1b:free`, за вызов — **29 из 30** (0,967) против 7 из 30

Оговорка к первой строке. *Подпись и картинка измерены на разных задачах: у подписи запросом было название позиции чека, у картинки — согласие с текстовым эталоном. Меры «подпись против картинки на одном запросе» у кейса нет.*

Хранение и индексация: когда сканов не тридцать

Внешняя практика: на этом стенде индекс не строился, векторы не сжимались, база не поднималась.

Порог, ниже которого индекса нет вовсе. Qdrant не строит индекс, пока в сегменте меньше 10 000 КиБ векторов: для вектора на 2048 чисел это примерно 1250 векторов — в сорок раз больше корпуса разбора.

МОДЕЛЬ	ИЗМЕРЕНИЙ	НА МИЛЛИОН КАРТИНОК	ИНДЕКС PGVECTOR ПО ТИПУ VECTOR
CLIP	512	2,05 ГБ	берёт
Модель разбора	2048	**8,19 ГБ**	**не берёт — предел 2000**

Отпечаток лежит своим типом — двоичное поле на 64 бита с расстоянием Хэмминга.

Слияние сигналов на картинках: замер на тридцати сканах

Устройство. 30 сканов, два дубля; слияние — тот же RRF, k = 60 из узла Кейса 3. 91 вызов, 107,7 с, отказов ноль.

ЗАМЕР	ОДИН СИГНАЛ	ВТОРОЙ СИГНАЛ	СЛИЯНИЕ
Снимок под углом	вектор **0,967**	отпечаток 0,233	**0,600**
Пересканировали	вектор **1,000**	отпечаток 0,967	**1,000**
Смысловая задача	картинка 0,267	подпись 1,000 — тавтология	**0,700** · испорчено 9 из 30

Поштучно: под углом сброшено 12 верных из 29, выручен 1 — минус 11 сканов из 30.

Внешняя практика (здесь не проверялась): приём другой — объединение первых пяти из каждого списка, картинка с текстом рядом: точность@10 — текст 0,406, картинка 0,275, объединение 0,479. Картинку-запрос не берёт ни один из четырёх размещённых API реранка; у `jina-reranker-m0` — локально.

Два кандидата прямого сравнения картинок

НА СВОЕЙ МАШИНЕ

`openai/clip-vit-base-patch32`

Повторный скан — **30 из 30**

Снято под углом — 23 из 30

Смысловая задача — 4 из 30

Повторный скан мельче вдвое — **30 из 30**

Он же в размытии 2 и 3 пикселя — **17 и 11 из 30**

Минута на установку, **3,1 ГБ** на диске, **0,12 с** на картинку, сети нет

ЗА ВЫЗОВ

`nvidia/nemotron-3.5-embed-1b:free`

Повторный скан — **30 из 30**

Снято под углом — **29 из 30**

Смысловая задача — **8 из 30**

Он же мельче вдвое — 18 из 30

Он же в размытии 2 и 3 пикселя — 13 и 4 из 30

1,13–1,56 с на вызов — сетевой круг и зависимость от каталога

Доля попаданий на первое место, 30 сканов. Геометрию — снимок под углом — держит модель за вызов, и запас у неё вдесятеро больше: 0,244 против 0,0235. Порчу входа — уменьшенную и пережатую картинку — держит своя машина. Обе модели нейросетевые, и одна опорная цифра этого перевеса не показывает.

Когда прямое сравнение картинок нужно и когда нет

КОГДА НУЖНО

Ищется буквальный повтор документа, снятый заново под углом: **0,967** против 0,233 у отпечатка

Вход приходит в опорном виде — не мельче 300 × 450 и без размытия от 2 пикселей

Модель прошла обе проверки на вашем корпусе: разный вход — разный выход, свой дубль ближе чужого документа

КОГДА НЕ НУЖНО

Вопрос «тот же ли это файл» при неизменной геометрии: отпечаток делает это бесплатно, 0,967 против 1,000

Вход заведомо мелкий или смазанный: там отпечаток обгоняет модель в **5,6–7,3 раза**

Задача смысловая: подпись и текстовый поиск дают **29 из 30** против 8 из 30 у картинки — каждое число на своей задаче, общей меры у кейса нет

Предел подхода — чужой замер: на документах-картинках один вектор на страницу проигрывает многовекторному, 17,7 у Jina-CLIP против 81,3 у ColPali, ценой 264 ГБ на миллион страниц против 8.

Четвёртая строка оси закрыта. Подпись теряет облик документа, а на повороте этот облик — всё, что осталось. Отпечаток не ушёл в прошлое: ломается он на другом входе. А прямое сравнение работает — после отбора: из 9 моделей каталога прошла одна, и она держит 29 из 30 на снимке под углом.

Релевантно ≠ верно

Четыре кейса сегодня учили находить нужный кусок базы знаний и класть его в промт перед ответом. Всё это время за кадром стоял не проверенный явно допуск: раз система нашла кусок, топически относящийся к вопросу, значит ответ на его основе окажется верным.

Случай 1. Google AI Overviews и совет про пиццу

В 2024 году функция обзоров с помощью ИИ в поиске Google несколько раз выдавала пользователям советы, взятые из источников, которые по форме звучали как достоверные, а по содержанию были шуткой: один из широко обсуждавшихся случаев — рекомендация добавлять нетоксичный клей в соус для пиццы, источником которой оказался старый шуточный комментарий на интернет-форуме.

Система нашла текст, который действительно был об этом — про сыр, про пиццу, про то, как сделать её менее текучей. По меркам поиска — успех: релевантность высокая. По меркам ответа пользователю — провал: источник оказался шуткой — кулинарной рекомендацией он не был.

Случай 2. Чат-бот городской администрации Нью-Йорка

Отдельный, документированный журналистским расследованием случай 2024 года: городской чат-бот Нью-Йорка, созданный в помощь владельцам малого бизнеса, на прямые вопросы о городских правилах несколько раз выдавал уверенные, грамматически безупречные ответы, которые были юридически неверны или напрямую противоречили закону города — например, бот говорил, что можно забирать себе чаевые сотрудников, и что можно отказывать арендаторам с жилищными субсидиями.

Оба случая технически сработали правильно: нашли релевантный по теме текст и построили на его основе грамматически корректный ответ. Провал сидит в допущении, что тематическая близость равна фактической верности — механика поиска тут ни при чём.

Почему это касается всех четырёх кейсов сегодня

Ни Кейс 1 (хранение), ни Кейс 2 (резка), ни Кейс 3 (поиск), ни Кейс 4 (поиск по изображениям) не застрахованы от этого автоматически самим фактом, что они используют поиск вместо того, чтобы передавать модели весь объём данных целиком. Поиск, который правильно нашёл наиболее похожий по смыслу фрагмент — ровно то, что измеряли метрики recall и ранг во всех четырёх кейсах, — отвечает только на вопрос «это похоже на то, что спросили» — вопрос «это верно» он не затрагивает.

Это не повод отказаться от поиска по базе знаний — отказ вернул бы занятие к промт-стаффингу, который Кейс 1 уже показал невыгодным при росте базы. Это повод для отдельного шага, который следующие занятия этой дуги строят отдельно: оценка качества и выключатель для ответа, построенного на найденном материале.

Четыре строки оси: чем оказалось

ВЫГЛЯДИТ НАДЁЖНЫМ	ЧЕМ ОКАЗЫВАЕТСЯ
если база выросла — просто перечислим её всю в промте, как на C9	Accuracy держится на одном уровне (~0,7 на 10/50/200) без предупреждающего сигнала, стоимость при этом растёт ×17,0 — а на 500 документах запрос физически отклонён (HTTP 400, контекст превышен); keyword держит recall@1=0,8 на всех размерах, vector — 1,0 на 10/50/200 и 0,9 на 500, ~$0,00005 на любом размере
порезать документ на части можно как угодно, главное чтобы кусок попал в хранилище	Резка по символам рвёт ответ в 2,8–12,5% случаев; резка по предложениям — почти всегда 0–1,4%; «удобный на вид» размер не гарантирует качества без проверки на своих данных
поиск по смыслу (вектор) и так находит то же самое, что поиск по словам, только умнее	На жёстком корпусе вектор обгоняет слова по recall@1 (0,86 vs 0,74) — но объединение сигналов не побеждает по каждой метрике разом; реранкер поднимает recall@1 до 0,96 ценой отдельного вызова модели и собственных ошибок
если умеем искать текст — картинку найдём тем же способом, просто подписав её словами	Подпись теряет облик документа, а под углом он — всё, что осталось: прямое сравнение картинок держит recall@1=0,967 против 0,233 у отпечатка — но лишь после отбора модели двумя проверками, из 9 принимающих картинку прошла одна

Откуда процесс берёт факты и почему считает их верными?

Счёт занятия: что измерено, что осталось непроверенным

Четыре кейса, каждый на собственных прогонах стенда и на реальных данных — SberQuAD для текста (Кейсы 1-3), CORD для изображений (Кейс 4). Ни один кейс не стоит на придуманном числе. Отрицательные результаты показаны как есть: первая же найденная модель Кейса 4 отвечала без ошибки и возвращала одинаковый вектор для разных чеков — рабочую отобрали двумя проверками, одну из девяти; слияние рангов, выигравшее в Кейсе 3, на картинках потеряло 11 сканов из 30.

Хранилище (Кейс 1) экономит на стоимости ответа, но добавляет шаг подготовки данных и риск устаревшего индекса — копия базы не обновляется сама, когда меняется источник. Резка по смыслу (Кейс 2) точнее резки по счёту символов, но чуть сложнее в реализации и зависит от качества разбивки текста на предложения. Гибридный поиск (Кейс 3) надёжнее одного способа, но стоит лишнего шага вычисления и слияния на каждый запрос — и не оправдан на маленькой однородной базе; реранкер добавляет ещё один платный шаг сверху. Поиск по изображениям (Кейс 4) там, где он действительно нужен, требует отдельно проверенного компонента под каждый класс похожести — и ни один удобный универсальный ответ не оказался готов к использованию без собственной проверки.

Что дальше

Может ли процесс не только отвечать, но и действовать от имени компании?

Вопрос, с которого начался прошлый семинар («может ли процесс отвечать обратившемуся сам»), и вопрос, с которого начался сегодняшний («откуда процесс берёт факты»), вместе подводят к следующему шагу ступенчатой дуги курса: что происходит, когда процессу дают не только знание, но и полномочие — право не просто предложить ответ, но и совершить действие от имени компании.

И то, чего сегодняшнее занятие не чинит: разбавитель этого дня — «найдено» ≠ «верно» — сам не закрывается ни выносом базы наружу, ни правом действовать. Это отдельная ступень: оценка качества и выключатель, дальше по дуге.